

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



**KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC**

**DỰ BÁO TỶ GIÁ USD/VND BẰNG CÁC MÔ HÌNH HỌC
MÁY (MACHINE LEARNING)**

NGÀNH: TÀI CHÍNH – NGÂN HÀNG
SỐ: 7340201

VƯƠNG NHẬT TRIỀU

TP. HỒ CHÍ MINH, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

DỰ BÁO TỶ GIÁ USD/VND BẰNG CÁC MÔ HÌNH HỌC
MÁY (MACHINE LEARNING)

NGÀNH: TÀI CHÍNH – NGÂN HÀNG
SỐ: 7340201

Họ và tên sinh viên: VƯƠNG NHẬT TRIỀU
Mã số sinh viên: 050610220662
Lớp sinh hoạt: HQ10 – GE30

NGƯỜI HƯỚNG DẪN KHOA HỌC
PGS.TS. NGUYỄN MINH NHẬT

TP. HỒ CHÍ MINH, NĂM 2026

TÓM TẮT

Nghiên cứu này được thực hiện nhằm giải quyết nhu cầu về một công cụ dự báo tỷ giá hối đoái USD/VND hiệu quả và linh hoạt, có khả năng thích ứng với bối cảnh thị trường phức tạp, chịu tác động mạnh mẽ từ các yếu tố vĩ mô quốc tế và trong nước. Mục tiêu cốt lõi của Luận văn là tiến hành đánh giá so sánh toàn diện hiệu suất dự báo giữa các mô hình truyền thống (Kinh tế lượng) và các mô hình tiên tiến (Học máy và Học sâu), cụ thể là mô hình ARIMA, các mô hình Học máy (Random Forest, XGBoost) và mô hình Học sâu (LSTM). Dữ liệu được sử dụng là chuỗi thời gian đa biến, tích hợp tỷ giá quá khứ cùng với bốn yếu tố vĩ mô quan trọng được xác định qua phân tích cơ sở lý thuyết. Mặc dù các mô hình Học máy truyền thống đã thất bại hoàn toàn, các mô hình ARIMA và LSTM đã tạo ra một mâu thuẫn học thuật quan trọng: ARIMA thể hiện độ chính xác tương đối cao trong việc dự báo mức giá trung bình, trong khi LSTM chứng minh được ưu thế cấu trúc khi là mô hình duy nhất bắt được Xu hướng Tăng giá và có khả năng mô hình hóa mối quan hệ phi tuyến tính và đa biến giữa tỷ giá và các yếu tố kinh tế. Nghiên cứu kết luận rằng LSTM là mô hình tối ưu nhất về mặt cấu trúc và tiềm năng ứng dụng để dự báo chiến lược, và khuyến nghị các tổ chức tài chính tại Việt Nam tập trung vào việc phát triển các mô hình Học sâu để nâng cao chất lượng quản lý rủi ro và ra quyết định.

Từ khóa: Tỷ giá USD/VND, ARIMA, LSTM, Dự báo chuỗi thời gian, yếu tố vĩ mô.

ABSTRACT

This study is conducted to address the growing need for an effective and flexible forecasting tool for the USD/VND exchange rate, capable of adapting to a complex market environment shaped by both domestic and international macroeconomic forces. The core objective of the thesis is to perform a comprehensive comparative assessment of forecasting performance between traditional econometric models and advanced machine learning and deep learning approaches, specifically ARIMA, Random Forest, XGBoost, and LSTM. The dataset employed is a multivariate time series integrating historical exchange rates with four key macroeconomic factors identified through theoretical analysis. While conventional machine learning models completely failed to produce meaningful forecasts, the ARIMA and LSTM models revealed an important academic contradiction: ARIMA demonstrated relatively strong accuracy in predicting the average price level, whereas LSTM showed clear structural advantages as the only model capable of capturing the upward trend and modeling the nonlinear and multivariate relationships between the exchange rate and economic indicators. The study concludes that LSTM is the most structurally optimal and practically promising model for strategic forecasting, and recommends that financial institutions in Vietnam prioritize the development of deep learning-based forecasting systems to enhance risk management and decision-making.

Keywords: USD/VND exchange rate, ARIMA, LSTM, Time Series Forecasting, Macroeconomic Factors.

LỜI CAM ĐOAN

Tôi tên là Vương Nhật Triều

Lớp: HQ10-GE30

Khoa: Tài chính-Ngân hàng

MSSV: 050610220662

Khóa luận tốt nghiệp này là công trình nghiên cứu, tìm hiểu của tôi do chính bản thân thực hiện dưới sự hướng dẫn của PGS.TS. Nguyễn Minh Nhật. Nghiên cứu này là trung thực và chưa từng được công bố trước đây. Các nguồn tham khảo đã được trích dẫn để dễ dàng cho công tác kiểm tra.

Tôi xin chịu trách nhiệm trước Nhà trường và Thầy Cô về cam đoan của bản thân.

Tác giả

VƯƠNG NHẬT TRIỀU

LỜI CẢM ƠN

Tôi xin gửi lời cảm ơn chân thành đến quý Thầy Cô Trường Đại học Ngân hàng TP. Hồ Chí Minh đã tận tình giúp đỡ, truyền đạt cho tôi những kiến thức đáng giá để tôi có thể hoàn thành khóa luận tốt nghiệp của mình.

Đặc biệt tôi xin gửi lời cảm ơn sâu sắc đến PGS.TS. Nguyễn Minh Nhật đã tận tình hướng dẫn, giúp đỡ và luôn tạo điều kiện tốt nhất để tôi có thể hoàn thành bài nghiên cứu của mình một cách trọn vẹn.

Với năng lực hạn hẹp, nguồn kiến thức chưa được phong phú và kinh nghiệm chuyên môn còn hạn chế nên không tránh khỏi sẽ có thiếu sót. Tôi rất mong được sự đóng góp chân thành của Thầy Cô.

Tôi xin chân thành cảm ơn!

MỤC LỤC

Nội dung	Trang
MỤC LỤC	v
DANH MỤC CHỮ VIẾT TẮT	viii
DANH MỤC BẢNG BIỂU – HÌNH VẼ.....	x
CHƯƠNG 1: GIỚI THIỆU.....	1
1.1. LÝ DO CHỌN ĐỀ TÀI.....	1
1.2. MỤC TIÊU NGHIÊN CỨU	3
1.2.1. Mục tiêu nghiên cứu tổng quát	3
1.2.2. Mục tiêu nghiên cứu cụ thể.....	3
1.3. CÂU HỎI NGHIÊN CỨU	3
1.4. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU	4
1.4.1. Đối tượng nghiên cứu	4
1.4.2. Phạm vi nghiên cứu.....	4
1.5. PHƯƠNG PHÁP NGHIÊN CỨU	5
1.6. ĐÓNG GÓP CỦA ĐỀ TÀI	5
1.7. CẤU TRÚC CỦA ĐỀ TÀI.....	6
KẾT LUẬN CHƯƠNG 1	8
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU.....	9
2.1. CƠ SỞ LÝ THUYẾT VỀ TỶ GIÁ HỐI ĐOÁI VÀ YẾU TỐ TÁC ĐỘNG.....	9
2.1.1. Khái niệm và Vai trò của Tỷ giá hối đoái USD/VND.....	10
2.1.2. Lý thuyết về các Yếu tố Kinh tế vĩ mô tác động.....	11
2.2. CƠ SỞ LÝ THUYẾT VỀ MÔ HÌNH DỰ BÁO	13
2.2.1. Mô hình kinh tế lượng truyền thống (ARIMA)	13
2.2.2. Khái niệm và cơ sở của học máy (Machine Learning)	13
2.2.3. Các mô hình học máy cụ thể (RF, XGBoost, LSTM).....	14
2.3. TỔNG QUAN NGHIÊN CỨU VỀ DỰ BÁO TỶ GIÁ	14
2.3.1. Tổng quan Nghiên cứu trong nước	14
2.3.2. Tổng quan Nghiên cứu nước ngoài	16
2.3.3. Khoảng trống Nghiên cứu	18

KẾT LUẬN CHƯƠNG 2	19
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU	20
3.1. DỮ LIỆU NGHIÊN CỨU VÀ THỐNG KÊ MÔ TẢ	20
3.1.1. Nguồn Dữ liệu và Phạm vi Nghiên cứu	20
3.1.2. Thống kê mô tả.....	21
3.1.3. Phân tích Ma trận Tương quan.....	23
3.2. QUY TRÌNH TIỀN XỬ LÝ DỮ LIỆU	25
3.2.1. Xử lý dữ liệu thiếu	25
3.2.2. Chuẩn hóa Dữ liệu	26
3.2.3. Kỹ thuật Tạo độ trễ.....	26
3.2.4. Chia tập Dữ liệu	27
3.3. CÁC MÔ HÌNH DỰ BÁO CHI TIẾT	27
3.3.1. Mô hình ARIMA	28
3.3.2. Các Mô hình học máy	28
3.3.3. Mô hình LSTM	30
3.4. TIÊU CHÍ ĐÁNH GIÁ MÔ HÌNH	31
KẾT LUẬN CHƯƠNG 3	33
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN.....	34
4.1. KẾT QUẢ ĐÁNH GIÁ TỔNG QUAN MÔ HÌNH.....	34
4.2. PHÂN TÍCH CHI TIẾT KẾT QUẢ DỰ BÁO CỦA TỪNG MÔ HÌNH.....	35
4.2.1. Phân tích Mô hình Kinh tế lượng (ARIMA).....	35
4.2.2. Phân tích mô hình học sâu LSTM.....	37
4.2.3. Phân tích hai mô hình RF & XGBoost	39
4.3. PHÁT HIỆN MÂU THUẬN VÀ GIẢI THÍCH CẤU TRÚC MÔ HÌNH.....	40
4.4. KẾT LUẬN VÀ KHUYẾN NGHỊ LỰA CHỌN MÔ HÌNH.....	41
KẾT LUẬN CHƯƠNG 4	43
CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ	44
5.1. KẾT LUẬN NGHIÊN CỨU	44
5.1.1. Tóm tắt Kết quả Chính.....	45
5.1.2. Đóng góp của Nghiên cứu.....	46

5.2. KHUYẾN NGHỊ ỨNG DỤNG	47
5.2.1. Đối với Ngân hàng Nhà nước	47
5.2.2. Đối với Doanh nghiệp Xuất Nhập khẩu và Đầu tư.....	48
5.3. HẠN CHẾ CỦA NGHIÊN CỨU	49
5.4. KHUYẾN NGHỊ NGHIÊN CỨU TIẾP THEO	50
KẾT LUẬN CHƯƠNG 5	52
TÀI LIỆU THAM KHẢO	1
PHỤ LỤC	5

DANH MỤC CHỮ VIẾT TẮT

TỪ VIẾT TẮT	NGUYÊN NGHĨA TIẾNG VIỆT	NGUYÊN NGHĨA TIẾNG ANH
ARIMA	Trung bình Trượt Tích hợp Tự hồi quy	AutoRegressive Integrated Moving Average
LSTM	Mạng Bộ nhớ Dài-Ngắn hạn	Long Short-Term Memory
RF	Rừng Ngẫu nhiên	Random Forest
XGBoost	Tăng cường Gradient Cực đại	eXtreme Gradient Boosting
MAE	Sai số Tuyệt đối Trung bình	Mean Absolute Error
RMSE	Sai số Căn bậc hai Trung bình	Root Mean Square Error
MAPE	Sai số Phần trăm Tuyệt đối Trung bình	Mean Absolute Percentage Error
DXY	Chỉ số Sức mạnh Đồng Đô la Mỹ	US Dollar Index
US10Y	Lợi suất Trái phiếu Chính phủ Mỹ 10 năm	U.S. 10-Year Treasury Yield
VND	Đồng Việt Nam	Vietnamese Dong
USD	Đô la Mỹ	United States Dollar

MSE	Sai số Bình phương Trung bình	Mean Squared Error
-----	----------------------------------	--------------------

DANH MỤC BẢNG BIỂU – HÌNH VẼ

Bảng 3.1: Thống kê mô tả các biến nghiên cứu.....	21
Bảng 4.1: Bảng Tổng hợp và Phân tích Hiệu suất	34
Hình 3.1: Ma trận tương quan giữa các biến nghiên cứu.....	23
Hình 3.2: Kiến trúc của một tế bào nhớ LSTM	30
Hình 4.1: Biểu đồ dự báo ARIMA	35
Hình 4.2: Biểu đồ dự báo LSTM	37
Hình 4.3: Biểu đồ dự báo RF/XGBoost.....	39

CHƯƠNG 1: GIỚI THIỆU

1.1. LÝ DO CHỌN ĐỀ TÀI

Tỷ giá hối đoái là một trong những biến số kinh tế vĩ mô quan trọng và có tác động lớn nhất đến hoạt động của nền kinh tế mở toàn cầu. Đối với Việt Nam 2024, tổng kim ngạch xuất nhập khẩu lên tới 786,2 tỉ USD (xuất khẩu 405,5 tỉ USD, nhập khẩu 380,7 tỉ USD), độ mở của nền kinh tế là 165%, vì vậy biến động của tỷ giá USD/VND có thể ảnh hưởng trực tiếp tới lạm phát, cán cân thương mại, dòng vốn quốc tế và khả năng điều hành chính sách tiền tệ của Ngân hàng Nhà nước Việt Nam. Nhiều nghiên cứu kinh tế vĩ mô kinh điển đã khẳng định tầm quan trọng của tỷ giá tiền tệ trong việc ổn định nền kinh tế, chẳng hạn như Goldberg và

Knetter (1997), cho rằng biến động tỷ giá có thể truyền dẫn ảnh hưởng sang giá xuất khẩu và cán cân thương mại quốc gia. Ngoài ra, Mishkin (2019) nhấn mạnh tỷ giá là một trong những kênh truyền dẫn quan trọng của chính sách tiền tệ, đặc biệt đối với các nền kinh tế đang phát triển như Việt Nam.

Trong bối cảnh toàn cầu hóa mạnh mẽ, các nền kinh tế mới nổi bao gồm Việt Nam ngày càng nhạy cảm với các cú sốc từ bên ngoài quốc gia, những chính sách kinh tế quan trọng như việc Cục Dự trữ Liên bang Mỹ (Fed) điều chỉnh lãi suất, giá dầu thế giới hay tình hình địa chính trị. Báo cáo Global Financial Stability Report của IMF (2023) chỉ ra rằng những cú sốc tài chính quốc tế đang ảnh hưởng đến tỷ giá các thị trường mới nổi với cường độ ngày càng lớn so với các thập niên trước. Đối với Việt Nam, giai đoạn 2020–2024 chứng kiến nhiều biến động đáng kể của tỷ giá USD/VND do tác động từ đại dịch COVID-19, chu kỳ tăng lãi suất mạnh của Fed và biến động giá hàng hóa quốc tế. Tổng hợp những yếu tố này khiến nhu cầu dự báo tỷ giá ngày càng trở nên cấp thiết để hỗ trợ doanh nghiệp xuất nhập khẩu, các ngân hàng thương mại và cơ quan hoạch định chính sách.

Việc dự báo tỷ giá từ lâu vốn là một thách thức lớn trong kinh tế học. Các mô hình kinh điển như ARIMA của Box và Jenkins (1970) tuy được sử dụng phổ biến, nhưng dựa trên giả định tuyến tính và tính ổn định của chuỗi thời gian. Điều này khiến chúng gặp khó khăn khi tỷ giá lại thể hiện tính phi tuyến, nhiễu cao và chịu tác

động đồng thời của nhiều yếu tố vĩ mô khác nhau đặc điểm phổ biến ở các nền kinh tế mới nổi. Nhiều nghiên cứu, như Alvarez-Díaz và Mateu (2006), cho thấy dữ liệu kinh tế đặc biệt là tỷ giá thường mang tính phi tuyến mạnh, khiến mô hình truyền thống giảm độ chính xác.

Để giải quyết vấn đề này trong hai thập kỷ gần đây, sự phát triển nhanh chóng của trí tuệ nhân tạo mang lại hướng tiếp cận mới cho bài toán dự báo tài chính. Breiman (2001) với Random Forest và Chen & Guestrin (2016) với XGBoost đã chứng minh rằng các thuật toán học máy hiện đại có khả năng mô hình hóa quan hệ phi tuyến và xử lý dữ liệu phức tạp tốt hơn đáng kể so với phương pháp thống kê cổ điển như là ARIMA. Đặc biệt, mô hình mạng nơ-ron hồi quy dài ngắn hạn (LSTM) của Hochreiter và Schmidhuber (1997) đã trở thành một công cụ mạnh trong phân tích chuỗi thời gian nhờ khả năng nắm bắt phụ thuộc dài hạn. Nhiều nghiên cứu gần đây áp dụng LSTM vào dự báo tỷ giá, chứng minh mức cải thiện rõ rệt so với mô hình truyền thống

Mặc dù tiềm năng là rất lớn, việc ứng dụng các thuật toán học máy vào dự báo tài chính tại Việt Nam vẫn đang ở giai đoạn sơ khai. Qua lược khảo tài liệu, có thể thấy đa số các nghiên cứu trong nước hiện nay vẫn chủ yếu dựa vào các mô hình kinh tế lượng tuyến tính truyền thống như ARIMA hay VAR. Một số ít nghiên cứu đã bắt đầu thử nghiệm học máy, tuy nhiên thường chỉ dừng lại ở việc áp dụng đơn lẻ mà thiếu đi sự so sánh đối chứng toàn diện về hiệu quả giữa các nhóm mô hình trên cùng một bộ dữ liệu chuẩn.

Chính khoảng trống nghiên cứu này đã đặt ra nhu cầu cấp thiết phải thực hiện một đánh giá thực nghiệm sâu rộng, nhằm trả lời câu hỏi: Liệu các mô hình học sâu phi tuyến tính có thực sự vượt trội hơn so với các phương pháp truyền thống trong việc nắm bắt quy luật vận động của tỷ giá USD/VND hay không. Câu hỏi này càng trở nên quan trọng trong bối cảnh thị trường tài chính toàn cầu và trong nước đang trải qua giai đoạn biến động khó lường với nhiều cú sốc ngoại sinh.

Chính vì vậy, nghiên cứu này được thực hiện nhằm lấp đầy khoảng trống đó thông qua một đánh giá thực nghiệm sâu rộng và toàn diện. Trọng tâm của nghiên

cứu là so sánh năng lực dự báo giữa mô hình truyền thống (ARIMA) và mô hình học máy hiện đại đối với tỷ giá USD/VND. Câu hỏi nghiên cứu này càng trở nên cấp thiết hơn bao giờ hết trong bối cảnh thị trường tài chính hiện nay đang chịu tác động mạnh mẽ từ các cú sốc ngoại sinh khó lường (như chính sách tiền tệ của Fed hay các căng thẳng địa chính trị), đòi hỏi các công cụ dự báo phải có khả năng ghi nhớ dài hạn và thích ứng linh hoạt với những biến động bất thường.

1.2. MỤC TIÊU NGHIÊN CỨU

1.2.1. Mục tiêu nghiên cứu tổng quát

Mục tiêu tổng quát của nghiên cứu này là thực hiện một đánh giá thực nghiệm toàn diện và khách quan về năng lực dự báo tỷ giá hối đoái USD/VND trên dữ liệu tần suất ngày. Thông qua việc so sánh đối chứng giữa các mô hình kinh tế lượng truyền thống (ARIMA) và các mô hình học máy phi tuyến tính (Random Forest, XGBoost, LSTM), nghiên cứu nhằm mục đích xác định mô hình dự báo tối ưu nhất có khả năng nắm bắt được các quy luật phức tạp và sự biến động của tỷ giá trong bối cảnh thị trường tài chính hiện đại.

1.2.2. Mục tiêu nghiên cứu cụ thể

Nghiên cứu tập trung phân tích, so sánh hiệu suất giữa mô hình ARIMA và các mô hình học máy (RF, XGBoost, LSTM) để xác định thuật toán dự báo tối ưu, từ đó đề xuất các hàm ý quản trị rủi ro tỷ giá dựa trên dữ liệu cho các ngân hàng thương mại và doanh nghiệp xuất nhập khẩu tại Việt Nam.

1.3. CÂU HỎI NGHIÊN CỨU

Để thực hiện được các mục tiêu trên, đề tài sẽ trả lời các câu hỏi nghiên cứu sau:

Một là, hiệu suất dự báo tỷ giá USD/VND của các mô hình phi tuyến tính (Random Forest, XGBoost, LSTM) có sự khác biệt như thế nào, và liệu chúng có vượt trội hơn đáng kể so với mô hình kinh tế lượng tuyến tính truyền thống (ARIMA) hay không?

Hai là, dựa trên các chỉ số sai số (MAE, RMSE, MAPE), mô hình nào trong số bốn mô hình được thử nghiệm (ARIMA, RF, XGBoost, LSTM) cung cấp kết quả

dự báo tối ưu nhất, và đặc tính kỹ thuật nào của mô hình đó lý giải cho sự vượt trội này?

Ba là, những hàm ý thực tiễn nào có thể được rút ra từ mô hình dự báo tối ưu nhất để đề xuất các giải pháp quản lý rủi ro tỷ giá cho Ngân hàng thương mại và Doanh nghiệp xuất nhập khẩu tại Việt Nam?

1.4. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu chính của đề tài là khả năng dự báo của tỷ giá hối đoái USD/VND.

Nghiên cứu tập trung vào phân tích hiệu quả so sánh và năng lực dự báo ngoài mẫu của các mô hình kinh tế lượng truyền thống (ARIMA) và các mô hình Học máy phi tuyến tính (Random Forest, XGBoost, LSTM).

1.4.2. Phạm vi nghiên cứu

Về thời gian: nghiên cứu được triển khai dựa trên dữ liệu chuỗi thời gian tần suất theo ngày, bao trùm một giai đoạn dài và mang tính thời sự cao, kéo dài từ ngày 01/01/2015 đến hết tháng 09/2025. Việc lựa chọn phạm vi thời gian này là có chủ đích nhằm đảm bảo cả tính toàn diện và tính thời sự của dữ liệu. Cụ thể, giai đoạn này không chỉ bao quát quá trình Ngân hàng Nhà nước áp dụng cơ chế điều hành tỷ giá trung tâm (bắt đầu từ năm 2016), một sự kiện quan trọng trong lịch sử điều hành tỷ giá Việt Nam; mà còn mở rộng đến Quý III năm 2025. Sự cập nhật dữ liệu đến gần thời điểm hiện tại này là cần thiết để mô hình có thể phản ánh và học được các cú sốc tài chính mới nhất, đặc biệt là những diễn biến phức tạp của thị trường quốc tế, chẳng hạn như các quyết định chính sách tiền tệ từ Cục Dự trữ Liên bang Mỹ (Fed) trong năm 2025. Điều này đặc biệt quan trọng để kiểm định hiệu quả của các mô hình học máy trong môi trường dữ liệu biến động gần đây.

Về không gian: nghiên cứu có trọng tâm là cặp tỷ giá hối đoái USD/VND, được xem xét trong bối cảnh của Thị trường Ngoại hối Việt Nam. Biến phụ thuộc của nghiên cứu được xác định là Tỷ giá bán ra của đồng USD/VND tại Ngân hàng Thương mại. Việc lựa chọn tỷ giá giao dịch thực tế thay vì Tỷ giá trung tâm do Ngân hàng

Nhà nước (SBV) công bố được biện minh bởi hai yếu tố: (1) Tỷ giá này phản ánh áp lực cung cầu thực tế và là mức giá mà các doanh nghiệp sử dụng trong giao dịch, phục vụ trực tiếp cho mục tiêu ứng dụng; (2) Tỷ giá này có thể thu thập liên tục, dễ dàng dưới dạng chuỗi thời gian tần suất ngày từ các cổng thông tin tài chính uy tín như Investing.com, qua đó đảm bảo tính khả thi dữ liệu và chất lượng cao cho việc huấn luyện các mô hình Học sâu (LSTM) một cách chính xác.

1.5. PHƯƠNG PHÁP NGHIÊN CỨU

Nghiên cứu này được tiến hành thông qua phương pháp nghiên cứu định lượng, sử dụng cách tiếp cận thực nghiệm so sánh chuyên sâu nhằm kiểm chứng giả thuyết về sự ưu việt của các thuật toán học máy phi tuyến tính trong dự báo tỷ giá. Toàn bộ quy trình nghiên cứu được xây dựng một cách khoa học và chặt chẽ: Đầu tiên, dữ liệu chuỗi thời gian tần suất ngày được thu thập và phân chia thành Tập Huấn luyện, Tập Thăm định và Tập Kiểm định theo trình tự thời gian, là bước thiết yếu để đảm bảo tính khách quan trong việc đánh giá. Dữ liệu sau đó được xử lý sơ bộ thông qua các kỹ thuật tiền xử lý như tạo độ trễ và chuẩn hóa dữ liệu. Nghiên cứu tiến hành xây dựng và tối ưu hóa bốn mô hình dự báo chính, gồm ARIMA, Random Forest, XGBoost và LSTM, với Tập Thăm định được sử dụng đặc biệt để tinh chỉnh các siêu tham số và tránh hiện tượng quá khớp (overfitting). Cuối cùng, các mô hình này được kiểm tra nghiêm ngặt bằng phương pháp dự báo ngoài mẫu trên Tập Kiểm định. Hiệu suất dự báo được đánh giá dựa trên các chỉ số sai số chuẩn mực như sai số tuyệt đối trung bình MAE, sai số căn bậc hai trung bình RMSE và phần trăm sai số tuyệt đối trung bình MAPE, từ đó xác định mô hình có năng lực dự báo tối ưu nhất đối với tỷ giá USD/VND.

1.6. ĐÓNG GÓP CỦA ĐỀ TÀI

Nghiên cứu này được kỳ vọng sẽ mang lại những đóng góp đáng kể, kết hợp giữa giá trị học thuật và ứng dụng thực tiễn: Về mặt học thuật, đề tài cung cấp một sự so sánh đối chứng toàn diện và chuyên sâu, thông qua việc kiểm chứng hiệu quả dự báo của các mô hình kinh tế lượng truyền thống (ARIMA) so với các mô hình Học máy phi tuyến tính tiên tiến (Random Forest, XGBoost, LSTM) trên dữ liệu tần suất

ngày, qua đó thu hẹp khoảng trống nghiên cứu trong nước. Nghiên cứu còn thiết lập một quy trình xử lý dữ liệu và kiểm định mô hình vô cùng nghiêm ngặt (sử dụng 3 tập dữ liệu huấn luyện, thẩm định và kiểm định), tạo ra một khuôn mẫu khoa học để đánh giá năng lực dự báo ngoài mẫu trong lĩnh vực tài chính. Về mặt thực tiễn, kết quả nghiên cứu sẽ trực tiếp xác định và cung cấp mô hình dự báo tối ưu nhất, tạo cơ sở dữ liệu đáng tin cậy cho các Ngân hàng thương mại trong việc định giá các công cụ phòng ngừa rủi ro và hỗ trợ các Doanh nghiệp xuất nhập khẩu trong việc hoạch định chiến lược kinh doanh và quản lý rủi ro tỷ giá.

1.7. CẤU TRÚC CỦA ĐỀ TÀI

Ngoài phần Mở đầu và Kết luận, Khóa luận được xây dựng với cấu trúc gồm 5 chương chính, được sắp xếp theo trình tự logic và phương pháp luận như sau:

Chương 1: Mở đầu. Chương này giới thiệu tổng quan về đề tài nghiên cứu, bao gồm lý do chọn đề tài, mục tiêu nghiên cứu, các câu hỏi nghiên cứu cần giải quyết, phạm vi không gian và thời gian được áp dụng, cùng với phương pháp luận và đóng góp chính của đề tài.

Chương 2: Tổng quan Lý thuyết và Mô hình Dự báo. Chương này trình bày cơ sở lý thuyết về tỷ giá hối đoái USD/VND} và các yếu tố tác động theo các mô hình kinh tế vĩ mô. Đồng thời, chương này tổng quan các công trình nghiên cứu trong và ngoài nước có liên quan và đi sâu vào lý thuyết của các mô hình dự báo sẽ được sử dụng, bao gồm ARIMA (kinh tế lượng), Random Forest và XGBoost, LSTM

Chương 3: Phương pháp Nghiên cứu và Dữ liệu. Chương này mô tả chi tiết phương pháp luận định lượng được áp dụng. Nội dung bao gồm việc mô tả nguồn dữ liệu tần suất ngày, lý do lựa chọn các biến độc lập. Đặc biệt, chương này trình bày chi tiết quy trình xử lý dữ liệu (tạo độ trễ, chuẩn hóa) và cơ chế chia dữ liệu thành ba tập Huấn luyện, Thẩm định, Kiểm định theo thứ tự thời gian, cùng với việc trình bày chi tiết về cấu trúc và quy trình ước lượng của từng mô hình.

Chương 4: Kết quả Thực nghiệm và Phân tích So sánh. Chương này trình bày các phát hiện chính từ việc chạy mô hình. Nội dung bao gồm kết quả thống kê mô tả, kết quả huấn luyện, ước lượng tham số và kết quả dự báo ngoài mẫu của tất cả 4 mô

hình. Phân tích so sánh đối chứng sẽ được thực hiện dựa trên các chỉ số sai số MAE, RMSE, MAPE, qua đó lý giải sự khác biệt về hiệu suất và xác định mô hình dự báo tối ưu nhất.

Chương 5: Kết luận và Hàm ý Ứng dụng. Chương này tóm tắt những đóng góp chính và các phát hiện quan trọng nhất của nghiên cứu. Trên cơ sở đó, chương đề xuất các Hàm ý Chính sách và khuyến nghị ứng dụng thực tiễn cụ thể cho các Ngân hàng thương mại và Doanh nghiệp xuất nhập khẩu tại Việt Nam, đồng thời đưa ra những hạn chế và hướng nghiên cứu mở rộng trong tương lai.

KẾT LUẬN CHƯƠNG 1

Chương 1 đã trình bày được tầm quan trọng của đề tài, mục tiêu, đối tượng, phạm vi nghiên cứu và phương pháp nghiên cứu của khóa luận. Dựa vào chương này thấy được khái quát cấu trúc của khóa luận và các vấn đề cụ thể cần giải quyết đồng thời xây dựng được nền tảng để phát triển cơ sở lý thuyết của bài viết ở chương 2.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

2.1. CƠ SỞ LÝ THUYẾT VỀ TỶ GIÁ HỐI ĐOÁI VÀ YẾU TỐ TÁC ĐỘNG

Tỷ giá hối đoái được hiểu là mức giá của một đồng tiền khi được biểu thị thông qua một đồng tiền khác. Trong nghiên cứu này, tỷ giá USD/VND phản ánh lượng Đồng Việt Nam cần thiết để mua một Đô la Mỹ và được xem là biến số thể hiện sức mạnh tương đối giữa hai đồng tiền trong bối cảnh hội nhập tài chính quốc tế. Theo Habib và Eichengreen (2016), tỷ giá – đặc biệt là tỷ giá thực – là một trong những yếu tố có tính quyết định đối với động lực tăng trưởng kinh tế ở các nền kinh tế mới nổi. Chính vì vậy, việc xác định và phân tích tỷ giá danh nghĩa cùng tỷ giá thực là cơ sở quan trọng để đánh giá sức cạnh tranh quốc tế của Việt Nam.

Tỷ giá danh nghĩa thể hiện mức niêm yết trực tiếp trên thị trường ngoại hối, trong khi tỷ giá thực được điều chỉnh theo chênh lệch lạm phát giữa các quốc gia và phản ánh sức cạnh tranh thực sự của hàng hóa trong thương mại xuyên biên giới. Rodrik (2008) cho thấy rằng tỷ giá thực có vai trò quan trọng trong việc thúc đẩy tăng trưởng khi đồng nội tệ được duy trì ở mức định giá thấp hợp lý, qua đó hỗ trợ khu vực sản xuất định hướng xuất khẩu. Điều này đặc biệt đúng với các nền kinh tế đang phát triển, nơi xuất khẩu là động lực chính thúc đẩy tăng trưởng dài hạn.

Trong trường hợp Việt Nam, tỷ giá USD/VND là một công cụ điều tiết kinh tế vĩ mô quan trọng. Biến động của tỷ giá ảnh hưởng trực tiếp đến thương mại quốc tế, bởi khi tỷ giá tăng, hàng hóa xuất khẩu của Việt Nam trở nên rẻ hơn tương đối, qua đó nâng cao sức cạnh tranh; đồng thời chi phí nhập khẩu tăng, tác động đến giá đầu vào của doanh nghiệp. Goldberg và Klein (2005) cũng chỉ ra rằng tỷ giá ảnh hưởng đồng thời đến thương mại và dòng vốn, cho thấy tầm quan trọng của việc duy trì tỷ giá ổn định đối với nền kinh tế có độ mở cao như Việt Nam.

Tỷ giá USD/VND còn có tác động đáng kể đến dòng vốn đầu tư nước ngoài. Các nhà đầu tư thường đánh giá rủi ro tỷ giá khi quyết định phân bổ vốn, và biến động mạnh của tỷ giá có thể khiến dòng vốn FDI và FII suy giảm. He (2021) ghi nhận rằng sự bất ổn của tỷ giá thực tạo ra rủi ro cho lợi nhuận kỳ vọng, từ đó làm giảm mức độ hấp dẫn của các dự án đầu tư trực tiếp. Đối với khu vực Đông Á – Thái Bình

Dương, Wongsamee (2024) cho thấy tỷ giá thực có mối liên hệ đáng kể với dòng FDI rót vào khu vực, phản ánh xu hướng chung tại các nền kinh tế mới nổi.

Nhiều nghiên cứu tập trung riêng vào Việt Nam cũng khẳng định vai trò của tỷ giá. Pham (2013) chỉ ra mối tương quan hai chiều giữa FDI, xuất khẩu và tỷ giá thực, cho thấy biến số này tác động trực tiếp đến cấu trúc kinh tế đối ngoại của Việt Nam. Gần đây hơn, Đỗ (2025) nhấn mạnh rằng biến động tỷ giá USD/VND có thể ảnh hưởng đến quyết định mở rộng đầu tư của khu vực FDI tại Việt Nam, đặc biệt trong những thời kỳ dòng vốn quốc tế có xu hướng dịch chuyển.

Từ các nghiên cứu trên có thể thấy rằng tỷ giá hối đoái USD/VND là một biến số trọng yếu trong điều hành kinh tế vĩ mô, ảnh hưởng đến thương mại quốc tế, dòng vốn đầu tư và ổn định kinh tế nói chung. Do đó, việc theo dõi, phân tích và dự báo tỷ giá là cần thiết để hỗ trợ quá trình hoạch định chính sách kinh tế của Việt Nam trong bối cảnh biến động toàn cầu ngày càng mạnh.

2.1.1. Khái niệm và Vai trò của Tỷ giá hối đoái USD/VND

Tỷ giá hối đoái được hiểu là mức giá của một đồng tiền khi được biểu thị thông qua một đồng tiền khác và đóng vai trò là nền tảng trong các phân tích tài chính quốc tế. Trong phạm vi nghiên cứu này, tỷ giá USD/VND phản ánh số lượng Đồng Việt Nam cần thiết để mua một Đô la Mỹ. Việc xem xét diễn biến tỷ giá danh nghĩa và tỷ giá thực cho phép đánh giá đúng sức mạnh tương đối của VND trong bối cảnh hội nhập. Theo Habib và Eichengreen (2016), tỷ giá thực là một trong những biến số có ảnh hưởng đáng kể đến tăng trưởng kinh tế, đặc biệt tại các nền kinh tế đang phát triển.

Tỷ giá danh nghĩa thể hiện mức niêm yết trên thị trường ngoại hối, trong khi tỷ giá thực được điều chỉnh theo chênh lệch lạm phát giữa hai quốc gia. Rodrik (2008) chỉ ra rằng việc duy trì đồng nội tệ ở trạng thái định giá thấp hợp lý có thể thúc đẩy tăng trưởng thông qua mở rộng khu vực sản xuất định hướng xuất khẩu. Đây là luận điểm có ý nghĩa đặc biệt với các nền kinh tế mới nổi, trong đó có Việt Nam.

Tỷ giá hối đoái cũng là nhân tố tác động mạnh tới thương mại quốc tế. Khi tỷ giá tăng, hàng hóa xuất khẩu trở nên cạnh tranh hơn, trong khi chi phí nhập khẩu tăng

và ảnh hưởng đến cán cân thương mại. Nghiên cứu của Goldberg và Klein (2005) cho thấy tỷ giá không chỉ tác động tới thương mại mà còn ảnh hưởng tới dòng vốn quốc tế, qua đó nhấn mạnh yêu cầu duy trì ổn định tỷ giá cho các nền kinh tế có độ mở cao.

Trong lĩnh vực đầu tư quốc tế, biến động tỷ giá được xem là một rủi ro quan trọng đối với các nhà đầu tư. He (2021) cho thấy sự biến động của tỷ giá thực có thể làm giảm sức hấp dẫn của dòng vốn FDI thông qua việc gia tăng bất định về lợi nhuận kỳ vọng. Tại khu vực Đông Á – Thái Bình Dương, Wongsamee (2024) cũng khẳng định mối quan hệ có ý nghĩa giữa tỷ giá thực và dòng vốn FDI vào khu vực. Riêng trường hợp Việt Nam, Pham (2013) chỉ ra rằng tỷ giá thực có mối liên hệ chặt chẽ với FDI và xuất khẩu, cho thấy tầm quan trọng của biến số này trong cấu trúc kinh tế đối ngoại của Việt Nam.

Về mặt điều hành, Ngân hàng Nhà nước Việt Nam (SBV) sử dụng cơ chế tỷ giá trung tâm kết hợp biên độ nhằm duy trì ổn định thị trường ngoại hối và hỗ trợ mục tiêu kiểm soát lạm phát, ổn định kinh tế vĩ mô. Cơ chế điều hành tỷ giá của Việt Nam thường xuyên được điều chỉnh phù hợp với diễn biến quốc tế và điều kiện trong nước, qua đó đảm bảo mục tiêu ổn định thị trường và thu hút dòng vốn (SBV, 2023).

Từ các nghiên cứu quốc tế và các bằng chứng thực nghiệm tại Việt Nam có thể thấy rằng tỷ giá hối đoái USD/VND giữ vai trò trọng yếu đối với thương mại, dòng vốn đầu tư và chính sách kinh tế vĩ mô nói chung. Việc phân tích và dự báo tỷ giá do đó có ý nghĩa thiết thực trong việc hoạch định chính sách và định hướng phát triển kinh tế trong bối cảnh toàn cầu biến động mạnh.

2.1.2. Lý thuyết về các Yếu tố Kinh tế vĩ mô tác động

Tỷ giá hối đoái chịu ảnh hưởng đồng thời của các yếu tố vĩ mô trong nước và quốc tế, trong đó các lý thuyết kinh tế nền tảng như Lãi suất Ngang giá. Cán cân Thanh toán và sức mạnh tương đối của đồng USD cung cấp cơ sở để nhận diện các biến số có khả năng tác động mạnh tới biến động USD/VND. Trên nền tảng đó, nhiều nghiên cứu thực nghiệm và ứng dụng mô hình dự báo, bao gồm cả học máy, đã sử dụng các biến này như đầu vào quan trọng cho mô hình, tạo thành cơ sở khoa học cho việc lựa chọn biến độc lập trong nghiên cứu này

Theo lý thuyết IRP, chênh lệch lãi suất giữa hai quốc gia quyết định kỳ vọng về biến động tỷ giá trong tương lai, do nhà đầu tư sẽ dịch chuyển vốn nhằm đạt lợi suất cao hơn khi chi phí phòng ngừa rủi ro được cân bằng. Lợi suất trái phiếu chính phủ Mỹ kỳ hạn 10 năm (US10Y) là tham số phản ánh mặt bằng lãi suất dài hạn của Hoa Kỳ và được các nghiên cứu xem như một yếu tố quan trọng giải thích xu hướng của USD. Nhiều nghiên cứu thực nghiệm cho thấy lợi suất dài hạn của Mỹ giúp cải thiện khả năng dự báo tỷ giá, bao gồm Wang và Wu (2012), Rossi (2013) và Neely (2017), trong đó các mô hình học máy như Support Vector Regression hoặc Random Forest đạt kết quả tốt hơn khi bổ sung US long-term yield. Những kết quả này khẳng định US10Y là biến có khả năng giải thích biến động USD/VND và phù hợp đưa vào mô hình

Lý thuyết về Cán cân Thanh toán (BoP) giải thích sự tương tác giữa các dòng vốn quốc tế, cán cân thương mại và tỷ giá. Trong bối cảnh các thị trường mới nổi, biến động trên thị trường chứng khoán thường phản ánh dòng vốn đầu tư gián tiếp nước ngoài (FII/FPI), qua đó tác động đến cung cầu ngoại tệ. Các nghiên cứu của Kim và Yang (2011), Gupta và Modise (2013) và Narayan và cộng sự (2019) cho thấy chỉ số chứng khoán có khả năng cải thiện mô hình dự báo tỷ giá, đặc biệt khi kết hợp với các thuật toán học máy. Từ nền tảng đó, VNINDEX được sử dụng như đại diện cho tâm lý rủi ro và biến động dòng vốn quốc tế vào Việt Nam. Bên cạnh đó, giá dầu Brent (OIL_BRENT) là yếu tố ảnh hưởng trực tiếp đến cán cân thương mại của Việt Nam, một nền kinh tế có tỷ trọng nhập khẩu xăng dầu lớn. Các nghiên cứu của Basher, Haug và Sadorsky (2012), Baumeister và Kilian (2015) và Jammazi và cộng sự (2017) đều khẳng định giá dầu là biến quan trọng trong việc dự báo biến động tiền tệ ở các nền kinh tế mới nổi

Ngoài ra, biến động của đồng USD trên phạm vi toàn cầu có tác động lan tỏa mạnh đến các đồng tiền quốc gia, đặc biệt tại những nền kinh tế có độ mở thương mại và tài chính lớn. Chỉ số sức mạnh đồng USD (DXY) đo lường giá trị của USD so với các đồng tiền chủ chốt và là một biến được sử dụng phổ biến trong các mô hình dự báo tỷ giá. Các nghiên cứu như Patel (2020), Cerchiello và Nicola (2018) và Habib

và Stracca (2012) ghi nhận DXY có vai trò đặc biệt quan trọng trong việc giải thích biến động của các đồng tiền châu Á, cả trong mô hình thống kê truyền thống và mô hình học máy.

Từ cơ sở lý thuyết và thực nghiệm trên, US10Y, VNINDEX, OIL_BRENT và DXY được lựa chọn đưa vào mô hình dự báo tỷ giá USD/VND trong nghiên cứu này. Các biến này vừa phù hợp với các lý thuyết kinh tế quốc tế kinh điển, vừa được chứng minh có khả năng cải thiện độ chính xác của mô hình dự báo trong nhiều nghiên cứu học thuật và ứng dụng học máy gần đây, đảm bảo cơ sở khoa học và tính hợp lý khi áp dụng vào điều kiện thị trường Việt Nam.

2.2. CƠ SỞ LÝ THUYẾT VỀ MÔ HÌNH DỰ BÁO

2.2.1. Mô hình kinh tế lượng truyền thống (ARIMA)

Mô hình tự hồi quy tích hợp trung bình trượt (ARIMA) là phương pháp kinh tế lượng cổ điển được Box và Jenkins (1970) phát triển, tập trung vào việc mô hình hóa các chuỗi thời gian dựa trên các giá trị trễ và sai số quá khứ. Mặc dù ARIMA hiệu quả đối với các chuỗi dữ liệu tuyến tính và có tính dừng, nhưng theo Makridakis và cộng sự (2020), hạn chế cơ bản của mô hình này nằm ở việc không thể nắm bắt được các mối quan hệ phi tuyến tính phức tạp thường xuất hiện trong dữ liệu tài chính biến động mạnh.

2.2.2. Khái niệm và cơ sở của học máy (Machine Learning)

Học máy (Machine Learning) là một nhánh của trí tuệ nhân tạo, tập trung vào việc phát triển các thuật toán có khả năng tự học hỏi và nhận diện quy luật từ dữ liệu mà không cần các giả định cứng nhắc về phân phối xác suất. Theo Bishop (2006), học máy tối ưu hóa hiệu suất thông qua việc giảm thiểu sai số dự báo trên tập dữ liệu đào tạo. Trong bối cảnh tài chính, học máy đóng vai trò như các "bộ lọc phi tuyến", có khả năng xử lý hiệu quả độ nhiễu (noise) và các mối quan hệ phi tuyến tính (non-linear) mà các mô hình truyền thống thường bỏ qua, từ đó cải thiện đáng kể độ chính xác của dự báo (Mitchell, 1997).

2.2.3. Các mô hình học máy cụ thể (RF, XGBoost, LSTM)

Random Forest (RF) và XGBoost: Đây là các thuật toán dựa trên cây quyết định (Decision Trees). RF sử dụng phương pháp "Bagging" để giảm phương sai, trong khi XGBoost áp dụng cơ chế "Boosting" để tối ưu hóa hàm mục tiêu một cách tuần tự (Chen & Guestrin, 2016). Các mô hình này đặc biệt mạnh mẽ trong việc xử lý các biến số vĩ mô đa chiều và xác định tầm quan trọng của từng biến trong dự báo tỷ giá.

Long Short-Term Memory (LSTM): Là một dạng mạng thần kinh tái tạo (RNN) cải tiến được Hochreiter và Schmidhuber (1997) giới thiệu. LSTM giải quyết triệt để vấn đề mất mát thông tin (vanishing gradient) bằng cấu trúc "cổng" (gating mechanism), cho phép mô hình ghi nhớ các phụ thuộc dài hạn (long-term dependencies) trong dữ liệu. Đối với tỷ giá USD/VND, cấu trúc này giúp mô hình nhận diện được các chu kỳ biến động phức tạp dựa trên dữ liệu quá khứ.

2.3. TỔNG QUAN NGHIÊN CỨU VỀ DỰ BÁO TỶ GIÁ

2.3.1. Tổng quan Nghiên cứu trong nước

Theo Trần Văn Thời (2025), nghiên cứu đăng trên Tạp chí Kinh tế & Dự báo đã sử dụng mô hình ARIMA để dự báo tỷ giá USD/VND dựa trên chuỗi dữ liệu tháng từ năm 2016 đến giữa năm 2025. Tác giả tiến hành kiểm định tính dừng, xác định bậc sai phân và sử dụng mô hình ARIMA(5,1,5) nhằm nắm bắt cả thành phần tự hồi quy và trung bình trượt của chuỗi tỷ giá. Kết quả thực nghiệm cho thấy mô hình ARIMA dự báo tốt trong ngắn hạn, đặc biệt trong chu kỳ 4 tháng tiếp theo với sai số dự báo tương đối thấp. Nghiên cứu khẳng định mô hình ARIMA vẫn phù hợp trong bối cảnh thị trường ngoại hối Việt Nam có xu hướng ổn định, ít biến động đột ngột.

Theo Nguyễn Thị Minh Phương, Lê Văn Hưng, Hoàng Quốc Việt và Phạm Hải Yến (2024) tại Trường Đại học Công nghiệp Hà Nội, nhóm tác giả đã phối hợp mô hình ARIMA và GARCH, cụ thể là mô hình TARCH(1,1), nhằm dự báo tỷ giá USD/VND giai đoạn từ tháng 12/2019 đến tháng 11/2024. Nghiên cứu sử dụng phần mềm R để ước lượng đồng thời hai thành phần: ARIMA mô tả xu hướng và TARCH mô tả mức độ biến động không đối xứng của tỷ giá. Kết quả cho thấy mặc dù tỷ giá có xu hướng giảm nhẹ trong hai tuần đầu tháng 12/2024, nhưng biến động lại duy trì

ở mức cao, thể hiện sự nhạy cảm của thị trường Việt Nam trước các cú sốc tài chính. Công trình này đóng góp quan trọng trong việc nhấn mạnh tầm quan trọng của việc mô hình hóa biến động (volatility) trong dự báo tỷ giá.

Theo Nguyễn Thành Long, Trần Nhật Huy và Lê Thị Mỹ Ngọc (2018) công bố trên Tạp chí Khoa học & Công nghệ – Đại học Công nghiệp TP. HCM, nhóm tác giả đã ứng dụng phương pháp Box–Jenkins để mô hình hóa tỷ giá trung tâm USD/VND dựa trên dữ liệu do Ngân hàng Nhà nước Việt Nam công bố. Sau quá trình xác định mô hình tối ưu, ARIMA(0,1,1) được lựa chọn do phù hợp nhất với cấu trúc dữ liệu và sai số dự báo thấp. Nghiên cứu cung cấp dự báo tỷ giá trung bình tháng sau năm 2017 và kiểm định độ chính xác bằng dữ liệu thực tế. Kết quả chỉ ra rằng mô hình ARIMA có hiệu quả cao trong bối cảnh tỷ giá trung tâm được điều hành theo cơ chế linh hoạt nhưng vẫn định hướng bởi chính sách tiền tệ.

Theo Nguyễn Trung Trực (2020) đăng trên Tạp chí Công Thương, tác giả phân tích các yếu tố kinh tế vĩ mô ảnh hưởng đến tỷ giá VND/USD thông qua mô hình hồi quy tuyến tính bội với dữ liệu chuỗi thời gian. Sử dụng phần mềm Stata, nghiên cứu đưa vào các biến như lãi suất, dự trữ ngoại hối, dòng vốn FDI, chỉ số giá tiêu dùng và cung tiền. Kết quả cho thấy lãi suất và dự trữ ngoại hối có tác động mạnh nhất đến biến động tỷ giá, trong khi FDI và CPI cũng đóng vai trò quan trọng trong ngắn hạn. Nghiên cứu đề xuất NHNN và Chính phủ cần cân đối giữa điều hành lãi suất và ổn định tâm lý thị trường nhằm hạn chế biến động tỷ giá và nâng cao niềm tin vào VND.

Theo Phạm Quốc Cường, Lê Thanh Tâm, Hoàng Minh Tuấn và Nguyễn Thị Thu Hà (2022), một nghiên cứu công bố trong Tạp chí Nghiên cứu Tài chính – Marketing đã đánh giá khả năng dự báo tỷ giá VND/USD bằng mô hình học máy dựa trên dữ liệu kinh tế vĩ mô hằng tháng. Nhóm tác giả áp dụng ba thuật toán gồm Random Forest, XGBoost và Support Vector Regression, đồng thời so sánh với mô hình ARIMA truyền thống. Kết quả chỉ ra rằng mô hình ML, đặc biệt là XGBoost, cho sai số dự báo thấp hơn đáng kể so với ARIMA trong giai đoạn biến động mạnh của thị trường năm 2020–2021. Nghiên cứu này là một trong số rất ít công trình tại

Việt Nam ứng dụng học máy cho dự báo tỷ giá, góp phần lấp khoảng trống nghiên cứu trong lĩnh vực này.

2.3.2. Tổng quan Nghiên cứu nước ngoài

Trên bình diện quốc tế, một lượng lớn nghiên cứu đã so sánh hiệu suất giữa các mô hình kinh tế lượng truyền thống và các kỹ thuật học máy / học sâu (machine learning / deep learning) khi dự báo tỷ giá hối đoái, đồng thời nhiều nghiên cứu điển hình sử dụng LSTM để nắm bắt tính phi tuyến và tính phụ thuộc thời gian trong chuỗi tỷ giá.

Trước hết, Siami Namini và Siami Namin (2018) trong bài “Forecasting Economics and Financial Time Series: ARIMA vs. LSTM” đã tiến hành thử nghiệm trên các chuỗi thời gian kinh tế và tài chính sử dụng mô hình ARIMA truyền thống và mô hình LSTM sâu. Kết quả cho thấy LSTM vượt trội hơn ARIMA rất rõ ràng về độ chính xác dự báo, với mức giảm lỗi trung bình khoảng 84–87% so với ARIMA arXiv. Nghiên cứu này là một minh chứng mạnh mẽ cho quyền ưu thế của mạng nơ ron hồi tiếp dài/ngắn hạn (LSTM) trong việc nắm bắt các cấu trúc phi tuyến, phụ thuộc thời gian và các đặc tính phức tạp mà mô hình tuyến tính như ARIMA khó xử lý.

Tiếp theo, Kaushik & Giri (2020) đã thực hiện một phân tích so sánh đa biến giữa mô hình VAR (Vector AutoRegression – một mô hình kinh tế lượng truyền thống), SVM (máy học hiện đại), và RNN (LSTM) để dự báo tỷ giá USD/INR. Họ sử dụng dữ liệu kinh tế vĩ mô hàng tháng (1994–2018) và nhận thấy rằng LSTM cho độ chính xác cao nhất (gần 97,83%) so với SVM (97,17%) và VAR (96,31%). Kết quả này chỉ rõ tiềm năng của deep learning trong dự báo tỷ giá quốc tế và khẳng định rằng các mô hình phi tuyến có thể vượt mô hình kinh tế lượng khi dữ liệu đủ chất lượng và quy mô.

Một nghiên cứu mới hơn cũng so sánh trực tiếp ARIMA và LSTM là của García, Guijarro, Oliver & Tamošiūnienė (2023), trong bài “Foreign Exchange Forecasting Models: ARIMA and LSTM Comparison”. Họ chạy mô hình ARIMA và mạng LSTM trên dữ liệu tỷ giá ngoại hối và báo cáo rằng LSTM có khả năng bắt mô

hình tốt hơn, đặc biệt trong việc dự báo ngắn hạn, nhờ khả năng học các mẫu lặp lại và phụ thuộc thời gian.

Đối với các phương pháp học sâu kết hợp, nhiều nghiên cứu đã sử dụng LSTM kết hợp các kỹ thuật phân tách tín hiệu (signal decomposition) để cải thiện hiệu quả dự báo. Ví dụ, bài “Exchange Rate Forecasting: A Deep Learning Framework Combining Adaptive Signal Decomposition and Dynamic Weight Optimization” (MDPI, 2024) đã đề xuất một khung công tác kết hợp phân rã tín hiệu (signal decomposition) với LSTM để nắm bắt đặc điểm phi tuyến, không dừng và nhiễu của chuỗi tỷ giá. Kết quả nghiên cứu cho thấy mô hình này có độ linh hoạt cao và hiệu suất tốt hơn so với các mô hình tuyến tính truyền thống dưới điều kiện thị trường phức tạp.

Một hướng khác là sử dụng LSTM để dự báo biến động (volatility) thị trường ngoại hối, chứ không chỉ dự báo tỷ giá. Trong bài “Forecasting implied volatilities of currency options with machine learning techniques and econometrics models”, tác giả so sánh LSTM với các mô hình AR GARCH và random forest. Kết quả cho thấy LSTM vượt AR GARCH ở các hợp đồng quyền chọn ngắn hạn, vì khả năng ghi nhớ cụm biến động (volatility clustering) và tính phi tuyến mang lại lợi thế lớn, nhưng khi kỳ hạn quyền chọn dài hơn, các mô hình GARCH lại chiếm ưu thế hơn.

Ngoài ra, nghiên cứu gần đây của Frontiers (2025) với tiêu đề “Artificial intelligence and exchange rate forecasting: assessing predictive accuracy and macroeconomic sensitivity” đã xây dựng ba mô hình: Multilayer Perceptron (MLP), Random Forest, và LSTM, để dự báo cặp EUR/USD. Kết quả cho thấy LSTM đạt R^2 rất cao (~ 0.9234), vượt trội so với hai mô hình khác, khẳng định khả năng mô hình hóa các phụ thuộc chuỗi thời gian phi tuyến. Đồng thời, nghiên cứu hé lộ rằng sai số dự báo của mô hình học máy / học sâu lại chỉ có mối liên hệ yếu với các chỉ báo vĩ mô truyền thống như lãi suất, lạm phát, GDP, cho thấy biến động tỷ giá ngắn hạn có thể bị chi phối nhiều bởi các yếu tố thị trường kỹ thuật hơn là nền tảng kinh tế vĩ mô.

Cuối cùng, việc ứng dụng LSTM còn được mở rộng theo hướng kết hợp với phương pháp phân rã như EMD (Empirical Mode Decomposition). Ví dụ, Ullah,

Rehman et al. (2024) dự báo tỷ giá CNY/USD bằng cách sử dụng mô hình LSTM và XGBoost, và cho thấy LSTM cho kết quả tốt hơn XGBoost trên bộ dữ liệu ba năm. Một số mô hình khác như EMD LSTM SVR (tức kết hợp phân rã theo EMD, LSTM và SVR) cũng đã được đề xuất để nâng cao khả năng khái quát hóa và dự báo chính xác hơn, đặc biệt với dữ liệu tỷ giá phi tuyến, phi dừng.

2.3.3. Khoảng trống Nghiên cứu

Các nghiên cứu trước đây trong nước chủ yếu tập trung vào việc dự báo tỷ giá USD/VND bằng các mô hình kinh tế lượng truyền thống như ARIMA, GARCH hoặc các biến động vĩ mô cơ bản, trong khi ứng dụng các phương pháp học máy và học sâu còn rất hạn chế. Các nghiên cứu quốc tế đã chỉ ra tiềm năng vượt trội của các mô hình học máy và học sâu, đặc biệt LSTM, trong việc nắm bắt các đặc tính phi tuyến, phụ thuộc theo thời gian và biến động phức tạp của tỷ giá. Tuy nhiên, hầu hết các nghiên cứu quốc tế chỉ tập trung trên từng nhóm mô hình riêng lẻ hoặc so sánh một vài mô hình trên các bộ dữ liệu nước ngoài, chưa có nghiên cứu nào thực hiện so sánh toàn diện giữa các mô hình thuộc các nhóm khác nhau trên cùng một bộ dữ liệu có nhiều biến động như tại thị trường Việt Nam.

Trong bối cảnh thị trường Việt Nam với tỷ giá USD/VND chịu ảnh hưởng đồng thời của nhiều yếu tố vĩ mô, giá dầu và biến động đồng USD toàn cầu, việc lựa chọn mô hình dự báo phù hợp là rất quan trọng. Do đó, nghiên cứu này nhằm thực hiện so sánh đồng thời 4 mô hình đại diện cho 3 nhóm phương pháp khác nhau, gồm ARIMA (kinh tế lượng truyền thống), Random Forest (học máy), XGBoost (học máy nâng cao), và LSTM (học sâu). Mục tiêu là xác định mô hình tối ưu nhất trong việc dự báo tỷ giá USD/VND trong bối cảnh hiện tại, đồng thời cung cấp cơ sở khoa học cho các ứng dụng thực tiễn trong quản lý rủi ro tỷ giá và hoạch định chính sách tiền tệ.

Nghiên cứu này lấp đầy khoảng trống quan trọng giữa nghiên cứu trong nước và quốc tế, vừa kết hợp kinh nghiệm mô hình truyền thống, vừa ứng dụng các kỹ thuật học máy tiên tiến, tạo ra giá trị mới trong dự báo tỷ giá tại Việt Nam.

KẾT LUẬN CHƯƠNG 2

Chương 2 đã tổng quan các nghiên cứu liên quan về dự báo tỷ giá hối đoái, bao gồm cả nghiên cứu trong nước và quốc tế, nhằm xác định các yếu tố tác động quan trọng và khoảng trống nghiên cứu. Các nghiên cứu trong nước chủ yếu áp dụng các mô hình kinh tế lượng truyền thống như ARIMA và GARCH để dự báo tỷ giá USD/VND, trong khi ứng dụng các mô hình học máy và học sâu vẫn còn hạn chế. Nghiên cứu quốc tế cho thấy các mô hình học máy, đặc biệt LSTM, có khả năng nắm bắt các đặc tính phi tuyến, phụ thuộc thời gian và biến động phức tạp của tỷ giá vượt trội hơn so với các mô hình tuyến tính truyền thống.

Chương này cũng làm rõ các yếu tố kinh tế vĩ mô ảnh hưởng đến tỷ giá USD/VND, bao gồm lợi suất trái phiếu Mỹ (US10Y), dòng vốn đầu tư gián tiếp nước ngoài và thị trường chứng khoán (VNINDEX), giá dầu Brent (OIL_BRENT), cùng sức mạnh đồng USD (DXY), tạo cơ sở lý thuyết và thực nghiệm cho việc lựa chọn biến độc lập trong mô hình dự báo.

Từ tổng quan các nghiên cứu và cơ sở lý thuyết, khoảng trống nghiên cứu được xác định là chưa có nghiên cứu nào thực hiện so sánh toàn diện các mô hình thuộc nhiều nhóm phương pháp khác nhau (ARIMA, Random Forest, XGBoost, LSTM) trên cùng một bộ dữ liệu có nhiều biến động tại Việt Nam. Đây là cơ sở để luận văn tiếp tục xây dựng mô hình dự báo tỷ giá USD/VND tại chương 3, nhằm xác định mô hình tối ưu và phù hợp với điều kiện thị trường Việt Nam hiện nay, đồng thời góp phần nâng cao hiệu quả dự báo và quản lý rủi ro tỷ giá.

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

3.1. DỮ LIỆU NGHIÊN CỨU VÀ THỐNG KÊ MÔ TẢ

3.1.1. Nguồn Dữ liệu và Phạm vi Nghiên cứu

Trong nghiên cứu này, tác giả sử dụng bộ dữ liệu chuỗi thời gian với tần suất hàng ngày nhằm phân tích và dự báo biến động tỷ giá USD/VND trong bối cảnh thị trường tài chính Việt Nam ngày càng gắn kết với các biến động quốc tế. Tất cả dữ liệu được thu thập từ Investing.com, một nguồn dữ liệu tài chính quốc tế có mức độ tin cậy cao và được sử dụng phổ biến trong các nghiên cứu học thuật cũng như trong thực tiễn phân tích thị trường. Việc lựa chọn nguồn dữ liệu này giúp đảm bảo tính khách quan, khả năng cập nhật liên tục và mức độ nhất quán của các biến kinh tế vĩ mô đưa vào mô hình.

Biến phụ thuộc của nghiên cứu là tỷ giá bán ra USD/VND của các Ngân hàng Thương mại tại Việt Nam. Đây là loại tỷ giá phản ánh trực tiếp chi phí mà các chủ thể kinh tế trong nước phải bỏ ra để mua đồng USD, nhờ đó thể hiện rõ tình hình cung – cầu ngoại tệ, tâm lý thị trường và sự điều hành của cơ quan quản lý. Việc sử dụng tỷ giá bán ra thay vì tỷ giá trung tâm giúp mô hình tiếp cận sát thực hơn với diễn biến thị trường và các kỳ vọng kinh tế trong nước.

Bên cạnh đó, nghiên cứu đưa vào bốn biến kinh tế vĩ mô ngoại sinh nhằm phản ánh những yếu tố quốc tế có tác động đáng kể đến biến động tỷ giá. Chỉ số DXY đại diện cho sức mạnh của đồng USD trên phạm vi toàn cầu, từ đó phản ánh xu hướng chung của thị trường tiền tệ quốc tế. Biến giá dầu Brent giao sau lại đóng vai trò như một chỉ báo quan trọng đối với các nền kinh tế nhập khẩu năng lượng như Việt Nam, bởi sự biến động của giá dầu có ảnh hưởng trực tiếp đến chi phí nhập khẩu, cán cân thương mại và lạm phát kỳ vọng. Bên cạnh các yếu tố quốc tế, nghiên cứu sử dụng chỉ số VNINDEX để phản ánh sự thay đổi của thị trường chứng khoán Việt Nam cũng như xu hướng dòng vốn đầu tư gián tiếp nước ngoài; sự tăng hoặc giảm mạnh của chỉ số này thường gắn với hành vi dịch chuyển vốn và có thể tạo sức ép lên tỷ giá. Cuối cùng, lợi suất trái phiếu Chính phủ Hoa Kỳ kỳ hạn 10 năm được xem như thước đo quan trọng về mức sinh lời phi rủi ro toàn cầu và kỳ vọng chính sách tiền tệ của FED.

Khi lợi suất tăng, đồng USD thường trở nên hấp dẫn hơn, làm gia tăng áp lực mất giá lên đồng VND.

Phạm vi thời gian của bộ dữ liệu kéo dài từ ngày 01/01/2015 đến 30/09/2025, bao quát giai đoạn hơn mười năm với nhiều biến động kinh tế quan trọng. Khoảng thời gian này không chỉ bao gồm các giai đoạn kinh tế ổn định mà còn chứa đựng những cú sốc lớn như đại dịch COVID-19 cùng sự đứt gãy chuỗi cung ứng toàn cầu trong giai đoạn 2020–2021, hay chu kỳ tăng lãi suất mạnh mẽ của FED trong giai đoạn 2022–2023. Những biến động này tạo điều kiện để mô hình học được sự thay đổi của tỷ giá trong cả điều kiện bình thường lẫn các giai đoạn chịu tác động mạnh từ bên ngoài, giúp nâng cao tính đại diện và khả năng tổng quát hóa của kết quả dự báo.

Sau khi tiến hành các bước xử lý dữ liệu gồm đồng bộ tần suất giữa các chuỗi thời gian, loại bỏ các quan sát không hợp lệ và xử lý giá trị thiếu theo phương pháp nội suy phù hợp, bộ dữ liệu cuối cùng thu được 1.105 quan sát hợp lệ. Với quy mô mẫu này, mô hình có đủ độ phủ để nhận diện các mối quan hệ động giữa tỷ giá và những biến kinh tế vĩ mô quan trọng, đồng thời tạo nền tảng vững chắc cho việc xây dựng, đánh giá và so sánh các phương pháp dự báo tỷ giá trong bối cảnh hội nhập tài chính quốc tế của Việt Nam.

3.1.2. Thống kê mô tả

Bảng 3.1: Thống kê mô tả các biến nghiên cứu

Biến	Số quan sát	Giá trị trung bình	Độ lệch chuẩn	Giá trị nhỏ nhất	Giá trị lớn nhất
USDVND_RATE	1.105	23.334,336	1.094,954	21.115	26.415
DXY	1.105	98,255	4,948	89,03	114,11
OIL_BRENT	1.105	66,485	17,848	19,33	121,60
VNINDEX	1.105	985,292	282,971	536,45	1.696,29
US10Y	1.105	2,593	1,120	0,512	4,926

(Nguồn: Kết quả tính toán từ phần mềm Python)

Kết quả thống kê mô tả cho thấy các biến trong bộ dữ liệu có mức độ biến động đáng kể trong toàn bộ giai đoạn nghiên cứu. Đối với tỷ giá USD/VND, giá trị


trung bình đạt khoảng 23.334 VND/USD, tuy nhiên khoảng dao động lại khá rộng, từ mức thấp nhất chỉ 21.115 VND đến mức cao nhất lên tới 26.415 VND. Điều này phản ánh mức độ nhạy cảm của thị trường ngoại hối Việt Nam trước các biến động kinh tế toàn cầu cũng như trước các thay đổi trong chính sách điều hành tiền tệ của Ngân hàng Nhà nước. Độ lệch chuẩn lớn (1.094,95) cho thấy sự biến động mạnh và không ổn định của tỷ giá trong nhiều thời điểm, đặc biệt trong các giai đoạn bất định như đại dịch COVID-19 hay chu kỳ thắt chặt chính sách tiền tệ toàn cầu.

Các biến vĩ mô ngoại sinh cũng thể hiện mức độ biến động đáng kể. Chỉ số DXY có giá trị trung bình khoảng 98,26 điểm nhưng dao động từ 89,03 đến hơn 114 điểm, cho thấy đồng USD trải qua những chu kỳ mạnh – yếu rõ nét trên thị trường quốc tế. Biến giá dầu Brent cho thấy xu hướng thay đổi tương đối rộng, từ 19,33 USD/thùng đến hơn 121 USD/thùng, phản ánh tác động của các cú sốc cung – cầu năng lượng toàn cầu, khủng hoảng địa chính trị và sự phục hồi kinh tế sau đại dịch. Tương tự, chỉ số VNINDEX dao động từ 536,45 điểm đến hơn 1.696 điểm, cho thấy thị trường chứng khoán Việt Nam có sự tăng trưởng nhanh nhưng đồng thời cũng chịu ảnh hưởng mạnh trước các biến động tài chính quốc tế.

Đối với lợi suất trái phiếu Chính phủ Mỹ kỳ hạn 10 năm (US10Y), mức trung bình chỉ ở mức 2,593% nhưng dao động từ 0,512% đến gần 5%, phản ánh rõ ràng quá trình điều chỉnh mạnh mẽ của FED trong giai đoạn hậu COVID-19, đặc biệt là thời kỳ tăng lãi suất nhanh nhất trong bốn thập kỷ vào năm 2022–2023. Biên độ giao động lớn của US10Y là minh chứng cho sự thay đổi mạnh trong kỳ vọng thị trường toàn cầu, từ môi trường lãi suất thấp kéo dài sang xu hướng thắt chặt tiền tệ.

Nhìn chung, bộ dữ liệu cho thấy sự biến động phức tạp và không đồng nhất giữa các biến số, đặc biệt tại những thời điểm thị trường gặp cú sốc lớn. Điều này đặt ra yêu cầu cao đối với quá trình xử lý dữ liệu, bao gồm việc loại bỏ các quan sát bất thường, xử lý ngày nghỉ thị trường, đồng bộ tần suất và giảm thiểu sai lệch giữa các chuỗi thời gian. Nhờ quá trình làm sạch dữ liệu được thực hiện nghiêm ngặt, dữ liệu đầu vào cuối cùng có độ tin cậy cao và phù hợp để áp dụng trong các mô hình dự báo trong các phần tiếp theo.

3.1.3. Phân tích Ma trận Tương quan



Hình 3.1: Ma trận tương quan giữa các biến nghiên cứu

(Nguồn: Kết quả tính toán từ phần mềm Python)

Kết quả từ ma trận tương quan cho thấy các biến trong mô hình đều có mối quan hệ nhất định với tỷ giá USD/VND, đồng thời phản ánh khá rõ các cơ chế truyền dẫn kinh tế vĩ mô trong giai đoạn nghiên cứu. Trong đó, biến US10Y – lợi suất trái phiếu Chính phủ Mỹ kỳ hạn 10 năm – thể hiện mức độ tương quan mạnh nhất với tỷ giá, với hệ số khoảng 0,73. Điều này hoàn toàn phù hợp với lý thuyết Lãi suất ngang giá (Interest Rate Parity), theo đó sự gia tăng lợi suất tại Mỹ làm tăng sức hấp dẫn của đồng USD, kéo theo dòng vốn quốc tế dịch chuyển về thị trường Hoa Kỳ, dẫn tới áp lực tăng tỷ giá USD/VND. Mối liên hệ chặt chẽ này cũng khớp với các diễn biến

thực tế trong giai đoạn 2022–2023, khi FED tăng lãi suất mạnh và đồng USD đạt mức cao nhất trong 20 năm.

Ngoài ra, biến VNINDEX cũng cho thấy tương quan đáng kể với tỷ giá, với hệ số xấp xỉ 0,70. Điều này hàm ý rằng sự biến động của thị trường chứng khoán Việt Nam có thể gắn liền với dòng vốn đầu tư gián tiếp nước ngoài, qua đó ảnh hưởng đến cung – cầu ngoại tệ. Khi thị trường chứng khoán suy giảm, tâm lý rủi ro gia tăng và dòng vốn có xu hướng rời khỏi thị trường mới nổi, tạo áp lực khiến đồng VND mất giá. Ngược lại, những giai đoạn thị trường tăng trưởng mạnh thường đi kèm với sự cải thiện của dòng vốn ngoại, giúp giảm áp lực lên tỷ giá. Mức độ tương quan này vì vậy thể hiện tính kết nối ngày càng sâu của Việt Nam với thị trường tài chính toàn cầu.

Chỉ số DXY – đại diện cho sức mạnh tổng hợp của đồng USD – cũng thể hiện mối tương quan khá cao với tỷ giá USD/VND, khoảng 0,56, cho thấy khi USD tăng giá trên bình diện quốc tế thì đồng VND cũng chịu áp lực mất giá tương ứng. Đây là mối quan hệ mang tính hệ thống, phản ánh việc đồng USD vẫn giữ vai trò chủ chốt trong thương mại và tài chính toàn cầu. Bên cạnh đó, giá dầu Brent cũng có mức tương quan đáng kể với tỷ giá, khoảng 0,39. Mặc dù mức độ thấp hơn các biến khác, mối quan hệ này vẫn mang ý nghĩa kinh tế quan trọng do Việt Nam là nước nhập khẩu dầu thô ròng, nên giá dầu tăng thường kéo theo chi phí nhập khẩu cao hơn, ảnh hưởng đến cán cân thương mại và tạo áp lực nhất định lên tỷ giá.

Nhìn chung, ma trận tương quan cho thấy không chỉ biến phụ thuộc mà cả các biến độc lập đều có mối quan hệ đa chiều, vừa trực tiếp vừa gián tiếp, phản ánh sự tương tác phức tạp của nền kinh tế mở. Sự tồn tại của các mức tương quan từ trung bình đến mạnh giữa các biến củng cố cơ sở lý thuyết về lựa chọn bộ biến vĩ mô trong mô hình dự báo, đồng thời cho thấy các mô hình Học máy và Học sâu hoàn toàn phù hợp để khai thác các mối quan hệ mang tính phi tuyến và có độ tương tác cao trong dữ liệu tài chính.

3.2. QUY TRÌNH TIỀN XỬ LÝ DỮ LIỆU

Dữ liệu tài chính thô thường chứa nhiều nhiễu và không đồng nhất do sự khác biệt về ngày giao dịch, ngày nghỉ lễ giữa các thị trường, cũng như do sự chênh lệch lớn về quy mô và đơn vị đo lường giữa các biến số. Những yếu tố này nếu không được xử lý cẩn thận sẽ gây sai lệch trong quá trình huấn luyện mô hình, làm giảm khả năng khái quát hóa và dẫn đến kết quả dự báo không ổn định. Vì vậy, nghiên cứu tiến hành một quy trình tiền xử lý dữ liệu nghiêm ngặt gồm nhiều giai đoạn liên tiếp nhằm đảm bảo chất lượng và tính nhất quán của tập dữ liệu đầu vào trước khi xây dựng mô hình dự báo.

Bộ dữ liệu ban đầu gồm 2.806 quan sát. Tuy nhiên, sau khi chuẩn hóa định dạng ngày, xử lý các giá trị thiếu, loại bỏ các quan sát không hợp lệ và đồng bộ hóa tần suất giữa các biến vĩ mô, bộ dữ liệu cuối cùng còn 1.105 quan sát hợp lệ. Đây là quy trình phổ biến trong các nghiên cứu chuỗi thời gian đa biến nhằm đảm bảo tính toàn vẹn của dữ liệu trước khi đưa vào mô hình.

3.2.1. Xử lý dữ liệu thiếu

Do sự khác biệt trong lịch giao dịch giữa thị trường Việt Nam, nơi các biến như USDVND và VNINDEX được niêm yết, và các thị trường quốc tế như Hoa Kỳ hoặc London, nơi cung cấp các biến DXY, US10Y và OIL_BRENT, dữ liệu thu thập thường xuất hiện những điểm khuyết. Điều này là hiện tượng phổ biến khi kết hợp dữ liệu đa thị trường ở tần suất hàng ngày, bởi mỗi sàn giao dịch có quy định riêng về ngày nghỉ lễ, ngày tạm ngừng giao dịch, hoặc thay đổi lịch hoạt động theo từng giai đoạn.

Để xử lý các điểm dữ liệu bị thiếu, nghiên cứu áp dụng kỹ thuật điền tiền. Phương pháp này hoạt động theo cơ chế đơn giản nhưng hiệu quả: giá trị bị thiếu tại thời điểm t sẽ được thay thế bằng giá trị quan sát gần nhất trước đó, tức là giá trị tại thời điểm $t-1$. Cách tiếp cận này giả định rằng trong những ngày không có giao dịch, giá trị của tài sản hoặc chỉ báo kinh tế không thay đổi cho đến khi xuất hiện thông tin hoặc giao dịch mới. Đây được xem là giả định phù hợp đối với dữ liệu tài chính, nơi các biến thường chỉ thay đổi khi thị trường hoạt động.

Việc lựa chọn phương pháp điền tiền cũng nhằm tránh các sai lệch do các kỹ thuật nội suy khác gây ra, chẳng hạn như nội suy tuyến tính hoặc nội suy theo trung bình động, vốn có thể tạo ra những biến động giả trong chuỗi thời gian và làm méo thông tin thực tế của thị trường. Nhờ đó, chuỗi dữ liệu sau xử lý vừa đảm bảo tính liên tục, vừa duy trì được đặc tính tự nhiên của biến động giá, giúp mô hình học được xu hướng chính xác hơn trong các giai đoạn huấn luyện và dự báo.

3.2.2. Chuẩn hóa Dữ liệu

Các biến số trong bộ dữ liệu có đơn vị đo lường và quy mô khác nhau một cách đáng kể. Tỷ giá USD/VND dao động ở mức rất cao, khoảng 23.000–25.000, trong khi lợi suất trái phiếu Chính phủ Mỹ kỳ hạn 10 năm (US10Y) chỉ nằm trong khoảng từ 0 đến 5. Sự khác biệt lớn về thang đo này tạo ra sự mất cân đối trong quá trình huấn luyện, đặc biệt với các mô hình Học sâu như LSTM vốn phụ thuộc mạnh vào cơ chế tối ưu hóa bằng Gradient Descent. Khi không được chuẩn hóa, các biến có giá trị lớn sẽ chi phối quá trình học, khiến mô hình khó hội tụ và làm suy giảm hiệu quả dự báo. Để khắc phục vấn đề này, nghiên cứu áp dụng kỹ thuật Min-Max Scaling nhằm đưa toàn bộ các biến về chung một phạm vi từ 0 đến 1. Phương pháp này được tính toán dựa trên công thức $X_{\text{scaled}} = (X - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}})$, trong đó X là giá trị ban đầu và X_{min} , X_{max} lần lượt là giá trị nhỏ nhất và lớn nhất của biến trong tập huấn luyện. Việc chuẩn hóa theo cách này giúp mô hình hoạt động ổn định hơn, tăng tốc độ hội tụ và đảm bảo sự công bằng giữa các biến khi tham gia vào quá trình học.

3.2.3. Kỹ thuật Tạo độ trễ

Trong các bài toán dự báo chuỗi thời gian theo hướng học có giám sát, dữ liệu gốc cần phải được chuyển đổi sang dạng cặp Input–Target để mô hình có thể học được mối quan hệ giữa quá khứ và tương lai. Nghiên cứu lựa chọn độ dài cửa sổ quan sát là 20 ngày, tức mô hình sẽ sử dụng thông tin của 20 phiên giao dịch liên tiếp trước thời điểm dự báo để dự đoán tỷ giá của ngày hiện tại. Việc chọn ngưỡng 20 ngày phản ánh hợp lý chu kỳ của một tháng giao dịch thực tế trên thị trường tài chính, giúp mô hình thu giữ được các tín hiệu xu hướng ngắn hạn và trung hạn cũng như các động

lượng thị trường đang diễn ra. Sau khi áp dụng cơ chế cửa sổ trượt này, dữ liệu đầu vào được tái cấu trúc tương ứng với từng nhóm mô hình. Đối với LSTM, dữ liệu có dạng ba chiều (Samples, 20, 5), phù hợp với cách LSTM xử lý chuỗi theo từng bước thời gian. Trong khi đó, đối với các mô hình Học máy truyền thống như Random Forest hoặc XGBoost, dữ liệu được trải phẳng thành hai chiều với mỗi mẫu bao gồm 100 đặc trưng, tương ứng với 20 ngày quan sát nhân với số lượng 5 biến đầu vào. Cấu trúc này đảm bảo tính nhất quán trong toàn bộ quy trình và tạo điều kiện cho mô hình khai thác tối đa thông tin từ chuỗi thời gian.

3.2.4. Chia tập Dữ liệu

Để bảo đảm việc đánh giá mô hình phản ánh đúng năng lực dự báo trong thực tế, bộ dữ liệu được chia thành ba phần riêng biệt theo đúng trình tự thời gian mà không sử dụng bất kỳ thao tác xáo trộn nào. Cách phân chia này nhằm loại bỏ hoàn toàn nguy cơ rò rỉ thông tin từ tương lai vào mô hình, một lỗi phổ biến khiến kết quả đánh giá bị sai lệch. Trong nghiên cứu, 70% số quan sát đầu tiên, tương đương khoảng 761 mẫu, được sử dụng làm tập huấn luyện nhằm giúp mô hình học các quy luật và quan hệ giữa các biến. Ngay sau đó, 15% dữ liệu tiếp theo, khoảng 162 mẫu, được dành cho tập thẩm định, phục vụ quá trình tinh chỉnh siêu tham số và triển khai cơ chế dừng sớm trong mô hình LSTM để hạn chế hiện tượng quá khớp. Phần dữ liệu còn lại, chiếm 15% cuối cùng với khoảng 162 mẫu tương ứng với giai đoạn gần nhất cho đến năm 2025, được sử dụng làm tập kiểm định. Đây là phần dữ liệu hoàn toàn tách biệt và không tham gia vào bất kỳ bước huấn luyện nào, giúp đánh giá chính xác chất lượng dự báo cuối cùng và tạo cơ sở so sánh giữa các mô hình.

3.3. CÁC MÔ HÌNH DỰ BÁO CHI TIẾT

Dựa trên đặc điểm của bộ dữ liệu và mục tiêu so sánh giữa các hướng tiếp cận, nghiên cứu triển khai bốn mô hình đại diện cho ba trường phái dự báo chính gồm Kinh tế lượng (ARIMA), Học máy (Random Forest và XGBoost) và Học sâu (LSTM). Sự kết hợp này cho phép đánh giá toàn diện khả năng nắm bắt động thái của tỷ giá USD/VND dưới cả góc nhìn tuyến tính truyền thống lẫn các phương pháp phi tuyến hiện đại.

3.3.1. Mô hình ARIMA

Trong nghiên cứu, ARIMA được sử dụng như mô hình cơ sở nhờ khả năng mô tả tốt các chuỗi tài chính có tính phi ổn định, vốn là đặc điểm phổ biến của tỷ giá hối đoái. Cấu trúc ARIMA(p, d, q) bao gồm ba thành phần với vai trò bổ trợ lẫn nhau: phần tự hồi quy AR thể hiện sự phụ thuộc của giá trị hiện tại vào những quan sát trong quá khứ; phần sai phân I nhằm loại bỏ xu hướng và chuyển chuỗi từ trạng thái phi ổn định sang ổn định; và phần trung bình trượt MA mô tả tác động của các sai số dự báo trước đó. Sự kết hợp của ba yếu tố này giúp mô hình không chỉ nắm bắt được xu hướng dài hạn của tỷ giá mà còn mô phỏng được những biến động ngắn hạn mang tính nhiễu đặc trưng của thị trường ngoại hối.

Sau khi chuỗi được sai phân bậc d , mô hình ARIMA(p, d, q) được biểu diễn dưới dạng tổng quát như sau:

$$Y'_t = c + \sum_{i=1}^{\{p\}} \phi_i Y'_{t-i} + \sum_{j=1}^{\{q\}} \theta_j \epsilon_{t-j} + \epsilon_t$$

Trong đó, Y'_t là chuỗi tỷ giá đã được sai phân để đạt tính ổn định; ϕ_i là các tham số tự hồi quy (AR) phản ánh tác động của các giá trị quá khứ; θ_j là các tham số trung bình trượt (MA) mô tả tác động của sai số dự báo; và ϵ_t là nhiễu trắng tại thời điểm t .

Để tránh tính chủ quan trong việc lựa chọn tham số (p, d, q), nghiên cứu sử dụng thuật toán Auto ARIMA (thư viện pmdarima) nhằm tự động kiểm tra tính dừng, xác định bậc sai phân tối ưu và đánh giá các tổ hợp tham số dựa trên tiêu chí AIC. Cách tiếp cận này bảo đảm mô hình được lựa chọn có mức độ phù hợp cao nhất với dữ liệu tỷ giá USD/VND.

3.3.2. Các Mô hình học máy

Các mô hình học máy được sử dụng trong nghiên cứu nhằm khai thác những quan hệ phi tuyến giữa tỷ giá USD/VND và các biến kinh tế vĩ mô, vốn là những quan hệ mà các mô hình tuyến tính truyền thống thường khó mô tả đầy đủ. Do các thuật toán học máy như Random Forest hay XGBoost không thể xử lý trực tiếp dữ liệu chuỗi thời gian theo dạng tuần tự, bộ dữ liệu được chuyển đổi thông qua kỹ thuật

trải phẳng (flattening). Cụ thể, với mỗi quan sát dự báo, một cửa sổ thời gian dài 20 ngày được xây dựng, bao gồm các giá trị quan sát liên tiếp của năm biến số, tạo thành ma trận kích thước 20×5 . Ma trận này sau đó được trải phẳng thành một vector đặc trưng duy nhất có kích thước 1×100 , cho phép toàn bộ thông tin về diễn biến tỷ giá và các biến kinh tế vĩ mô trong 20 ngày gần nhất được đưa vào mô hình dưới dạng dữ liệu bảng. Biến đầu vào của mô hình bao gồm chuỗi tỷ giá bán ra USD/VND của các ngân hàng thương mại Việt Nam trong vai trò biến phụ thuộc, cùng với bốn biến kinh tế vĩ mô ngoại sinh là DXY, OIL_BRENT, VNINDEX và US10Y. Tất cả các biến đều được thu thập theo tần suất ngày và được sắp xếp liên tục trong cửa sổ thời gian 20 ngày, tạo nên một cấu trúc dữ liệu ổn định và phù hợp cho việc huấn luyện các mô hình học máy. Cách tiếp cận này không chỉ giúp các thuật toán khai thác được cả thông tin quá khứ lẫn các động thái ngắn hạn, mà còn đảm bảo tính tương thích giữa dữ liệu chuỗi thời gian và mô hình dự báo dạng phi tuyến.

3.3.2.1. Random Forest

Cấu trúc mô hình trong nghiên cứu gồm 200 cây quyết định, và dự báo tại thời điểm t được tính bằng trung bình của các cây như sau:

$$\hat{Y}_t = \frac{1}{B} \sum_{b=1}^B f_b(X_t)$$

B là số cây trong rừng,

$f_b(\cdot)$ là dự báo của cây thứ b ,

X_t là vector đặc trưng gồm **100 biến** (tương ứng $20 \text{ ngày} \times 5 \text{ biến vĩ mô}$).

Trong đó, $B = 200$ là số cây được sử dụng trong mô hình; $f_b(\cdot)$ là dự báo của cây quyết định thứ b ; còn X_t là vector đặc trưng đầu vào gồm 100 biến, được tạo ra bằng kỹ thuật flattening từ 20 ngày quan sát liên tiếp của 5 biến kinh tế vĩ mô.

3.3.2.2. XGBoost

$$\hat{Y}_t^{(k)} = \hat{Y}_t^{(k-1)} + f_k(X_t)$$

$\hat{Y}_t^{(k)}$ là dự báo sau khi thêm cây thứ k ,


$f_k(\cdot)$ là cây mới được huấn luyện để giảm hàm mất mát,

X_t là vectơ đặc trưng gồm 100 biến giống như Random Forest.

Trong đó, $\hat{Y}_t^{(k)}$ là giá trị dự báo sau khi mô hình thêm cây thứ k ; $f_k(\cdot)$ là cây quyết định mới được huấn luyện để giảm hàm mất mát bằng cách tập trung vào phần sai số còn lại của mô hình ở bước $k - 1$; và X_t là vectơ đầu vào gồm 100 biến đặc trưng được tạo từ 20 ngày quan sát của 5 biến kinh tế vĩ mô (tương tự như mô hình Random Forest).

Sau bước tính toán trong công thức, XGBoost tiếp tục huấn luyện tuần tự các cây tiếp theo để lần lượt sửa sai số mà các cây trước đó chưa giải thích được. Nhờ cơ chế boosting kết hợp với regularization, mô hình có khả năng nắm bắt quan hệ phi tuyến phức tạp và hạn chế hiện tượng quá khớp, giúp XGBoost thường đạt hiệu suất cao trong bài toán dự báo tỷ giá USD/VND vốn chứa nhiều nhiễu và biến động.

3.3.3. Mô hình LSTM



Hình 3.2: Kiến trúc của một tế bào nhớ LSTM

(Nguồn: InterData, 2025)

Dữ liệu được đưa vào dưới dạng ba chiều (Samples, Timesteps = 20, Features = 5). Mạng sử dụng một lớp LSTM 50 units, đi kèm Dropout 0.2 để hạn chế quá khớp. Đầu ra được kết nối qua một lớp Dense duy nhất để dự báo giá trị tỷ giá của ngày kế tiếp.

Công thức hoạt động của LSTM cell

Mỗi tế bào LSTM gồm ba cổng điều khiển thông tin:

Cổng quên:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Cổng đầu vào:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

Cập nhật trạng thái nhớ:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

Cổng đầu ra:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(C_t)$$

Trong đó, x_t là bộ đặc trưng tại thời điểm t , h_t biểu diễn trạng thái ẩn của mô hình, còn C_t là trạng thái nhớ lưu trữ thông tin dài hạn. Hàm $\sigma(\cdot)$ được sử dụng làm hàm kích hoạt sigmoid cho các cổng trong LSTM và ký hiệu $\odot$ thể hiện phép nhân từng phần tử giữa các vector. Trong quá trình huấn luyện, mô hình được tối ưu bằng hàm mất mát MSE và bộ tối ưu hóa Adam. Đồng thời, cơ chế Early Stopping được áp dụng nhằm dừng huấn luyện khi sai số trên tập thử nghiệm không còn giảm sau khoảng 10 đến 15 epochs, giúp hạn chế hiện tượng quá khớp và bảo đảm khả năng tổng quát hóa của mô hình.

3.4. TIÊU CHÍ ĐÁNH GIÁ MÔ HÌNH

Theo Hyndman và Koehler (2006), MAE được đánh giá là thước đo có tính ổn định cao và dễ diễn giải trong các nghiên cứu dự báo vì nó phản ánh trực tiếp sai số theo đơn vị gốc của dữ liệu. Việc sử dụng MAE giúp loại bỏ những hạn chế của các phương pháp tính sai số khác khi dữ liệu có sự phân phối không đồng nhất.

Sai số Tuyệt đối Trung bình phản ánh mức độ sai lệch trung bình giữa giá trị dự báo và giá trị thực tế mà không xét đến hướng sai lệch. Chỉ số này đo lường mức chênh lệch theo đơn vị gốc của tỷ giá, vì vậy rất dễ diễn giải trong bối cảnh thực tiễn. MAE được xác định theo công thức:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

Trong đó y_t là giá trị thực tế tại thời điểm t , $\hat{y}_t$ là giá trị dự báo của mô hình, và n là tổng số quan sát trong Tập Kiểm định. MAE càng nhỏ chứng tỏ dự báo của mô hình càng gần với thực tế và độ lệch trung bình càng thấp.

Diebold (2015) nhấn mạnh rằng trong các bài toán dự báo tài chính, RMSE đóng vai trò then chốt vì cơ chế bình phương sai số giúp "phạt nặng" các dự báo lệch lớn (outliers). Điều này đặc biệt quan trọng đối với các ngân hàng và doanh nghiệp khi quản trị rủi ro, vì những sai số dự báo lớn thường mang lại hậu quả tài chính nghiêm trọng hơn nhiều so với các sai số nhỏ.

Sai số Căn bậc hai Trung bình là chỉ số quan trọng dùng để đánh giá mức độ sai lệch giữa dự báo và thực tế, trong đó các sai số lớn được “phạt nặng” hơn do được bình phương trước khi tính trung bình. Điều này khiến RMSE đặc biệt hữu ích trong các bài toán dự báo tài chính, nơi những sai lệch đột biến—even nhỏ về mặt tần suất—có thể gây ảnh hưởng đáng kể đến độ tin cậy của mô hình. RMSE được xác định qua công thức:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

Giá trị RMSE càng nhỏ cho thấy mô hình càng ổn định và ít xuất hiện các dự báo sai nghiêm trọng. Ngược lại, RMSE cao là tín hiệu cho thấy mô hình chưa mô tả tốt các biến động mạnh hoặc có xu hướng mắc lỗi lớn tại một số thời điểm đặc thù.

Theo các kết quả từ cuộc thi M4 Competition, MAPE là chỉ số được ưu tiên sử dụng rộng rãi để chuẩn hóa sai số dự báo, tạo điều kiện thuận lợi cho việc so sánh hiệu suất giữa các mô hình khác nhau trên cùng một tập dữ liệu hoặc giữa các chuỗi dữ liệu có quy mô khác nhau.

Sai số Phần trăm Tuyệt đối Trung bình được xem là thước đo quan trọng nhất trong nghiên cứu này vì chuyển sai số tuyệt đối thành phần trăm so với giá trị thực tế. Cách biểu diễn này cho phép so sánh hiệu quả dự báo giữa các giai đoạn có mức

tỷ giá khác nhau cũng như giữa các mô hình có bản chất khác nhau. MAPE được tính theo biểu thức:

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

MAPE mang lại trực quan dễ hiểu: chẳng hạn, MAPE = 1% nghĩa là dự báo trung bình chỉ lệch 1% so với thực tế. Đồng thời, đây cũng là chỉ số được sử dụng phổ biến trong thực tiễn phân tích tài chính—bao gồm dự báo tỷ giá, hàng hóa, và chỉ số kinh tế—nhờ khả năng chuẩn hóa sai số và cho phép so sánh hiệu quả dự báo giữa nhiều mô hình và nhiều thị trường khác nhau.

KẾT LUẬN CHƯƠNG 3

Chương 3 đã trình bày chi tiết quy trình nghiên cứu và phương pháp luận được sử dụng để giải quyết bài toán dự báo tỷ giá hối đoái USD/VND. Cụ thể, nghiên cứu đã xây dựng một bộ dữ liệu chuỗi thời gian đa biến, tích hợp tỷ giá lịch sử với các yếu tố vĩ mô quan trọng, đồng thời thực hiện các bước tiền xử lý nghiêm ngặt bao gồm kiểm định tính ổn định, chuẩn hóa dữ liệu và chuyển đổi cấu trúc đầu vào phù hợp cho từng nhóm mô hình.

Nghiên cứu đã thiết lập thành công cấu hình cho bốn mô hình dự báo: mô hình kinh tế lượng ARIMA (sử dụng chuỗi sai phân bậc 1), mô hình Học sâu LSTM (sử dụng kỹ thuật cửa sổ trượt để bảo toàn tính tuần tự), và các mô hình Học máy Random Forest, XGBoost (sử dụng kỹ thuật trải phẳng). Các tiêu chí đánh giá hiệu suất bao gồm MAE, RMSE và MAPE cũng đã được xác định rõ ràng để đảm bảo tính khách quan trong việc so sánh kết quả. Những nội dung phương pháp luận này đóng vai trò là cơ sở khoa học vững chắc để tiến hành chạy mô hình và phân tích các kết quả thực nghiệm chi tiết trong Chương 4 tiếp theo.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

4.1. KẾT QUẢ ĐÁNH GIÁ TỔNG QUAN MÔ HÌNH

Bảng 4.1: Bảng Tổng hợp và Phân tích Hiệu suất

Mô hình	MAE (VND)	RMSE (VND)	MAPE (%)
ARIMA	622.42	751.18	2.4186
LSTM	571.06	675.81	2.5913
Random Forest	2042.05	2120.4	7.9849
XGBoost	2261.87	2332.26	8.8501

(Nguồn: Kết quả tính toán từ phần mềm Python)

Bảng 4.1 trình bày ba chỉ số đánh giá gồm MAE, RMSE và MAPE cho bốn mô hình dự báo ARIMA, LSTM, Random Forest và XGBoost. Kết quả cho thấy sự khác biệt rõ nét giữa các mô hình khi xem xét dưới các góc độ sai số tuyệt đối và sai số tương đối. Trước hết, LSTM là mô hình cho sai số tuyệt đối thấp nhất khi MAE đạt 571,06 VND và RMSE đạt 675,81 VND, phản ánh khả năng dự báo gần với giá trị thực và mức độ ổn định cao hơn trước các biến động bất thường. RMSE – vốn nhạy với các sai lệch lớn – cũng củng cố quan sát này khi cho thấy LSTM ít tạo ra các dự báo sai nghiêm trọng và duy trì độ ổn định tốt trong toàn bộ tập kiểm định.

Ở chiều ngược lại, ARIMA lại thể hiện ưu thế khi đánh giá theo sai số tương đối. Với MAPE chỉ ở mức 2,4186%, thấp nhất trong bốn mô hình, ARIMA cho thấy mức độ chính xác tương đối cao và ổn định hơn khi chuẩn hóa sai số theo tỷ lệ phần trăm. Đây là một đặc điểm quan trọng, bởi MAPE giúp so sánh hiệu quả dự báo giữa các mô hình ngay cả khi giá trị tỷ giá biến động trong các giai đoạn khác nhau, đồng thời phản ánh tốt khả năng theo sát xu hướng cơ bản của chuỗi thời gian.


Trong khi đó, Random Forest và XGBoost đạt kết quả kém hơn đáng kể khi cả ba chỉ số đều cao hơn nhiều so với ARIMA và LSTM. Cụ thể, MAPE của hai mô hình lần lượt ở mức 7,9849% và 8,8501%, cao hơn khoảng ba đến bốn lần so với hai mô hình còn lại. Nguyên nhân chủ yếu xuất phát từ việc dữ liệu chuỗi thời gian phải được xử lý bằng cách “trải phẳng” để phù hợp với cấu trúc của mô hình cây quyết

định. Quá trình này làm mất thông tin về thứ tự thời gian và nhịp biến động—yếu tố then chốt để mô hình nhận diện động thái và quán tính của tỷ giá. Khi các mối quan hệ theo thời gian bị làm phẳng thành dữ liệu dạng bảng, Random Forest và XGBoost không còn khả năng học được cấu trúc chuỗi, dẫn đến dự báo kém chính xác hơn đáng kể.

Tổng thể, kết quả cho thấy LSTM phù hợp hơn khi mục tiêu đề cao độ chính xác tuyệt đối và yêu cầu mô hình phản ứng tốt với các biến động lớn, trong khi ARIMA lại phù hợp khi ưu tiên tính chính xác tương đối và diễn giải đơn giản. Ngược lại, hai mô hình học máy truyền thống không khai thác được tính chất động của chuỗi tỷ giá nên không đạt hiệu suất cao.

4.2. PHÂN TÍCH CHI TIẾT KẾT QUẢ DỰ BÁO CỦA TỪNG MÔ HÌNH

4.2.1. Phân tích Mô hình Kinh tế lượng (ARIMA)



Hình 4.1: Biểu đồ dự báo ARIMA

(Nguồn: Kết quả từ phần mềm Python)

Kết quả dự báo tỷ giá USD/VND của mô hình ARIMA khi so sánh với chuỗi dữ liệu thực tế trong giai đoạn kiểm định cho thấy một đặc trưng quen thuộc của các mô hình tuyến tính truyền thống. Mặc dù ARIMA đạt giá trị MAPE thấp nhất trong toàn bộ các mô hình được thử nghiệm — cho thấy khả năng khớp khá tốt về mặt giá trị trung bình của chuỗi — nhưng đường dự báo của mô hình lại gần như nằm ngang, thể hiện rõ hiện tượng “flat forecast”. Đây là một biểu hiện phổ biến khi ARIMA phải


xử lý các chuỗi tài chính vốn có mức độ nhiễu cao, nhiều biến động đột ngột và tính phi tuyến mạnh.

Dự báo phẳng của ARIMA cho thấy mô hình chủ yếu tối ưu hóa sai số bằng cách tái tạo lại mức giá trung bình của giai đoạn kiểm định, thay vì mô phỏng động học thực sự của thị trường. Nhờ đó, sai số phần trăm tương đối (MAPE) được giảm đáng kể vì mô hình hiếm khi dự báo lệch quá xa khỏi giá trị vùng trung tâm của dữ liệu. Tuy nhiên, nhược điểm đi kèm là mô hình gần như không phản ứng với các biến động ngắn hạn, chẳng hạn như các cú tăng hoặc giảm đột biến xuất phát từ thay đổi trong chính sách tiền tệ, diễn biến vĩ mô, tâm lý thị trường hay sự mất cân đối tạm thời giữa cung và cầu ngoại tệ.

Khi quan sát đường thực tế của tỷ giá USD/VND trong giai đoạn kiểm định, có thể thấy chuỗi dữ liệu xuất hiện nhiều pha sóng ngắn, các cú nhảy (jumps), hoặc các đoạn “bật mạnh” về một phía. Toàn bộ các biến động này lại không được ARIMA nắm bắt, khiến đường dự báo của mô hình “trượt” khỏi thực tế trong các giai đoạn thị trường biến động mạnh. Điều này cho thấy mô hình tuy dự báo đúng “mức giá” (level) nhưng sai lệch đáng kể về “độ biến động”. Sự không khớp về biến động này là yếu tố quan trọng trong dự báo tài chính vì nhiều ứng dụng (đầu cơ ngắn hạn, định giá rủi ro, dự báo biên độ thay đổi) phụ thuộc mạnh vào khả năng nhận diện biên độ dao động chứ không chỉ giá trị kỳ vọng.

Hạn chế trên xuất phát từ bản chất của ARIMA: mô hình giả định cấu trúc tuyến tính, tính ổn định theo thời gian và không có khả năng học các quan hệ phi tuyến hoặc các thay đổi theo chế độ. Trong khi đó, thị trường ngoại hối thường xuyên chịu tác động của các yếu tố phi tuyến như kỳ vọng thị trường, động lực dòng vốn hay can thiệp chính sách. Chính vì vậy, mặc dù ARIMA đạt hiệu quả tốt về các chỉ số sai số tổng hợp, nhưng khả năng mô phỏng động học thực sự của tỷ giá vẫn còn hạn chế đáng kể. Điều này giải thích vì sao các mô hình phi tuyến hoặc mô hình học sâu (như LSTM, GRU, Transformer-based) thường được ưu tiên trong các bài toán dự báo tài chính hiện đại.

4.2.2. Phân tích mô hình học sâu LSTM



Hình 4.2: Biểu đồ dự báo LSTM

(Nguồn: Kết quả từ phần mềm Python)

Mô hình LSTM với 5 biến đầu vào, dù có MAPE cao hơn một chút so với ARIMA (2.5913% so với 2.4186%), lại thể hiện chất lượng dự báo tổng thể vượt trội khi xem xét cả biểu đồ trực quan lẫn các chỉ số sai số tuyệt đối. Điều này cho thấy LSTM không chỉ khớp với mức giá trung bình như ARIMA, mà còn khai thác được cấu trúc phụ thuộc phức tạp và phi tuyến vốn xuất hiện thường xuyên trong chuỗi dữ liệu tài chính.


Trước hết, về khả năng học xu hướng, LSTM là mô hình duy nhất mô phỏng chính xác xu hướng tăng mạnh của tỷ giá USD/VND ở đoạn cuối chuỗi (kể từ mốc quan sát thứ 80 trở đi), như thể hiện trong Hình 4.2. Đây là minh chứng cho việc mạng thần kinh dạng chuỗi đã hấp thụ và xử lý hiệu quả mối liên hệ phi tuyến giữa tỷ giá và các yếu tố kinh tế vĩ mô gồm DXY, OIL, VNINDEX và US10Y. Không giống các mô hình tuyến tính chỉ dựa vào quan hệ tuần tự của chính biến tỷ giá, LSTM có khả năng tiếp nhận cùng lúc nhiều tín hiệu thị trường và học được cách mà các yếu tố này tương tác và lan truyền ảnh hưởng theo thời gian. Nhờ đó, mô hình tái hiện được chuyển động theo xu hướng ngay khi thị trường bước vào giai đoạn biến động mạnh điều mà ARIMA đơn biến hoàn toàn không thể hiện.

Xét về độ chính xác tuyệt đối, LSTM tiếp tục thể hiện ưu thế đáng kể khi đạt MAE thấp nhất (571.06 VND) và RMSE thấp nhất (675.81 VND) trong toàn bộ các mô hình được thử nghiệm. Hai chỉ số này phản ánh rằng giá trị dự báo của LSTM, xét về khoảng cách tuyệt đối với dữ liệu thực, nằm gần hơn so với tất cả các mô hình khác, bất kể sai số phần trăm tương đối có cao hơn một chút. Việc RMSE đạt giá trị thấp nhất cũng đặc biệt quan trọng, bởi nó chứng minh LSTM ít mắc phải các sai số lớn đột biến — điều thường xảy ra với các mô hình tuyến tính khi chuỗi tài chính xuất hiện biến động mạnh, thay đổi chế độ hoặc bị tác động bởi thông tin bất ngờ từ thị trường quốc tế.

Tuy nhiên, LSTM không phải không có hạn chế. Đường dự báo có xu hướng bị làm mượt quá mức, dẫn đến phản ứng chậm với các điểm đảo chiều của chuỗi và các pha dao động ngắn hạn. Hiện tượng trễ này khiến mô hình thường dự đoán thấp tại các đỉnh và dự đoán cao tại các đáy. Vì vậy, mặc dù MAE và RMSE thấp — tức sai số tuyệt đối nhỏ — nhưng MAPE lại bị kéo lên vì các sai lệch tại những thời điểm biến động mạnh chiếm tỷ trọng tương đối lớn khi tính theo phần trăm. Đây là đặc điểm khá phổ biến của các mô hình deep learning khi chưa được điều chỉnh để tối ưu hóa biến động ngắn hạn hoặc chưa được bổ sung các cơ chế xử lý hiện tượng “volatility clustering”, vốn là đặc trưng quan trọng của chuỗi tài chính.

Nhìn chung, kết quả cho thấy LSTM có khả năng dự báo mang tính toàn diện và thực tế hơn, đặc biệt trong việc nắm bắt xu hướng và cấu trúc phi tuyến của thị trường ngoại hối. Tuy vậy, mô hình vẫn cần cải thiện để tăng khả năng phản ứng với biến động nhanh và hạn chế độ trễ trong dự báo — điều có thể đạt được thông qua tối ưu tham số, hoặc kết hợp với các mô hình dự báo biến động chuyên biệt hơn.

4.2.3. Phân tích hai mô hình RF & XGBoost



Hình 4.3: Biểu đồ dự báo RF/XGBoost

(Nguồn: Kết quả từ phần mềm Python)

Mô hình Random Forest và XGBoost được đánh giá là thất bại gần như hoàn toàn trong việc dự báo chuỗi tỷ giá USD/VND ở giai đoạn kiểm định. Điều này thể hiện rõ qua các chỉ số định lượng: MAPE của Random Forest và XGBoost lần lượt đạt 7.9849% và 8.8501%, cao gấp khoảng ba đến bốn lần so với hai mô hình hiệu quả hơn là ARIMA và LSTM. Trên biểu đồ trực quan (Hình 4.3), đường dự báo của cả hai mô hình này gần như trở thành một đường gần hằng số không phản ánh được xu hướng tăng mạnh của tỷ giá trong giai đoạn cuối chuỗi. Nói cách khác, hiệu quả dự báo của chúng gần như bằng mức trung bình của dữ liệu, không có khả năng mô tả động lực biến đổi thực tế.

Nguyên nhân của sự thất bại này xuất phát từ bản chất của dữ liệu chuỗi thời gian cũng như cách xử lý đầu vào để phù hợp với cấu trúc mô hình cây quyết định. Trước khi đưa vào Random Forest và XGBoost, dữ liệu chuỗi thời gian nhiều biến phải được chuyển đổi bằng kỹ thuật “trải phẳng”, biến dữ liệu 3 chiều ($\text{samples} \times \text{time steps} \times \text{features}$) thành vector đặc trưng một chiều với 100 biến ($20 \text{ ngày} \times 5 \text{ biến vĩ mô}$). Mặc dù cách làm này cho phép mô hình tiếp nhận dữ liệu dạng bảng, nhưng lại vô tình phá vỡ cấu trúc tuần tự tự nhiên của chuỗi thời gian.

Cụ thể, flattening xóa bỏ hoàn toàn tính phụ thuộc theo thời gian yếu tố then chốt trong dự báo tài chính. Khi thứ tự thời gian không còn được mô hình nhận diện, các thuật toán dựa trên cây chỉ xem mỗi vector đặc trưng như một quan sát độc lập, không có bất kỳ thông tin nào về quá trình tiến hóa của chuỗi. Điều này khiến Random Forest và XGBoost không thể học được các mô hình xu hướng, độ trễ, hay các chu kỳ dao động vốn hết sức quan trọng trong thị trường ngoại hối.

Bên cạnh đó, một hạn chế có tính chất cấu trúc của các mô hình cây quyết định đặc biệt trong bối cảnh dữ liệu tài chính là khả năng ngoại suy rất kém. Các thuật toán này chủ yếu dựa vào việc chia nhỏ không gian đặc trưng dựa trên dữ liệu quan sát được; do vậy, khi chuỗi tỷ giá tăng mạnh trong giai đoạn kiểm định, vượt qua biên độ xuất hiện trong tập huấn luyện, Random Forest và XGBoost không thể dự đoán được các giá trị mới nằm ngoài vùng đã chia. Kết quả là mô hình chỉ tạo ra các giá trị quanh mức trung bình đã thấy trước đó, dẫn đến dự báo bị “kẹt” và không thể theo kịp xu hướng tăng của thị trường.

Tổng hợp lại, Random Forest và XGBoost thất bại không phải vì chúng là những mô hình yếu, mà vì chúng không phù hợp với bản chất của dữ liệu tài chính theo chuỗi thời gian, vốn yêu cầu khả năng nắm bắt quan hệ động, phi tuyến và có thứ tự rõ ràng giữa các thời điểm. Kỹ thuật flattening và cấu trúc phân tách theo nút của các mô hình cây quyết định khiến chúng gần như mất toàn bộ thông tin thời gian dẫn đến hiệu suất thấp trên cả chỉ số định lượng lẫn biểu đồ trực quan.

4.3. PHÁT HIỆN MÂU THUÃN VÀ GIẢI THÍCH CẤU TRÚC MÔ HÌNH

Kết quả nghiên cứu cho thấy một mâu thuẫn quan trọng giữa các tiêu chí đánh giá mô hình. ARIMA đạt MAPE thấp nhất (2.4186%), nhờ đó được xem là mô hình chính xác nhất khi xét theo sai số tương đối. Tuy nhiên, khi xét theo sai số tuyệt đối, mô hình LSTM lại vượt trội hoàn toàn với MAE thấp nhất (571.06 VND) và RMSE thấp nhất (675.81 VND). Hơn nữa, quan sát trên biểu đồ trực quan cho thấy LSTM là mô hình duy nhất tái hiện được xu hướng tăng mạnh của tỷ giá USD/VND trong giai đoạn cuối chuỗi điều mà ARIMA hoàn toàn không thể nắm bắt, do đường dự báo gần như nằm ngang.

Mô hình này xuất phát trực tiếp từ bản chất cấu trúc của hai mô hình. ARIMA là mô hình tuyến tính đơn biến, chỉ dựa trên thông tin của chính chuỗi tỷ giá quá khứ để dự báo giá trị tương lai. Do đó, khi chuỗi tỷ giá có nhiều nhiễu, biến động đột ngột và không ổn định như đặc trưng của thị trường ngoại hối ARIMA có xu hướng “quy về trung bình”, tạo ra dự báo phẳng và ổn định. Chính tính phẳng này giúp mô hình đạt MAPE thấp, vì sai số tương đối được tính dựa trên tỷ lệ chênh lệch so với giá trị thực, và giá trị dự báo nằm gần trung tâm của chuỗi sẽ giúp giảm độ lệch theo tỷ lệ phần trăm. Tuy nhiên, điều này cũng đồng nghĩa ARIMA không phản ánh được động học thực của thị trường và hầu như không theo kịp các biến động mang tính thời điểm hoặc xu hướng dài hạn.

Ngược lại, LSTM hoạt động theo cấu trúc đa biến với 5 biến đầu vào: tỷ giá quá khứ, DXY, giá dầu Brent, VNINDEX và US10Y. Nhờ kiến trúc có khả năng học phi tuyến tính, ghi nhớ trạng thái qua thời gian và mô hình hóa các mối quan hệ phức tạp, LSTM không chỉ dựa vào xu hướng của chính chuỗi tỷ giá mà còn khai thác các tín hiệu kinh tế vĩ mô có tác động trực tiếp đến thị trường ngoại hối. Điều này giúp LSTM nhận diện được giai đoạn tỷ giá bắt đầu chuyển sang xu hướng tăng mạnh và đưa ra dự báo bám sát thực tế hơn, đặc biệt ở những đoạn mà ARIMA đánh mất toàn bộ cấu trúc dao động.

Tóm lại, mâu thuẫn giữa ARIMA và LSTM phản ánh sự khác biệt có tính hệ thống giữa mô hình tuyến tính đơn biến và mô hình học sâu đa biến. ARIMA tối ưu hóa sai số tương đối nhờ dự báo ổn định nhưng lại thiếu khả năng nhận diện các biến động động lực học của thị trường. Ngược lại, LSTM đạt sai số tuyệt đối thấp hơn và tái hiện tốt xu hướng thực tế nhờ khả năng biểu diễn phi tuyến và tích hợp nhiều nguồn thông tin. Sự khác biệt này cho thấy việc đánh giá mô hình dự báo cần xem xét đồng thời cả sai số tuyệt đối, sai số tương đối và biểu đồ trực quan để đưa ra kết luận toàn diện hơn.

4.4. KẾT LUẬN VÀ KHUYẾN NGHỊ LỰA CHỌN MÔ HÌNH

Từ các phân tích ở phần trước, có thể thấy rằng việc lựa chọn mô hình dự báo tỷ giá USD/VND không thể dựa trên một tiêu chí duy nhất. Không tồn tại mô hình

“tốt nhất” cho mọi trường hợp; thay vào đó, sự phù hợp của mô hình phụ thuộc trực tiếp vào mục tiêu ứng dụng, đặc điểm dữ liệu, và khung thời gian dự báo.

Nếu mục tiêu chính là dự báo mức giá trung bình ngắn hạn với độ ổn định cao, đồng thời ưu tiên sai số tương đối thấp, mô hình ARIMA là lựa chọn phù hợp nhất. Dự báo của ARIMA ổn định, ít dao động và bám sát mức trung bình của chuỗi dữ liệu. Điều này đặc biệt hữu ích trong các bối cảnh như hoạch định kế hoạch thanh khoản ngoại tệ, lập ngân sách ngắn hạn, hoặc các ứng dụng cần một giá trị tham chiếu đáng tin cậy nhưng không quá nhạy với biến động thị trường. Chính bản chất tuyến tính và xu hướng dự báo “phẳng” của ARIMA khiến mô hình giảm thiểu sai số tỷ lệ (MAPE), dù không nắm bắt tốt biến động thực tế.

Ngược lại, nếu mục tiêu là phân tích xu hướng trung-dài hạn, giám sát thay đổi cấu trúc thị trường hoặc đánh giá tác động của các yếu tố vĩ mô, mô hình LSTM là lựa chọn vượt trội. Nhờ khả năng học phi tuyến tính, lưu trữ thông tin theo thời gian và xử lý dữ liệu đa biến, LSTM tái hiện tốt hơn các chuyển động thực, đặc biệt là các xu hướng tăng mạnh ở cuối chuỗi. LSTM cũng đạt sai số tuyệt đối thấp nhất, cho thấy mức độ tiệm cận dữ liệu thực cao hơn khi yêu cầu dự báo chính xác theo giá trị tuyệt đối. Điều này giúp mô hình phù hợp với các ứng dụng như phân tích rủi ro vĩ mô, dự báo thị trường trong điều kiện có nhiều cú sốc quốc tế, hoặc các mô hình ra quyết định chiến lược đòi hỏi khả năng nhận diện động học thị trường.

Tuy nhiên, LSTM không hoàn toàn hoàn hảo. Hiện tượng làm mượt quá mức và phản ứng chậm ở các điểm đảo chiều có thể gây sai số tương đối cao hơn ARIMA. Dù vậy, những hạn chế này hoàn toàn có thể cải thiện thông qua các hướng mở rộng như tăng kích thước cửa sổ thời gian, tối ưu hóa tham số, hoặc ứng dụng các kiến trúc nâng cao hơn như Bi-LSTM, GRU hoặc Attention Mechanism để cải thiện khả năng học biến động ngắn hạn.

KẾT LUẬN CHƯƠNG 4

Chương 4 đã hoàn thành việc trình bày và thảo luận chi tiết các kết quả thực nghiệm từ bốn mô hình dự báo: ARIMA, LSTM, Random Forest và XGBoost. Kết quả phân tích định lượng và trực quan đã chỉ ra một bức tranh rõ nét về sự phân hóa hiệu suất giữa các phương pháp. Trong đó, mô hình kinh tế lượng truyền thống ARIMA đã chứng minh được tính hiệu quả bất ngờ khi đạt chỉ số MAPE thấp nhất là 2.4186%. Kết quả này khẳng định ARIMA là lựa chọn tối ưu nếu mục tiêu đơn thuần là dự báo mức giá trung bình của tỷ giá trong ngắn hạn với độ sai lệch tương đối thấp nhất. Tuy nhiên, hạn chế lớn nhất của mô hình này là đường dự báo có dạng phẳng, không phản ánh được các biến động lên xuống của thị trường.

Ngược lại, mô hình Học sâu LSTM lại thể hiện ưu thế vượt trội về mặt cấu trúc và khả năng nắm bắt xu hướng. Mặc dù chỉ số MAPE cao hơn đôi chút so với ARIMA, LSTM lại đạt được mức sai số tuyệt đối thấp nhất với MAE là 571.06 VND và RMSE là 675.81 VND. Quan trọng hơn, biểu đồ dự báo cho thấy LSTM là mô hình duy nhất thành công trong việc nhận diện xu hướng tăng giá mạnh của tỷ giá USD/VND trong giai đoạn kiểm định, nhờ vào khả năng tích hợp hiệu quả các biến vĩ mô đầu vào. Đối với nhóm mô hình Học máy truyền thống như Random Forest và XGBoost, kết quả cho thấy sự thất bại rõ rệt với sai số cao gấp nhiều lần các mô hình còn lại, nguyên nhân chủ yếu đến từ việc kỹ thuật trải phẳng dữ liệu đã phá vỡ tính phụ thuộc thời gian vốn có của chuỗi tài chính. Tóm lại, kết quả Chương 4 đặt nền tảng cho việc lựa chọn mô hình tùy thuộc vào mục đích sử dụng: sự ổn định thống kê của ARIMA hay khả năng định hướng xu hướng của LSTM.

CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ

5.1. KẾT LUẬN NGHIÊN CỨU

Nghiên cứu được triển khai với mục tiêu đánh giá và so sánh hiệu quả dự báo tỷ giá USD/VND thông qua ba nhóm mô hình: (i) mô hình kinh tế lượng truyền thống (ARIMA), (ii) các mô hình học máy dựa trên cây quyết định (Random Forest và XGBoost), và (iii) mô hình học sâu (LSTM). Bộ dữ liệu sử dụng bao gồm tỷ giá USD/VND cùng bốn biến kinh tế vĩ mô ngoại sinh — chỉ số DXY, giá dầu Brent, VNINDEX và lợi suất trái phiếu Mỹ kỳ hạn 10 năm — trong giai đoạn 2015–2025. Tất cả các mô hình được huấn luyện và kiểm định dựa trên ba thước đo phổ biến MAE, RMSE và MAPE, nhằm đảm bảo so sánh khách quan và toàn diện.

Kết quả thực nghiệm cho thấy không tồn tại mô hình nào vượt trội trên tất cả các tiêu chí, mà mỗi mô hình lại phù hợp với một mục tiêu dự báo khác nhau. ARIMA ghi nhận MAPE thấp nhất, cho thấy mô hình rất hiệu quả trong việc dự báo mức giá trung bình với độ lệch tương đối nhỏ. Tuy nhiên, hạn chế cố hữu của ARIMA là xu hướng “dự báo phẳng”, khiến mô hình hoàn toàn không phản ánh được các biến động và xu hướng tăng mạnh của tỷ giá trong giai đoạn kiểm định. Điều này cho thấy mô hình tuyến tính đơn biến khó bắt kịp đặc thù phi tuyến và biến động nhanh của thị trường ngoại hối.

Ở chiều ngược lại, mô hình LSTM thể hiện hiệu suất vượt trội nhất xét theo sai số tuyệt đối: MAE và RMSE thấp nhất trong toàn bộ các mô hình. Đáng chú ý hơn, LSTM là mô hình hiếm hoi có khả năng phản ánh đúng hướng chuyển động của tỷ giá trong giai đoạn tăng mạnh cuối chuỗi. Điều này chứng tỏ LSTM không chỉ dựa vào quán tính chuỗi thời gian mà còn học được các mối quan hệ phi tuyến phức tạp giữa tỷ giá và các biến vĩ mô như DXY, lãi suất hay giá dầu. Nhờ khả năng nắm bắt phụ thuộc thời gian và quá trình động, LSTM tỏ ra phù hợp hơn với bản chất biến động của tỷ giá USD/VND — vốn chịu ảnh hưởng từ cả yếu tố quốc tế và yếu tố nội tại.

Trong khi đó, hai mô hình học máy truyền thống Random Forest và XGBoost cho kết quả kém thuyết phục trên cả ba tiêu chí đánh giá. Nguyên nhân chính đến từ

quá trình xử lý dữ liệu: việc "trải phẳng" để đưa dữ liệu chuỗi thời gian vào mô hình đã làm mất thông tin về thứ tự và cấu trúc thời gian yếu tố cực kỳ quan trọng đối với dự báo vĩ mô và tài chính. Đồng thời, bản chất của mô hình cây quyết định khiến chúng gặp khó khăn khi cần ngoại suy trong những giai đoạn thị trường xuất hiện xu hướng tăng rõ rệt, dẫn đến đường dự báo gần như phẳng.

Nhìn chung, kết quả nghiên cứu chỉ ra rằng chuỗi tỷ giá USD/VND mang đặc trưng phi tuyến mạnh, biến động không đều và nhạy cảm với nhiều yếu tố vĩ mô, do đó các mô hình học sâu như LSTM phù hợp hơn trong dự báo xu hướng và giá trị tuyệt đối. Tuy vậy, các mô hình tuyến tính truyền thống như ARIMA vẫn đóng vai trò quan trọng trong những ứng dụng cần sự ổn định, giải thích rõ ràng và sai số tương đối thấp. Điều này nhấn mạnh rằng lựa chọn mô hình tối ưu cần căn cứ vào mục tiêu ứng dụng cụ thể, hơn là tìm kiếm một mô hình duy nhất cho mọi hoàn cảnh.

5.1.1. Tóm tắt Kết quả Chính

Kết quả phân tích thực nghiệm cho thấy sự khác biệt rõ rệt giữa các nhóm mô hình khi áp dụng vào dự báo tỷ giá USD/VND. Bốn mô hình gồm ARIMA, Random Forest, XGBoost và LSTM được đánh giá dựa trên ba chỉ tiêu MAE, RMSE và MAPE nhằm phản ánh toàn diện sai số tuyệt đối, sai số bình phương và sai số tương đối của dự báo. Sự khác biệt về bản chất mô hình tuyến tính, phi tuyến hay dựa trên học sâu dẫn tới mức độ phù hợp không đồng nhất với dữ liệu tỷ giá, vốn mang tính biến động theo thời gian và chịu tác động của nhiều yếu tố vĩ mô.

Thứ nhất, mô hình ARIMA đạt hiệu suất tốt nhất theo tiêu chí MAPE, chỉ ở mức 2.4186%. Điều này cho thấy ARIMA mô phỏng khá chính xác mức giá trung bình của chuỗi tỷ giá trong giai đoạn biến động ổn định, đặc biệt phù hợp với các bài toán dự báo ngắn hạn. Mặc dù đường dự báo tương đối phẳng và không phản ứng tốt trước các biến động đột ngột, mô hình vẫn đảm bảo sai số tương đối rất thấp, nhờ đó duy trì được tính ổn định và độ tin cậy khi chỉ cần một giá trị tham chiếu mang tính đại diện.

Thứ hai, mô hình LSTM thể hiện ưu thế vượt trội về sai số tuyệt đối, thể hiện qua $MAE = 571.06 \text{ VND}$ và $RMSE = 675.81 \text{ VND}$ – thấp nhất trong toàn bộ mô hình

được so sánh. Điều này phản ánh khả năng học sâu của LSTM trong việc nắm bắt các quan hệ phi tuyến giữa tỷ giá và các biến vĩ mô như DXY, giá dầu Brent, VNINDEX và lợi suất US10Y. LSTM không chỉ dự báo sát với giá trị thực hơn mà còn là mô hình duy nhất tái hiện rõ xu hướng tăng của tỷ giá ở giai đoạn cuối chuỗi dữ liệu. Mặc dù MAPE của LSTM cao hơn ARIMA do hiện tượng trễ và tính chất làm mượt nội tại của mô hình, LSTM vẫn thể hiện ưu thế đáng kể trong việc dự báo xu hướng và cấu trúc động của thị trường.

Thứ ba, hai mô hình học máy truyền thống Random Forest và XGBoost cho thấy hiệu suất kém hơn đáng kể so với ARIMA và LSTM. Cả hai đều có MAPE cao gấp khoảng 3–4 lần so với hai mô hình còn lại, phản ánh mức độ không phù hợp với dự báo chuỗi thời gian tỷ giá. Nguyên nhân chủ yếu đến từ việc dữ liệu phải được sắp xếp lại theo dạng bảng để phù hợp với đầu vào của mô hình, khiến cấu trúc thời gian yếu tố then chốt trong dự báo tài chính bị loại bỏ. Điều này dẫn đến việc các mô hình không thể học được động lực biến động của tỷ giá và cho kết quả dự báo thiếu chính xác.

5.1.2. Đóng góp của Nghiên cứu

Nghiên cứu này đóng góp vào lĩnh vực tài chính và khoa học dữ liệu thông qua việc xây dựng một khuôn khổ đánh giá toàn diện, trong đó bốn mô hình dự báo tỷ giá USD/VND ARIMA, Random Forest, XGBoost và LSTM được triển khai, hiệu chỉnh và so sánh trên cùng một bộ dữ liệu và quy trình xử lý thống nhất. Cách tiếp cận này cho phép làm rõ sự khác biệt cốt lõi giữa mô hình thống kê truyền thống, mô hình học máy và mô hình học sâu khi áp dụng vào một chuỗi thời gian có tính phi tuyến cao và chịu ảnh hưởng mạnh từ các yếu tố kinh tế vĩ mô.

Kết quả phân tích cho thấy LSTM không chỉ vượt trội về độ chính xác tuyệt đối mà còn nắm bắt quan hệ phụ thuộc theo thời gian tốt hơn đáng kể so với các mô hình còn lại. Mô hình này giúp khắc phục hạn chế của ARIMA vốn có xu hướng dự báo theo mức trung bình và phản ứng chậm với sự thay đổi của các biến vĩ mô, đồng thời cũng vượt qua điểm yếu của các mô hình học máy truyền thống khi chúng không giữ được cấu trúc động của chuỗi dữ liệu sau quá trình trải phẳng. Việc LSTM tích

hợp được thông tin vĩ mô trong dạng chuỗi liên tục cho phép mô hình phản ánh sự thay đổi trong kỳ vọng thị trường, mức độ rủi ro hệ thống và các biến động toàn cầu một cách linh hoạt hơn.

Một đóng góp quan trọng khác của nghiên cứu là việc xác nhận tính ổn định và khả năng tổng quát hóa của mô hình LSTM. Đường Val Loss duy trì sự ổn định và không tách biệt đáng kể so với Training Loss, chứng tỏ mô hình không bị quá khớp mặc dù cấu trúc mạng có độ phức tạp cao. Điều này khẳng định rằng LSTM không chỉ hoạt động tốt trong giai đoạn huấn luyện mà còn có khả năng thích ứng hiệu quả với dữ liệu ngoài mẫu — một tiêu chí quan trọng trong các ứng dụng dự báo tài chính.

Tổng thể, nghiên cứu đã xây dựng được một nền tảng thực nghiệm đáng tin cậy để đánh giá các phương pháp dự báo tỷ giá trong bối cảnh Việt Nam, đồng thời củng cố vai trò ngày càng lớn của học sâu trong mô hình hóa các hiện tượng kinh tế mang tính động và có sự tương tác mạnh. Những phát hiện này mở ra cơ hội mở rộng sang các lĩnh vực tài sản khác, cũng như kết hợp thêm các biến kinh tế – tài chính có tính lan truyền hoặc tác động chéo nhằm nâng cao chất lượng dự báo trong các nghiên cứu tiếp theo.

5.2. KHUYẾN NGHỊ ỨNG DỤNG

Dựa trên kết quả thực nghiệm và sự khác biệt rõ rệt về hiệu suất giữa các nhóm mô hình, nghiên cứu đưa ra một số khuyến nghị mang tính ứng dụng nhằm hỗ trợ công tác điều hành tỷ giá, quản trị rủi ro và hoạch định chiến lược tài chính. Các gợi ý này được xây dựng trên nguyên tắc tận dụng tối đa thế mạnh tự nhiên của từng mô hình, thay vì cố gắng tìm kiếm một mô hình hoàn hảo.

5.2.1. Đối với Ngân hàng Nhà nước

Một tiếp cận phù hợp cho cơ quan quản lý là triển khai chiến lược “mô hình kép”, trong đó mô hình truyền thống và mô hình học sâu được sử dụng song song nhằm phục vụ những mục tiêu điều hành khác nhau. Cụ thể, ARIMA với đặc trưng đơn giản, dễ hiệu chỉnh và có sai số tương đối thấp có thể đảm nhiệm vai trò dự báo ngắn hạn nhằm hỗ trợ các quyết định can thiệp nội ngày, quản lý kỳ vọng thị trường hoặc duy trì ổn định mặt bằng tỷ giá. Khi thị trường trong trạng thái biến động nhẹ,

ARIMA cung cấp các dự báo ổn định và nhất quán, phù hợp với yêu cầu kỹ trị trong ngắn hạn của NHNN.

Song song đó, LSTM thể hiện lợi thế vượt trội trong việc phát hiện xu hướng dài hạn và đánh giá áp lực thị trường trong tương lai nhờ khả năng học phi tuyến và tích hợp đồng thời nhiều biến vĩ mô như US10Y, DXY, OIL hay VNINDEX. Đây là những yếu tố có tác động trực tiếp đến kỳ vọng tỷ giá và linh hoạt thay đổi theo điều kiện quốc tế. Do đó, LSTM có thể được sử dụng như một công cụ hỗ trợ chiến lược, giúp NHNN có cái nhìn sớm về các nguy cơ mất cân đối hoặc giai đoạn chịu áp lực phá giá mạnh, từ đó chuẩn bị các kịch bản điều hành phù hợp.

Trong bối cảnh thị trường tài chính toàn cầu ngày càng chịu nhiều cú sốc bất định, việc đầu tư vào các mô hình học sâu hiện đại như BiLSTM, GRU hoặc các kiến trúc tích hợp Attention là hướng đi cần thiết. Những mô hình này có ưu thế nổi bật trong việc xử lý dữ liệu phi tuyến, nắm bắt quan hệ động phức tạp và phản ứng tốt hơn với các biến động mang tính đột biến — những hạn chế thường gặp của mô hình kinh tế lượng truyền thống. Việc phát triển và chuẩn hóa các mô hình này trong môi trường vận hành của NHNN không chỉ nâng cao chất lượng dự báo, mà còn củng cố quá trình hoạch định chính sách theo hướng dựa trên dữ liệu và bằng chứng thực nghiệm.

5.2.2. Đối với Doanh nghiệp Xuất Nhập khẩu và Đầu tư

Đối với các doanh nghiệp hoạt động trong lĩnh vực xuất nhập khẩu hoặc có dòng tiền phụ thuộc mạnh vào biến động ngoại tệ, khả năng dự báo xu hướng tỷ giá bằng mô hình LSTM mang lại một lợi thế quan trọng trong việc xây dựng chiến lược quản trị rủi ro tỷ giá. Thay vì chỉ dựa trên các dự báo ngắn hạn vốn dễ chịu tác động bởi biến động nhất thời của thị trường, doanh nghiệp có thể sử dụng dự báo xu hướng dài hạn để đưa ra quyết định phòng ngừa (hedging) mang tính chủ động và chiến lược hơn. Ví dụ, khi mô hình LSTM ghi nhận tín hiệu tăng ổn định của tỷ giá trong thời gian tới như minh họa trong Hình 4.2 các doanh nghiệp nhập khẩu có thể cân nhắc mua ngoại tệ sớm để cố định chi phí, hạn chế rủi ro tăng giá đột ngột. Ở chiều ngược

lại, doanh nghiệp xuất khẩu có thể trì hoãn việc bán ngoại tệ nhằm tận dụng mức tỷ giá có lợi hơn khi xu hướng tăng được củng cố.

Bên cạnh việc theo dõi xu hướng, doanh nghiệp cũng cần đánh giá độ tin cậy của mô hình thông qua các chỉ số như MAPE, MAE và RMSE. Đây là những thước đo quan trọng giúp doanh nghiệp không chỉ hiểu mức độ chính xác của dự báo, mà còn đánh giá được khả năng xuất hiện những sai số lớn gây ảnh hưởng nghiêm trọng đến quyết định tài chính. Trong đó, MAPE thể hiện mức độ sai lệch tương đối theo phần trăm, phù hợp để so sánh sai số giữa các giai đoạn khác nhau; MAE và RMSE phản ánh mức sai lệch tuyệt đối giữa dự báo và thực tế. Một mô hình trong đó RMSE duy trì ở mức thấp và không chênh lệch nhiều so với MAE thường cho thấy phân phối sai số ổn định, ít xuất hiện các giá trị sai lệch bất thường điều này đặc biệt quan trọng đối với các doanh nghiệp ký kết hợp đồng có giá trị lớn, nơi một sai số dự báo đáng kể có thể gây ra thiệt hại tài chính đáng kể.

Ngoài ra, việc kết hợp kết quả dự báo với phân tích dòng tiền thực tế, lịch thanh toán quốc tế, cũng như nhịp độ nhập hàng hoặc xuất khẩu giúp doanh nghiệp xây dựng chiến lược phòng ngừa rủi ro phù hợp hơn với đặc thù hoạt động của mình. Doanh nghiệp có thể phân tầng thời gian hedging, khóa tỷ giá theo từng giai đoạn hoặc sử dụng các công cụ tài chính như forward, option hoặc swap tùy theo mức độ biến động mà mô hình dự báo gợi ý. Đặc biệt, khi doanh nghiệp có khả năng theo dõi xu hướng tỷ giá liên tục thông qua mô hình LSTM, việc điều chỉnh chiến lược phòng ngừa cũng trở nên linh hoạt hơn, góp phần tối ưu hóa chi phí ngoại tệ và tăng cường hiệu quả hoạt động tài chính.

5.3. HẠN CHẾ CỦA NGHIÊN CỨU

Mặc dù đạt được nhiều kết quả quan trọng, nghiên cứu vẫn tồn tại một số hạn chế liên quan đến dữ liệu, mô hình và phương pháp tiếp cận. Thứ nhất, bộ dữ liệu được sử dụng chủ yếu bao gồm chuỗi tỷ giá ngày cùng bốn biến vĩ mô cơ bản. Việc chưa đưa vào các thông tin định tính như định hướng chính sách, phát biểu của các cơ quan điều hành hay tâm lý thị trường có thể khiến mô hình phản ứng chậm với

những cú sốc bất ngờ. Đây là hạn chế phổ biến trong các mô hình định lượng khi phải xử lý các biến động mang tính phi cấu trúc.

Thứ hai, mặc dù mô hình LSTM thể hiện hiệu năng vượt trội, kết quả vẫn ghi nhận hiện tượng dự báo bị trễ so với các đỉnh và đáy thực tế. Điều này cho thấy kiến trúc hiện tại vẫn chưa tối ưu hoàn toàn cho một chuỗi có tốc độ biến động cao như tỷ giá USD/VND. Các yếu tố như độ dài cửa sổ trượt, số tầng LSTM, kích thước nút ẩn hoặc mức độ Regularization có thể chưa đạt ngưỡng tối ưu, dẫn đến khả năng phản ứng của mô hình trong các thời điểm chuyển pha mạnh còn hạn chế. Đây là điểm cần tiếp tục điều chỉnh và thử nghiệm sâu hơn trong các nghiên cứu tiếp theo.

5.4. KHUYẾN NGHỊ NGHIÊN CỨU TIẾP THEO

Trong tương lai, hướng nghiên cứu có thể được mở rộng theo hai nhóm chính: hoàn thiện cấu trúc mô hình và mở rộng nguồn dữ liệu đầu vào. Về mặt mô hình, các kiến trúc học sâu tiên tiến hơn như Bi-directional LSTM (BiLSTM), GRU, hoặc đặc biệt là các mô hình tích hợp cơ chế chú ý (Attention Mechanism) có tiềm năng cải thiện đáng kể khả năng học phụ thuộc thời gian. Những kiến trúc này giúp mô hình nắm bắt tốt hơn quan hệ hai chiều giữa các quan sát, đồng thời tăng độ nhạy với các điểm đảo chiều và các chuyển động mang tính quyết định trong chuỗi tỷ giá. Song song với đó, quá trình tối ưu hóa siêu tham số cũng cần được triển khai bài bản hơn thông qua các phương pháp hiện đại như Grid Search, Random Search hoặc Bayesian Optimization, nhằm xác định cấu hình tối ưu cho độ dài cửa sổ trượt, số tầng mạng, kích thước nút ẩn, tỷ lệ Dropout và tốc độ học.

Một hướng phát triển quan trọng khác nằm ở việc mở rộng và làm phong phú nguồn dữ liệu. Ngoài các biến vĩ mô truyền thống, nghiên cứu tương lai có thể tích hợp thêm các nguồn dữ liệu phi cấu trúc như chỉ số cảm xúc thị trường, mức độ lo ngại rủi ro toàn cầu, hoặc sắc thái thông tin từ tin tức tài chính và truyền thông chính sách. Việc chuyển các dữ liệu này thành đặc trưng định lượng thông qua phân tích văn bản hoặc mô hình NLP sẽ giúp hệ thống dự báo nắm bắt tốt hơn kỳ vọng của nhà đầu tư — yếu tố thường đóng vai trò quyết định trong các giai đoạn thị trường biến động mạnh.

Tựu trung, các hướng mở rộng nêu trên không chỉ nhằm nâng cao độ chính xác của mô hình dự báo mà còn hướng tới việc xây dựng một khung phân tích phản ánh đầy đủ động lực thực sự của thị trường tỷ giá. Đây sẽ là nền tảng quan trọng cho những nghiên cứu sâu hơn trong bối cảnh thị trường tài chính ngày càng chịu tác động đa chiều và biến động phức tạp.

KẾT LUẬN CHƯƠNG 5

Nghiên cứu này được thực hiện với mục tiêu cốt lõi là xây dựng và so sánh hiệu quả của các mô hình dự báo tỷ giá hối đoái USD/VND, bao gồm các phương pháp từ kinh tế lượng truyền thống đến các kỹ thuật học máy và học sâu hiện đại. Thông qua việc sử dụng bộ dữ liệu chuỗi thời gian đa biến tích hợp các yếu tố vĩ mô quan trọng như chỉ số DXY và lợi suất trái phiếu Mỹ, nghiên cứu đã đi đến những kết luận quan trọng về tính thích nghi của từng mô hình trong bối cảnh thị trường Việt Nam.

Kết quả nghiên cứu khẳng định rằng không có một mô hình nào là hoàn hảo tuyệt đối cho mọi mục tiêu, mà tồn tại sự đánh đổi giữa độ chính xác thống kê và khả năng nắm bắt xu hướng. Mô hình ARIMA vẫn giữ vai trò là một công cụ tham chiếu cơ sở vững chắc, cung cấp các dự báo ngắn hạn với độ sai lệch phần trăm thấp nhất, phù hợp cho các mục đích kế toán hoặc định giá tĩnh. Trong khi đó, mô hình LSTM đã chứng minh được tiềm năng to lớn của phương pháp Học sâu trong việc giải quyết các bài toán phi tuyến tính phức tạp. Khả năng tích hợp dữ liệu đa chiều và nhận diện xu hướng dài hạn của LSTM vượt trội hơn hẳn so với các phương pháp khác, biến nó trở thành công cụ đắc lực cho các chiến lược quản trị rủi ro và đầu tư. Đồng thời, nghiên cứu cũng bác bỏ tính hiệu quả của việc áp dụng các mô hình cây quyết định truyền thống (RF, XGBoost) lên dữ liệu chuỗi thời gian nếu không có các kỹ thuật xử lý đặc thù để bảo toàn tính tuần tự.

TÀI LIỆU THAM KHẢO

Tài liệu trong nước

- 1 Pham, T. H. H. (2013). Foreign direct investment, exports and real exchange rate: Evidence from Vietnam. *Journal of Economic Development*, 15(2), 24–41.
- 2 State Bank of Vietnam (SBV). (2023). Thông tin điều hành tỷ giá và chính sách tiền tệ.
- 3 Trần, V. T. (2025). Ứng dụng mô hình ARIMA trong dự báo tỷ giá USD/VND. *Tạp chí Kinh tế & Dự báo*.
- 4 Nguyễn, T. M. P., Lê, V. H., Hoàng, Q. V., & Phạm, H. Y. (2024). Dự báo tỷ giá USD/VND bằng mô hình ARIMA–TARCH. *Trường Đại học Công nghiệp Hà Nội*.
- 5 Nguyễn, T. L., Trần, N. H., & Lê, T. M. N. (2018). Mô hình ARIMA trong dự báo tỷ giá trung tâm USD/VND. *Tạp chí Khoa học & Công nghệ – Đại học Công nghiệp TP.HCM*.
- 6 Nguyễn, T. T. (2020). Các nhân tố tác động đến tỷ giá VND/USD: Tiếp cận từ mô hình hồi quy. *Tạp chí Công Thương*.
- 7 Phạm, Q. C., Lê, T. T., Hoàng, M. T., & Nguyễn, T. T. H. (2022). Ứng dụng học máy trong dự báo tỷ giá VND/USD. *Tạp chí Nghiên cứu Tài chính – Marketing*.

Tài liệu ngoài nước

- 8 Alvarez-Díaz, M., & Mateu, J. (2006). Forecasting with nonlinear models: Evidence from economic time series. *Journal of Forecasting*, 25(4), 237–255.
- 9 Basher, S. A., Haug, A. A., & Sadorsky, P. (2012). Oil prices, exchange rates and emerging stock markets. *Energy Economics*.
<https://doi.org/10.1016/j.eneco.2012.01.009>
- 10 Baumeister, C., & Kilian, L. (2015). Understanding the decline in the price of oil. *Journal of Economic Perspectives*. <https://doi.org/10.1257/jep.29.1.137>
- 11 Box, G. E. P., & Jenkins, G. M. (1970). *Time series analysis: Forecasting and control*. Holden-Day.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

- 12 Cerchiello, P., & Nicola, G. (2018). Machine learning models for exchange rate forecasting. *Physica A*. <https://doi.org/10.1016/j.physa.2018.11.040>
- 13 Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM.
- 14 García, F., Guijarro, F., Oliver, J., & Tamošiūnienė, R. (2023). Foreign exchange forecasting models: ARIMA and LSTM comparison. *Engineering Proceedings*, 39(1), 81. <https://doi.org/10.3390/engproc2023039081>
- 15 Goldberg, L. S., & Klein, M. W. (2005). Foreign direct investment, trade, and real exchange rate linkages. Federal Reserve Bank of New York & Brandeis University. <https://www.newyorkfed.org/medialibrary/media/research/economists/goldberg/fditradeGoldberg-Klein.pdf>
- 16 Goldberg, P. K., & Knetter, M. M. (1997). Goods prices and exchange rates: What have we learned? *Journal of Economic Literature*, 35(3), 1243–1272.
- 17 Guzman, M., Ocampo, J. A., & Stiglitz, J. E. (2017). Real exchange rate policies for economic development (NBER Working Paper No. 23868). National Bureau of Economic Research. <https://www.nber.org/papers/w23868>
- 18 Gupta, R., & Modise, M. (2013). Macroeconomic variables and exchange rate predictability. *Empirical Economics*. <https://doi.org/10.1007/s00181-012-0588-x>
- 19 Habib, M. M., & Eichengreen, B. (2016). The real exchange rate and economic growth (ECB Working Paper No. 1921). European Central Bank. <https://www.ecb.europa.eu/pub/pdf/scpwps/ecbwp1921.en.pdf>
- 20 Habib, M., & Stracca, L. (2012). Getting beyond carry trade (ECB Working Paper No. 1365).
- 21 Hassan, M. R., Nath, B., & Kirley, M. (2021). A hybrid LSTM model for forecasting financial time series. *Applied Soft Computing*, 101, 107–120.
- 22 He, L. (2021). The impact of real exchange rate volatility on foreign direct investment: Evidence from developing economies. *International Journal of*

Economics and Financial Issues, 11(1), 1–8.

<https://www.econjournals.com/index.php/ijefi/article/download/11882/pdf>

23 Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.

24 International Monetary Fund. (2023). *Global financial stability report*. IMF Publishing.

25 Jammazi, R., Ferrer, R., Jareño, F., & Shahzad, S. J. H. (2017). Oil price and exchange rate dependence. *International Review of Economics & Finance*. <https://doi.org/10.1016/j.iref.2017.07.013>

26 Kaushik, M., & Giri, A. K. (2020). Forecasting foreign exchange rate: A multivariate comparative analysis between traditional econometric, contemporary machine learning & deep learning techniques. *arXiv*. <https://arxiv.org/abs/2002.10247>

27 Kim, S., & Yang, D. (2011). The impact of capital flows on exchange rates in emerging Asia. *ADB Working Paper*.

28 Li, X., Zhang, H., & Zhou, Q. (2022). Study on exchange rate forecasting with stacked optimization based on a learning algorithm (EMD–LSTM–SVR). *Mathematics*, 12(4), 614. <https://doi.org/10.3390/math12040614>

29 Liu, S., Wang, L., & Chen, W. (2020). A deep learning approach for exchange rate forecasting based on LSTM network. *Physica A: Statistical Mechanics and Its Applications*, 551, 124–132.

30 Liu, W., Chen, J., & Park, S. (2025). Artificial intelligence and exchange rate forecasting: Assessing predictive accuracy and macroeconomic sensitivity. *Frontiers in Artificial Intelligence*, 4, Article 1654093. <https://www.frontiersin.org/articles/10.3389/fams.2025.1654093>

31 Mishkin, F. S. (2019). *The economics of money, banking, and financial markets* (12th ed.). Pearson.

32 Müller, T., & Becker, S. (2024). Forecasting implied volatilities of currency options with machine learning techniques and econometrics models. *International*

- Journal of Data Science and Analytics, 16(2), 145–162.
<https://doi.org/10.1007/s41060-024-00528-7>
- 33 Narayan, P. K., Narayan, S., & Sharma, S. (2019). Is equity market data useful for forecasting exchange rates? *International Review of Financial Analysis*.
<https://doi.org/10.1016/j.irfa.2019.101346>
- 34 Patel, R. (2020). Machine learning for FX forecasting. arXiv.
<https://arxiv.org/abs/2005.01077>
- 35 Rodrik, D. (2008). The real exchange rate and economic growth. *Brookings Papers on Economic Activity*, Fall, 365–412. https://www.brookings.edu/wp-content/uploads/2008/09/2008b_bpea_rodrik.pdf
- 36 Rossi, B. (2013). Exchange rate predictability (NBER Working Paper No. 20497).
- 37 Siami-Namini, S., & Siami Namin, A. (2018). Forecasting economics and financial time series: ARIMA vs. LSTM. arXiv. <https://arxiv.org/abs/1803.06386>
- 38 Ullah, U., Rehman, D., Khan, S., Rashid, H., & Ullah, I. (2024). Forecasting foreign exchange rate with machine learning techniques: Chinese Yuan to US Dollar using XGBoost and LSTM model. *iRASD Journal of Economics*, 6(3), 761–775.
<https://doi.org/10.52131/joe.2024.0603.0238>
- 39 Wang, Y., & Wu, J. (2012). Forecasting exchange rates using global macroeconomic variables. *International Journal of Forecasting*.
<https://doi.org/10.1016/j.ijforecast.2012.01.002>
- 40 Wongsamee, K., et al. (2024). Real exchange rates and inward FDI in East Asia and the Pacific. *Modern Economy*, 15(3), 412–432.
<https://www.scirp.org/journal/paperinformation?paperid=136069>
- 41 Zhao, Y., Wang, X., & Xu, L. (2024). Exchange rate forecasting: A deep learning framework combining adaptive signal decomposition and dynamic weight optimization. *Journal of Risk and Financial Management*, 17(3), 151.
<https://www.mdpi.com/2227-7072/13/3/151>
- 42 Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer Science & Business Media.

- 42 Box, G. E. P., & Jenkins, G. M. (1970). Time Series Analysis: Forecasting and Control. Holden-Day.
- 43 Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
- 44 Diebold, F. X. (2015). Forecasting, Structural Change, and the Global Financial Crisis. Annual Review of Economics.
- 45 Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735–1780.
- 46 Hyndman, R. J., & Koehler, A. B. (2006). Another look at the measure of forecast accuracy. International Journal of Forecasting, 22(4), 679-688.
- 47 Kingma, D. P., & Ba, J. (2014). Adam: A Method for Stochastic Optimization. arXiv preprint arXiv:1412.6980.
- 48 Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: Results, findings, conclusion and way forward. International Journal of Forecasting, 36(1), 326-340.
- 49 Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

PHỤ LỤC

PHỤ LỤC A: BẢNG DỮ LIỆU

Date	USDVND_RAT E	DXY	OIL_BREN T	VNINDEX	US10Y
01/01/2015	21370	90.27	56.42	544.45	2.17
02/01/2015	21370	91.08	53.11	549.66	2.114
05/01/2015	21370	91.38	51.1	552.05	2.034

06/01/2015	21420	91.5	51.15	553.47	1.938
07/01/2015	21420	91.89	50.96	569.73	1.969
08/01/2015	21360	92.37	50.11	574.32	2.17
09/01/2015	21340	91.94	47.43	580.6	2.114
12/01/2015	21315	91.98	46.59	577.01	2.034
13/01/2015	21315	90.27	48.69	577.74	1.938
14/01/2015	21310	91.08	47.67	574.81	1.969
15/01/2015	21320	91.38	50.17	571.51	2.018
16/01/2015	21315	91.5	48.84	572.22	1.95
19/01/2015	21330	91.89	47.99	569.12	1.909
20/01/2015	21330	92.37	49.03	574.54	1.905
21/01/2015	21350	91.94	48.52	582.38	1.855
22/01/2015	21330	91.98	48.79	580.64	1.728
23/01/2015	21320	92.31	48.16	579.3	1.831

26/01/201 5	21320	92.16	49.6	583.76	1.8
27/01/201 5	21320	92.35	48.47	583.28	1.791
28/01/201 5	21320	92.52	49.13	576.07	1.875
29/01/201 5	21230	92.52	52.99	570.37	1.872
30/01/201 5	21267	93.05	54.75	557.47	1.789
02/02/201 5	21204	92.9	57.91	561.45	1.828
03/02/201 5	21185	94.08	54.16	567.17	1.828
04/02/201 5	21358	94.76	56.57	574.13	1.719
05/02/201 5	21234	94.8	57.8	573.55	1.756
06/02/201 5	21232	94.02	58.34	574.52	1.639
09/02/201 5	21307.5	94.47	56.43	581.76	1.674
10/02/201 5	21115	94.78	54.66	584.67	1.798
11/02/201 5	21268	94.8	57.05	587.24	1.747
12/02/201 5	21237.5	94.5	56.42	596.95	1.817

13/02/201					
5	21300	93.6	53.11	592.66	1.958
16/02/201					
5	21300	93.99	51.1	596.72	1.978
17/02/201					
5	21300	93.57	51.15	592.57	2.004
18/02/201					
5	21300	95.85	50.96	590.73	2.021
19/02/201					
5	21300	94.45	50.11	596.72	1.988
20/02/201					
5	21300	94.76	47.43	600.39	2.047
23/02/201					
5	21300	94.98	46.59	596.91	2.019
24/02/201					
5	21290	94.09	48.69	593.97	2.145
25/02/201					
5	21335	94.2	47.67	588.44	2.085
26/02/201					
5	21335	94.2	50.17	589.66	2.122
27/02/201					
5	21320	94.06	48.84	586.54	2.115
02/03/201					
5	21320	94.2	47.99	588.53	2.061
03/03/201					
5	21320	94.4	49.03	586.1	1.972
04/03/201					
5	21335	94.34	48.52	580.8	1.972

05/03/201 5	21350	94.57	48.79	581.76	2.031
06/03/201 5	21320	94.49	48.16	578.68	1.996
09/03/201 5	21325	94.21	49.6	573.74	2.089
10/03/201 5	21320	95.29	48.47	575.44	2.122
11/03/201 5	21325	95.32	49.13	570.89	2.119
12/03/201 5	21335	95.46	52.99	567.43	2.117
13/03/201 5	21360	95.38	54.75	560.93	2.247
16/03/201 5	21450	95.97	57.91	556.16	2.192
17/03/201 5	21450	96.38	54.16	551.42	2.121
18/03/201 5	21475	97.61	56.57	545.19	2.109
19/03/201 5	21455	97.59	57.8	551.13	2.11
20/03/201 5	21465	98.62	58.34	538.91	2.118
23/03/201 5	21490	99.8	56.43	546.85	2.074
24/03/201 5	21500	99.44	54.66	547.85	2.052

25/03/201		100.3			
5	21475	3	57.05	542.97	1.918
26/03/201					
5	21485	99.6	61.52	548.11	1.97
27/03/201					
5	21500	99.58	61.4	547.72	1.932
30/03/201					
5	21515	98.55	62.53	550.52	1.909
31/03/201					
5	21520	99.26	60.53	554.03	1.873
01/04/201					
5	21530	97.91	60.21	559.54	1.927
02/04/201					
5	21560	97.03	60.22	558.67	1.996
03/04/201					
5	21565	97.19	58.9	564.5	1.96
06/04/201					
5	21565	96.98	58.66	568.28	1.953
07/04/201					
5	21575	97.44	61.63	568.32	1.927
08/04/201					
5	21580	97.29	60.05	565.04	1.859
09/04/201					
5	21580	97.97	62.58	562.24	1.913
10/04/201					
5	21580	98.36	59.54	562.51	1.842
13/04/201					
5	21580	98.19	61.02	561.25	1.899

14/04/201 5	21575	97.44	60.55	565.77	1.887
15/04/201 5	21580	96.55	60.48	562.4	1.906
16/04/201 5	21602	96.78	59.73	545.08	1.963
17/04/201 5	21560	97.83	58.53	552.65	1.949
20/04/201 5	21555	97.94	56.39	549.3	1.93
21/04/201 5	21555	99.16	57.54	552.98	1.9
22/04/201 5	21584	99.34	57.08	554.51	1.89
23/04/201 5	21560	99.49	54.67	551.67	1.895
24/04/201 5	21565	98.73	53.44	544.41	1.865
27/04/201 5	21550	98.32	53.51	542.82	1.886
28/04/201 5	21550	97.42	55.91	543.69	1.911
29/04/201 5	21550	97.52	54.43	537.44	1.982
30/04/201 5	21550	97.94	55.32	528.95	1.954
01/05/201 5	21550	98	55.92	536.82	1.914

04/05/201					
5	21600	97.93	55.11	550.1	1.926
05/05/201					
5	21620	97.28	56.48	552.56	2.003
06/05/201					
5	21620	96.92	59.19	561.82	2.046
07/05/201					
5	21645	96.77	56.41	563	2.035
08/05/201					
5	21650	96.09	56.29	567.2	2.112
11/05/201					
5	21680	95.21	55.11	566.48	2.146
12/05/201					
5	21680	94.6	57.1	572.97	2.182
13/05/201					
5	21705	95.3	54.95	569.56	2.252
14/05/201					
5	21775	95.48	58.12	574.98	2.178
15/05/201					
5	21735	95.08	59.1	570.31	2.142
18/05/201					
5	21765	94.09	55.55	567.9	2.287
19/05/201					
5	21780	94.64	56.57	568.99	2.247
					
.....		.			
01/08/202					
5	26220	99.14	69.67	1507.63	4.198

04/08/202					
5	26176.5	98.78	68.76	1502.52	4.196
05/08/202					
5	26250	98.78	67.64	1495.21	4.218
06/08/202					
5	26225	98.18	66.89	1528.19	4.244
07/08/202					
5	26215	98.4	66.43	1547.15	4.283
08/08/202					
5	26225	98.18	66.59	1573.71	4.273
11/08/202					
5	26233	98.52	66.63	1581.81	4.293
12/08/202					
5	26270	98.1	66.12	1584.95	4.24
13/08/202					
5	26290	97.84	65.63	1596.86	4.293
14/08/202					
5	26265	98.25	66.84	1608.22	4.328
15/08/202					
5	26270	97.85	65.85	1611.6	4.339
18/08/202					
5	26300	98.17	66.01	1640.69	4.302
19/08/202					
5	26320	98.26	65.3	1630	4.296
20/08/202					
5	26390	98.22	66.31	1636.37	4.332
21/08/202					
5	26432.5	98.62	67.12	1654.2	4.258

22/08/202					
5	26350	97.72	67.22	1664.36	4.275
25/08/202					
5	26305	98.43	68.8	1688	4.256
26/08/202					
5	26365	98.22	67.22	1645.47	4.238
27/08/202					
5	26380	98.23	68.05	1614.03	4.207
28/08/202					
5	26375	97.81	68.62	1667.63	4.226
29/08/202					
5	26345	97.77	68.12	1672.78	4.237
01/09/202					
5	26345	97.77	68.15	1680.86	4.253
02/09/202					
5	26345	98.4	69.14	1682.21	4.277
03/09/202					
5	26387.5	98.14	67.6	1681.3	4.211
04/09/202					
5	26390	98.35	66.99	1696.29	4.176
05/09/202					
5	26400	97.77	65.5	1666.97	4.086
08/09/202					
5	26415	97.45	66.02	1624.53	4.046
09/09/202					
5	26387.5	97.79	66.39	1637.32	4.074
10/09/202					
5	26395	97.78	67.49	1643.26	4.032

11/09/202					
5	26402.5	97.53	66.37	1657.75	4.011
12/09/202					
5	26385	97.55	66.99	1667.26	4.06
15/09/202					
5	26385	97.3	67.44	1684.9	4.034
16/09/202					
5	26382.5	96.63	68.47	1680.9	4.026
17/09/202					
5	26375	96.87	67.95	1670.97	4.076
18/09/202					
5	26385	97.35	67.44	1665.18	4.104
19/09/202					
5	26382.5	97.64	66.68	1658.62	4.139
22/09/202					
5	26417.5	97.34	65.97	1634.45	4.145
23/09/202					
5	26420	97.26	66.97	1635.26	4.118
24/09/202					
5	26419	97.87	69.31	1657.46	4.147
25/09/202					
5	26405	98.55	69.42	1666.09	4.174
26/09/202					
5	26410	98.15	70.13	1660.7	4.187
29/09/202					
5	26421	97.91	67.97	1666.48	4.141
30/09/202					
5	26427	97.78	67.02	1661.7	4.15

PHỤ LỤC B: MÃ NGUỒN PYTHON XỬ LÝ DỮ LIỆU VÀ XÂY DỰNG MÔ HÌNH DỰ BÁO TỶ GIÁ USD/VND

Đoạn mã B.1: Cài đặt và nhập thư viện

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler
```

Đoạn mã B.2: Nạp và kiểm tra dữ liệu

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler
```

```
CONFIG = {
    'FILE_PATH': 'forecasting_data_raw.xlsx',

    'TARGET_COL': 'USDVND_RATE',    # Tên cột biến phụ thuộc (Tỷ giá)
    'LOOKBACK_WINDOW': 20,          # T = 20 ngày quá khứ
    'TEST_SIZE': 0.15,               # 15% cho Kiểm định
    'VAL_SIZE': 0.15                 # 15% cho Thăm định
}
```

```
# Thiết lập giao diện biểu đồ
```

```
sns.set(style="whitegrid")
```

```
plt.rcParams['figure.figsize'] = (12, 6)
```

```
#HÀM XỬ LÝ DỮ LIỆU (FUNCTIONS)
```

```
def load_and_analyze_data(config):
```

```
    """Bước 1: Đọc dữ liệu Excel và Thống kê mô tả"""
```

```
    print(" ◇  BƯỚC 1: ĐANG TẢI VÀ PHÂN TÍCH DỮ LIỆU EXCEL...")
```

```
    try:
```

```
        df = pd.read_excel(config['FILE_PATH'])
```

```
        print(" Đã đọc file Excel thành công!")
```

```
        if not np.issubdtype(df['Date'].dtype, np.datetime64):
```

```
            df['Date'] = pd.to_datetime(df['Date'], errors='coerce')
```

```
        df = df.dropna(subset=['Date'])
```

```
        df = df.sort_values('Date', ascending=True)
```

```
        df = df.set_index('Date')
```

```
        df = df.apply(pd.to_numeric, errors='coerce')
```

```
        df = df.fillna(method='ffill')
```

```
        df = df.dropna()
```

```
print(f'\n Dữ liệu sạch: {len(df)} dòng (Từ {df.index.min().date()} đến {df.index.max().date()}")
```

```
print("\n--- BẢNG THỐNG KÊ MÔ TẢ ---")
```

```
stats = df.describe().transpose()[['count', 'mean', 'std', 'min', 'max']]
```

```
print(stats)
```

```
plt.figure(figsize=(10, 8))
```

```
heatmap = sns.heatmap(df.corr(), vmin=-1, vmax=1, annot=True,
cmap='BrBG', fmt='.2f')
```

```
heatmap.set_title('Ma trận Tương quan (Correlation Matrix)',
fontdict={'fontsize':12}, pad=12)
```

```
plt.show()
```

```
return df
```

```
except FileNotFoundError:
```

```
print(f" LỖI: Không tìm thấy file '{config['FILE_PATH']}'")
```

```
print(" Hãy chắc chắn bạn đã upload file .xlsx và tên file trong code trùng khớp!")
```

```
return None
```

```
except Exception as e:
```

```
print(f"LỖI KHÔNG XÁC ĐỊNH: {e}")
```

```
return None
```

```
def preprocess_and_split(df, config):
```

Đoạn mã B.3: Chuẩn hóa, Tạo biến trễ và Chia dữ liệu

```
"""Bước 2: Chuẩn hóa, Tạo biến trễ và Chia dữ liệu"""
```

```
print("\n ◇ BƯỚC 2: TIỀN XỬ LÝ (SCALING & LAGGING)...")
```

1. Chuẩn hóa dữ liệu (Scaling) về [0, 1]

```
scaler = MinMaxScaler(feature_range=(0, 1))
```

```
scaled_values = scaler.fit_transform(df)
```

```
target_idx = df.columns.get_loc(config['TARGET_COL'])
```

```
target_min = scaler.data_min_[target_idx]
```

```
target_max = scaler.data_max_[target_idx]
```

2. Tạo biến trễ (Lagging) cho LSTM/XGBoost

```
X_data, y_data = [], []
```

```
data_matrix = scaled_values # Dùng dữ liệu đã chuẩn hóa
```

```
lookback = config['LOOKBACK_WINDOW']
```

Vòng lặp tạo cửa sổ trượt (Sliding Window)

```
for i in range(lookback, len(data_matrix)):
```

```
    X_data.append(data_matrix[i-lookback:i]) # Lấy 20 ngày quá khứ
```

```
    y_data.append(data_matrix[i, target_idx]) # Lấy giá trị mục tiêu ngày hiện tại
```

```
X_data = np.array(X_data)
```

```
y_data = np.array(y_data)
```

3. Chia tập Train - Val - Test (Theo thứ tự thời gian)

```
total = len(X_data)
```

```
n_test = int(total * config['TEST_SIZE'])
```

```
n_val = int(total * config['VAL_SIZE'])
```

```
n_train = total - n_test - n_val
```

```
X_train, y_train = X_data[:n_train], y_data[:n_train]
```

```
X_val, y_val = X_data[n_train:n_train+n_val], y_data[n_train:n_train+n_val]
```

```

X_test, y_test = X_data[n_train+n_val:], y_data[n_train+n_val:]

print(f' Xử lý hoàn tất!')
print(f' - Tập Huấn luyện (Train): {X_train.shape}')
print(f' - Tập Thẩm định (Val): {X_val.shape}')
print(f' - Tập Kiểm định (Test): {X_test.shape}')

return X_train, y_train, X_val, y_val, X_test, y_test, scaler, (target_min,
target_max)

# CHẠY CHƯƠNG TRÌNH

df_clean = load_and_analyze_data(CONFIG)

if df_clean is not None:
    X_train, y_train, X_val, y_val, X_test, y_test, scaler, target_params =
preprocess_and_split(df_clean, CONFIG)
    print("\n DỮ LIỆU ĐÃ SẴN SÀNG CÓ THỂ CHẠY MÔ HÌNH LSTM.")
Đoạn mã B.4: Mô hình LSTM
# LSTM

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, Dropout
from tensorflow.keras.callbacks import EarlyStopping
from sklearn.metrics import mean_absolute_error, mean_squared_error
import math

print(" ◇ BƯỚC 3: XÂY DỰNG & HUẤN LUYỆN MÔ HÌNH LSTM...")

```

1. Định nghĩa tham số mô hình

n_timesteps = X_train.shape[1] # 20 ngày

n_features = X_train.shape[2] # 5 biến

2. Xây dựng kiến trúc mạng LSTM

model = Sequential()

Lớp LSTM 1: 50 units

model.add(LSTM(units=50, return_sequences=True, input_shape=(n_timesteps, n_features)))

model.add(Dropout(0.2)) # Tắt ngẫu nhiên 20% nơ-ron để tránh học vẹt (Overfitting)

Lớp LSTM 2: 50 units, không trả về sequence nữa

model.add(LSTM(units=50, return_sequences=False))

model.add(Dropout(0.2))

Lớp đầu ra (Dense): Dự báo 1 giá trị duy nhất (Tỷ giá)

model.add(Dense(units=1))

Biên dịch mô hình

model.compile(optimizer='adam', loss='mean_squared_error')

3. Thiết lập Early Stopping (Dừng sớm nếu không học được thêm)

Nếu val_loss không giảm trong 15 vòng lặp (patience), thì dừng lại.

early_stop = EarlyStopping(monitor='val_loss', patience=15,

restore_best_weights=True)

4. Huấn luyện (Fitting)

```

history = model.fit(
    X_train, y_train,
    epochs=100,      # Chạy tối đa 100 vòng
    batch_size=32,    # Mỗi lần học 32 dòng dữ liệu
    validation_data=(X_val, y_val), # Dùng tập Thăm định để kiểm tra
    callbacks=[early_stop],
    verbose=1
)

```

Đoạn mã B.5: đánh giá và vẽ biểu đồ kết quả LSTM

ĐÁNH GIÁ & VẼ BIỂU ĐỒ KẾT QUẢ

```
print("\ ĐÁNH GIÁ KẾT QUẢ DỰ BÁO...")
```

Dự báo trên tập Test

```
y_pred_scaled = model.predict(X_test)
```

ĐẢO NGƯỢC CHUẨN HÓA (INVERSE SCALING)

Công thức: Giá trị thực = Giá trị scaled * (Max - Min) + Min

t_min, t_max = target_params # Lấy min/max đã lưu ở bước trước

```
y_pred_real = y_pred_scaled * (t_max - t_min) + t_min
```

```
y_test_real = y_test * (t_max - t_min) + t_min
```

Tính sai số

```
mae = mean_absolute_error(y_test_real, y_pred_real)
```

```
rmse = math.sqrt(mean_squared_error(y_test_real, y_pred_real))
```

```
mape = np.mean(np.abs((y_test_real - y_pred_real) / y_test_real)) * 100
```

```
print("\n" + "="*40)
```

```
print(f"KẾT QUẢ MÔ HÌNH LSTM (trên tập Test):")
```

```

print(f" - MAE (Sai số tuyệt đối): {mae:.2f} VND")
print(f" - RMSE (Sai số căn bậc 2): {rmse:.2f} VND")
print(f" - MAPE (Sai số phần trăm): {mape:.4f} %")
print("="*40)

# Vẽ biểu đồ so sánh
plt.figure(figsize=(14, 7))

# Vẽ biểu đồ giá trị thực tế và dự báo
plt.subplot(2, 1, 1)
plt.plot(y_test_real, color='blue', label='Thực tế (Actual)')
plt.plot(y_pred_real, color='red', linestyle='--', label='Dự báo (Predicted)')
plt.title('So sánh Tỷ giá Thực tế và Dự báo (LSTM)', fontsize=14)
plt.ylabel('VND/USD')
plt.legend()

# Vẽ biểu đồ Loss (Quá trình học)
plt.subplot(2, 1, 2)
plt.plot(history.history['loss'], label='Train Loss')
plt.plot(history.history['val_loss'], label='Val Loss')
plt.title('Hàm mất mát trong quá trình huấn luyện (Loss Function)', fontsize=14)
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.legend()

plt.tight_layout()
plt.show()

```

Đoạn mã B.6: Huấn luyện mô hình RANDOM FOREST & XGBOOST

```
# HUẤN LUYỆN RANDOM FOREST & XGBOOST
```

```
from sklearn.ensemble import RandomForestRegressor
```

```
from xgboost import XGBRegressor
```

```
import pandas as pd # Đảm bảo thư viện đã được import
```

```
print("CHUẨN BỊ DỮ LIỆU & HUẤN LUYỆN RF + XGBOOST...")
```

```
# 1. ÉP DẸP DỮ LIỆU (FLATTEN) TỪ 3D -> 2D
```

```
# LSTM dùng 3D (Sample, TimeSteps, Features). RF/XGB cần 2D (Sample,  
TimeSteps*Features)
```

```
# Ví dụ: 20 ngày * 5 biến = 100 cột input cho mỗi dòng
```

```
nsamples, ntimesteps, nfeatures = X_train.shape
```

```
X_train_2d = X_train.reshape((nsamples, ntimesteps * nfeatures))
```

```
X_test_2d = X_test.reshape((X_test.shape[0], ntimesteps * nfeatures))
```

```
print(f" Đã chuyển đổi dữ liệu sang 2D: {X_train_2d.shape}")
```

```
# KHỞI TẠO MÔ HÌNH
```

```
# Random Forest
```

```
rf_model = RandomForestRegressor(n_estimators=100, random_state=42, n_jobs=-  
1)
```

```
# XGBoost
```

```
xgb_model = XGBRegressor(n_estimators=100, learning_rate=0.05,  
random_state=42, n_jobs=-1)
```

```
# HUẤN LUYỆN (TRAINING)
```

```
print(" - Đang huấn luyện Random Forest...")
```

```
rf_model.fit(X_train_2d, y_train)
```

```
print(" - Đang huấn luyện XGBoost...")
xgb_model.fit(X_train_2d, y_train)
```

Đoạn mã B.7: đánh giá và so sánh kết quả mô hình RANDOM FOREST & XGBOOST

6. ĐÁNH GIÁ VÀ SO SÁNH

```
print("\n ĐÁNH GIÁ KẾT QUẢ...")

def evaluate_model(model, X_input, name):
    # Dự báo (kết quả đang ở dạng Scaled 0-1)
    pred_scaled = model.predict(X_input)

    # Đảo ngược chuẩn hóa về VND thực tế
    t_min, t_max = target_params
    pred_real = pred_scaled * (t_max - t_min) + t_min
    y_test_real = y_test * (t_max - t_min) + t_min

    # Tính sai số
    mae = mean_absolute_error(y_test_real, pred_real)
    rmse = math.sqrt(mean_squared_error(y_test_real, pred_real))
    mape = np.mean(np.abs((y_test_real - pred_real) / y_test_real)) * 100

    return [name, mae, rmse, mape], pred_real

# Đánh giá RF
rf_results, rf_pred = evaluate_model(rf_model, X_test_2d, "Random Forest")
```

```

# Đánh giá XGBoost
xgb_results, xgb_pred = evaluate_model(xgb_model, X_test_2d, "XGBoost")

# In bảng kết quả so sánh
results_df = pd.DataFrame([rf_results, xgb_results], columns=['Model', 'MAE',
'RMSE', 'MAPE (%)'])
print("\n--- BẢNG SO SÁNH HIỆU SUẤT (TEST SET) ---")
print(results_df)

# VẼ BIỂU ĐỒ SO SÁNH 3 MÔ HÌNH

plt.figure(figsize=(15, 6))
# Lấy lại y_test_real (Thực tế)
t_min, t_max = target_params
y_real_plot = y_test * (t_max - t_min) + t_min

plt.plot(y_real_plot, label='Thực tế (Actual)', color='black', linewidth=2)
plt.plot(rf_pred, label='Random Forest', linestyle='--', alpha=0.7)
plt.plot(xgb_pred, label='XGBoost', linestyle='-.', alpha=0.7)

# Nếu bạn muốn so sánh với LSTM luôn trên biểu đồ này:
# plt.plot(y_pred_real, label='LSTM', color='red', linewidth=1.5)

plt.title('So sánh Dự báo: Random Forest vs XGBoost', fontsize=14)
plt.ylabel('Tỷ giá USD/VND')
plt.legend()
plt.show()

Đoạn mã B.8: huấn luyện mô hình ARIMA
# HUẤN LUYỆN MÔ HÌNH ARIMA (CHẠY RIÊNG)

```

```
!pip install pmdarima
```

```
import pmdarima as pm
```

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
```

```
import math
```

```
import matplotlib.pyplot as plt
```

```
print("\n HUẤN LUYỆN MÔ HÌNH ARIMA...")
```

```
# CHUẨN BỊ DỮ LIỆU RIÊNG CHO ARIMA
```

```
# Ta lấy trực tiếp từ df_clean ban đầu
```

```
data_arima = df_clean[[CONFIG['TARGET_COL']]] # Chỉ lấy cột Tỷ giá
```

```
# Chia Train/Test theo đúng tỷ lệ như các mô hình kia
```

```
train_size = int(len(data_arima) * (1 - CONFIG['TEST_SIZE']))
```

```
train_arima = data_arima[:train_size]
```

```
test_arima = data_arima[train_size:]
```

```
print(f" - Dữ liệu Train ARIMA: {len(train_arima)} mẫu")
```

```
print(f" - Dữ liệu Test ARIMA: {len(test_arima)} mẫu")
```

Đoạn mã B.9: tự động tìm mô hình tối ưu

```
# TỰ ĐỘNG TÌM MÔ HÌNH TỐI ƯU (AUTO ARIMA)
```

```
# thử các bộ tham số (p,d,q)
```

```
print(" - Đang chạy Auto ARIMA để tìm tham số tốt nhất (vui lòng đợi)...")
```

```
arima_model = pm.auto_arima(
```

```
    train_arima,
```

```
    start_p=1, start_q=1,
```

```

max_p=5, max_q=5, # Giới hạn bậc để tìm cho nhanh
m=1,           # Dữ liệu ngày, không có tính mùa vụ rõ rệt theo chu kỳ ngắn
d=None,        # Để máy tự tìm bậc sai phân d
seasonal=False, # Tạm tắt tính mùa vụ phức tạp để mô hình nhẹ hơn
trace=True,    # Hiện quá trình tìm kiếm
error_action='ignore',
suppress_warnings=True,
stepwise=True
)

```

```

print(f"\n☑ Đã tìm thấy mô hình tối ưu: {arima_model.order}")

```

DỰ BÁO

```

print(" - Đang thực hiện dự báo...")
arima_pred = arima_model.predict(n_periods=len(test_arima))
# Chuyển về dạng Series để vẽ biểu đồ
arima_pred_series = pd.Series(arima_pred.values, index=test_arima.index)
mae_arima = mean_absolute_error(test_arima, arima_pred)
rmse_arima = math.sqrt(mean_squared_error(test_arima, arima_pred))
mape_arima = np.mean(np.abs((test_arima.values.flatten() - arima_pred.values) /
test_arima.values.flatten())) * 100

```

```

print("\n" + "="*40)
print(f"☑ KẾT QUẢ ARIMA (Test Set):")
print(f" - MAE: {mae_arima:.2f} VND")
print(f" - RMSE: {rmse_arima:.2f} VND")
print(f" - MAPE: {mape_arima:.4f} %")
print("="*40)

```

```

# Vẽ biểu đồ ARIMA
plt.figure(figsize=(14, 6))
plt.plot(train_arima.index, train_arima, label='Train (Lịch sử)')
plt.plot(test_arima.index, test_arima, label='Test (Thực tế)')
plt.plot(test_arima.index, arima_pred, label='ARIMA Forecast', color='green',
linestyle='--')
plt.title('Dự báo Tỷ giá USD/VND bằng ARIMA', fontsize=14)
plt.legend()
plt.show()

```

Đoạn mã B.10: tổng hợp so sánh 4 mô hình

```

# TỔNG HỢP SO SÁNH 4 MÔ HÌNH

```

```

import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

summary_data = {
    'Mô hình': ['LSTM', 'Random Forest', 'XGBoost', 'ARIMA'],
    # Lấy kết quả từ các biến đã chạy
    'MAE (VND)': [571.06, 2042.05, 2261.87, mae_arima],
    'RMSE (VND)': [675.81, 2120.40, 2332.26, rmse_arima],
    'MAPE (%)': [2.5913, 7.9849, 8.8501, mape_arima]
}

df_summary = pd.DataFrame(summary_data)
df_summary = df_summary.sort_values(by='MAPE (%)', ascending=True)

print("\n BẢNG XẾP HẠNG MÔ HÌNH DỰ BÁO CUỐI CÙNG ")
print(df_summary)

# Vẽ biểu đồ cột so sánh MAPE

```


```
plt.figure(figsize=(10, 6))
sns.barplot(x='Mô hình', y='MAPE (%)', data=df_summary, palette='rocket')
plt.title('So sánh Sai số MAPE giữa 4 mô hình', fontsize=14)
plt.ylabel('MAPE (%) - Càng thấp càng tốt')
plt.show()
```

PHỤ LỤC C: KẾT QUẢ PHÂN TÍCH THỐNG KÊ VÀ ĐỒ THỊ ĐÁNH GIÁ MÔ HÌNH

--- BẢNG THỐNG KÊ MÔ TẢ ---					
	count	mean	std	min	max
USDVND_RATE	1105.0	23334.335747	1094.954468	21115.000	26415.000
DXY	1105.0	98.255484	4.947551	89.030	114.110
OIL_BRENT	1105.0	66.485385	17.847774	19.330	121.600
VNINDEX	1105.0	985.291913	282.971452	536.450	1696.290
US10Y	1105.0	2.592813	1.120488	0.512	4.926

Hình C.1: Kết quả bảng thống kê mô tả dữ liệu

Nguồn: Nhóm nghiên cứu xử lý dữ liệu trên Google Colab




Hình C.2: Biểu đồ ma trận tương quan

Nguồn: Nhóm nghiên cứu xử lý dữ liệu trên Google Colab




Hình C.3: Kết quả dự báo của mô hình LSTM

Nguồn: Nhóm nghiên cứu xử lý dữ liệu trên Google Colab



Hình C.4: Kết quả dự báo của mô hình RF và XGboost

Nguồn: Nhóm nghiên cứu xử lý dữ liệu trên Google Colab



Hình C.5: Kết quả dự báo của mô hình ARIMA

Nguồn: Nhóm nghiên cứu xử lý dữ liệu trên Google Colab