

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN TỐT NGHIỆP
ĐẠI HỌC

DỰ ĐOÁN GIÁ CHỨNG KHOÁN BẰNG PHƯƠNG PHÁP
HỌC MÁY KẾT HỢP LỘC NHIỀU: NGHIÊN CỨU TỪ
THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM

CHUYÊN NGÀNH: TÀI CHÍNH - NGÂN HÀNG

MÃ SỐ: 7 34 02 01

PHẠM BÁ HÙNG

TP. HỒ CHÍ MINH, 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN TỐT NGHIỆP
ĐẠI HỌC

Chuyên ngành: Tài chính - Ngân hàng

Mã số: 7 34 02 01

DỰ ĐOÁN GIÁ CHỨNG KHOÁN BẰNG PHƯƠNG PHÁP
HỌC MÁY KẾT HỢP LỘC NHIỀU: NGHIÊN CỨU TỪ
THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM

Họ và tên sinh viên: PHẠM BÁ HÙNG

Mã số sinh viên: 030138220158

Lớp sinh hoạt: DH38QR01

NGƯỜI HƯỚNG DẪN KHOA HỌC
TS. TRIỆU KIM LANH

TP. HỒ CHÍ MINH, 2025

TÓM TẮT

Trước bối cảnh phát triển kinh tế như hiện nay, thị trường chứng khoán Việt Nam đã và đang thu hút các nhà đầu tư trong nước và cả nước ngoài. Đối với các nhà đầu tư trong nước, kinh nghiệm đầu tư cùng với các kiến thức liên quan đến thị trường nói chung và chứng khoán nói riêng vẫn còn hạn chế. Mục đích của việc đầu tư việc quan trọng nhất vẫn là giảm thiểu rủi ro và bảo toàn hoặc tối ưu lợi nhuận, nhưng vì một số lý do nêu trên làm cho hoạt động đầu tư gặp nhiều trở ngại.

Tuy nhiên với sự bùng nổ của cách mạng công nghiệp 5.0, ứng dụng các mô hình học máy vào dự đoán giá chứng khoán dần được triển khai rộng rãi củng cố cơ sở thông tin trong lĩnh vực đầu tư. Những năm gần đây tại Việt Nam, nhiều đề tài sử dụng mô hình học máy vào dự đoán giá chứng khoán đã nghiên cứu rất nhiều và mang đến nhiều kết quả nổi bật.

Nhằm củng cố nhận định mô hình học máy nói chung và học sâu nói riêng mang đến nhiều giá trị về mặt lý thuyết lẫn thực tiễn trong dự đoán giá chứng khoán, ngoài lý do đó khóa luận này được thực hiện với mục đích tối ưu gia tăng hiệu suất của mô hình thông qua kết hợp kỹ thuật lọc nhiễu và mô hình học sâu.

Nghiên cứu trên thị trường chứng khoán Việt Nam với đại diện là chỉ số VN-Index trong giai đoạn 10 năm, kỹ thuật lọc nhiễu được sử dụng là biến đổi wavelet rời rạc (DWT) thực nghiệm trên các tùy chỉnh khác nhau để tối ưu dữ liệu đầu vào cho mô hình học sâu (LSTM và GRU). Kết quả cho thấy, kỹ thuật lọc nhiễu được áp dụng mang đến cải thiện so với các mô hình gốc được tiến hành riêng lẻ trên dữ liệu giá đóng cửa. Mặt khác khi thực hiện trên tỉ suất sinh lời của chỉ số thì lại mang đến kết quả không như mong đợi.

Từ khóa: Dự đoán, Mô hình học sâu, LSTM, Lọc nhiễu, Dự báo thị trường chứng khoán

ABSTRACT

In the context of current economic development, the Vietnamese stock market has increasingly attracted both domestic and foreign investors. However, for many local investors, investment experience and knowledge related to the market in general and securities in particular remain limited. The primary objective of investment is to minimize risks while preserving or optimizing returns, yet the aforementioned limitations often hinder effective investment activities.

With the advent of the Fifth Industrial Revolution, the application of machine learning models to stock price prediction has been widely adopted to strengthen the informational foundation for investment decision-making. In recent years, numerous studies in Vietnam have employed machine learning techniques for stock market forecasting and have yielded notable results.

To reinforce the view that machine learning and deep learning in particular offers substantial theoretical and practical value in stock price prediction, this thesis aims to further enhance model performance by integrating noise-filtering techniques with deep learning architectures. This study focuses on the Vietnamese stock market, represented by the VN-Index over a 10-year period. The employed Wavelet Denoising technique is the Discrete Wavelet Transform (DWT), implemented with various configurations to optimize the input data for deep learning models (LSTM and GRU). The findings indicate that applying wavelet-based denoising yields performance improvements compared to baseline models trained directly on closing-price data. Conversely, applying the same approach to return series does not produce the expected results.

Key words: Prediction; Deep Learning Models; LSTM; GRU; Wavelet Denoising; Stock Market Forecasting.

LỜI CAM ĐOAN

Xin cam đoan khóa luận “Dự đoán giá chứng khoán bằng phương pháp học máy kết hợp lọc nhiễu: Nghiên cứu từ thị trường chứng khoán Việt Nam” được tác giả chính tay thực hiện và trình bày. Nội dung và kết quả nghiên cứu này là độc nhất và chưa từng được công bố trước đây. Nguồn tham khảo và các thông tin liên quan đã được trích dẫn minh bạch.

TP.HCM, Ngày...Tháng...Năm...

Tác giả

(Ký, ghi rõ Họ tên)

LỜI CẢM ƠN

Tôi xin phép được gửi lời cảm ơn đến Trường Đại Học ngân hàng cùng toàn thể ban giám hiệu, cán bộ giảng viên nhân viên trường đã luôn tạo điều kiện về vật chất lẫn tinh thần trong quá trình tôi theo học tại đây. Thật biết ơn những tri thức và kinh nghiệm mà các thầy cô đã chia sẻ, nhờ đó mà tôi có đủ các cơ sở về lý luận và căn đảm để thực hiện khóa luận này

Tiếp theo là lời cảm ơn chân thành dành cho giảng viên cố vấn-TS. Triệu Kim Lanh. Nhờ có sự giúp đỡ cố vấn tận tình không ngại nghỉ của cô cùng với những lời khuyên và những kinh nghiệm sâu sắc nhất mà tác giả có thể hoàn thành khóa luận này.

Khóa luận này được xem là đã hoàn thành tuy nhiên vẫn còn tồn tại những thiếu sót do một số hạn chế về mặt thời gian, kiến thức, kinh nghiệm của tác giả trong việc làm nghiên cứu nói riêng và các hoạt động liên quan đến học thuật nói chung. Chính vì lý do đó mong các thầy cô thuộc hội đồng phản biện hãy đưa ra những nhận xét khách quan và công tâm nhất để tác giả có cơ hội hoàn thiện và phát triển các nghiên cứu sau này.

MỤC LỤC

TÓM TẮT.....	i
ABSTRACT	ii
LỜI CAM ĐOAN	iii
LỜI CẢM ƠN.....	iv
MỤC LỤC	v
DANH MỤC TỪ VIẾT TẮT	viii
DANH MỤC CÁC BẢNG	x
DANH MỤC CÁC HÌNH	xi
CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu nghiên cứu	2
1.2.1 Mục tiêu tổng quát	2
1.2.2 Mục tiêu cụ thể	2
1.3 Câu hỏi nghiên cứu	3
1.4 Đối tượng và phạm vi nghiên cứu	3
1.4.1 Đối tượng nghiên cứu	3
1.4.2 Phạm vi nghiên cứu	3
1.5 Phương pháp nghiên cứu	4
1.6 Ý nghĩa nghiên cứu.....	5
1.6.1 Về mặt khoa học	5
1.6.2 Về mặt thực tiễn.....	5
1.7 Bố cục nghiên cứu	6
KẾT LUẬN CHƯƠNG 1	7
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU	8
2.1 Tổng quan về thị trường chứng khoán Việt Nam.....	8
2.2 Cơ sở lý thuyết.....	9
2.2.1 Khái niệm về dự báo chứng khoán	9
2.2.2 Lý thuyết bước đi ngẫu nhiên (Random Walk Theory)	10
2.2.3 Giả thuyết Thị trường Hiệu quả (Efficient Market Hypothesis - EMH).....	10

2.2.4 Lý thuyết Tài chính hành vi (Behavioral Finance).....	11
2.2.5 Lý thuyết về chuỗi thời gian.....	13
2.2.6 Lý thuyết về kỹ thuật lọc nhiễu và biến đổi wavelet.....	14
2.3 Tổng quan về học máy.....	16
2.4. Giới thiệu một số mô hình học máy	17
2.4.1 Mạng bộ nhớ ngắn hạn dài hạn (Long Short-Term Memory - LSTM).....	17
2.4.2 Mạng nơ-ron hồi quy có cổng (Gated Recurrent Unit - GRU)	18
2.4.3 Mô hình kết hợp (Hybrid Model)	19
2.5 Tổng quan về vấn đề và các nghiên cứu liên quan.....	20
2.5.1 Các nghiên cứu ngoài nước	24
2.5.2 Các nghiên cứu trong nước.....	25
2.5.3. Khoảng trống tri thức (Research Gap)	26
KẾT LUẬN CHƯƠNG 2	27
CHƯƠNG 3 PHƯƠNG PHÁP NGHIÊN CỨU	28
3.1 Quy trình thực hiện nghiên cứu	28
3.2 Dữ liệu nghiên cứu	30
3.3 Kỹ thuật lọc nhiễu Biến đổi Wavelet rời rạc (Discrete Wavelet Transform)	30
3.3.1 Cơ chế hoạt động	31
3.3.2 Cơ sở lý thuyết toán học	32
3.3.3. Các họ sóng mẹ (Mother Wavelets) sử dụng	33
3.3.4. Thuật toán Mallat và Quá trình phân rã.....	34
3.3.5 Ngưỡng (Thresholding)	35
3.4 Phương pháp nghiên cứu	36
3.4.1 Tổng quan về mạng nơ-ron bộ nhớ dài ngắn hạn (LSTM).....	36
3.4.2 Mô hình hồi quy đơn vị cổng GRU	38
3.4.3 Các hàm kích hoạt sử dụng trong mô hình.....	39
3.4.4 Hàm mục tiêu.....	40
3.4.5 Bộ tối ưu adam.....	40
3.4.6 Chuẩn hóa Minmax scaler	42
3.4.7 Tập xác thực (Validation set) và cơ chế dừng sớm (Early stopping)	43
3.5 Đánh giá hiệu suất mô hình	44
3.5.1 Chỉ số đánh giá MSE	44
3.5.2 Chỉ số đánh giá RMSE	45

3.5.3 Chỉ số đánh giá MAE	45
3.5.4 Chỉ số đánh giá MAPE	46
3.5.5 Hệ số xác định R^2	47
KẾT LUẬN CHƯƠNG 3	48
Chương 4 Kết quả và đánh giá	49
4.1 Các siêu tham số sử dụng trong mô hình.....	49
4.2 Kết quả sau lọc nhiễu.....	51
4.2.1 Trên chỉ số VN-Index	51
4.2.2 Trên log return	52
4.3 Dự đoán trên chỉ số VN-Index.....	53
4.3.1 Kết quả dự đoán của LSTM.....	53
4.3.2 Kết quả dự đoán của GRU	55
4.3.3 Kết quả của DWT kết hợp LSTM	56
4.3.4 Kết quả của DWT kết hợp GRU.....	59
4.4 Dự đoán trên Log return của chỉ số VN-Index.....	62
4.4.1 Kết quả.....	62
4.4.2. Hiệu suất của các mô hình trên dữ liệu biến động tỉ suất.....	63
4.4.3. Tác động ngược chiều của kỹ thuật lọc nhiễu	64
4.5 Đánh giá kết quả	64
KẾT LUẬN CHƯƠNG 4	66
CHƯƠNG 5 KẾT LUẬN KIẾN NGHỊ	67
5.1 Kết luận.....	67
5.2 Hạn chế và các hướng nghiên cứu tiếp theo	68
5.2.1. Hạn chế của nghiên cứu.....	68
5.2.2. Các hướng nghiên cứu tiếp theo	69
KẾT LUẬN CHƯƠNG 5	71
TÀI LIỆU THAM KHẢO	72
PHỤ LỤC	76

DANH MỤC TỪ VIẾT TẮT

Từ Viết Tắt	Tiếng Anh	Tiếng Việt
TTCK	(Stock Market)	Thị trường Chứng khoán
HOSE	(Ho Chi Minh Stock Exchange)	Sở Giao dịch Chứng khoán Thành phố Hồ Chí Minh
RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy
LSTM	Long Short-Term Memory	Bộ nhớ dài-ngắn hạn
GRU	Gated Recurrent Unit	Đơn vị Hồi quy Cổng
WT	Wavelet Transform	Phép biến đổi Wavelet
DWT	Discrete Wavelet Transform	Phép biến đổi Wavelet Rời rạc
MSE	Mean Squared Error	Sai số Bình phương Trung bình
RMSE	Root Mean Squared Error	Căn bậc hai của Sai số Bình phương Trung bình
MAE	Mean Absolute Error	Sai số Tuyệt đối Trung bình
MAPE	Mean Absolute Percentage Error	Sai số Phần trăm Tuyệt đối Trung bình
EMH	Efficient Market Hypothesis	Giả thuyết Thị trường Hiệu quả
MRA	Multi-Resolution Analysis	Phân tích Đa Độ phân giải
Adam	Adaptive Moment Estimation	Ước tính Mô men Thích nghi

CNN	Convolutional Neural Network	Mạng nơ-ron Tích chập
MAD	Mean Absolute Deviation	Sai số tuyệt đối

DANH MỤC CÁC BẢNG

Bảng 2. 1 Lược khảo các nghiên cứu trước	24
 Bảng 4. 1 Siêu tham số của mô hình LSTM.....	49
Bảng 4. 2 Siêu tham số của mô hình GRU	50
Bảng 4. 3 Kết quả các chỉ số đánh giá của mô hình DWT kết hợp LSTM (trên hai mức phân rã)	57
Bảng 4. 4 Kết quả các chỉ số đánh giá của mô hình DWT kết hợp GRU (trên hai mức phân rã)	60
Bảng 4. 5 Kết quả chỉ số đánh giá trên biến động tỉ suất log return.....	63

DANH MỤC CÁC HÌNH

Hình 2. 1 sơ đồ quy trình xây dựng mô hình học máy	16
Hình 3. 1 Quy trình thực hiện nghiên cứu	28
Hình 3. 2 Sơ đồ quy trình lọc nhiễu.....	31
Hình 3. 3 Sơ đồ mô tả cách phân rã của DWT	34
Hình 3. 4 Mô-đun của mạng LTSM	37
Hình 3. 5 Mô-đun của mô hình GRU	38
Hình 4. 1 Dữ liệu sau khi lọc nhiễu hàm haar với hai mức phân rã (bên trái mức 1 và bên phải mức 2)	51
Hình 4. 2 Dữ liệu tập train (log return) sau lọc nhiễu phân rã mức một (hàm haar bên trái và sym6 bên phải)	52
Hình 4. 3 Kết quả dự đoán của mô hình LSTM gốc trên chỉ số VN-Index	53
Hình 4. 4 Kết quả dự đoán của mô hình GRU gốc trên chỉ số VN-Index.....	55
Hình 4. 5 Kết quả dự đoán củaDWT kết hợp LSTM trên chỉ số VN-Index (phân rã mức 1 với hàm sym6)	56
Hình 4. 6 Kết quả dự đoán củaDWT kết hợp LSTM trên chỉ số VN-Index (phân rã mức 2 với hàm coif1).....	56
Hình 4. 7 Kết quả dự đoán củaDWT kết hợp GRU trên chỉ số VN-Index (phân rã mức 1 với hàm haar).....	59
Hình 4. 8 Kết quả dự đoán củaDWT kết hợp GRU trên chỉ số VN-Index (phân rã mức 2 với hàm haar).....	59
Hình 4. 9 Kết quả dự đoán của hai mô hình gốc trên tỉ suất sinh lời (bên trái là của LSTM bên phải là của GRU).....	62
Hình 4. 10 Kết quả dự đoán của LSTM kết hợp lọc nhiễu (phân rã mức 1 với hàm sym6)	62
Hình 4. 11 Kết quả dự đoán của GRU kết hợp lọc nhiễu (phân rã mức 1 với hàm haar)	63

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1 Lý do chọn đề tài

Từ những năm 2000 đến nay, thị trường chứng khoán Việt nam (TTCK) đang dần trở thành một nơi đầy tiềm năng để đầu tư sinh lời khiến cho các nhà đầu tư từ lớn đến nhỏ từ các tổ chức, nhà đầu tư chuyên nghiệp cho đến những cá nhân nhỏ lẻ đều tìm đến. TTCK càng phát triển thì cơ hội của nhà đầu tư càng nhiều và đa dạng đi kèm theo đó là một lượng rủi ro không hề nhỏ kèm theo.

TTCK Việt Nam vốn xuất hiện khá muộn so với các quốc gia, chính vì sự non trẻ này đã khiến vị thế của chứng khoán Việt Nam được đánh giá không quá tích cực trong mắt các nhà đầu tư quốc tế. Song với đó phần đông nhà đầu tư trong nước vẫn còn đầu tư theo cảm tính mua bán ồ ạt chỉ sau vài thông tin ngắn hạn, chính vì điều này đã làm giá chứng khoán nói riêng và cả thị trường chứng khoán nói chung hay xảy ra tình trạng biến động thất thường dẫn đến sự không ổn định và theo thời gian, thói quen đầu tư “tùy hứng” như vậy khiến cho TTCK khó mà phát triển bền vững.

Để ra quyết định đầu tư cần xem xét kỹ lưỡng về tỉ suất lợi tức và rủi ro. Đặc biệt là các nhân tố rủi ro hệ thống gồm sự biến động của: lạm phát, lãi suất, chính sách tiền tệ thay đổi, tang trường hoặc suy thoái kinh tế, quy định pháp luật và cả khủng hoảng địa chính trị trong khu vực

Nhằm giảm thiểu rủi ro mà vẫn giữ được tỉ suất sinh lợi hợp lý là mục tiêu tối quan trọng đối với nhà đầu tư. Việc dự đoán xu hướng hoặc giá trị tương lai của chỉ số chứng khoán trở thành nhu cầu thiết yếu cho nhà đầu tư, quỹ đầu tư và cơ quan quản lý.

Tuy có ý nghĩa quan trọng, việc dự báo VN-Index lại là một thách thức lớn do tính chất biến động cao, chịu ảnh hưởng từ nhiều yếu tố nhiễu và đặc tính phi tuyến phức tạp. Trong bối cảnh đó, sự trỗi dậy của các mô hình học máy và học sâu như GRU và LSTM đã mở ra những hướng tiếp cận mới, với khả năng nắm bắt các mẫu hình phi tuyến và phụ thuộc dài hạn trong dữ liệu, hứa hẹn mang lại những dự báo vượt trội.

Để nâng cao hơn nữa độ chính xác của các mô hình hiện đại, một hướng nghiên cứu được quan tâm là kết hợp chúng với các kỹ thuật tiền xử lý tín hiệu. Trong đó, biến đổi Wavelet nổi bật với khả năng phân tách chuỗi thời gian tài chính gốc thành các thành phần tần số khác nhau, từ đó lọc bỏ nhiễu và tách biệt xu hướng cốt lõi với các biến động ngắn hạn. Việc kết hợp sức mạnh lọc nhiễu trong việc làm sạch dữ liệu với khả năng học các phụ thuộc phức tạp của các mô hình học sâu tạo nên các mô hình lai có tiềm năng lớn trong việc giải quyết bài toán dự báo chỉ số chứng khoán.

Đề tài “Dự đoán giá chứng khoán bằng phương pháp học máy kết hợp lọc nhiễu: Nghiên cứu từ thị trường chứng khoán Việt Nam” đã trở thành một nghiên cứu cần thiết để giải đáp những vấn đề được nêu trên. Mục đích của nghiên cứu này nhằm tìm ra cách tối ưu các mô hình học máy trong việc dự đoán biến động thị trường thông qua đánh giá kết quả và hiệu suất của các mô hình nghiên cứu.

1.2 Mục tiêu nghiên cứu

1.2.1 Mục tiêu tổng quát

Mục tiêu cốt lõi của nghiên cứu này nhằm ứng dụng phương pháp lọc nhiễu kết hợp với các mô hình học máy để dự đoán chỉ số VN-Index đại diện biến động của thị trường chứng khoán Việt Nam. Từ đó so sánh đánh giá và đưa ra kết luận có hay không việc lọc nhiễu đem lại kết quả khả quan hơn so với mô hình thuần túy

1.2.2 Mục tiêu cụ thể

Để giải quyết vấn đề một cách logic ta chia mục tiêu tổng quát thành các mục tiêu cụ thể sau:

Đầu tiên: xây dựng các mô hình học máy để dự báo sự biến động của thị trường qua chỉ số VN-Index

Thứ hai: Phân tích và đánh giá mô hình dựa trên kết quả đầu ra. Để xem mô hình nào là tối ưu nhất trong các điều kiện nghiên cứu khác nhau.

1.3 Câu hỏi nghiên cứu

Muốn giải quyết các mục tiêu nghiên cứu từ cụ thể đến tổng quát ta đặt ra và tập trung trả lời các câu hỏi nghiên cứu sau đây:

Câu hỏi xuyên suốt: Phương pháp lọc nhiễu được sử dụng trong nghiên cứu có mang đến sự cải thiện cho các mô hình học máy được chọn hay không?

Các câu hỏi phụ

Mô hình học máy nào kết hợp với lọc nhiễu sẽ đem lại kết quả tốt hơn trong các điều kiện nghiên cứu đặt ra?

Câu hỏi mở rộng:

Việc ứng dụng lọc nhiễu có cải thiện kết quả mô hình trên biến động của chỉ số (log return) hay không?

1.4 Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu được hướng tới trong thực nghiệm này là phương pháp lọc nhiễu trên tiền dữ liệu kết hợp các mô hình học máy vào dự đoán sự biến động của thị trường qua chỉ số VN-Index.

1.4.2 Phạm vi nghiên cứu

Mặt thời gian: Nghiên cứu sẽ thu thập dữ liệu lịch sử của chỉ số VN-Index trong khoảng thời gian từ 1/10/2015 đến ngày 1/10/2025 (dữ liệu chỉ số đóng cửa theo ngày trong 10 năm). Lý do chọn dữ liệu nghiên cứu trong khoảng thời gian trên như sau: Thời gian đủ dài để làm đầu vào cho các mô hình học máy, thể hiện đầy đủ các xu hướng tăng trưởng cũng như biến động thị trường.

Khoảng thời gian 10 năm cũng vừa đủ để thể hiện các sự kiện về kinh tế đáng chú ý ảnh hưởng trực tiếp hoặc gián tiếp đến thị trường (chỉ số VN-Index) đã qua:

Các khủng hoảng tài chính, thay đổi về chính sách tài khóa cũng như về các chính sách tiền tệ, các thay đổi về mặt pháp luật. sự biến động toàn cầu, thay đổi về chính sách thuế quan của các nước trên thế giới và khu vực và các tín hiệu

trong hoạt động ngoại giao đi kèm với các khủng hoảng địa chính trị. Kể cả việc thay đổi nhân thức và hành vi của nhà đầu tư về thị trường chứng khoán.

Mặt không gian: Tập trung chủ yếu vào chỉ số VN-Index được niêm yết trên sàn HOSE.

Mặt nội dung: Nghiên cứu chủ yếu bám sát về cách tối ưu và ứng mô hình học máy vào dự đoán chỉ số của thị trường chứng khoán dựa trên dữ liệu lịch sử. Nghiên cứu không xem xét đến các yếu tố cơ bản khác như lãi suất, tỷ giá, biến số vĩ mô, hay tin tức thị trường

1.5 Phương pháp nghiên cứu

Phương pháp nghiên cứu tác giả lựa chọn là phương pháp định lượng được thực hiện bằng các mô hình học máy được thực hiện trên ngôn ngữ lập trình Python với sự hỗ trợ bởi Google Colaboratory và các thư viện tích hợp sẵn của Python

Biến phụ thuộc trong nghiên cứu này là chỉ số đóng cửa của VNIndex theo thời gian và Log return của chỉ số VN-INDEX. Với mục tiêu cốt lõi nhằm dự đoán các biến số với dữ liệu gốc.

Nghiên cứu này chia biến phụ thuộc làm hai loại chính. Biến thuộc kiểu dữ liệu chuỗi thời gian gồm dữ liệu lịch sử, log return của chỉ số VN-Index và các chỉ báo kỹ thuật. Dữ liệu được dùng trong nghiên cứu được tác giả thu thập trên nền tảng dữ liệu tài chính toàn diện và chuyên sâu FiinPro, được phát triển bởi FiinGroup để phục vụ các tổ chức tài chính, công ty chứng khoán, quỹ đầu tư, ngân hàng và nhà đầu tư chuyên nghiệp tại Việt Nam. Việc xử lý và làm sạch dữ liệu được tác giả thực hiện trên phần mềm Excel và trên môi trường lập trình Python nhằm đảm bảo chất lượng đầu vào cho huấn luyện các mô hình học máy. Đồng thời dữ liệu được phân chia thành tập huấn luyện và kiểm tra theo tỉ lệ hợp lý nhằm xây dựng và đánh giá mô hình một cách dễ dàng.

Các mô hình học máy của khóa luận được thực hiện trên nền tảng Google Colaboratory bằng ngôn ngữ lập trình Python gồm hai mô hình học sâu (LSTM, GRU) dùng để phân tích dữ liệu dạng chuỗi thời gian phi tuyến.

Việc đánh giá các mô hình được dựa trên kết quả so sánh các thước đo: RMSE, MAPE và R^2 . Nghiên cứu sẽ đưa ra kết luận về phương pháp lọc nhiễu có

thay đổi hiệu suất mô hình hay không và mô hình nào là mô hình học máy tối ưu nhất trong điều kiện nghiên cứu.

1.6 Ý nghĩa nghiên cứu

1.6.1 Về mặt khoa học

Cung cấp bằng chứng thực nghiệm cho lý thuyết về mô hình lai (Hybrid Model): Nghiên cứu góp phần kiểm chứng và làm phong phú thêm cơ sở lý thuyết về việc kết hợp các phương pháp xử lý tín hiệu (Wavelet) với các mô hình học sâu để giải quyết bài toán dự báo chuỗi thời gian tài chính, một lĩnh vực đầy thách thức do tính phi tuyến và nhiễu cao.

Đóng góp vào tài liệu nghiên cứu cho thị trường Việt Nam: Trong khi các nghiên cứu về dự báo chỉ số trên thế giới đã rất phổ biến, thì tại thị trường non trẻ và có nhiều biến động như Việt Nam, các nghiên cứu hệ thống như thế này vẫn còn hạn chế. Khóa luận sẽ là một nguồn tài liệu tham khảo có giá trị cho các nghiên cứu sinh, sinh viên và nhà nghiên cứu quan tâm đến lĩnh vực Tài chính định lượng (Quantitative Finance) và Trí tuệ nhân tạo ứng dụng tại Việt Nam.

So sánh đa mô hình một cách hệ thống: Nghiên cứu không chỉ dừng lại ở việc đề xuất một mô hình mới mà còn thực hiện một cuộc đối chiếu toàn diện giữa các trường phái mô hình khác nhau (như GRU, LSTM và mô hình lai), từ đó cung cấp một cái nhìn tổng quan và khách quan về hiệu quả của từng phương pháp.

1.6.2 Về mặt thực tiễn

Hỗ trợ ra quyết định cho nhà đầu tư: Kết quả dự báo chính xác từ mô hình có thể trở thành một công cụ tham khảo quan trọng cho các nhà đầu tư cá nhân và tổ chức trong việc xác định điểm mua, điểm bán, từ đó tối đa hóa lợi nhuận và quản lý rủi ro một cách chủ động hơn.

Gợi ý một công cụ phân tích cho các công ty chứng khoán và quỹ đầu tư: Các công ty tài chính có thể kế thừa phương pháp và kết quả của nghiên cứu để phát triển

các hệ thống dự báo nội bộ, phục vụ cho công tác phân tích, tư vấn và xây dựng chiến lược đầu tư cho khách hàng.

Cung cấp một quy trình nghiên cứu khả thi: Toàn bộ quy trình từ thu thập dữ liệu, tiền xử lý, xây dựng mô hình đến đánh giá được trình bày trong khóa luận có thể trở thành một khuôn mẫu (template) để giải quyết các bài toán dự báo tương tự cho các tài sản tài chính khác (cổ phiếu riêng lẻ, chỉ số ngành, tiền điện tử...) trên thị trường Việt Nam.

Góp phần nâng cao hiệu quả thị trường: Về dài hạn, việc ứng dụng các mô hình dự báo tiên tiến có thể góp phần giúp thị trường vận hành hiệu quả hơn thông qua việc cung cấp các dự báo sát với giá trị thực, giảm thiểu các phản ứng thái quá do cảm tính.

1.7 Bố cục nghiên cứu

Khóa luận được phân thành năm chương bao gồm

Chương 1: Giới thiệu đề tài

Chương 2: Cơ sở lý thuyết

Chương 3: Dữ liệu và phương pháp nghiên cứu

Chương 4: Kết quả và phân tích

Chương 5: kết luận và khuyến nghị

KẾT LUẬN CHƯƠNG 1

Chương 1 đã cho người đọc thấy cái nhìn tổng quát về đối tượng nghiên cứu, các biến, phương pháp và nội dung nghiên cứu. Nguồn dữ liệu đầu vào được lấy từ nguồn nào cũng đã được đề cập rõ. Ý nghĩa của nghiên cứu cũng đã cho ta thấy được đóng góp của nghiên cứu về mặt khoa học và cả mặt thực tiễn là có giá trị. Đặc biệt ở chương này đã đặt ra câu hỏi nghiên cứu, định hướng cho cả nghiên cứu. Mục tiêu của cả khóa luận sẽ được làm sáng tỏ nếu giải quyết được các vấn đề đặt ra trong chương một, Quan trọng nhất là trả lời các câu hỏi nghiên cứu. Đồng thời cũng cho thấy những triển vọng về việc ứng dụng lọc nhiễu xử lý dữ liệu và các mô hình học máy trong việc dự đoán biến động thị trường.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

2.1 Tổng quan về thị trường chứng khoán Việt Nam

Khởi đầu cho sự xuất hiện của thị trường chứng khoán Việt Nam là vào ngày 28/11/1996, theo Nghị định số 75/CP của Chính phủ quyết định thành lập Ủy ban Chứng khoán Nhà nước Việt Nam. Tới ngày 11/7/1998 tức 2 năm sau khi quyết định thành lập Ủy ban Chứng khoán, Nhà nước đã thông qua Nghị định số 48/CP của Chính Phủ cái tên thị trường chứng khoán việt nam chính thức ra đời. Song với đó là quyết định thành lập trung tâm giao dịch chứng khoán với cơ sở đặt tại Thành phố hồ chí minh và Thành phố Hà nội. Trung tâm Giao dịch Chứng khoán TP.HCM được phép chính thức đưa vào hoạt động vào ngày 28/7/2000, với hai mã cổ phiếu REE và SAM được xem là bước chân đầu tiên cho sự phát triển của thị trường chứng khoán sau này.

Theo định nghĩa, thị trường chứng khoán là nơi bán và mua các loại hàng hóa đặc thù có thể đại diện, được thỏa thuận hay thay thế một giá trị của tài sản tài chính hay nói cách khác là các chứng chỉ có tính thanh khoản gồm: chứng chỉ quỹ, trái phiếu, cổ phiếu,...(được gọi là chứng khoán)

Dựa vào cách phát hành và mua bán các loại cổ phiếu chứng khoán mà thị trường được chia làm hai loại. Thứ nhất là thị trường sơ cấp – là nơi đầu tiên phát hành các cổ phiếu đối với các công ty để thu hút vốn đầu tư, huy động vốn. đối tượng của việc phát hành cổ phiếu này thường là các tổ chức hay quỹ đầu tư – là những nguồn đầu tư lớn. Thứ hai, thị trường thứ cấp là nơi chứng khoán được mua đi bán lại trên thị trường tự do, bất kì ai cũng có thể tham gia thị trường.

Để đánh xu hướng, mức độ hoạt động của một số chứng khoán, người ta đặt ra một thước đo đánh giá, phản ánh các biến động theo các tiêu chí nhất định đặc thù về ngành nghề, vốn hóa,...Đó được gọi là chỉ số chứng khoán, còn đối với thị trường việc đánh giá được dựa trên các chỉ số chứng khoán thị trường đại diện là chỉ số VN-Index được niêm yết trên sàn HOSE.

2.2 Cơ sở lý thuyết

2.2.1 Khái niệm về dự báo chứng khoán

Dự báo chứng khoán thường được định nghĩa như là một quá trình đánh giá xác định giá trị tương lai tiềm năng của các chứng khoán, chỉ số chứng khoán gồm các loại cổ phiếu trái phiếu, các chỉ số thị trường hoặc các chỉ số tài chính liên quan. Việc dự báo chứng khoán được thực hiện nhằm một mục tiêu cốt lõi là mang lại lợi nhuận tối đa cho nhà đầu tư thông qua việc nhận diện sớm các xu hướng tăng giảm giá hoặc ước lượng biên độ biến động rủi ro. Dưới góc nhìn học thuật và nghiên cứu định lượng nói riêng, các bài toán dự báo này thường được mô hình hóa dưới dạng phân tích chuỗi thời gian, trong đó các dữ liệu lịch sử như giá đóng cửa, giá mở cửa, khối lượng giao dịch hay tỷ suất sinh lợi được sử dụng làm đầu vào để tiên đoán các giá trị tương lai tại các thời điểm khác nhau.

Về mặt bản chất, dự báo chứng khoán được xem là một trong những bài toán thách thức nhất trong lĩnh vực tài chính. Nguyên nhân xuất phát từ đặc tính "phi tuyến tính" và "hỗn loạn" của dữ liệu tài chính. Theo Giả thuyết Thị trường Hiệu quả (Efficient Market Hypothesis - EMH) của (Fama, 1970), giá chứng khoán luôn phản ánh đầy đủ mọi thông tin sẵn có, do đó sự biến động giá mang tính ngẫu nhiên và không thể dự báo chính xác nếu chỉ dựa vào quá khứ. Tuy nhiên, nhiều nghiên cứu thực nghiệm sau này đã chỉ ra rằng thị trường không hoàn toàn hiệu quả, và giá chứng khoán vẫn tồn tại các quy luật tiềm ẩn hoặc các mẫu hình lặp lại do tâm lý hành vi của nhà đầu tư. Đây chính là "khe hở" để các phương pháp dự báo khai thác.

Có hai trường phái chính trong dự báo chứng khoán được phân chia dựa trên cơ sở đánh giá các phương pháp phân tích đánh giá. Trường phái thứ nhất là phân tích cơ bản, ở trường phái này nhà đầu tư sẽ dự báo giá cổ phiếu dựa vào sức khỏe nội tại của doanh nghiệp (báo cáo tài chính, doanh thu, lợi nhuận) và các yếu tố vĩ mô. Thông qua các đánh giá phân tích trên các chỉ số quan trọng đó, nhà đầu tư sẽ đưa ra các nhận định và quyết định đầu tư.

Kể đến là phân tích kỹ thuật, nhà đầu tư theo trường phái này tin rằng tất cả thông tin của cổ phiếu đã tồn tại bên trong biến động giá và khối lượng giao dịch trong quá khứ. Trường phái này sẽ phân tích và đánh giá dựa trên những thông tin đó mà đưa ra nhận định về giá cổ phiếu tương lai và việc có ra quyết định đầu tư hay không. Đây là cơ sở cho các mô hình học máy (Machine Learning) và học sâu (Deep Learning).

2.2.2 Lý thuyết bước đi ngẫu nhiên (Random Walk Theory)

Lý thuyết bước đi ngẫu nhiên (Random Walk Theory) theo (Van Horne & Parker, 1967) cho rằng biến động giá tài sản tài chính diễn ra theo một chuỗi các bước thay đổi ngẫu nhiên theo thời gian, trong đó mỗi biến động mới gần như độc lập với các biến động trong quá khứ. Theo quan điểm này, giá thị trường đã phản ánh toàn bộ thông tin sẵn có, do đó các thay đổi về giá xuất hiện từ những thông tin mới vốn mang tính ngẫu nhiên và không thể dự đoán trước. Điều này hàm ý rằng không tồn tại mô hình dự báo nào có thể liên tục tạo ra lợi thế vượt trội so với chiến lược mua và nắm giữ trong thị trường hiệu quả.

Lý thuyết bước đi ngẫu nhiên có vai trò quan trọng trong tài chính hiện đại, đặc biệt trong việc đánh giá tính hiệu quả của thị trường và khả năng ứng dụng của các mô hình dự báo. Nếu thị trường thực sự tuân theo mô hình bước đi ngẫu nhiên, các phương pháp học máy và mô hình chuỗi thời gian phi tuyến sẽ khó đạt được độ chính xác vượt trội một cách bền vững, trừ khi chuỗi dữ liệu tồn tại các đặc tính như xu hướng, chu kỳ, độ nhớ hoặc phi tuyến.

2.2.3 Giả thuyết Thị trường Hiệu quả (Efficient Market Hypothesis - EMH)

Được chính thức công bố vào năm 1970, giả thuyết Thị Trường Hiệu Quả của (Fama, 1970) đã trở thành một hiện tượng lúc bấy giờ và đặt nền móng cho nền kinh tế thị trường hiện đại. Cốt lõi của giả thuyết này khẳng định rằng giá cả của chứng khoán trên thị trường luôn phản ánh đầy đủ và tức thời mọi thông tin sẵn có. Điều này đồng nghĩa với việc không một nhà đầu tư nào có thể liên tục đạt được mức lợi nhuận

vượt trội so với thị trường thông qua việc phân tích thông tin, vì mọi thông tin mới đều đã được hấp thụ vào giá ngay lập tức. Trên quan điểm của giả thuyết của EMH, các biến động trên thị trường được xem là các bước đi ngẫu nhiên khiến cho việc dự đoán giá tương lai trên dữ liệu quá khứ là điều không tưởng.

Dựa vào tác động của thông tin thị trường đến giá cổ phiếu giả thuyết thị trường hiệu quả chia thị trường hiệu quả thành ba cấp độ sau

Thị trường hiệu quả dạng yếu: nhận định giá hiện tại đã phản ánh toàn bộ dữ liệu giá và khối lượng trong quá khứ. Nếu thị trường đạt hiệu quả dạng yếu, Phân tích kỹ thuật bao gồm cả các mô hình dự báo chuỗi thời gian sẽ trở nên khó chứng thực.

Hiệu quả dạng bán mạnh: Giá phản ánh tất cả thông tin công khai (báo cáo tài chính, tin tức vĩ mô). Lúc này, cả Phân tích cơ bản cũng không mang lại lợi thế.

Hiệu quả dạng mạnh: Giá phản ánh tất cả thông tin, bao gồm cả thông tin nội bộ (insider information).

Theo một số nghiên cứu thực nghiệm đã cho thấy thị trường hiệu quả dạng mạnh là không khả thi trong thực tế, bởi thị trường không có khả năng hoạt động một cách hoàn thiện như vậy. Song kết quả của các thực nghiệm cũng chỉ ra rằng thị trường dạng bán mạnh và dạng yếu là có thể xảy ra trong thực tế.

Sự xuất hiện của các mô hình học máy hiện đại đã một phần phản bác giả thuyết EMH. Việc áp dụng các mô hình học sâu như LSTM hay GRU để dự báo giá dựa trên dữ liệu lịch sử chính là một nỗ lực nhằm mang lại một cái nhìn mới về giả thuyết thị trường hiệu quả ở dạng yếu.

2.2.4 Lý thuyết Tài chính hành vi (Behavioral Finance)

Tài chính hành vi là lĩnh vực nghiên cứu kết hợp giữa kinh tế học, tâm lý học và tài chính nhằm giải thích cách các yếu tố tâm lý và hành vi ảnh hưởng đến quyết định của nhà đầu tư cũng như sự vận động của thị trường. Khác với giả định “nhà đầu tư lý trí” trong lý thuyết tài chính truyền thống, tài chính hành vi cho rằng con người thường

đưa ra quyết định dựa trên cảm xúc, niềm tin chủ quan và các thiên kiến nhận thức, dẫn đến những sai lệch mang tính hệ thống trong hành vi đầu tư.

Các nghiên cứu nền tảng trong tài chính hành vi, đặc biệt là của (Kahneman & Tversky, 1979), chỉ ra rằng con người thường không hành động theo mô hình tối ưu hóa kỳ vọng, mà bị chi phối bởi những hiện tượng như ác cảm thua lỗ (loss aversion), quá tự tin (overconfidence), tâm lý bầy đàn (herding behavior), và xu hướng phản ứng thái quá hoặc kém nhạy với thông tin mới (overreaction/underreaction). Những thiên kiến này có thể khiến giá tài sản lệch khỏi giá trị hợp lý trong ngắn hạn, dẫn đến các hiện tượng như bong bóng giá, hoảng loạn bán tháo hoặc biến động thị trường phi lý.

Một số thiên kiến tâm lý phổ biến nhất của tài chính hành vi nêu rằng thị trường tồn tại các bất thường là hệ quả của các loại thiên kiến tâm lý này. Với tâm lý bầy đàn,): Nhà đầu tư có xu hướng mua/bán theo đám đông, tạo ra các đợt tăng giá nóng hoặc bán tháo hoảng loạn, làm giá chệch khỏi giá trị thực. Đối với ám ảnh mất mát Nỗi đau khi mất tiền lớn hơn niềm vui khi kiếm được tiền, khiến nhà đầu tư giữ cổ phiếu lỗ quá lâu hoặc bán cổ phiếu lãi quá sớm. và sự tự tin thái quá Tin rằng mình có thông tin tốt hơn người khác, dẫn đến giao dịch quá mức.

Sự ra đời của lý thuyết này là một lời phản bác đồng thời cũng bổ sung cho EMH. Tài chính hành vi chỉ ra rằng thị trường không phải lúc nào cũng hiệu quả theo nghĩa truyền thống. Các bất thường thị trường như hiệu ứng tháng Giêng, động lượng hay đảo chiều là minh chứng cho việc hành vi phi lý của nhà đầu tư có thể tạo ra cơ hội dự báo trong ngắn hạn. Do đó, các mô hình dự báo dựa trên học máy và chuỗi thời gian phi tuyến đôi khi có thể khai thác được các quy luật hành vi tiềm ẩn trong dữ liệu.

Vai trò trong dự báo chứng khoán Đối với bài toán dự báo sử dụng Deep Learning, Lý thuyết Tài chính hành vi đóng vai trò là cơ sở lý luận cốt lõi. Chính những hành vi phi lý trí lặp đi lặp lại của con người (tham lam, sợ hãi) đã tạo ra các mẫu hình (patterns) và xu hướng (trends) trong chuỗi dữ liệu giá. Các mô hình như LSTM hay

GRU thực chất đang học cách nhận diện những "dấu vết tâm lý" này của đám đông được lưu lại trong dữ liệu lịch sử để đưa ra dự báo cho tương lai.

2.2.5 Lý thuyết về chuỗi thời gian

Chuỗi thời gian được định nghĩa là một tập hợp các quan sát của một biến số ngẫu nhiên được sắp xếp theo trình tự thời gian cụ thể, thường là các khoảng cách đều nhau (hàng ngày, hàng giờ, hàng phút). Trong lĩnh vực tài chính, chuỗi thời gian điển hình là giá đóng cửa của cổ phiếu, chỉ số thị trường, tỷ giá hối đoái hoặc lãi suất. Khác với các dữ liệu chéo, đặc trưng cốt lõi của chuỗi thời gian là sự phụ thuộc lẫn nhau giữa các quan sát: giá trị của ngày hôm nay thường có mối tương quan chặt chẽ với giá trị của các ngày hôm trước.

Bên cạnh đó, dữ liệu tài chính thường thể hiện tự tương quan trong phương sai có điều kiện, hay còn gọi là hiện tượng “phân cụm biến động” (volatility clustering). Điều này có nghĩa là các giai đoạn biến động mạnh hoặc yếu có xu hướng xuất hiện liên tiếp. (Engle, 1982) và (Bollerslev, 1986) đã mô tả hiện tượng này qua mô hình ARCH/GARCH, trở thành nền tảng của nhiều nghiên cứu về biến động tài chính.

Một đặc điểm quan trọng khác của chuỗi thời gian tài chính là phân phối không chuẩn, thường có đuôi dày (fat tails) và độ nhọn cao (leptokurtosis). Điều này cho thấy xác suất xuất hiện các cú sốc lớn cao hơn so với phân phối chuẩn, làm tăng độ khó khi dự báo bằng mô hình tuyến tính (Campbell, et al., 1997).

Ngoài tính phi tuyến và nhiễu cao, dữ liệu tài chính còn mang cấu trúc đa thang đo (multi-scale characteristics), nghĩa là các mô hình dao động cùng tồn tại ở nhiều khoảng thời gian khác nhau. Các phương pháp xử lý tín hiệu như Wavelet Transform được sử dụng nhằm tách dữ liệu thành các thành phần đặc trưng để cải thiện khả năng học của các mô hình dự báo phi tuyến.

Hơn nữa, chuỗi tài chính chịu ảnh hưởng mạnh từ các cú sốc ngoại sinh như công bố chính sách, biến động vĩ mô và tâm lý thị trường. Những cú sốc này có thể gây ra đứt gãy cấu trúc (structural breaks), khiến tham số mô hình thay đổi theo thời gian. Các mô hình học sâu như LSTM và GRU được đánh giá cao vì khả năng học quan hệ phi

tuyến dài hạn và thích ứng tốt hơn với dữ liệu nhiễu, phức tạp so với các mô hình tuyến tính truyền thống.

Tóm lại, bản chất đặc thù của chuỗi thời gian tài chính – bao gồm tính không dừng, phân cụm biến động, phi tuyến, phân phối có đuôi dày và tác động từ các cú sốc ngoại sinh – đòi hỏi việc lựa chọn mô hình dự báo phải thận trọng. Việc hiểu rõ các đặc tính này là nền tảng quan trọng khi ứng dụng mô hình học sâu hoặc mô hình thống kê vào dự báo biến động tài chính.

2.2.6 Lý thuyết về kỹ thuật lọc nhiễu và biến đổi wavelet

Trong phân tích chuỗi thời gian tài chính, dữ liệu thường chứa mức độ nhiễu cao do tác động của thông tin ngẫu nhiên, tâm lý thị trường và các yếu tố ngoại sinh khó kiểm soát. Điều này khiến việc mô hình hóa và dự báo trở nên khó khăn, đặc biệt với các mô hình học máy vốn nhạy cảm với nhiễu. Do đó, các kỹ thuật lọc nhiễu đóng vai trò quan trọng nhằm trích xuất tín hiệu hữu ích và cải thiện hiệu suất dự báo.

2.2.6.1 Biến đổi Wavelet

Một trong những phương pháp lọc nhiễu hiệu quả và phổ biến là biến đổi Wavelet (Wavelet Transform – WT). Wavelet là công cụ phân tích tín hiệu đa thang đo (multi-scale), cho phép phân tách chuỗi thời gian thành các thành phần ở những tần số và độ phân giải khác nhau. Khác với biến đổi Fourier truyền thống vốn chỉ thể hiện thông tin tần số, biến đổi Wavelet đồng thời giữ được thông tin theo cả miền tần số và thời gian, nhờ đó phù hợp hơn với các chuỗi tài chính có tính phi tuyến, đột biến và dao động phức tạp (Mallat, 1999).

Biến đổi Wavelet rời rạc (Discrete Wavelet Transform – DWT) là dạng được sử dụng nhiều trong lọc nhiễu. Thông qua quá trình phân rã (decomposition), DWT tách chuỗi thành các hệ số xấp xỉ (approximation coefficients) và hệ số chi tiết (detail coefficients), tương ứng với thành phần tín hiệu thấp tần và cao tần. Vì phần lớn nhiễu xuất hiện ở tần số cao, việc áp dụng kỹ thuật wavelet thresholding – chẳng hạn như ngưỡng mềm (soft thresholding) hoặc ngưỡng cứng (hard thresholding) – giúp loại bỏ

các hệ số chi tiết có biên độ nhỏ, từ đó giảm nhiễu mà không làm mất tín hiệu chính (Donoho & Johnstone, 1994).

Một lợi thế nổi bật của Wavelet là khả năng xử lý các chuỗi thời gian không dừng (non-stationary) và có cấu trúc đa thang đo – hai đặc trưng quan trọng của dữ liệu tài chính. Nhờ đó, nhiều nghiên cứu chứng minh việc kết hợp Wavelet với các mô hình dự báo như LSTM hoặc GRU có thể cải thiện độ chính xác dự báo so với khi sử dụng dữ liệu gốc, đặc biệt trong bối cảnh tín hiệu giá bị nhiễu mạnh (Gençay, et al., 2001).

Tóm lại, kỹ thuật lọc nhiễu dựa trên biến đổi Wavelet là công cụ hữu hiệu để nâng cao chất lượng dữ liệu đầu vào và cải thiện hiệu suất dự báo. Với khả năng phân tích tín hiệu theo cả miền thời gian và tần số, Wavelet đặc biệt thích hợp trong xử lý chuỗi thời gian tài chính vốn chứa nhiều nhiễu và cấu trúc phi tuyến.

2.2.6.2 Một số lưu ý khi dùng biến đổi wavelet

Thứ nhất, việc lựa chọn loại wavelet (wavelet family) đóng vai trò quyết định trong cấu trúc tín hiệu sau khi phân rã. Các wavelet như Daubechies, Symlet, Coiflet hoặc Haar có đặc tính khác nhau về tính trơn, độ đối xứng và khả năng tái tạo tín hiệu (Daubechies, 1992). Lựa chọn không phù hợp có thể khiến tín hiệu bị biến dạng hoặc mất thông tin quan trọng. Do đó, chọn wavelet nên dựa trên đặc tính dữ liệu và mục tiêu nghiên cứu.

Thứ hai, số mức phân rã (decomposition levels) cần được xác định hợp lý. Mức phân rã quá cao có thể gây mất mát thông tin, làm tín hiệu trở nên quá “mượt”, trong khi mức phân rã quá thấp có thể không đủ để tách nhiễu.

Thứ ba, kỹ thuật ngưỡng hóa (thresholding) là yếu tố quan trọng ảnh hưởng đến chất lượng lọc nhiễu. Ngưỡng quá cao làm mất cấu trúc thật của dữ liệu, trong khi ngưỡng quá thấp không loại bỏ được nhiễu hiệu quả. Soft-thresholding thường được khuyến khích hơn so với hard-thresholding vì giữ được tính liên tục của tín hiệu sau khi xử lý (Donoho & Johnstone, 1994).


Cuối cùng, biến đổi wavelet có thể làm thay đổi phân phối xác suất của dữ liệu, đặc biệt khi áp dụng thresholding. Điều này tạo ra rủi ro sai lệch khi dữ liệu đầu vào được dùng trong các mô hình học máy hoặc mô hình thống kê nhạy cảm với phân phối. Do vậy, các nghiên cứu cần đánh giá tác động của quá trình lọc nhiễu lên thống kê mô tả của dữ liệu trước và sau xử lý.

2.3 Tổng quan về học máy

Học máy được định nghĩa là phương pháp cho phép máy tính học từ dữ liệu thông qua việc điều chỉnh các tham số mô hình nhằm tối ưu hóa hiệu suất cho một nhiệm vụ cụ thể. Cốt lõi của học máy nằm ở khả năng khái quát hóa, tức là mô hình có thể đưa ra dự đoán chính xác cho dữ liệu chưa từng gặp trước đó.

Các thuật toán học máy được chia thành ba nhóm chính: học có giám sát (supervised learning), học không giám sát (unsupervised learning) và học tăng cường (reinforcement learning). Trong dự báo tài chính, học có giám sát – bao gồm các mô hình hồi quy, mạng nơ-ron và học sâu – được sử dụng phổ biến nhất vì phù hợp với bài toán dự đoán giá hoặc lợi suất.

Quy trình xây dựng một mô hình học máy thường bao gồm một chuỗi các bước có hệ thống nhằm đảm bảo mô hình được phát triển, kiểm định và triển khai một cách chính xác và hiệu quả. quy trình này có thể được mô tả qua ba giai đoạn chính:



Hình 2. 1 sơ đồ quy trình xây dựng mô hình học máy

Ở giai đoạn đầu, dữ liệu được thu thập, làm sạch, chuẩn hóa và biến đổi nhằm xử lý các vấn đề như thiếu dữ liệu, nhiễu, phân phối không đồng nhất, hoặc đa cộng tuyến. Việc tiền xử lý phù hợp giúp cải thiện đáng kể khả năng học của mô hình (Kuhn & Johnson, 2013) .

Tiếp theo, nhà nghiên cứu lựa chọn thuật toán phù hợp tùy theo bản chất của bài toán (hồi quy, phân loại, dự báo chuỗi thời gian, v.v.) và tiến hành huấn luyện trên tập dữ liệu mẫu.

Sau khi mô hình được huấn luyện, bước đánh giá được thực hiện bằng các chỉ số phù hợp như MSE, RMSE, MAE đối với bài toán dự báo. Ngoài ra, tập dữ liệu được chia thành train-validation-test nhằm đảm bảo mô hình không bị overfitting và có khả năng tổng quát hóa tốt (Goodfellow, et al., 2016). Giám sát hiệu suất, cập nhật mô hình kiểm soát rủi ro do dịch chuyển phân phối dữ liệu.

2.4. Giới thiệu một số mô hình học máy

Do nhu cầu nghiên cứu trên tập dữ liệu chuỗi thời gian phi tuyến, nghiên cứu lựa chọn mô hình học sâu để thực nghiệm do một số lý do sau: Thứ nhất là khả năng mô hình hóa các mối quan hệ phức tạp của dữ liệu phi tuyến. thứ hai, mô hình học sâu (LSTM và GRU) có khả năng xử lý các phụ thuộc dài hạn. thứ ba là khả năng nhận biết các đặc trưng và xu hướng (gradient). Và cuối cùng là khả năng xử lý ưu việt trên các dữ liệu dài ngắn khác nhau.

2.4.1 Mạng bộ nhớ ngắn hạn dài hạn (Long Short-Term Memory - LSTM)

Long Short-Term Memory (LSTM) là một biến thể đặc biệt của mạng nơ-ron hồi quy (Recurrent Neural Network – RNN), được thiết kế nhằm khắc phục vấn đề biến mất và bùng nổ gradient trong quá trình học chuỗi dài (Hochreiter & Schmidhuber, 1997). Khác với RNN truyền thống chỉ lưu giữ thông tin ngắn hạn, LSTM sử dụng cấu trúc bộ nhớ dạng cell-state kết hợp với ba cổng điều khiển – cổng quên (forget gate),

cổng đầu vào (input gate) và cổng đầu ra (output gate) – cho phép mô hình học và duy trì thông tin quan trọng trong thời gian dài.

Cơ chế hoạt động của LSTM giúp mô hình có khả năng xử lý tốt các quan hệ phụ thuộc dài hạn (long-term dependencies), vốn thường xuất hiện trong dữ liệu chuỗi thời gian tài chính. Cổng quên quyết định lượng thông tin từ trạng thái cũ được giữ lại; cổng đầu vào cập nhật thông tin mới; và cổng đầu ra xác định phần thông tin được sử dụng để tạo ra đầu ra của thời điểm hiện tại (Gers, et al., 2000). Nhờ cấu trúc này, LSTM có khả năng mô hình hóa các mô hình biến động phi tuyến, bất ổn và có tính nhớ của thị trường tài chính hiệu quả hơn so với các mô hình truyền thống.

Tuy nhiên, LSTM cũng tồn tại những hạn chế nhất định như chi phí tính toán cao, thời gian huấn luyện dài và yêu cầu dữ liệu lớn để đạt hiệu suất tối ưu. Do đó, trong thực tế, việc triển khai LSTM thường đi kèm với các kỹ thuật tối ưu như chuẩn hóa dữ liệu, chọn kích thước cửa sổ hợp lý, regularization hoặc kết hợp với các công cụ xử lý tín hiệu như Wavelet để nâng cao chất lượng đầu vào.

2.4.2 Mạng nơ-ron hồi quy có cổng (Gated Recurrent Unit - GRU)

Gated Recurrent Unit (GRU) là một biến thể cải tiến của mạng nơ-ron hồi quy (Recurrent Neural Network – RNN), được đề xuất bởi (Cho, et al., 2014) nhằm đơn giản hóa cấu trúc của LSTM đồng thời vẫn duy trì khả năng học các quan hệ phụ thuộc dài hạn trong dữ liệu chuỗi thời gian. GRU kết hợp bộ nhớ trạng thái và cơ chế cổng điều khiển trong một cấu trúc gọn nhẹ hơn, giúp giảm số lượng tham số và rút ngắn thời gian huấn luyện so với LSTM (Chung, et al., 2014)

Trong lĩnh vực tài chính, GRU được ứng dụng rộng rãi để dự báo chuỗi thời gian như giá cổ phiếu, tỷ giá hay biến động thị trường vì khả năng mô hình hóa các quan hệ phi tuyến và sự phụ thuộc dài hạn trong dữ liệu. Một số nghiên cứu đã cho thấy GRU có hiệu suất tốt hơn LSTM trong các bài toán dữ liệu nhiễu cao hoặc kích thước tập dữ liệu nhỏ – vốn là đặc trưng phổ biến trong dự báo tài chính (Zhang, et al., 2017).

Bên cạnh các ưu điểm về hiệu suất và tốc độ, GRU còn có khả năng giảm nguy cơ overfitting nhờ kiến trúc đơn giản hơn, giúp mô hình ổn định hơn khi dữ liệu không đủ lớn. Tuy vậy, việc lựa chọn giữa LSTM và GRU vẫn phụ thuộc vào bản chất dữ liệu và mục tiêu nghiên cứu: LSTM thường mạnh hơn khi cần học phụ thuộc rất dài hạn, trong khi GRU phù hợp với các bài toán đòi hỏi tốc độ và mô hình nhỏ gọn.

2.4.3 Mô hình kết hợp (Hybrid Model)

Mô hình kết hợp (Hybrid Model) là cách tiếp cận tích hợp nhiều phương pháp hoặc thuật toán khác nhau nhằm khai thác ưu điểm của từng mô hình và cải thiện hiệu suất dự báo. Trong lĩnh vực phân tích chuỗi thời gian tài chính – nơi dữ liệu có tính phi tuyến, nhiễu cao và biến động khó lường – mô hình kết hợp ngày càng được xem là giải pháp hiệu quả để nâng cao chất lượng mô hình hóa (Zhang, 2003) .

Các mô hình kết hợp thường dựa trên nguyên tắc phân tách thành phần dữ liệu hoặc tích hợp đa mức. Một hướng phổ biến là tách chuỗi thời gian thành các thành phần tuyến tính và phi tuyến, sau đó áp dụng mô hình thống kê cho phần tuyến tính và mô hình học máy cho phần phi tuyến. Cách tiếp cận này, được gọi là mô hình kết hợp, được chứng minh giúp cải thiện độ chính xác dự báo khi chuỗi thời gian chứa cả quan hệ tuyến tính và phi tuyến

Một hướng khác là sử dụng kỹ thuật xử lý tín hiệu, chẳng hạn như Wavelet Transform, để phân rã chuỗi thời gian thành các thang tần số khác nhau trước khi đưa vào mô hình học sâu. Phương pháp WT-LSTM hoặc WT-GRU giúp giảm nhiễu, giữ lại các đặc trưng quan trọng và tăng khả năng học của mô hình, đặc biệt trong dữ liệu tài chính vốn chứa nhiều nhiễu và biến động cục bộ (Khadem, et al., 2020)

Nhìn chung, mô hình kết hợp đã chứng minh hiệu quả vượt trội trong dự báo tài chính nhờ khả năng xử lý dữ liệu phức tạp hơn so với mô hình đơn lẻ. Tuy nhiên, chúng cũng yêu cầu chi phí tính toán cao hơn, quá trình xây dựng phức tạp và cần lựa chọn cẩn thận các thành phần kết hợp để tránh rủi ro overfitting.

2.5 Tổng quan về vấn đề và các nghiên cứu liên quan

Tác giả (năm công bố)	Mục tiêu nghiên cứu	Dữ liệu nghiên cứu	Kết quả nghiên cứu
(Liang, et al., 2019)	Cải thiện độ chính xác dự đoán giá cổ phiếu bằng cách kết hợp LSTM với phương pháp tiền xử lý dữ liệu bằng biến đổi wavelet	Dữ liệu giá mở cửa của chỉ số S&P 500 trong gần 18 năm	Mô hình kết hợp cải thiện rõ rệt độ chính xác dự đoán; LSTM 2 tầng cho kết quả tốt nhất; MOCWT vượt trội so với wavelet truyền thống và cải tiến'
(Wu, et al., 2022)	Đề xuất khung lai DAELM (DWT–AE–ELM) để cải thiện độ chính xác dự đoán xu hướng thị trường chứng khoán, bằng cách kết hợp giảm nhiễu, trích xuất đặc trưng và học máy hiệu quả.	Dữ liệu 400 cổ phiếu từ thị trường chứng khoán Trung Quốc (Thượng Hải và Thâm Quyển), giai đoạn 2001–2020. Dữ liệu gồm giá mở cửa, đóng cửa, cao nhất, thấp nhất, khối lượng và giá trị giao dịch.	Mô hình DAELM đạt độ chính xác cao hơn các nghiên cứu trước đó. Sai số giảm đáng kể, chiến lược đầu tư dựa trên dự đoán của mô hình cho lợi suất đến hạn (YTM) vượt trội so với chiến lược mua và giữ .

(Li & Tam, 2017)	Kết hợp phương pháp khử nhiễu sóng con theo thời gian thực (Wavelet Denoising) với mạng LSTM để cải thiện độ chính xác dự đoán chỉ số chứng khoán.	Dữ liệu chỉ số chứng khoán (Shanghai Composite Index, Shenzhen Component Index) với chuỗi thời gian giá cổ phiếu.	Mô hình WTD–LSTM cho kết quả dự đoán chính xác hơn so với các mô hình truyền thống. Sai số giảm đáng kể, mô hình thể hiện khả năng dự báo ổn định và hiệu quả trong môi trường dữ liệu nhiễu.
(Jarrah, 2024)	Phát triển mô hình lai kết hợp LSTM, DWT và ARIMA để dự đoán giá cổ phiếu trên thị trường chứng khoán Saudi Arabia (Tadawul).	Dữ liệu giá đóng cửa của 4 công ty niêm yết trên Tadawul (Saudi Arabian Mining Co., Yanbu Cement Co., Sabic, Saudi Indian) và TSLA làm benchmark. Giai đoạn từ 01/01/2019 đến 23/07/2023, tổng cộng 1132 ngày.	Mô hình LSTM–DWT–ARIMA đạt độ chính xác cao (97.54%) so với ARIMA truyền thống (96.29%). Sai số MAE, RMSE, MAPE đều thấp hơn. Kết quả cho thấy mô hình lai có khả năng dự báo ổn định, tổng quát tốt và hữu ích cho nhà đầu tư.
(Ziółkowski & Wiczyński, 2025)	So sánh khả năng dự báo của mô hình LSTM kết hợp DWT với ARIMA trong dự báo chỉ số chứng khoán. Nhấn mạnh vai trò của hệ số wavelet như biến giải thích để cải thiện độ chính xác.	Dữ liệu từ 3 chỉ số: WIG, WIG20 (Ba Lan) và S&P 500 (Mỹ). Giai đoạn 15 năm từ 01/07/2009 đến 30/06/2024, tổng cộng ~3750 quan sát ngày.	Mô hình LSTM kết hợp DWT cho sai số thấp hơn đáng kể so với LSTM thuần và ARIMA. Các hệ số wavelet giúp giảm lỗi ngoài mẫu, đặc biệt với wavelet Haar/db1 và số mức MRA thấp (1–3). Kết quả cho thấy LSTM–DWT vượt trội hơn ARIMA khoảng 12 lần về hiệu năng dự báo.

(Jothimani, et al., 2016)	Đề xuất mô hình lai kết hợp MODWT với ANN và SVR để dự đoán chỉ số chứng khoán NIFTY 50, nhằm cải thiện độ chính xác so với các mô hình truyền thống.	Dữ liệu chỉ số NIFTY 50 (Ấn Độ), giai đoạn 2007–2015, gồm 409 điểm dữ liệu tuần. Dữ liệu bao phủ cả khủng hoảng tài chính 2008.	Mô hình lai MODWT–SVR đạt RMSE thấp nhất (50.08) và độ chính xác hướng (DA) cao nhất (80%). Kết quả cho thấy mô hình lai vượt trội hơn ANN và SVR thuần. Chiến lược giao dịch dựa trên dự đoán của MODWT–SVR cho ROI cao hơn chiến lược mua và giữ (Buy-and-Hold).
(Qiu, et al., 2020)	Xây dựng mô hình dự đoán giá cổ phiếu bằng cách kết hợp LSTM với cơ chế Attention và tiền xử lý dữ liệu bằng biến đổi wavelet	Chỉ số S&P 500, DJIA (2000–2019); Chỉ số HSI (2002–2019);	"Mô hình LSTM + Attention + wavelet trên S&P 500 và DJIA; Hiệu quả vượt trội so với các mô hình so sánh; Trên HSI, hiệu suất thấp hơn do đặc điểm dữ liệu"
(Alrumaih & Al-Fawzan, 2002)	Khảo sát hiệu quả của biến đổi wavelet trong việc làm sạch dữ liệu (denoising) và cải thiện độ chính xác dự báo chuỗi thời gian của chỉ số chứng khoán Saudi	Chỉ số chứng khoán Saudi (SSI) 1705 điểm dữ liệu từ 26/01/1994 đến 04/11/1999	Lọc nhiễu bằng wavelet giúp giảm sai số dự báo rõ rệt. lọc nhiễu không cải thiện nhiều với các mô hình đơn giản như LR, SMA, ES
(Li, et al., 2025)	So sánh hiệu suất dự báo chuỗi thời gian tài chính	Dữ liệu giá đóng cửa của chỉ số CSI300	-CEEMDAN–Informer–LSTM vượt trội cho kết quả ổn định, phù hợp với chiến lược giao dịch định lượng

(Tang, et al., 2021)	So sánh các mô hình lai của LSTM	Các chỉ số Dow jones, S&P500, Nasdaq Composite	- Mô hình lai cải thiện độ chính xác. WT-LSTM cho kết quả tốt nhất trong dự báo ngắn hạn và trung hạn
(Wang & Vo, 2025)	Đề xuất mô hình ARIMAX kết hợp với kỹ thuật chọn lọc đặc trưng bằng XGBoost để dự báo giá cổ phiếu tại thị trường Việt Nam	- VN-Index từ 2013–2023 và 87 chỉ báo kỹ thuật, chọn	- ARIMAX + 5 vượt trội hơn các mô hình khác GALSTM đứng thứ hai, Prophet thứ ba, LSTM thứ tư, XGBoost thấp nhất
(Oanh & Châu, 2024)	Đánh giá hiệu quả của các mô hình học máy (TCN và LSTM) trong dự báo biến động chỉ số ,VN-Index	- Giá đóng cửa hàng ngày của VN-Index từ 2001–2023	- LSTM có sai số thấp hơn TCN. TCN có tốc độ huấn luyện nhanh hơn nhưng độ chính xác thấp hơn Kết quả trái ngược với một số nghiên cứu quốc tế, cho thấy đặc thù thị trường Việt Nam
(Tuyen, 2024)	Kiểm định hiệu suất mô hình phức hợp LSTM–GRU trong dự báo chỉ số đo lường xu hướng biến động giá cổ phiếu trên sàn HOSE, nhằm cung cấp công cụ hỗ trợ ra quyết định đầu tư	Chỉ số VN-Index từ 14/7/2008 đến 14/07/2023	- Mô hình cải tiến LSTM–GRU vượt trội hơn TCN về độ chính xác Kết quả trái ngược với một số nghiên cứu quốc tế, cho thấy đặc thù thị trường Việt Nam Mô hình học sâu có khả năng học đặc trưng phi tuyến và biến động ngắn hạn tốt hơn

(Uyen & Huyen., 2014)	Ứng dụng mô hình ARIMA để dự báo chỉ số VN-Index, nhằm kiểm định khả năng của mô hình thống kê tuyến tính trong môi trường thị trường mới nổi như Việt Nam	- Dữ liệu giá đóng cửa chỉ số VN-Index Thời gian: 2005–2013 Nguồn: Sở Giao dịch Chứng khoán TP.HCM (HOSE)	- Mô hình ARIMA(1,1,1) cho kết quả dự báo tốt nhất trong giai đoạn nghiên cứu Sai số dự báo thấp, phù hợp với chuỗi có tính tuyến tính và ổn định. ARIMA phù hợp với dữ liệu tài chính ngắn hạn và ít biến động
(Tu & Bahagawan, 2023)	So sánh hiệu suất dự báo: SVM, XGBoost và LSTM, nhằm xác định mô hình phù hợp nhất với dữ liệu tài chính nội địa	- Dữ liệu VN-Index, HNX-Index, UPCoM Dữ liệu lịch sử từ 2015–2022 Các biến: giá mở cửa, đóng cửa, khối lượng, chỉ báo kỹ thuật	LSTM thể hiện tốt nhất so với hai mô hình còn lại
(Dương, 2023)	Ứng dụng thuật toán tăng cường (boosting) để dự báo chiều biến động (tăng/giảm) của chỉ số ,VN-Index, nhằm hỗ trợ nhà đầu tư ra quyết định giao dịch ngắn hạn	- Dữ liệu VN-Index từ 2015–2022 Biến đầu vào: giá mở cửa, đóng cửa, khối lượng, chỉ báo kỹ thuật	- XGBoost phù hợp với dự báo ngắn hạn và dữ liệu kỹ thuật Tăng cường khả năng phân loại chiều biến động trong môi trường biến động

Bảng 2. 1 Lược khảo các nghiên cứu trước

2.5.1 Các nghiên cứu ngoài nước

Có thể thấy rằng các nghiên cứu quốc tế đã ứng dụng các mô hình học sâu như LSTM và cả GRU trong việc dự đoán chuỗi thời gian, không những vậy họ còn nghiên cứu cách cải thiện kết quả mô hình bằng các phương pháp khác nhau để cải thiện kết quả của mô hình.

Theo (Li & Tam, 2017) thực hiện nghiên cứu trên dữ liệu các chỉ số chứng khoán bằng cách kết hợp lọc nhiễu theo thời gian thực với LSTM nhằm cải thiện dự đoán với kết quả kết hợp lọc nhiễu tốt hơn các mô hình truyền thống. Như nghiên cứu của (Liang, et al., 2019) thực hiện kết hợp mô hình học sâu LSTM với lọc nhiễu WT nhằm gia tăng hiệu suất của mô hình. Nghiên cứu được thực hiện trên Dữ liệu giá mở cửa của chỉ số S&P 500 trong gần 18 năm, đã cho ra kết quả rất khả quan rằng việc lọc nhiễu cải thiện đáng kể mô hình.

Nghiên cứu của (Tang, et al., 2021) thực nghiệm nghiên cứu trên Dữ liệu giá đóng cửa chỉ số Dow Jones Industrial Average (DJIA) 19,666 điểm dữ liệu, nhằm đề xuất mô hình kết hợp cho việc dự đoán chứng khoán. Kết quả cho thấy WT-LSTM cho kết quả tốt nhất trong dự báo ngắn hạn và trung hạn WT-LSTM giảm RMSE tới 79.55% so với LSTM gốc. Cả hai mô hình lai đều cải thiện đáng kể độ chính xác và độ ổn định so với LSTM gốc và LSTM-dropout. (Ziółkowski & Wieceński, 2025) cũng thực nghiệm nghiên cứu với mục đích cải thiện mô hình bằng cách kết hợp LSTM và DWT, nghiên cứu chỉ ra rằng sai số của mô hình kết hợp thấp hơn hẳn so với LSTM gốc và ARIMA

Nhìn chung việc kết hợp lọc nhiễu (WT) đều mang đến cải thiện đối với mô hình học sâu đặc biệt là dạng hồi quy dạng công như LSTM. Khóa luận sẽ lấy kết quả nghiên cứu của (Ziółkowski & Wieceński, 2025) để làm đường tham chiếu do tính tương đồng và gần với nghiên cứu trong khóa luận này nhất.

2.5.2 Các nghiên cứu trong nước

Ở Việt Nam cũng có rất nhiều nghiên cứu thực nghiệm về dự đoán giá của chuỗi thời gian tài chính. Theo (Uyen & Huyen., 2014) mô hình ARIMA phù hợp với dữ liệu tài chính ngắn hạn ít biến động. nghiên cứu của (Tu & Bahagawan, 2023) trên dữ liệu chỉ số của các sàn giao dịch trong nước cho thấy LSTM mang đến hiệu suất tốt nhất trong các mô hình so sánh. Nghiên cứu của (Oanh & Châu, 2024) cũng đánh giá hiệu suất mô hình thông qua thực nghiệm trên dữ liệu lịch sử của chỉ số VN-Index, kết quả là LSTM có sai số thấp hơn so với mô hình còn lại. Đi gần hơn về mục đích cải thiện kết quả mô hình ta có nghiên cứu của (Tuyen, 2024) cũng mang đến kết quả khả quan,

với mục tiêu xây dựng mô hình nhằm cải thiện đầu tư thực nghiệm trên chỉ số VN-Index trong giai đoạn 14/7/2008 đến 14/7/2023 đã khẳng định mô hình kết hợp GRU-LSTM đem lại kết quả vượt trội hơn mô hình so sánh, đặc biệt trong dữ liệu phi tuyến và các biến động ngắn hạn.

Qua các nghiên cứu liên quan trong nước có thể thấy việc cải thiện mô hình để gia tăng độ tin cậy của kết quả các mô hình học máy. Tuy nhiên để đánh giá tính hiệu quả của các mô hình học máy của các mô hình học sâu hồi quy dạng công vẫn còn bỏ ngỏ, đồng thời các phương pháp, kỹ thuật xử lý dữ liệu vẫn cho thấy nhiều thiếu sót.

2.5.3. Khoảng trống tri thức (Research Gap)

Thứ nhất, thiếu sự đánh giá toàn diện về tác động của lọc nhiễu. Đối với thị trường Việt Nam việc ứng dụng các phương pháp tiền xử lý dữ liệu nói riêng và lọc nhiễu nói chung vẫn còn rất mờ nhạt. Chính vì vậy mà khiến cho việc xử lý tiền dữ liệu để cải thiện mô hình học máy là rất cần thiết. Các nghiên cứu quốc tế đã cho thấy sự hiệu quả của lọc nhiễu trên các chỉ số như S&P 500, Dow Jones,... Việc chứng thực cho kỹ thuật xử lý tiền dữ liệu này cho chỉ số chứng khoán đại diện của Việt Nam- VN-Index là điều cần thiết.

Thứ hai, sự so sánh đối đầu trực tiếp giữa LSTM và GRU dưới điều kiện có và không có xử lý tín hiệu. Nhiều nghiên cứu chỉ tập trung vào một mô hình hoặc so sánh chúng trên dữ liệu thô. Đề tài này sẽ mở rộng phạm vi so sánh bằng cách đặt hai mô hình này vào các kịch bản xử lý dữ liệu khác nhau để tìm ra mô hình tối ưu nhất cho đặc thù thị trường Việt Nam.

Thứ ba, tính đặc thù của thị trường cận biên. Việt Nam là thị trường cận biên với độ biến động cao và tâm lý đám đông mạnh mẽ. Việc kiểm chứng lại các lý thuyết và mô hình trên dữ liệu VN-Index sẽ mang lại những đóng góp thực tiễn có giá trị cho cộng đồng đầu tư trong nước.

KẾT LUẬN CHƯƠNG 2

Chương 2 đã hệ thống hóa toàn bộ cơ sở lý luận nền tảng cho đề tài nghiên cứu.


Trước hết, chương đã trình bày các khái niệm cốt lõi về thị trường chứng khoán, bao gồm Giả thuyết thị trường hiệu quả (EMH) và Lý thuyết tài chính hành vi, làm cơ sở để giải thích tính khả thi của việc dự báo. Tiếp theo, lý thuyết về chuỗi thời gian tài chính, đặc biệt là khái niệm về tính dừng và biến động tụ nhóm, đã được làm rõ để định hướng cho việc xử lý dữ liệu.

Trọng tâm của chương là phần tổng quan về các mô hình học sâu (Deep Learning). Kiến trúc và nguyên lý hoạt động của mạng LSTM và GRU, cùng với cơ sở toán học của kỹ thuật lọc nhiễu Wavelet, đã được giới thiệu như là công cụ chính để giải quyết bài toán.

Cuối cùng, thông qua việc lược khảo các nghiên cứu liên quan, tác giả đã xác định được xu hướng phát triển từ mô hình đơn lẻ sang mô hình kết hợp, đồng thời chỉ ra khoảng trống nghiên cứu về việc đánh giá tác động hai mặt của kỹ thuật lọc nhiễu. Đây chính là tiền đề quan trọng để xây dựng khung phương pháp nghiên cứu chi tiết sẽ được trình bày trong Chương 3 tiếp theo.

CHƯƠNG 3 PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Quy trình thực hiện nghiên cứu



Hình 3. 1 Quy trình thực hiện nghiên cứu

Bước 1: Tổng hợp thông tin thứ cấp:

Tác giả sẽ tìm kiếm và thu thập thông tin trên các nguồn thông tin thứ cấp như báo đài, bách khoa toàn thư, các trang web hay các diễn đàn để tìm ra những thông tin nổi bật, các đề tài hấp dẫn hay là chọn lọc các thông tin theo thiên hướng sở thích.

Bước 2: Lược khảo lý thuyết

Sau khi tổng hợp chọn lọc được từ các thông tin ở bước 1, ta thực hiện việc lược khảo lý thuyết bằng cách đọc các bài nghiên cứu liên quan có thể gồm các nghiên cứu được thực hiện trước đó, các báo cáo hoặc sách xuất bản. Việc tìm kiếm các nghiên cứu liên quan này được thực hiện bằng cách tìm các từ khóa thuộc vấn đề đang nghiên cứu, đối với khóa luận này từ khóa tìm kiếm có thể là “dự đoán”, “chỉ số VN-Index”, “Lọc nhiễu”. mục đích cuối cùng của lược khảo là để tìm ra khoản trống tri thức cần lấp đầy

Bước 3: Xác định vấn đề nghiên cứu

Với các thông tin về các liên cứu ở phần lược khảo ta thực hiện đặt, xác định vấn đề nghiên cứu. các yếu tố có thể cân nhắc để chọn làm vấn đề nghiên cứu gồm tính khả thi về mặt thực tiễn và lý thuyết, tài nguyên nghiên cứu, môi trường và nguồn lực, tính kế thừa,... Riêng khóa luận này vấn đề nghiên cứu là làm sao cải thiện kết quả dự báo của mô hình học máy trong dự đoán kết quả chỉ số chứng khoán việt nam

Bước 4: Thu thập và xử lý dữ liệu sơ bộ

Nghiên cứu này thực hiện trên chỉ số VN-Index, việc thực hiện lấy dữ liệu lịch sử của chỉ số được thực hiện thông qua nền tảng Fiinpro như đã trình bày ở chương 1. Dữ liệu sau khi được lấy còn phải điều chỉnh số lượng điểm dữ liệu (lịch sử giao dịch theo ngày của chỉ số VN-Index từ 1/10/2015-1/10/2025), định dạng cho phù hợp với dữ liệu đầu vào của mô hình, việc này được thực hiện trên cả phần mềm Excel và cả trên Python. Ngoài ra mô hình còn dự đoán cả Log_return của chỉ số VN-Index, log return được tính toán sau khi tải dữ liệu đầu vào trên Python.

Bước 5: Tiền xử lý dữ liệu mô hình

Ở bước này ta thực hiện chuẩn hóa dữ liệu đầu vào sao cho phù hợp với mô hình học máy đang thực hiện (LSTM,GRU).Trước hết ta chia dữ liệu thành hai tập huấn luyện và tập kiểm tra với tỉ lệ 7:3, chuẩn hóa được thực hiện trên tập huấn luyện. Phương pháp được sử dụng gồm lọc nhiễu bằng biến đổi wavelet kết hợp Minmaxscaler đối với mô hình cải tiến, còn đối với mô hình gốc dữ liệu chỉ được chuẩn hóa bằng Minmaxscaler. Với biến đổi wavelet được thực hiện để loại bỏ các phần nhiễu không quan trọng và giữ lại các phần thông tin có giá trị cho dự đoán, Minmaxscaler dùng để giảm đi độ lệch dữ liệu giao dịch.

Bước 6: Xây dựng, huấn luyện mô hình học máy

Sau khi tiền xử lý dữ liệu, tiến hành xây dựng mô hình học máy. Khóa luận thực nghiệm nghiên cứu trên hai mô hình học sâu LSTM và GRU làm mô hình gốc để thực hiện song song với mô hình gốc có lọc nhiễu.

Bước 7: Đánh giá kết quả mô hình

Thực hiện đánh giá mô hình trên kết quả dự đoán trên tập kiểm tra thông qua các hệ số R^2 , RMSE, MSE, MAE, MAPE.

Bước 8: Đưa ra kết luận

Dựa trên các đánh giá kết quả ở bước 7, đưa ra các kết luận phù hợp với mục tiêu và vâu hồi nghiên cứu. Nghiên cứu kết luận mô hình có hiệu quả hơn khi kết hợp lọc nhiễu tiền dữ liệu hay không.

3.2 Dữ liệu nghiên cứu

Khóa luận thực hiện nghiên cứu với dữ liệu đầu vào là giá đóng cửa của chỉ số VN-Index trong thời gian 10 năm từ ngày 1/10/2015 đến 1/10/2025 theo ngày giao dịch.


Ngoài ra nghiên cứu còn thực hiện trên log return của chỉ số VN-Index để dự đoán đánh giá dữ liệu tuyến tính. Tỷ suất sinh lời log return được tính toán theo công thức sau

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \quad (3.1)$$

- P_t : giá tại thời điểm t
- P_{t-1} : giá tại thời điểm trước đó
- r_t : log return ngày t
- $\ln$: log tự nhiên

3.3 Kỹ thuật lọc nhiễu Biến đổi Wavelet rời rạc (Discrete Wavelet Transform)

Trong khuôn khổ nghiên cứu này, kỹ thuật Biến đổi Wavelet Rời rạc (Discrete Wavelet Transform - DWT) được áp dụng như một phương pháp tiền xử lý dữ liệu quan trọng. Mục tiêu là loại bỏ các thành phần nhiễu ngẫu nhiên (noise) ra khỏi chuỗi thời gian tài chính, nhằm cung cấp một tập dữ liệu đầu vào "sạch" và chất lượng hơn cho các mô hình học sâu LSTM và GRU.



Hình 3. 2 Sơ đồ quy trình lọc nhiễu

3.3.1 Cơ chế hoạt động

Discrete Wavelet Transform (DWT) là một kỹ thuật phân tích tín hiệu dựa trên việc tách tín hiệu thành các thành phần ở những dải tần số khác nhau thông qua các bộ lọc thông thấp và thông cao. Về cơ chế hoạt động, DWT phân rã tín hiệu thành hai phần: thành phần xấp xỉ (Approximation) biểu diễn xu hướng dài hạn và thành phần chi tiết (Detail) biểu diễn các dao động nhanh thường chứa nhiễu. Quá trình này được thực hiện lặp lại trên các thành phần xấp xỉ để tạo ra phân tích đa phân giải (Multiresolution Analysis), cho phép mô tả tín hiệu ở nhiều mức độ chi tiết khác nhau. Xét trên phương

diện toán học, DWT biểu diễn tín hiệu dưới dạng tổ hợp tuyến tính của các hàm scale $\phi(t)$ và wavelet $\psi(t)$, với các hệ số tương ứng phản ánh năng lượng của tín hiệu tại từng mức và từng vị trí (Daubechies, 1992), (Mallat, 1999).

Trong ứng dụng lọc nhiễu, DWT đóng vai trò quan trọng nhờ khả năng cô lập nhiễu trong các hệ số chi tiết. Sau khi phân rã, mức độ nhiễu được ước lượng thông qua Mean Absolute Deviation (MAD), từ đó xác định ngưỡng theo công thức ngưỡng phổ quát (Universal Threshold) của (Donoho & Johnstone, 1994). Các hệ số chi tiết được xử lý bằng kỹ thuật ngưỡng (thresholding), phổ biến nhất là ngưỡng mềm (soft-thresholding), nhằm loại bỏ các biên độ nhỏ do nhiễu gây ra nhưng vẫn giữ lại các dao động quan trọng của tín hiệu. Sau bước ngưỡng, tín hiệu được tái tạo thông qua biến đổi ngược (Inverse DWT) bằng cách ghép lại các thành phần xấp xỉ và chi tiết ở từng mức bằng hệ thống bộ lọc tổng hợp.

DWT có nhiều ưu điểm, đặc biệt là khả năng phân tích tín hiệu theo nhiều mức độ phân giải, xử lý tốt các tín hiệu phi tuyến và không dừng như dữ liệu tài chính, và hiệu quả trong việc tách nhiễu mà vẫn giữ nguyên cấu trúc cục bộ của tín hiệu. Tuy nhiên, kỹ thuật này cũng có những hạn chế, bao gồm việc kết quả phụ thuộc mạnh vào lựa chọn loại wavelet, số mức phân rã và phương pháp thresholding. Trong trường hợp chọn sai tham số, tín hiệu có thể bị làm mịn quá mức hoặc mất các đặc trưng quan trọng. Ngoài ra, DWT kém hiệu quả đối với các tín hiệu có tần số thay đổi liên tục hoặc có nhiều điểm nhảy mạnh.

3.3.2 Cơ sở lý thuyết toán học

Biến đổi Wavelet rời rạc (Discrete Wavelet Transform – DWT) là một công cụ phân tích tín hiệu mạnh mẽ cho phép biểu diễn dữ liệu trong cả miền thời gian và miền tần số. Khác với biến đổi Fourier chỉ mô tả tín hiệu trong miền tần số toàn cục, DWT cung cấp khả năng phân giải đa mức (multi-resolution analysis), cho phép xác định các đặc trưng tín hiệu tại những thang thời gian khác nhau (Daubechies, 1992).

Về mặt toán học, DWT dựa trên việc phân rã tín hiệu ban đầu $x(t)$ thông qua hai hàm cơ sở: wavelet mẹ $\psi(t)$ và hàm tỉ lệ $\phi(t)$. Các hàm này được sử dụng để xây dựng các phiên bản tịnh tiến và co giãn theo công thức:

$$\psi_{j,k}(t) = 2^{j/2}\psi(2^j t - k), \phi_{j,k}(t) = 2^{j/2}\phi(2^j t - k) \quad (3.2)$$

Trong đó, j biểu diễn mức phân giải (scale), còn k biểu diễn vị trí (translation). Tín hiệu được biểu diễn dưới dạng tổ hợp tuyến tính của các hệ số xấp xỉ (approximation coefficients) và hệ số chi tiết (detail coefficients):

$$x(t) = \sum_k a_{J,k} \phi_{J,k}(t) + \sum_{j=1}^J \sum_k d_{j,k} \psi_{j,k}(t) \quad (3.3)$$

Ở đây:

- $a_{J,k}$: hệ số xấp xỉ cấp J , chứa thành phần tần số thấp của tín hiệu,
- $d_{j,k}$: hệ số chi tiết tại mức j , biểu diễn các dao động cục bộ và nhiễu tần số cao.
- j : mức phân rã

3.3.3. Các họ sóng mẹ (Mother Wavelets) sử dụng

Việc lựa chọn hàm sóng mẹ phù hợp là yếu tố then chốt ảnh hưởng đến hiệu quả khử nhiễu. Nghiên cứu này tiến hành thực nghiệm trên các họ sóng phổ biến sau:

- Haar (haar): Dạng sóng đơn giản nhất, không liên tục. Ưu điểm là tốc độ tính toán nhanh nhưng nhược điểm là khả năng làm trơn kém.
- Daubechies (db2, db4): Họ sóng bất đối xứng, có khả năng nắm bắt tốt các điểm gãy khúc của tín hiệu giá. Bậc sóng càng cao (ví dụ db4) thì sóng càng mượt.
- Symlets (sym4, sym6): Là phiên bản cải tiến của Daubechies với tính đối xứng cao hơn (near symmetry).

- Coiflets (coif1, coif3): Có tính đối xứng cao và các mô men biến mất, phù hợp cho việc nén dữ liệu.

Sau khi thu được các hệ số chi tiết (cd), bước quan trọng nhất là loại bỏ các hệ số đại diện cho nhiễu. Nghiên cứu áp dụng phương pháp Làm tròn ngưỡng (Thresholding).


3.3.4. Thuật toán Mallat và Quá trình phân rã

Trong phân rã DWT, tín hiệu đầu vào $x[n]$ được biểu diễn thông qua việc co giãn (scaling) và tịnh tiến (shifting) một hàm cơ sở gọi là sóng mẹ (mother wavelet) $\psi(t)$. Dựa trên các phiên bản giãn–dịch này, DWT trích xuất các hệ số biểu diễn đặc trưng của tín hiệu ở nhiều thang phân giải khác nhau. Nhờ đó, tín hiệu có thể được tách thành:

Thành phần xấp xỉ (Approximation coefficients – A): Thể hiện xu hướng dài hạn, đặc trưng tần số thấp.

Thành phần chi tiết (Detail coefficients – D): Đại diện cho các dao động tần số cao, thường chứa nhiều thị trường, biến động đột ngột hoặc thông tin cục bộ.

Ý tưởng này dựa trên nguyên lý multi-resolution analysis (MRA) của (Mallat, 1989), cho phép phân rã tín hiệu thành các lớp thông tin ở nhiều cấp độ phân giải.



Hình 3. 3 Sơ đồ mô tả cách phân rã của DWT

DWT của tín hiệu rời rạc $x[n]$ được định nghĩa bởi:

$$W(j, k) = \sum_n x[n] \quad (3.4)$$

Trong đó:

- j : tham số tỷ lệ (scale), xác định mức phân rã
- k : tham số dịch chuyển (translation), xác định vị trí thời gian
- $\psi(t)$: hàm wavelet mẹ

Tham số scale j kiểm soát mức độ “co giãn” của sóng mẹ.

- Với j lớn $\rightarrow$ sóng mẹ giãn rộng $\rightarrow$ bắt tín hiệu tần số thấp (xu hướng).
- Với j nhỏ $\rightarrow$ sóng mẹ hẹp $\rightarrow$ bắt tín hiệu tần số cao (nhiều, dao động nhanh).

Tham số dịch chuyển k quy định vị trí của wavelet trên trục thời gian, cho phép DWT phân tích cục bộ (localized analysis).

3.3.5 Ngưỡng (Thresholding)

Soft-thresholding được dùng phổ biến vì cho kết quả mượt và ổn định hơn. Sau khi thu được các hệ số chi tiết (CD), bước quan trọng nhất là loại bỏ các hệ số đại diện cho nhiễu. Nghiên cứu áp dụng phương pháp Làm trơn ngưỡng (Thresholding).

Giá trị ngưỡng λ được xác định dựa trên độ lệch chuẩn của nhiễu. Có hai phương pháp xử lý chính:

1. Ngưỡng cứng (Hard Thresholding):
 - Giữ nguyên các hệ số lớn hơn ngưỡng λ .
 - Gán các hệ số nhỏ hơn λ về 0.
 - *Nhược điểm*: Có thể gây ra sự gián đoạn đột ngột trong tín hiệu tái tạo.
2. Ngưỡng mềm (Soft Thresholding):

- Các hệ số nhỏ hơn ngưỡng λ được gán về 0.
- Các hệ số lớn hơn λ sẽ bị thu nhỏ lại một lượng bằng λ
- *Ưu điểm:* Tạo ra sự chuyển tiếp mượt mà, giúp chuỗi dữ liệu tái tạo giữ được tính liên tục. Nghiên cứu này ưu tiên sử dụng Ngưỡng mềm để đảm bảo tính trơn tru tối đa cho đầu vào của mạng nơ-ron.

Sau quá trình xử lý ngưỡng, tín hiệu sạch được khôi phục thông qua Biến đổi Wavelet Ngược (Inverse DWT), sẵn sàng cho giai đoạn huấn luyện mô hình.


3.4 Phương pháp nghiên cứu

Dựa trên mục đích nghiên cứu nhằm tối ưu và đánh giá hiệu suất, hai mô hình học máy hồi quy dạng cổng trong khóa luận này được điều chỉnh siêu tham số (hyperparameters) đầu vào tương tự nhau để xây dựng mô hình. Việc đồng nhất tham số cho những so sánh đánh giá mô hình được khác quan nhất. nghiên cứu thực hiện huấn luyện trên tập train và tiến hành dự đoán và đánh giá trên tập test để cho ra kết quả khách quan nhất.

Về thực nghiệm trên kỹ thuật lọc nhiễu, nghiên cứu chủ yếu tập trung vào chỉ số VN-Index và tìm ra các hàm wavelet gốc và trong hai mức phân rã thì hàm nào và mức phân rã nào mang đến kết quả tốt nhất.

3.4.1 Tổng quan về mạng nơ-ron bộ nhớ dài ngắn hạn (LSTM)

Mạng nơ-ron bộ nhớ dài ngắn hạn (Long Short-Term Memory – LSTM) là một biến thể quan trọng của mạng nơ-ron hồi quy (Recurrent Neural Network – RNN), được đề xuất bởi (Hochreiter & Schmidhuber, 1997) nhằm khắc phục hiện tượng mất mát và bùng nổ gradient (vanishing/exploding gradient) thường gặp trong quá trình huấn luyện RNN truyền thống. LSTM được thiết kế chuyên biệt cho các bài toán mô hình hóa chuỗi thời gian, trong đó thông tin tại thời điểm hiện tại không chỉ phụ thuộc vào các quan sát gần kề mà còn chịu tác động bởi các trạng thái trong quá khứ xa hơn. Đây là đặc điểm đặc biệt phù hợp với dữ liệu tài chính, nơi các chuỗi giá có tính phụ thuộc động, tự tương quan và chứa cấu trúc dài hạn.



Hình 3. 4 Mô-dun của mạng LTSM

Mạng nơ ron dài ngắn hoạt động theo nguyên lý sau:

Lstm duy trì hai trạng thái, một là trạng thái ô nhớ (C_{t-1}) và trạng thái ẩn (H_{t-1}). Trạng thái ô nhớ có nghĩa vụ lưu trữ các thông tin dài hạn và hoạt động bằng cách chạy xuyên qua các nút lưu trữ thông tin (đường thẳng từ C_{t-1} đến C_t minh họa trên hình) nhờ vậy có thể truyền tải được thông tin trong quá khứ mà không bị cản trở nhiều.

Bên cạnh đó Lstm còn có khả năng thay đổi (bỏ đi hoặc thêm vào) trạng thái nhớ của ô các thông tin thiết yếu. Ở trạng thái ẩn thông tin đầu vào tức thời được truyền vào để đi đến các bước tiếp theo. Luồng thông tin đầu vào được điều tiết bằng ba cổng (gate unit) gồm cổng quên F_t , cổng đầu vào I_t , cổng đầu ra O_t . Mỗi cổng được tính từ kết hợp X_t và H_{t-1} qua lớp ma trên trọng số và hàm sigmoid hoặc tanh.

Ở ba cổng này mỗi cổng thực hiện một công dụng khác nhau:

Cổng quên dựa vào đầu vào và trạng thái ẩn mà có đưa ra việc loại bỏ thông tin trước đó từ ô trạng thái nhớ


Cổng đầu vào dựa trên đầu vào trạng thái ẩn mà quyết định có bao nhiêu thông tin sẽ được thêm vào.

Cổng đầu ra: trạng thái ẩn hiện tại và đầu ra của đơn vị LSTM sẽ được xác định bởi giá trị nào

3.4.2 Mô hình hồi quy đơn vị cổng GRU

Mạng nơ-ron hồi quy đơn vị cổng (Gated Recurrent Unit – GRU) là một biến thể cải tiến của mạng nơ-ron hồi quy (Recurrent Neural Network – RNN), được đề xuất bởi Cho và cộng sự vào năm 2014 nhằm đơn giản hóa cấu trúc của Long Short-Term Memory (LSTM) nhưng vẫn duy trì khả năng học các quan hệ phụ thuộc dài hạn trong chuỗi thời gian (Cho, et al., 2014). GRU được thiết kế nhằm giải quyết vấn đề mất mát gradient trong RNN truyền thống và tối ưu hóa khả năng học theo thời gian mà không cần cài đặt cấu trúc cổng phức tạp như LSTM.

Khác với LSTM vốn sử dụng ba cổng điều khiển (cổng quên, cổng đầu vào và cổng đầu ra) cùng trạng thái ô nhớ riêng biệt, GRU rút gọn kiến trúc bằng cách chỉ sử dụng hai cổng chính: cổng cập nhật (update gate) và cổng đặt lại (reset gate). Đồng thời, GRU hợp nhất trạng thái ô nhớ và trạng thái ẩn của LSTM thành một trạng thái duy nhất h_t . Nhờ đó, GRU trở nên nhẹ hơn về mặt tính toán, giảm số lượng tham số, tăng tốc độ huấn luyện mà vẫn đạt hiệu suất tương đương, thậm chí vượt trội trong một số bài toán chuỗi thời gian có mẫu ngắn hoặc dữ liệu nhiễu cao (Chung, et al., 2014)



Hình 3. 5 Mô-đun của mô hình GRU

Không có trạng thái ô C_t ; toàn bộ thông tin dài-ngắn hạn được gói trong trạng thái ẩn duy nhất H_{t-1} , GRU kết hợp ưu điểm của cơ chế “quên” của LSTM nhưng cấu trúc gọn hơn

Cổng đặt lại (Reset gate – R_t)

Cổng đặt lại kiểm soát mức độ ảnh hưởng của trạng thái ẩn trước đó khi tạo ra trạng thái tiềm năng mới. Nếu R_t gần 0, mô hình gần như bỏ qua H_{t-1} và chủ yếu dựa vào đầu vào X_t . Nếu R_t gần 1, thông tin từ H_{t-1} được sử dụng đầy đủ. Điều này cho phép GRU linh hoạt xóa hoặc giữ lại quá khứ khi xây dựng thông tin mới.

Cổng cập nhật (Update gate – Z_t)

Cổng cập nhật quyết định mức độ giữ lại trạng thái cũ so với việc thay thế nó bằng trạng thái tiềm năng mới. Khi Z_t gần 1, H_t gần giống H_{t-1} nên mô hình “nhớ dài hạn” tốt. Khi Z_t gần 0, mô hình ưu tiên thông tin mới cho phép thích ứng nhanh với thay đổi của chuỗi thời gian.

3.4.3 Các hàm kích hoạt sử dụng trong mô hình

3.4.3.1 Hàm tanh

Là một hàm kích hoạt với khoảng đầu ra từ -1 đến 1, mục đích của hàm là để nó lấy giá trị 0 làm trung tâm, cần các giá trị âm dương biểu hiện tính tăng giảm của dữ liệu để tạo trạng thái ẩn tiềm năng cho mô hình GRU và trạng thái ô nhớ cho LSTM. Hàm được thể hiện bằng công thức:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3.5)$$

Trong đó x: là giá trị đầu vào

3.4.3.2 hàm Sigmoid

Trong mô hình học máy hồi quy dạng cổng, hàm sigmoid (thường được kí hiệu $\sigma(x)$) được dùng để kích hoạt các cổng. đặc điểm của hàm là tạo các kết quả đầu ra trong khoảng từ 0 đến 1 với công thức:

$$\sigma(x) = \frac{1}{1+e^x} \quad (3.6)$$

Trong đó x: là giá trị đầu vào

Sigmoid được dùng để tạo các cổng (gates) như cổng reset và update trong GRU, hoặc cổng forget / input / output trong LSTM. Thực hiện mở cổng với giá trị gần 1, đóng cổng với giá trị gần 0

3.4.4 Hàm mục tiêu

Mô hình học máy hoạt động có tốt hay không? Muốn biết được điều đó các nhà nghiên cứu đi trước đã tạo ra một thước đo được gọi là hàm mục tiêu (Objective Function) để đánh giá hoạt động mô hình. Hàm mục tiêu được sử dụng để làm giảm thiểu sai số và cải thiện độ chính xác trong dự đoán cũng như đánh giá của mô hình. Để giảm thiểu giá trị của hàm mục tiêu thường các hàm tối ưu kèm theo ví dụ như gradient decent, momentum, RMSprop, hoặc Adam

Hàm mục tiêu được sử dụng trong nghiên cứu là Mean Absolute Error (hàm mất mát -Loss function). MSE được sử dụng rộng rãi trong học máy nhờ đặc tính khuếch đại sai số lớn, giúp mô hình chú trọng hơn vào các điểm dự đoán sai lệch mạnh. Việc sử dụng MSE phù hợp với đặc trưng dữ liệu chuỗi thời gian và giúp mô hình LSTM/GRU học được cấu trúc phi tuyến phức tạp của dữ liệu (Bishop, 2006).

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \quad (3.7)$$

y_i là giá trị thực tế,

$\hat{y}_i$ là giá trị mô hình dự đoán,

n là số quan sát.

3.4.5 Bộ tối ưu adam

Bộ tối ưu hóa Adam (Adaptive Moment Estimation) là phương pháp tối ưu phổ biến trong học sâu, được đề xuất bởi (Kingma & Ba, 2014). Adam kết hợp ưu điểm của hai thuật toán SGD mở rộng là Momentum và RMSProp, nhờ đó duy trì được tốc độ hội tụ nhanh và khả năng ổn định cao khi huấn luyện các mô hình có cấu trúc phức tạp như LSTM và GRU. Điểm nổi bật của thuật toán Adam dựa trên tính toán momentum

bậc nhất và gradient bậc hai có thể điều chỉnh tốc độ học của mô hình trên các tham số, có thể đi lên thẳng giá trị cực đại và không thể bị rơi vào cực tiểu.

Cơ chế cốt lõi của Adam là tính toán tỷ lệ học (learning rate) thích nghi cho từng tham số riêng biệt bằng cách ước lượng các mô-men bậc nhất (first moment - trung bình) và bậc hai (second moment - phương sai không chỉnh sửa) của gradient.

Quy trình cập nhật tham số của thuật toán Adam tại bước thời gian t được thực hiện qua các bước sau:

Tính toán Gradient:

Đầu tiên, đạo hàm riêng của hàm mục tiêu f theo tham số θ tại bước t được tính toán:

$$g_t = \nabla_{\theta} f(\theta_{t-1}) \quad (3.8)$$

Cập nhật ước lượng mô-men:

Thuật toán duy trì các biến trung bình trượt theo hàm mũ (exponential moving averages) của gradient m_t và bình phương gradient v_t :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (3.9)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (3.10)$$

Trong đó:

- m_t : Ước lượng mô-men bậc nhất (kỳ vọng của gradient).
- v_t Ước lượng mô-men bậc hai (kỳ vọng bình phương của gradient).
- $\beta_1, \beta_2 \in [0,1)$: Các hệ số suy giảm (decay rates), thường được gán giá trị mặc định là $\beta_1 = 0.9$ và $\beta_2 = 0.999$.

Hiệu chỉnh chệch (Bias Correction):

Do m_t và v_t được khởi tạo bằng vector 0, chúng có xu hướng bị lệch về 0 (biased towards zero) trong các bước đầu tiên của quá trình huấn luyện. Để khắc phục, Adam thực hiện hiệu chỉnh chệch:

$$\widehat{m}_t = \frac{m_t}{1-\beta_1^t} \quad (3.11)$$

$$\widehat{v}_t = \frac{v_t}{1-\beta_2^t} \quad (3.12)$$

Cập nhật tham số:

Cuối cùng, tham số θ được cập nhật dựa trên các mô-men đã hiệu chỉnh:

$$\theta_t = \theta_{t-1} - \alpha \cdot \frac{\widehat{m}_t}{\sqrt{\widehat{v}_t} + \epsilon} \quad (3.13)$$

Trong đó:

- α : Tỷ lệ học (Learning rate), hay bước nhảy (step size).
- ϵ : Một hằng số rất nhỏ (thường là 10^{-8}) để đảm bảo tính ổn định số học, tránh lỗi chia cho 0.

Lý do lựa chọn Adam cho nghiên cứu: Việc lựa chọn bộ tối ưu Adam cho bài toán dự báo giá chứng khoán trong khóa luận này dựa trên các ưu điểm sau

Thích nghi với dữ liệu nhiễu: Do đặc thù dữ liệu tài chính chứa nhiều nhiễu (noise) và có tính biến động không dừng, khả năng điều chỉnh learning rate linh hoạt của Adam giúp quá trình huấn luyện ổn định hơn, tránh bị kẹt tại các điểm tối ưu cục bộ kém.

Yêu cầu ít tinh chỉnh: Các siêu tham số mặc định của Adam thường hoạt động tốt trên đa số các bài toán học sâu mà không cần tinh chỉnh quá nhiều (hyperparameter tuning).

3.4.6 Chuẩn hóa Minmax scaler

Đối với các loại dữ liệu có tính biến động mạnh nói chung và dữ liệu chỉ số VN-Index nói riêng đều cần được chuẩn hóa đặc biệt để làm dữ liệu đầu vào cho các mô hình hồi quy, học máy, học sâu. Chính vì lý do đó mà chuẩn hóa Minmax scaler ra đời, để đảm bảo các thang đo được nhất quán sau khi chuẩn hóa bằng Minmax scaler dữ liệu không bị thay đổi về mặt bản chất mà chỉ bị nén lại về mặt kích thước giao động trong khoảng từ 0 tới 1. với các mô hình học máy và học sâu, việc làm chuẩn hóa đầu vào rất quan trọng, nhờ có Minmax scaler mà mô hình hạn chế được rất nhiều từ các khuyết tật vốn có của dữ liệu.

Minmax scaler chuẩn hóa dữ liệu theo công thức:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (3.14)$$

Trong đó

X là giá trị chưa chuẩn hóa

X_{scaled} là giá trị đã chuẩn hóa

X_{min} là giá trị nhỏ nhất của dữ liệu

X_{max} là giá trị lớn nhất của dữ liệu

Trong nghiên cứu này Minmax scaler được thiết kế ngay sau lọc nhiễu trong xử lý tiền dữ liệu. lý do của việc sắp xếp này là vì lọc nhiễu chỉ có tác dụng làm mượt dữ liệu và không có khả năng chuẩn hóa, đồng thời việc sắp xếp thứ tự như vậy trong tiền xử lý dữ liệu cũng rất phù hợp cho mục đích so sánh đánh giá kết quả mô hình mà khóa luận này hướng tới.

3.4.7 Tập xác thực (Validation set) và cơ chế dừng sớm (Early stopping)

Tập xác thực (validation set) là một thành phần quan trọng trong quy trình xây dựng mô hình học máy nhằm đánh giá hiệu suất mô hình trong quá trình huấn luyện và hỗ trợ việc lựa chọn siêu tham số (hyperparameters). Không giống như tập huấn luyện (training set) được dùng để tối ưu trọng số mô hình, tập xác thực giúp đánh giá khả năng khái quát hóa của mô hình trên dữ liệu chưa từng được học, từ đó hạn chế tình trạng

quá khớp (overfitting). Trong nghiên cứu này, tập xác thực được lấy ra 1:9 từ tập huấn luyện và kết hợp với cơ chế dừng sớm để tăng độ tin cậy trong huấn luyện mô hình.

Cơ chế dừng sớm (Early Stopping) là một kỹ thuật regularization (chính quy hóa) quan trọng trong huấn luyện mô hình học sâu, được sử dụng nhằm ngăn ngừa hiện tượng quá khớp (overfitting). Ý tưởng cốt lõi của phương pháp này là theo dõi một chỉ số đánh giá trên tập xác thực và dừng quá trình huấn luyện khi chỉ số này không còn được cải thiện sau một số epoch liên tiếp (Prechelt, 1998).

Khi mô hình tiếp tục học quá lâu, sai số trên tập huấn luyện tiếp tục giảm nhưng sai số trên tập xác thực lại tăng, cho thấy mô hình bắt đầu ghi nhớ nhiều thay vì học quy luật chung. Early Stopping giúp dừng mô hình tại thời điểm tối ưu đó, hạn chế overfitting và đồng thời rút ngắn thời gian huấn luyện (Goodfellow, et al., 2016). Nhờ cơ chế này, mô hình đạt được trạng thái cân bằng tốt hơn giữa độ phức tạp và khả năng khái quát hóa.

3.5 Đánh giá hiệu suất mô hình

Các chỉ số đánh giá mô hình (evaluation metrics) giữ vai trò quan trọng trong phân tích hiệu suất dự báo. Đối với các mô hình dự báo chuỗi thời gian như LSTM và GRU, các chỉ số sai số được sử dụng nhằm phản ánh mức độ phù hợp giữa giá trị dự đoán và giá trị thực tế. Trong luận văn này, nhóm chỉ số gồm MSE, RMSE, MAE, MAPE và hệ số xác định R^2 được sử dụng để đánh giá và so sánh hiệu suất giữa các mô (Hyndman & Athanasopoulos, 2018) (Bishop, 2006)

3.5.1 Chỉ số đánh giá MSE

MSE (Mean Squared Error) là chỉ số dùng phổ biến trong các mô hình hồi quy. Kết quả đánh giá mô hình thường đưa ra sau khi đánh giá chỉ số mất mát này. MSE đo lường sai số trung bình bình phương giữa giá trị dự đoán và giá trị thực, có khả năng khuếch đại những sai lệch lớn, giúp mô hình chú ý hơn vào các điểm dự đoán sai nặng (Bishop, 2006).

Khi chỉ số MSE càng gần giá trị 0 thì độ tin cậy của mô hình càng cao. Chỉ số được tính toán theo công thức

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.15)$$

Trong đó:

- y_i : giá trị thực tế,
- $\hat{y}_i$: giá trị dự đoán,
- n : số lượng mẫu quan sát.

3.5.2 Chỉ số đánh giá RMSE

Chỉ số RMSE (Root Mean Squared Error) được dùng để đánh giá mô hình và được xem là biến thể của MSE. Đúng như tên của nó chỉ số này được tính toán bằng cách khai căn bậc hai MSE, và nó được tạo ra để người đọc dễ dàng đánh giá được chỉ số. Việc đánh giá RMSE cũng tương tự như MSE khi giá trị càng gần về 0 thì kết quả hồi quy của mô hình càng tốt

Công thức tính toán:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.16)$$

y_i : giá trị thực tế,

$\hat{y}_i$: giá trị dự đoán,

n : số lượng mẫu quan sát

3.5.3 Chỉ số đánh giá MAE

Chỉ số đánh giá trên giá sai số tuyệt đối của giá trị kết quả dự đoán mô hình so với thực tế là MAE (Mean Absolute Error). Khác với RMSE, MAE đánh giá tất cả các sai

số một cách bình đẳng (tuyến tính), không phóng đại các sai số lớn. Cũng đánh giá kết quả dựa trên giá trị chỉ số càng nhỏ càng tốt.

Và được tính toán theo công thức:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.17)$$

Trong đó

y_i : giá trị thực tế,

- $\hat{y}_i$: giá trị dự đoán,
- n : số lượng mẫu quan sát

3.5.4 Chỉ số đánh giá MAPE

MAPE (Mean Absolute Percentage Error) thường được dùng cho các bài toán kinh tế vì thước đo này phản ánh sai số trung bình theo tỉ lệ phần trăm, phản ánh mức độ sai lệch tương đối giữa giá trị dự đoán và giá trị thực. cách đánh giá chỉ số này cũng tương tự như các chỉ số đã được trình bày, khi giá trị MAPE càng nhỏ thì kết quả của mô hình càng tốt.

Công thức tính:

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (3.18)$$

Với

y_i : giá trị thực tế,

- $\hat{y}_i$: giá trị dự đoán,
- n : số lượng mẫu quan sát

3.5.5 Hệ số xác định R^2

Hệ số xác định (Coefficient of Determination - R^2) là hệ số thống kê quan trọng được dùng để đánh giá mức độ phù hợp của mô hình. Hệ số xác định R^2 là thước đo mức độ mô hình giải thích được phương sai của dữ liệu. R^2 có giá trị trong khoảng $(-\infty, 1]$, trong đó giá trị càng gần 1 cho thấy mô hình càng phù hợp

Công thức tính toán:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3.19)$$

y_i : giá trị thực tế,

- $\hat{y}_i$: giá trị dự đoán,
- n : số lượng mẫu quan sát

KẾT LUẬN CHƯƠNG 3

Tổng kết chương 3, ta có thể thấy tác giả đã mô tả quy trình và cách tiến nghiên cứu thực nghiệm trên mô hình. Cơ chế hoạt động cũng như cơ sở toán học về lọc nhiễu và hai mô hình nghiên cứu là LSTM, GRU.

Phương pháp nghiên cứu cũng đã cho thấy một khía cạnh khác khi nghiên cứu tham chiếu thực hiện trên các loại chỉ số chứng khoán khác nhau còn khóa luận này chỉ nghiên cứu trên duy nhất chỉ số VN-Index vào tìm cách chứng thực kết quả qua hai mức phân rã và nhiều hàm gốc khác nhau thay vì hai hàm wavelet gốc của nghiên cứu tham chiếu.

Các chỉ số đánh giá mô hình được trình bày đầy đủ để thuận tiện triển khai chương tiếp theo

Chương 4 Kết quả và đánh giá

4.1 Các siêu tham số sử dụng trong mô hình

Các siêu tham số của mô hình LSTM được thiết lập như Bảng 4.1:

Các siêu tham số	
Units (Lớp LSTM thứ nhất)	60
Units (Lớp LSTM thứ hai)	40
Dense (Hidden Layer)	Không có
Dense (Output Layer)	1
Epochs	40
Batch size	16
Loss	Mean Squared Error (MSE)
Optimizer	Adam

Bảng 4. 1 Siêu tham số của mô hình LSTM

Và dưới đây là các siêu tham số của mô hình GRU


Các siêu tham số	
Units (Lớp GRU thứ nhất)	60
Units (Lớp GRU thứ hai)	40
Dense (Hidden Layer)	Không có
Dense (Output Layer)	1
Epochs	40
Batch size	16
Loss	Mean Squared Error (MSE)
Optimizer	Adam

Bảng 4. 2 Siêu tham số của mô hình GRU

4.2 Kết quả sau lọc nhiễu

Dữ liệu ở tập train được sử dụng để lọc nhiễu và so sánh với kết quả lọc nhiễu với đường màu xanh đại diện cho dữ liệu gốc, đường màu cam đại diện cho dữ liệu sau khi lọc nhiễu.

4.2.1 Trên chỉ số VN-Index



Hình 4. 1 Dữ liệu sau khi lọc nhiễu hàm haar với hai mức phân rã (bên trái mức 1 và bên phải mức 2)

Theo như Hình 4.1. Lấy hàm haar làm hàm wavelet đại diện cho kỹ thuật lọc nhiễu, kết quả thực nghiệm sử dụng hàm cơ sở Haar ở mức phân rã 1 và mức phân rã 2 trên tập dữ liệu huấn luyện được thể hiện trực quan qua các biểu đồ đường giá.


Quan sát tổng thể cho thấy, chuỗi dữ liệu sau khi khử nhiễu (Denoised data) ở cả hai mức phân rã đều thể hiện khả năng bám sát chặt chẽ với chuỗi dữ liệu gốc (Actual data). Các điểm đảo chiều xu hướng và biên độ dao động của giá đóng cửa trong giai đoạn từ năm 2016 đến 2023 đều được đường tín hiệu lọc tái tạo chính xác, hầu như không xuất hiện hiện tượng trễ pha hay làm biến dạng cấu trúc xu hướng chính của thị trường. Điều này chứng tỏ hàm Haar, với đặc tính không liên tục và dạng xung vuông, đặc biệt tương thích với tính chất biến động ngẫu nhiên và các bước nhảy giá đặc thù của chuỗi thời gian tài chính.

Khi đi sâu vào so sánh chi tiết giữa hai mức phân rã, kết quả cho thấy sự khác biệt về hình thái tín hiệu là không quá lớn về mặt trực quan, tuy nhiên vẫn phản ánh đúng bản chất của lý thuyết đa phân giải (MRA). Ở mức phân rã 1, quá trình lọc chủ

yếu loại bỏ các nhiễu tần số cao nhất, do đó đường tín hiệu khôi phục giữ lại được tối đa các chi tiết nhỏ của biến động giá.

Trong khi đó, tại mức phân rã 2, tín hiệu được làm trơn sâu hơn nhằm loại bỏ thêm các thành phần nhiễu ở dải tần số thấp hơn. Việc đường dữ liệu sau lọc ở mức 2 vẫn duy trì độ trùng khớp cao với dữ liệu thực tế là một tín hiệu tích cực, cho thấy mô hình đã loại bỏ nhiễu hiệu quả mà không gây ra hiện tượng quá trơn (over-smoothing) làm mất mát thông tin quan trọng. Đây là cơ sở dữ liệu "sạch" có độ tin cậy cao để phục vụ cho các mô hình dự báo tiếp theo trong nghiên cứu.

4.2.2 Trên log return




Hình 4. 2 Dữ liệu tập train (log return) sau lọc nhiễu phân rã mức một (hàm haar bên trái và sym6 bên phải)

Khi xem xét đồng thời kết quả khử nhiễu trên chuỗi lợi suất Logarit sử dụng hai hàm cơ sở khác nhau là Haar và Symlet 6 ở cùng mức phân rã 1, điểm chung nổi bật nhất là khả năng nhận diện và bóc tách hiệu quả các thành phần nhiễu ngẫu nhiên tần số cao mà không làm biến đổi cấu trúc cốt lõi của chuỗi dữ liệu. Cả hai phương pháp đều cho thấy sự tương đồng lớn trong cơ chế xử lý tín hiệu: đường dữ liệu sau lọc (màu cam) đều loại bỏ được các dao động biên độ nhỏ được xem là nhiễu trắng, giúp tín hiệu trở nên rõ ràng và tập trung hơn.

Quan trọng hơn, cả hai hàm sóng con này đều thể hiện ưu điểm vượt trội trong việc bảo toàn độ lớn và thời điểm xuất hiện của các cú sốc thị trường, cụ thể là các điểm cực trị trong giai đoạn biến động mạnh năm 2020 và 2022 vẫn được giữ lại gần như nguyên vẹn. Điều này khẳng định rằng ở mức phân rã đầu tiên (Level 1), phương pháp Wavelet có tính ổn định cao, đảm bảo giữ lại được tính chất "đuôi béo" (fat-tailed) – một đặc trưng quan trọng phản ánh rủi ro của dữ liệu tài chính, bất kể việc lựa chọn hình dạng hàm cơ sở là đối xứng (Symlet) hay gián đoạn (Haar).

4.3 Dự đoán trên chỉ số VN-Index

4.3.1 Kết quả dự đoán của LSTM



Hình 4. 3 Kết quả dự đoán của mô hình LSTM gốc trên chỉ số VN-Index

Kết quả thực nghiệm trên tập kiểm thử cho thấy mô hình Long Short-Term Memory (LSTM) thể hiện khả năng vượt trội trong việc nắm bắt các quy luật biến động

phi tuyến tính phức tạp của chỉ số VN-Index. Quan sát trực quan biểu đồ Hình 4.3 so sánh giữa giá trị thực tế (Actual) và giá trị dự báo (Prediction), có thể thấy đường dự báo bám sát chặt chẽ xu hướng vận động chung của thị trường, đặc biệt trong các giai đoạn chỉ số hình thành xu hướng rõ ràng. Mô hình không chỉ nhận diện tốt hướng đi của giá mà còn phản ánh khá chính xác biên độ dao động trong các nhịp điều chỉnh ngắn hạn.


Tuy nhiên, khi đi sâu vào phân tích các điểm đảo chiều xu hướng, hiện tượng trễ pha nhẹ vẫn xuất hiện – một đặc tính thường thấy ở các mô hình mạng nơ-ron hồi quy khi xử lý chuỗi thời gian tài chính. Cụ thể, tại các thời điểm thị trường xảy ra những cú sụt giảm hoặc tăng trưởng đột biến với biên độ lớn, đường tín hiệu dự báo có xu hướng phản ứng chậm hơn một nhịp so với dữ liệu thực tế và đôi khi chưa vươn tới được các đỉnh/đáy cực đại.

Mặc dù vậy, xét trên tổng thể khung thời gian đánh giá, mức độ sai lệch này là chấp nhận được và không làm ảnh hưởng đến khả năng định hướng xu thế dài hạn của mô hình. Điều này khẳng định độ tin cậy của mô hình LSTM đề xuất trong việc hỗ trợ ra quyết định đầu tư, đặc biệt khi kết hợp với các phương pháp xử lý nhiễu tín hiệu đầu vào đã thực hiện ở giai đoạn trước.

Dựa trên các chỉ số đánh giá thu được từ mô hình LSTM, có thể nhận thấy mô hình đạt hiệu suất dự báo tương đối tốt và ổn định. Cụ thể, $MSE = 237,14$ và $RMSE = 15,40$ cho thấy sai số bình phương trung bình và sai số căn bậc hai đều ở mức thấp, phù hợp với thang đo dữ liệu.

Giá trị $MAE = 10.46$ phản ánh mức chênh lệch trung bình giữa dự đoán và giá trị thực không quá lớn. Đồng thời, $MAPE = 0,008571$ (tương đương khoảng 0.86%) cho thấy mô hình có độ chính xác cao, khi sai số phần trăm trung bình dưới 1%. Hệ số xác định $R^2 = 0,988587$ cho thấy mô hình giải thích được gần 99% biến thiên của chuỗi dữ liệu, chứng tỏ mức độ phù hợp mạnh mẽ. Nhìn chung, bộ chỉ số trên khẳng định LSTM hoạt động hiệu quả trong nhiệm vụ dự báo và thể hiện hiệu năng cao.

4.3.2 Kết quả dự đoán của GRU




Hình 4. 4 Kết quả dự đoán của mô hình GRU gốc trên chỉ số VN-Index

Theo Hình 4.4 cũng có thể thấy không quá nhiều sự khác biệt so với kết quả của mô hình LSTM trừ việc GRU đưa ra kết quả có vẻ sát với giá gốc hơn so với LSTM


Dựa trên các chỉ số đánh giá thu được từ mô hình GRU, có thể thấy hiệu suất dự báo rất tốt. Cụ thể, $MSE = 206,24$ và $RMSE = 14,36$ cho thấy sai số dự đoán tuyệt đối tương đối thấp so với quy mô dữ liệu gốc. Giá trị $MAE = 9,58$ phản ánh độ lệch trung bình giữa dự đoán và giá trị thực chỉ ở mức nhỏ.

Đáng chú ý, $MAPE = 0,007836$ (tương đương 0.78%) là mức sai số phần trăm cực kỳ thấp, cho thấy khả năng dự đoán chính xác và ổn định của mô hình. Cuối cùng, hệ số xác định $R^2 = 0,990075$ chứng tỏ mô hình giải thích được khoảng 99% biến thiên của dữ liệu, thể hiện mức độ phù hợp rất cao. Tổng thể, các chỉ số trên khẳng định mô hình GRU hoạt động hiệu quả và có độ tin cậy lớn trong nhiệm vụ dự báo chuỗi thời gian được sử dụng trong nghiên cứu.

4.3.3 Kết quả của DWT kết hợp LSTM



Hình 4. 5 Kết quả dự đoán của DWT kết hợp LSTM trên chỉ số VN-Index (phân rã mức 1 với hàm sym6)



Hình 4. 6 Kết quả dự đoán của DWT kết hợp LSTM trên chỉ số VN-Index (phân rã mức 2 với hàm coif1)

Phân rã mức 1					
chỉ số	MSE	RMSE	MAE	MAPE	R2
LSTM gốc	237,14212	15,3994	10,4624	0,00857	0,98859
haar	219,93467	14,8302	10,1552	0,00829	0,98942
db2	259,11377	16,097	10,9861	0,00899	0,98753
db4	192,8978	13,8888	9,30748	0,00761	0,99072
sym4	192,42979	13,8719	9,47492	0,0077	0,99074
sym6	187,89455	13,7075	9,19687	0,00745	0,99096
coif1	210,02716	14,4923	9,97463	0,00811	0,98989
coif3	228,58493	15,119	10,4513	0,00852	0,989
Phân rã mức 2					
chỉ số	MSE	RMSE	MAE	MAPE	R2
LSTM gốc	237,14212	15,3994	10,4624	0,00857	0,98859
haar	263,26986	16,2256	11,15	0,00911	0,98733
db2	239,13541	15,464	10,3388	0,0083	0,98849
db4	273,38716	16,5344	11,4333	0,00924	0,98684
sym4	241,6911	15,5464	10,6954	0,00868	0,98837
sym6	293,8617	17,1424	11,6798	0,00944	0,98586
coif1	222,3798	14,9124	10,2519	0,00831	0,9893
coif3	304,38805	17,4467	11,8105	0,00953	0,98535

Bảng 4. 3 Kết quả các chỉ số đánh giá của mô hình DWT kết hợp LSTM (trên hai mức phân rã)

Nguồn: tác giả tự tổng hợp

Khi xét tại mức phân rã 1, đa số các phương pháp khử nhiễu đều mang lại sự cải thiện tích cực so với mô hình LSTM gốc. Trong đó, hàm Symlet 6 (sym6) thể hiện sự vượt trội tuyệt đối, giúp giảm chỉ số sai số trung bình bình phương (MSE) từ 237,14 (mô hình gốc) xuống còn 187,89, tương ứng với mức cải thiện đáng kể khoảng 20.7%; đồng thời nâng hệ số xác định R^2 lên mức 0.9909.


Các hàm khác như db4 hay sym4 cũng cho thấy hiệu quả khử nhiễu tốt khi các chỉ số sai số đều thấp hơn mô hình gốc. Tuy nhiên, vẫn tồn tại ngoại lệ là hàm db2 và coif3, khi áp dụng ở mức này lại khiến sai số tăng nhẹ hoặc không cải thiện đáng kể, cho thấy cấu trúc sóng của chúng chưa thực sự tương thích với đặc trưng dữ liệu ở độ phân giải này.

Ngược lại, khi chuyển sang mức phân rã 2, xu hướng cải thiện bị đảo chiều rõ rệt. So sánh chéo giữa hai mức phân rã, hầu hết các chỉ số sai số tại Level 2 đều tăng cao hơn so với mức 1 và thậm chí tệ hơn cả mô hình LSTM gốc. Điển hình như trường hợp của sym6 tối ưu nhất ở mức phân rã một, khi áp dụng ở phân rã mức 2 lại cho MSE tăng vọt lên 293,86, cao hơn nhiều so với dữ liệu thô ban đầu. Hiện tượng này chỉ ra rằng, việc tăng mức phân rã lên 2 đã dẫn đến tình trạng làm trơn quá mức (over-smoothing), vô tình loại bỏ cả những thông tin biến động ngắn hạn mang tính tín hiệu thay vì chỉ loại bỏ nhiễu.


So với nghiên cứu tham chiếu của (Ziółkowski & Wieceński, 2025) thì có thể thấy có một sự khác biệt khi DWT kết hợp LSTM với haar và mức phân rã 2 không cải thiện so với mô hình gốc. tuy nhiên kết quả lại tối ưu ở haar phân rã mức một

Tóm lại, kết quả thực nghiệm khẳng định rằng việc kết hợp LSTM với kỹ thuật Wavelet Denoising sử dụng hàm Symlet 6 tại mức phân rã 1 là phương án tối ưu nhất, giúp cân bằng giữa việc làm sạch dữ liệu và bảo toàn thông tin, từ đó nâng cao đáng kể độ chính xác của dự báo.

4.3.4 Kết quả của DWT kết hợp GRU



Hình 4. 7 Kết quả dự đoán của DWT kết hợp GRU trên chỉ số VN-Index (phân rã mức 1 với hàm haar)



Hình 4. 8 Kết quả dự đoán của DWT kết hợp GRU trên chỉ số VN-Index (phân rã mức 2 với hàm haar)

Phân rã mức 1					
Chỉ số	MSE	RMSE	MAE	MAPE	R2
GRU gốc	206,2407	14,36108	9,5763	0,00784	0,99008
haar	185,23785	13,61021	9,08801	0,00741	0,99109
db2	196,6885	14,02457	9,42853	0,0077	0,99053
db4	200,41866	14,15693	9,53104	0,00776	0,99036
sym4	292,42298	17,10038	11,7424	0,00955	0,98593
sym6	258,08445	16,06501	10,9234	0,00888	0,98758
coif1	193,53879	13,91182	9,34643	0,00759	0,99069
coif3	212,75531	14,58613	9,81205	0,00799	0,98976
Phân rã mức 2					
Chỉ số	MSE	RMSE	MAE	MAPE	R2
GRU gốc	206,2407	14,36108	9,5763	0,00784	0,99008
haar	187,00209	13,67487	9,24812	0,00753	0,991
db2	192,33221	13,86839	9,20322	0,00751	0,99074
db4	206,80459	14,3807	9,60513	0,0078	0,99005
sym4	221,62897	14,88721	10,0029	0,00811	0,98933
sym6	229,17588	15,13856	10,2204	0,00829	0,98897
coif1	193,66104	13,91622	9,42994	0,00763	0,99068
coif3	200,55391	14,16171	9,4178	0,00766	0,99035

Bảng 4. 4 Kết quả các chỉ số đánh giá của mô hình DWT kết hợp GRU (trên hai mức phân rã)

Nguồn: Tác giả tự tổng hợp

Tại mức phân rã 1 (Level 1), hàm Haar đã chứng minh là phương pháp tối ưu nhất cho mô hình GRU. Việc áp dụng biến đổi Haar đã giúp giảm chỉ số sai số trung bình bình phương (MSE) từ 206.24 (mô hình GRU gốc) xuống mức thấp nhất là 185.23, đồng thời cải thiện hệ số xác định R^2 lên 0.9910.


Các hàm thuộc họ Coiflet (như coif1) và Daubechies (như db2, db4) cũng mang lại hiệu quả tích cực với mức sai số thấp hơn mô hình gốc. Tuy nhiên, điều đáng chú ý là họ Symlet (cụ thể là sym4 và sym6) – vốn hoạt động rất tốt trên một số kiến trúc khác – lại cho kết quả kém hiệu quả đối với GRU tại mức phân rã này, với chỉ số MSE tăng vọt lên mức 292.42 và 258.08, cao hơn đáng kể so với dữ liệu chưa qua xử lý.

Khi xem xét tại mức phân rã 2 (Level 2), xu hướng biến động trở nên phức tạp hơn. Trong khi hàm Haar vẫn duy trì được hiệu quả tốt (MSE = 187.00) nhưng đã giảm nhẹ so với chính nó ở Level 1, thì hàm db2 lại cho thấy sự cải thiện khi tăng mức phân rã (MSE giảm từ 196.68 ở Level 1 xuống 192.33 ở Level 2). Đa phần các chỉ số sai số ở Level 2 đều có xu hướng cao hơn hoặc chỉ cải thiện không đáng kể.


Tổng hợp lại, kết quả định lượng khẳng định rằng đối với mô hình GRU trên tập dữ liệu này, việc sử dụng kỹ thuật Wavelet Denoising với hàm Haar tại mức phân rã 1 là chiến lược hiệu quả nhất. Phương pháp này không chỉ giúp loại bỏ nhiễu tốt hơn so với các hàm sóng phức tạp (như Symlet) mà còn bảo toàn được thông tin tốt hơn so với việc phân rã sâu ở Level 2, qua đó giúp mô hình GRU đạt được độ chính xác dự báo cao nhất.

4.4 Dự đoán trên Log return của chỉ số VN-Index


4.4.1 Kết quả



Hình 4. 9 Kết quả dự đoán của hai mô hình gốc trên tỉ suất sinh lời (bên trái là của LSTM bên phải là của GRU)



Hình 4. 10 Kết quả dự đoán của LSTM kết hợp lọc nhiễu (phân rã mức 1 với hàm sym6)



Hình 4. 11 Kết quả dự đoán của GRU kết hợp lọc nhiễu (phân rã mức 1 với hàm haar)

Chỉ số	LSTM	LSTM+sym6 (mức phân rã 1)	GRU	GRU+haar (mức phân rã 1)
MSE	0,000152	0,00115	0,00016	0,000523
RMSE	0,01233	0,033913	0,01263	0,022867
MAE	0,008662	0,025521	0,009016	0,017263
MAPE	8,646841	21,695647	9,236475	16,783478
R2	-0,31373	-8,938116	-0,37835	-3,518579

Bảng 4. 5 Kết quả chỉ số đánh giá trên biến động tỉ suất log return

Nguồn: Tác giả tự tổng hợp

4.4.2. Hiệu suất của các mô hình trên dữ liệu biến động tỉ suất

Nhìn chung, việc dự báo chính xác giá trị lợi suất logarit khó khăn hơn rất nhiều so với dự báo giá tuyệt đối. Điều này thể hiện qua việc hệ số xác định (R^2) ở tất cả các kịch bản đều mang giá trị âm. Điều này ngụ ý rằng biến động của lợi suất hàng ngày mang tính ngẫu nhiên cao, và các mô hình học sâu dù mạnh mẽ như LSTM hay GRU cũng gặp khó khăn trong việc tìm ra quy luật tất định để dự báo tốt hơn giá trị trung

bình mẫu. Trong bối cảnh này, mô hình LSTM gốc (chưa qua lọc nhiễu) đạt kết quả khả quan nhất tương đối với MSE thấp nhất (0,000152) và R2 ít âm nhất (-0,31).

4.4.3. Tác động ngược chiều của kỹ thuật lọc nhiễu

Một phát hiện quan trọng trong nghiên cứu này là tác động tiêu cực của việc khử nhiễu lên chuỗi lợi suất. Cụ thể:

Khi áp dụng Wavelet Symlet 6 (mức 1) vào LSTM, sai số MSE tăng mạnh từ 0,00015 lên 0,00115 (tăng gấp 7 lần), và R^2 giảm sâu xuống -8,93.

Tương tự, khi áp dụng Wavelet Haar (mức 1) vào GRU, sai số MSE cũng tăng từ 0,00016 lên 0,00052.

Nguyên nhân: Khác với chuỗi giá nơi thông tin nằm chủ yếu ở xu hướng, chuỗi lợi suất (Log Return) có đặc tính là chuỗi dừng, dao động quanh 0 và thông tin quan trọng về biến động thị trường (volatility) thường nằm lẫn ngay trong các tần số cao. Việc áp dụng kỹ thuật khử nhiễu lên chuỗi lợi suất đã vô tình lọc bỏ quá mức (over-smoothing), làm mất đi các tín hiệu biến động vì mô vốn mang thông tin dự báo quan trọng. Do đó, dữ liệu đầu vào trở nên quá trơn và mất đi tính chất đặc thù của thị trường, dẫn đến mô hình không thể học được quy luật biến động thực tế.

4.5 Đánh giá kết quả

Thứ nhất, khi so sánh khả năng dự báo trên dữ liệu thô (chưa qua lọc nhiễu), mô hình GRU thể hiện ưu thế vượt trội hơn so với LSTM. Cụ thể trên tập dữ liệu giá đóng cửa, GRU đạt mức sai số MSE thấp hơn (206,24 so với 237,14 của LSTM) và các chỉ số RMSE, MAE cũng đều thấp hơn. Điều này cho thấy với kiến trúc đơn giản hóa và cơ chế cổng cập nhật linh hoạt, GRU có khả năng thích ứng tốt hơn với nhiễu tự nhiên của thị trường chứng khoán Việt Nam khi không có sự can thiệp của các thuật toán tiền

xử lý. Trong khi đó, LSTM dường như nhạy cảm hơn và dễ bị ảnh hưởng bởi các biến động nhiễu trong dữ liệu gốc.

Thứ hai, về hiệu quả của các mức phân rã Wavelet tùy vào hàm gốc mà hiệu quả khác nhau, kết quả thống nhất chỉ ra rằng việc lọc nhiễu chỉ thực sự cải thiện mô hình hơn ở mức phân rã 1. Tại mức này, kỹ thuật giúp loại bỏ các nhiễu trắng tần số cao mà vẫn giữ lại được cấu trúc xu hướng chính của giá. Ngược lại, việc tăng mức phân rã lên 2 đã gây ra tác dụng ngược, làm tăng sai số dự báo ở hầu hết các trường hợp kiểm thử. Nguyên nhân là do mức phân rã 2 đã thực hiện làm trơn quá mức (over-smoothing), vô tình loại bỏ các biến động ngắn hạn mang tính tín hiệu và làm mất đi các đặc trưng quan trọng tại các điểm đảo chiều của thị trường.

Thứ ba, xét về mức độ hưởng lợi từ kỹ thuật tiền xử lý, LSTM là mô hình có sự cải thiện hiệu suất ấn tượng nhất nhờ lọc nhiễu. Mặc dù khởi điểm với sai số cao hơn GRU trên dữ liệu gốc, nhưng khi được kết hợp với Wavelet Symlet 6 (mức 1), hiệu suất của LSTM đã tăng vọt, giảm sai số MSE tới hơn 20% (từ 237,14 xuống 187,89), tiệm cận và thậm chí cạnh tranh sòng phẳng với kết quả tốt nhất của GRU. Điều này chứng minh rằng LSTM có tiềm năng rất lớn nhưng cần một nguồn dữ liệu đầu vào "sạch" và ổn định để phát huy tối đa khả năng ghi nhớ dài hạn của mình.

Cuối cùng, một phát hiện quan trọng giải thích lý do kết quả lọc nhiễu trên chuỗi lợi suất Logarit (Log Return) lại kém hiệu quả. Khác với chuỗi giá mang tính xu hướng, chuỗi lợi suất có tính dừng và đặc trưng bởi sự dao động quanh giá trị 0. Trong chuỗi dữ liệu này, các biến động tần số cao (vốn bị coi là nhiễu trong chuỗi giá) lại chính là thông tin về độ biến động (volatility) của thị trường. Việc áp dụng lọc nhiễu lên chuỗi lợi suất đã vô tình triệt tiêu các thông tin biến động này, dẫn đến việc mô hình mất đi các dữ kiện đầu vào quan trọng để dự báo biên độ dao động, khiến hệ số R^2 chuyển sang giá trị âm và sai số tăng cao.

KẾT LUẬN CHƯƠNG 4

Chương 4 đã trình bày chi tiết các kết quả thực nghiệm nhằm đánh giá hiệu quả của phương pháp khử nhiễu Wavelet khi kết hợp với các mô hình học sâu (LSTM, GRU) trong bài toán dự báo chỉ số VN-Index. Thông qua việc phân tích định lượng trên các chỉ số (MSE, RMSE, MAE, MAPE) và hệ số xác định (R^2) với nhiều kịch bản thử nghiệm khác nhau (các hàm sóng con, các mức phân rã và loại dữ liệu đầu vào), nghiên cứu rút ra rằng việc lọc nhiễu có mang đến cải thiện kết quả dự đoán mô hình trên dữ liệu chỉ số VN-Index, nhưng khi thực hiện trên dữ liệu tỉ xuất sinh lời thì lọc nhiễu mang đến kết quả tệ hơn rất nhiều so với mô hình gốc.

CHƯƠNG 5 KẾT LUẬN KIẾN NGHỊ

5.1 Kết luận

Dựa trên đánh giá kết quả thực nghiệm nghiên cứu trên mô hình trên tập dữ liệu chỉ số của thị trường chứng khoán VN-Index trong khoảng thời gian 10 năm từ ngày 1/10/2015 cho đến 1/10/2025, khóa luận này đã có thể trả lời các câu hỏi nghiên cứu được đặt ra từ chương đầu tiên.

Trả lời cho câu hỏi: “: Phương pháp lọc nhiễu được sử dụng trong nghiên cứu có mang đến sự cải thiện cho các mô hình học máy được chọn hay không?”

Dựa vào dữ liệu huấn luyện đã qua lọc nhiễu cho thấy kết quả không thay đổi quá lớn so với dữ liệu ban đầu bởi vì bản chất của kỹ thuật xử lý dữ liệu này chủ yếu làm mềm và mượt.

Dựa vào đánh giá kết quả huấn luyện và dự đoán trên chuỗi giá của chỉ số VN-Index:

Thứ nhất, về các mô hình LSTM và GRU khi thực nghiệm mô hình cho thấy GRU thể hiện tốt hơn LSTM cả khi lọc nhiễu và không lọc nhiễu trong cùng thông số đầu vào. Mô hình GRU cho kết quả RMSE là 14,36 còn LSTM là 15,399, R^2 của GRU cũng gần với một hơn là của LSTM (0,990075 so với 0,988587)

Thứ hai đối với mô hình có áp dụng kỹ thuật lọc nhiễu, kết quả của dự đoán cho thấy việc kết hợp DWT mang đến một số cải thiện rõ rệt. Hiệu suất mô hình lọc nhiễu phụ thuộc rất lớn vào các hàm wavelet mẹ và cả mức độ phân rã, trên cả hai mô hình thường xảy ra hai hiện tượng sau, cùng một hàm gốc khi tăng độ phân rã từ một lên hai thì càng cải thiện mô hình và ngược lại khi càng tăng độ phân rã thì kết quả càng tệ. Khi lọc nhiễu ở mức phân rã bằng một thì phần lớn hàm gốc cho kết quả đầu ra cải thiện đáng kể so với mô hình gốc trên cả GRU và LSTM. Lý do cho việc này là vì khi dữ liệu được lọc nhiễu ở mức phân rã một giữ lại được đa số các thông tin cần thiết để mô hình có thể học tốt hơn, còn ở mức hai lọc nhiễu quá mức khi làm lệch một số thông tin quan trọng.

Dựa vào đánh giá kết quả trên biến động tỉ suất của chỉ số VN-Index (log return)

Trên nghiên cứu thực nghiệm mô hình gốc, kết quả của LSTM lại vượt trội hơn GRU. Đầu ra của cả hai mô hình đều thể hiện giá trị khi dự đoán trên dữ liệu biến động quanh 0 này, MSE của LSTM và GRU lần lượt là 0,000152 và 0,00016. Trái ngược với kết quả khả quan của các mô hình kết hợp trên chỉ số đóng cửa của VN-Index, áp dụng lọc nhiễu vào xử lý tiền dữ liệu trên biến động tỉ suất log return mang đến kết quả không mong muốn, hệ số đánh giá R^2 của cả hai mô hình nghiêng hẳn về giá trị âm cho thấy độ lệch quá lớn. Thông qua đánh giá đồ thị cũng có thể thấy kết quả dự đoán trên log return nhảy loạn, một số đoạn dày và biến động mạnh hơn cả cho thấy mô hình đã học quá mức làm sai hoàn toàn dự đoán. Nghiên cứu thực nghiệm cũng đã làm rõ lưu ý được nhắc đến ở chương hai khi lọc nhiễu sẽ xóa quá nhiều các thông tin quan trọng, tạo xu hướng giả khiến mô hình chỉ nhớ thay vì học hiệu quả.

5.2 Hạn chế và các hướng nghiên cứu tiếp theo

Mặc dù nghiên cứu đã đạt được những kết quả khả quan trong việc so sánh hiệu suất các mô hình học sâu và kỹ thuật xử lý tín hiệu, đề tài vẫn tồn tại một số hạn chế nhất định cần được nhìn nhận khách quan.

5.2.1. Hạn chế của nghiên cứu

Thứ nhất, hạn chế về dữ liệu đầu vào: Nghiên cứu hiện tại chỉ tập trung khai thác dữ liệu chuỗi thời gian đơn biến, cụ thể là sử dụng lịch sử giá đóng cửa và tỷ suất sinh lợi của VN-Index để dự báo tương lai. Trong thực tế, thị trường chứng khoán chịu tác động của rất nhiều yếu tố ngoại sinh phức tạp mà mô hình chưa bao quát hết, bao gồm: Các chỉ số kinh tế vĩ mô (lãi suất, lạm phát, tỷ giá hối đoái, tăng trưởng GDP). Tâm lý nhà đầu tư và tin tức thị trường.

Biến động của các thị trường tài chính lớn trên thế giới (như Dow Jones, S&P 500). Việc chỉ dựa vào dữ liệu quá khứ có thể dẫn đến việc mô hình bị trễ pha hoặc phản ứng chậm trước các cú sốc thông tin bất ngờ.

Thứ hai, hạn chế về phạm vi nghiên cứu: Đề tài mới chỉ thực hiện thực nghiệm trên chỉ số chung VN-Index đại diện cho thị trường chứng khoán Việt Nam. Kết quả

ngiên cứu chưa được kiểm chứng rộng rãi trên các mã cổ phiếu riêng lẻ vốn có độ biến động cao hơn nhiều so với chỉ số thị trường hoặc các chỉ số ngành cụ thể. Do đó, khả năng tổng quát hóa của mô hình đối với các loại tài sản tài chính khác vẫn cần được kiểm định thêm.

Thứ ba, hạn chế về tối ưu hóa tham số kỹ thuật: Trong phạm vi nghiên cứu, việc lựa chọn các họ sóng Wavelet (Haar, db, sym, coif) và các siêu tham số (hyperparameters) của mạng LSTM/GRU chủ yếu dựa trên thử nghiệm thực nghiệm và tham khảo các nghiên cứu đi trước. Nghiên cứu chưa áp dụng các thuật toán tối ưu hóa tự động nâng cao (như Genetic Algorithm hay Bayesian Optimization) để tìm ra bộ tham số tối ưu nhất một cách toàn diện.

5.2.2. Các hướng nghiên cứu tiếp theo

Để khắc phục các hạn chế nêu trên và nâng cao tính ứng dụng thực tiễn của mô hình, các hướng nghiên cứu tiếp theo có thể được triển khai như sau:

Một là, mở rộng dữ liệu đầu vào theo hướng đa biến (Multivariate Analysis): Nghiên cứu tương lai nên tích hợp thêm các biến số kinh tế vĩ mô và các chỉ báo phân tích kỹ thuật vào làm đầu vào cho mô hình. Đặc biệt, việc kết hợp kỹ thuật Xử lý ngôn ngữ tự nhiên để phân tích cảm xúc tin tức (Sentiment Analysis) từ các trang báo tài chính hoặc mạng xã hội sẽ giúp mô hình nắm bắt tốt hơn tâm lý đám đông, từ đó cải thiện khả năng dự báo các điểm đảo chiều của thị trường.

Hai là, ứng dụng các kiến trúc mô hình tiên tiến hơn: Bên cạnh LSTM và GRU, các nghiên cứu tiếp theo có thể thử nghiệm các kiến trúc Deep Learning hiện đại hơn như cơ chế chú ý (Attention Mechanism) hoặc mô hình Transformer. Cơ chế Attention cho phép mô hình tập trung vào các khoảng thời gian quan trọng trong quá khứ có ảnh hưởng lớn đến hiện tại, giúp giải quyết tốt hơn vấn đề phụ thuộc xa mà LSTM/GRU đôi khi vẫn gặp khó khăn. Ngoài ra, mô hình lai kết hợp CNN (để trích xuất đặc trưng) và LSTM/GRU (để học chuỗi thời gian) cũng là một hướng đi tiềm năng.

Ba là, xây dựng chiến lược giao dịch thực nghiệm. Thay vì chỉ dừng lại ở việc dự báo giá trị số học, hướng phát triển tiếp theo có thể tập trung vào bài toán phân loại

xu hướng để xây dựng các tín hiệu giao dịch tự động. Việc đánh giá hiệu quả mô hình thông qua lợi nhuận giả lập có tính đến phí giao dịch và quản trị rủi ro sẽ mang lại ý nghĩa thực tiễn cao hơn cho các nhà đầu tư.

KẾT LUẬN CHƯƠNG 5

Chương cuối cùng của khóa luận trả lời cho các vấn đề được đặt ra. Ứng dụng lọc nhiễu kết hợp các mô hình học sâu đã thực sự cải thiện được hiệu suất mô hình, ngoài kết quả tốt ta cũng có thất bại đáng ghi nhận khi thực nghiệm trên chuỗi biến động tỉ suất log return khi lọc nhiễu làm mô hình tệ hơn so với mô hình gốc rất nhiều. Song với việc trả lời câu hỏi nghiên cứu, chương cũng đã chỉ ra những điểm yếu vốn có của nghiên cứu này đồng thời cũng vạch ra hướng đi phát triển đề tài và các nghiên cứu khác sau này.

TÀI LIỆU THAM KHẢO

1. Alrumaih, R. M. & Al-Fawzan, M. A., 2002. Time series forecasting using wavelet denoising an application to saudi stock index.. *Journal of King Saud University-Engineering Sciences*.
2. Bergstra, J. & Bengio, Y., 2012. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, Issue 13, p. 281–305..
3. Bishop, C. M., 2006. Pattern Recognition and Machine Learning. *Springer*.
4. Bollerslev, T., 1986. Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*..
5. Campbell, J. Y., Lo, A. W. & MacKinlay, A. C., 1997. The Econometrics of Financial Markets. *Princeton University Press*.
6. Cho, K. et al., 2014. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. *arXiv:1406.1078*..
7. Chung, J., Gulcehre, C., Cho, K. & Bengio, Y., 2014. Empirical evaluation of gated recurrent neural networks on sequence modeling. *NIPS Workshop*.
8. Daubechies, I., 1992. Ten Lectures on Wavelets. *SIAM*.
9. Dietterich, T. G., 2000. Ensemble methods in machine learning. *International Workshop on Multiple Classifier Systems*.
10. Donoho, D. L. & Johnstone, I. M., 1994. Ideal spatial adaptation by wavelet shrinkage. *Biometrika*.
11. Dương, T. T. T., 2023. Dự báo chiều biến động của chỉ số chứng khoán bằng thuật toán tăng cường. *Journal of Economic and Banking Studies - JEBS*.
12. Engle, R. F., 1982. Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*..
13. Fama, E. F., 1970. Efficient market hypothesis: A review of theory and empirical work. *Journal of Finance*, 25(2), pp. 28-30.

14. Fischer, T. & Krauss, C., 2018. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), p. 654–669..
15. Gençay, R., Selçuk, F. & Whitcher, B., 2001. An Introduction to Wavelets and Other Filtering Methods in Finance and Economics. *Academic Press*.
16. Gers, F. A., Schmidhuber, J. & Cummins, F., 2000. Learning to forget: Continual prediction with LSTM. *Neural Computation*, 12(10), p. 2451–2471.
17. Goodfellow, I., Bengio, Y. & Courville, A., 2016. Deep Learning. *MIT Press*.
18. Hastie, T., Tibshirani, R. & Friedman, J., 2009. The Elements of Statistical Learning. *Springer*.
19. Hochreiter, S. & Schmidhuber, J., 1997. Long Short-Term Memory. *Neural Computation*.
20. Hyndman, R. J. & Athanasopoulos, G., 2018. *Forecasting: Principles and Practice*.. s.l.:Otexts.
21. Jarrah, M., 2024. Long Short-Term Memory and Discrete Wavelet Transform based Univariate Stock Market Prediction Model. *Journal of Information and Organizational Sciences*.
22. Jothimani, D., Shankar, R. & Yadav, S. S., 2016. Discrete wavelet transform-based prediction of stock index: A study on national stock exchange fifty index. *arXiv preprint arXiv:1605.07278*..
23. Kahneman, D. & Tversky, A., 1979. Prospect Theory: An Analysis of Decision Under Risk. *Econometrica*.
24. Khadem, S., Liu, X. & Amini, M., 2020. Financial time-series forecasting using wavelet transforms and deep neural networks. *Expert Systems with Applications*.
25. Kingma, D. P. & Ba, J., 2014. Adam: A Method for Stochastic Optimization. *arXiv:1412.6980*..
26. Kuhn, M. & Johnson, K., 2013. Applied Predictive Modeling. *Springer*.

27. Liang, X. et al., 2019. LSTM with wavelet transform based data preprocessing for stock price prediction. *Mathematical Problems in Engineering*.
28. Li, J. C., Sun, L. P., Wu, X. & Tao, C., 2025. Enhancing financial time series forecasting with hybrid Deep Learning: CEEMDAN-Informer-LSTM model. *Applied Soft Computing*.
29. Li, Z. & Tam, V., 2017. Combining the real-time wavelet denoising and long-short-term-memory neural network for predicting stock indexes. *IEEE Symposium Series on Computational Intelligence (SSCI)*.
30. Mallat, S., 1989. A Theory for Multiresolution Signal Decomposition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*..
31. Mallat, S., 1999. A Wavelet Tour of Signal Processing. *Academic Press*.
32. Mitchell, T. M., 1997. 1.Does Machine Learning Really Work. *Ai Magazine*.
33. Oanh, Đ. L. K. & Châu, N. T. M., 2024. Dự báo chứng khoán bằng học máy: Bằng chứng thực nghiệm trên thị trường chứng khoán Việt Nam. *Tạp chí Kinh tế và Dự báo*.
34. Prechelt, L., 1998. Early Stopping — But When? In Neural Networks: Tricks of the Trade. *Springer*.
35. Qiu, J., Wang, B. & Zhou, C., 2020. Forecasting stock prices with long-short term memory neural network based on attention mechanism. *PloS one*.
36. Sutton, R. S. & Barto, A. G., 2018. Reinforcement Learning: An Introduction. *MIT Press*.
37. Tang, Q. et al., 2021. Prediction of financial time series based on LSTM using wavelet transform and singular spectrum analysis. *Mathematical Problems in Engineering*.
38. Tu, T. D. & Bahagawan, N., 2023. Predicting Stock Market Trends in Vietnam Using SVM, XGBoost, and LSTM Architectures. *The MIC ICT Research Journal*.


39. Tuyen, T. Đ., 2024. Đánh giá hiệu suất mô hình phức hợp LSTM-GRU: nghiên cứu điển hình về dự báo chỉ số đo lường xu hướng biến động giá cổ phiếu trên sàn giao dịch chứng khoán Hồ Chí Minh. *Can Tho University Journal of Science*.
40. Uyen, N. H. D. & Huyen., N. T. T., 2014. Ứng dụng Mô hình ARIMA Trong dự báo chỉ số VN-INDEX.. *Tạp Chí Khoa học Và Công nghệ - Đại học Đà Nẵng*.
41. Van Horne, J. C. & Parker, G. G., 1967. The random-walk theory: an empirical test. *Financial analysts journal*, 23(6), pp. 87-92.
42. Wang, P. C. & Vo, T. T. H., 2025. Stock price prediction based on dual important indicators using ARIMAX: A case study in Vietnam. *Journal of Intelligent Systems*.
43. Wu, D., Wang, X. & Wu, S., 2022. A hybrid framework based on extreme learning machine, discrete wavelet transform, and autoencoder with feature penalty for stock prediction. *Expert Systems with Applications*.
44. Zhang, G. P., 2003. Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, Volume 50, p. 159–175..
45. Zhang, Y., Aggarwal, C. & Qi, G., 2017. Stock price prediction via recurrent neural networks with GRU cells. *IEEE*.
46. Ziółkowski, K. & Wieceżyński, P., 2025. Enhancing financial time series forecasting: a comparative study of discrete wavelet transform and LSTM models for selected global indices. *Quality & Quantity*.

PHỤ LỤC

Kết quả lọc nhiễu

Mức phân rã 1

Haar



Db2



Db4



Sym4




Sym6



Coif1




Coif3




Phân rã mức 2

Haar




Db2




db4




Sym4




Sym6



Coif1




Coif3




Kết quả của DWT+LSTM

Phân rã mức 1


haar




Db2




Db4




Sym4




Sym6



Coif1




Coif3



Phân rã mức 2


Haar




Db2




Db4




Sym4




Sym6



Coif1




Coif3




Kết quả của DWT+GRU

Phân rã mức 1

Haar



Db2



Db4



Sym4




Sym6



Coif1




Coif3




Phân rã mức 2


Haar



Db2



Db4




sym4




Sym6



coif1



Coif3



Mô hình DWT+LSTM

https://colab.research.google.com/drive/1OA0T3qYMVBLIUyVgXitfuE459DCZcn1?usp=drive_link

Mô hình DWT+GRU

https://colab.research.google.com/drive/1UU13I1bk26ZflvZx9-OsoBqDLIitoOcx#scrollTo=WfFZ_FgVGSzD

Dữ liệu đã xử lý

<https://drive.google.com/file/d/15WIBDES-rgm-M1Rt94zVKQEUInClGla8/view?usp=sharing>

Dữ liệu gốc

<https://docs.google.com/spreadsheets/d/1qNILOQAkFn08xDYokJILD3jxPmKRJbRG/edit?usp=sharing&ouid=108146432743743259627&rtpof=true&sd=true>