

BỘ GIÁO DỤC VÀ ĐÀO TẠO

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM

TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



**KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC**

**TỐI ƯU HÓA DANH MỤC ĐẦU TƯ CỔ PHIẾU: TIẾP CẬN
THEO MÔ HÌNH KẾT HỢP LSTM – GRU**

NGÀNH: TÀI CHÍNH - NGÂN HÀNG

MÃ SỐ: 7340201

NGUYỄN HUỲNH ĐIỂM MY

TP. HỒ CHÍ MINH, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

TỐI ƯU HÓA DANH MỤC ĐẦU TƯ CỔ PHIẾU: TIẾP CẬN
THEO MÔ HÌNH KẾT HỢP LSTM - GRU

NGÀNH: TÀI CHÍNH - NGÂN HÀNG

MÃ SỐ: 7340201

Họ và tên sinh viên: NGUYỄN HUỲNH DIỄM MY

Mã số sinh viên: 050610221087

Lớp sinh hoạt: HQ10 - GE27

NGƯỜI HƯỚNG DẪN KHOA HỌC

PGS. TS. NGUYỄN MINH NHẬT

TP. HỒ CHÍ MINH, NĂM 2026

TÓM TẮT

Sự phát triển mạnh mẽ của công nghệ tài chính cùng những biến động khó lường của thị trường chứng khoán đã đặt công tác quản trị rủi ro và phân bổ tài sản trước sức ép vô cùng lớn. Trong bối cảnh đó, việc củng cố năng lực dự báo và tối ưu hóa hiệu suất sinh lời thông qua trí tuệ nhân tạo được xem là định hướng cốt lõi, quyết định trực tiếp đến khả năng sinh tồn cũng như định hướng tăng trưởng dài hạn của các nhà đầu tư. Xuất phát từ thực tiễn nêu trên, nghiên cứu này được thực hiện nhằm mục tiêu đo lường và đánh giá chuyên sâu về: ***“Tối ưu hóa danh mục đầu tư cổ phiếu: tiếp cận theo mô hình kết hợp LSTM - GRU”***. Để giải quyết mục tiêu này, bài nghiên cứu tiến hành thu thập, khai thác và xử lý thực nghiệm bộ dữ liệu lịch sử được trích xuất từ các mã cổ phiếu thép niêm yết trên thị trường trong giai đoạn 11 năm, từ 2015 đến 2025.

Về mặt phương pháp luận, bài nghiên cứu sử dụng kiến trúc mạng nơ-ron hồi quy lai (LSTM-GRU) làm thước đo đại diện cho năng lực nhận diện quy luật thị trường, kết hợp với chỉ số Sharpe để đánh giá hiệu quả hoạt động. Đồng thời, mô hình nghiên cứu cũng tích hợp bộ biến đầu vào đa chiều bao gồm: độ biến động (Volatility), động lượng (Momentum), chỉ số sức mạnh tương đối (RSI) và tỷ lệ trung bình động (MA). Quá trình phân tích được thực hiện dựa trên việc thiết kế hàm mất mát chuyên biệt (Sharpe Loss), và đặc biệt ứng dụng ràng buộc entropy như một giải pháp xử lý các vi phạm về tập trung rủi ro, từ đó củng cố độ chuẩn xác và tính đa dạng hóa vững chắc cho bộ kết quả phân bổ trọng số.

Bằng chứng thực nghiệm chỉ ra rằng, hệ thống học sâu đóng vai trò như một động lực tích cực góp phần gia tăng hiệu suất sinh lời cho danh mục đầu tư, đặc biệt khi có sự cộng hưởng từ khả năng thích ứng linh hoạt với môi trường kinh tế vĩ mô thuận lợi. Ở chiều ngược lại, các quy tắc quản trị thụ động truyền thống tạo ra rào cản tiêu cực đến hiệu quả kinh doanh, trong khi đó sự can thiệp của thuật toán AI lại cho thấy sự tác động tích cực và vượt trội. Cụ thể, chiến lược phân bổ động từ mô hình LSTM-GRU đạt lợi

nhuận trung bình 59.61% với hệ số Sharpe 4.06, hoàn toàn đánh bại chiến lược phân bổ đều (Equal Weight) và chiến lược 80-20.

Từ những phát hiện nêu trên, khóa luận không chỉ góp phần làm phong phú thêm hệ thống văn liệu học thuật về lĩnh vực công nghệ tài chính tại Việt Nam, mà còn cung cấp những hàm ý thực tiễn giá trị. Đây sẽ là cơ sở khoa học quan trọng giúp các nhà đầu tư cá nhân và cơ quan quản lý quỹ hoạch định chiến lược giao dịch sắc bén, kiểm soát rủi ro hiệu quả, hướng tới mục tiêu tăng trưởng bền vững trong bối cảnh thị trường ngày càng biến động khốc liệt.

Từ khóa: Tối ưu hóa danh mục, Học sâu, Mạng nơ-ron lai (LSTM-GRU), Cổ phiếu ngành thép, Hệ số Sharpe.

ABSTRACT

The robust development of financial technology, coupled with the unpredictable volatility of the stock market, has placed immense pressure on risk management and asset allocation. In this context, strengthening forecasting capabilities and optimizing investment performance through artificial intelligence is considered a core orientation, directly determining the survival and long-term growth trajectory of investors. Stemming from the aforementioned reality, this study is conducted to measure and deeply evaluate: ***"Stock portfolio optimization: An approach based on the combined LSTM - GRU model"***. To achieve this objective, the research collects, extracts, and empirically processes a historical dataset of listed steel stocks in the market over a 10-year period, from 2015 to 2025.

Methodologically, the study utilizes a hybrid recurrent neural network architecture (LSTM-GRU) as a proxy for the ability to identify market patterns, combined with the Sharpe ratio to evaluate operational performance. Simultaneously, the research model integrates a multidimensional set of input variables, including Volatility, Momentum, Relative Strength Index (RSI), and Moving Average (MA) ratios. The analysis process is conducted based on the design of a specialized loss function (Sharpe Loss), and notably applies an entropy penalty as a solution to handle risk concentration violations, thereby reinforcing the accuracy and robust diversification of the weight allocation results.

Empirical evidence indicates that the deep learning system acts as a positive driver contributing to the enhancement of portfolio returns, particularly when resonating with its ability to flexibly adapt to a favorable macroeconomic environment. Conversely, traditional passive management rules create negative barriers to investment performance, whereas AI algorithmic intervention demonstrates a positive and superior impact. Specifically, the dynamic allocation strategy from the LSTM-GRU model achieved an average return of 59.61% with a Sharpe ratio of 4.06, completely outperforming the Equal Weight strategy and the 80-20 allocation strategy.

From the above findings, the thesis not only contributes to enriching the academic literature on financial technology in Vietnam but also provides valuable practical implications. This will serve as an important scientific basis helping individual investors and fund management agencies formulate sharp trading strategies, effectively control risks, and aim for sustainable growth in an increasingly volatile market.

Keywords: Portfolio optimization, Deep Learning, Hybrid neural network (LSTM-GRU), Steel stocks, Sharpe Ratio.

LỜI CAM ĐOAN

Tôi xin cam đoan đề tài khóa luận tốt nghiệp: “Tối ưu hóa danh mục đầu tư cổ phiếu: tiếp cận theo mô hình kết hợp LSTM - GRU” là công trình nghiên cứu độc lập do chính cá nhân tôi thực hiện, dưới sự hướng dẫn khoa học tận tình của PGS. TS. Nguyễn Minh Nhật.

Tôi xin khẳng định mọi số liệu, kết quả phân tích và nội dung được trình bày trong khóa luận này là hoàn toàn trung thực, khách quan và chưa từng được công bố trong bất kỳ công trình nghiên cứu nào khác. Tất cả các tài liệu tham khảo, số liệu thứ cấp, cũng như các luận điểm kế thừa từ các đơn vị, tổ chức và các nhà nghiên cứu đi trước đều được tôi ghi nhận xuất xứ rõ ràng, minh bạch và tuân thủ nghiêm ngặt các quy chuẩn về trích dẫn học thuật, nhằm đảm bảo tính thuận tiện cho công tác tra cứu và kiểm chứng.

Tôi xin chịu hoàn toàn trách nhiệm trước Hội đồng đánh giá và nhà trường về tính trung thực của công trình nghiên cứu này.

TP. HCM, ngày.....tháng.....năm 202...

Tác giả

(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Để hoàn thành được khóa luận tốt nghiệp này, trước tiên em xin gửi lời tri ân sâu sắc và chân thành nhất đến PGS. TS. Nguyễn Minh Nhật - người đã trực tiếp hướng dẫn em. Trong suốt quá trình thực hiện đề tài, đặc biệt là khi tiếp cận một lĩnh vực đòi hỏi sự kết hợp phức tạp giữa phân tích tài chính và kỹ thuật mô hình hóa, em đã may mắn nhận được sự tận tâm chỉ bảo và định hướng khoa học quý báu từ thầy. Sự nhiệt huyết và bao dung của thầy đã truyền cho em nguồn động lực to lớn để trau dồi tư duy và hoàn thiện kỹ năng nghiên cứu.

Bên cạnh đó, em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu cùng toàn thể quý thầy cô giảng viên tại Trường Đại học Ngân hàng TP. Hồ Chí Minh, đặc biệt là các thầy cô thuộc Khoa Tài chính - Ngân hàng. Những nền tảng kiến thức chuyên ngành vững chắc mà quý thầy cô đã dày công truyền đạt trong suốt những năm tháng trên giảng đường chính là hành trang quan trọng nhất, giúp em có đủ cơ sở lý luận để vận dụng vào quá trình hoàn thành bài khóa luận này.

Mặc dù đã nỗ lực hết mình và dành trọn tâm huyết, song do những giới hạn nhất định về mặt thời gian cũng như kinh nghiệm nghiên cứu thực chứng chưa thực sự dày dặn, bài khóa luận của em chắc chắn sẽ không tránh khỏi những thiếu sót. Em rất mong mọi và trân trọng đón nhận những ý kiến đóng góp, nhận xét từ quý thầy cô trong Hội đồng đánh giá để bài nghiên cứu được hoàn thiện và đạt chất lượng tốt nhất.

Sau cùng, em kính chúc toàn thể thầy cô luôn dồi dào sức khỏe, tràn đầy năng lượng và gặt hái được thêm nhiều thành tựu rực rỡ trong sự nghiệp “trồng người” cũng như trên con đường nghiên cứu khoa học. Một lần nữa, em xin gửi lời tri ân sâu sắc nhất!

Em xin trân trọng cảm ơn!

MỤC LỤC

TÓM TẮT	i
ABSTRACT	iii
LỜI CAM ĐOAN	v
LỜI CẢM ƠN	vi
DANH MỤC TỪ VIẾT TẮT.....	x
DANH MỤC HÌNH.....	xii
DANH MỤC BẢNG.....	xii
CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI	1
1.1. Tính cấp thiết của đề tài	1
1.2. Mục tiêu nghiên cứu	3
1.3. Câu hỏi nghiên cứu	3
1.4. Đối tượng và phạm vi nghiên cứu	4
1.5. Phương pháp nghiên cứu	5
1.6. Ý nghĩa nghiên cứu.....	6
1.7. Kết cấu của nghiên cứu.....	6
TÓM TẮT CHƯƠNG 1.....	8
CHƯƠNG 2. CƠ SỞ LÝ LUẬN VÀ LƯỢC KHẢO NGHIÊN CỨU TRƯỚC	9
2.1 Các khái niệm liên quan.....	9
2.1.1 Khái niệm về danh mục đầu tư.....	9
2.1.2. Khái niệm về học máy	10
2.1.3. Khái niệm về học sâu	11
2.2. Các lý thuyết về danh mục đầu tư.....	12

2.2.1. Lý thuyết danh mục đầu tư hiện đại (Modern Portfolio Theory - MPT)	12
2.2.2. Lý thuyết hành vi trong tài chính (Behaviora Finance Theory).....	14
2.2.3. Lý thuyết phân bổ tài sản động (Dynamic Asset Allocation - DAA)	16
2.3. Tổng quan các nghiên cứu liên quan	17
2.3.1. Các nghiên cứu trong nước.....	17
2.3.2. Các nghiên cứu ngoài nước	19
2.3.3. Tổng hợp các nghiên cứu trước.....	21
2.4. Khoảng trống nghiên cứu.....	25
TÓM TẮT CHƯƠNG 2.....	28
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU	29
3.1. Quy trình thực hiện nghiên cứu	29
3.2. Các thuật toán học máy ứng dụng.....	32
3.2.1. Khái quát về mạng Trí nhớ ngắn hạn dài hạn (Long Short - Term Memory - LSTM).....	32
3.2.2. Khái quát về mạng Hồi quy đơn vị cổng (Gated Recurrent Unit - GRU).....	36
3.2.3. Khái quát về cấu trúc kết hợp LSTM - GRU.	38
3.3. Các hàm sử dụng trong kiến trúc mô hình.....	39
3.3.1. Hàm kích hoạt Tanh (Hyperbolic Tangent)	39
3.3.2. Hàm kích hoạt Sigmoid	40
3.3.3. Hàm mục tiêu.....	41
3.4. Thuật toán tối ưu hóa Adam	43
3.5. Dữ liệu nghiên cứu.....	47
3.6. Phương pháp xây dựng App lựa chọn danh mục đầu tư.....	48

TÓM TẮT CHƯƠNG 3.....	49
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU.....	50
4.1. Tiền xử lý dữ liệu.....	50
4.2. Cấu trúc và các siêu tham số của mô hình.....	52
4.2.1. Cấu trúc của mô hình.....	52
4.2.2. Các siêu tham số huấn luyện.....	52
4.3. Quy trình huấn luyện và tối ưu hóa mô hình học sâu.....	53
4.4. Đánh giá và so sánh hiệu quả các chiến lược đầu tư.....	54
4.5. Phát triển ứng dụng hỗ trợ lựa chọn danh mục đầu tư.....	57
TÓM TẮT CHƯƠNG 4.....	60
CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ QUY TRÌNH ÁP DỤNG.....	60
5.1. Kết luận.....	60
5.2. Khuyến nghị quy trình áp dụng.....	61
5.3. Hạn chế của đề tài và hướng nghiên cứu tiếp theo.....	63
TÓM TẮT CHƯƠNG 5.....	64
MỤC LỤC THAM KHẢO.....	65
Phụ lục.....	67

DANH MỤC TỪ VIẾT TẮT

Chữ viết tắt	Tên đầy đủ
Adam	Ước lượng động lượng thích nghi (Adaptive Moment Estimation)
AI	Trí tuệ nhân tạo (Artificial Intelligence)
CAPM	Mô hình định giá tài sản vốn (Capital Asset Pricing Model)
CNN	Mạng nơ-ron tích chập (Convolutional Neural Network)
DAA	Phân bổ tài sản động (Dynamic Asset Allocation)
DDPG	Deep Deterministic Policy Gradient
DL	Học sâu (Deep Learning)
ETF	Quỹ hoán đổi danh mục (Exchange Traded Fund)
GRU	Mạng hồi quy đơn vị cổng (Gated Recurrent Unit)
HNX	Sở Giao dịch Chứng khoán Hà Nội (Hanoi Stock Exchange)
HOSE	Sở Giao dịch Chứng khoán Thành phố Hồ Chí Minh (Ho Chi Minh City Stock Exchange)

LSTM	Trí nhớ ngắn hạn dài hạn (Long Short-Term Memory)
MA	Tỷ lệ trung bình động (Moving Average)
MAE	Sai số tuyệt đối trung bình (Mean Absolute Error)
MPT	Lý thuyết danh mục đầu tư hiện đại (Modern Portfolio Theory)
NLP	Xử lý ngôn ngữ tự nhiên (Natural Language Processing)
RL	Học tăng cường (Reinforcement Learning)
RMSE	Căn bậc hai sai số bình phương trung bình (Root Mean Square Error)
RNN	Mạng nơ-ron hồi quy (Recurrent Neural Network)
RSI	Chỉ số sức mạnh tương đối (Relative Strength Index)
TTCK	Thị trường chứng khoán
VSA	Hiệp hội Thép Việt Nam
VSDC	Tổng công ty Lưu ký và Bù trừ Chứng khoán Việt Nam

DANH MỤC HÌNH

Hình 3. 1. Quy trình thực hiện nghiên cứu	29
Hình 3. 2. Mô đun của mạng RNN chuẩn R. Zhang et al., (2023).....	33
Hình 3. 3. Mô đun của mạng LSTM chuẩn R. Zhang et al., (2023).....	34
Hình 3. 4. Cấu trúc mạng GRU tiêu chuẩn (Zhang et al., 2023).....	37
Hình 5.1. Quy trình áp dụng mô hình học sâu.....	62
Hình 4. 1. Danh mục 10 cổ phiếu có Sharpe Ratio cao nhất	51
Hình 4. 2. Biểu đồ khối phân bố tỷ trọng của danh mục đầu tư.....	54
Hình 4. 3. So sánh mức độ hiệu quả của mô hình	55
Hình 4. 4. Kết quả lợi nhuận kỳ vọng, độ lệch chuẩn và Sharpe của danh mục	56
Hình 4. 5. Giao diện chính của app	Error! Bookmark not defined.
Hình 4. 6. Kết quả tính toán trên app.....	59
Hình 4. 7. Mã QR App Xây dựng danh mục đầu tư tối ưu bằng mô hình LSTM-GRU	Error! Bookmark not defined.
Hình 5. 1. Quy trình áp dụng mô hình học sâu.....	62

DANH MỤC BẢNG

Bảng 2.1. Tổng hợp các nghiên cứu liên quan	21
Bảng 4. 2. Cấu trúc mô hình LSTM - GRU	52
Bảng 4. 3. Bộ siêu tham số của mô hình LSTM - GRU	52

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1. Tính cấp thiết của đề tài

Trong bối cảnh hội nhập quốc tế ngày càng sâu rộng, thị trường chứng khoán (TTCK) Việt Nam đã xác lập vai trò là một trong những cột trụ huy động vốn quan trọng nhất của nền kinh tế, thu hút sự quan tâm mạnh mẽ từ đông đảo công chúng. Tốc độ phổ cập chứng khoán trong những năm gần đây ghi nhận những con số tăng trưởng ấn tượng. Theo thống kê từ Tổng công ty Lưu ký và Bù trừ Chứng khoán Việt Nam (VSDC), tính đến thời điểm cuối năm 2025, tổng số lượng tài khoản giao dịch đã đạt ngưỡng xấp xỉ 11,9 triệu, chiếm khoảng 11% quy mô dân số. Đáng chú ý, chỉ trong vòng 12 tháng của năm 2025, thị trường đã tiếp nhận thêm gần 2,6 triệu tài khoản mới, giúp Việt Nam về đích sớm hơn dự kiến so với kế hoạch phát triển mà Chính phủ đã đề ra cho tầm nhìn 2030. Những chỉ dấu này cho thấy một bước chuyển mình rõ rệt: chứng khoán không còn là sân chơi dành riêng cho các định chế tài chính chuyên nghiệp, mà đã trở thành phương thức tích lũy tài sản và đầu tư thiết yếu của mọi tầng lớp dân cư.

Mặc dù có sự bứt phá về quy mô, TTCK Việt Nam vẫn giữ nguyên các đặc thù của một thị trường cận biên, nơi mà sự biến động của giá cổ phiếu thường chịu áp lực tổng hòa từ các biến số vĩ mô, tâm lý đám đông và sự thay đổi trong các chính sách quản lý nhà nước. Trong đó, ngành Thép đóng vai trò là một minh chứng điển hình cho tính chu kỳ cực kỳ đậm nét. Nhóm cổ phiếu nguyên vật liệu cơ bản này có độ nhạy bén cao với các chỉ số như tốc độ tăng trưởng GDP, tiến độ giải ngân đầu tư công, đà phục hồi của phân khúc bất động sản và sự biến động khó lường của giá nguyên vật liệu trên thế giới. Theo báo cáo của Hiệp hội Thép Việt Nam (VSA, 2025) chỉ ra rằng, song song với việc tháo gỡ các rào cản pháp lý cho các dự án hạ tầng lớn, ngành Thép sẽ tiếp tục duy trì vị thế là "mạch máu" quan trọng, đóng góp trực tiếp vào quá trình phục hồi chung của toàn bộ nền kinh tế quốc gia.

Thêm vào đó, đặc tính biến động mạnh về giá của các mã cổ phiếu ngành thép - hệ quả từ độ trễ trong quản trị hàng tồn kho và sự nhạy cảm đặc biệt với các tin tức vĩ mô - đã vô hình trung tạo ra một môi trường dữ liệu đầy thách thức. Đây chính là "phòng thí nghiệm" đặc thù để thử nghiệm và đánh giá hiệu năng của các thuật toán học sâu (Deep Learning). Việc triển khai những kiến trúc mạng nơ-ron hiện đại như LSTM hay GRU vào phân tích các chuỗi thời gian tài chính có độ nhiễu cao không đơn thuần là giải pháp công nghệ nhằm lấp sự thiếu hụt về công cụ tự động hóa tại Việt Nam. Xa hơn thế, phương pháp này còn khai mở những lộ trình mới trong việc tối ưu hóa lợi nhuận thông qua các chiến lược quản lý danh mục thích ứng động (adaptive portfolio strategies).

Sự cộng hưởng giữa làn sóng chuyển đổi số và những bước tiến đột phá của Trí tuệ nhân tạo (AI), trọng tâm là các mô hình học sâu như Long Short - Term Memory (LSTM) và Gated Recurrent Unit (GRU), đã thiết lập những chuẩn mực mới trong phân tích dự báo và quản trị đầu tư. Hàng loạt các công trình nghiên cứu học thuật quốc tế tiêu biểu (như:

Jang & Seong, 2023; Huang, 2018; Kim & Won, 2018) đã chứng minh khả năng vượt trội của học sâu trong việc giải mã các chuỗi dữ liệu dài hạn. Các thuật toán này có năng lực nhận diện chính xác những quy luật phi tuyến tính phức tạp, từ đó mang lại hiệu quả phân bổ nguồn vốn tối ưu hơn hẳn so với các mô hình lý thuyết tài chính cổ điển. Tuy nhiên, tại thị trường chứng khoán Việt Nam, việc ứng dụng các công nghệ tiên phong này vào bài toán thực tế về tối ưu hóa danh mục cổ phiếu vẫn còn khá sơ khai, mở ra một dư địa nghiên cứu lớn chưa được khai thác toàn diện.

Từ những khoảng trống nghiên cứu nêu trên, việc thiết lập và đánh giá thực nghiệm mô hình học sâu lai kết hợp LSTM - GRU dựa trên dữ liệu từ thị trường chứng khoán Việt Nam, với trọng tâm là các mã cổ phiếu ngành thép, mang lại những đóng góp quan trọng cả về mặt lý luận lẫn thực tiễn. Đề tài không dừng lại ở việc đề xuất một phương thức đầu tư tự động hóa có tính chính xác cao, mà còn làm phong phú thêm kho tàng các công cụ phân tích tài chính định lượng trong kỷ nguyên số. Đặc biệt, trong bối cảnh nền kinh tế quốc gia đang chuyển mình sang giai đoạn phục hồi tích cực, được thúc

đẩy bởi sự khởi sắc của thị trường bất động sản và các nỗ lực đẩy mạnh giải ngân đầu tư công, việc tối ưu hóa hiệu quả đầu tư cho nhóm ngành "xương sống" như thép càng chứng minh được giá trị thực tiễn và tính thời sự cấp thiết của nghiên cứu này.

1.2. Mục tiêu nghiên cứu

Mục tiêu tổng quát

Nghiên cứu tập trung xây dựng giải pháp tối ưu hóa danh mục đầu tư thông qua việc vận dụng các mô hình học sâu tiên tiến (LSTM - GRU), áp dụng cụ thể vào bộ dữ liệu thực tế của các doanh nghiệp thép đang niêm yết trên thị trường chứng khoán Việt Nam.

Mục tiêu cụ thể

Ứng dụng mô hình LSTM-GRU để tối ưu hóa phân bổ vốn cho danh mục cổ phiếu thép, kết hợp kiểm chứng lịch sử (backtesting) nhằm đối chiếu hiệu suất với chiến lược tỷ trọng đều và nguyên lý Pareto (80-20).

Xây dựng nền tảng ứng dụng (Application) hỗ trợ nhà đầu tư cá nhân trong việc theo dõi, quản lý và tự động hóa quy trình tối ưu danh mục dựa trên các tín hiệu dự báo từ kiến trúc học sâu.

Đề xuất khung quy trình vận hành các thuật toán học sâu trong việc sàng lọc cổ phiếu và quản trị danh mục đầu tư đặc thù cho thị trường Việt Nam, giúp các nhà đầu tư cá nhân và tổ chức tài chính dễ dàng ứng dụng phương pháp định lượng hiện đại để ra quyết định, loại bỏ rủi ro cảm xúc và tối ưu hóa hiệu suất sinh lời.

1.3. Câu hỏi nghiên cứu

1. Mô hình LSTM-GRU cải thiện hiệu suất đầu tư cổ phiếu thép ra sao so với các chiến lược truyền thống (phân bổ đều, 80 - 20)?

2. Giải pháp thiết kế ứng dụng (App) nào giúp nhà đầu tư cá nhân dễ dàng tự động hóa quy trình phân bổ vốn bằng học sâu?
3. Khung quy trình thực tiễn nào là phù hợp để ứng dụng trí tuệ nhân tạo vào quản trị danh mục tại thị trường Việt Nam?

1.4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu:

Trọng tâm nghiên cứu của đề tài tập trung vào việc phân tích và vận hành mô hình học sâu lai kết hợp LSTM - GRU, đồng thời đối chiếu hiệu quả với hai phương thức quản trị danh mục kinh điển là chiến lược phân bổ tỷ trọng đều và quy tắc 80 - 20 trong bài toán tối ưu hóa nguồn vốn đầu tư.

Phạm vi nghiên cứu:

Đề tài tập trung khảo sát chuyên sâu vào nhóm các mã cổ phiếu thuộc ngành Thép đang thực hiện niêm yết và giao dịch công khai trên thị trường chứng khoán Việt Nam. Việc lựa chọn ngành Thép xuất phát từ đặc tính chu kỳ mạnh mẽ và độ nhạy bén cao của nhóm ngành này trước các biến động vĩ mô, tạo ra một môi trường dữ liệu lý tưởng để kiểm chứng năng lực của các mô hình dự báo tiên tiến. Để phục vụ cho quá trình thực nghiệm, dữ liệu giao dịch lịch sử được trích xuất một cách hệ thống và liên tục trong giai đoạn 11 năm, kéo dài từ đầu năm 2015 đến hết năm 2025. Sau các bước sàng lọc và tiền xử lý nghiêm ngặt nhằm loại bỏ những mã cổ phiếu thiếu tính nhất quán hoặc bị gián đoạn dữ liệu, một danh mục gồm 10 doanh nghiệp đầu ngành đã được thiết lập để làm cơ sở xây dựng không gian mẫu cho thuật toán.

Nhằm đảm bảo tính khách quan và khả năng ứng dụng thực tế trong quản trị danh mục, phạm vi dữ liệu được phân tách một cách khoa học thành hai tập độc lập theo phương pháp kiểm chứng ngoài mẫu (Backtesting). Cụ thể, toàn bộ dữ liệu trong giai đoạn 2015 - 2024 được sử dụng làm tập huấn luyện (Train set), đóng vai trò giúp mô hình

học sâu nhận diện các quy luật biến động phức tạp và tinh chỉnh hệ số tham số một cách tối ưu. Trong khi đó, dữ liệu của năm 2025 được dành riêng làm tập kiểm tra độc lập (Out-of-sample Test set) để đánh giá năng lực thích ứng thực tế của hệ thống.

1.5. Phương pháp nghiên cứu

Nghiên cứu được triển khai dựa trên phương pháp định lượng với trọng tâm là việc ứng dụng các cấu trúc mạng nơ-ron học sâu để giải quyết bài toán phân tỷ trọng một cách tối ưu. Quy trình thực nghiệm bắt đầu bằng việc trích xuất và đồng bộ hóa chuỗi dữ liệu giá đóng cửa lịch sử của các mã cổ phiếu ngành thép thông qua nền tảng dữ liệu của Công ty Cổ phần Chứng khoán KB Việt Nam. Nhằm thiết lập một không gian dữ liệu đầu vào chất lượng, bộ lọc Sharpe Ratio được kích hoạt để sàng lọc ra 10 doanh nghiệp có hiệu suất sinh lời và quản trị rủi ro tốt nhất. Trọng tâm của nghiên cứu nằm ở việc thiết lập và huấn luyện mô hình lai kết hợp giữa LSTM và GRU, hỗ trợ dự báo chính xác các biến số về lợi nhuận kỳ vọng cũng như ma trận hiệp phương sai, từ đó trích xuất ra vector trọng số vốn lý tưởng cho danh mục đầu tư.

Để nâng cao độ chính xác và ngăn chặn hiện tượng học quá mức (overfitting), quá trình thực nghiệm đi kèm với kỹ thuật tinh chỉnh siêu tham số (hyperparameter tuning) một cách khắt khe, tập trung vào việc điều phối số lượng nơ-ron, quy mô batch và tốc độ học để đảm bảo sự hội tụ tối ưu của hàm mất mát. Hiệu quả của chiến lược do mô hình đề xuất sau đó sẽ được đối chiếu thực chứng (backtesting) với các phương pháp phân bổ truyền thống dựa trên các hệ thống chỉ tiêu rủi ro và lợi nhuận. Đặc biệt, nghiên cứu hướng tới việc số hóa toàn bộ quy trình này thành một ứng dụng phần mềm chuyên biệt, cho phép tự động hóa hoàn toàn luồng công việc từ khâu cập nhật dữ liệu thực tế đến việc đưa ra các khuyến nghị đầu tư, qua đó khẳng định năng lực ứng dụng và giá trị thực tiễn mạnh mẽ của mô hình trong môi trường tài chính hiện đại.

1.6. Ý nghĩa nghiên cứu

Ý nghĩa khoa học: Về mặt lý luận, nghiên cứu này đóng góp những bằng chứng thực chứng quan trọng về khả năng ứng dụng kiến trúc mạng nơ-ron tuần hoàn lai (LSTM-GRU) trong việc giải quyết bài toán phân bổ tài sản tại một thị trường cận biên như Việt Nam. Bằng việc đi sâu phân tích nhóm cổ phiếu ngành Thép - một nhóm ngành đặc thù với tính chu kỳ khốc liệt và biên độ dao động giá lớn - đề tài đã khẳng định được năng lực ưu việt của mô hình học sâu trong việc giải mã các chuỗi thời gian tài chính phi tuyến tính. Hơn thế nữa, việc thiết lập khung so sánh đối chiếu giữa mô hình và các chiến lược định lượng truyền thống đã tạo ra một hệ quy chiếu đáng tin cậy, cung cấp tài liệu tham khảo giá trị cho các học giả và định chế tài chính định hướng theo giao dịch thuật toán (Algorithmic Trading).

Ý nghĩa thực tiễn: Dưới góc độ ứng dụng, đề tài mang đến một giải pháp công nghệ đột phá nhằm mở rộng khả năng tiếp cận các công cụ quản trị rủi ro phức tạp, đưa chúng đến gần hơn với cộng đồng nhà đầu tư cá nhân. Thông qua một chu trình khép kín: từ bước tự động sàng lọc rõ 10 mã thép có chỉ số Sharpe tối ưu, đến việc khai thác sức mạnh dự báo của LSTM - GRU, và cuối cùng là đóng gói toàn bộ thuật toán lên một giao diện ứng dụng (App) trực quan. Nhờ đó, bất kỳ nhà đầu tư nào cũng có thể dễ dàng tiếp cận chiến lược tái cơ cấu danh mục chuyên nghiệp, giúp tối đa hóa tỷ suất sinh lời và triệt tiêu rủi ro hệ thống. Việc hiện thực hóa mô hình thành một sản phẩm phần mềm không chỉ mang lại giá trị kinh tế trực tiếp cho người dùng mà còn bắt nhịp mạnh mẽ với xu hướng chuyển đổi số (Fintech), góp phần hiện đại hóa hệ sinh thái dịch vụ tài chính trong nước.

1.7. Kết cấu của nghiên cứu

Chương 1: Tổng quan nghiên cứu

Chương này giới thiệu những vấn đề cơ bản của đề tài, bao gồm bối cảnh thị trường và tính cấp thiết của việc ứng dụng trí tuệ nhân tạo vào đầu tư chứng khoán. Tiếp

theo, nghiên cứu trình bày rõ mục tiêu, câu hỏi nghiên cứu, phạm vi và đối tượng khảo sát (nhóm cổ phiếu ngành Thép), phương pháp tiếp cận, cũng như những ý nghĩa khoa học và thực tiễn mà đề tài mang lại.

Chương 2: Cơ sở lý luận và lược khảo tài liệu

Nội dung chương tập trung vào việc hệ thống hóa các khái niệm và khung lý thuyết về quản trị danh mục đầu tư và các tiêu chí đo lường. Song song với đó, tác giả tiến hành tổng hợp và đánh giá các bài nghiên cứu trong và ngoài nước có cùng chủ đề. Thông qua quá trình lược khảo nghiên cứu, tác giả chỉ ra những khoảng trống tri thức còn tồn tại, từ đó tạo dựng cơ sở khoa học vững chắc cho việc triển khai các bước tiếp theo.

Chương 3: Phương pháp nghiên cứu

Chương này cung cấp mô tả chi tiết quy trình thực hiện của đề tài. Cụ thể, chương trình bày cách thức thu thập, xử lý dữ liệu, tiêu chí chọn lọc danh mục cổ phiếu, và giải thích cấu trúc của mô hình học sâu LSTM - GRU. Các phương thức dùng để đánh giá hiệu quả hoạt động của mô hình, cũng như các bước để xây dựng một ứng dụng (App) phân bổ tài sản tự động.

Chương 4: Kết quả nghiên cứu và Thảo luận

Đây là chương trình bày chi tiết các kết quả chạy thực nghiệm. Tác giả áp dụng mô hình LSTM - GRU lên dữ liệu 10 mã cổ phiếu ngành Thép đã chọn, đi qua các bước như: chia tập dữ liệu huấn luyện và kiểm thử (train/test), và điều chỉnh các siêu tham số. Kết quả do mô hình đưa ra sau đó được so sánh trực tiếp với hai chiến lược truyền thống (phân bổ đồng đều và chiến lược 80-20) thông qua các bảng biểu, đồ thị để minh chứng mức độ hiệu quả của thuật toán. Cuối cùng, chương này giới thiệu một phiên bản ứng dụng (App) thử nghiệm, trình bày giao diện và các chức năng cốt lõi từ lúc nhập dữ liệu đến khi đưa ra gợi ý phân bổ vốn, nhằm hỗ trợ nhà đầu tư ra quyết định thực tế.

Chương 5:

Dựa trên cơ sở kết quả thực nghiệm từ Chương 4, Chương 5 tiến hành tổng kết toàn bộ đề tài, đồng thời cung cấp định hướng chi tiết giúp nhà đầu tư vận hành hiệu quả ứng dụng (App) quản trị danh mục vào thực tiễn.

TÓM TẮT CHƯƠNG 1

Nội dung Chương 1 đã cung cấp một cái nhìn toàn diện về đề tài thông qua việc làm rõ tính cấp thiết của đề tài, hệ thống hóa mục tiêu và xác lập phạm vi nghiên cứu. Song song đó, các khía cạnh về phương pháp luận, giá trị đóng góp về mặt khoa học cũng như thực tiễn, cùng sơ đồ cấu trúc tổng thể của khóa luận đã được diễn giải một cách logic. Những nội dung này đóng vai trò là nền tảng quan trọng, tạo tiền đề vững chắc để triển khai các phân tích chuyên sâu trong những chương tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ LUẬN VÀ LƯỢC KHẢO NGHIÊN CỨU TRƯỚC

2.1 Các khái niệm liên quan

2.1.1 Khái niệm về danh mục đầu tư

Theo Kapoor (2014), khái niệm danh mục đầu tư được hiểu là một hệ thống quản trị tài sản bao gồm nhiều loại hình công cụ tài chính khác nhau như cổ phiếu, các loại trái phiếu, công cụ nợ hoặc các tài sản có tính thanh khoản tương đương tiền mặt. Việc thiết lập một danh mục như vậy hướng tới mục tiêu cốt lõi là duy trì trạng thái cân bằng giữa các mục tiêu tài chính, đồng thời giảm thiểu tối đa các tác động tiêu cực từ rủi ro thị trường. Tiếp nối quan điểm này, Đoàn Văn Đính (2022) nhấn mạnh mối tương quan mật thiết giữa lợi nhuận và rủi ro: nhà đầu tư luôn phải đổi mặt với khả năng thua lỗ song hành cùng cơ hội sinh lời, tuân theo quy luật đánh đổi "lợi nhuận cao đi kèm rủi ro lớn". Do đó, năng lực lựa chọn và định hình các dự án đầu tư phù hợp đóng vai trò quyết định trong việc tối ưu hóa hiệu quả của danh mục. Để bảo vệ vốn, chiến lược đa dạng hóa trở thành yêu cầu tất yếu, giúp nhà đầu tư tìm kiếm điểm giao thoa lý tưởng giữa quy mô và chủng loại chứng khoán, từ đó đảm bảo mức lợi nhuận kỳ vọng tối ưu thông qua quá trình phân tích và sàng lọc kỹ lưỡng các mã có tiềm năng tăng trưởng mạnh.

Theo nghiên cứu của Aithal & Cộng sự (2023), quản trị danh mục đầu tư hiện nay thường được triển khai qua hai trường phái chủ đạo: chủ động và thụ động. Phương thức thụ động vận hành dựa trên niềm tin vào sự hiệu quả của thị trường, trong đó nhà quản lý thường phân bổ vốn vào các chỉ số hoặc danh mục cổ phiếu cố định và duy trì chúng cho đến khi đáo hạn mà không thực hiện thay đổi. Ngược lại, trường phái chủ động lại ưu tiên việc liên tục điều chỉnh tỷ trọng tài sản dựa trên các biến động của thị trường. Những người theo đuổi chiến lược này tin rằng có thể tạo ra lợi nhuận vượt trội so với thị trường thông qua việc kết hợp chặt chẽ giữa phân tích cơ bản, đánh giá sự kiện và các kỹ thuật phân tích đồ thị để tìm kiếm các cơ hội tối ưu hóa nguồn vốn liên tục.

Tại thị trường tài chính Việt Nam, cấu trúc phân bổ tài sản của tầng lớp nhà đầu tư cá nhân đang trải qua sự chuyển dịch sâu sắc. Mặc dù các kênh trú ẩn truyền thống như vàng hay bất động sản vẫn duy trì sức hút nhờ khả năng bảo toàn sức mua và thanh khoản ổn định, dòng tiền đang có xu hướng hội tụ mạnh mẽ vào thị trường chứng khoán. Sự bứt phá về quy mô giao dịch, kết hợp cùng sự ra đời của các sản phẩm phái sinh và chứng chỉ quỹ, đã mở rộng đáng kể không gian lựa chọn cho bài toán đa dạng hóa tài sản. Tuy nhiên, đặc thù của một thị trường cận biên là mức độ biến động vô cùng khốc liệt. Các phương pháp định giá truyền thống dựa trên phân tích cơ bản hay kỹ thuật thường bộc lộ độ trễ lớn khi thị trường chịu các cú sốc vĩ mô hoặc thay đổi chính sách. Đặc biệt đối với các nhóm cổ phiếu mang tính chu kỳ đậm nét như ngành Thép, sự nhiễu loạn của giá cả khiến công tác quản trị rủi ro trở thành chốt chặn sinh tử, đòi hỏi những hệ thống dự báo linh hoạt và có khả năng thích ứng động cao hơn.

2.1.2. Khái niệm về học máy

Học máy (Machine Learning) là một nhánh nghiên cứu cốt lõi thuộc lĩnh vực trí tuệ nhân tạo, hướng tới việc trang bị cho máy tính khả năng tự tích lũy tri thức và học hỏi mà không cần đến sự can thiệp trực tiếp từ các dòng lệnh lập trình cứng nhắc. Về bản chất, phương pháp này tập trung vào việc kiến tạo các hệ thống thuật toán có khả năng tự chất lọc kinh nghiệm từ kho dữ liệu thực tế, qua đó liên tục tối ưu hóa hiệu năng xử lý theo thời gian cho từng tác vụ chuyên biệt. Thông qua quá trình huấn luyện bằng các tệp dữ liệu lịch sử, hệ thống sẽ tự thiết lập tư duy logic để đưa ra những dự báo chuẩn xác đối với các biến số mới phát sinh (El Naqa & Murphy, 2015). Chính vì thế, tính hiệu quả và độ tin cậy của mô hình chịu tác động trực tiếp bởi quy mô cũng như chất lượng của nguồn dữ liệu đầu vào. Thay vì vận hành thụ động theo các chuỗi lệnh điều kiện (If - Else) do con người định sẵn, học máy tiếp cận bài toán bằng cách chủ động khai phá các tập dữ liệu đồ sộ. Thuật toán có năng lực tự động bóc tách các đặc trưng ẩn, tìm kiếm mô thức (patterns) và nhận diện các chu kỳ lặp lại, từ đó tự động xây dựng nên một bộ quy tắc linh hoạt phục vụ cho việc suy luận và dự phóng các tình huống trong tương lai.

Dựa trên tính chất của dữ liệu đầu vào, các phương pháp học máy thường được phân loại thành ba nhóm chủ đạo: học có giám sát (supervised learning), học không giám sát (unsupervised learning) và học bán giám sát (semi-supervised learning) (El Naqa & Murphy, 2015).

- Học có giám sát: Trong cơ chế này, thuật toán được tiếp cận với tập dữ liệu đã được gán nhãn mục tiêu cụ thể (target labels). Quá trình đối chiếu giữa biến đầu vào và kết quả chuẩn giúp hệ thống hình thành hàm ánh xạ, từ đó đưa ra những dự đoán có độ chính xác cao cho các quan sát mới.

- Học không giám sát: Ngược lại, phương thức này vận hành trên các khối dữ liệu thô, không có nhãn định trước. Nhiệm vụ trọng tâm của thuật toán là tự khai phá, thực hiện phân cụm và bóc tách các cấu trúc ẩn giấu bên trong tập dữ liệu.

- Học bán giám sát: Đây là sự kết hợp tối ưu giữa hai phương pháp trên, thường được ứng dụng trong các bài toán thực tế nơi hệ thống tận dụng một lượng nhỏ dữ liệu đã gán nhãn hòa trộn với khối lượng khổng lồ dữ liệu chưa qua xử lý để nâng cao hiệu suất học.

Nhờ năng lực khai phá dữ liệu vượt trội, học máy được xem là công nghệ then chốt để mô phỏng trí tuệ con người, dẫn đến việc ứng dụng rộng rãi trong nhiều lĩnh vực trọng yếu như tài chính, thị giác máy tính, y tế và nhận dạng mẫu (El Naqa & Murphy, 2015).

2.1.3. Khái niệm về học sâu

Học sâu được xem là một nhánh của học máy và trí tuệ nhân tạo, tập trung vào việc thiết lập các hệ thống mạng nơ-ron quy mô lớn với năng lực đưa ra phản hồi và quyết định chính xác dựa trên nền tảng dữ liệu (Kelleher, 2019). Đặc trưng nổi bật của các mô hình học sâu (Deep learning - DL) là cấu trúc đa tầng thường sử dụng nhiều lớp ẩn trong mạng nơ-ron, từ vài chục đến hàng trăm lớp. Tại đây, mỗi tầng trong mạng nơ-ron vận hành như một màng lọc thông tin, đảm nhiệm chức năng phân tích và bóc tách

các thuộc tính quan trọng từ nguồn dữ liệu thô ban đầu. Tùy thuộc vào kiến trúc và mục đích ứng dụng cụ thể, các tầng này có thể được cấu tạo từ lớp tích chập (convolutional layer), lớp gộp (pooling layer) hoặc lớp kết nối toàn phần (fully connected layer). So với các thuật toán học máy truyền thống, học sâu đòi hỏi nguồn tài nguyên dữ liệu khổng lồ cùng hạ tầng tính toán mạnh mẽ để tối ưu hóa quy trình huấn luyện mô hình. Chính nhờ cơ chế tự động trích xuất đặc trưng chuyên sâu, học sâu sở hữu khả năng nhận diện và khám phá các quy luật phức tạp trong bộ dữ liệu ưu việt hơn hẳn so với học máy thông thường (Gasparin et al., 2022).

So với các thuật toán học máy cổ điển, học sâu bộc lộ nhiều lợi thế đặc biệt ấn tượng. Một trong những thế mạnh cốt yếu chính là năng lực tự động hóa quá trình nhận diện các thuộc tính từ dữ liệu nguồn, loại bỏ sự lệ thuộc vào khâu thiết kế đặc trưng thủ công thường thấy ở các mô hình học máy truyền thống. Ưu điểm này mang lại hiệu quả vượt trội trong các lĩnh vực như thị giác máy tính, xử lý ngôn ngữ tự nhiên hay phân tích âm thanh - những phân khúc dữ liệu có cấu trúc cực kỳ phức tạp và thách thức đối với các phương pháp tiếp cận thông thường (Goodfellow et al., 2016).

Mặc dù sở hữu nhiều ưu điểm, các cấu trúc học sâu thường đòi hỏi nguồn dữ liệu khổng lồ để tối ưu hóa năng lực vận hành, dẫn đến việc tiêu tốn đáng kể về mặt thời gian cũng như ngân sách cho công tác huấn luyện. Thêm vào đó, việc gia tăng hiệu năng cho mô hình cũng đối mặt với nhiều rào cản do tính chất khó định lượng chính xác khối lượng dữ liệu cần thiết để đạt được mức độ cải thiện mục tiêu (Hao & cộng sự, 2016).

2.2. Các lý thuyết về danh mục đầu tư

2.2.1. Lý thuyết danh mục đầu tư hiện đại (Modern Portfolio Theory - MPT)

Trong quản trị tài chính, Lý thuyết danh mục đầu tư hiện đại (Modern Portfolio Theory - MPT) đóng vai trò là nền móng vững chắc định hình tư duy phân bổ tài sản. Lý thuyết này được khởi xướng bởi nhà kinh tế học Harry Markowitz vào năm 1952 thông qua bài báo lịch sử "Portfolio Selection". Thay vì chỉ tập trung lựa chọn các chứng khoán

riêng lẻ dựa trên lợi nhuận như tư duy truyền thống, Markowitz (1952) đã tạo ra bước ngoặt khi chứng minh toán học rằng: rủi ro tổng thể của một danh mục không đơn thuần là trung bình cộng rủi ro của các tài sản đơn lẻ, mà còn phụ thuộc vào mối tương quan giữa chúng. Nguyên tắc cốt lõi của MPT là ứng dụng chiến lược đa dạng hóa thông qua khung phân tích Trung bình - Phương sai. Bằng cách kết hợp các tài sản có độ tương quan thấp để triệt tiêu rủi ro phi hệ thống, lý thuyết này giúp nhà đầu tư thiết lập trạng thái cân bằng tối ưu giữa mức độ rủi ro và tỷ suất sinh lời kỳ vọng, từ đó xây dựng các danh mục đầu tư hiệu quả nhất (Markowitz, 1959).

Theo Aithal và cộng sự (2023), giá trị trọng tâm của mô hình Markowitz (được công bố vào những năm đầu thập niên 1950) nằm ở quan điểm: việc phân bổ tài sản vào một tập hợp nhiều cổ phiếu sẽ mang lại hiệu năng sinh lời vượt trội so với việc đầu tư tập trung vào các mã đơn lẻ. Trong mô hình này, lợi nhuận của danh mục được định lượng thông qua tỷ suất sinh lời kỳ vọng $E(R)$, trong khi yếu tố rủi ro được đo lường bằng phương sai σ^2 hoặc độ lệch chuẩn σ . Làm rõ hơn về cơ chế tối ưu hóa, Fabozzi và cộng sự (2002) chỉ ra rằng một danh mục lý tưởng có thể được thiết lập dựa trên ba biến số chính: mức sinh lời dự kiến, độ biến động của từng tài sản và hệ số tương quan giữa chúng. Kết quả của các phép tính toán này hình thành nên một quỹ đạo đồ thị được gọi là "Đường biên hiệu quả" (Efficient Frontier). Một danh mục được xác định là nằm trên đường biên này khi nó mang lại lợi nhuận tối đa tại một mức rủi ro cụ thể, hoặc duy trì mức rủi ro thấp nhất ứng với một mục tiêu lợi nhuận xác định. Những tập hợp tài sản đáp ứng được các tiêu chuẩn này được định nghĩa là các danh mục đầu tư hiệu quả.

Sự kết hợp giữa lý thuyết danh mục đầu tư hiện đại và các nguyên lý định giá tài sản đã thiết lập một hệ thống cơ sở lý luận vững chắc để nhận diện, đo lường các rủi ro tài chính, đồng thời làm rõ mối tương quan giữa mức sinh lời kỳ vọng và các biến số rủi ro đi kèm (Fabozzi et al., 2002). Trong đó, mô hình định giá tài sản vốn (CAPM - Capital Asset Pricing Model) được xem là một bước tiến hóa quan trọng, kế thừa và mở rộng những giá trị cốt lõi từ nền tảng nghiên cứu của Markowitz. Sự đột phá của CAPM nằm ở giả thuyết về tính duy lý của nhà đầu tư: thay vì chỉ tập trung vào rõ chứng khoán rủi ro,

họ còn có thể phân bổ nguồn lực vào các công cụ phi rủi ro (tiêu biểu là trái phiếu chính phủ). Theo cơ chế vận hành này, cấu trúc danh mục tối ưu không còn là một hằng số mà sẽ thay đổi linh hoạt dựa trên hai trục chính: lợi suất của tài sản an toàn và mức độ nhạy cảm rủi ro (risk aversion) của từng chủ thể. Nói cách khác, sự phân chia tỷ trọng vốn giữa nhóm tài sản rủi ro và tài sản phi rủi ro chính là sự phản chiếu trung thực nhất về "khẩu vị" đầu tư của mỗi cá nhân trên thị trường.

Đóng vai trò là một thước đo cốt lõi trong Lý thuyết danh mục hiện đại (MPT), hệ số Sharpe (Sharpe Ratio) được sử dụng để đánh giá hiệu suất sinh lời của một khoản đầu tư sau khi đã điều chỉnh rủi ro (Sharpe, 1994). Về mặt toán học, chỉ số này định lượng mức phần bù rủi ro - tức là khoảng chênh lệch giữa tỷ suất sinh lời của danh mục R_p và lãi suất

phi rủi ro R_f - trên mỗi đơn vị rủi ro tổng thể (đại diện bởi độ lệch chuẩn σ_p).

$$\text{Sharpe Ratio} = \frac{E(R_p) - R_f}{\sigma_p}$$

Tuy nhiên, theo Zakamouline và Koekebakker (2009), do được xây dựng chặt chẽ trên khung phân tích trung bình - phương sai, thước đo này chịu sự ràng buộc nghiêm ngặt của giả định phân phối chuẩn. Điều này đồng nghĩa với việc hệ số Sharpe chỉ phản ánh chính xác hiệu quả đầu tư khi độ lệch chuẩn thực sự đo lường được toàn bộ rủi ro của thị trường. Xét trên đồ thị tối ưu hóa, cấu trúc tài sản nào đạt được giá trị Sharpe cực đại sẽ chính là danh mục tiếp tuyến (tangency portfolio) nằm trên đường biên hiệu quả, đại diện cho phương án phân bổ vốn tối ưu nhất.

2.2.2. Lý thuyết hành vi trong tài chính (Behaviora Finance Theory)

Lý thuyết tài chính hành vi không phải là sản phẩm của một cá nhân đơn lẻ mà là kết quả của quá trình tích hợp sâu sắc giữa tâm lý học nhận thức và kinh tế học. Nền móng đầu tiên của lý thuyết này được đặt bởi hai nhà tâm lý học Daniel Kahneman và

Amos Tversky thông qua việc công bố "Lý thuyết triển vọng" (Prospect Theory) vào năm 1979. Công trình này đã trực tiếp thách thức giả định về sự duy lý của Thuyết hữu dụng kỳ vọng (Expected Utility Theory), chứng minh bằng thực nghiệm rằng con người thường đánh giá rủi ro và lợi ích thông qua lăng kính cảm xúc, đặc biệt là tâm lý ngại thua lỗ (Kahneman & Tversky, 1979).

Dựa trên nền tảng tâm lý học đó, Richard Thaler là người đã có công đưa những phát hiện này ứng dụng trực tiếp vào thị trường tài chính, chính thức khai sinh ra bộ môn Tài chính hành vi hiện đại. Bằng việc giới thiệu các khái niệm như "Kế toán tâm lý" (Mental accounting), Thaler đã làm rõ cơ chế khiến các nhà đầu tư phân bổ nguồn vốn và ra quyết định sai lệch so với các mô hình tài chính định lượng truyền thống (Thaler, 1985). Những đóng góp tiên phong này đã định hình lại toàn diện phương pháp phân tích thị trường tài chính, mang lại giải thưởng Nobel Kinh tế cho Daniel Kahneman vào năm 2002 và Richard Thaler vào năm 2017 (Shiller, 2003).

Kế thừa những nền tảng lý thuyết trên, lý thuyết hành vi tài chính hiện đại là một hướng tiếp cận thay thế cho các mô hình tài chính cổ điển vốn giả định rằng các nhà đầu tư là duy lý, có khả năng tiếp cận thông tin đầy đủ và tối ưu hóa danh mục dựa trên logic toán học thuần túy. Thay vào đó, lý thuyết này cho rằng hành vi của nhà đầu tư trong thực tế thường bị ảnh hưởng bởi các yếu tố tâm lý, nhận thức sai lệch, và cảm xúc cá nhân, dẫn đến các quyết định tài chính không hợp lý nhưng phổ biến. Các hiện tượng như quá tự tin (overconfidence), neo thông tin (anchoring), ngại thua lỗ (loss aversion) hay bầy đàn (herding behavior) là những ví dụ tiêu biểu của lý thuyết hành vi (Barberis & Thaler, 2003).

Bên cạnh các mô hình tài chính truyền thống, Tài chính hành vi (Behavioral Finance) đóng vai trò then chốt trong việc giải thích những giới hạn của MPT và CAPM khi áp dụng vào thực tế. Khung lý thuyết này chỉ ra rằng con người hiếm khi là những "nhà đầu tư duy lý" tuyệt đối; thay vào đó, các quyết định phân bổ vốn thường bị bóp méo bởi tâm lý đám đông hoặc hội chứng săn đuổi các "cổ phiếu nóng". Sự chênh lệch giữa lý thuyết định lượng và hành vi thực tế này tạo ra những điểm mù lớn trong quản trị

rủi ro. Chính vì vậy, sự can thiệp của các thuật toán học máy và mạng nơ-ron học sâu trở thành một giải pháp bù đắp tất yếu. Bằng cách vận hành hoàn toàn dựa trên toán học và xác suất, trí tuệ nhân tạo giúp loại bỏ triệt để các thiên kiến cảm xúc, trung hòa sự phi lý trí của thị trường, từ đó thiết lập một kỷ luật giao dịch khách quan và hiệu quả hơn.

Bên cạnh đó, sức mạnh tính toán của học máy và học sâu cho phép hệ thống tự động bóc tách những khuôn mẫu giao dịch phi lý trí của đám đông. Năng lực này tạo tiền đề để thiết lập các chiến lược đầu tư ngược xu hướng (contrarian strategies), nhằm thu lợi từ những vùng định giá sai lệch trên thị trường. Cùng cố cho lập luận này, Subrahmanyam

(2007) chỉ ra rằng sự kết hợp giữa lăng kính tài chính hành vi và nền tảng công nghệ máy học sẽ mang lại tỷ lệ dự báo vượt trội, đặc biệt tại các thị trường thiếu vắng tính hiệu quả. Góc nhìn này hoàn toàn khớp nối với thực tiễn tại thị trường chứng khoán Việt Nam. Với đặc thù là một thị trường cận biên - nơi cấu trúc giao dịch bị chi phối áp đảo bởi dòng tiền của nhà đầu tư cá nhân và tâm lý bầy đàn - việc ứng dụng AI để "lọc" nhiễu cảm xúc không chỉ là một lợi thế, mà là một yêu cầu tất yếu để sinh lời bền vững.

2.2.3. Lý thuyết phân bổ tài sản động (Dynamic Asset Allocation - DAA)

Thông qua các mô hình toán học đột phá, Samuelson (1969) và Merton (1969) đã lần đầu tiên vượt qua giới hạn của bài toán đầu tư tĩnh một thời kỳ, chứng minh bằng toán học rằng các nhà đầu tư không nên giữ nguyên một danh mục cố định mà phải liên tục điều chỉnh các quyết định phân bổ tài sản xuyên suốt vòng đời của họ.

Kế thừa nền tảng định lượng đó, John Y. Campbell và Luis M. Viceira là những người đã có công hiện đại hóa và hệ thống hóa tư duy này thành khuôn khổ lý thuyết Phân bổ tài sản động (Dynamic Asset Allocation - DAA) ứng dụng trực tiếp vào thị trường tài chính hiện đại. Trái ngược với các giả định truyền thống về một môi trường đầu tư bất biến, Campbell và Viceira (2002) lập luận rằng các cơ hội sinh lời và mức độ rủi ro trên thị trường luôn biến thiên theo thời gian, do đó đòi hỏi một chiến lược quản trị danh mục mang tính chủ động cao.

Chính vì vậy, khác với Lý thuyết danh mục đầu tư hiện đại (MPT) vốn hướng tới một chiến lược phân bổ tĩnh (static allocation), lý thuyết DAA tập trung vào việc điều chỉnh liên tục tỷ trọng phân bổ tài sản theo thời gian và điều kiện thị trường biến động. Theo hướng tiếp cận này, nhà đầu tư từ bỏ chiến lược "mua và nắm giữ" cứng nhắc để liên tục cập nhật các yếu tố đầu vào như: lợi suất kỳ vọng, mức độ rủi ro, sự thay đổi trong ma trận tương quan giữa các tài sản và xu hướng vĩ mô. Sự linh hoạt này giúp danh mục đầu tư thích ứng kịp thời, tối ưu hóa lợi nhuận và hạn chế rủi ro trước những pha chuyển động không ngừng của thị trường (Campbell & Viceira, 2002). Trong kỷ nguyên tài chính định lượng, triết lý cốt lõi của DAA chính là nền tảng lý thuyết hoàn hảo nhất để ứng dụng các mạng nơ-ron nhân tạo. Thay vì điều chỉnh tỷ trọng một cách thủ công và mang nặng cảm tính, các thuật toán học máy tiêu biểu như Học tăng cường hay mạng nơ-ron hồi quy - đóng vai trò như những cỗ máy tự động hóa quy trình phân bổ động. Hệ thống sẽ liên tục dung nạp các trạng thái mới của thị trường để xuất ra chuỗi quyết định tối ưu hóa theo thời gian thực.

Chiến lược tái cân bằng này đặc biệt phát huy năng lực tại các thị trường có biên độ dao động khắc nghiệt. Sự biến động khó lường của dòng vốn khiến các chiến lược tĩnh trở nên rủi ro và lỗi thời. Do đó, việc ứng dụng cấu trúc mạng LSTM hay GRU chính là sự hiện thực hóa triết lý DAA ở mức độ tinh vi nhất: thuật toán không ngừng tự cập nhật dữ liệu mới để tái cấu trúc danh mục, qua đó bảo vệ nguồn vốn và đón đầu các chu kỳ tăng trưởng một cách chủ động.

2.3. Tổng quan các nghiên cứu liên quan

2.3.1. Các nghiên cứu trong nước

Nghiên cứu của Đinh Thị Mai Phương và Lê Trung Thành (2021) đã thực hiện đánh giá hiệu năng của các phương pháp nhằm tìm kiếm công cụ tối ưu cho hoạt động đầu tư. Nhóm tác giả đã sử dụng bộ dữ liệu giá cổ phiếu của các doanh nghiệp niêm yết trên sàn HOSE trong chu kỳ 5 năm, từ 2015 đến 2020. Nghiên cứu đã triển khai thực nghiệm đồng thời ba thuật toán bao gồm: Hồi quy tuyến tính (Linear Regression), Rừng

ngẫu nhiên (Random Forest) và Máy vector hỗ trợ (Support Vector Machine). Qua quá trình kiểm chứng bằng hệ thống chỉ tiêu định lượng như MAE, RMSE và hệ số xác định R^2 , kết quả cho thấy mô hình Support Vector Machine (SVM) sở hữu khả năng dự báo ưu việt nhất.

Đáng chú ý, mô hình này duy trì được độ chính xác cao ngay cả trong những giai đoạn thị trường có sự biến động mạnh, trở thành cơ sở tin cậy hỗ trợ các nhà đầu tư trong việc đưa ra các quyết định chiến lược.

Nguyễn Thị Phương Thảo và Nguyễn Minh Quân (2022) đã triển khai thực nghiệm mô hình mạng nơ-ron nhân tạo (ANN) trên rổ cổ phiếu thuộc chỉ số VN30 (giai đoạn 2016 - 2021). Bằng việc đặt mô hình ANN lên bàn cân so sánh với phương pháp ARIMA cổ điển, nghiên cứu đã chứng minh lợi thế vượt trội của mạng nơ-ron trong việc tiếp nhận và xử lý các đặc tính phi tuyến tính phức tạp của chuỗi giá. Kết quả này không chỉ cải thiện độ chính xác trong công tác dự báo mà còn cung cấp một công cụ hỗ trợ ra quyết định đầu tư hiệu quả hơn cho các chủ thể trên thị trường.

Phạm Thị Thanh Xuân và Trần Việt Dũng (2022) khi tập trung vào các thuật toán học máy để nhận diện xu hướng giá trên cả hai sàn HOSE và HNX (chu kỳ 2017 - 2021). Nhóm tác giả đã kết hợp các kỹ thuật xử lý dữ liệu tài chính chuyên sâu với các thuật toán tiêu biểu như Decision Tree, Random Forest và Gradient Boosting. Qua quá trình kiểm chứng, Gradient Boosting được xác lập là mô hình có hiệu năng cao nhất, đặc biệt phù hợp cho các mục tiêu dự báo ngắn hạn. Đây là tiền đề quan trọng giúp cộng đồng nhà đầu tư xây dựng các chiến lược phân bổ nguồn vốn tối ưu và linh hoạt hơn.

Từ góc độ quản trị danh mục, Bùi Quốc Hoàn (2023) đã nghiên cứu ứng dụng học sâu nhằm tối ưu hóa hiệu quả đầu tư trên sàn HOSE giai đoạn 2017 - 2022. Điểm nổi bật của công trình này là sự cộng hưởng giữa mô hình học sâu LSTM với các nguyên lý cốt lõi của Lý thuyết danh mục đầu tư hiện đại (Markowitz). Những dẫn liệu thực nghiệm cho thấy kiến trúc LSTM sở hữu năng lực dự báo xu thế biến động giá rất ấn tượng, từ đó giúp cải thiện đáng kể tỷ suất sinh lời của danh mục so với các phương thức quản trị truyền thống..

Trần Minh Thái, Bình An Chu Đặng và Đình Thăng Hoàng (2025) đã thực hiện so sánh hiệu năng của nhiều mô hình học máy khác nhau nhằm nhận diện xu thế biến động giá cổ phiếu tại Việt Nam. Nhóm tác giả đã khai thác dữ liệu từ 30 doanh nghiệp tiêu biểu niêm yết trên sàn HOSE trong chu kỳ từ năm 2019 đến 2024. Thực nghiệm được tiến hành bằng cách áp dụng đồng thời các phương pháp bao gồm ARIMA, VAR, Holt-Winters và Facebook Prophet. Những dẫn liệu thực chứng cho thấy Facebook Prophet sở hữu độ chính xác ưu việt nhất, nhờ vào lợi thế đặc trưng trong việc nhận diện và bóc tách các quy luật về tính mùa vụ cũng như các biến động phi tuyến tính phức tạp tồn tại trong chuỗi thời gian tài chính.

2.3.2. Các nghiên cứu ngoài nước

Kingma & Ba (2015) đã giới thiệu thuật toán Adam, một phương pháp tiếp cận đột phá dựa trên sự cộng hưởng ưu điểm của AdaGrad và RMSProp. Thông qua thực nghiệm trên các bộ dữ liệu tiêu chuẩn như MNIST và CIFAR-10, nghiên cứu đã chứng minh khả năng hội tụ vượt trội và năng lực vận hành ổn định của Adam so với các thuật toán tối ưu hóa cổ điển.

Bên cạnh đó, Kim & Won (2018) đã triển khai một hướng nghiên cứu triển vọng khi kết hợp mô hình LSTM với các cấu trúc GARCH, EGARCH và GJR-GARCH nhằm dự báo biến động thị trường chứng khoán. Sử dụng dữ liệu từ chỉ số S&P 500 (giai đoạn 1992 - 2015), kết quả thực nghiệm cho thấy sự giao thoa giữa kỹ thuật học sâu và các mô hình thống kê mang lại độ chính xác cao hơn hẳn so với việc sử dụng các phương pháp đơn lẻ hoặc mạng nơ-ron truyền thống trong việc nhận diện các biến số biến động.

Zhang & cộng sự (2019) đã đề xuất phương thức tích hợp hồi quy phân vị vào cấu trúc lai giữa CNN và LSTM để dự đoán phân vị giá cổ phiếu. Bằng việc khai thác dữ liệu sổ lệnh giới hạn (LOB) từ sàn LSE, nhóm tác giả đã khẳng định tính hiệu quả của mô hình tích hợp này khi cho kết quả dự báo ưu việt hơn so với các mô hình dự báo điểm thông thường, mở ra tiềm năng lớn trong việc hỗ trợ các chiến lược giao dịch tự động..

Ma (2020) Ma (2020) đã thực hiện đánh giá hiệu năng của các mô hình ARIMA, ANN và LSTM dựa trên dữ liệu giá cổ phiếu của tập đoàn Dell trong năm 2010. Kết quả thực nghiệm cho thấy kiến trúc LSTM sở hữu ưu thế vượt trội nhờ năng lực quản trị hiệu quả các chuỗi dữ liệu thời gian có độ dài lớn.

Zhang (2020) thực hiện nghiên cứu về tối ưu hóa giao dịch hợp đồng tương lai bằng DRL. Dữ liệu từ 50 hợp đồng tương lai thanh khoản cao (2011 - 2019), và mô hình so sánh gồm DQN, PG, A2C. Kết quả chỉ ra DQN là mô hình hiệu quả nhất, vượt qua cả chiến lược mua và giữ.

Zhang & cộng sự (2021) đã triển khai thực nghiệm các mô hình học sâu bao gồm LSTM, CNN và FCN nhằm tối đa hóa chỉ số Sharpe trên thị trường quỹ ETF thuộc sàn NYSE (giai đoạn 2006 - 2020). Những dẫn liệu thực chứng cho thấy mô hình LSTM đạt hiệu năng vận hành ưu việt nhất, đồng thời nghiên cứu cũng nhấn mạnh rằng các đặc tính dữ liệu trong thời gian gần có sức ảnh hưởng quyết định đến hiệu suất chung của toàn hệ thống.

Jang & Seong (2023) đã đề xuất một phương thức tiếp cận đột phá thông qua việc cộng hưởng giữa Deep Reinforcement Learning (DRL), Lý thuyết danh mục đầu tư hiện đại (MPT) và các mô hình học sâu để tối ưu hóa việc phân bổ tài sản. Dựa trên tập dữ liệu cổ phiếu Mỹ từ năm 2008 đến 2019, nhóm tác giả đã vận dụng kết hợp 3D CNN, Tucker Decomposition và thuật toán DDPG. Kết quả thực nghiệm khẳng định giải pháp tích hợp này sở hữu khả năng thích ứng linh hoạt với thị trường và mang lại tỷ lệ Sharpe vượt trội so với các phương pháp truyền thống.

Ma & cộng sự (2023) đã ứng dụng mạng nơ-ron LSTM kết hợp với mô hình Worstcase Omega trên bộ dữ liệu chỉ số CSI 100 (chu kỳ 2007 - 2015). Những phát hiện từ nghiên cứu chỉ ra rằng, sự giao thoa này giúp tạo ra một danh mục có hiệu quả sinh lời ấn tượng hơn hẳn so với việc sử dụng mô hình LSTM đơn lẻ hay chiến lược phân bổ tỷ trọng đều.

2.3.3. Tổng hợp các nghiên cứu trước.

Bảng 2.1. Tổng hợp các nghiên cứu liên quan

Tác giả (năm công bố)	Vấn đề nghiên cứu	Phương pháp nghiên cứu	Dữ liệu nghiên cứu	Kết quả nghiên cứu
Ma (2020)	So sánh hiệu suất dự đoán cổ phiếu của 3 mô hình: ANN, LSTM và ARIMA	Học sâu, thống kê	Giá cổ phiếu cổ công ty Dell trong năm 2010	Mô hình LSTM có khả năng dự báo vượt trội, điều mà các mô hình ARIMA và ANN không thể đạt được
Zhang (2020)	Ứng dụng các thuật toán DRL nhằm xây dựng các chiến lược giao dịch tối ưu	Học tăng cường sâu	50 hợp đồng tương lai liên tục có thanh khoản cao nhất từ năm 2011 đến năm 2019	

Zhang & cộng sự (2021)	Ứng dụng học sâu để tối ưu hóa tỷ lệ Sharpe của danh mục đầu tư	Học máy	Giá cổ phiếu của một số doanh nghiệp niêm yết trên HOSE giai đoạn 2015 - 2020	Mô hình Support Vector Machine (SVM) đạt hiệu quả tốt nhất, đặc biệt trong điều kiện thị trường có nhiều biến động, từ đó có thể hỗ trợ hiệu quả trong việc ra quyết định đầu tư.
Đinh Thị Mai Phương và Lê Trung Thành (2021)	So sánh hiệu suất dự đoán cổ phiếu của ba mô hình: ARIMA, ANN và LSTM	Học sâu, thống kê	Giá cổ phiếu công ty Dell trong năm 2010	Mô hình LSTM có khả năng dự báo vượt trội, điều mà các mô hình ARIMA và ANN không thể đạt được.

Nguyễn Thị Phương Thảo và Nguyễn Minh Quân (2022)	Ứng dụng thuật toán học máy vào dự báo giá cổ phiếu tại Việt Nam	Học máy tăng cường	Cổ phiếu niêm yết trên sàn HOSE và HNX trong giai đoạn 2017 – 2021	Mô hình Gradient Boosting có độ chính xác và hiệu quả cao nhất trong dự báo ngắn hạn, từ đó là cơ sở cho các nhà đầu tư xây dựng chiến lược đầu tư tối ưu.
Phạm Thị Thanh Xuân và Trần Việt Dũng (2022)	Ứng dụng mô hình mạng nơ-ron nhân tạo (ANN) trong dự báo giá cổ phiếu tại Việt Nam	Trí tuệ nhân tạo, mạng nơ-ron nhân tạo (ANN)	Các công ty thuộc chỉ số CN30 trên sàn HOSE từ 2016 – 2021	Mô hình ANN có khả năng học tốt các đặc điểm phi tuyến tính trong chuỗi giá cổ phiếu, giúp tăng độ chính xác trong dự báo và hỗ trợ chiến lược đầu tư hiệu quả hơn.

Bùi Quốc Hoàn (2023)	Ứng dụng mô hình học sâu trong tối ưu hóa danh mục đầu tư trên thị trường chứng khoán Việt Nam	Học sâu	Cổ phiếu niêm yết trên sàn HOSE trong giai đoạn 2017 – 2022	Mô hình cho thấy khả năng dự báo chính xác xu hướng biến động giá và tối ưu hóa tỷ suất sinh lợi cả danh mục đầu tư tốt hơn các mô hình truyền thống.
Jang & Seong (2023)	Kết hợp mô hình DRL, RL và lý thuyết MPT để tối ưu hóa danh mục đầu tư	Học tăng cường sâu, học sâu	Cổ phiếu niêm yết trên thị trường chứng khoán Mỹ có dữ liệu từ tháng 01/2018 đến 01/2019	Phương pháp đề xuất vượt trội hơn các phương pháp cơ bản và tiến tiến khác về tỷ lệ Sharpe, MDD và fAPV
Ma & cộng sự (2023)	Đề xuất mô hình tối ưu hóa danh mục đầu tư dựa trên kỹ thuật DL	Học sâu	Lịch sử giá cổ phiếu của chỉ số CSI 100 được thu thập từ ngày	Mô hình này đạt được lợi nhuận cao hơn và giảm thiểu

			04/01/2017 đến ngày 31/12/2015	rủi ro so với các mô hình khác, khi thị trường biến động hoặc có rủi ro cao hơn.
Trần Minh Thái, Bình An, Chu Đặng và Đình Thăng Hoàng (2025)	So sánh hiệu suất các mô hình học máy trong dự báo xu hướng giá cổ phiếu trên thị trường chứng khoán Việt Nam.	Mô hình ARIMA, VAR, Holt-Winters và Facebook Prophet	30 mã cổ phiếu niêm yết trên sàn HOSE trong khoảng thời gian từ 2019 – 2024	Prophet có độ chính xác cao nhất nhờ khả năng nắm bắt yếu tố mùa vụ và xu hướng phi tuyến trong chuỗi thời gian tài chính.

Nguồn: Tác giả tổng hợp.

2.4. Khoảng trống nghiên cứu

Có thể thấy làn sóng ứng dụng trí tuệ nhân tạo vào lĩnh vực tài chính đang diễn ra hết sức mạnh mẽ, gắn liền với sự lên ngôi của các kiến trúc học sâu tiên tiến như CNN, Prophet, LSTM hay GRU. Tuy nhiên, một thực tế cho thấy các công trình đột phá này đại đa số được thực nghiệm và kiểm chứng trên các hệ thống dữ liệu thuộc những thị trường chứng khoán đã phát triển toàn diện (điển hình như Mỹ, Anh hay Trung Quốc). Ở chiều ngược lại, khi xét trong bối cảnh của một thị trường cận biên mang đặc tính biến động cao như Việt Nam, quy mô ứng dụng cũng như hàm lượng nghiên cứu chuyên sâu về các mô hình mạng nơ-ron này vẫn còn khá khiêm tốn.

Tại thị trường nội địa thời gian qua, các thuật toán học máy và học sâu cũng đã bước đầu được giới học thuật khai thác nhằm giải mã bài toán dự phóng biến động giá cổ

phiếu. Những nỗ lực này được thể hiện rõ nét qua các ấn phẩm khoa học của Nguyễn Thị Minh Thảo và Nguyễn Minh Quân (2022), Bùi Quốc Hoàn (2023), cũng như Trần Minh Thái và cộng sự (2025). Mặc dù đã đạt được những thành tựu nhất định, quá trình lược khảo tài liệu vẫn chỉ ra một khoảng trống nghiên cứu đáng kể: phần lớn các tác giả mới chỉ giới hạn trọng tâm ở việc dự báo chuỗi điểm giá đơn thuần. Một khung giải pháp mang tính định lượng toàn diện hơn, nơi kết quả dự báo từ AI được trực tiếp chuyển hóa thành chiến lược tối ưu hóa tỷ trọng phân bổ nguồn vốn vẫn là một địa hạt chưa được khai phá triệt để.

Thực tiễn nghiên cứu tại Việt Nam cho thấy, hệ thống phương pháp luận hiện hành vẫn chủ yếu xoay quanh các kỹ thuật thống kê định lượng cổ điển hoặc những thuật toán học máy ở dạng cơ bản (như ARIMA, Random Forest và SVM). Việc khai phá sức mạnh của các kiến trúc học sâu chuyên biệt cho dữ liệu chuỗi thời gian, đặc biệt là cấu trúc LSTM, vẫn chỉ dừng lại ở mức độ thử nghiệm rời rạc chứ chưa hình thành một hệ phương pháp luận mang tính hệ thống. Đáng chú ý hơn cả, sự giao thoa giữa năng lực dự báo ưu việt của AI và các kỹ thuật quản trị danh mục đầu tư trong cùng một nền tảng tích hợp vẫn đang là một "điểm mù" lớn trong hệ thống tài liệu nghiên cứu hiện nay. Từ những điểm nghẽn nêu trên, tác giả tìm thấy động lực cốt lõi để triển khai đề tài này. Mục tiêu trọng tâm của nghiên cứu là thiết kế một chu trình tự động hóa khép kín xuyên suốt từ bước dự phóng tín hiệu thị trường đến khâu định lượng tỷ trọng phân bổ vốn. Thông qua đó, công trình kỳ vọng sẽ khóa lấp những thiếu hụt cả về nền tảng học thuật lẫn khả năng ứng dụng thực chiến trên thị trường chứng khoán Việt Nam.

Đáng chú ý, các thị trường tài chính tại những nền kinh tế mới nổi, điển hình như Việt Nam, luôn tiềm ẩn tính bất ổn và các chu kỳ biến động rủi ro cao. Dù vậy, hệ thống y văn hiện hành vẫn chưa ghi nhận nhiều giải pháp định lượng đủ sức tháo gỡ triệt để bài toán phân bổ nguồn vốn trong bối cảnh vĩ mô phức tạp như vậy. Trên bình diện toàn cầu, giới học thuật đã công nhận hiệu năng vượt xa các phương pháp truyền thống của những cấu trúc AI hiện đại - từ DRL, DDPG cho đến sự tích hợp giữa mô hình học sâu lai LSTM - GRU và nền tảng quản trị Markowitz - thông qua hàng loạt thực nghiệm uy tín

(Zhang et al., 2021; Ma et al., 2023; Jang & Seong, 2023). Tuy thế, quá trình tùy chỉnh và vận dụng những thành tựu công nghệ này nhằm tương thích với hệ sinh thái chứng khoán nội địa vẫn là một khu vực còn nhiều bỏ ngỏ, đòi hỏi sự đầu tư nghiên cứu một cách bài bản và toàn diện hơn.

Xuất phát từ những điểm hạn chế đã phân tích, đề tài đặt trọng tâm vào việc thiết kế một khung định lượng toàn diện, kết hợp sức mạnh dự báo của kiến trúc học sâu lai LSTM - GRU với các nguyên lý cốt lõi của Lý thuyết danh mục đầu tư hiện đại. Đích đến cuối cùng là tối đa hóa hiệu năng sinh lời cho danh mục tài sản. Phương thức tiếp cận mang tính đột phá này được kỳ vọng sẽ lấp những khoảng trống trong nền tảng học thuật hiện hành, đồng thời cung cấp thêm các dẫn liệu thực chứng giá trị về tiến trình ứng dụng AI vào thực tiễn thị trường tài chính nội địa.

Bên cạnh đó, khoá luận đặc biệt đề cao việc kiến tạo một cấu trúc mô hình có năng lực tùy biến sâu, đủ sức chống chịu và tự điều chỉnh linh hoạt trước các pha rung lắc của thị trường. Quá trình triển khai cũng ưu tiên tối ưu hóa độ rườm rà của thuật toán, đảm bảo hệ thống vận hành trơn tru mà không tiêu tốn quá nhiều tài nguyên máy tính. Tầm nhìn xa hơn của công trình là chuyển hóa các mô hình lý thuyết thành một công cụ hỗ trợ giao dịch mang tính thực chiến cao, tháo gỡ bài toán quản trị vốn cho cả giới đầu tư cá nhân lẫn các tổ chức tài chính chuyên nghiệp. Tóm lại, giá trị cốt lõi của nghiên cứu không nằm ở việc thử nghiệm các công cụ mới một cách máy móc, mà hướng đến việc tinh chỉnh và nâng cấp nền tảng thuật toán sẵn có, từ đó phác họa ra một chiến lược phân bổ tài sản hiệu quả và tương thích nhất với môi trường vĩ mô đặc thù của các nền kinh tế đang chuyển đổi.


TÓM TẮT CHƯƠNG 2

Nội dung Chương 2 đã thiết lập khung lý luận và hệ thống hóa các minh chứng thực nghiệm làm bộ phóng cho toàn bộ đề tài. Nghiên cứu đã làm rõ các khái niệm cốt lõi về quản trị danh mục, lý thuyết danh mục hiện đại (MPT), cũng như cơ chế dự báo ưu việt của học máy và học sâu. Đặc biệt, thông qua quá trình lược khảo y văn, tác giả đã vạch rõ một khoảng trống lớn: sự thiếu hụt các ứng dụng mạng nơ-ron sâu tại thị trường chứng khoán Việt Nam. Những đúc kết quan trọng này chính là tiền đề vững chắc để triển khai mô hình tối ưu hóa thực nghiệm ở các chương tiếp theo.

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Quy trình thực hiện nghiên cứu

Nghiên cứu này được xây dựng dựa trên nền tảng kỹ thuật học sâu (Deep Learning), cụ thể trọng tâm khai thác là cấu trúc mạng nơ-ron hồi quy kết hợp. Nhằm đảm bảo độ tính cậy và giảm thiểu sai sót tối đa cho mô hình dự báo, tác giả thiết lập lộ trình triển khai gồm các giai đoạn kế tiếp nhau như sau:



Hình 3. 1. Quy trình thực hiện nghiên cứu

Nguồn: Tác giả tổng hợp

Bước 1: Tổng quan cơ sở lý thuyết

Đầu tiên, nghiên cứu tiến hành tập hợp và đối chiếu các bài báo khoa học đi trước về tiềm năng ứng dụng Học sâu trong việc tối ưu hóa danh mục. đơn thuần là sự chất lọc các khung phương pháp luận định lượng đã được khẳng định, mà cốt lõi nằm ở việc nhận

diện những "khoảng trống nghiên cứu". Từ việc giải quyết những thiếu sót của nghiên cứu trước, tác giả tạo nghiên cứu hoàn toàn khác biệt, mang lại những đóng góp mới mẻ khi ứng dụng vào nhóm doanh nghiệp thép.

Bước 2: Xác định mục tiêu và phạm vi

Dựa trên kết quả tổng thuật, tác giả xác định mục tiêu trọng tâm: Thiết lập mô hình lai LSTM - GRU nhằm tối ưu hóa quy trình phân bổ vốn. Trong nghiên cứu này, thay vì dàn trải trên toàn thị trường, tác giả lựa chọn tập trung vào 10 cổ phiếu tiêu biểu của ngành thép có chỉ số Sharpe dẫn đầu. Cách tiếp cận này giúp đảm bảo danh mục sơ khởi đã hội tụ những mã có sự cân bằng tốt giữa lợi nhuận và rủi ro trước khi đưa vào huấn luyện mô hình học sâu.

Bước 3: Truy xuất và tập hợp dữ liệu đầu vào

Sau khi xác định được mục tiêu và phạm vi nghiên cứu, tác giả tiến hành trích xuất dữ liệu giá đóng cửa lịch sử của các doanh nghiệp thép. Dữ liệu được lấy mẫu với tần suất ngày giao dịch, trải dài xuyên suốt giai đoạn 2015 - 2025. Mục đích cốt lõi của việc nói rộng dải quan sát là nhằm trang bị cho mô hình một lăng kính dữ liệu bao quát, hỗ trợ quá trình tự học và nắm bắt các quy luật dao động phức tạp mang tính chu kỳ tại thị trường Việt Nam.

Bước 4: Làm sạch và chuẩn hóa dữ liệu

Vì dữ liệu thô từ thị trường thường chứa các yếu tố "nhiều" hoặc lỗ hổng số liệu, tác giả thực hiện bước sàng lọc và dọn dẹp kỹ lưỡng. Các kỹ thuật xử lý giá trị khuyết thiếu và lọc bỏ những biến động bất thường được áp dụng nghiêm ngặt, đảm bảo nguồn đầu vào cho quá trình huấn luyện mô hình phải thực sự sạch, đồng nhất và phản ánh đúng bản chất của chuỗi thời gian tài chính.

Bước 5: Phân tách dữ liệu

Tại giai đoạn này, Tiếp nối quy trình, bài toán tiên hành định lượng hệ số Sharpe cho toàn bộ rổ cổ phiếu ngành thép để đánh giá mức phần bù rủi ro. Các thông số cốt lõi được thuật toán sử dụng bao gồm: trung bình tỷ suất sinh lợi ngày, độ lệch chuẩn và mức lãi suất phi rủi ro quy đổi. Thông qua màng lọc này, 10 mã chứng khoán sở hữu tỷ lệ Sharpe ưu việt nhất được chất lọc để định hình rổ danh mục mục tiêu. Điểm đáng chú ý là hệ thống dữ liệu đầu vào không chỉ dừng lại ở chuỗi giá đơn thuần, mà còn được kỹ sư hóa (feature engineering) nhằm trích xuất thêm các đặc trưng chuyên sâu như: độ biến động trượt (rolling volatility), động lượng (momentum), chỉ số sức mạnh tương đối (RSI) và tỷ lệ trung bình động (MA ratios). Khối dữ liệu đa chiều này đóng vai trò là bộ biến quan sát hoàn chỉnh, cung cấp "nguyên liệu" để cấu trúc mạng nơ-ron lai LSTM - GRU tiến hành học tập và định lượng vector trọng số phân bổ vốn tối ưu ở các phân đoạn tiếp theo

Bước 6: Huấn luyện mô hình

Trong giai đoạn này, tiên hành định lượng hệ số Sharpe cho toàn bộ rổ cổ phiếu ngành thép để đánh giá mức phần bù rủi ro. Các thông số cốt lõi được thuật toán sử dụng bao gồm: trung bình tỷ suất sinh lợi ngày, độ lệch chuẩn và mức lãi suất phi rủi ro quy đổi. Thông qua màng lọc này, 10 mã chứng khoán sở hữu tỷ lệ Sharpe ưu việt nhất được chất lọc để định hình rổ danh mục mục tiêu. Điểm đáng chú ý là hệ thống dữ liệu đầu vào không chỉ dừng lại ở chuỗi giá đơn thuần, mà còn được kỹ sư hóa (feature engineering) nhằm trích xuất thêm các đặc trưng chuyên sâu như: độ biến động trượt (rolling volatility), động lượng (momentum), chỉ số sức mạnh tương đối (RSI) và tỷ lệ trung bình động (MA ratios). Khối dữ liệu đa chiều này đóng vai trò là bộ biến quan sát hoàn chỉnh, cung cấp "nguyên liệu" để cấu trúc mạng nơ-ron lai LSTM - GRU tiến hành học tập và định lượng trọng số phân bổ vốn tối ưu ở các phân đoạn tiếp theo.

Bước 7: Đánh giá và đo lường hiệu quả mô hình

Ở bước này, sau khi tính toán được tỷ trọng đầu tư từ mạng nơ-ron LSTM - GRU, tác giả sẽ tiến hành kiểm tra hiệu quả thực tế của hệ thống. Cụ thể, mô hình học sâu này

sẽ được đem ra so sánh trực tiếp với hai phương pháp quản lý danh mục truyền thống: chiến lược phân bổ đều (Equal Weight) và chiến lược 80-20. Với chiến lược phân bổ đều, toàn bộ vốn đầu tư sẽ được chia bằng nhau cho 10 mã cổ phiếu, tức là mỗi mã chiếm đúng 10%. Trong khi đó, chiến lược 80-20 sẽ dồn 80% số vốn vào 2 cổ phiếu có chỉ số Sharpe cao nhất (hiệu quả sinh lời trên rủi ro tốt nhất) trong giai đoạn huấn luyện, và 20% vốn còn lại mới chia đều cho 8 cổ phiếu kia. Để đảm bảo tính khách quan khi so sánh, nghiên cứu dùng ba thước đo tài chính quen thuộc: lợi nhuận kỳ vọng trung bình, độ lệch chuẩn (dùng để đo lường rủi ro) và hệ số Sharpe. Quá trình so sánh này sẽ giúp chứng minh hiệu quả mô hình

LSTM - GRU có thực sự linh hoạt và mang lại hiệu quả vượt trội hơn các cách chia vốn thủ công tại thị trường chứng khoán Việt Nam hay không.

Bước 8: Kết luận và đưa ra giải pháp

Dựa trên các kết quả thu được, tác giả xác định đây là mô hình mang lại hiệu quả cao nhất từ đó làm nền tảng cho việc đưa ra các khuyến nghị. Những số liệu tính ra từ mô hình học sâu sẽ được đúc kết thành các lời khuyên mua bán cụ thể, giúp nhà đầu tư cá nhân dễ dàng thao tác. Từ nền tảng này, nghiên cứu hướng dẫn chi tiết cách thức ứng dụng mô hình vào thực tế đầu tư, đồng thời gợi mở ra thêm những hướng đi mới nhằm tiếp tục nâng cấp các phần mềm trí tuệ nhân tạo hỗ trợ ra quyết định tài chính trong tương lai.

3.2. Các thuật toán học máy ứng dụng


3.2.1. Khái quát về mạng Trí nhớ ngắn hạn dài hạn (Long Short - Term Memory - LSTM).

Về mặt lý thuyết, mạng nơ-ron hồi quy (RNN) là công cụ mạnh mẽ để xử lý các chuỗi dữ liệu nhờ khả năng ghi nhớ các phụ thuộc dài hạn (long-term dependencies). Tuy nhiên, nghiên cứu của Bengio và cộng sự (1994) đã chỉ ra rằng trong môi trường thực tế, mạng RNN tiêu chuẩn thường gặp khó khăn khi học các thông tin quan trọng nằm cách

xa thời điểm hiện tại. Nguyên nhân chính dẫn đến hạn chế này là hiện tượng "biến mất độ dốc" (Gradient Vanishing), khiến mô hình mất dần tín hiệu phản hồi khi chuỗi dữ liệu quá dài, từ đó làm giảm độ chính xác trong các dự báo mang tính phụ thuộc chéo.

Để khắc phục nhược điểm này, Hochreiter và Schmidhuber (1997) đã giới thiệu mạng Trí nhớ ngắn hạn dài hạn (LSTM) - một biến thể đặc biệt của kiến trúc RNN. Khác với cấu trúc đơn giản của RNN truyền thống thường chỉ gồm một tầng kích hoạt đơn lẻ, LSTM sở hữu một kiến trúc nội tại phức tạp hơn. Điểm mấu chốt tạo nên sức mạnh của LSTM chính là "trạng thái ô nhớ" (cell state), đóng vai trò như một sợi băng chuyền xuyên suốt các mô-đun để truyền tải và lưu giữ các thông tin quan trọng từ quá khứ xa mà không bị suy giảm tín hiệu.


Mạng nơ-ron hồi quy (RNN) theo kiến trúc chuẩn thường bao gồm một chuỗi các mô-đun lặp lại với cấu trúc đơn giản, điển hình là tầng kích hoạt tanh. Trong các sơ đồ kỹ thuật, những ký hiệu hình tròn thường đại diện cho các thao tác tính toán như cộng véc-tơ, trong khi các khối hình chữ nhật là những tầng mạng nơ-ron được huấn luyện. Các luồng dữ liệu được biểu thị bằng mũi tên: khi chúng hội tụ nghĩa là có sự kết hợp thông tin, và khi rẽ nhánh đơn thuần là việc sao chép nội dung để chuyển tới các thành phần khác nhau trong hệ thống.



Hình 3. 2. Mô đun của mạng RNN chuẩn R. Zhang et al., (2023)

Tương tự như RNN, mạng LSTM cũng duy trì cấu trúc dạng chuỗi nhưng sở hữu thiết kế nội tại phức tạp hơn đáng kể. Điểm khác biệt mấu chốt nằm ở việc lưu trữ thông tin: trong khi RNN chỉ có một lớp trạng thái ẩn đại diện cho trí nhớ ngắn hạn, LSTM được bổ sung thêm một thành phần gọi là trạng thái ô nhớ (cell state). Thành phần này đóng vai trò là "trí nhớ dài hạn" của mô hình, cho phép nó duy trì và bảo toàn các dữ liệu quan trọng từ quá khứ xa xôi, đảm bảo chúng không bị thất lạc trong quá trình truyền tải để phục vụ

tối ưu cho việc tính toán kết quả đầu ra.



Hình 3. 3. Mô đun của mạng LSTM chuẩn R. Zhang et al., (2023)

Thành phần cốt lõi tạo nên sức mạnh của mạng LSTM chính là trạng thái ô nhớ (cell state), thường được minh họa bằng đường kẻ ngang chạy phía trên cùng của sơ đồ cấu trúc. Có thể hình dung trạng thái này giống như một băng chuyền chạy dọc theo các nút mạng, đóng vai trò then chốt trong việc duy trì và bảo toàn những dữ liệu quan trọng từ quá khứ xa xôi. Nhờ cơ chế này, các luồng thông tin dài hạn có thể được truyền tải xuyên suốt mà không bị thất lạc hay biến đổi đáng kể.

Bên cạnh đó, mô hình LSTM còn sở hữu tính linh hoạt cao trong việc sàng lọc dữ liệu thông qua các cấu trúc điều tiết được gọi là "cổng" (gate). Các cổng này thực hiện việc thêm mới hoặc loại bỏ thông tin khỏi trạng thái ô nhớ bằng sự phối hợp giữa một lớp kích hoạt sigmoid và các phép tính nhân. Cụ thể, lớp sigmoid sẽ xuất ra các giá trị trong phạm vi từ 0 đến 1 để xác định tỷ lệ dữ liệu được phép đi qua. Nếu kết quả trả về là 0, toàn bộ thông tin sẽ bị chặn lại; ngược lại, giá trị bằng 1 đồng nghĩa với việc mọi dữ liệu đều được chấp nhận để tiếp tục truyền đi trong mạng (Olah, 2015).

Cấu trúc của một mạng LSTM điển hình bao gồm nhiều tầng chức năng, bao gồm lớp tiếp nhận dữ liệu đầu vào, các tầng ẩn xử lý trung gian và lớp trích xuất kết quả đầu ra. Hoạt động điều tiết thông tin bên trong mỗi đơn vị LSTM được thực hiện thông qua ba cơ chế cổng chính sau đây:


- *Cổng quên (Forget Gate)*: Đóng vai trò sàng lọc, quyết định những phần dữ liệu nào từ trạng thái ẩn trước đó và đầu vào hiện tại không còn giá trị dự báo để loại bỏ khỏi ô trạng thái.
- *Cổng vào (Input Gate)*: Chịu trách nhiệm chọn lọc và cập nhật những thông tin mới thực sự hữu ích từ dữ liệu hiện tại để đưa vào bộ nhớ dài hạn của ô trạng thái.
- *Cổng đầu ra (Output Gate)*: Xác định những giá trị cụ thể nào từ bộ nhớ ô trạng thái sẽ được trích xuất để hình thành trạng thái ẩn hiện tại và chuyển tiếp dữ liệu ra bên ngoài đơn vị.

Trong bài nghiên cứu này, tác giả ứng dụng kiến trúc mạng LSTM nhằm phân tích và khai thác các quy luật từ dữ liệu giao dịch lịch sử của thị trường chứng khoán Việt Nam. Cụ thể, dựa trên các thực nghiệm trong mã nguồn, mô hình được thiết lập lớp đầu tiên là tầng LSTM với 96 đơn vị (units) để đảm bảo khả năng ghi nhớ các phụ thuộc thời gian phức tạp. Sau khi dữ liệu đi qua các lớp hồi quy, một tầng Dense (lớp kết nối đầy đủ) sẽ được sử dụng để chuẩn hóa các đặc trưng đã học được, từ đó chuyển đổi chúng thành các kết quả dự báo tỷ trọng danh mục đầu tư cuối cùng.

3.2.2. Khái quát về mạng Hồi quy đơn vị cổng (Gated Recurrent Unit - GRU)

Mặc dù kiến trúc LSTM đã giải quyết thành công bài toán phụ thuộc xa mà các mạng RNN truyền thống gặp phải, nhưng nó vẫn tồn tại những hạn chế nhất định. Do cấu trúc bên trong mỗi nút mạng LSTM chứa quá nhiều cổng chức năng, hệ thống đòi hỏi khối lượng tính toán lớn, gây tiêu tốn thời gian và tài nguyên phần cứng đáng kể. Sự phức tạp này còn làm tăng số lượng tham số huấn luyện, dễ dẫn đến rủi ro "quá khớp" (Overfitting), khiến mô hình dự báo kém hiệu quả khi áp dụng vào dữ liệu thực tế. Đặc biệt, đối với dữ liệu biến động như giá chứng khoán - nơi các mối quan hệ tương quan thường chỉ biểu hiện rõ rệt trong ngắn hạn - việc sử dụng một kiến trúc cổng kênh như LSTM có thể gây lãng phí tài nguyên không cần thiết.

Chính vì những lý do này, nghiên cứu quyết định tích hợp thêm mạng Hồi quy đơn vị cổng (Gated Recurrent Unit - GRU). Theo Cho và cộng sự (2014), GRU được xem là một biến thể tối ưu của RNN, giúp xử lý hiện tượng "biến mất độ dốc" (Vanishing Gradient) với cấu trúc tinh gọn hơn so với LSTM. Điểm khác biệt mấu chốt nằm ở chỗ GRU không sử dụng trạng thái ô nhớ (cell state) riêng biệt để lưu trữ thông tin dài hạn; thay vào đó, mọi dữ liệu lịch sử đều được truyền tải và lưu trữ trực tiếp thông qua trạng thái ẩn. Nhờ lược bỏ cơ chế này, GRU chỉ cần sử dụng hai cổng điều tiết thông tin thay vì ba cổng như LSTM, từ đó giúp giảm thiểu áp lực tính toán mà vẫn duy trì khả năng học các phụ thuộc dữ liệu theo thời gian một cách hiệu quả.



Hình 3. 4. Cấu trúc mạng GRU tiêu chuẩn (Zhang et al., 2023)

Kiến trúc mạng GRU tiêu chuẩn điều tiết dòng thông tin thông qua hai cơ chế cổng chính sau đây:

- **Cổng cập nhật (Update Gate):** Thành phần này đóng vai trò quyết định tỷ lệ thông tin từ trạng thái ẩn trước đó cần được duy trì so với lượng dữ liệu mới được nạp vào từ đầu vào hiện tại để hình thành trạng thái kế tiếp. Về bản chất, nó thiết lập sự cân bằng giữa khả năng ghi nhớ dài hạn và việc tiếp nhận các tín hiệu ngắn hạn. Khi kết quả của hàm kích hoạt sigmoid tiến gần đến giá trị 1, mô hình sẽ ưu tiên bảo toàn các đặc trưng từ trạng thái cũ. Ngược lại, giá trị gần bằng 0 đồng nghĩa với việc trạng thái mới sẽ bị chi phối nhiều hơn bởi dữ liệu hiện thời. Cơ chế điều tiết này cho phép các tín hiệu quan trọng từ quá khứ được truyền tải xuyên suốt qua nhiều chu kỳ thời gian, hỗ trợ mạng nơ-ron học tốt các phụ thuộc dữ liệu dài hạn.

- **Cổng xóa (Forget/Reset Gate):** Cổng này kiểm soát mức độ loại bỏ dữ liệu từ trạng thái ẩn liền trước để tính toán một trạng thái ứng viên tạm thời. Chức năng chính của nó là quản lý thông tin ngắn hạn, giúp hệ thống tập trung hiệu quả vào các biến động thị trường gần nhất. Nếu giá trị tại cổng này thấp (tiến về 0), phần lớn thông tin từ quá

khử bị lược bỏ, buộc trạng thái hiện tại phải phụ thuộc chủ yếu vào đầu vào mới. Trong trường hợp giá trị cao (tiến về 1), các thuộc tính từ bước thời gian trước được giữ lại đáng kể, giúp mô hình tận dụng tối đa các đặc tính vận động đã học được. Nhờ tính linh hoạt này, cấu trúc GRU có thể thích ứng hiệu quả với các chuỗi dữ liệu tài chính có tính chất và độ phức tạp đa dạng.

Việc lược bớt số lượng công điều tiết giúp mạng GRU xử lý các tín hiệu ngắn hạn một cách linh hoạt, đồng thời tối ưu hóa tài nguyên tính toán đáng kể so với kiến trúc LSTM phức tạp. Từ kết quả xây dựng và triển khai mô hình thực tế, cấu trúc của lớp GRU được thiết lập với 48 đơn vị (units), đóng vai trò tinh chỉnh các đặc trưng và giảm thiểu rủi ro quá khớp cho mô hình. Kết quả từ các lớp hồi quy sau đó được đưa qua một tầng Dense (lớp kết nối đầy đủ) nhằm chuẩn hóa dữ liệu đầu ra, giúp nâng cao độ chính xác trong việc khai thác các thuộc tính quan trọng từ các chuỗi dữ liệu tài chính có độ dài lớn.

3.2.3. Khái quát về cấu trúc kết hợp LSTM - GRU.

Trong thực tế, giá trị cổ phiếu thường chịu tác động đan xen bởi cả những xu hướng dài hạn lẫn các biến động tức thời trong ngắn hạn. Điều này dẫn đến một thách thức: nếu chỉ đơn thuần sử dụng kiến trúc LSTM để quản lý các đặc tính dài hạn, hệ thống sẽ đòi hỏi năng lực tính toán rất lớn và dễ rơi vào tình trạng quá khớp (overfitting). Ngược lại, việc chỉ áp dụng mạng GRU tuy tiết kiệm tài nguyên hơn nhưng lại gặp hạn chế trong việc xử lý các mối liên hệ dữ liệu quá xa trong quá khứ, từ đó làm giảm độ chính xác tổng thể của dự báo.

Xuất phát từ những phân tích trên, nghiên cứu này đề xuất một giải pháp tối ưu thông qua mô hình tích hợp lai. Cấu trúc của hệ thống được thiết kế theo phân tầng bao gồm các lớp chính sau:

- *Lớp LSTM (Long Short - Term Memory)*: Được thiết lập ở tầng đầu tiên với 96 đơn vị (units) nhằm mục đích trích xuất và ghi nhớ các đặc trưng dài hạn từ chuỗi dữ liệu lịch sử.

- *Lớp GRU (Gated Recurrent Unit)*: Tiếp nối ngay sau LSTM là tầng GRU với 48

đơn vị (units) để tinh chỉnh các tín hiệu và xử lý linh hoạt các biến động trong ngắn hạn.

- *Các lớp Dropout*: Xen kẽ giữa các lớp hồi quy là các tầng Dropout (với tỷ lệ loại bỏ từ 0.1 đến 0.2) giúp ngăn chặn hiện tượng quá khớp bằng cách vô hiệu hóa ngẫu nhiên một số nơ-ron trong quá trình huấn luyện.

- *Lớp Dense*: Sau cùng, dữ liệu được làm phẳng và đưa qua lớp Dense (kết nối đầy đủ).

3.3. Các hàm sử dụng trong kiến trúc mô hình

3.3.1. Hàm kích hoạt Tanh (Hyperbolic Tangent)

Theo nghiên cứu của Roy và các cộng sự (2022), Hyperbolic Tangent (Tanh) là một trong những hàm kích hoạt được áp dụng rộng rãi, với khả năng chuẩn hóa đầu ra về phạm vi giá trị từ -1 đến 1. Mặc dù đóng vai trò nền tảng trong các mô hình xử lý chuỗi dữ liệu biến thiên, Tanh vẫn tồn tại hạn chế cố hữu là dễ dẫn đến tình trạng "biến mất độ dốc" (vanishing gradient) khi thực hiện thuật toán lan truyền ngược (Godin và cộng sự, 2018).

Công thức toán học của hàm Tanh được xác định như sau:

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3.1)$$

Trong đó:

x là giá trị đầu vào của biến số.

Trong nghiên cứu này, hàm Tanh giữ nhiệm vụ then chốt trong việc tinh chỉnh và cập nhật các trọng số ở giai đoạn đầu ra. Cơ chế này cho phép điều tiết luồng dữ liệu một

cách hiệu quả trước khi tích hợp với kết quả của các tầng mạng nơ-ron tiền nhiệm. Nhờ đó, tính toàn vẹn của thông tin được bảo toàn và quá trình cập nhật diễn ra chuẩn xác xuyên suốt giai đoạn huấn luyện của mô hình.

3.3.2. Hàm kích hoạt Sigmoid

Trong cấu trúc mạng nơ-ron hồi quy, đặc biệt là kiến trúc LSTM và GRU, hàm Sigmoid đóng vai trò là thành phần cốt lõi điều tiết các cơ chế cổng. Theo nghiên cứu của Vijayaprabakaran & Sathiyamurthy (2022), đặc tính quan trọng nhất của hàm này là khả năng chuyển đổi các giá trị đầu vào thực bất kỳ thành một giá trị xác suất nằm trong phạm vi từ 0 đến 1.

Công thức biểu diễn hàm Sigmoid được xác định như sau:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3.2)$$

Trong đó:

x là giá trị của biến số đầu vào.

Đặc điểm đầu ra của hàm Sigmoid không đối xứng qua điểm 0, nhưng lại cực kỳ hiệu quả trong việc dự báo dựa trên xác suất tại các tầng chức năng của kiến trúc học sâu. Trong mô hình nghiên cứu này, hàm Sigmoid được lập trình để vận hành các cổng kiểm soát thông tin của lớp LSTM (96 đơn vị) và lớp GRU (48 đơn vị). Cơ chế này cho phép hệ thống linh hoạt đưa ra quyết định: duy trì những đặc trưng quan trọng từ dữ liệu lịch sử hoặc loại bỏ những nhiễu loạn không cần thiết. Thông qua việc tinh lọc thông tin này, mô hình có thể xác định chính xác các tín hiệu thị trường thiết yếu, từ đó tối ưu hóa việc phân bổ tỷ trọng đầu tư cho 10 mã cổ phiếu trong danh mục.

3.3.3. Hàm mục tiêu

Để xác định một cấu trúc máy học có đang vận hành hiệu quả hay không, việc thiết lập một tiêu chuẩn đo lường để định lượng chất lượng đầu ra sau mỗi chu kỳ huấn luyện là vô cùng thiết yếu. Hàm mục tiêu (Objective Function) đóng vai trò là thước đo trung tâm, giúp đánh giá độ chính xác và khả năng tối ưu hóa của hệ thống đối với một mục đích cụ thể. Thông qua chỉ số này, mô hình có căn cứ để tự động tinh chỉnh hệ thống trọng số nơ-ron, từ đó liên tục nâng cao hiệu suất dự báo qua thời gian.

Trong quy trình tối ưu hóa này, mô hình sử dụng thuật toán Adam (Adaptive Moment Estimation) làm bộ tối ưu hóa chính để điều chỉnh các tham số nội tại. Thuật toán này kết hợp ưu điểm của cả Momentum và RMSprop, giúp đưa giá trị của hàm mục tiêu về mức tối ưu một cách nhanh chóng và ổn định. Bên cạnh bộ tối ưu hóa, mô hình còn tích hợp các kỹ thuật bổ trợ quan trọng sau:

- *Hàm mất mát tùy chỉnh (Custom Sharpe Loss)*: Đây là hàm mục tiêu cốt lõi, giúp mô hình tập trung tối đa hóa tỷ suất sinh lời trên mỗi đơn vị rủi ro thay vì chỉ giảm thiểu sai số dự báo thông thường.
- *Kỹ thuật Dropout*: Được áp dụng giữa các lớp hồi quy (với tỷ lệ từ 0.1 đến 0.2) để vô hiệu hóa ngẫu nhiên các nơ-ron, giúp chống lại hiện tượng quá khớp (overfitting) và tăng khả năng tổng quát hóa của mô hình.
- *Cơ chế Early Stopping*: Tự động dừng quá trình huấn luyện khi hiệu suất trên tập kiểm thử không còn cải thiện, giúp tiết kiệm tài nguyên và tránh việc mô hình học thuộc lòng dữ liệu nhiễu.
- *Reduce Learning Rate on Plateau*: Kỹ thuật tự động giảm tốc độ học (learning rate) khi hàm mất mát rơi vào vùng bão hòa, giúp mô hình hội tụ chính xác hơn ở giai đoạn cuối của quá trình huấn luyện.

Việc xác định đúng hàm mục tiêu kết hợp cùng hệ thống các thuật toán điều chỉnh và kỹ thuật chống quá khớp này là những quyết định then chốt, đặt nền móng cho sự thành công của kiến trúc học sâu LSTM - GRU trong bài nghiên cứu.

Trong bài nghiên cứu này, mục tiêu cốt lõi của mô hình là tìm ra phương án phân bổ vốn tối ưu nhằm đạt được hiệu quả quản trị danh mục cao nhất thông qua việc tối đa hóa chỉ số Sharpe (Sharpe Ratio). Để hiện thực hóa điều này, kiến trúc mạng nơ-ron được huấn luyện dựa trên một hàm mất mát tùy chỉnh, gọi là Sharpe Loss. Khác với các phương pháp truyền thống chỉ tập trung vào sai số dự báo, hàm Sharpe Loss cho phép mô hình trực tiếp tối ưu hóa lợi nhuận kỳ vọng trên mỗi đơn vị rủi ro chấp nhận.

Công thức toán học của hàm mục tiêu này được thiết lập như sau:

$$S = \frac{E(R^P) - R^f}{\sigma_p} \quad (3.3)$$

Trong đó:

- $E(R_P)$: Tỷ suất sinh lời kỳ vọng của danh mục đầu tư.
- R_f : Tỷ suất sinh lời phi rủi ro (Risk-free rate)
- σ_p : Độ lệch chuẩn (rủi ro) của danh mục đầu tư.

Việc áp dụng hàm Sharpe Loss làm cơ sở tối ưu hóa giúp mô hình đánh giá một cách trực quan và chuẩn xác khả năng cân bằng giữa rủi ro và lợi nhuận. Cách tiếp cận này không chỉ nâng cao hiệu quả quản trị danh mục mà còn đảm bảo tính đồng nhất với các mục tiêu chiến lược và bối cảnh vận động thực tế của thị trường trong phạm vi nghiên cứu.

3.4. Thuật toán tối ưu hóa Adam

Bên cạnh việc thiết lập hàm mục tiêu, quá trình huấn luyện mạng nơ-ron đòi hỏi một thuật toán tối ưu hóa hiệu quả để tinh chỉnh hệ thống trọng số nội tại, từ đó đưa giá trị hàm mất mát về mức tối thiểu. Trong các kiến trúc học sâu, nhiều kỹ thuật phổ biến thường được áp dụng như suy giảm độ dốc (Gradient Descent), động lượng (Momentum) hay ước lượng động lượng thích nghi (Adam). Quyết định lựa chọn bộ tối ưu hóa mang tính sống còn, vì nó trực tiếp chi phối tốc độ hội tụ và độ chính xác cuối cùng của hệ thống dự báo.

Nghiên cứu đã lựa chọn thuật toán Adam làm bộ tối ưu hóa chính để điều chỉnh các tham số nội tại của mô hình. Việc sử dụng phương pháp Adam giúp hệ thống cập nhật trọng số một cách linh hoạt, từ đó thúc đẩy tốc độ hội tụ và nâng cao hiệu quả trong việc tìm kiếm điểm tối ưu của hàm mục tiêu. Ngoài ra, để gia tăng hiệu suất và độ ổn định khi huấn luyện, nghiên cứu còn tích hợp hệ thống các kỹ thuật bổ trợ sau:

- *Dừng sớm (Early Stopping)*: Theo dõi sự biến động của hàm mất mát trên tập kiểm định để tự động ngắt quá trình huấn luyện khi không còn sự cải thiện đáng kể, giúp ngăn chặn hiện tượng học thuộc lòng dữ liệu nhiễu (overfitting).
- *Điều chỉnh tốc độ học tự động (Reduce Learning Rate on Plateau)*: Cơ chế này sẽ tự động giảm tỷ lệ học xuống một nửa khi mô hình rơi vào trạng thái bão hòa, hỗ trợ thuật toán Adam tìm kiếm điểm tối ưu cục bộ một cách tinh vi hơn.
- *Vô hiệu hóa nơ - ron ngẫu nhiên (Dropout)*: Được phân bổ tại các lớp LSTM, GRU và lớp Dense, kỹ thuật này giúp mô hình trở nên bền vững hơn trước những biến động bất thường của dữ liệu tài chính.
- *Reproducibility*: giúp thẩm định độ vững (robustness) của các chiến lược đầu tư dưới nhiều điểm neo khác nhau, mà còn đảm bảo kết quả đầu ra luôn đáp ứng các chuẩn mực khắt khe về khả năng tái lập trong nghiên cứu khoa học (Goodfellow et al., 2016).

- *Random Seed*: Loại bỏ các sai lệch do máy tính tự phát sinh, đảm bảo mô hình luôn xuất ra một kết quả đồng nhất. Điều này tạo cơ sở tin cậy để đo lường chính xác tác động của quá trình tinh chỉnh siêu tham số (hyperparameter tuning) lên hiệu suất chung.

Việc phối hợp nhịp nhàng giữa thuật toán tối ưu hóa hiện đại và các cơ chế kiểm soát huấn luyện chặt chẽ này đảm bảo mô hình LSTM - GRU đạt được hiệu quả tối ưu trong việc phân bổ danh mục đầu tư.

Trong lĩnh vực học sâu, thuật toán Adam được ứng dụng phổ biến nhờ khả năng tự động hóa việc điều chỉnh tốc độ học và hiệu suất hội tụ nhanh chóng. Phương pháp này là sự kết hợp tinh hoa giữa cơ chế Động lượng (Momentum) và Lan truyền trung bình bình phương căn (RMSProp) để tối ưu hóa tiến trình huấn luyện mô hình. Theo nghiên cứu của Liu (2021), một trong những lợi thế cốt lõi của

Adam là khả năng tránh việc bị kẹt tại các điểm cực tiểu địa phương, từ đó hướng tới điểm tối ưu một cách hiệu quả. Điều này đạt được nhờ việc tính toán linh hoạt các momen bậc một và bậc hai của gradient cho từng tham số, giúp quá trình cập nhật trọng số diễn ra ổn định và chính xác hơn.

Về mặt vận hành, Adam thực hiện giám sát song song giá trị trung bình động của các gradient nhằm hạn chế sự dao động quá mức (tương tự cơ chế của Động lượng) và giá trị trung bình động của bình phương gradient để tinh chỉnh tỷ lệ học cho mỗi tham số riêng biệt (kế thừa từ RMSProp). Quy trình cập nhật tham số thông qua thuật toán Adam được triển khai cụ thể theo các bước sau:

Bước đầu tiên, mô hình tiến hành xác định đạo hàm (gradient) của hàm mất mát tại bước lặp t dựa trên phương trình:

$$g_t = \nabla_{\theta} J(\theta_t) \quad (3.4)$$

Trong đó:

θ_t : là tập hợp các tham số đang được tinh chỉnh tại chu kỳ t .

J: Biểu diễn hàm mục tiêu (objective function) mà hệ thống cần tối thiểu hóa.

Giai đoạn kế tiếp liên quan đến việc tính toán các giá trị trung bình trượt hàm mũ (exponential moving average). Cụ thể, ước lượng moment bậc nhất (đại diện cho động lượng - momentum) và moment bậc hai (bình phương đạo hàm) :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (3.5)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (3.6)$$

Trong đó:

m_t và v_t : lần lượt là các véc-tơ ước lượng moment bậc nhất và bậc hai tại thời điểm t .

β_1 và β_2 : lần lượt là các siêu tham số mang giá trị không âm. Trong phần lớn các mô hình, hai tỷ lệ này được khuyến nghị thiết lập mặc định ở mức 0.9 đối với β_1 và 0.999 đối với β_2 .

Do các véc-tơ moment ban đầu thường được gán bằng 0, chúng có xu hướng bị lệch mạnh về mốc 0 trong những vòng lặp huấn luyện đầu tiên. Để khắc phục triệt để hiện tượng này, cơ chế hiệu chỉnh lệch (bias correction) được áp dụng:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (3.7)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (3.8)$$

Tại bước cuối cùng, thuật toán sẽ dựa vào các moment đã được hiệu chỉnh để thực hiện việc cập nhật bộ tham số θ theo cơ chế thích ứng:

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\epsilon_{\hat{v}_{t+1}}}} \hat{m}_t \quad (3.9)$$

Trong đó:

α : Tốc độ học (learning rate), quy định độ lớn của mỗi bước nhảy trong quá trình tối ưu. Giá trị tiêu chuẩn thường được lựa chọn là 0.001.

ϵ : Một hằng số cực nhỏ được bổ sung vào mẫu số nhằm loại bỏ rủi ro tính toán do lỗi chia cho 0.

So với các phương pháp tối ưu hóa truyền thống, thuật toán Adam thể hiện tính ưu việt vượt trội nhờ khả năng đẩy nhanh tốc độ hội tụ, đặc biệt trong các không gian bài toán có sự biến thiên gradient phức tạp. Năng lực tự động tinh chỉnh bước nhảy cập nhật trọng số giúp thuật toán này duy trì hiệu năng cao ngay cả khi làm việc với các tập dữ liệu chứa nhiều nhiễu hoặc có cấu trúc gradient thưa thớt. Dù vậy, trên phương diện lý thuyết, một hạn chế tiềm tàng của Adam là rủi ro hội tụ sớm về các điểm tối ưu cục bộ (local optima) thay vì đạt đến trạng thái tối ưu toàn cục (global optimum).

Trong phạm vi của nghiên cứu này, thuật toán Adam được định chuẩn làm cơ chế tối ưu hóa chủ đạo cho mạng nơ-ron kết hợp LSTM - GRU. Bằng cách tính toán và điều chỉnh linh hoạt dựa trên trung bình trượt của cả gradient và bình phương gradient, thuật toán giúp hệ thống kiểm soát và triệt tiêu các dao động sai số đột ngột trong quá trình huấn luyện. Đặc tính này đóng vai trò mang tính quyết định khi mô hình phải học và xử lý chuỗi thời gian tài chính chứa đầy nhiễu động khác nghiệt, tiêu biểu như chuỗi giá lịch sử của 10 mã cổ phiếu nhóm ngành Thép. Cổ phiếu thép mang nặng tính chu kỳ, dẫn đến hiện tượng gradient không đồng nhất (non-uniform gradients) liên tục xuất hiện xuyên suốt các vòng lặp. Sự thích ứng nhạy bén của thuật toán Adam đã khắc phục thành công rào cản này, hỗ trợ

mô hình tối ưu hóa tỷ trọng danh mục một cách ổn định và đạt hiệu suất dự báo cao nhất.

3.5. Dữ liệu nghiên cứu

Toàn bộ dữ liệu lịch sử được khai thác trong nghiên cứu tập trung chuyên sâu vào nhóm các doanh nghiệp niêm yết thuộc ngành Thép trên thị trường chứng khoán Việt Nam. Thông qua giao diện lập trình ứng dụng (API) của thư viện mã nguồn mở vnstock (sử dụng cấu hình nguồn dữ liệu truy xuất từ KBS), bộ dữ liệu chuỗi thời gian theo tần suất ngày của 41 mã cổ phiếu thép được thu thập liên tục trong giai đoạn từ ngày 01/01/2015 đến ngày 31/12/2025.

Quá trình tiền xử lý và chuẩn hóa dữ liệu (data cleansing) được tiến hành một cách nghiêm ngặt. Để giải quyết rủi ro đứt gãy dữ liệu do các phiên ngừng giao dịch hoặc mất thanh khoản cục bộ, hệ thống áp dụng kỹ thuật nội suy điền khuyết hai chiều (forward-fill kết hợp backward-fill) lên chuỗi giá đóng cửa, qua đó bảo toàn tính liên tục của dữ liệu đầu vào. Kế tiếp, nghiên cứu phân tách tập dữ liệu huấn luyện (Training Set) trong khoảng thời gian từ 2015 đến 2024 nhằm đánh giá toàn diện hệ số Sharpe của toàn bộ 41 mã cổ phiếu. Dựa trên bộ lọc thống kê này, 10 mã cổ phiếu có mức bù đắp rủi ro (hiệu suất sinh lời tương xứng với biến động) xuất sắc nhất được lựa chọn để cấu thành danh mục mục tiêu. Việc thu hẹp quy mô đầu tư dựa trên hiệu suất quá khứ giúp mạng nơ-ron tập trung phân bổ nguồn lực vào các tài sản đã minh chứng được nền tảng vững chắc.

Tại bước cuối cùng, sau khi mô hình học sâu LSTM - GRU hoàn thiện việc trích xuất đặc trưng và đưa ra trọng số phân bổ động (Dynamic Allocation), tập dữ liệu kiểm thử ngoài mẫu trong năm 2025 được triển khai để nghiệm chứng tính thực chiến của thuật toán. Nhằm cung cấp góc nhìn đa chiều về năng lực quản trị rủi ro của mô hình, hiệu suất cuối cùng của danh mục học sâu được so sánh với hai chiến lược đầu tư tham chiếu phổ biến: (1) Chiến lược Phân bổ tỷ trọng đều (Equal Weight) và (2) Chiến lược Phân bổ 80-20

3.6. Phương pháp xây dựng App lựa chọn danh mục đầu tư

Để giúp các nhà đầu tư cá nhân dễ dàng áp dụng mô hình trí tuệ nhân tạo vào thực tiễn, nghiên cứu đã phát triển một ứng dụng web trực quan bằng công cụ Streamlit. Đây là một nền tảng mã nguồn mở bằng ngôn ngữ Python, cho phép xây dựng các trang web dữ liệu một cách nhanh chóng mà không đòi hỏi người viết phải rành rọt về các ngôn ngữ thiết kế giao diện phức tạp như HTML, CSS hay JavaScript. Nhờ đó, việc trình bày số liệu thống kê, vẽ biểu đồ trực quan hay triển khai các mô hình học máy phức tạp trở nên thuận tiện và dễ tiếp cận hơn rất nhiều.

Bước đầu tiên trong quy trình xây dựng hệ thống là thiết lập môi trường làm việc thông qua câu lệnh cài đặt cơ bản `pip install streamlit`. Ngay sau đó, ứng dụng sẽ được tích hợp thêm các thư viện nền tảng quan trọng khác như Pandas và Matplotlib. Những công cụ hỗ trợ này đóng vai trò thiết yếu trong việc giúp phần mềm đọc hiểu bảng biểu, xử lý các phép toán tài chính và phục vụ trực tiếp cho quá trình vẽ đồ thị minh họa khi ứng dụng hoạt động.

Về mặt giao diện, ứng dụng sử dụng các hàm có sẵn của Streamlit để tương tác với người dùng. Ngay khi người dùng chọn xong rõ cổ phiếu và nhấn nút "Bắt đầu", ứng dụng sẽ tự động chạy ngầm các bước tiền xử lý: trích xuất chuỗi giá lịch sử, lấp đầy các ngày bị thiếu dữ liệu, loại bỏ những mã không đủ điều kiện và chuẩn hóa các con số. Tập dữ liệu sạch này sau đó được đưa thẳng vào mạng nơ-ron học sâu để chạy thuật toán. Kết quả cuối cùng trả về trên màn hình sẽ là tỷ lệ phân bổ vốn tối ưu nhất cho từng mã cổ phiếu, đi kèm với các biểu đồ trực quan giúp nhà đầu tư dễ dàng đưa ra quyết định.

TÓM TẮT CHƯƠNG 3


Chương 3, tác giả đã hoàn thành việc thiết lập khung khổ nghiên cứu cho khóa luận, bao gồm lộ trình triển khai chi tiết cùng hệ thống các mô hình và công thức tính toán đặc thù. Song song đó, các tiêu chí định lượng dùng để đo lường và kiểm chứng độ chính xác của mô hình cũng đã được xác lập một cách cụ thể. Những phương pháp luận và công cụ kỹ thuật được xây dựng trong chương này sẽ đóng vai trò là nền tảng then chốt để thực hiện các phép tính thực nghiệm và phân tích số liệu ở Chương 4.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

4.1. Tiền xử lý dữ liệu

Nghiên cứu tiến hành thu thập và sử dụng dữ liệu lịch sử của các cổ phiếu thuộc ngành Thép đang niêm yết trên thị trường chứng khoán Việt Nam trong giai đoạn từ năm 2015 đến năm 2025. Nhằm bảo đảm tính liên tục và độ tin cậy của chuỗi thời gian, toàn bộ tập dữ liệu thô được làm sạch thông qua kỹ thuật điền khuyết để xử lý triệt để các giá trị rỗng phát sinh do những phiên ngừng giao dịch.

Kế tiếp, để đánh giá hiệu suất điều chỉnh theo rủi ro, nghiên cứu tiến hành tính toán hệ số Sharpe cho toàn bộ các mã cổ phiếu hợp lệ. Dựa trên kết quả thu được, 10 mã cổ phiếu sở hữu hệ số Sharpe cao nhất sẽ được chọn lọc để cấu thành danh mục đầu tư mục tiêu. Việc định hình rổ tài sản dựa trên tiêu chí này nhằm đảm bảo mô hình tập trung phân bổ nguồn vốn vào những cổ phiếu có năng lực sinh lời vượt trội, đồng thời duy trì mức độ biến động rủi ro trong phạm vi an toàn



ểm soát.

Hình 4.1. Danh mục 10 cổ phiếu có Sharpe Ratio cao nhất

Nguồn: Kết quả tính toán của tác giả.

Về phân tách dữ liệu cho mục đích thực nghiệm, tác giả chia bộ dữ liệu thành hai phần riêng biệt:

- Giai đoạn huấn luyện (Training Set): Từ năm 2015 đến hết năm 2024, được dùng để mô hình LSTM - GRU tự học các đặc trưng biến động của thị trường.
- Giai đoạn kiểm thử (Test Set): Toàn bộ dữ liệu năm 2025, đóng vai trò dữ liệu ngoài mẫu (out - of - sample) để nghiệm chứng hiệu quả phân bổ thực tế.

Cách thiết lập này giúp mô hình khai thác được xu hướng dài hạn từ dữ liệu lịch sử, đồng thời sử dụng năm 2025 như một tập kiểm định độc lập nhằm đánh giá chính xác năng lực dự báo trong điều kiện thị trường thực tế.

4.2. Cấu trúc và các siêu tham số của mô hình

4.2.1. Cấu trúc của mô hình

Cấu trúc mô hình LSTM – GRU được trình bày trong bảng 4.2 dưới đây:

Bảng 4. 2. Cấu trúc mô hình LSTM - GRU

Cửa sổ quan sát (Window size)	30
Khoảng dự báo (Horizon)	5
Lớp hồi quy LSTM	96 nơ-ron
Lớp Dropout 1 & 2	0.2 (20%)
Lớp hồi quy GRU	48 nơ-ron
Lớp kết nối đầy đủ (Dense ẩn)	64 nơ-ron
Lớp Dropout 3	0.1 (10%)
Lớp đầu ra (Output Layer)	10 nơ-ron

4.2.2. Các siêu tham số huấn luyện

Bộ siêu tham số của mô hình được trình bày trong bảng 4.3 sau:

Bảng 4. 3. Bộ siêu tham số của mô hình LSTM - GRU

Kích thước lô dữ liệu (Batch size)	32
Số vòng lặp tối đa (Epochs)	100
Tốc độ học (Learning Rate)	0.0005
Thuật toán tối ưu hóa (Optimizer)	Adam

Hàm mục tiêu (Loss Function)	Custom Sharpe Loss
Cơ chế dừng sớm (Early Stopping)	Patience = 10
Điều chỉnh tốc độ học tự động	Factor = 0.5, Patience = 5


4.3. Quy trình huấn luyện và tối ưu hóa mô hình học sâu

Quy trình huấn luyện mạng nơ-ron LSTM - GRU được tác giả thiết lập một cách hệ thống nhằm đảm bảo tính ổn định và khả năng tổng quát hóa cao cho danh mục đầu tư. Đầu tiên, trước khi khởi chạy hệ thống được cố định các hạt giống ngẫu nhiên (Seeds) trên toàn bộ môi trường lập trình để đảm bảo tính tái lập, giúp các kết quả thực nghiệm có thể được kiểm chứng lại một cách nhất quán. Về mặt cấu hình, tác giả sử dụng thuật toán tối ưu hóa Adam với tốc độ học (Learning Rate) khởi tạo được tinh chỉnh ở mức 0.0005, kết hợp cùng hàm mất mát tùy chỉnh (Custom Sharpe Loss) để trực tiếp tối đa hóa hiệu suất sinh lời trên rủi ro của danh mục. Quá trình học tập được thiết lập với kích thước lô dữ liệu (Batch Size) là 32 và trải qua tối đa 100 vòng lặp (Epochs).

Tiếp theo, nhằm bảo vệ mô hình khỏi hiện tượng học vẹt (Overfitting) - một rủi ro rất phổ biến khi xử lý chuỗi dữ liệu tài chính nhiễu động, tác giả đã tích hợp hai cơ chế giám sát tự động trong quá trình huấn luyện. Thứ nhất, kỹ thuật dừng sớm (Early Stopping) được kích hoạt để tự động ngắt quá trình học tập nếu hàm mất mát trên tập kiểm định không ghi nhận sự cải thiện sau 10 vòng lặp liên tiếp. Thứ hai, cơ chế điều chỉnh tốc độ học (ReduceLROnPlateau) sẽ tự động thu hẹp 50% bước nhảy của thuật toán nếu hiệu suất chững lại sau 5 vòng, giúp mô hình từ từ hội tụ sâu hơn vào điểm tối ưu toàn cục.

Và cuối cùng, để khắc phục nhược điểm nhạy cảm với các tham số khởi tạo ban đầu của mạng nơ-ron, tác giả không sử dụng kết quả của một lần chạy duy nhất. Thay vào đó, sử dụng phương pháp huấn luyện đa hạt giống (Ensemble Training) được áp dụng bằng cách lặp lại quy trình trên 5 hạt giống hoàn toàn khác nhau (bao gồm các giá trị 7,

21, 42, 99 và 123). Sau mỗi lượt chạy, hệ thống sẽ tự động thực hiện dự báo tỷ trọng phân bổ trên tập dữ liệu kiểm thử của năm 2025. Mô hình mang lại hệ số Sharpe thực tế cao nhất ở bước kiểm thử ngoài mẫu này sẽ được tác giả trích xuất và lựa chọn làm mô hình chính thức để đánh giá hiệu quả đầu tư cuối cùng.



Hình 4.2 Biểu đồ khối phân bố tỷ trọng của danh mục đầu tư

Nguồn: Kết quả tính toán của tác giả

4.4. Đánh giá và so sánh hiệu quả các chiến lược đầu tư

Sau khi chọn ra được phiên bản AI tối ưu nhất từ các lần chạy thử, tác giả sử dụng tập dữ liệu kiểm thử của năm 2025 để đánh giá khả năng hoạt động thực tế của hệ thống. Để làm nổi bật mức độ hiệu quả, kết quả phân bổ vốn của thuật toán học sâu được mang ra so sánh trực tiếp với hai chiến lược đầu tư cơ bản thường thấy trên thị trường. Chiến


lược thứ nhất là phân bổ đều (Equal Weight - Allo_1), trong đó tác giả giả định chia đều 100% vốn cho cả 10 mã cổ phiếu (mỗi mã chiếm 10%). Chiến lược thứ hai là phân bổ theo tỷ lệ 80 - 20 (Allo_2), áp dụng nguyên tắc dồn 80% tiền vốn vào mua 2 mã cổ phiếu có chỉ số Sharpe tốt nhất trong quá khứ, 20% vốn còn lại mới đem chia đều cho 8 mã xếp sau.

Để đảm bảo tính công bằng, cả ba phương pháp này đều được vận hành trên cùng một tập dữ liệu thực tế của năm 2025 và được chấm điểm dựa trên ba tiêu chí cốt lõi: lợi nhuận trung bình năm, độ lệch chuẩn (đo lường rủi ro giá trị tài sản trời sập) và hệ số Sharpe (đo lường khả năng sinh lời dựa trên mức rủi ro phải gánh chịu).

	Chiến lược đầu tư	Lợi nhuận trung bình	Độ lệch chuẩn	Hệ số Sharpe
0	LSTM-GRU (Dynamic)	59.6075	13.5804	4.0579
1	Phân bổ đều	40.7649	23.2241	1.5615
2	Phân bổ 80-20	19.3967	31.4120	0.4742

Hình 4.3. So sánh mức độ hiệu quả của mô hình

Nguồn: Kết quả tính toán của tác giả.



Hình 4.4. Kết quả lợi nhuận kỳ vọng, độ lệch chuẩn và Sharpe của danh mục

Nguồn: Kết quả tính toán của tác giả.

Từ các số liệu thống kê thu được, có thể thấy rõ mô hình học sâu LSTM-GRU mang lại năng lực tối ưu hóa danh mục vượt trội, đặc biệt là khả năng dung hòa giữa lợi nhuận và rủi ro thông qua thước đo Sharpe.

Cụ thể, danh mục được điều phối bởi mô hình LSTM - GRU đạt mức lợi nhuận trung bình năm cao nhất lên tới 59.61%, đồng thời ghi nhận độ lệch chuẩn thấp nhất chỉ ở mức 13.58%. Điều này dẫn đến hệ số Sharpe vươn lên mức 4.06 - minh chứng cho sự tối ưu hóa phần bù rủi ro cực kỳ hiệu quả. Trong khi đó, phương pháp phân bổ đều (Equal Allocation) tuy vẫn duy trì được lợi nhuận kỳ vọng khả quan ở mức 40.76%, nhưng biên độ biến động rủi ro lại tăng cao lên 23.22%, khiến hệ số Sharpe của chiến lược này giảm về mức 1.56.

Ngược lại, chiến lược tập trung 80 - 20 lại thể hiện hiệu suất kém nhất trong đợt kiểm thử. Phương pháp này chỉ mang lại mức lợi nhuận 19.40% nhưng đồng thời lại đi kèm với mức độ rủi ro rất lớn (31.41%). Kết quả là hệ số Sharpe bị kéo rớt xuống đáy với giá trị vốn vẹn 0.47, thấp nhất trong cả ba phương pháp tiếp cận.


Như vậy, có thể đưa ra kết luận rằng mô hình LSTM - GRU cung cấp một giải pháp đầu tư mang lại hiệu suất tổng thể ưu việt hơn hẳn. Chiến lược này đặc biệt phù hợp với những nhà đầu tư mong muốn gia tăng tối đa tỷ suất sinh lợi nhưng vẫn yêu cầu duy trì rủi ro trong một biên độ an toàn và hợp lý. Kết quả thực nghiệm một lần nữa khẳng định rằng việc tích hợp các công cụ học sâu vào quy trình xây dựng danh mục đầu tư sẽ tạo ra lợi thế cạnh tranh rõ ràng, nhất là trong bối cảnh thị trường chứng khoán Việt Nam đầy tiềm năng nhưng cũng tiềm ẩn không ít những nhịp biến động khó lường.

Tuy nhiên, để công cụ dự báo này phát huy tối đa công năng, hệ thống đòi hỏi phải được liên tục nạp dữ liệu giao dịch mới và tái tính chỉnh định kỳ (có thể theo chu kỳ hàng tháng hoặc hàng quý). Thêm vào đó, tác giả khuyến nghị nhà đầu tư cần chủ động rà soát lại rõ tài sản ngành Thép mỗi khi có sự chuyển dịch lớn về chu kỳ kinh tế, nhằm đảm bảo các thông số của mô hình luôn phản ánh sát với hiện trạng thị trường, từ đó bảo vệ và tối ưu hóa dòng vốn trong dài hạn.

4.5. Phát triển ứng dụng hỗ trợ lựa chọn danh mục đầu tư

Từ những thành quả tích cực ghi nhận được qua các vòng nghiệm chứng, năng lực định lượng và điều phối dòng vốn của mạng nơ-ron LSTM-GRU đã được khẳng định rõ nét. Nhằm chuyển hóa mô hình học thuật thành một công cụ mang tính thực chiến cao, tác giả tiến hành lập trình và đóng gói thuật toán thành một phần mềm ứng dụng sở hữu giao diện tương tác thân thiện. Giải pháp này nhằm mục đích tháo gỡ rào cản về mặt công nghệ, tạo điều kiện để các nhà đầu tư cá nhân có thể dễ dàng ứng dụng sức mạnh của trí tuệ nhân tạo vào quy trình phân tích tài chính hàng ngày.

Về mặt vận hành, phần mềm cung cấp một không gian thao tác mở, cho phép người sử dụng tùy biến thiết lập các tham số đầu vào chuyên biệt cho nhóm ngành Thép - vốn là trọng tâm nghiên cứu cốt lõi của khóa luận. Chỉ với một vài thao tác chọn lọc danh sách mã cổ phiếu đang niêm yết và giới hạn khung thời gian quan tâm, hệ thống sẽ tự động kích hoạt toàn bộ chuỗi quy trình ngầm. Dữ liệu lịch sử sẽ lập tức được thu thập, làm sạch và nạp thẳng vào kiến trúc mạng học sâu để tiến hành tính toán. Thành phẩm cuối cùng được xuất ra màn hình là một bản quy hoạch tỷ trọng phân bổ vốn chi tiết cho từng tài sản thành phần, giúp nhà đầu tư nhanh chóng nắm bắt được chiến lược rót vốn tối ưu và an toàn nhất.




Hình 4. 5. Giao diện chính của app

Nguồn: Kết quả xây dựng của tác giả

Hệ thống được phân bố bố cục rõ ràng với một thanh điều khiển bên trái (sidebar) chuyên dùng để thiết lập các siêu tham số. Tại đây, người dùng được yêu cầu cung cấp khóa API VNStock (nếu có) nhằm đảm bảo đường truyền trích xuất dữ liệu chứng khoán diễn ra ổn định. Kế tiếp, nhà đầu tư có thể khoanh vùng mục tiêu nghiên cứu bằng cách chỉ định nhóm ngành cụ thể (ví dụ: ngành Thép) thông qua một danh sách thả xuống, đồng thời thiết lập chính xác chuỗi thời gian phân tích từ "Ngày bắt đầu" đến "Ngày kết thúc".

Nhằm tối đa hóa sự tiện lợi và đáp ứng đa dạng nhu cầu của nhà đầu tư, ứng dụng cung cấp hai phương thức nạp dữ liệu riêng biệt. Ở lựa chọn thứ nhất mang tính tự động hóa toàn diện, hệ thống sẽ tự động lấy dữ liệu, huấn luyện thuật toán cho đến nghiệm chứng hiệu suất, ngay sau khi người dùng thiết lập xong tiêu chí ngành và thời gian nghiên cứu. Với lựa chọn thứ hai, chức năng "Upload CSV" hỗ trợ chèn trực tiếp các tập dữ liệu tự chuẩn bị từ bên ngoài, chỉ với điều kiện tệp tin phải chứa đúng định dạng ba cột biến số cốt lõi: "time", "ticker" và "close". Khi các bước tinh chỉnh đã hoàn thiện, lệnh "Bắt đầu" sẽ đóng vai trò như một công tắc khởi chạy mô hình, từ đó đưa ra biểu đồ phân phối tỷ trọng vốn tối ưu nhất cho nhà đầu tư.



Hình 4.7. Kết quả tính toán trên app

Nguồn: Kết quả xây dựng của tác giả

Nhằm mang lại góc nhìn trực quan và tạo điều kiện nghiệm chứng thực tế, tác giả đã triển khai ứng dụng quản trị danh mục đầu tư này công khai trên môi trường web. Các nhà đầu tư quan tâm có thể trực tiếp trải nghiệm phần mềm thông qua mã QR sau:



Hình 3.7. Mã QR App Xây dựng danh mục đầu tư tối ưu bằng mô hình LSTM-GRU

Nguồn: Kết quả xây dựng của tác giả.

TÓM TẮT CHƯƠNG 4

Thông qua các phân tích thực nghiệm tại Chương 4, nghiên cứu đã chứng minh năng lực ưu việt của mô hình lai LSTM-GRU trong việc kiến tạo một danh mục đầu tư hiệu quả hơn hẳn so với các chiến lược phân bổ truyền thống. Những con số thống kê thực tế cho thấy cấu trúc học sâu này không chỉ thúc đẩy tỷ suất sinh lời mục tiêu mà còn duy trì khả năng quản trị rủi ro chặt chẽ, được minh chứng rõ nét qua mức hệ số Sharpe.

Thành quả nghiên cứu này là một minh chứng mạnh mẽ cho khả năng thực thi của các thuật toán học sâu trong lĩnh vực tài chính phức tạp. Đặc biệt, mô hình đã cung cấp một công cụ hỗ trợ ra quyết định phân bổ vốn linh hoạt và thông minh, thích ứng tốt với các đặc thù biến động mạnh và không chắc chắn của thị trường chứng khoán Việt Nam.

CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ QUY TRÌNH ÁP DỤNG

5.1. Kết luận

Đặt mục tiêu cốt lõi là khai thác sức mạnh của các thuật toán học sâu để giải quyết bài toán phân bổ dòng vốn trên thị trường chứng khoán Việt Nam, nghiên cứu đã hoàn thành trọn vẹn các nhiệm vụ đề ra với ba thành quả nổi bật như sau:

Thứ nhất, nghiên cứu đã thiết kế và vận hành thành công kiến trúc mạng nơ-ron lai LSTM-GRU, đồng thời tiến hành đối chuẩn trực tiếp với hai chiến lược cơ bản (phân bổ đều và phân bổ 80 - 20) trên tập dữ liệu thực tế của nhóm ngành Thép. Kết quả kiểm định ngoài mẫu cho thấy mô hình học sâu sở hữu sự vượt trội tuyệt đối khi thiết lập được hệ số Sharpe đạt mức 4.06, cao hơn rất nhiều so với các phương pháp tiếp cận truyền thống. Bằng chứng định lượng này khẳng định năng lực xuất sắc của hệ thống trí tuệ nhân tạo trong việc tối đa hóa lợi nhuận đồng thời triệt tiêu hiệu quả các rủi ro biến động, trở thành một chiến lược hấp dẫn và đáng tin cậy.

Thứ hai, nhằm thu hẹp khoảng cách giữa lý thuyết học thuật và khả năng ứng dụng thực chiến, tác giả đã lập trình và triển khai thành công một phần mềm hỗ trợ ra quyết định đầu tư trực quan. Nền tảng ứng dụng này cho phép người dùng linh hoạt lựa chọn nhóm ngành, tinh chỉnh khung thời gian hoặc trực tiếp tải lên các tệp dữ liệu cá nhân, sau đó tự động hóa hoàn toàn quy trình xử lý để xuất ra biểu đồ tỷ trọng đầu tư cuối cùng. Giải pháp công nghệ này đã tháo gỡ thành công rào cản kỹ thuật, giúp các nhà đầu tư cá nhân hoàn toàn có thể tận dụng triệt để sức mạnh của mô hình học sâu mà không bị đòi hỏi khắt khe về kỹ năng lập trình hay kiến thức chuyên môn AI.

Thứ ba, nghiên cứu đã đúc kết và đề xuất một bộ quy trình chuẩn hóa các bước để ứng dụng học sâu vào công tác lựa chọn cổ phiếu. Chu trình tham chiếu này bao quát toàn diện từ khâu thu thập, tiền xử lý điền khuyết dữ liệu, thiết lập không gian đặc trưng, cho đến tiến trình huấn luyện, nghiệm chứng chiến lược và giám sát tái cân bằng định kỳ. Việc định hình một khung vận hành khoa học và chặt chẽ như vậy không chỉ mang lại giá trị thực tiễn cho nhà đầu tư nhỏ lẻ mà còn hoàn toàn có thể được điều chỉnh để đáp ứng tiêu chuẩn của các tổ chức tài chính hay quỹ đầu tư trong nghiệp vụ quản trị tài sản.

5.2. Khuyến nghị quy trình áp dụng

Để đưa mô hình học sâu vào thực tế một cách hiệu quả, tác giả đề xuất một quy trình triển khai gồm 4 bước cụ thể như sau:



Hình 6.1. Quy trình áp dụng mô hình học sâu

Nguồn: Đề xuất của tác giả

Bước 1: Thu thập và xử lý dữ liệu đầu vào

Công việc đầu tiên và quan trọng nhất là phải xây dựng được một bộ dữ liệu chuẩn. Nhà đầu tư cần xác định danh sách các cổ phiếu mình quan tâm và lựa chọn khoảng thời gian nghiên cứu đủ dài để máy tính có thể học được các quy luật của thị trường. Tại bước này, tác giả lưu ý cần loại bỏ những mã cổ phiếu ít người mua bán hoặc bị thiếu quá nhiều số liệu. Sau khi làm sạch, chúng ta sẽ tính toán mức lợi nhuận và rủi ro của từng mã, từ đó lọc ra những cổ phiếu có phong độ tốt nhất để đưa vào danh mục đầu tư chính thức.

Bước 2: Xây dựng và thiết lập mô hình học sâu

Đây là giai đoạn cốt lõi, nơi mô hình LSTM-GRU đóng vai trò dự báo và chia tiền vào các mã cổ phiếu. Tác giả thực hiện phân chia dữ liệu thành hai phần: một phần để máy học (train) và một phần để kiểm tra kết quả (test). Trong quá trình này, mô hình sẽ sử dụng một hàm tính toán đặc biệt để tự điều chỉnh sao cho danh mục luôn đạt được sự cân bằng giữa tiền lãi và mức độ an toàn. Người dùng cần chú ý tinh chỉnh các thông số như số vòng lặp và tốc độ học của máy để đảm bảo mô hình dự báo chính xác, tránh việc máy chỉ "học vẹt" dữ liệu cũ mà không áp dụng được vào thực tế.

Bước 3: Kiểm tra hiệu suất và so sánh kết quả

Sau khi mô hình đưa ra tỷ lệ chia vốn cho từng mã cổ phiếu, tác giả tiến hành đánh giá xem cách làm này có thực sự tốt hơn các phương pháp truyền thống hay không. Cụ thể, kết quả của AI sẽ được đặt lên bàn cân so sánh với chiến lược chia đều tiền hoặc chiến lược tập trung 80-20. Dựa trên các chỉ số như lợi nhuận thu về và mức độ biến động của tài sản, nhà đầu tư có thể nhìn ra ngay sự vượt trội của mô hình học sâu, từ đó tự tin hơn khi quyết định giải ngân tiền vốn vào thị trường thực tế.

Bước 4: Vận hành thực tế và theo dõi điều chỉnh định kỳ

Khi đã có một danh mục tối ưu, nhà đầu tư bắt đầu triển khai mua bán thực tế. Tuy nhiên, thị trường chứng khoán luôn thay đổi, nên tác giả khuyến nghị không nên giữ nguyên một danh mục quá lâu. Cần có kế hoạch kiểm tra lại định kỳ (khoảng 3 đến 6 tháng một lần) hoặc bất cứ khi nào thị trường có biến động mạnh. Lúc này, người dùng nên nạp dữ liệu mới nhất vào ứng dụng để máy tính toán lại, giúp danh mục luôn bắt kịp xu hướng mới và tránh được những rủi ro bất ngờ.

5.3. Hạn chế của đề tài và hướng nghiên cứu tiếp theo

Mặc dù nghiên cứu đã đạt được những kết quả khả quan trong việc ứng dụng mạng nơ-ron học sâu để quản trị danh mục, tác giả nhận thấy đề tài vẫn còn tồn tại một số rào cản nhất định cần được nhìn nhận khách quan. Trước hết, về phạm vi thực nghiệm, bài viết mới chỉ tập trung phân tích chuyên sâu vào nhóm cổ phiếu ngành Thép. Do đây là nhóm ngành có tính chu kỳ rất mạnh và biến động phụ thuộc nhiều vào giá nguyên vật liệu thế giới, nên các kết quả thu được có thể chưa mang tính đại diện cao nếu áp dụng trực tiếp cho các lĩnh vực khác như ngân hàng, bất động sản hay công nghệ. Điều này đặt ra yêu cầu về việc cần phải mở rộng quy mô dữ liệu sang nhiều nhóm ngành khác nhau để kiểm chứng tính đa dụng của mô hình trong tương lai.

Bên cạnh đó, một hạn chế đáng kể khác nằm ở việc mô hình hiện tại chủ yếu vận hành dựa trên các dữ liệu định lượng như giá đóng cửa lịch sử và các chỉ báo kỹ thuật. Trong thực tế, thị trường chứng khoán Việt Nam lại chịu tác động rất lớn từ các yếu tố định tính như thông báo chính sách của Chính phủ, biến động kinh tế vĩ mô hay các luồng tin tức trên mạng xã hội. Việc thiếu vắng các dữ liệu phi cấu trúc này khiến mô hình đôi khi phản ứng chậm trước những cú sốc tâm lý đám đông hoặc các sự kiện bất ngờ. Ngoài ra, các phép tính thực nghiệm cũng chưa tính toán sát sao đến chi phí thuế, phí giao dịch và vấn đề thanh khoản thực tế, điều này có thể tạo ra một sai lệch nhỏ giữa hiệu suất trên lý thuyết và lợi nhuận thực tế khi giải ngân vốn lớn.

Để khắc phục những thiếu sót trên và nâng cao giá trị thực tiễn cho đề tài, tác giả đề xuất một số định hướng nghiên cứu tiềm năng trong giai đoạn tiếp theo. Hướng đi quan trọng nhất là mở rộng không gian nghiên cứu ra toàn bộ các mã cổ phiếu niêm yết trên sàn HOSE và HNX, giúp mô hình học được cách luân chuyển dòng tiền thông minh giữa các lĩnh vực khác nhau thay vì chỉ bó hẹp trong một ngành duy nhất. Đồng thời, việc tích hợp thêm các kỹ thuật xử lý ngôn ngữ tự nhiên (NLP) để phân tích cảm xúc từ tin tức tài chính sẽ là một bước tiến lớn, giúp mô hình trí tuệ nhân tạo nhạy bén hơn với các biến động vĩ mô và tâm lý thị trường.

Cuối cùng, về mặt công nghệ, tác giả dự kiến sẽ nâng cấp kiến trúc mạng nơ-ron hiện tại lên các mô hình tiên tiến hơn như Transformer hoặc ứng dụng Học tăng cường (Reinforcement Learning) để xây dựng các đại lý giao dịch tự động. Những cải tiến này, kết hợp với việc hoàn thiện giao diện ứng dụng và bổ sung các tính năng cảnh báo rủi ro tự động, sẽ giúp công cụ không chỉ dừng lại ở mức độ gợi ý tỷ trọng mà còn có thể hỗ trợ nhà đầu tư ra quyết định mua bán theo thời gian thực một cách chính xác và hiệu quả nhất.

TÓM TẮT CHƯƠNG 5

Chương cuối đã tổng kết toàn bộ các kết quả đạt được của nghiên cứu, đồng thời thiết lập một lộ trình cụ thể để triển khai mô hình học sâu LSTM - GRU vào thực tiễn thị trường chứng khoán Việt Nam. Bằng các dẫn chứng thực nghiệm, đề tài đã khẳng định năng lực vượt trội của mạng nơ-ron này trong việc tinh chỉnh danh mục đầu tư khi đặt lên bàn cân đối chiếu với những phương thức phân bổ vốn cổ điển. Song song với đó, nghiên cứu cũng giới thiệu một công cụ ứng dụng thực tế, hỗ trợ nhà đầu tư tối giản hóa quy trình quản trị tài sản.

Mặc dù đạt được những kết quả khả quan nhưng vẫn còn những rào cản còn tồn tại như: quy mô so sánh mô hình chưa thực sự bao quát, hệ thống tiêu chí đo lường cần đa dạng hơn, cũng như khung thời gian dữ liệu và tính cá nhân hóa trong sàng lọc cổ phiếu vẫn còn những hạn chế nhất định. Trên cơ sở đó, nghiên cứu đã đề xuất các phương án khắc phục cùng những định hướng phát triển mới nhằm mở rộng biên độ ứng dụng, từ đó gia tăng giá trị thực tiễn cho mô hình trong các giai đoạn tiếp theo.

MỤC LỤC THAM KHẢO

Tài liệu tham khảo tiếng việt

Anh, H. (2024). Thị trường chứng khoán năm 2024: Kỳ vọng phục hồi tích cực. Bộ Tài Chính. https://www.mof.gov.vn/webcenter/portal/btcvn/pages_r/l/tin-bo-taichinh?dDocName=MOFUCM301481

Bùi, Q. H. (2023). Ứng dụng mô hình học sâu trong tối ưu hóa danh mục đầu tư trên thị trường chứng khoán Việt Nam. Tạp chí Kinh tế và Dự báo, 12(839), 84-87.

Đinh, T. M. P., & Lê, T. T. (2021). So sánh các mô hình học máy trong dự đoán giá cổ phiếu tại Việt Nam. Tạp chí Khoa học Thống kê, 32(4), 45-52.

Đoàn Đ. (2022). GIẢI PHÁP QUẢN TRỊ TÀI CHÍNH VÀ ĐẦU TƯ TRONG BỐI CẢNH HỘI NHẬP.

Nguyễn, T. P. T., & Nguyễn, M. Q. (2022). Ứng dụng mô hình mạng nơ-ron nhân tạo trong dự báo giá cổ phiếu tại Việt Nam. Tạp chí Kinh tế và Dự báo, 612(22), 65-70.

Phạm, T. T. X., & Trần, V. D. (2022). Ứng dụng thuật toán học máy vào dự báo giá cổ phiếu tại Việt Nam. Tạp chí Tài Chính Doanh Nghiệp. <https://tapchitaichinh.vn/ungdung-thuat-toan-hoc-may-vao-du-bao-gia-co-phieu-tai-viet-nam-post102676.html>

Trần M. T., Bình A. C. Đ., & Đình T. H. (2025). So sánh các mô hình học máy vào việc dự đoán xu hướng giá chứng khoán. Tạp chí Khoa học HUFLIT, 9(1), Article 1.

Tài liệu tham khảo tiếng anh

Aithal, P. K., Geetha, M., U, D., Savitha, B., & Menon, P. (2023). Real-Time Portfolio Management System Utilizing Machine Learning Techniques. IEEE Access, 11, 3259532608. <https://doi.org/10.1109/ACCESS.2023.3263260>

Barberis, N., & Thaler, R. (2003). Chapter 18 A survey of behavioral finance. In Handbook of the Economics of Finance (Vol. 1, pp. 1053-1128). Elsevier. [https://doi.org/10.1016/S1574-0102\(03\)01027-6](https://doi.org/10.1016/S1574-0102(03)01027-6)

Campbell, J. Y., & Viceira, L. M. (2002). Strategic Asset Allocation: Portfolio Choice for Long-term Investors. Oxford University Press.

El Naqa, I., & Murphy, M. J. (2015). What Is Machine Learning? In I. El Naqa, R. Li, & M. J. Murphy (Eds.), Machine Learning in Radiation Oncology: Theory and Applications (pp. 3-11). Springer International Publishing. https://doi.org/10.1007/978-3-319-183053_1

Fabozzi, F. J., Gupta, F., & Markowitz, H. M. (2002). The Legacy of Modern Portfolio Theory. The Journal of Investing, 11(3), 7-22. <https://doi.org/10.3905/joi.2002.319510>

Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. European Journal of Operational Research, 270(2), 654669. <https://doi.org/10.1016/j.ejor.2017.11.054>

Gasparin, A., Lukovic, S., & Alippi, C. (2022). Deep learning for time series forecasting: The electric load case. CAAI Transactions on Intelligence Technology, 7(1), 1-25. <https://doi.org/10.1049/cit2.12060>

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. <https://www.deeplearningbook.org/>

Huang, C. Y. (2018). Financial Trading as a Game: A Deep Reinforcement Learning Approach (No. arXiv:1807.02787). arXiv. <https://doi.org/10.48550/arXiv.1807.02787>

Jang, J., & Seong, N. (2023). Deep reinforcement learning for stock portfolio optimization by connecting with modern portfolio theory. *Expert Systems with Applications*, 218, 119556. <https://doi.org/10.1016/j.eswa.2023.119556>

Kapoor, N. (2014). Financial Portfolio management: Overview and Decision Making in investment Process. 1(10).

Kelleher, J. D. (2019). Deep Learning. MIT Press. <https://mitpress.mit.edu/9780262537551/deep-learning/>

Kim, H. Y., & Won, C. H. (2018). Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems with Applications*, 103, 25-37. <https://doi.org/10.1016/j.eswa.2018.03.002>

Samuel, A. L. (1959). Some Studies in Machine Learning Using the Game of Checkers. *IBM Journal of Research and Development*, 3(3), 210-229. <https://doi.org/10.1147/rd.33.0210>

Trần M. T., Bình A. C. Đ., & Đình T. H. (2025). So sánh các mô hình học máy vào việc dự đoán xu hướng giá chứng khoán. *Tạp chí Khoa học HUFLIT*, 9(1), Article 1.

Zakamouline, V., & Koekebakker, S. (2009). Portfolio performance evaluation with generalized Sharpe ratios: Beyond the mean and variance. *Journal of Banking & Finance*, 33(7), 1242-1254. <https://doi.org/10.1016/j.jbankfin.2009.01.005>

Zhang, R., Zhao, C., & Lin, G. (2023). Interpretable image-based deep learning for price trend prediction in ETF markets. *The European Journal of Finance*, 1-29. <https://doi.org/10.1080/1351847X.2023.2275567>

Phụ lục

1. Danh sách các doanh nghiệp thép niêm yết trên thị trường chứng khoán Việt Nam.

STT	Mã	Tên doanh nghiệp
1	BCA	Công ty Cổ phần B.C.H
2	BVG	Công ty Cổ phần Group Bắc Việt
3	CBI	Công ty Cổ phần Gang thép Cao Bằng
4	DFC	Công ty Cổ phần Xích Líp Đông Anh
5	DTL	Công ty Cổ phần Đại Thiên Lộc
6	GDA	Công ty Cổ phần Tôn Đông Á

7	HLA	Công ty Cổ phần Hữu Liên Á Châu
8	HMC	Công ty Cổ phần Kim khí TP.HCM - VNSTEEL
9	HMG	Công ty Cổ phần Kim khí Hà Nội - VNSTEEL
10	HPG	Công ty Cổ phần Tập đoàn Hòa Phát
11	HSG	Công ty Cổ phần Tập đoàn Hoa Sen
12	HSV	Công ty Cổ phần Tập đoàn HSV Việt Nam
13	ITQ	Công ty Cổ phần Tập đoàn Thiên Quang
14	KKC	Công ty Cổ phần Tập đoàn Thành Hưng (Kim khí Hải Phòng)
15	KMT	Công ty Cổ phần Kim khí Miền Trung
16	KTL	Công ty Cổ phần Kim khí Thăng Long
17	KVC	Công ty Cổ phần Sản xuất Xuất nhập khẩu Inox Kim Vĩ
18	MEL	Công ty Cổ phần Thép Mê Lin
19	MHL	Công ty Cổ phần Minh Hữu Liên
20	NKG	Công ty Cổ phần Thép Nam Kim
21	PAS	Công ty Cổ phần Quốc tế Phương Anh
22	POM	Công ty Cổ phần Thép Pomina
23	SHA	Công ty Cổ phần Sơn Hà Sài Gòn
24	SHI	Công ty Cổ phần Quốc tế Sơn Hà
25	SMC	Công ty Cổ phần Đầu tư Thương mại SMC
26	SSM	Công ty Cổ phần Chế tạo Kết cấu Thép VNECO.SSM
27	TDS	Công ty Cổ phần Thép Thủ Đức - VNSTEEL
28	TIS	Công ty Cổ phần Gang thép Thái Nguyên (TISCO)
29	TLH	Công ty Cổ phần Tập đoàn Thép Tiến Lên
30	TMG	Công ty Cổ phần Kim loại Màu Thái Nguyên - VIMICO
31	TNA	Công ty Cổ phần Thương mại Xuất nhập khẩu Thiên Nam
32	TNB	Công ty Cổ phần Thép Nhà Bè - VNSTEEL
33	TNI	Công ty Cổ phần Tập đoàn Thành Nam
34	TNS	Công ty Cổ phần Thép Tấm lá Thống Nhất
35	TTH	Công ty Cổ phần Thương mại và Dịch vụ Tiến Thành
36	TTS	Công ty Cổ phần Cán thép Thái Trung
37	TVN	Tổng Công ty Thép Việt Nam - CTCP (VNSTEEL)

38	VCA	Công ty Cổ phần Thép VICASA - VNSTEEL
39	VDT	Công ty Cổ phần Lưới thép Bình Tây
40	VGL	Công ty Cổ phần Mạ kẽm Công nghiệp VINGAL - VNSTEEL
41	VGS	Công ty Cổ phần Ống thép Việt Đức VG PIPE

1. Các đoạn code đã sử dụng trong nghiên cứu

#1. Khởi tạo thư viện import warnings

```
warnings.filterwarnings("ignore")
```

```
import numpy as np import
```

```
pandas as pd import
```

```
matplotlib.pyplot as plt import
```

```
squarify
```

```
from IPython.display import display
```

```
from tensorflow.keras.models import Sequential from
```

```
tensorflow.keras.layers import Input, LSTM, GRU, Dense from
```

```
tensorflow.keras.optimizers import Adam from
```

```
tensorflow.keras import backend as K
```

#2. Tham số import

```
tensorflow as tf import
```

```
random import numpy
```

```
as np
```

```
RF_ANNUAL = 0.045
```

```
TRADING_DAYS = 252
```

```
LSTM_UNITS = 256
```

```
GRU_UNITS = 256
```

```
EPOCHS = 100
```

```
BATCH_SIZE = 32
```

```
WINDOW_SIZE = 30
```

```
SEED = 42
```

```
TRAIN_START = "2015-01-01"
```

```
TRAIN_END = "2024-12-31"
```

```
TEST_START = "2025-01-01"
```

```
TEST_END = "2025-12-31"
```

```
# Fix seed random.seed(SEED) np.random.seed(SEED)
```

```
tf.random.set_seed(SEED) #3. Chọn ngành from
```

```
data.industry_tickers import INDUSTRY_TICKERS #
```

```
Chọn 1 hoặc nhiều ngành ở đây
```

```
SELECTED_INDUSTRIES = ["Thép"]
```

```
# SELECTED_INDUSTRIES = ["Thép", "Vật liệu xây dựng"]
```

```
selected_tickers = []
```

```
for industry in SELECTED_INDUSTRIES:
```

```
    selected_tickers.extend(INDUSTRY_TICKERS[industry])
```

```

# Xóa mã trùng selected_tickers =
sorted(list(set(selected_tickers)))

print("Ngành đã chọn:", SELECTED_INDUSTRIES)
print("Tổng số mã:", len(selected_tickers)) print(selected_tickers)

#4. Lấy giá đóng cửa của ngành đã chọn
import time import pandas as pd from
vnstock import Vnstock

all_data = [] failed_tickers
= []

print(f'Dang tải dữ liệu cho {len(selected_tickers)} mã:", SELECTED_INDUSTRIES)
request_count = 0 window_start = time.time()

for i, ticker in enumerate(selected_tickers, start=1):
    success = False
    retry_count = 0    max_retry
    = 5

    while not success and retry_count < max_retry:
    try:
        stock = Vnstock().stock(symbol=ticker, source="KBS")
    df = stock.quote.history(        start=TRAIN_START,
    end=TEST_END,            interval="1D"
        )

```

```

    if df is None or df.empty:
        print(f"[{i}/{len(selected_tickers)}] Không có dữ liệu: {ticker}")
    failed_tickers.append(ticker)          success = True          break

    df = df.copy()
    df["ticker"] = ticker
    if "time" not in df.columns:
    if "date" in df.columns:
        df["time"] = df["date"]
    elif "datetime" in df.columns:
        df["time"] = df["datetime"]
    else:
        raise ValueError(f"{ticker}: Không tìm thấy cột thời gian.")

    keep_cols = [c for c in ["time", "open", "high", "low",
"close", "volume", "ticker"] if c in df.columns]
    ]
    df = df[keep_cols]

    all_data.append(df)
    {ticker} - {len(df)} dòng")
    print(f"[{i}/{len(selected_tickers)}] OK: success = True

    request_count += 1
time.sleep(3.2)

    if request_count >= 18:

```

```

        elapsed = time.time() - window_start
    if elapsed < 60:
        sleep_time = 60 - elapsed
        print(f'Dang nghỉ {sleep_time:.1f}s để tránh rate limit...')
        time.sleep(sleep_time)

        request_count = 0
        window_start = time.time()

    except Exception as e:
        msg = str(e).lower()
        retry_count += 1

        if "rate limit" in msg or "429" in msg or "forbidden" in msg:
            wait_time = 30
            print(f'[{i}/{len(selected_tickers)}] Bị chặn ở
            {ticker} -> nghỉ {wait_time}s
            ({retry_count}/{max_retry})')
            time.sleep(wait_time)
        else:
            print(f'[{i}/{len(selected_tickers)}] Lỗi {ticker}: {e}')
            failed_tickers.append(ticker)
            break

        if not success and ticker not in failed_tickers:
            failed_tickers.append(ticker)

    if all_data:

```

```

raw_data = pd.concat(all_data, ignore_index=True)
print("\n=== HOÀN TẤT ===") print("Raw data
shape:", raw_data.shape) print("Số mã lỗi / không có dữ
liệu:", len(failed_tickers)) if failed_tickers:

    print("Danh sách lỗi:", failed_tickers)
display(raw_data.head()) else:
    raise ValueError("Không tải được dữ liệu cho bất kỳ mã nào.")

#5. Pivot thành bảng giá
pivot_df_clean =
raw_data.pivot_table( index="time",
columns="ticker", values="close",
aggfunc="last"
).sort_index()

pivot_df_clean.index = pd.to_datetime(pivot_df_clean.index) pivot_df_clean
= pivot_df_clean.sort_index()

print("Shape:", pivot_df_clean.shape)
display(pivot_df_clean.head()) display(pivot_df_clean.tail())

#6. Tính daily return
# Fill missing trên GIÁ trước, không fill trên return price_filled
= pivot_df_clean.ffill()

# Tính return returns_df =
price_filled.pct_change() # Xử lý
inf/nan returns_df =

```

```

returns_df.replace([np.inf, -np.inf],
np.nan)

# Loại dòng đầu tiên và các dòng còn thiếu returns_df
= returns_df.dropna(how="any")

print("Kích thước returns_df:", returns_df.shape) display(returns_df.head())

print("Mean daily return:") display(returns_df.mean())

print("Max                daily                return:")
display(returns_df.max().sort_values(ascending=False).head(10))

print("Min daily return:") display(returns_df.min().sort_values().head(10))
#7. Tính Sharpe từng mã và chọn ra top 10 mã có sharpe cao nhất để train rf_daily
= RF_ANNUAL / TRADING_DAYS

mean_ret = returns_df.mean() std_ret =
returns_df.std().replace(0, np.nan)

sharpe_ratio = ((mean_ret - rf_daily) / std_ret).dropna().sort_values(ascending=False)

TOP_N = 10
top_10_symbols = sharpe_ratio.head(TOP_N).index.tolist()

print(f"Top {TOP_N} mã theo Sharpe từ ngành:", SELECTED_INDUSTRIES)
print(top_10_symbols)

```

```
display(sharpe_ratio.head(TOP_N))
```

Top 10 mã có Sharpe cao nhất

```
Top 10 mã theo Sharpe từ ngành: ['Thép']
['BCA', 'CBI', 'DFC', 'VGS', 'TNI', 'TMG', 'TNB', 'HMC', 'KKC', 'HPG']
ticker
BCA      0.049659
CBI      0.043063
DFC      0.042114
VGS      0.036488
TNI      0.034966
TMG      0.033035
TNB      0.031066
HMC      0.020482
KKC      0.019298
HPG      0.017934
dtype: float64
```

Nguồn: Kết quả tính toán của tác giả.

#8. Chia tập train, test

```
train_prices = price_top10.loc[TRAIN_START:TRAIN_END].copy() test_prices
= price_top10.loc[TEST_START:TEST_END].copy()
```

```
# Fill missing trên giá train_prices =
train_prices.sort_index().ffill().bfill() test_prices =
test_prices.sort_index().ffill().bfill()
```

```
# Tính return từ giá đã fill train_returns =
train_prices.pct_change().replace([np.inf, -np.inf], np.nan) test_returns =
test_prices.pct_change().replace([np.inf, -np.inf], np.nan)
```

```
# Bỏ dòng đầu do pct_change train_returns =
train_returns.dropna(how="any") test_returns =
test_returns.dropna(how="any")
```

```

print("train_prices:", train_prices.shape)
print("test_prices :", test_prices.shape)
print("train_returns:", train_returns.shape)
print("test_returns :", test_returns.shape)

```

```

print("NaN train_prices:", train_prices.isna().sum().sum())
print("NaN test_prices :", test_prices.isna().sum().sum()) print("NaN
train_returns:", train_returns.isna().sum().sum()) print("NaN
test_returns :", test_returns.isna().sum().sum())

```

```

display(train_prices.head())
display(train_returns.head()) #9. Khởi tạo mô
hình from sklearn.preprocessing import
StandardScaler

```

```

HORIZON = 5 # dùng trung bình return 5 ngày tới

```

```

def compute_rsi(price_df, period=14):
    delta = price_df.diff()
    gain = delta.clip(lower=0)
    loss = -delta.clip(upper=0)

    avg_gain    = gain.rolling(period, min_periods=period).mean()
    avg_loss    = loss.rolling(period, min_periods=period).mean()

```

```

    rs = avg_gain / (avg_loss + 1e-9)
    rsi = 100 - (100 / (1 + rs))    return
    rsi

```

```

def build_features(price_df, return_df):

```

```

    common_idx = price_df.index.intersection(return_df.index)
    price_df = price_df.loc[common_idx].copy()    return_df =
    return_df.loc[common_idx].copy()

```

```

    price_df = price_df.replace([np.inf, -np.inf], np.nan).ffill().bfill()
    return_df = return_df.replace([np.inf, -np.inf], np.nan).fillna(0)

```

```

    feat_list = []

```

```

    ret_1 = return_df.copy()    ret_1.columns =
    [f'{c}_ret1' for c in ret_1.columns]
    feat_list.append(ret_1)

```

```

    ret_5 = price_df.pct_change(5)    ret_5.columns =
    [f'{c}_ret5' for c in ret_5.columns]
    feat_list.append(ret_5)

```

```

    ret_10 = price_df.pct_change(10)
    ret_10.columns = [f'{c}_ret10' for c in ret_10.columns]
    feat_list.append(ret_10)

```

```

ma5_ratio = price_df / (price_df.rolling(5, min_periods=5).mean() + 1e-9) - 1
ma5_ratio.columns = [f'{c}_ma5_ratio' for c in ma5_ratio.columns]
feat_list.append(ma5_ratio)

ma10_ratio = price_df / (price_df.rolling(10, min_periods=10).mean() + 1e-9) - 1
ma10_ratio.columns = [f'{c}_ma10_ratio' for c in ma10_ratio.columns]
feat_list.append(ma10_ratio)

vol5 = return_df.rolling(5, min_periods=5).std()
vol5.columns = [f'{c}_vol5' for c in vol5.columns]
feat_list.append(vol5)

vol10 = return_df.rolling(10, min_periods=10).std()
vol10.columns = [f'{c}_vol10' for c in vol10.columns]
feat_list.append(vol10)

mom5 = price_df.pct_change(5)    mom5.columns =
[f'{c}_mom5' for c in mom5.columns]
feat_list.append(mom5)

rsi14 = compute_rsi(price_df, period=14) / 100.0
rsi14.columns = [f'{c}_rsi14' for c in rsi14.columns] feat_list.append(rsi14)

features = pd.concat(feat_list, axis=1)    features =
features.replace([np.inf, -np.inf], np.nan)    features =
features.dropna(axis=0, how="any")

```

```
return features
```

```
train_features = build_features(train_prices, train_returns) test_features
= build_features(test_prices, test_returns)
```

```
print("train_features shape:", train_features.shape) print("test_features
shape :", test_features.shape) display(train_features.head())
```

```
scaler = StandardScaler()
```

```
train_features_scaled =
pd.DataFrame(    scaler.fit_transform(train_features),
index=train_features.index,    columns=train_features.columns
)
```

```
test_features_scaled = pd.DataFrame(
    scaler.transform(test_features),
    index=test_features.index,
    columns=test_features.columns
)
```

```
train_target_returns      =      train_returns.loc[train_features_scaled.index].copy()
test_target_returns = test_returns.loc[test_features_scaled.index].copy()
```

```
def    create_sequences_and_targets(features_df,    target_returns_df,    window_size,
horizon=5):
    X, y, dates = [], [], []
```

```

    feat_values = features_df.values.astype(np.float32)
    target_values = target_returns_df.values.astype(np.float32)    idx
    = features_df.index

    for i in range(len(features_df) - window_size - horizon + 1):
        X.append(feat_values[i:i + window_size])
        y.append(target_values[i + window_size:i + window_size + horizon].mean(axis=0))
    dates.append(idx[i + window_size + horizon - 1])

    return np.array(X, dtype=np.float32), np.array(y, dtype=np.float32), pd.Index(dates)

X_train,          y_train_target,          train_seq_dates          =
create_sequences_and_targets(          train_features_scaled,  train_target_returns,
WINDOW_SIZE, horizon=HORIZON
)

X_test,          y_test_target,          test_seq_dates          =
create_sequences_and_targets(          test_features_scaled,          test_target_returns,
WINDOW_SIZE, horizon=HORIZON
)

print("X_train shape:", X_train.shape)
print("y_train_target shape:", y_train_target.shape)
print("X_test shape :", X_test.shape) print("y_test_target
shape :", y_test_target.shape)

```

10. Khởi tạo hàm Sharpe Loss from tensorflow.keras import
backend as K

LAMBDA_ENTROPY = 0.01

def sharpe_loss(y_true, y_pred):

 portfolio_returns = K.sum(y_true * y_pred, axis=1) portfolio_returns =
 portfolio_returns - (RF_ANNUAL / TRADING_DAYS)

 mean_returns = K.mean(portfolio_returns)
 std_returns = K.std(portfolio_returns)

 sharpe = mean_returns / (std_returns + 1e-9)

 entropy = -K.sum(y_pred * K.log(y_pred + 1e-9), axis=1)
 entropy = K.mean(entropy)

 return -sharpe - LAMBDA_ENTROPY * entropy

11. Nâng cấp mô hình

from tensorflow.keras.models import Sequential from
tensorflow.keras.layers import Input, LSTM, GRU, Dense, Dropout
from tensorflow.keras.optimizers import Adam

def build_lstm_gru_model(timesteps, n_features, n_assets):

 model = Sequential([
 Input(shape=(timesteps, n_features)),

```

LSTM(
    96,
    return_sequences=True,
activation="tanh",
recurrent_activation="sigmoid"
),
Dropout(0.2),

GRU(
    48,
    return_sequences=False,
activation="tanh",
recurrent_activation="sigmoid"
),
Dropout(0.2),

Dense(64, activation="relu"),
Dropout(0.1),

Dense(n_assets, activation="softmax")
])
return model

model_lstm_gru =
build_lstm_gru_model(    timesteps=X_train.shape[1],
n_features=X_train.shape[2],
n_assets=y_train_target.shape[1]

```

)

```
model_lstm_gru.compile( optimizer=Adam(learning_rate
=0.0005), loss=sharpe_loss
)
```

model_lstm_gru.summary() #12. Train model nhiều Seed

```
import os
import random
import tensorflow as tf
from tensorflow.keras.callbacks import EarlyStopping, ReduceLROnPlateau
```

```
def set_seed(seed=42):
    os.environ["PYTHONHASHSEED"] = str(seed)
    random.seed(seed)
    np.random.seed(seed)
    tf.random.set_seed(seed)
```

```
def train_one_run(seed, X_train, y_train_target):
    set_seed(seed)
```

```
    model =
    build_lstm_gru_model(      timesteps=X_train.shape[1],
    n_features=X_train.shape[2],
    n_assets=y_train_target.shape[1]
    )
```

```
model.compile(optimizer=Adam(learning_rate=0.0005),
              loss=sharpe_loss
              )
```

```
callbacks =
[ EarlyStopping( monitor
itor="val_loss",
patience=10,
restore_best_weights=True
),
```

```
ReduceLROnPlateau( monitor
="val_loss", factor=0.5,
patience=5, min_lr=1e-5
)
]
```

```
history =
model.fit( X_train,
y_train_target,
epochs=100,
batch_size=32,
shuffle=False,
verbose=0,
validation_split=0.2,
callbacks=callbacks
```

)

return model, history

#13. Chạy nhiều Seed và chọn model tốt nhất

results_runs = []

best_model = None

best_sharpe = -1e9 best_seed =

None best_history = None

best_portfolio_returns = None

best_pred_weights_test =

None seed_list = [7, 21, 42, 99,
123]

for seed in seed_list:

 model, history = train_one_run(seed, X_train, y_train_target)

 pred_weights_test = model.predict(X_test, verbose=0)

 weights_test_df =

 pd.DataFrame(pred_weights_test,

 index=test_seq_dates,

 columns=top_10_symbols

)

```

y_test_df =
pd.DataFrame(      y_test_target,
index=test_seq_dates,
columns=top_10_symbols
)

```

```

portfolio_returns = (weights_test_df * y_test_df).sum(axis=1)

```

```

run_er = portfolio_returns.mean() * TRADING_DAYS
run_std = portfolio_returns.std() * np.sqrt(TRADING_DAYS)
run_sharpe = (run_er - RF_ANNUAL) / (run_std + 1e-12)
results_runs.append({

    "seed": seed,

    "Lợi nhuận TB năm": run_er,

    "Độ lệch chuẩn năm": run_std,

    "Sharpe": run_sharpe

})

```

```

if run_sharpe > best_sharpe:      best_sharpe =
run_sharpe      best_seed = seed      best_model =
model      best_history = history
best_portfolio_returns = portfolio_returns.copy()
best_pred_weights_test = pred_weights_test.copy()

```

```

results_runs_df = pd.DataFrame(results_runs).sort_values("Sharpe",
ascending=False).reset_index(drop=True)

```

```

print("Best seed:", best_seed)
print("Best Sharpe:", best_sharpe)
display(results_runs_df)

portfolio_returns_lstm_dynamic = best_portfolio_returns.copy()

weights_lstm_gru_avg = best_pred_weights_test.mean(axis=0)
results_LSTM_GRU = pd.DataFrame({
    "Asset": top_10_symbols,
    "Weight": weights_lstm_gru_avg
}).sort_values("Weight", ascending=False).reset_index(drop=True)

print("Tổng trọng số trung bình:", results_LSTM_GRU["Weight"].sum())
display(results_LSTM_GRU)

```

Bảng chạy các Seed

	seed	Lợi nhuận TB năm	Độ lệch chuẩn năm	Sharpe
0	42	0.596075	0.135804	4.057868
1	7	0.419121	0.105505	3.546001
2	99	0.464772	0.134202	3.127912
3	21	0.357365	0.101504	3.077356
4	123	0.218198	0.119699	1.446942

Nguồn: Kết quả tính toán của tác giả.

```
#14. Tính ER, STD def port_char(weights_df, returns_df, annualize=True,
freq=TRADING_DAYS):
```

```
    er = returns_df.mean().reset_index()
    er.columns = ["Asset", "Er"]
```

```
    weights_merged = pd.merge(weights_df, er, on="Asset", how="left")
    weights_merged["Er"] = weights_merged["Er"].fillna(0.0)
```

```
    portfolio_er_daily = np.dot(weights_merged["Weight"], weights_merged["Er"])
    cov_matrix = returns_df.cov()    asset_order = weights_merged["Asset"].tolist()
    cov_matrix = cov_matrix.loc[asset_order, asset_order]
```

```
    w = weights_merged["Weight"].values    portfolio_std_daily =
    np.sqrt(np.dot(w, np.dot(cov_matrix, w)))
```

```
    if annualize:
        portfolio_er = portfolio_er_daily * freq
    portfolio_std_dev = portfolio_std_daily * np.sqrt(freq)    else:
        portfolio_er = portfolio_er_daily
    portfolio_std_dev = portfolio_std_daily
```

```
    return portfolio_er, portfolio_std_dev
```

```
def port_char_from_series(portfolio_return_series, annualize=True,
freq=TRADING_DAYS):
```

```
    portfolio_return_series = pd.Series(portfolio_return_series).dropna()
```

```

er_daily      =      portfolio_return_series.mean()
std_daily = portfolio_return_series.std()

```

```

if annualize:
    er = er_daily * freq      std =
std_daily * np.sqrt(freq)  else:
    er  =  er_daily
std = std_daily

```

```

return er, std

```

```

#15. Tính Sharpe danh mục def sharpe_port(weights_df, returns_df,
rf=RF_ANNUAL, freq=TRADING_DAYS):  portfolio_er, portfolio_std_dev =
port_char(      weights_df,      returns_df,      annualize=True,      freq=freq
    )
    sharpe_ratio = (portfolio_er - rf) / (portfolio_std_dev + 1e-12)
return sharpe_ratio

```

```

def      sharpe_from_series(portfolio_return_series,      rf=RF_ANNUAL,
freq=TRADING_DAYS):
    portfolio_er, portfolio_std_dev =
port_char_from_series(      portfolio_return_series,
annualize=True,      freq=freq
    )
    sharpe_ratio = (portfolio_er - rf) / (portfolio_std_dev + 1e-12) return
sharpe_ratio

```

#16. Phân bổ đều

```

Allo_1 = pd.DataFrame({

```

```

"Asset": top_10_symbols,
"Weight": [1 / len(top_10_symbols)] * len(top_10_symbols) })

print("Tổng trọng số Allo_1:", Allo_1["Weight"].sum())
display(Allo_1) #17. Phân bổ 80 – 20 def
build_allocation_80_20(train_returns):
    rf_daily = RF_ANNUAL / TRADING_DAYS

    mean_ret = train_returns.mean()    std_ret =
train_returns.std().replace(0, np.nan)
    sharpe_train = ((mean_ret - rf_daily) /
std_ret).dropna().sort_values(ascending=False)

    ranked          =          sharpe_train.reset_index()
ranked.columns = ["Asset", "Score"]

    n_assets = len(ranked)    top_count = max(1,
int(np.ceil(0.2 * n_assets)))    bottom_count =
n_assets - top_count

    top_weights = [0.8 / top_count] * top_count    bottom_weights = [0.2 /
bottom_count] * bottom_count if bottom_count > 0 else []

    ranked["Weight"] = top_weights + bottom_weights
return ranked[["Asset", "Weight"]]

```

```
Allo_2 = build_allocation_80_20(train_returns)
```

```
print("Tổng trọng số Allo_2:", Allo_2["Weight"].sum()) display(Allo_2)
```