

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

ĐÁNH GIÁ ĐỘ CHÍNH XÁC CỦA MÔ HÌNH PROPHET VÀ
ARIMA TRONG DỰ BÁO GIÁ CỔ PHIẾU TRÊN
SỞ GIAO DỊCH CHỨNG KHOÁN TP. HCM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG
MÃ SỐ: 7340201

NGUYỄN NGỌC LAN TÂY

TP. HỒ CHÍ MINH, NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

ĐÁNH GIÁ ĐỘ CHÍNH XÁC CỦA MÔ HÌNH PROPHET VÀ
ARIMA TRONG DỰ BÁO GIÁ CỔ PHIẾU TRÊN
SỞ GIAO DỊCH CHỨNG KHOÁN TP. HCM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG

MÃ SỐ: 7340201

Họ và tên sinh viên: NGUYỄN NGỌC LAN

TÂY

Mã số sinh viên: 050609212182

Lớp sinh hoạt: HQ9 – GE06

NGƯỜI HƯỚNG DẪN KHOA HỌC

TS. NGUYỄN DUY LINH

TP. HỒ CHÍ MINH, NĂM 2025

TÓM TẮT

Trong bối cảnh thị trường chứng khoán Việt Nam ngày càng biến động mạnh mẽ dưới ảnh hưởng của các yếu tố kinh tế, chính trị và sự kiện toàn cầu, việc dự báo chính xác giá cổ phiếu trở thành yếu tố quan trọng giúp nhà đầu tư tối ưu hóa lợi nhuận và giảm thiểu rủi ro. Tuy nhiên, việc lựa chọn mô hình dự báo phù hợp vẫn là một thách thức lớn đối với các nhà phân tích tài chính. Nghiên cứu này tập trung vào việc so sánh hai mô hình dự báo chuỗi thời gian phổ biến, Prophet và ARIMA, nhằm đánh giá độ chính xác và khả năng ứng dụng của từng mô hình trong việc dự báo giá cổ phiếu của các công ty niêm yết trên HOSE, đại diện cho mỗi ngành nghề khác nhau. Mục tiêu của nghiên cứu là đánh giá và so sánh hiệu quả của hai mô hình này trong điều kiện thị trường chứng khoán Việt Nam, đặc biệt là trong các giai đoạn có sự biến động mạnh. Phương pháp nghiên cứu bao gồm thu thập dữ liệu giá đóng cửa cổ phiếu của các công ty từ năm 2020 đến 2025, với các chỉ số đánh giá như RMSE, MAE và MAPE được sử dụng để đo lường độ chính xác của mô hình. Dữ liệu được làm sạch và xử lý trước khi được áp dụng vào hai mô hình. Kết quả nghiên cứu cho thấy mô hình Prophet có khả năng xử lý tốt các yếu tố mùa vụ, xu hướng và biến động bất thường, mang lại kết quả dự báo ổn định và chính xác hơn so với ARIMA trong nhiều trường hợp. Tuy nhiên, mô hình ARIMA vẫn cho thấy hiệu quả đáng kể khi áp dụng vào các chuỗi dữ liệu ổn định, ít bị ảnh hưởng bởi các yếu tố ngoại lai. Từ kết quả này, nghiên cứu khuyến nghị rằng các nhà đầu tư và tổ chức tài chính nên lựa chọn mô hình dự báo linh hoạt, tùy thuộc vào đặc thù của dữ liệu và mục tiêu cụ thể. Kết luận của nghiên cứu khẳng định rằng trong môi trường thị trường chứng khoán Việt Nam với nhiều yếu tố bất định, mô hình Prophet sẽ mang lại hiệu quả dự báo tốt hơn, giúp nhà đầu tư đưa ra quyết định đầu tư chính xác và kịp thời.

Từ khóa: *Dự báo giá chứng khoán, mô hình ARIMA, mô hình Prophet, Sở Giao dịch Chứng khoán TP. Hồ Chí Minh, độ chính xác dự báo, chuỗi thời gian.*

ABSTRACT

In the context of the Vietnamese stock market experiencing increasing volatility under the influence of economic, political, and global events, accurate stock price forecasting has become a crucial factor for investors to optimize returns and minimize risks. However, selecting an appropriate forecasting model remains a significant challenge for financial analysts. This study focuses on comparing two popular time series forecasting models, Prophet and ARIMA, to evaluate their accuracy and applicability in forecasting the stock prices of companies listed on the HOSE, which represent various industries. The goal of the research is to assess and compare the effectiveness of these two models in the context of the volatile Vietnamese stock market, especially during periods of significant fluctuations. The research method involves collecting daily closing stock price data of companies from 2020 to 2025, with performance indicators such as RMSE, MAE, and MAPE used to measure the accuracy of the models. The data is cleaned and preprocessed before being applied to the ARIMA and Prophet models. The results indicate that the Prophet model handles seasonality, trends, and unexpected fluctuations better, providing more stable and accurate forecasts than ARIMA in many cases. However, the ARIMA model still demonstrates significant effectiveness when applied to stable time series with fewer external influences. Based on these findings, the research recommends that investors and financial institutions select a flexible forecasting model depending on the characteristics of the data and specific goals. The conclusion emphasizes that in the uncertain environment of the Vietnamese stock market, the Prophet model will provide better forecasting performance, helping investors make accurate and timely investment decisions.

Keywords: *Stock price forecasting, ARIMA model, Prophet model, Ho Chi Minh Stock Exchange, forecasting accuracy, time series.*

LỜI CAM ĐOAN

Khóa luận này là công trình nghiên cứu riêng của em, kết quả nghiên cứu là trung thực, trong đó không có các nội dung đã được công bố trước đây hoặc các nội dung do người khác thực hiện, ngoại trừ các trích dẫn được dẫn nguồn đầy đủ trong khóa luận.

TP. Hồ Chí Minh, ngày ... tháng ... năm 2025

Ký tên

Nguyễn Ngọc Lan Tây

LỜI CẢM ƠN

Đầu tiên, em xin gửi lời cảm ơn chân thành và sâu sắc nhất tới thầy TS. Nguyễn Duy Linh, người hướng dẫn khoa học của em. Thầy không chỉ cung cấp những chỉ dẫn chuyên môn quý báu mà còn luôn đồng hành cùng em trong suốt quá trình nghiên cứu và hoàn thành khóa luận. Sự tận tâm, hỗ trợ nhiệt tình của thầy là nguồn động lực lớn lao giúp em hoàn thành công trình nghiên cứu này.

Em cũng xin gửi lời cảm ơn tới các thầy cô giáo trường Đại học Ngân hàng TP. Hồ Chí Minh, những người đã trang bị cho em nền tảng kiến thức chuyên môn vững vàng trong suốt quá trình học tập. Các thầy cô không chỉ là những người giảng dạy mà còn là nguồn cảm hứng to lớn để em có thể thực hiện nghiên cứu này. Nhờ sự hướng dẫn tận tâm của các thầy cô, em đã có cơ hội xây dựng nền tảng vững chắc và vận dụng chúng hiệu quả vào thực tiễn.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc tới gia đình, người thân và bạn bè đã luôn bên cạnh, ủng hộ và động viên em trong suốt quãng thời gian thực hiện khóa luận. Sự yêu thương, sự hy sinh và sự hỗ trợ vô điều kiện của gia đình là nguồn động viên lớn nhất đối với em trong suốt quá trình học tập và nghiên cứu. Gia đình và bạn bè đã tạo ra một môi trường đầy cảm hứng, giúp em vượt qua những trở ngại và thử thách để hoàn thành khóa luận này.

Cuối cùng, em xin cảm ơn tất cả những ai đã giúp đỡ, ủng hộ và đóng góp vào sự thành công của khóa luận này. Em xin ghi nhận tất cả sự hỗ trợ của mọi người và trân trọng cảm ơn!

Trong quá trình thực hiện đề tài, do kiến thức và kinh nghiệm thực tiễn còn hạn chế, chắc chắn không thể tránh khỏi những thiếu sót. Em rất mong nhận được sự thông cảm cùng những góp ý quý báu từ thầy cô, để từ đó có thể nâng cao thêm kỹ năng và hoàn thiện khóa luận.

TP. Hồ Chí Minh, ngày ... tháng ... năm 2025

Ký tên

Nguyễn Ngọc Lan Tây

MỤC LỤC

TÓM TẮT	i
ABSTRACT	ii
LỜI CAM ĐOAN	iii
LỜI CẢM ƠN	iv
DANH MỤC CHỮ VIẾT TẮT	ix
DANH MỤC HÌNH.....	xi
DANH MỤC BẢNG.....	xii
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU	1
1.1. Lý do chọn đề tài	1
1.2. Mục tiêu nghiên cứu.....	3
1.2.1. Mục tiêu tổng quát	3
1.2.2. Mục tiêu cụ thể.....	3
1.3. Câu hỏi nghiên cứu.....	4
1.4. Đối tượng và phạm vi nghiên cứu	4
1.4.1. Đối tượng nghiên cứu	4
1.4.2. Phạm vi nghiên cứu.....	4
1.5. Phương pháp nghiên cứu.....	5
1.6. Đóng góp của đề tài.....	6
1.7. Kết cấu của nghiên cứu	6
KẾT LUẬN CHƯƠNG 1.....	9
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU	10
2.1. Cơ sở lý thuyết về dự báo chuỗi thời gian	10
2.1.1. Khái niệm về chuỗi thời gian.....	10

2.1.2.	Khái niệm về dự báo chuỗi thời gian	11
2.2.	Khái niệm và đặc điểm của hai mô hình	13
2.2.1.	Mô hình Prophet	13
2.2.2.	Mô hình ARIMA	15
2.3.	Các chỉ số đánh giá hiệu suất mô hình	17
2.3.1.	Chỉ số RMSE	18
2.3.2.	Chỉ số MAE	19
2.3.3.	Chỉ số MAPE	20
2.4.	Tổng quan các nghiên cứu trước	21
2.4.1	Nghiên cứu ngoài nước	21
2.4.2	Nghiên cứu trong nước	24
2.4.3	Khoảng trống của nghiên cứu	27
KẾT LUẬN CHƯƠNG 2		29
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU		30
3.1.	Quy trình trình nghiên cứu	30
3.2.	Phương pháp nghiên cứu	32
3.3.	Dữ liệu nghiên cứu	33
3.3.1.	Mẫu nghiên cứu	33
3.3.2.	Thu thập và tiền xử lý dữ liệu	33
3.3.3.	Chia tập dữ liệu	34
3.3.4.	Công cụ nghiên cứu	35
3.4.	Mô hình nghiên cứu và kỹ thuật dự báo	36
3.4.1.	Giả thuyết nghiên cứu	36
3.4.2.	Mô hình Prophet	36

3.4.3.	Mô hình ARIMA.....	39
3.4.4.	Lý do lựa chọn mô hình Prophet và ARIMA trong nghiên cứu	41
3.5.	Phương pháp so sánh và đánh giá hiệu suất mô hình.....	42
3.5.1.	Các chỉ số đánh giá	42
3.5.2.	Kiểm định thống kê Diebold – Mariano (DM)	43
KẾT LUẬN CHƯƠNG 3.....		46
CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN		47
4.1.	Thống kê mô tả.....	47
4.1.1.	Mô tả dữ liệu	47
4.1.2.	Biểu đồ phân phối giá cổ phiếu.....	51
4.1.3.	Biến động giá cổ phiếu giai đoạn 2020 – 2025.....	53
4.2.	Kết quả dự báo từ mô hình Prophet	55
4.3.	Kết quả dự báo từ mô hình ARIMA.....	58
4.4.	So sánh hiệu quả hai mô hình.....	64
4.4.1.	Kết quả dự báo	64
4.4.2.	Kết quả kiểm định Ljung – Box và Diebold – Mariano	71
4.5.	Thảo luận và liên hệ thực tiễn	73
CHƯƠNG 5. KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ		79
5.1.	Kết luận và đóng góp của nghiên cứu	79
5.2.	Các khuyến nghị	80
5.3.	Hạn chế của nghiên cứu	81
5.4.	Đề xuất hướng nghiên cứu tiếp theo	83
KẾT LUẬN CHƯƠNG 5.....		85
TÀI LIỆU THAM KHẢO		86

PHỤ LỤC.....	91
---------------------	-----------

DANH MỤC CHỮ VIẾT TẮT

Từ viết tắt	Giải nghĩa
ACF	Autocorrelation Function
ADF	Augmented Dickey-Fuller
ARCH	Autoregressive conditional heteroskedasticity
ARIMA	AutoRegressive Integrated Moving Average
CTR	Tổng Công ty Cổ phần Công trình Viettel
DBD	Công ty Cổ phần Dược phẩm Bến Tre
DM	Kiểm định Diebold-Mariano
FiinPro-X	Nền tảng dữ liệu tài chính của Fiin Group
FPT	Tập đoàn FPT
GARCH	Generalized Autoregressive Conditional Heteroskedasticity
GICS	Global Industry Classification Standard
HOSE	Ho Chi Minh Stock Exchange (Sở Giao dịch Chứng khoán TP. HCM)
HVN	Tổng Công ty Hàng không Việt Nam
IQR	Interquartile Range
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
MLE	Maximum Likelihood Estimation
MSN	Công ty Cổ phần Tập đoàn MaSan
MWG	Công ty cổ phần Đầu tư Thế giới Di động
PACF	Partial Autocorrelation Function
PVS	Tổng Công ty cổ phần Dịch vụ Kỹ thuật Dầu khí Việt Nam
REE	Công ty Cổ phần Cơ điện lạnh
RMSE	Root Mean Squared Error
SVR	Support Vector Regression

TZS	Tanzanian Shilling
VAR	Vector Autoregression
VCB	Ngân hàng TMCP Ngoại thương Việt Nam
VIC	Tập đoàn Vingroup - Công ty Cổ phần

DANH MỤC HÌNH

Hình 3.1. Sơ đồ quy trình nghiên cứu	30
Hình 4.1. Biểu đồ phân phối giá cổ phiếu	52
Hình 4.2. Biểu đồ Boxplot phân phối giá cổ phiếu trước, sau khi xử lý ngoại lai	53
Hình 4.3. Biến động giá cổ phiếu giai đoạn 2020 – 2025.....	54
Hình 4.4. Kết quả dự báo của mã cổ phiếu VCB (Fold 4).....	57
Hình 4.5. Kiểm tra tính dừng của mã cổ phiếu HPG (Fold 1).....	59
Hình 4.6. Biểu đồ ACF và PACF của mã cổ phiếu HPG – Fold 1.....	59
Hình 4.7. Kết quả lựa chọn tham số mô hình qua AutoARIMA	60
Hình 4.8. Biểu đồ so sánh RMSE giữa Prophet và ARIMA của các mã cổ phiếu	65
Hình 4.9. Biểu đồ so sánh chỉ số MAE và RMSE giữa Prophet và ARIMA.....	68
Hình 4.10. Biểu đồ so sánh chỉ số MAPE giữa Prophet và ARIMA.....	69
Hình 4.11. Biểu đồ so sánh dự báo Prophet và ARIMA của mã HPG – Fold 1.....	70
Hình 4.12. Kết quả kiểm định Ljung – Box của mã cổ phiếu HPG (Fold 1) và Diebold – Mariano của tất cả mã cổ phiếu	72

DANH MỤC BẢNG

Bảng 2.1. So sánh đặc điểm của hai mô hình.....	16
Bảng 2.2. Tổng hợp các nghiên cứu liên quan	26
Bảng 4.1. Danh sách 11 công ty đại diện các nhóm ngành niêm yết trên HOSE	48
Bảng 4.2. Thống kê mô tả của toàn bộ dữ liệu	49
Bảng 4.3. Thống kê mô tả của các mã cổ phiếu	50
Bảng 4.4. Kết quả các chỉ số đánh giá của mô hình Prophet	56
Bảng 4.5. Bảng tham số ước lượng ARIMA(p,d,q) của các mã cổ phiếu.....	61
Bảng 4.6. Kết quả các chỉ số đánh giá của mô hình ARIMA	63
Bảng 4.7. Kết quả các chỉ số đánh giá của hai mô hình Prophet và ARIMA	66
Bảng 4.8. Tổng hợp kết quả so sánh hiệu quả giữa ARIMA và Prophet	77

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU

1.1. Lý do chọn đề tài

Thị trường chứng khoán không chỉ là nơi huy động và phân bổ vốn hiệu quả mà còn là chỉ số quan trọng phản ánh sức khỏe của nền kinh tế và hiệu quả hoạt động của các doanh nghiệp, đặc biệt tại thị trường Việt Nam. Đây cũng là chỉ số quan trọng đo lường sự phát triển của các doanh nghiệp và có tác động trực tiếp đến các quyết định đầu tư của tổ chức và cá nhân. Việc dự báo chính xác giá cổ phiếu là yếu tố then chốt trong lĩnh vực tài chính, giúp nhà đầu tư nhận diện xu hướng, hạn chế rủi ro và tối ưu hóa quyết định đầu tư. Tuy nhiên, trong bối cảnh thị trường chứng khoán ngày càng chịu ảnh hưởng từ các yếu tố bất định như dịch bệnh, chiến tranh hay biến động kinh tế toàn cầu, các mô hình truyền thống như ARIMA đang gặp phải những khó khăn trong việc phản ánh đúng bản chất của dữ liệu.

Trong lĩnh vực dự báo chuỗi thời gian tài chính, mô hình ARIMA là một trong những công cụ được áp dụng sớm và phổ biến nhờ khả năng mô hình hóa các chuỗi dữ liệu ổn định và tuyến tính (Box & Jenkins, 1976). Tuy nhiên, ARIMA lại gặp khó khăn khi xử lý các yếu tố phi tuyến tính, mùa vụ, hoặc những cú sốc bất thường, là những đặc điểm thường thấy trong thị trường chứng khoán hiện đại (Makridakis và c.s., 2020). Những hạn chế này càng trở nên rõ rệt trong những giai đoạn thị trường có biến động mạnh, khi các yếu tố ngoại lai không thể dự đoán được bằng mô hình tuyến tính truyền thống. Để giải quyết những hạn chế này, mô hình Prophet do Facebook phát triển đã được giới thiệu như một công cụ linh hoạt hơn, có khả năng xử lý mùa vụ, xu hướng và các điểm ngoại lệ một cách rõ ràng và dễ điều chỉnh (Taylor & Letham, 2017). Prophet đang dần được ứng dụng nhiều hơn trong các lĩnh vực thương mại, tài chính, chuỗi cung ứng,... Tuy nhiên, việc sử dụng Prophet trong dự báo giá cổ phiếu tại thị trường chứng khoán Việt Nam vẫn còn khá mới mẻ và chưa được nghiên cứu rộng rãi.

Về mặt lý luận, mô hình ARIMA từ lâu đã là một trong những phương pháp nền tảng trong phân tích chuỗi thời gian và dự báo giá cổ phiếu (Box & Jenkins, 1976; Hyndman & Athanasopoulos, 2018). Tuy nhiên, nhiều nghiên cứu đã chỉ ra

rằng ARIMA gặp phải nhiều hạn chế trong điều kiện thị trường có nhiều biến động bất thường (Makridakis và c.s., 2020). Trong khi đó, Prophet là một mô hình có khả năng tích hợp linh hoạt các yếu tố xu hướng, mùa vụ, và sự kiện bất ngờ, đồng thời dễ tùy biến và thích hợp cho cả người dùng không chuyên về thống kê (Taylor & Letham, 2017). Một số nghiên cứu gần đây đã chứng minh hiệu quả của Prophet trong dự báo giá cổ phiếu tại Trung Quốc (Shen và c.s., 2023). Tuy nhiên, ở thị trường Việt Nam, việc áp dụng Prophet vẫn chưa phổ biến và thiếu các nghiên cứu đánh giá toàn diện. Đến nay, hầu hết các nghiên cứu chỉ tập trung vào mô hình ARIMA hoặc các phương pháp truyền thống khác mà chưa nghiên cứu sâu về Prophet và khả năng ứng dụng của nó trong bối cảnh đặc thù của thị trường Việt Nam.

Vì vậy, nghiên cứu này góp phần lấp đầy khoảng trống tri thức về việc ứng dụng mô hình Prophet trong thị trường Việt Nam, đồng thời cung cấp một cái nhìn đối chiếu với mô hình ARIMA. Thay vì chỉ tập trung vào một mô hình đơn lẻ, việc so sánh hai mô hình này giúp làm rõ ưu nhược điểm của từng phương pháp trong điều kiện thị trường có nhiều biến động, từ đó lựa chọn được mô hình phù hợp hơn cho bối cảnh trong nước.

Việc dự báo chính xác giá cổ phiếu đóng vai trò quan trọng trong việc giúp nhà đầu tư ra quyết định đúng đắn, tối ưu hóa lợi nhuận và giảm thiểu rủi ro. Với sự phát triển nhanh chóng của thị trường chứng khoán Việt Nam và các yếu tố bất định trong bối cảnh quốc tế, việc có một mô hình dự báo linh hoạt và chính xác là rất cấp thiết. Giai đoạn 2020 – 2022 là thời kỳ thị trường chịu ảnh hưởng nặng nề bởi đại dịch COVID-19, trong khi năm 2023 – 2024 tiếp tục biến động do chính sách vĩ mô và xu hướng dòng tiền. Những cú sốc này khiến dữ liệu giá cổ phiếu biến động mạnh, đặt ra yêu cầu cao đối với mô hình dự báo có khả năng xử lý linh hoạt như Prophet. Vì vậy, nhu cầu về một mô hình dự báo phù hợp để bảo vệ lợi ích của nhà đầu tư trong các thời điểm biến động mạnh càng trở nên rõ ràng hơn. Việc nghiên cứu và so sánh hai mô hình Prophet và ARIMA sẽ giúp nhà đầu tư, các tổ chức tài

chính và chuyên gia phân tích dữ liệu lựa chọn công cụ phù hợp để ứng dụng trong thực tiễn (Nguyễn Thị Thúy Hạnh, 2023).

Với sự phát triển mạnh mẽ của công nghệ hiện đại, việc áp dụng các công cụ kỹ thuật trong quá trình thu thập, xử lý và phân tích dữ liệu ngày càng trở nên quan trọng. Việc sử dụng Python trong nghiên cứu này không chỉ nâng cao hiệu quả xử lý mà còn mang đến khả năng mô hình hóa dữ liệu linh hoạt, giúp các nhà đầu tư có được công cụ dự báo đáng tin cậy và tối ưu hơn trong quá trình ra quyết định.

Tóm lại, đề tài không chỉ có giá trị về mặt lý thuyết, đóng góp vào kho tàng tri thức về ứng dụng các mô hình hiện đại trong bối cảnh thị trường Việt Nam, mà còn mang lại lợi ích thực tiễn rõ ràng cho các nhà đầu tư trong việc ra quyết định trong các giai đoạn nhạy cảm của thị trường.

1.2. Mục tiêu nghiên cứu

1.2.1. Mục tiêu tổng quát

Mục tiêu tổng quát của nghiên cứu là phân tích độ chính xác của hai mô hình Prophet và ARIMA trong việc dự báo giá cổ phiếu của các công ty niêm yết trên sàn HOSE. Mục tiêu này nhằm xác định mô hình dự báo phù hợp nhất với đặc điểm biến động giá cổ phiếu trên thị trường chứng khoán Việt Nam, từ đó cung cấp cơ sở tham khảo hữu ích cho nhà đầu tư và tổ chức tài chính.

1.2.2. Mục tiêu cụ thể

- Đánh giá độ chính xác của mô hình Prophet và ARIMA trong việc dự báo giá cổ phiếu của các công ty niêm yết trên HOSE.
- So sánh hiệu quả dự báo của hai mô hình dựa trên các chỉ số như RMSE, MAE, MAPE để xác định mô hình dự báo tốt nhất.
- Đề xuất mô hình phù hợp nhất cho dự báo giá cổ phiếu trong thị trường chứng khoán Việt Nam, đặc biệt khi đối mặt với các biến động mạnh.

1.3. Câu hỏi nghiên cứu

- Mô hình Prophet và ARIMA có độ chính xác như thế nào trong việc dự báo giá cổ phiếu của các công ty niêm yết trên HOSE?
- Mô hình nào cho kết quả dự báo chính xác hơn khi áp dụng vào thị trường chứng khoán Việt Nam, đặc biệt là trong các giai đoạn biến động?
- Mô hình nào là công cụ dự báo giá cổ phiếu phù hợp nhất trong thị trường chứng khoán Việt Nam ở các giai đoạn khác nhau?

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là đánh giá độ chính xác của hai mô hình Prophet và ARIMA trong việc dự báo giá cổ phiếu của các công ty niêm yết trên HOSE.

1.4.2. Phạm vi nghiên cứu

Về *phạm vi không gian*, nghiên cứu bao gồm 11 ngành trên sàn HOSE, được lựa chọn dựa trên tiêu chí đại diện cho mỗi lĩnh vực, ngành nghề trong nền kinh tế. Dựa theo tiêu chí phân ngành GICS (Global Industry Classification Standard), một chuẩn phân ngành quốc tế được phát triển bởi MSCI và S&P Dow Jones Indices, hiện đang được áp dụng rộng rãi tại nhiều thị trường tài chính trên thế giới, bao gồm cả Việt Nam (MSCI & S&P Dow Jones Indices, 2023). GICS giúp phản ánh chính xác sự phân loại ngành nghề trong bối cảnh thị trường tài chính toàn cầu. Nghiên cứu không bao gồm các công ty chưa niêm yết hoặc các sản giao dịch chứng khoán khác ngoài HOSE, nhằm đảm bảo tính đồng nhất trong việc so sánh các mô hình.

Về *phạm vi thời gian*, nghiên cứu sẽ sử dụng dữ liệu trong 5 năm tính từ 01/01/2020 đến 31/03/2025. Đây là giai đoạn có sự biến động mạnh trong thị trường chứng khoán Việt Nam, đặc biệt trong bối cảnh đại dịch Covid-19 và các thay đổi mạnh mẽ từ chính sách kinh tế vĩ mô.

1.5. Phương pháp nghiên cứu

Trong nghiên cứu này, phương pháp định lượng trong phân tích chuỗi thời gian sẽ được sử dụng để đánh giá và so sánh độ chính xác của hai mô hình dự báo Prophet và ARIMA trong việc dự báo giá cổ phiếu của các công ty niêm yết trên sàn HOSE. Mỗi mô hình được huấn luyện và kiểm định trên cùng một tập dữ liệu. Kết quả dự báo được so sánh với giá trị thực tế để tính toán sai số theo các chỉ số đánh giá. Mô hình nào có các chỉ số sai số nhỏ hơn sẽ được đánh giá là có độ chính xác cao hơn trong dự báo. Ngoài ra, kiểm định thống kê sẽ được sử dụng để so sánh sự khác biệt về độ chính xác giữa hai mô hình.

Nguồn dữ liệu là dữ liệu thứ cấp được thu thập từ các nguồn uy tín, chính thống, xác thực như FiinPro-X và CafeF, các nền tảng được sử dụng rộng rãi trong nghiên cứu tài chính tại Việt Nam. Dữ liệu sau đó sẽ được làm sạch và chuẩn hóa để đảm bảo độ chính xác khi đưa vào mô hình, phù hợp với quy trình xử lý dữ liệu trong nghiên cứu chuỗi thời gian được khuyến nghị bởi (Zhang và c.s., 1998).

Quá trình thực nghiệm sẽ sử dụng các chỉ số đánh giá độ chính xác như RMSE, MAE và MAPE, vốn là các thước đo phổ biến được nhiều nghiên cứu như Makridakis và c.s. (2018) sử dụng để đánh giá hiệu quả mô hình dự báo. Các kiểm định thống kê được áp dụng để xác định liệu sự khác biệt giữa hai mô hình có ý nghĩa thống kê hay không.

Cả hai mô hình sẽ được triển khai trên nền tảng Jupyter Notebook, sử dụng ngôn ngữ Python và các thư viện hỗ trợ như statsmodels cho ARIMA và prophet cho Prophet. Việc sử dụng Python được ưa chuộng trong các nghiên cứu tài chính hiện đại nhờ tính linh hoạt, mã nguồn mở và thư viện phong phú (McKinney, 2017). Nghiên cứu đề xuất lựa chọn ngôn ngữ này, không chỉ bởi những thư viện mạnh mẽ như pandas, numpy, và prophet giúp thực hiện phân tích chuỗi thời gian hiệu quả, mà còn vì hỗ trợ xử lý dữ liệu tài chính phức tạp một cách linh hoạt và chính xác.

1.6. Đóng góp của đề tài

Về mặt học thuật, nghiên cứu sẽ đóng góp kiến thức mới trong việc ứng dụng mô hình Prophet vào dự báo giá cổ phiếu tại thị trường chứng khoán Việt Nam, nơi mà mô hình này chưa được nghiên cứu nhiều. Việc so sánh giữa Prophet và ARIMA sẽ giúp làm rõ ưu nhược điểm của từng mô hình trong việc dự báo giá cổ phiếu, qua đó cung cấp cơ sở lý thuyết cho việc ứng dụng các mô hình này trong thị trường chứng khoán.

Về mặt thực tiễn, nghiên cứu góp phần hỗ trợ cho các nhà đầu tư và chuyên gia tài chính một công cụ đánh giá hữu ích để lựa chọn mô hình dự báo phù hợp. Việc dự báo chính xác giá cổ phiếu sẽ giúp nhà đầu tư tối ưu hóa quyết định đầu tư và quản lý rủi ro trong môi trường thị trường đầy biến động. Các mô hình này cũng có thể được ứng dụng để đưa ra chiến lược đầu tư hiệu quả hơn trong các giai đoạn thị trường không ổn định.

Về mặt giải quyết vấn đề thực tiễn, nghiên cứu có thể mang lại một công cụ dự báo giá cổ phiếu hiệu quả. Việc lựa chọn mô hình dự báo chính xác sẽ giúp các nhà đầu tư có thể quyết định đầu tư tốt hơn, giảm thiểu rủi ro và tăng trưởng lợi nhuận. Nghiên cứu cũng sẽ chỉ ra mô hình nào phù hợp nhất đối với mỗi nhà đầu tư trên thị trường chứng khoán Việt Nam.

Nghiên cứu này không chỉ cung cấp cái nhìn sâu sắc về hiệu quả của hai mô hình mà còn giới thiệu việc ứng dụng công nghệ trong phân tích dữ liệu tài chính, đặc biệt là sử dụng Python để triển khai các mô hình chuỗi thời gian và dự báo.

1.7. Kết cấu của nghiên cứu

Bài khóa luận bao gồm 5 chương:

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU

Chương này sẽ giới thiệu tổng quan về đề tài nghiên cứu, bao gồm lý do chọn đề tài, mục tiêu nghiên cứu, câu hỏi nghiên cứu, đối tượng và phạm vi nghiên cứu, phương pháp nghiên cứu và kết cấu khóa luận. Mục đích của chương này là

đưa ra cái nhìn tổng quát về nghiên cứu, từ đó có thể hiểu rõ các vấn đề nghiên cứu sẽ được làm rõ trong các chương tiếp theo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

Chương này sẽ trình bày các lý thuyết cơ bản về mô hình Prophet và ARIMA, đồng thời tổng hợp các nghiên cứu trước đây liên quan đến ứng dụng các mô hình này trong dự báo. Mục đích của chương là làm rõ cơ sở lý thuyết của nghiên cứu và chỉ ra khoảng trống tri thức mà nghiên cứu này sẽ lấp đầy. Bên cạnh đó, sẽ cung cấp các lý thuyết nền và các nghiên cứu tham khảo để hiểu rõ hơn về các mô hình dự báo trong bối cảnh thị trường chứng khoán.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU

Chương này trình bày chi tiết phương pháp nghiên cứu được sử dụng trong khóa luận, bao gồm cách thu thập và xử lý dữ liệu, các chỉ tiêu đánh giá mô hình như RMSE, MAE, MAPE, và phương pháp so sánh hai mô hình Prophet và ARIMA. Mục đích làm rõ phương pháp nghiên cứu, công cụ phân tích dữ liệu được áp dụng và cách thức đánh giá độ chính xác của các mô hình dự báo.

CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

Chương này sẽ trình bày các kết quả thực nghiệm từ việc áp dụng các mô hình Prophet và ARIMA vào dự báo giá cổ phiếu của một số doanh nghiệp trên sàn HOSE. Các kết quả dự báo sẽ được so sánh và phân tích, từ đó đưa ra nhận định về độ chính xác và tính ứng dụng của từng mô hình, và xác định mô hình nào có hiệu quả dự báo tốt nhất.

CHƯƠNG 5. KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ

Chương cuối sẽ tóm tắt các kết quả nghiên cứu, đồng thời đưa ra kết luận chính của khóa luận. Bên cạnh đó, chương này sẽ đưa ra các đóng góp của nghiên cứu đối với lý thuyết và thực tiễn, nêu lên những hạn chế của nghiên cứu và đề xuất hướng nghiên cứu tiếp theo. Các khuyến nghị cho các nhà đầu tư và tổ chức tài

chính sẽ được trình bày nhằm tối ưu hóa việc sử dụng các mô hình dự báo trong thực tiễn.

KẾT LUẬN CHƯƠNG 1

Chương 1 đã tạo nền tảng vững chắc cho nghiên cứu bằng cách trình bày tổng quan về đề tài “ĐÁNH GIÁ ĐỘ CHÍNH XÁC CỦA MÔ HÌNH PROPHET VÀ ARIMA TRONG DỰ BÁO GIÁ CỔ PHIẾU TRÊN SỞ GIAO DỊCH CHỨNG KHOÁN TP. HCM”. Ngoài ra, không chỉ khái quát về các vấn đề nghiên cứu mà còn làm rõ sự quan trọng của việc dự báo giá cổ phiếu trong bối cảnh thị trường chứng khoán Việt Nam đang chịu tác động từ nhiều yếu tố bất định. Và chỉ ra được các câu hỏi mà nghiên cứu sẽ giải quyết. Điều này giúp làm rõ các yếu tố quan trọng trong việc lựa chọn mô hình dự báo phù hợp và sự cần thiết của việc so sánh các mô hình Prophet và ARIMA trong bối cảnh đặc thù của thị trường chứng khoán Việt Nam.

Trong các chương tiếp theo, Chương 2 sẽ tập trung vào việc trình bày cơ sở lý thuyết và tổng quan các nghiên cứu trước đây, giúp làm rõ các mô hình dự báo giá cổ phiếu và các phương pháp liên quan. Chương này sẽ cung cấp nền tảng vững chắc để giải thích lý do tại sao các mô hình Prophet và ARIMA được chọn làm đối tượng nghiên cứu. Đồng thời, chương cũng sẽ chỉ ra khoảng trống trong các nghiên cứu trước đây và làm rõ mục đích của nghiên cứu này trong việc lấp đầy khoảng trống tri thức đó, đặc biệt là trong bối cảnh thị trường chứng khoán Việt Nam. Chương 2 sẽ là bước đi tiếp theo quan trọng trong việc cung cấp các thông tin lý thuyết và thực tiễn để có cái nhìn rõ ràng hơn về ứng dụng của các mô hình dự báo và phương pháp nghiên cứu được áp dụng.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

Chương 2 nhằm xây dựng nền tảng lý luận và thực tiễn cho đề tài thông qua việc trình bày tổng quan thị trường chứng khoán Việt Nam trong giai đoạn 2020 – 2025 và hệ thống hóa các kiến thức liên quan đến mô hình dự báo chuỗi thời gian. Chương này sẽ giới thiệu khái niệm chuỗi thời gian tài chính, cơ sở lý thuyết của hai mô hình Prophet và ARIMA, các chỉ số đánh giá hiệu suất mô hình, đồng thời tổng hợp các nghiên cứu trong và ngoài nước có liên quan. Trên cơ sở đó, chương cũng xác định khoảng trống nghiên cứu hiện hữu, làm cơ sở cho việc lựa chọn hướng tiếp cận và mô hình phù hợp trong các chương tiếp theo.

2.1. Cơ sở lý thuyết về dự báo chuỗi thời gian

2.1.1. Khái niệm về chuỗi thời gian

Chuỗi thời gian là tập hợp các quan sát được ghi nhận theo thứ tự thời gian, thể hiện sự biến đổi của một biến số theo từng khoảng thời gian cụ thể, có thể là ngày, tuần, tháng hoặc năm (Box & Jenkins, 1976). Trong lĩnh vực tài chính, chuỗi thời gian thường biểu diễn sự thay đổi của các đại lượng kinh tế như giá cổ phiếu, chỉ số chứng khoán, lãi suất, tỷ giá ngoại tệ và các chỉ số kinh tế vĩ mô khác.

Việc phân tích và dự báo chuỗi thời gian trong tài chính đóng vai trò quan trọng, giúp các nhà đầu tư, tổ chức tài chính và nhà hoạch định chính sách đưa ra các quyết định hiệu quả dựa trên những dự đoán về xu hướng tương lai của thị trường (Hyndman & Athanasopoulos, 2018).

Chuỗi thời gian trong tài chính mang nhiều đặc điểm phức tạp do chịu ảnh hưởng của các yếu tố như biến động kinh tế, chính trị, tâm lý nhà đầu tư, các sự kiện toàn cầu và các cú sốc thị trường đột ngột. Những đặc điểm này bao gồm xu hướng dài hạn, tính chu kỳ hoặc mùa vụ và biến động ngẫu nhiên (Tsay, 2010). Hiểu và nhận diện rõ ràng các thành phần này là điều kiện tiên quyết để lựa chọn các mô hình dự báo phù hợp, qua đó nâng cao độ chính xác của dự báo.

Một khía cạnh quan trọng trong phân tích chuỗi thời gian là tính dừng của chuỗi, tức là sự ổn định về mặt thống kê như trung bình, phương sai và hiệp phương

sai không đổi theo thời gian. Nhiều mô hình dự báo truyền thống, trong đó có ARIMA, yêu cầu chuỗi dữ liệu phải dừng hoặc được biến đổi thành dừng thông qua các kỹ thuật như lấy sai phân (Hyndman & Athanasopoulos, 2018). Chuỗi thời gian không dừng thường chứa xu hướng hoặc biến động dài hạn, cần được xử lý kỹ lưỡng nhằm tránh sai số trong dự báo.

Chuỗi thời gian tài chính cũng nổi bật với tính không chắc chắn cao và biến động liên tục, điều này làm cho việc dự báo trở nên khó khăn và đòi hỏi các mô hình dự báo phải có khả năng thích ứng linh hoạt với các biến động và sự kiện bất ngờ (Zivot & Wang, 2006). Ngoài ra, chuỗi thời gian trong tài chính thường có tính tự tương quan, tức là giá trị tại thời điểm hiện tại chịu ảnh hưởng từ các giá trị quá khứ (Tsay, 2010). Việc nhận diện và khai thác tính chất này là rất quan trọng trong việc xây dựng mô hình dự báo chính xác.

Các mô hình dự báo chuỗi thời gian hiện đại như Prophet và ARIMA được áp dụng rộng rãi trong việc xử lý linh hoạt các đặc điểm phức tạp của dữ liệu tài chính, giúp các nhà đầu tư và tổ chức tài chính đưa ra các quyết định chính xác và kịp thời trong bối cảnh thị trường biến động mạnh mẽ.

2.1.2. Khái niệm về dự báo chuỗi thời gian

Dự báo chuỗi thời gian là quá trình sử dụng các dữ liệu lịch sử được ghi nhận theo trình tự thời gian để ước lượng các giá trị tương lai của một biến số. Khác với các phương pháp phân tích thống kê truyền thống vốn giả định các quan sát độc lập, dự báo chuỗi thời gian tận dụng mối quan hệ phụ thuộc giữa các điểm dữ liệu theo thời gian tại các thời điểm khác nhau để phát hiện quy luật và đưa ra dự báo chính xác hơn cho tương lai (Hyndman & Athanasopoulos, 2018).

Dữ liệu chuỗi thời gian nói chung có thể được phân tích thành bốn thành phần cơ bản:

- **Xu hướng dài hạn (trend)**

Thể hiện qua chiều hướng tăng hoặc giảm trong một giai đoạn dài. Ví dụ về lãi suất có thể giảm dần trong chu kỳ nói lỏng tiền tệ.

- **Tính mùa vụ (seasonality)**

Là các mô hình lặp lại có chu kỳ ngắn hạn như theo tháng, quý hoặc năm. Ví dụ về chỉ tiêu tăng mạnh vào dịp cuối năm hay ngày lễ tết.

- **Chu kỳ kinh tế (cycle)**

Phản ánh các biến động dài hạn có liên quan đến trạng thái vĩ mô nhưng không đều đặn như mùa vụ, thường gắn với giai đoạn kinh tế.

- **Yếu tố ngẫu nhiên (noise)**

Là các dao động bất thường, ngẫu nhiên không theo quy luật, chẳng hạn như ảnh hưởng bất ngờ từ một sự kiện chính trị đến tỷ giá hoặc giá cổ phiếu, khó có thể dự đoán được.

Trong thực tiễn, dự báo chuỗi thời gian đóng vai trò then chốt trong nhiều lĩnh vực, đặc biệt là trong tài chính và ngân hàng, là nơi các quyết định đầu tư, lập kế hoạch ngân sách hoặc quản trị rủi ro phụ thuộc mạnh mẽ vào khả năng dự đoán chính xác các biến động theo thời gian. Một số ví dụ điển hình bao gồm: dự báo tỷ giá hối đoái để xây dựng chiến lược phòng ngừa rủi ro cho các giao dịch quốc tế, ước lượng nhu cầu rút tiền mặt tại ATM theo ngày nhằm tối ưu hóa vận hành dòng tiền, dự báo doanh thu phí dịch vụ định kỳ để phục vụ lập kế hoạch tài chính...

Việc lựa chọn mô hình dự báo phụ thuộc vào đặc điểm cấu trúc của chuỗi và mục tiêu phân tích. Các mô hình thống kê truyền thống như ARIMA thường phát huy hiệu quả khi chuỗi có tính dừng và mối quan hệ tuyến tính ổn định. Trong khi đó, các mô hình hiện đại như Prophet được thiết kế với mục tiêu xử lý linh hoạt các chuỗi dữ liệu có tính không dừng, chứa mùa vụ không cố định hoặc chịu ảnh hưởng bởi các sự kiện bất thường (Taylor & Letham, 2017). Chẳng hạn, nếu cần dự báo lãi suất cho vay trung bình hàng tháng, dưới dạng một chuỗi có xu hướng tuyến tính và ít yếu tố đột biến thì mô hình ARIMA có thể là lựa chọn phù hợp. Ngược lại, với chuỗi có yếu tố mùa vụ rõ rệt như doanh thu phí giao dịch tăng mạnh vào dịp Tết, mô hình Prophet sẽ mang lại độ chính xác cao hơn do khả năng phát hiện các thay đổi xu hướng (changepoints) và mô hình hóa linh hoạt các thành phần thời gian.

Tóm lại, dự báo chuỗi thời gian không chỉ là một kỹ thuật phân tích số liệu lịch sử, mà còn là một công cụ chiến lược giúp các tổ chức tài chính ra quyết định hiệu quả hơn trong môi trường nhiều biến động như hiện nay. Việc hiểu rõ cấu trúc chuỗi, lựa chọn mô hình phù hợp và đánh giá hiệu suất dự báo là các yếu tố nền tảng giúp đảm bảo chất lượng và độ tin cậy của kết quả đầu ra (Hyndman & Athanopoulos, 2018; Makridakis và c.s., 2020).

2.2. Khái niệm và đặc điểm của hai mô hình

2.2.1. Mô hình Prophet

Mô hình Prophet do Taylor & Letham (2017) của Facebook phát triển, nhằm khắc phục những hạn chế của các mô hình dự báo truyền thống, vốn gặp khó khăn khi xử lý chuỗi thời gian có xu hướng phi tuyến, yếu tố mùa vụ phức tạp hoặc các điểm dị thường do sự kiện kinh tế, xã hội gây ra. Mô hình cho phép tự động phát hiện xu hướng, chu kỳ và điểm dị biệt, đồng thời hỗ trợ can thiệp chủ động của người dùng như thêm sự kiện đặc biệt hoặc điều chỉnh xu hướng.

Prophet xây dựng dự báo dựa trên tổng hợp các thành phần chính, có phương trình tổng quát như sau:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

Trong đó:

- $y(t)$: giá trị quan sát (giá cổ phiếu) tại thời điểm t
- t : thời gian (ngày giao dịch)
- $g(t)$: xu hướng dài hạn tại thời điểm t
- $s(t)$: thành phần mùa vụ tại thời điểm t
- $h(t)$: các sự kiện bất thường tại thời điểm t
- ϵ_t : nhiễu trắng tại thời điểm t (sai số ngẫu nhiên)

Thành phần xu hướng $g(t)$ phản ánh biến động dài hạn của giá cổ phiếu theo thời gian và có thể được mô hình hóa dưới dạng tuyến tính hoặc phi tuyến tùy thuộc vào đặc điểm dữ liệu. Trong bối cảnh nghiên cứu này, $g(t)$ cho thấy xu hướng tăng hoặc giảm bền vững của giá cổ phiếu do tác động của các yếu tố như tăng trưởng

kinh tế, kết quả kinh doanh hoặc những thay đổi trong môi trường kinh doanh. Tiếp theo, thành phần mùa vụ $s(t)$ mô tả các biến động mang tính chu kỳ lặp lại theo tuần, tháng hoặc năm. Prophet sử dụng chuỗi Fourier để mô hình hóa yếu tố này, cho phép nhận diện các dạng mùa vụ phức tạp, đối với giá cổ phiếu, $s(t)$ có thể phản ánh các biến động do mùa mua sắm, dịp lễ tết hoặc thời điểm công bố báo cáo tài chính. Thành phần sự kiện bất thường $h(t)$ ghi nhận tác động của những sự kiện đặc biệt không lặp lại theo chu kỳ, chẳng hạn như công bố thông tin đột xuất, điều chỉnh chính sách, biến động giá hàng hóa quốc tế hoặc khủng hoảng kinh tế, việc bổ sung các mốc sự kiện này vào mô hình giúp nâng cao độ chính xác dự báo. Cuối cùng, thành phần nhiễu đại diện cho các biến động ngẫu nhiên không thể giải thích bằng các thành phần trên, thường xuất phát từ thông tin bất ngờ, tâm lý nhà đầu tư hoặc các hoạt động giao dịch bất thường trên thị trường.

Ưu điểm của Prophet là khả năng phát hiện tự động điểm thay đổi xu hướng mà không cần phải xác định thủ công. Ngoài ra, Prophet xử lý tốt dữ liệu không đều, dữ liệu thiếu, hoặc biến động mạnh, là những đặc điểm rất phổ biến trong dữ liệu giá cổ phiếu (Taylor & Letham, 2017). Giao diện thân thiện với người dùng, khả năng trực quan hóa dự báo và không yêu cầu chuỗi phải đạt tính dừng là những lý do Prophet ngày càng được ứng dụng rộng rãi trong lĩnh vực tài chính, bán lẻ hay vận hành. Một số thách thức khi áp dụng Prophet bao gồm việc lựa chọn tham số phù hợp cho chuỗi thời gian có đặc điểm phức tạp, và việc cần dữ liệu lịch sử đủ dài để mô hình học tốt các mẫu xu hướng và mùa vụ. Để khắc phục, nhà nghiên cứu cần sử dụng quy trình chọn tham số tự động hoặc bán tự động kết hợp kiểm định chéo (cross-validation) (Taylor & Letham, 2017). Đồng thời, việc tích hợp biến phụ trợ đúng cách và làm sạch dữ liệu trước khi huấn luyện cũng rất quan trọng để tránh overfitting hoặc dự báo sai lệch.

Tại Việt Nam, Prophet đã được ứng dụng trong các nghiên cứu dự báo giá cổ phiếu với kết quả tích cực, đặc biệt trong các giai đoạn có biến động lớn như các sự kiện về kinh tế, chính trị đặc biệt. Mô hình này giúp các nhà đầu tư có cái nhìn rõ ràng hơn về xu hướng thị trường và hỗ trợ đưa ra quyết định kịp thời trong bối cảnh

thị trường chứng khoán không ổn định. Prophet có thể kết hợp với các kỹ thuật học máy khác như mạng nơ – ron hoặc phương pháp ensemble để nâng cao độ chính xác dự báo trong môi trường dữ liệu lớn và phức tạp (Huang, 2022). Ngoài ra, việc tùy chỉnh hàm xu hướng và thêm biến số ngoài như dữ liệu kinh tế vĩ mô hoặc các chỉ số sentiment trên mạng xã hội giúp mô hình linh hoạt hơn trong dự báo giá tài sản tài chính (Lukauskas và c.s., 2022).

2.2.2. Mô hình ARIMA

Mô hình ARIMA là một mô hình cổ điển được phát triển bởi Box & Jenkins (1976), là một trong những phương pháp phổ biến và cơ bản nhất trong phân tích và dự báo chuỗi thời gian, có khả năng dự báo các chuỗi có tính tuyến tính sau khi đã được xử lý để đạt trạng thái dừng. Mô hình này kết hợp ba thành phần chính: tự hồi quy (AR), sai phân tích phân (I), và trung bình trượt (MA), và được ký hiệu là ARIMA(p, d, q), trong đó:

- p : bậc của phần tự hồi quy
- d : số lần sai phân để làm chuỗi dừng
- q : bậc của phần trung bình trượt

Phương trình tổng quát của mô hình ARIMA có dạng:

$$Y'_t = c + \phi_1 Y'_{t-1} + \phi_2 Y'_{t-2} + \dots + \phi_p Y'_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q}$$

Trong đó:

- t : thời gian (ngày giao dịch)
- Y'_t : sai phân của chuỗi Y_t (sai phân đến d lần) tại thời điểm t
- c : hằng số
- ϕ_i (với $i = 1, 2, \dots, p$): các hệ số tự hồi quy (AR)

ARIMA đặc biệt hiệu quả trong các trường hợp chuỗi thời gian ổn định, có cấu trúc tuyến tính rõ ràng và không có yếu tố mùa vụ phức tạp. Mô hình có nền tảng lý thuyết vững chắc, dễ kiểm định chất lượng dự báo thông qua các chỉ số như AIC, BIC, RMSE và kiểm định Ljung–Box (Hyndman & Athanasopoulos, 2018).

Tuy nhiên, mô hình này gặp hạn chế trong việc xử lý chuỗi phi tuyến, dữ liệu có mùa vụ mạnh hoặc các cú sốc đột ngột, vốn thường xuất hiện trong dữ liệu giá cổ phiếu (Makridakis và c.s., 2020). Hơn nữa, ARIMA đòi hỏi dữ liệu phải dừng, nên xử lý chuỗi không dừng đúng cách là thách thức lớn và sự sai lệch trong việc lựa chọn tham số p , d , q có thể làm giảm hiệu quả dự báo. Để giải quyết các vấn đề đó, cần phân tích kỹ các biểu đồ ACF và PACF, sử dụng các tiêu chí thông tin như AIC, BIC để chọn tham số tối ưu (Hyndman & Athanasopoulos, 2018). Ngoài ra, khi đối mặt với chuỗi có mùa vụ phức tạp, ARIMA cần mở rộng thành SARIMA hoặc kết hợp với các mô hình mùa vụ khác để cải thiện.

Tại Việt Nam, ARIMA đã được sử dụng để dự báo các chỉ số kinh tế như CPI, lạm phát, lãi suất và giá cổ phiếu trong các giai đoạn thị trường ổn định (Nguyễn Thị Thanh Huyền & Nguyễn Tuấn Sơn, 2022). Tuy nhiên, trong bối cảnh thị trường ngày càng biến động và khó kiểm soát do yếu tố chính trị, kinh tế và tâm lý nhà đầu tư, các mô hình linh hoạt như Prophet thường cho kết quả tốt hơn trong ứng dụng thực tiễn. Ngoài ra, ARIMA có thể được kết hợp với các kỹ thuật như GARCH để dự báo cả giá và độ biến động trong tài chính, giúp mô hình phù hợp với dữ liệu có tính biến động cao (Bollerslev, 1986). Các mô hình hybrid kết hợp ARIMA với mạng nơ-ron nhân tạo (ANN) hoặc phương pháp học sâu đang được nghiên cứu để khai thác ưu điểm của cả hai phương pháp, nâng cao độ chính xác trong các chuỗi phi tuyến và biến động bất thường (Zhang và c.s., 1998).

Bảng 2.1. So sánh đặc điểm của hai mô hình

Tiêu chí	Prophet	ARIMA
Ưu điểm	- Xử lý tốt chuỗi phi tuyến, có mùa vụ hoặc dị thường - Tự động phát hiện điểm thay đổi xu hướng - Hoạt động tốt với dữ liệu thiếu, không đều - Không yêu cầu chuỗi phải dừng - Giao diện thân thiện, dễ sử dụng	- Hiệu quả với chuỗi tuyến tính và ổn định - Cơ sở lý thuyết vững chắc, dễ kiểm định mô hình - Cho phép đánh giá bằng AIC, BIC, Ljung-Box - Dự báo chính xác trong điều kiện dữ liệu ổn định
Nhược điểm	- Hiệu quả giảm nếu dữ liệu quá	- Yêu cầu dữ liệu phải dừng

	nhiều hoặc ngắn hạn - Cần điều chỉnh tham số với chuỗi phức tạp - Dễ bị overfit nếu không làm sạch dữ liệu	- Khó xử lý chuỗi phi tuyến hoặc có mùa vụ phức tạp - Nhạy cảm với lựa chọn p , d , q - Ít linh hoạt với dữ liệu có sự kiện bất thường
Khả năng mở rộng/kết hợp	- Dễ kết hợp với dữ liệu vĩ mô, sentiment, mạng xã hội - Có thể kết hợp với học sâu, ensemble để nâng cao độ chính xác	- Có thể mở rộng thành SARIMA cho dữ liệu có mùa vụ - Dễ tích hợp với GARCH, ANN hoặc hybrid models để dự báo biến động
Ứng dụng thực tế tại Việt Nam	- Hiệu quả trong giai đoạn thị trường biến động mạnh - Được tìm hiểu và áp dụng trong các nghiên cứu tài chính gần đây	- Ứng dụng nhiều trong giai đoạn thị trường ổn định - Phù hợp với các chuỗi kinh tế vĩ mô có cấu trúc rõ ràng

Nguồn: Tác giả tự tổng hợp

ARIMA và Prophet là hai phương pháp dự báo chuỗi thời gian với triết lý xây dựng mô hình khác nhau. ARIMA đại diện cho hướng tiếp cận thống kê truyền thống, yêu cầu chuỗi dữ liệu phải đạt tính dừng và phù hợp với các mối quan hệ tuyến tính. Trong khi đó, Prophet được phát triển theo hướng linh hoạt, xử lý tốt các xu hướng phi tuyến, mùa vụ và các sự kiện bất thường mà không cần nhiều bước tiền xử lý. Prophet thân thiện hơn với người dùng và dễ triển khai thực tế, đặc biệt khi dữ liệu bị thiếu hoặc có nhiều biến động. Tuy nhiên, ARIMA lại cung cấp sự kiểm soát sâu và chính xác hơn trong điều kiện dữ liệu ổn định, không quá nhiễu. Việc lựa chọn mô hình tùy thuộc vào đặc điểm chuỗi thời gian cụ thể và mục tiêu dự báo.

2.3. Các chỉ số đánh giá hiệu suất mô hình

Đánh giá hiệu suất của các mô hình dự báo chuỗi thời gian là một bước không thể thiếu nhằm xác định mức độ chính xác và tin cậy của mô hình trong việc dự báo các giá trị tương lai. Đặc biệt trong lĩnh vực tài chính, việc dự báo chính xác giá cổ phiếu hoặc các chỉ số thị trường có ý nghĩa thiết thực trong việc hỗ trợ nhà đầu tư ra quyết định đúng đắn và giảm thiểu rủi ro. Có nhiều chỉ số đánh giá hiệu

suất mô hình, trong đó phổ biến và được sử dụng rộng rãi là RMSE, MAE, và MAPE. Mỗi chỉ số có vai trò và ưu nhược điểm riêng, việc sử dụng phối hợp các chỉ số này giúp đánh giá toàn diện hơn. Theo Hyndman & Athanasopoulos (2018), việc sử dụng các chỉ số đánh giá là yếu tố cốt lõi giúp lựa chọn mô hình phù hợp và nâng cao hiệu quả dự báo trong thực tiễn.

2.3.1. Chỉ số RMSE

Chỉ số RMSE, viết tắt từ Root Mean Squared Error, hay còn gọi là căn của sai số bình phương trung bình, là một trong những thước đo phổ biến và hiệu quả nhất để đánh giá độ chính xác của các mô hình dự báo chuỗi thời gian. RMSE đo lường mức độ sai lệch trung bình giữa giá trị thực tế và giá trị dự báo bằng cách lấy bình phương các sai số từng điểm, sau đó tính trung bình và cuối cùng là lấy căn bậc hai của giá trị đó.

Công thức tính RMSE được biểu diễn như sau:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Trong đó:

- n : số lượng điểm dữ liệu (số quan sát)
- y_i : giá trị thực tế tại điểm i
- $\hat{y}_i$: giá trị dự báo tại điểm i (giá trị được mô hình dự báo tại điểm i)

Đặc biệt, (Chai & Draxler, 2014) nhấn mạnh rằng RMSE đặc biệt hữu ích trong các trường hợp cần chú ý đến các sai số lớn do tính chất bình phương của nó. Điều này giúp chỉ số RMSE trở thành công cụ cảnh báo hiệu quả khi mô hình có những điểm dự báo sai lệch đáng kể, từ đó giúp nhà nghiên cứu nhận biết được tính ổn định và độ tin cậy của mô hình dự báo. Chính vì vậy, RMSE rất được ưa chuộng trong các lĩnh vực tài chính và kinh tế, nơi mà những sai số lớn có thể gây ra tổn thất tài chính nghiêm trọng hoặc ảnh hưởng tiêu cực đến các quyết định đầu tư.

Tuy nhiên, RMSE cũng có một số hạn chế nhất định. Do nhạy cảm với các điểm ngoại lai (outliers) và dữ liệu nhiễu, chỉ số này có thể làm cho kết quả đánh

giá mô hình trở nên không chính xác nếu dữ liệu chưa được xử lý kỹ lưỡng. Thêm vào đó, RMSE giữ nguyên đơn vị đo của biến dự báo, điều này có thể gây khó khăn trong việc so sánh hiệu quả mô hình trên các bộ dữ liệu hoặc các mô hình khác nhau có phạm vi giá trị khác biệt. Trên thực tế, RMSE được ứng dụng rộng rãi trong nhiều nghiên cứu dự báo tài chính, chẳng hạn như dự báo giá cổ phiếu, tỷ giá ngoại tệ hay các chỉ số kinh tế quan trọng, với mục đích đánh giá sự chính xác và ổn định của các mô hình dự báo như Prophet và ARIMA (Hyndman & Athanasopoulos, 2018).

2.3.2. Chỉ số MAE

Tiếp theo là chỉ số MAE, viết tắt từ Mean Absolute Error, hay còn gọi là sai số tuyệt đối trung bình, là một chỉ số đánh giá phổ biến khác dùng để đo lường mức độ sai lệch trung bình giữa các giá trị dự báo và giá trị thực tế. Khác với RMSE, MAE tính toán dựa trên giá trị tuyệt đối của các sai số, giúp tránh việc phóng đại các sai số lớn thông qua bình phương. Theo Willmott & Matsuura (2005a), MAE có xu hướng ổn định hơn và phản ánh rõ ràng sai số trung bình, đặc biệt trong bối cảnh dữ liệu có nhiều nhiễu.

Công thức tính MAE được biểu diễn như sau:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Trong đó:

- n : số lượng điểm dữ liệu (số quan sát)
- y_i : giá trị thực tế tại điểm i
- $\hat{y}_i$: giá trị dự báo tại điểm i
- $|y_i - \hat{y}_i|$: sai số tuyệt đối tại điểm i

MAE cung cấp một cái nhìn trực quan về mức sai số trung bình mà mô hình dự báo gây ra, không phân biệt sai lệch theo hướng dự báo cao hay thấp hơn thực tế. Chỉ số này được đánh giá cao vì tính ổn định và khả năng phản ánh sai số tổng quát, đặc biệt ít bị ảnh hưởng bởi các điểm ngoại lai so với RMSE. Điều này giúp MAE

trở thành một công cụ hữu ích khi nhà nghiên cứu muốn có cái nhìn tổng thể về độ chính xác của mô hình mà không bị chi phối bởi những sai số bất thường.

Tuy nhiên, MAE cũng có nhược điểm khi không thể phân biệt mức độ nghiêm trọng của các sai số lớn, vì mỗi sai số đều được tính trọng số bằng nhau. Do đó, MAE thường được sử dụng kết hợp với RMSE để đánh giá toàn diện hơn về hiệu suất dự báo. Trong các nghiên cứu tài chính và kinh tế, MAE được sử dụng phổ biến như một chỉ số tiêu chuẩn để đánh giá sai số trung bình, đặc biệt khi dữ liệu có xu hướng biến động không quá mạnh hoặc không chứa nhiều ngoại lệ (Makridakis và c.s., 2020).

2.3.3. Chỉ số MAPE

Cuối cùng, chỉ số MAPE viết tắt từ Mean Absolute Percentage Error hay còn gọi là sai số phần trăm tuyệt đối trung bình, là một thước đo quan trọng dùng để đánh giá độ chính xác của dự báo dưới dạng tỷ lệ phần trăm so với giá trị thực tế. Với khả năng biểu diễn sai số dự báo một cách trực quan và dễ hiểu, MAPE giúp nhanh chóng nhận biết mức độ chính xác của mô hình và thuận tiện trong việc so sánh hiệu quả dự báo giữa các bộ dữ liệu hoặc các mô hình khác nhau. De Myttenaere và c.s. (2016) cho rằng mặc dù MAPE dễ hiểu nhưng có thể gây hiểu nhầm trong các trường hợp giá trị thực gần 0, do đó cần sử dụng kết hợp với các chỉ số khác.

Công thức tính MAPE được biểu diễn như sau:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Trong đó:

- n : số lượng điểm dữ liệu (số quan sát)
- y_i : giá trị thực tế tại điểm i
- $\hat{y}_i$: giá trị dự báo tại điểm i
- $\left| \frac{y_i - \hat{y}_i}{y_i} \right|$: phần trăm sai số tuyệt đối tại mỗi điểm

MAPE biểu thị sai số trung bình tính theo phần trăm, giúp người đọc dễ dàng hiểu và so sánh mức độ sai lệch dự báo trong bối cảnh thực tế. Do đó, MAPE thường được sử dụng trong các báo cáo tài chính, nghiên cứu kinh tế và các lĩnh vực liên quan. Tuy nhiên, một hạn chế đáng lưu ý là MAPE không ổn định khi giá trị thực tế gần bằng 0 hoặc bằng 0, dẫn đến sai số phần trăm rất lớn hoặc không xác định, làm ảnh hưởng đến tính chính xác và độ tin cậy của chỉ số, dẫn đến phản ánh không đúng thực tế. Do tính nhạy cảm này, Hyndman & Athanasopoulos (2018) nghị nên kết hợp MAPE với các chỉ số khác như RMSE và MAE để có đánh giá toàn diện và đáng tin cậy hơn. MAPE cũng giúp nhà đầu tư và các chuyên gia phân tích đánh giá rủi ro tương đối của các mô hình dự báo, từ đó lựa chọn phương pháp phù hợp để áp dụng trong quản lý tài sản và ra quyết định đầu tư.

Đối với nghiên cứu này, hai mô hình Prophet và ARIMA sẽ được đánh giá đồng thời theo ba tiêu chí trên để đảm bảo cho kết quả tốt và khách quan. Các cuộc thi dự báo như M4 cũng sử dụng đồng thời nhiều chỉ số như RMSE, MAE và MAPE để đảm bảo đánh giá khách quan và toàn diện (Makridakis và c.s., 2020). Mỗi chỉ số sẽ làm nổi bật một khía cạnh khác nhau về sai số dự báo, từ đó cho phép rút ra kết luận chính xác về mô hình nào là phù hợp hơn với dữ liệu thực tế của thị trường chứng khoán Việt Nam. Việc kết hợp các chỉ số này không chỉ đảm bảo tính toàn diện mà còn giúp giảm thiểu rủi ro đánh giá sai lệch do đặc điểm riêng của từng chỉ số.

2.4. Tổng quan các nghiên cứu trước

2.4.1 Nghiên cứu ngoài nước

Trên thế giới, việc ứng dụng các mô hình dự báo chuỗi thời gian trong dự đoán giá cổ phiếu đã thu hút sự quan tâm sâu rộng từ giới học thuật và chuyên gia tài chính. Trong đó, mô hình ARIMA, do Box & Jenkins (1976) phát triển, là một trong những phương pháp truyền thống và phổ biến nhất. ARIMA dựa trên các giả định về tính tuyến tính và tính dừng của chuỗi dữ liệu sau khi đã qua xử lý sai phân. Mô hình này phân tích và dự báo giá cổ phiếu dựa trên các giá trị quá khứ, đem lại

hiệu quả tốt khi dữ liệu ổn định. Tuy nhiên, hạn chế lớn của ARIMA là khả năng xử lý kém với các chuỗi dữ liệu có biến động bất thường hoặc bị ảnh hưởng bởi các yếu tố ngoại sinh. Điều này trở nên rõ nét hơn trong bối cảnh thị trường tài chính hiện đại, nơi các biến động thường không tuân theo các quy luật tuyến tính truyền thống, dẫn đến dự báo thiếu chính xác nếu chỉ dựa vào ARIMA (Box & Jenkins, 1976). Để khắc phục những điểm hạn chế này, các mô hình dự báo chuỗi thời gian với cấu trúc linh hoạt hơn đã được phát triển, trong đó nổi bật là mô hình Prophet do Taylor & Letham (2017) giới thiệu. Prophet được thiết kế đặc biệt nhằm xử lý các chuỗi dữ liệu có tính phi tuyến, có yếu tố mùa vụ và chứa các điểm dị biệt (outliers), đồng thời cho phép cập nhật mô hình một cách linh hoạt khi có dữ liệu mới. Mô hình này thể hiện sự phù hợp cao với dữ liệu tài chính biến động phức tạp, thiếu ổn định và mang tính mùa vụ rõ rệt, là những đặc điểm điển hình trong chuỗi giá cổ phiếu thực tế (Taylor & Letham, 2017).

Nhiều nghiên cứu quốc tế đã ghi nhận hiệu quả và tiềm năng ứng dụng của Prophet trong lĩnh vực tài chính. Garlapati và c.s. (2021) áp dụng Prophet để dự báo giá cổ phiếu trên thị trường Ấn Độ, một thị trường mới nổi có đặc điểm dữ liệu và biến động tương đồng với Việt Nam. Nghiên cứu này được thực hiện trên các chuỗi dữ liệu có nhiễu cao, kết hợp các yếu tố xu hướng dài hạn và mùa vụ ngắn hạn, cho thấy Prophet duy trì được sự ổn định và độ chính xác cao ngay cả trong những giai đoạn thị trường chịu ảnh hưởng mạnh bởi các yếu tố kinh tế vĩ mô (Garlapati và c.s., 2021).

Tương tự, Angelo và c.s. (2023) tiến hành nghiên cứu ứng dụng Prophet để dự báo chỉ số giá cổ phiếu tại một số quốc gia châu Âu. Họ nhấn mạnh rằng Prophet có khả năng phát hiện và xử lý hiệu quả các điểm dị biệt, là yếu tố quan trọng khi làm việc với dữ liệu tài chính thực tế. Khả năng điều chỉnh mô hình liên tục theo dữ liệu mới giúp Prophet thích nghi với sự biến động không ngừng của thị trường, gia tăng giá trị sử dụng trong bối cảnh tài chính hiện đại thay đổi nhanh chóng và chịu nhiều tác động từ các yếu tố ngoại lai (Angelo và c.s., 2023).

Ngoài ra, Adebisi và c.s. (2014) đã tiến hành nghiên cứu so sánh ARIMA với các mô hình dự báo hiện đại, trong đó có Prophet, trên thị trường chứng khoán Mỹ. Kết quả nghiên cứu chỉ ra rằng ARIMA đạt hiệu quả tốt khi dữ liệu có tính ổn định cao, nhưng giảm hiệu quả đáng kể với các chuỗi dữ liệu phi tuyến hoặc có biến động bất thường. Trong khi đó, Prophet thể hiện ưu thế vượt trội nhờ cấu trúc linh hoạt và khả năng mô hình hóa xu hướng phi tuyến. Nhóm nghiên cứu này cũng nhấn mạnh rằng việc lựa chọn mô hình dự báo nên dựa trên đặc điểm cụ thể của dữ liệu thay vì áp dụng một phương pháp cố định (Adebisi và c.s., 2014).

Dù vậy, một hạn chế chung của các nghiên cứu quốc tế này là phần lớn được thực hiện tại các thị trường phát triển với dữ liệu minh bạch, ổn định và hệ thống tài chính phát triển cao. Những điều kiện này ít phản ánh đúng tính chất của các thị trường mới nổi như Việt Nam, nơi dữ liệu tài chính còn có nhiều biến động bất định, chịu tác động mạnh từ các yếu tố kinh tế, chính trị và xã hội trong nước và quốc tế. Hơn nữa, phần lớn các nghiên cứu vẫn tập trung vào việc đánh giá từng mô hình riêng lẻ mà thiếu sự so sánh toàn diện và đồng thời về hiệu quả giữa các mô hình trong cùng điều kiện thị trường biến động cao. Ngoài ra, đa số các nghiên cứu chưa thực sự khai thác sâu về mặt dữ liệu đầu vào, chưa tích hợp đầy đủ các biến vĩ mô, các yếu tố ngoại sinh và thiếu sự đồng bộ trong các chỉ số đánh giá hiệu suất mô hình. Điều này tạo nên khoảng trống quan trọng, khiến các kết quả nghiên cứu chưa hoàn toàn phản ánh chính xác và đầy đủ bức tranh thực tế về khả năng ứng dụng của các mô hình dự báo chuỗi thời gian tài chính trong bối cảnh thị trường đầy biến động.

Chính vì vậy, nghiên cứu này đặt mục tiêu lấp đầy khoảng trống tri thức nói trên bằng việc so sánh hiệu quả của hai mô hình Prophet và ARIMA trên dữ liệu giá cổ phiếu thực tế của thị trường Việt Nam giai đoạn 2020 – 2025, áp dụng các phương pháp xử lý dữ liệu tiên tiến và đánh giá mô hình nhằm cung cấp cái nhìn khách quan và thực tiễn nhất. Qua đó, đề tài hướng tới góp phần làm sâu sắc thêm hiểu biết về dự báo chuỗi thời gian tài chính tại thị trường mới nổi có nhiều bất định

như Việt Nam, đồng thời tránh trùng lặp với các nghiên cứu đã có và mở rộng phạm vi ứng dụng của các mô hình hiện đại.

2.4.2 Nghiên cứu trong nước

Tại Việt Nam, mô hình ARIMA đã được sử dụng khá phổ biến trong các nghiên cứu về dự báo tài chính, đặc biệt là với chỉ số thị trường. Nguyễn Hồ Diệu Uyên & Nguyễn Thị Thanh Huyền (2014) đã ứng dụng mô hình ARIMA để dự báo chỉ số VN-Index, với dữ liệu chuỗi thời gian trong giai đoạn thị trường có nhiều biến động. Kết quả nghiên cứu cho thấy mô hình ARIMA có thể đưa ra những dự báo tương đối chính xác trong ngắn hạn, đồng thời khẳng định được vai trò của các yếu tố kỹ thuật trong việc xây dựng mô hình dự báo. Tuy nhiên, nhóm tác giả cũng chỉ ra rằng độ chính xác của mô hình sẽ giảm khi áp dụng trong điều kiện thị trường có nhiều cú sốc, đặc biệt là với dữ liệu tài chính ở các nước đang phát triển như Việt Nam – vốn còn thiếu sự ổn định và dễ bị tác động bởi yếu tố tâm lý đám đông.

Tương tự, nghiên cứu của Giang Ngọc Hà Linh và c.s. (2024) đã triển khai mô hình ARIMA để dự báo giá cổ phiếu trong ngành ngân hàng, một lĩnh vực có tính ổn định cao hơn so với các ngành khác. Nhóm nghiên cứu sử dụng dữ liệu giá cổ phiếu của các ngân hàng thương mại niêm yết và áp dụng quy trình kiểm định chặt chẽ để chọn thông số phù hợp cho mô hình. Kết quả cho thấy ARIMA hoạt động tốt với các cổ phiếu có tính chu kỳ rõ ràng và ít bị tác động bởi yếu tố bất thường. Tuy nhiên, nghiên cứu cũng nêu rõ rằng khi thị trường xuất hiện các biến động bất ngờ, mô hình này không phản ứng kịp thời, dẫn đến sai số tăng lên đáng kể.

Trước các hạn chế của mô hình truyền thống, nhiều nghiên cứu gần đây đã thử nghiệm kết hợp ARIMA với các phương pháp học máy hiện đại để tăng khả năng xử lý dữ liệu phi tuyến. Trần Quang Quý và c.s. (2024) đã tiến hành kết hợp ARIMA với mô hình LSTM, là một loại mạng nơ-ron hồi tiếp sâu, nhằm khai thác đồng thời cả thành phần tuyến tính và phi tuyến trong chuỗi dữ liệu giá cổ phiếu. Kết quả cho thấy mô hình kết hợp giúp cải thiện đáng kể độ chính xác trong giai đoạn thị trường biến động mạnh. Tuy nhiên, mô hình này cũng đặt ra thách thức về

thời gian huấn luyện dài và yêu cầu dữ liệu chất lượng cao, dẫn đến khó khăn khi áp dụng thực tế trong môi trường dữ liệu hạn chế.

Đặc biệt, nghiên cứu của Chu Đăng Bình An và c.s. (2025), một trong số rất ít công trình trong nước ứng dụng mô hình Prophet, vốn được phát triển bởi Facebook, được đưa vào dự báo giá cổ phiếu ngành công nghệ. Prophet cho phép xử lý linh hoạt các yếu tố mùa vụ, xu hướng phi tuyến và sự kiện bất thường trong chuỗi dữ liệu. Kết quả nghiên cứu chỉ ra rằng mô hình này hoạt động tốt hơn ARIMA trong điều kiện thị trường có yếu tố mùa vụ rõ ràng, chẳng hạn như các đợt công bố báo cáo tài chính hoặc chia cổ tức.

Ngoài ra, nghiên cứu của Trần Kim Toại và c.s. (2024) đã tiến hành so sánh ba mô hình dự báo VN-Index gồm ARIMA, SVR và LSTM. Kết quả cho thấy ARIMA hiệu quả trong dự báo ngắn hạn, trong khi LSTM cho kết quả tốt hơn ở khung trung và dài hạn. Điều này khẳng định rằng không có mô hình tối ưu duy nhất, mà hiệu quả phụ thuộc vào mục tiêu và thời gian dự báo cụ thể.

Bảng 2.2. Tổng hợp các nghiên cứu liên quan

STT	Tác giả (Năm)	Đối tượng và phạm vi nghiên cứu	Mô hình sử dụng	Mục tiêu nghiên cứu	Kết quả chính
1	Adebiyi và c.s. (2014)	Giá cổ phiếu tại Sở Giao dịch Chứng khoán New York (1988 – 2011)	ARIMA, Mạng Nơ- ron Nhân tạo (ANN)	So sánh hiệu quả của 2 mô hình trong dự báo giá cổ phiếu	ANN cho kết quả vượt trội so với ARIMA
2	Angelo và c.s. (2023)	Giá chuyển đổi từ Bitcoin sang Rupiah In- donesia (2019 – 2021)	Prophet, ARIMA	So sánh 2 mô hình trong dự báo giá	Prophet dự báo chính xác hơn cho ngắn hạn, ARIMA tốt hơn cho chuỗi dài hạn .
3	Box & Jenkins (1976)	Tỷ giá TZS/USD thị trường Tanzania (2009 – 2015)	ARCH, GARCH, EGARCH	Phân tích chuỗi thời gian phi tuyến tính và kiểm tra sự biến động không đồng đều trong tỷ giá	Tỷ giá hối đoái chứng minh sự cần thiết của ARCH trong phân tích
4	Chu Đặng Bình An và c.s. (2025)	30 mã cổ phiếu tại HOSE (2019 – 2024)	ARIMA, VAR, Holt- Winters, Prophet	Dự báo xu hướng giá chứng khoán	Prophet xử lý tốt so với các mô hình còn lại
5	Garlapati và c.s. (2021)	Giá cổ phiếu tại thị trường Ấn Độ (2012 – 2020)	Prophet, ARIMA	So sánh hiệu quả của Prophet và ARIMA trong dự báo giá cổ phiếu	Prophet vượt trội hơn ARI- MA trong dự báo giá cổ phiếu
6	Giang Ngọc Hà	Giá cổ phiếu của 4 ngân	ARIMA	Dự báo giá cổ phiếu ngân hàng	ARIMA dự báo tốt ngắn

	Linh và c.s. (2024)	hàng niêm yết trên HOSE (2023-2024)		(VCB, TCB, ACB, BIDV) trong ngắn hạn	hạn
7	Nguyễn Hồ Diệu Uyên & Huyền (2014)	VN-Index trên thị trường chứng khoán Việt Nam (2009-2014)	ARIMA	Dự báo ngắn hạn chỉ số VN-Index và đưa ra khuyến nghị ứng dụng cho nhà đầu tư	ARIMA phù hợp dự báo ngắn hạn
8	Taylor & Letham (2017)	Dự báo chuỗi thời gian trong lĩnh vực tài chính	Prophet	Phát triển mô hình Prophet để xử lý dữ liệu phi tuyến và yếu tố mùa vụ	Prophet có khả năng xử lý chuỗi thời gian với các yếu tố phi tuyến và mùa vụ, phù hợp cho các chuỗi dữ liệu không dừng
9	Trần Kim Toại và c.s. (2024)	Dự báo VN-Index dài hạn và ngắn hạn trên HOSE	ARIMA, SVR, LSTM, ARIMA-SVR	So sánh độ chính xác dự báo giữa các mô hình học máy	LSTM dự báo dài hạn tốt, ARIMA tốt hơn với dự báo ngắn hạn, ARIMA-SVR nâng cao hiệu suất mô hình
10	Trần Quang Quý và c.s. (2024)	Giá cổ phiếu của Amazon (1999 – 2024)	LSTM	Ứng dụng LSTM dự đoán xu hướng giá cổ phiếu	LSTM dự báo sát xu hướng nhưng độ chính xác chưa cao tuyệt đối

Nguồn: Tác giả tự tổng hợp

2.4.3 Khoảng trống của nghiên cứu

Dựa trên tổng quan các nghiên cứu, có thể thấy rằng trong lĩnh vực dự báo giá cổ phiếu tại thị trường Việt Nam, vẫn còn thiếu các nghiên cứu so sánh trực tiếp

giữa mô hình Prophet và ARIMA trên cùng một tập dữ liệu. Các nghiên cứu hiện tại chủ yếu chỉ tập trung vào nghiên cứu riêng lẻ từng mô hình mà chưa thực hiện phân tích đầy đủ để xác định mô hình nào phù hợp hơn trong điều kiện thị trường Việt Nam. Thị trường tài chính Việt Nam có những đặc điểm dữ liệu rất khác biệt so với các thị trường phát triển như sự nhiễu, thiếu ổn định, và tính mùa vụ rõ rệt, điều này khiến các mô hình truyền thống như ARIMA gặp khó khăn. Tuy nhiên, vẫn chưa có nhiều nghiên cứu kiểm chứng hiệu quả của mô hình Prophet trong bối cảnh này, tạo ra một khoảng trống nghiên cứu quan trọng. Các nghiên cứu quốc tế thường tập trung vào các thị trường phát triển, trong khi nghiên cứu trong nước lại thiếu sự khai thác sâu về ứng dụng các mô hình hiện đại như Prophet, và thiếu sự so sánh toàn diện giữa các mô hình dự báo. Bên cạnh đó, các nghiên cứu cũng chưa khai thác triệt để các yếu tố vĩ mô và cú sốc ngoại sinh đặc trưng của thị trường tài chính mới nổi như Việt Nam, khiến kết quả dự báo chưa phản ánh chính xác thực tế của thị trường. Điều này làm hạn chế khả năng so sánh và lựa chọn mô hình dự báo phù hợp.

Điểm mới của nghiên cứu là việc so sánh đồng thời hai mô hình Prophet và ARIMA trong dự báo giá cổ phiếu tại thị trường Việt Nam. Nghiên cứu không chỉ kiểm định độ chính xác của các mô hình qua các chỉ số đánh giá, mà còn cung cấp cái nhìn tổng quan về hiệu quả của hai mô hình này trong mỗi điều kiện khác nhau của thị trường Việt Nam. Việc áp dụng Prophet vào thị trường tài chính Việt Nam là một điểm mới, giúp lấp đầy khoảng trống của nghiên cứu.

Kết quả nghiên cứu kỳ vọng sẽ giúp cải thiện độ chính xác của dự báo, hỗ trợ các nhà đầu tư đưa ra quyết định chính xác hơn trong môi trường thị trường đầy biến động. Nghiên cứu này cũng đóng góp vào việc mở rộng ứng dụng các mô hình dự báo hiện đại trong các thị trường mới nổi và cung cấp một cái nhìn rõ ràng hơn về sự phù hợp của các mô hình này trong bối cảnh đặc thù của thị trường tài chính Việt Nam.

KẾT LUẬN CHƯƠNG 2

Chương 2 đã làm rõ bối cảnh học thuật và thực tiễn liên quan đến dự báo chuỗi thời gian tài chính, đặc biệt là ứng dụng hai mô hình Prophet và ARIMA trong dự báo giá cổ phiếu. Qua việc phân tích đặc điểm lý thuyết của từng mô hình, tổng hợp các nghiên cứu trong và ngoài nước cũng như xác định khoảng trống tri thức, chương này đã củng cố cơ sở khoa học cho việc lựa chọn hai mô hình làm đối tượng so sánh. Đặc biệt là với những thách thức đặc thù của thị trường chứng khoán Việt Nam, một thị trường mới nổi với dữ liệu nhiễu, thiếu ổn định và thường xuyên bị ảnh hưởng bởi các cú sốc vĩ mô, cho thấy sự cần thiết của việc đánh giá hiệu quả mô hình Prophet, vốn dĩ ít được nghiên cứu tại bối cảnh trong nước.

Từ những cơ sở lý luận và thực nghiệm đã đề cập, chương tiếp theo sẽ trình bày chi tiết thiết kế nghiên cứu hay quy trình nghiên cứu, bao gồm dữ liệu nghiên cứu, phương pháp thu thập và xử lý dữ liệu, mô hình dự báo được áp dụng, và các tiêu chí đánh giá hiệu suất của mô hình. Đây là bước quan trọng nhằm đảm bảo tính khách quan, khoa học và logic trong quá trình kiểm định giả thuyết nghiên cứu, qua đó xác định mô hình dự báo phù hợp nhất với thị trường chứng khoán Việt Nam trong điều kiện thực tế đầy biến động.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU

Chương 3 nhằm trình bày cụ thể cách thức nghiên cứu được triển khai để trả lời các câu hỏi nghiên cứu đã nêu ở chương 1, đồng thời làm rõ cách lựa chọn và áp dụng hai mô hình dự báo Prophet và ARIMA. Trên cơ sở lý thuyết đã xây dựng ở chương 2, chương này sẽ giới thiệu phương pháp định lượng, quy trình thu thập và xử lý dữ liệu, thiết kế mô hình dự báo cũng như các chỉ số đánh giá hiệu suất. Qua đó, chương sẽ cung cấp nền tảng kỹ thuật cần thiết để triển khai thực nghiệm trong chương tiếp theo, đảm bảo tính logic, minh bạch và khả năng lặp lại của toàn bộ nghiên cứu.

3.1. Quy trình nghiên cứu



Hình 3.1. Sơ đồ quy trình nghiên cứu

Quy trình nghiên cứu được tiến hành qua các bước ở hình 3.1 cụ thể như sau:

Nguồn: Tác giả tự tổng hợp

Bước 1. Tổng hợp lý thuyết và tổng quan các nghiên cứu trước

Nghiên cứu bắt đầu bằng việc thu thập và phân tích các tài liệu liên quan đến dự báo chuỗi thời gian, đặc biệt là mô hình Prophet và ARIMA. Mục tiêu là nhận diện khoảng trống nghiên cứu, từ đó xác định mục tiêu nghiên cứu phù hợp với bối cảnh thị trường chứng khoán Việt Nam.

Bước 2. Lựa chọn mẫu nghiên cứu

Mẫu nghiên cứu được chọn là 11 mã cổ phiếu tiêu biểu đại diện cho các ngành đại diện trên thị trường chứng khoán Việt Nam. Việc lựa chọn mẫu đảm bảo tính đa dạng, đại diện và phù hợp để phân tích, đánh giá các mô hình dự báo.

Bước 3. Thu thập dữ liệu

Dữ liệu giá đóng cửa hàng ngày được thu thập từ nền tảng FiinPro-X trong giai đoạn 2020 – 2025. Dữ liệu được chọn là giá điều chỉnh để loại bỏ các yếu tố kỹ thuật như chia cổ tức hoặc tách cổ phiếu.

Bước 4. Xử lý và phân tích dữ liệu

Dữ liệu được làm sạch, xử lý thiếu, loại bỏ ngoại lai và chuẩn hóa thời gian. Sau đó tiến hành phân tích thống kê mô tả để nhận diện đặc điểm dữ liệu và kiểm định tính dừng bằng kiểm định ADF nhằm xác định tính ổn định của chuỗi thời gian.

Bước 5. Chia tập dữ liệu

Dữ liệu được chia theo TimeSeriesSplit của phương pháp cross-validation.

Bước 6. Xây dựng và huấn luyện mô hình dự báo

Hai mô hình được triển khai trên tập huấn luyện bằng Python. Với ARIMA, các tham số được xác định thông qua auto_arima. Mô hình Prophet được cấu hình theo đặc điểm xu hướng và mùa vụ của dữ liệu. Cả hai mô hình đều được tối ưu hóa để phù hợp với từng chuỗi thời gian cụ thể. Quá trình huấn luyện và hiệu chỉnh mô hình được thực hiện dựa vào ngôn ngữ Python với các thư viện chuyên dụng.

Bước 7. Dự báo và đánh giá mô hình

Thực hiện dự báo trên tập kiểm định, sau đó đánh giá hiệu suất mô hình bằng các chỉ số RMSE, MAE, MAPE. Kiểm định thống kê Diebold-Mariano được áp dụng để so sánh độ chính xác giữa hai mô hình.

Bước 8. Tổng hợp kết quả và đưa ra kết luận

Dựa trên các chỉ số đánh giá, kết quả dự báo được phân tích, thảo luận về ưu nhược điểm của từng mô hình trong bối cảnh thị trường đặc thù. Trên cơ sở đó, đưa ra kết luận về mô hình nào có hiệu suất dự báo tốt hơn, đồng thời đề xuất hướng ứng dụng và mở rộng nghiên cứu trong tương lai.

3.2. Phương pháp nghiên cứu

Nghiên cứu này áp dụng phương pháp định lượng, lí do được lựa chọn là vì cho phép đánh giá khách quan các mô hình dự báo thông qua các chỉ số sai số phổ biến, đồng thời phù hợp với tính chất dữ liệu số liệu giá cổ phiếu ngày theo chuỗi thời gian (Hyndman & Athanasopoulos, 2018).

Phương pháp chính được sử dụng là dự báo chuỗi thời gian, tập trung vào phân tích các đặc điểm biến động theo thời gian của giá cổ phiếu, bao gồm xu hướng, tính mùa vụ, biến động và các điểm dị thường nếu có tồn tại. Mô hình ARIMA là mô hình thống kê truyền thống, phù hợp với các chuỗi thời gian có tính dừng sau khi thực hiện các bước xử lý dữ liệu như lấy sai phân (Box & Jenkins, 1976). Mô hình Prophet do Facebook phát triển, là mô hình phi tuyến linh hoạt, được thiết kế để xử lý chuỗi dữ liệu phức tạp, có xu hướng phi tuyến và các yếu tố mùa vụ cũng như các điểm dị biệt trong dữ liệu (Taylor & Letham, 2017).

Qua đó, nghiên cứu này được tiến hành với mục tiêu đảm bảo tính khách quan, khoa học và thực tiễn, đồng thời góp phần nâng cao hiệu quả ứng dụng các mô hình dự báo trong lĩnh vực tài chính, đặc biệt đối với các thị trường mới nổi như Việt Nam, nơi mà dữ liệu tài chính có nhiều đặc thù và biến động phức tạp.

3.3. Dữ liệu nghiên cứu

3.3.1. Mẫu nghiên cứu

Trong nghiên cứu này, mẫu dữ liệu bao gồm giá đóng cửa theo ngày của cổ phiếu của 11 công ty niêm yết trên HOSE trong khoảng thời gian từ 01/01/2020 đến 31/03/2025. Mỗi công ty được chọn đại diện cho một ngành chủ chốt trong nền kinh tế Việt Nam như tài chính (ngân hàng), bất động sản, sản xuất công nghiệp, năng lượng, tiêu dùng thiết yếu, tiêu dùng không thiết yếu, chăm sóc sức khỏe (y tế), công nghệ thông tin, dịch vụ viễn thông, dịch vụ tiện ích và nguyên vật liệu. Mục đích của việc lựa chọn các ngành nghề đa dạng này là giúp nghiên cứu có thể phản ánh sát thực trạng biến động của thị trường và đảm bảo tính khách quan trong việc đánh giá hiệu quả của các mô hình dự báo.

3.3.2. Thu thập và tiền xử lý dữ liệu

Để đảm bảo dữ liệu phản ánh đúng bản chất biến động thị trường, nghiên cứu sử dụng giá đóng cửa đã điều chỉnh thay vì giá đóng cửa thông thường. Điều này giúp loại bỏ các biến động giả tạo do chia cổ tức, phát hành thêm cổ phiếu hoặc tách cổ phiếu, những yếu tố có thể gây nhiễu cho mô hình dự báo. Giá điều chỉnh được thu thập trực tiếp từ nền tảng FiinPro-X. Sau khi thu thập, dữ liệu được tiến hành xử lý qua các bước quan trọng để đảm bảo phù hợp với yêu cầu phân tích chuỗi thời gian.

Dữ liệu sau khi thu thập sẽ được tiền xử lý theo quy trình gồm:

- **Làm sạch dữ liệu**

Các giá trị thiếu sẽ được xử lý bằng phương pháp nội suy tuyến tính hoặc loại bỏ nếu tỷ lệ thiếu vượt quá ngưỡng cho phép. Các quan sát ngoại lai được phát hiện thông qua việc sử dụng biểu đồ hộp (boxplot) và chỉ số Z-score (Tsay, 2010). Tùy thuộc vào bản chất của ngoại lai, chúng có thể được giữ lại nếu chúng phản ánh biến động thực tế của thị trường, hoặc loại bỏ nếu được xác định là do lỗi ghi nhận.

Các phương pháp phát hiện ngoại lai bao gồm:

- Phương pháp IQR (Interquartile Range): Xác định ngoại lai dựa trên khoảng tứ phân vị (Q1, Q3).

- Phương pháp Z-score: Dùng độ lệch chuẩn để xác định các điểm có giá trị quá cao hoặc quá thấp.

- **Chuẩn hóa định dạng thời gian**

Dữ liệu được chuẩn hóa về kiểu datetime để đảm bảo tính nhất quán và hỗ trợ các thao tác phân tích chuỗi thời gian sau này. Việc chuẩn hóa này rất quan trọng để dữ liệu có thể được xử lý đúng cách trong các mô hình chuỗi thời gian và hỗ trợ các thao tác phân tích tiếp theo.

- **Phân tích thống kê mô tả**

Sau khi tiền xử lý, nghiên cứu tiến hành thống kê mô tả sử dụng các thư viện pandas, matplotlib, và seaborn. Các chỉ số cơ bản như trung bình, độ lệch chuẩn, giá trị cực đại, giá trị cực tiểu, và phân vị được tính toán bằng hàm describe(). Song song đó, các biểu đồ như biểu đồ đường, histogram và boxplot được sử dụng để trực quan hóa xu hướng, phân phối, và các đặc điểm bất thường của chuỗi dữ liệu, giúp nhận diện các vấn đề trong dữ liệu và đưa ra các quyết định phù hợp (Hyndman & Athanasopoulos, 2018).

Toàn bộ quy trình xử lý dữ liệu được lập trình tự động nhằm đảm bảo tính nhất quán, khách quan và khả năng lặp lại cao, là điều cần thiết trong phân tích chuỗi thời gian tài chính. Qua đó, có thể thấy rằng quá trình thu thập và xử lý dữ liệu được xây dựng kỹ lưỡng nhằm đảm bảo bộ dữ liệu đầu vào đủ sạch, đầy đủ và phù hợp để xây dựng mô hình dự báo chuỗi thời gian hiệu quả, qua đó nâng cao độ chính xác và tính ứng dụng thực tiễn của nghiên cứu.

3.3.3. Chia tập dữ liệu

Trong nghiên cứu này, dữ liệu được chia thành 5 phần theo phương pháp TimeSeriesSplit nhằm đánh giá hiệu quả mô hình một cách khách quan. Khác với phương pháp chia dữ liệu truyền thống, nơi dữ liệu được chia ngẫu nhiên, TimeSeriesSplit giữ thứ tự thời gian của dữ liệu, giúp mô hình huấn luyện trên dữ liệu quá khứ và dự báo cho dữ liệu tương lai. Điều này ngăn ngừa rò rỉ thông tin từ

tương lai vào quá trình huấn luyện, một yêu cầu quan trọng trong phân tích chuỗi thời gian như giá cổ phiếu (Hyndman & Athanasopoulos, 2018; Shumway & Stoffer, 2011).

TimeSeriesSplit không chỉ bảo vệ tính liên kết theo thời gian trong dữ liệu mà còn giúp mô hình được kiểm tra trên dữ liệu chưa thấy (tức là kiểm tra khả năng tổng quát của mô hình). Khi sử dụng phương pháp này, mô hình chỉ được huấn luyện trên dữ liệu quá khứ và kiểm tra trên dữ liệu tương lai, điều này đảm bảo tính khách quan và chính xác trong dự báo. Ngoài ra, nghiên cứu lựa chọn 5-fold giúp cân bằng giữa độ chính xác và chi phí tính toán. Với quy mô dữ liệu trung bình trong nghiên cứu, 5-fold là lựa chọn phù hợp để đánh giá ổn định của mô hình mà không gây tổn kém quá nhiều tài nguyên.

Thông qua việc kiểm tra mô hình trên các tập dữ liệu khác nhau, phương pháp này giúp mô hình được kiểm tra khả năng hoạt động ổn định và dự báo chính xác trên dữ liệu chưa từng thấy. Từ đó, việc lựa chọn mô hình sẽ có cơ sở rõ ràng và đáng tin cậy hơn.

3.3.4. Công cụ nghiên cứu

Các bước xử lý, mô hình hóa và đánh giá được thực hiện bằng ngôn ngữ lập trình Python, với sự hỗ trợ của các thư viện:

- *pandas, numpy*: xử lý và phân tích dữ liệu
- *statsmodels, pmdarima*: xây dựng mô hình ARIMA
- *prophet*: triển khai mô hình Prophet
- *scikit-learn*: tính các chỉ số RMSE, MAE, MAPE
- *arch*: thực hiện kiểm định Diebold-Mariano
- *matplotlib, seaborn*: trực quan hóa dữ liệu và kết quả

Ngoài ra, trong quá trình thực hiện nghiên cứu sẽ sử dụng thêm một số thư viện cần thiết khác.

3.4. Mô hình nghiên cứu và kỹ thuật dự báo

3.4.1. Giả thuyết nghiên cứu

Mục tiêu chính của nghiên cứu là đánh giá và so sánh kết quả dự báo giá cổ phiếu giữa hai mô hình chuỗi thời gian là Prophet và ARIMA. Việc so sánh được thực hiện trên tập dữ liệu lịch sử giá cổ phiếu niêm yết trên Sở Giao dịch Chứng khoán TP.HCM, thông qua các chỉ số sai số phổ biến như RMSE, MAE và MAPE.

Từ đó, nghiên cứu đưa ra giả thuyết nghiên cứu như sau:

Giả thuyết H_0 : Không có sự khác biệt đáng kể về độ chính xác trong dự báo giữa hai mô hình Prophet và ARIMA.

Giả thuyết H_1 : Có sự khác biệt đáng kể về độ chính xác giữa Prophet và ARIMA.

Giả thuyết này sẽ được kiểm chứng thông qua quá trình huấn luyện, dự báo và đánh giá mô hình với ba chỉ số sai số nêu trên, kết hợp với kiểm định thống kê Diebold-Mariano (DM) nhằm xác định xem sự khác biệt có ý nghĩa thống kê hay không. Việc xây dựng giả thuyết rõ ràng không chỉ giúp định hướng cho toàn bộ nghiên cứu, mà còn đảm bảo tính khoa học và hợp lý trong việc đưa ra kết luận và khuyến nghị thực tiễn về lựa chọn mô hình dự báo phù hợp trong lĩnh vực tài chính.

3.4.2. Mô hình Prophet

Như đã trình bày trong chương 2, Prophet là mô hình dự báo chuỗi thời gian linh hoạt, có khả năng xử lý dữ liệu không dừng và tích hợp các yếu tố xu hướng, mùa vụ cũng như các sự kiện dị biệt. Trong phần này, nghiên cứu trình bày quy trình triển khai và huấn luyện mô hình Prophet một cách hệ thống, làm cơ sở cho việc áp dụng vào dữ liệu giá cổ phiếu ở chương sau.

Quá trình huấn luyện mô hình được thực hiện theo quy trình cơ bản như sau:

Bước 1: Chuẩn bị dữ liệu

Dữ liệu được định dạng thành hai cột:

- ds (date): thời gian (ngày giao dịch)
- y : giá trị cần dự báo (giá cổ phiếu)

Prophet yêu cầu cấu trúc dữ liệu này để xác định trục thời gian và biến đầu ra.

Bước 2: Cấu hình xu hướng (Trend)

Mô hình Prophet mô hình hóa xu hướng dài hạn qua hai phương pháp chính:

- Linear growth (tăng tuyến tính): giá trị chuỗi tăng đều theo thời gian, phù hợp với dữ liệu không bị giới hạn trên.
- Logistic growth (tăng trưởng giới hạn): giá trị tăng chậm dần và tiệm cận một mức trần (cap), phù hợp khi giá trị thực tế không thể vượt quá ngưỡng nhất định (ví dụ lượng người dùng, mức sản xuất tối đa). Khi dùng Logistic, cần thêm một cột cap trong dữ liệu để xác định ngưỡng trên.

Prophet tự động phát hiện các điểm thay đổi xu hướng (changepoints), là các thời điểm mà tốc độ tăng hoặc giảm của chuỗi biến đổi rõ rệt.

Tham số changepoint_prior_scale điều chỉnh độ nhạy với những thay đổi này:

- Giá trị nhỏ (ví dụ 0,05): xu hướng mượt mà, ít thay đổi.
- Giá trị lớn (ví dụ 0,5): mô hình linh hoạt hơn nhưng dễ bị nhiễu.

Bước 3: Mô hình hóa yếu tố mùa vụ (Seasonality)

Prophet tích hợp sẵn các mùa vụ như yearly seasonality, weekly seasonality, daily seasonality,... Các thành phần mùa vụ được xây dựng từ chuỗi Fourier, cho phép mô hình học được các chu kỳ lặp lại. Người dùng có thể tùy chỉnh thêm mùa vụ đặc biệt nếu cần, bằng tham số seasonality_mode:

- additive: dùng khi biên độ mùa vụ không phụ thuộc giá trị.
- multiplicative: dùng khi biên độ mùa vụ tỷ lệ thuận với mức giá (ví dụ giá cổ phiếu càng cao → dao động càng lớn).

Bước 4: Tích hợp sự kiện đặc biệt (Holidays)

Prophet cho phép tích hợp các sự kiện vĩ mô, ngày lễ, công bố chính sách,... thông qua biến giả. Chỉ cần cung cấp danh sách ngày và tên sự kiện, mô hình sẽ tự động học ảnh hưởng của chúng.

Bước 5: Huấn luyện mô hình

Mô hình Prophet được huấn luyện bằng phương thức `.fit()` trên tập dữ liệu huấn luyện. Trong quá trình này, Prophet sử dụng phương MAP (Maximum a Posteriori) thay vì ước lượng MLE như ARIMA. MAP là phương pháp tìm bộ tham số tốt nhất cho mô hình không chỉ dựa trên dữ liệu thực tế, mà còn kết hợp với giả định tiên nghiệm về hành vi của dữ liệu, là sự kết hợp giữa:

- Dữ liệu quan sát
- Giả định tiên nghiệm (prior), có thể hiểu là giả định sẵn có như dữ liệu có xu hướng mượt mà, không thay đổi đột ngột hay mùa vụ không quá

Việc kết hợp này giúp mô hình ổn định hơn, tránh quá khớp khi dữ liệu có nhiễu, chuỗi ngắn, hoặc thiếu thông tin rõ ràng. Đây là một trong những điểm mạnh của Prophet trong thực tiễn, vì nó cho phép mô hình dự báo chắc chắn hơn ngay cả khi dữ liệu đầu vào không lý tưởng.

Bước 6: Dự báo và mở rộng khung thời gian

Tập dữ liệu dự báo được mở rộng bằng hàm `make_future_dataframe()` đến 31/03/2025. Sau đó, hàm `predict()` được gọi để tạo ra:

- `yhat`: giá trị dự báo trung bình,
- `yhat_lower`, `yhat_upper`: khoảng tin cậy 95%, giúp đánh giá rủi ro dự báo.

Bước 7: Trực quan hóa và đánh giá mô hình

Các thành phần xu hướng, mùa vụ, và tác động sự kiện có thể được giải thích qua việc trực quan hóa bằng `plot()` và `plot_components()` để giải thích rõ đóng góp từng phần. Sau đó, kết quả được đánh giá bằng các chỉ số RMSE, MAE, MAPE.

Mặc dù Prophet không có cơ chế kiểm định phần dư như ARIMA, các biểu đồ phần dư có thể được trực quan để phát hiện bất thường. Prophet là công cụ linh hoạt, dễ triển khai và phù hợp với dữ liệu tài chính có tính nhiễu cao như thị trường chứng khoán Việt Nam.

3.4.3. Mô hình ARIMA

ARIMA là một trong những mô hình dự báo chuỗi thời gian truyền thống, yêu cầu chuỗi đầu vào phải đạt tính dừng để đảm bảo tính ổn định trong dự báo. Dựa trên nền tảng lý thuyết đã nêu ở chương 2, phần này trình bày cụ thể các bước xây dựng và huấn luyện mô hình ARIMA, bao gồm xác định tham số, kiểm định phần dư và lựa chọn mô hình tối ưu.

Trong nghiên cứu này, quá trình huấn luyện mô hình ARIMA được thực hiện qua các bước, sau khi đã được tiền xử lý:

Bước 1: Kiểm tra tính dừng (xác định tham số d)

Tính dừng là điều kiện bắt buộc khi áp dụng ARIMA, được hiểu là chuỗi có các đặc điểm thống kê như trung bình và phương sai không thay đổi theo thời gian. Việc xác định tính dừng được thực hiện bằng kiểm định Augmented Dickey-Fuller (ADF) (Dickey & Fuller, 1979).

- Giả thuyết H_0 : chuỗi không dừng (có đơn vị gốc)
- Giả thuyết H_1 : chuỗi dừng

Nếu $p\text{-value} < 0,05$, bác bỏ H_0 , kết luận chuỗi dừng. Nếu không, cần thực hiện sai phân bậc một và kiểm định lại. Quá trình này lặp lại cho đến khi chuỗi đạt tính dừng. Số lần sai phân cần thiết chính là giá trị của tham số d .

Việc kiểm định được thực hiện bằng hàm `adfuller()` thuộc thư viện `statsmodels`.

Bước 2: Xác định tham số p và q

Sau khi chuỗi đã đạt tính dừng, việc xác định bậc AR (p) và MA (q) được thực hiện thông qua phân tích đồ thị:

- **ACF (Autocorrelation Function)**

ACF là công cụ thống kê cho biết mức độ tương quan giữa một giá trị trong chuỗi thời gian và các giá trị trong quá khứ tại các độ trễ khác nhau (lag). Biểu đồ ACF thường được sử dụng để xác định bậc q (MA) trong mô hình ARIMA (Hyndman & Athanasopoulos, 2018).

Để xác định q , ta quan sát số lượng cột (tương ứng với các độ trễ) vượt khỏi ngưỡng tin cậy đầu tiên (thường là hai đường ngang màu xanh biểu diễn mức ý nghĩa 95%). Khi các cột bắt đầu nằm trong vùng tin cậy, đó là điểm cắt, từ đó suy ra bậc q . Ví dụ, nếu chỉ cột tại $\text{lag} = 1$ vượt ngưỡng, còn lại không, ta chọn $q = 1$.

▪ PACF (Partial Autocorrelation Function)

PACF đo lường mối tương quan giữa một giá trị hiện tại với một giá trị quá khứ tại độ trễ cụ thể, sau khi đã loại bỏ ảnh hưởng của các giá trị trung gian. Điều này giúp phát hiện chính xác độ trễ nào có ảnh hưởng trực tiếp đến giá trị hiện tại. PACF thường được sử dụng để xác định bậc p (AR) trong mô hình ARIMA (Hyndman & Athanasopoulos, 2018).

Tương tự ACF, ta xác định p bằng cách đếm số lượng cột đầu tiên trên biểu đồ PACF vượt ra ngoài vùng tin cậy. Ví dụ, nếu hai cột đầu ($\text{lag} = 1$ và $\text{lag} = 2$) vượt ngưỡng, còn các lag sau không, ta có thể chọn $p = 2$. Dùng để xác định bậc p theo cách tương tự. Ví dụ, nếu hai cột đầu vượt ngưỡng nên chọn $p = 2$.

Bước 3: Ước lượng mô hình (MLE – Maximum Likelihood Estimation)

Đây là phương pháp được sử dụng để ước lượng các tham số mô hình bằng cách tìm bộ tham số làm cực đại hàm hợp lý, có nghĩa là bộ tham số khiến xác suất quan sát được chuỗi dữ liệu là lớn nhất (Box và c.s., 2016). Trong mô hình ARIMA, các tham số được ước lượng thông qua kỹ thuật MLE nhằm tối ưu hóa mức độ phù hợp giữa mô hình và dữ liệu.

Phương pháp MLE được tự động tích hợp trong hàm `ARIMA()` của thư viện `statsmodels` hoặc `auto_arima()` từ thư viện `pmdarima`. Khi gọi hàm huấn luyện mô hình, quá trình tối ưu hóa tham số bằng MLE sẽ được thực hiện mặc định mà không cần viết tay công thức xác suất.

Phương pháp ước lượng tham số mô hình bằng cách tối đa hóa xác suất quan sát được dữ liệu thực tế, tức là sao cho xác suất quan sát được dữ liệu là lớn nhất, giúp tìm ra bộ tham số phù hợp nhất cho mô hình ARIMA.

Bước 4: Lựa chọn mô hình tối ưu

Để đánh giá mức độ phù hợp của các mô hình ARIMA với các tổ hợp tham số khác nhau, nghiên cứu sử dụng AIC và BIC. Là hai chỉ số đánh giá mô hình dựa trên sự đánh đổi giữa độ phù hợp và độ phức tạp. Mô hình có AIC hoặc BIC càng thấp thì được xem là càng tối ưu, vì đạt được sự cân bằng giữa việc giải thích tốt dữ liệu và không quá nhiều tham số (Burnham & Anderson, 2002).

Sau khi mô hình ARIMA được huấn luyện, các giá trị AIC và BIC được truy xuất thông qua các thuộc tính `.aic` và `.bic` của mô hình. Nhiều mô hình với các tổ hợp tham số khác nhau có thể được huấn luyện và so sánh AIC và BIC để chọn ra mô hình tối ưu nhất.

Bước 5: Kiểm định phần dư (Ljung-Box)

Sau khi mô hình được huấn luyện, phần dư cần được kiểm tra để đảm bảo rằng chúng không còn thông tin nào có thể khai thác. Kiểm định Ljung-Box được sử dụng để xác định xem phần dư có còn tự tương quan không.

- Nếu $p\text{-value} > 0,05$ tại các độ trễ nên phần dư là nhiễu trắng, mô hình phù hợp
- Nếu $p\text{-value} < 0,05$ nên mô hình chưa phù hợp, cần điều chỉnh lại

Việc kiểm định được thực hiện thông qua hàm `acorr_ljungbox()` thuộc thư viện `statsmodels.stats.diagnostic`. Hàm này trả về giá trị thống kê kiểm định và $p\text{-value}$ cho nhiều độ trễ. Nếu $p\text{-value}$ tại các độ trễ đều lớn hơn 0,05, ta kết luận phần dư không có tự tương quan đáng kể.

Mặc dù ARIMA không phù hợp với chuỗi có đặc tính phi tuyến hoặc mùa vụ mạnh, nhưng trong môi trường thị trường ổn định, mô hình vẫn cho kết quả tin cậy và là chuẩn đối sánh phù hợp để so sánh với Prophet trong nghiên cứu này.

3.4.4. Lý do lựa chọn mô hình Prophet và ARIMA trong nghiên cứu

Việc lựa chọn hai mô hình Prophet và ARIMA trong nghiên cứu này xuất phát từ đặc điểm biến động ngày càng phức tạp của thị trường chứng khoán Việt Nam hiện nay. Mô hình ARIMA đại diện cho nhóm phương pháp thống kê truyền thống, được sử dụng rộng rãi trong các nghiên cứu tài chính nhờ khả năng xử lý tốt các chuỗi dữ liệu tuyến tính và ổn định sau khi đã đạt tính dừng (Box & Jenkins,

1976; Hyndman & Athanasopoulos, 2018). ARIMA phù hợp trong các giai đoạn thị trường tương đối ít biến động và có xu hướng rõ ràng.

Tuy nhiên, đặc trưng của thị trường Việt Nam, là một thị trường mới nổi, có dữ liệu thường không ổn định, chứa nhiều điểm dị biệt và dễ bị tác động bởi các yếu tố tâm lý, chính sách, hoặc sự kiện đột biến. Trong bối cảnh đó, Prophet, là một mô hình linh hoạt do Facebook phát triển, đã trở thành lựa chọn phù hợp hơn nhờ khả năng tự động phát hiện xu hướng, mùa vụ và các biến động bất thường mà không yêu cầu chuỗi dữ liệu phải dừng (Taylor & Letham, 2017). Prophet cũng được đánh giá cao trong việc xử lý dữ liệu có yếu tố mùa vụ hoặc thiếu đều đặn, được coi là điều thường xuyên xảy ra trong thị trường chứng khoán thực tế (Garlapati và c.s., 2021).

Việc đồng thời sử dụng Prophet và ARIMA trong nghiên cứu này không chỉ giúp so sánh hai cách tiếp cận lý thuyết khác nhau mà còn mang tính thực tiễn cao, góp phần cung cấp cơ sở khoa học cho việc lựa chọn mô hình dự báo hiệu quả hơn trong điều kiện thị trường tài chính tại Việt Nam hiện nay.

3.5. Phương pháp so sánh và đánh giá hiệu suất mô hình

3.5.1. Các chỉ số đánh giá

Trong chương 2, nghiên cứu đã trình bày cơ sở lý thuyết, công thức tính toán cũng như ưu và nhược điểm của ba chỉ số đánh giá hiệu suất mô hình gồm RMSE, MAE và MAPE. Ba chỉ số này sẽ tiếp tục được sử dụng trong chương này, tập trung vào ứng dụng thực tiễn của chúng để đánh giá và so sánh mức độ chính xác của hai mô hình dự báo.

Việc sử dụng kết hợp RMSE, MAE và MAPE nhằm đảm bảo đánh giá toàn diện và khách quan hiệu quả dự báo của từng mô hình. RMSE có khả năng làm nổi bật các sai số lớn nhờ tính chất bình phương, qua đó giúp nhận diện những điểm dự báo sai lệch đáng kể (Chai & Draxler, 2014). Chỉ số này đặc biệt phù hợp trong các tình huống nhà đầu tư quan tâm đến rủi ro sai số cao. MAE đo lường sai số trung bình tuyệt đối, có độ ổn định cao và ít bị ảnh hưởng bởi các giá trị ngoại lai, đặc

biệt phù hợp trong điều kiện dữ liệu có độ nhiễu cao (Willmott & Matsuura, 2005b). Trong khi đó, MAPE biểu thị sai số theo tỷ lệ phần trăm, cho phép so sánh hiệu quả dự báo giữa các mô hình hoặc các cổ phiếu có quy mô giá khác nhau, đồng thời mang lại sự trực quan cao trong việc phân tích và diễn giải kết quả (De Myttenaere và c.s., 2016).

Trong khuôn khổ nghiên cứu, hai mô hình Prophet và ARIMA được huấn luyện bằng dữ liệu giá cổ phiếu lịch sử trong giai đoạn từ ngày 01/01/2020 đến ngày 31/12/2024. Giai đoạn kiểm định được chọn là từ 01/01/2025 đến 31/03/2025, và trong khoảng thời gian này, cả hai mô hình sẽ được sử dụng để dự báo giá cổ phiếu. Sai số giữa giá trị dự báo và giá trị thực tế trong giai đoạn kiểm định sẽ được tính toán dựa trên ba chỉ số nêu trên.

Trong cả ba chỉ số, sẽ không có một ngưỡng tuyệt đối để làm tiêu chí đánh giá vì mỗi dữ liệu là khác nhau. Nguyên tắc để đánh giá dựa trên các chỉ số được áp dụng trong nghiên cứu là giá trị của các chỉ số càng thấp thì mô hình càng có độ chính xác cao. Điều này đồng nghĩa với việc mô hình nào cho ra các chỉ số RMSE, MAE, MAPE thấp hơn sẽ được xem là hiệu quả hơn về mặt dự báo. Đây cũng là nguyên tắc thường được sử dụng trong các cuộc thi và nghiên cứu dự báo quy mô lớn, tiêu biểu là M4 Forecasting Competition, nơi các mô hình được đánh giá dựa trên nhiều tiêu chí định lượng, trong đó ưu tiên các mô hình có sai số thấp nhất (Makridakis và c.s., 2020).

Từ kết quả đánh giá, nghiên cứu sẽ tiến hành so sánh hiệu suất của từng mô hình không chỉ trên từng cổ phiếu riêng lẻ mà còn trên toàn bộ tập dữ liệu. Điều này giúp đưa ra kết luận khách quan về mô hình nào có độ chính xác cao hơn, từ đó làm cơ sở để đề xuất mô hình dự báo phù hợp trong bối cảnh đặc thù của thị trường chứng khoán Việt Nam.

3.5.2. Kiểm định thống kê Diebold – Mariano (DM)

Sau khi đo lường hiệu suất dự báo của các mô hình Prophet và ARIMA bằng ba chỉ số RMSE, MAE và MAPE, nghiên cứu tiếp tục thực hiện kiểm định thống kê Diebold – Mariano nhằm đánh giá xem sự khác biệt về độ chính xác giữa hai mô

hình có thực sự có ý nghĩa thống kê hay không. Kiểm định DM được đề xuất bởi Diebold & Mariano (1995), là một phương pháp phổ biến trong thống kê kinh tế lượng để so sánh độ chính xác dự báo của hai mô hình. Thay vì chỉ so sánh số liệu một cách đơn thuần, kiểm định này sử dụng chuỗi sai số dự báo của mỗi mô hình (ví dụ: RMSE hoặc MAE từng thời điểm) và tiến hành phân tích sự khác biệt giữa chúng dựa trên một hàm mất mát.

Trong bối cảnh nghiên cứu, kiểm định DM được áp dụng để kiểm tra giả thuyết đã nêu ở trên, cụ thể:

Giả thuyết H_0 : Không có sự khác biệt đáng kể về độ chính xác trong dự báo giữa mô hình Prophet và ARIMA.

Giả thuyết H_1 : Có sự khác biệt đáng kể về độ chính xác giữa hai mô hình.

Trong nghiên cứu này, kiểm định được thực hiện dựa trên hiệu sai giữa hai chuỗi sai số dự báo (thường là chuỗi RMSE hoặc MAE của Prophet và ARIMA), sau đó kiểm tra xem kỳ vọng trung bình của hiệu sai này có khác 0 một cách có ý nghĩa thống kê hay không. Việc kiểm định được thực hiện bằng thư viện arch trong Python, với dữ liệu đầu vào là chuỗi sai số dự báo của mỗi mô hình trên tập kiểm định.

Kết quả kiểm định được diễn giải dựa vào giá trị p-value như sau:

- Nếu $p\text{-value} > 0,05$: không đủ bằng chứng để bác bỏ H_0 , hai mô hình được xem là có độ chính xác tương đương.
- Nếu $p\text{-value} \leq 0,05$: bác bỏ H_0 , nghĩa là sự khác biệt về độ chính xác giữa hai mô hình là có ý nghĩa thống kê. Mô hình nào có sai số nhỏ hơn sẽ được xem là hiệu quả hơn.

Việc sử dụng kiểm định DM là một bước quan trọng, bởi vì không phải mọi khác biệt về mặt sai số đều là khác biệt có ý nghĩa thống kê. Ngoài ra, còn tránh việc đưa ra kết luận chủ quan dựa trên sự khác biệt nhỏ về mặt số liệu. Thực hiện kiểm định DM này giúp kết quả đánh giá mô hình không chỉ dựa trên trực quan từ chỉ số sai số mà còn được hỗ trợ bởi phương pháp thống kê có độ tin cậy cao. Đây là cách tiếp cận được nhiều công trình khoa học và nghiên cứu ứng dụng trong lĩnh

vực tài chính sử dụng để so sánh hiệu suất các mô hình dự báo (Wang và c.s., 2023; Zhou và c.s., 2025).

Vì vậy, việc kết hợp giữa các chỉ số định lượng và kiểm định thống kê không chỉ đảm bảo tính toàn diện trong đánh giá, mà còn tăng độ tin cậy, tính thuyết phục và giá trị thực tiễn của kết luận nghiên cứu.

KẾT LUẬN CHƯƠNG 3

Chương 3 đã trình bày toàn bộ quy trình nghiên cứu từ khâu lựa chọn phương pháp, thu thập và xử lý dữ liệu, đến thiết lập và huấn luyện hai mô hình dự báo Prophet và ARIMA. Trọng tâm không chỉ dừng lại ở lý thuyết mà còn thể hiện cách thức triển khai cụ thể trên tập dữ liệu thực tiễn, đảm bảo tính minh bạch và tái lập.

Việc xác định rõ các bước tiền xử lý, lựa chọn tham số và tiêu chí đánh giá là điều kiện quan trọng để đảm bảo độ tin cậy của kết quả mô hình hóa. Những nền tảng kỹ thuật được xây dựng trong chương này sẽ là cơ sở để tiến hành phân tích kết quả thực nghiệm ở chương 4. Tại đó, các mô hình sẽ được áp dụng vào dữ liệu giá cổ phiếu thực tế đã thu thập nhằm so sánh hiệu suất và đưa ra đánh giá cuối cùng về độ chính xác và tính phù hợp của từng mô hình trong bối cảnh thị trường chứng khoán Việt Nam.

CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

Chương 4 của nghiên cứu này sẽ trình bày kết quả nghiên cứu và thảo luận về kết quả của hai mô hình dự báo chuỗi thời gian phổ biến, Prophet và ARIMA, trong việc dự báo giá cổ phiếu của các công ty niêm yết trên HOSE. Mục tiêu của chương là so sánh hiệu quả của hai mô hình này thông qua các chỉ số sai số như RMSE, MAE, và MAPE. Nghiên cứu sẽ phân tích kết quả dự báo từ mỗi mô hình và đánh giá độ chính xác của chúng khi áp dụng vào dữ liệu thực tế từ thị trường chứng khoán Việt Nam. Chương này cũng sẽ làm rõ ưu nhược điểm của từng mô hình và thảo luận về tính ứng dụng của chúng trong bối cảnh tài chính thực tế, đặc biệt trong việc dự báo giá cổ phiếu trong các điều kiện biến động.

4.1. Thống kê mô tả

Phần thống kê mô tả trong nghiên cứu này giúp cung cấp cái nhìn tổng quan về các đặc điểm cơ bản của dữ liệu giá cổ phiếu. Thống kê mô tả giúp chúng ta hiểu rõ hơn về sự phân phối, biến động và các đặc tính của giá cổ phiếu. Các chỉ số thống kê mô tả bao gồm trung bình (Mean), độ lệch chuẩn (Standard Deviation), min/max, các phân vị (Percentiles) như 25%, 50% (trung vị), và 75%, giúp nhận diện phân phối dữ liệu và các yếu tố ảnh hưởng đến sự thay đổi của giá cổ phiếu.

4.1.1. Mô tả dữ liệu

Để có cái nhìn toàn diện về đặc điểm dữ liệu trước khi áp dụng mô hình dự báo, nghiên cứu tiến hành phân tích thống kê mô tả tập dữ liệu giá đóng cửa của 11 cổ phiếu niêm yết trên sàn HOSE, thu thập từ tháng 01 năm 2020 đến tháng 03 năm 2025, tổng cộng có 13.791 quan sát. Quy mô và độ phủ dữ liệu như vậy đảm bảo độ tin cậy và tính đại diện cho các phân tích chuỗi thời gian.

Việc lựa chọn 11 công ty trong mẫu nghiên cứu dựa trên các tiêu chí chặt chẽ nhằm đảm bảo tính đại diện và chất lượng dữ liệu. Thứ nhất, tất cả doanh nghiệp đều niêm yết trên HOSE, có vốn hóa và thanh khoản cao, giúp đảm bảo dữ liệu giao dịch liên tục, hạn chế sai lệch do thiếu thông tin. Thứ hai, danh mục bao quát 11 nhóm ngành chủ chốt của nền kinh tế Việt Nam, từ công nghệ, tài chính, tiêu dùng,

năng lượng, công nghiệp đến bất động sản, cho phép đánh giá mô hình dự báo trên nhiều cấu trúc ngành khác nhau. Thứ ba, các mã cổ phiếu trong danh sách thể hiện mức độ biến động giá đa dạng: một số mã có giá trung bình cao và ổn định (FPT, MSN, VIC), trong khi một số khác biến động mạnh hoặc có giá thấp hơn (HPG, HVN, PVS), tạo điều kiện kiểm chứng khả năng thích ứng của mô hình trong nhiều điều kiện thị trường.

Bảng 4.1. Danh sách 11 công ty đại diện các nhóm ngành niêm yết trên HOSE

Nhóm ngành	Mã cổ phiếu	Công ty
Năng lượng	PVS	Tổng Công ty cổ phần Dịch vụ Kỹ thuật Dầu khí Việt Nam
Nguyên vật liệu	HPG	Công ty cổ phần Tập đoàn Hòa Phát
Công nghiệp	HVN	Tổng Công ty Hàng không Việt Nam - CTCP
Hàng tiêu dùng không thiết yếu	MWG	Công ty cổ phần Đầu tư Thế giới Di động
Hàng tiêu dùng thiết yếu	MSN	Công ty Cổ phần Tập đoàn MaSan
Chăm sóc sức khỏe	DBD	Công ty Cổ phần Dược - Trang thiết bị Y tế Bình Định
Tài chính	VCB	Ngân hàng TMCP Ngoại thương Việt Nam
Công nghệ thông tin	FPT	Công ty Cổ phần FPT
Dịch vụ viễn thông	CTR	Tổng Công ty Cổ phần Công trình Viettel
Dịch vụ tiện ích	REE	Công ty Cổ phần Cơ điện lạnh
Bất động sản	VIC	Tập đoàn Vingroup - Công ty Cổ phần

Nguồn: Tác giả tự tổng hợp

Cuối cùng, việc kết hợp cả yếu tố vốn hóa, ngành nghề và đặc điểm biến động giúp đảm bảo kết quả nghiên cứu có độ khái quát cao và ứng dụng thực tiễn rõ rệt. Điều này giúp nghiên cứu đánh giá hiệu quả của các mô hình dự báo trong các điều kiện thị trường khác nhau.

Bảng 4.2. Thống kê mô tả của toàn bộ dữ liệu

Count	Mean	Std	Min	25%	50%	75%	Max
13.791	45.046,358	23.116,556	6.703,78	25.550	42.114,64	60.469,99	116.890,35

Nguồn: Tác giả tự tổng hợp

Theo bảng 4.1 thống kê tổng thể, giá trung bình của toàn bộ dữ liệu là 45.046 VND, trong khi trung vị đạt 42.114 VND, cho thấy phân phối dữ liệu có xu hướng lệch phải. Sự chênh lệch này phản ánh rằng một số cổ phiếu có giá rất cao như VIC, MSN, FPT đã kéo giá trị trung bình tăng lên so với phần lớn các cổ phiếu còn lại. Phân tích histogram cũng xác nhận điều này, phần lớn giá cổ phiếu tập trung trong khoảng 20.000 – 60.000 VND, còn các mức giá trên 100.000 VND chỉ xuất hiện với tần suất rất thấp và nằm ở phần đuôi của phân phối. Đây là đặc điểm phân phối thường gặp trong dữ liệu tài chính, đặc biệt ở thị trường mới nổi, nơi cổ phiếu vốn hóa vừa và nhỏ chiếm ưu thế, trong khi cổ phiếu vốn hóa lớn chỉ chiếm thiểu số.

Bên cạnh đó, khoảng dao động giá cũng rất đáng kể, từ 6.703 VND đến 116.890 VND, phản ánh sự chênh lệch rõ rệt về quy mô và định giá giữa các doanh nghiệp niêm yết. Độ lệch chuẩn lên tới 23.116 VND tiếp tục khẳng định mức biến động cao trong tập dữ liệu, đồng thời cho thấy mỗi cổ phiếu có hành vi giá khác biệt. Dữ liệu cũng cho thấy 75% quan sát có giá dưới 60.469 VND, củng cố nhận định rằng phần lớn cổ phiếu nằm trong vùng giá thấp đến trung bình.

Từ những đặc điểm phân phối trên, có thể thấy rằng việc áp dụng một mô hình dự báo duy nhất cho toàn bộ dữ liệu sẽ không mang lại hiệu quả tối ưu. Thay vào đó, cần phân loại các cổ phiếu dựa trên đặc tính hành vi giá để lựa chọn mô hình phù hợp. ARIMA có thể thích hợp với các cổ phiếu ổn định, ít dao động, trong khi Prophet lại có thể phát huy hiệu quả đối với các cổ phiếu mang tính xu hướng hoặc ảnh hưởng bởi yếu tố mùa vụ và sự kiện.

Để làm rõ hơn sự phân hóa trong dữ liệu, bảng 4.2 dưới đây trình bày thống kê mô tả chi tiết cho từng mã cổ phiếu:

Bảng 4.3. Thống kê mô tả của các mã cổ phiếu

Stock Code	Mean	Min	Max	Std	Count
CTR	56.094,37	13.216,84	116.830,49	22.416,49	1.076
DBD	34.381,35	22.518,36	62.000,00	9.846,77	1.308
FPT	53.984,09	17.104,75	116.639,20	21.752,99	1.097
HPG	23.246,28	6.703,78	39.904,40	7.542,46	1.308
HVN	19.505,51	8.610,00	36.350,00	5.648,89	1.308
MSN	75.682,56	39.651,32	116.720,31	19.459,83	1.169
MWG	49.838,28	18.844,67	78.200,64	13.754,10	1.308
PVS	26.015,19	7.569,67	44.948,12	9.636,83	1.308
REE	45.981,33	16.978,16	75.000,00	15.145,03	1.308
VCB	48.800,43	24.877,56	67.300,00	9.595,24	1.308
VIC	68.911,30	39.900,00	116.890,35	22.201,13	1.293

Nguồn: Tác giả tự tổng hợp

Dữ liệu thống kê mô tả của bảng 4.2 của 11 cổ phiếu trong mẫu nghiên cứu cho thấy sự phân hóa rõ rệt về giá trị và mức độ biến động giữa các mã cổ phiếu. Cụ thể, Các cổ phiếu như MSN, FPT, VIC, và CTR có giá trung bình cao nhất, lần lượt đạt 75.682 VND, 53.984 VND, 68.911 VND, và 56.094 VND. Đây đều là các doanh nghiệp có quy mô vốn hóa lớn, thuộc các lĩnh vực tăng trưởng như bán lẻ, công nghệ, và bất động sản. Mức giá cao phản ánh niềm tin của thị trường vào tiềm năng phát triển dài hạn của các doanh nghiệp này. Ngược lại, các mã như HVN, HPG, và PVS có mức giá trung bình thấp hơn, dao động từ khoảng 19.500 VND đến 26.000 VND. Điều này một phần xuất phát từ đặc thù ngành nghề hoặc tác động bất lợi trong giai đoạn nghiên cứu. Ví dụ, HVN hoạt động trong lĩnh vực hàng không và chịu ảnh hưởng nghiêm trọng từ đại dịch COVID-19, trong khi PVS thuộc nhóm ngành dầu khí, vốn có tính chu kỳ cao và chịu tác động lớn từ biến động giá dầu thế giới.

Về mức độ biến động giá, FPT và CTR là hai cổ phiếu có độ lệch chuẩn cao nhất, lần lượt là 21.752 VND và 22.416 VND, phản ánh biên độ giao dịch lớn và khả năng tăng hoặc giảm mạnh trong các giai đoạn nhất định. Tương tự, VIC và

MSN cũng ghi nhận độ lệch chuẩn cao, tương ứng là 22.201 VND và 19.459 VND, cho thấy dù có mức giá trung bình cao, nhưng biến động xung quanh giá trị này cũng đáng kể, từ đó tạo ra nhiều cơ hội nhưng cũng tiềm ẩn rủi ro đối với các nhà đầu tư ngắn hạn. Ngược lại, các mã như VCB (9.595 VND), PVS (9.636 VND), và DBD (9.846 VND) có độ lệch chuẩn thấp hơn, thể hiện tính ổn định cao hơn trong biến động giá. Đặc biệt, VCB là cổ phiếu thuộc nhóm ngân hàng lớn, thường có diễn biến giá ổn định và phù hợp với các chiến lược đầu tư dài hạn hoặc áp dụng các mô hình dự báo tuyến tính như ARIMA. Bên cạnh đó, dữ liệu cũng cho thấy đa số các cổ phiếu đều có số quan sát bằng 1.308, ngoại trừ CTR (1.076), FPT (1.097), MSN (1.169) và VIC (1.293). Mặc dù có sự chênh lệch nhỏ về độ dài chuỗi thời gian, nhìn chung số lượng quan sát vẫn đủ lớn để đảm bảo độ tin cậy trong phân tích và cho phép so sánh hiệu quả giữa các mô hình dự báo.


Tóm lại, kết quả thống kê mô tả cho thấy sự đa dạng và phân hóa rõ rệt giữa các cổ phiếu trong mẫu nghiên cứu, không chỉ về mức giá trung bình mà cả về độ biến động. Những đặc điểm này đóng vai trò định hướng trong việc lựa chọn mô hình dự báo phù hợp với từng loại cổ phiếu ở các phần tiếp theo của nghiên cứu.

4.1.2. Biểu đồ phân phối giá cổ phiếu

Trong nghiên cứu dự báo giá cổ phiếu, việc phân tích sự phân phối của giá cổ phiếu giúp hiểu rõ hơn về mức độ biến động và tính ổn định của thị trường. Các biểu đồ như histogram và boxplot cung cấp cái nhìn trực quan về sự phân bố giá cổ phiếu, từ đó giúp nhận diện các giá trị ngoại lai và mức độ tập trung của dữ liệu. Dưới đây là các biểu đồ được trích xuất từ dữ liệu của nghiên cứu.

Đầu tiên, biểu đồ Histogram (hình 4.1) phân phối giá cổ phiếu cho thấy sự phân bố của giá đóng cửa cổ phiếu trong suốt khoảng thời gian nghiên cứu. Qua đó, chúng ta có thể thấy rằng phần lớn giá cổ phiếu nằm trong phạm vi từ 20.000 đến 40.000 VND, với một số ít giá trị cao hơn 100.000 VND. Điều này phản ánh sự tập trung của đa số cổ phiếu vào mức giá thấp và trung bình, nhưng cũng cho thấy sự tồn tại của các giá trị ngoại lai, tức là những cổ phiếu có giá trị cao vượt xa phần còn lại của thị trường. Sự phân bố không đối xứng này cho thấy sự biến động mạnh

mẽ trong giá cổ phiếu, mà trong nhiều trường hợp có thể gây khó khăn cho việc dự báo và phân tích.




Hình 4.1. Biểu đồ phân phối giá cổ phiếu

Nguồn: Tác giả tự tổng hợp

Tiếp theo, biểu đồ boxplot phân phối giá cổ phiếu trước khi xử lý ngoại lai (hình 4.2) bên trái cho thấy rõ ràng hơn về sự phân bố của dữ liệu. Trục giá của biểu đồ mở rộng từ khoảng 20.000 VND đến 80.000 VND, và một số giá trị ngoại lai xuất hiện vượt ra ngoài ngưỡng 120.000 VND. Các giá trị này có thể gây ra sự bất ổn trong việc phân tích dữ liệu vì chúng kéo dài khoảng cách giữa các phần tử trong tập dữ liệu, làm tăng độ dao động và có thể dẫn đến kết quả không chính xác nếu không được xử lý. Biểu đồ này minh họa rõ ràng tác động của các ngoại lai đối với sự phân bố dữ liệu, đồng thời cho thấy sự cần thiết phải xử lý chúng để đảm bảo tính ổn định trong các mô hình dự báo.

Sau khi xử lý các ngoại lai, biểu đồ (hình 4.2) phân phối giá cổ phiếu bên phải cho thấy đã có sự thay đổi rõ rệt. Các giá trị ngoại lai đã được loại bỏ, và giá cổ phiếu giờ đây chủ yếu tập trung trong khoảng từ 20.000 VND đến 60.000 VND, với sự thu hẹp rõ rệt của biên độ giá.



Hình 4.2. Biểu đồ Boxplot phân phối giá cổ phiếu trước, sau khi xử lý ngoại lai

Nguồn: Tác giả tự tổng hợp


Điều này giúp giảm thiểu sự biến động của dữ liệu và làm cho phân phối trở nên chặt chẽ và ổn định hơn. Sự ổn định này không chỉ cải thiện tính chính xác của các mô hình dự báo mà còn giúp tăng cường độ tin cậy trong việc phân tích các xu hướng giá cổ phiếu. Việc loại bỏ ngoại lai là một bước quan trọng trong việc làm sạch dữ liệu, giúp các mô hình dự báo có thể hoạt động hiệu quả hơn.

4.1.3. Biến động giá cổ phiếu giai đoạn 2020 – 2025

Để rõ ràng về biến động hơn, nghiên cứu sẽ cho thấy diễn biến giá cổ phiếu của 11 doanh nghiệp đại diện cho các ngành kinh tế chủ chốt trên thị trường chứng khoán Việt Nam, bao gồm: công nghệ thông tin (FPT), tài chính (VCB), bất động sản (VIC), công nghiệp (HVN), bán lẻ - hàng tiêu dùng không thiết yếu (MWG), năng lượng (PVS), dịch vụ viễn thông (CTR), chăm sóc sức khỏe (DBD), nguyên vật liệu (HPG), dịch vụ tiện ích (REE), và hàng tiêu dùng thiết yếu (MSN). Giai đoạn được phân tích kéo dài từ tháng 01 năm 2020 đến cuối tháng 3 năm 2025.

Vào đầu năm 2020, hầu hết các mã cổ phiếu đều ghi nhận sự sụt giảm mạnh về giá, chủ yếu do tác động tiêu cực từ đại dịch COVID-19. Đây là thời kỳ thị trường toàn cầu gặp phải khủng hoảng niềm tin, dẫn đến làn sóng bán tháo tài sản tài chính. Các ngành nhạy cảm với yếu tố vĩ mô, như hàng không (HVN), nguyên vật liệu (HPG), và bán lẻ (MWG) là những đối tượng bị ảnh hưởng mạnh nhất. Biểu đồ thể hiện rõ mức giảm sâu của giá cổ phiếu trong giai đoạn này. Tuy nhiên, từ

giữa năm 2020 đến cuối năm 2021, thị trường có dấu hiệu phục hồi nhờ vào các chính sách kích thích kinh tế và nỗ lực kiểm soát dịch bệnh của Chính phủ. Các cổ phiếu trong ngành công nghệ như FPT và hàng tiêu dùng thiết yếu như MSN đã có xu hướng tăng trưởng ổn định, phản ánh sự thích ứng linh hoạt của các doanh nghiệp trong bối cảnh chuyển đổi số và tiêu dùng trực tuyến bùng nổ. Ngoài ra, các mã cổ phiếu như VIC và CTR cũng ghi nhận mức tăng trưởng tích cực, cho thấy kỳ vọng cao của nhà đầu tư vào các lĩnh vực có tiềm năng phát triển trung và dài hạn.



Hình 4.3. Biến động giá cổ phiếu giai đoạn 2020 – 2025

Nguồn: Tác giả tự tổng hợp

Từ năm 2022 đến 2023, thị trường bước vào giai đoạn điều chỉnh dưới tác động của các chính sách tiền tệ thắt chặt, đặc biệt là xu hướng tăng lãi suất tại nhiều nền kinh tế lớn. Mặc dù cổ phiếu VCB giữ được sự ổn định tương đối, nhiều mã cổ phiếu khác ghi nhận mức biến động mạnh, đặc biệt là các doanh nghiệp trong ngành bất động sản và công nghiệp. Biểu đồ cho thấy sự phân hóa rõ nét giữa các cổ phiếu trong giai đoạn này, với những mã như VIC và PVS ghi nhận mức giảm mạnh trong khi các mã khác như VCB duy trì ổn định. Điều này phản ánh sự phân hóa trong kỳ vọng của nhà đầu tư về sự phục hồi của các ngành trong bối cảnh thắt chặt tiền tệ.

Bước sang năm 2024, biểu đồ ghi nhận một đợt tăng trưởng ngắn hạn ở một số mã cổ phiếu, điển hình như FPT và VIC. Tuy nhiên, mức tăng này không duy trì lâu dài và nhanh chóng bị điều chỉnh trở lại vào năm 2025, đẩy lên nghi ngại về sự

thiếu bền vững trong xu hướng tăng. Mặc dù các công ty như FPT ghi nhận mức tăng mạnh, nhưng sự điều chỉnh trở lại của các cổ phiếu khác cho thấy thị trường vẫn đang trong giai đoạn nhạy cảm và dễ bị tác động bởi kỳ vọng tâm lý và các thông tin vĩ mô ngắn hạn. Qua đó, thấy rằng sự nhạy cảm của thị trường chứng khoán Việt Nam trước các cú sốc kinh tế, chính sách điều hành và kỳ vọng của nhà đầu tư. Các chu kỳ tăng và giảm mạnh cho thấy tính chất phi tuyến và phức tạp của dữ liệu tài chính, điều này đặt ra yêu cầu cao về khả năng thích ứng của các mô hình dự báo. Do đó, việc so sánh hai mô hình Prophet và ARIMA trong dự báo giá cổ phiếu là rất quan trọng để đưa ra lựa chọn mô hình phù hợp nhất với bối cảnh thực tiễn tại Việt Nam.

4.2. Kết quả dự báo từ mô hình Prophet

Kết quả dự báo từ mô hình Prophet cho thấy sự khác biệt đáng kể giữa các mã cổ phiếu, phản ánh tính chất riêng biệt của từng chuỗi dữ liệu tài chính. Prophet được thiết kế với khả năng mô hình hóa xu hướng phi tuyến, yếu tố mùa vụ và điểm thay đổi xu hướng, nhờ đó thường phát huy hiệu quả với chuỗi có tính cấu trúc rõ ràng. Tuy nhiên, kết quả thực nghiệm cho thấy hiệu suất dự báo của mô hình này không đồng đều, phụ thuộc mạnh vào đặc điểm ổn định và độ nhiễu trong dữ liệu của từng mã cổ phiếu. Nghiên cứu đã áp dụng kỹ thuật cross-validation với 5 fold cho mỗi mã cổ phiếu, sau đó tính trung bình ba chỉ số đánh giá MAE, RMSE và MAPE để đảm bảo khách quan, giảm sai lệch do đặc thù từng thời điểm trong chuỗi thời gian.

Bảng 4.3 dưới đây cho thấy hiệu suất dự báo của mô hình Prophet trên 11 mã cổ phiếu, với sự chênh lệch rõ rệt giữa các mã. Về chỉ số MAPE, Prophet đạt kết quả tốt nhất ở các mã như DBD (8,498%) và VCB (8,736%), là những mã có xu hướng giá tương đối ổn định và cấu trúc dữ liệu rõ ràng. Ngược lại, sai số dự báo tăng mạnh ở các mã cổ phiếu khác như MWG (24,295%), HPG (22,801%), CTR (21,128%) và PVS (21,078%), phản ánh sự khó khăn của mô hình trong việc dự báo các chuỗi biến động mạnh, thiếu chu kỳ lặp lại hoặc có sự can thiệp của yếu tố bất ngờ.

Bảng 4.4. Kết quả các chỉ số đánh giá của mô hình Prophet

Mã cổ phiếu	Prophet MAE (VND)	Prophet RMSE (VND)	Prophet MAPE (%)
CTR	13.463,918	16.121,894	21,128
DBD	3.190,512	3.756,819	8,498
FPT	10.261,394	12.126,285	15,819
HPG	5.461,935	6.415,456	22,801
HVN	4.170,273	4.777,718	19,967
MSN	10.477,587	12.701,054	12,734
MWG	11.668,670	13.399,633	24,295
PVS	6.011,655	6.824,476	21,078
REE	9.711,214	11.002,332	18,018
VCB	4.429,935	5.192,782	8,736
VIC	8.472,718	10.919,555	12,309


Nguồn: Tác giả tự tổng hợp

Về chỉ số RMSE và MAE, xu hướng tương tự cũng được thể hiện. DBD và VCB có giá trị sai số tuyệt đối và sai số bình phương thấp nhất, trong khi CTR, MWG và MSN là những mã có sai số cao, phần lớn do giá cổ phiếu có biến động phức tạp, không đều, gây khó khăn cho mô hình trong việc xác định xu hướng. Đáng chú ý, dù HPG có MAE và RMSE ở mức trung bình, nhưng MAPE lại khá cao (22,801%), cho thấy sự không tương đồng giữa mức sai lệch tuyệt đối và sai lệch tương đối, đây là đặc điểm thường gặp trong các chuỗi có mức giá thấp và dao động mạnh theo phần trăm.

Để minh họa rõ hơn cho hiệu quả hoạt động của Prophet, hình 4.4 trình bày kết quả dự báo cho mã cổ phiếu VCB tại Fold 4, là một trong những fold thể hiện rõ năng lực của mô hình. Trong biểu đồ, đường dự báo trung tâm (yhat) bám khá sát với đường giá thực tế trong giai đoạn kiểm tra. Bên cạnh đó, vùng dự báo tin cậy (confidence interval) bao phủ gần như toàn bộ chuỗi quan sát, cho thấy mức độ ổn định và đáng tin cậy cao của mô hình trong ngữ cảnh cụ thể này. Đáng chú ý là Prophet không chỉ thể hiện khả năng dự đoán xu hướng tổng thể mà còn phản ánh được phần nào các đợt dao động nhẹ trong ngắn hạn, mặc dù mức độ phản ứng có

phần trễ và bị làm mượt bởi bản chất cấu trúc mô hình. Đây là kết quả phù hợp với đặc điểm của Prophet, vốn hoạt động hiệu quả hơn trên các chuỗi có xu hướng rõ ràng, ít nhiễu và cấu trúc lặp lại nhất định.

Bên cạnh đó, khoảng tin cậy mở rộng hợp lý ở những đoạn giá biến động mạnh cho thấy Prophet có cơ chế lượng hóa bất định phù hợp. Khác với một số mô hình tuyến tính truyền thống, Prophet không chỉ đưa ra một giá trị dự báo duy nhất mà còn cung cấp vùng biên độ tin cậy, giúp người phân tích hiểu rõ hơn về rủi ro dự báo và khả năng biến động. Cụ thể, khoảng tin cậy được Prophet ước lượng dựa trên phân phối xác suất của các thành phần trong mô hình, như xu hướng, mùa vụ và nhiễu. Khi khoảng này hẹp, mô hình có độ tin cậy cao, ngược lại, khi khoảng mở rộng, đó là dấu hiệu của sự bất định cao hoặc biến động lớn trong dữ liệu, là các thông tin đặc biệt quan trọng đối với nhà đầu tư và quản trị rủi ro.



Hình 4.4. Kết quả dự báo của mã cổ phiếu VCB (Fold 4)

Nguồn: Tác giả tự tổng hợp

Việc lựa chọn biểu đồ minh họa từ VCB Fold 4 không mang tính ngẫu nhiên. Trong quá trình thực hiện mô hình, các fold khác của VCB và nhiều mã cổ phiếu khác tạo ra các đường dự báo gần như phẳng hoặc sai lệch đáng kể. VCB Fold 4 là trường hợp hiếm hoi vừa có sai số thấp trên bảng số liệu, vừa có biểu đồ dự báo bám sát thực tế, thể hiện đầy đủ đặc trưng của mô hình Prophet. Đây cũng là lý do Fold này được chọn làm đại diện minh họa trong nghiên cứu. Mặc dù cổ phiếu VCB

được xếp vào nhóm chuỗi ổn định với độ lệch chuẩn thấp nhất trong toàn bộ mẫu nghiên cứu và chỉ số MAPE thấp nhất khi áp dụng mô hình Prophet (8,736%), kết quả từ Fold 4 vẫn cho thấy Prophet hoạt động hiệu quả. Điều này cho thấy rằng Prophet không chỉ phù hợp với các chuỗi có đặc điểm phi tuyến hoặc biến động mạnh, mà còn có khả năng dự báo chính xác với cả những chuỗi ổn định và ít nhiễu. Việc mô hình hóa tốt một chuỗi đơn giản như VCB cũng góp phần khẳng định tính linh hoạt và ổn định của Prophet trong nhiều bối cảnh thị trường khác nhau.

Tuy nhiên, cần lưu ý rằng Prophet không đảm bảo hiệu suất đồng đều trên toàn bộ các mã và tất cả các fold. Mỗi fold phản ánh một giai đoạn khác nhau của thị trường, có thể là thời điểm ổn định hoặc nhiều nhiễu loạn. Nếu giai đoạn kiểm tra chứa những thay đổi bất thường mà tập huấn luyện chưa từng gặp, Prophet sẽ khó phát hiện và phản ứng kịp thời, dẫn đến sai số tăng cao. Điều này lý giải vì sao một số fold của cùng một mã lại có kết quả rất khác nhau, cả về chỉ số sai số lẫn đường dự báo.


Qua đó, thấy rằng Prophet phát huy hiệu quả trong các chuỗi thời gian có xu hướng ổn định, biến động mượt và có cấu trúc rõ ràng. Ngược lại, với các chuỗi nhiều dao động bất thường hoặc thiếu quy luật, mô hình cần được điều chỉnh tham số hoặc kết hợp với các yếu tố ngoại sinh để cải thiện độ chính xác dự báo. Kết quả thực nghiệm từ Prophet cho thấy mô hình có tiềm năng ứng dụng trong lĩnh vực tài chính, đặc biệt trong bối cảnh các công cụ truyền thống gặp giới hạn với dữ liệu phi tuyến.

4.3. Kết quả dự báo từ mô hình ARIMA

Trong phần này, chúng tôi sẽ trình bày chi tiết quá trình dự báo giá cổ phiếu VCB thông qua mô hình ARIMA, từ bước kiểm tra tính dừng của chuỗi, phân tích các biểu đồ ACF và PACF, đến việc lựa chọn các tham số ARIMA phù hợp và đánh giá độ chính xác của mô hình.

Trước khi áp dụng mô hình ARIMA, một bước quan trọng là kiểm tra tính dừng của chuỗi dữ liệu. Điều này rất quan trọng vì mô hình ARIMA yêu cầu chuỗi

thời gian phải có tính ổn định về mặt thống kê, nghĩa là các đặc tính như trung bình và phương sai của chuỗi không thay đổi theo thời gian. Để kiểm tra tính dừng, nghiên cứu sử dụng kiểm định ADF, một phương pháp phổ biến trong phân tích chuỗi thời gian để tiến hành.




Hình 4.5. Kiểm tra tính dừng của mã cổ phiếu HPG (Fold 1)

Nguồn: Tác giả tự tổng hợp

Hình 4.5 với kết quả kiểm định ADF cho mã cổ phiếu HPG tại Fold 1 cho thấy giá trị ADF Statistic là 0,780 và p-value là 0,991. Vì giá trị p-value lớn hơn 0,05, chúng tôi không thể bác bỏ giả thuyết chuỗi không dừng, điều này có nghĩa là chuỗi dữ liệu của mã cổ phiếu HPG không ổn định và cần phải thực hiện sai phân để làm cho chuỗi trở nên dừng. Việc thực hiện sai phân bậc 1 ($d = 1$) giúp loại bỏ xu hướng và mùa vụ trong dữ liệu, từ đó giúp chuỗi dữ liệu trở nên ổn định và phù hợp với các bước tiếp theo trong mô hình ARIMA.

Sau khi thực hiện sai phân bậc 1 để làm cho chuỗi dữ liệu trở nên dừng, bước tiếp theo là phân tích các biểu đồ ACF và PACF để xác định các tham số AR (p) và MA (q) cho mô hình ARIMA.



Hình 4.6. Biểu đồ ACF và PACF của mã cổ phiếu HPG – Fold 1

Nguồn: Tác giả tự tổng hợp

Biểu đồ ACF cho thấy sự tự tương quan mạnh mẽ ở độ trễ 1, với các đỉnh tự tương quan kéo dài qua hầu hết các độ trễ. Điều này chỉ ra rằng chuỗi dữ liệu có sự phụ thuộc mạnh vào các giá trị quá khứ của nó, đặc biệt là sự tự tương quan mạnh mẽ tại độ trễ đầu tiên. Cụ thể, sự tự tương quan không giảm nhanh chóng về 0, mà kéo dài qua nhiều độ trễ, cho thấy chuỗi có yếu tố xu hướng mạnh mẽ. Biểu đồ này cho thấy rằng mô hình ARIMA cần điều chỉnh thông qua các tham số AR và I (sai phân) để loại bỏ sự phụ thuộc vào quá khứ và làm cho chuỗi trở nên ổn định hơn.

Bên cạnh đó, biểu đồ PACF cung cấp thông tin chi tiết về sự tự tương quan của chuỗi tại từng độ trễ cụ thể, sau khi loại bỏ ảnh hưởng của các độ trễ trung gian. Biểu đồ PACF cho thấy một sự đột biến rõ rệt tại độ trễ 1, sau đó giảm dần xuống gần 0 ở các độ trễ lớn hơn. Điều này chỉ ra rằng chuỗi có sự phụ thuộc mạnh vào giá trị quá khứ ngay tại độ trễ 1 (lag 1). Do đó, theo lý thuyết, tham số $p = 1$ (tức là tham số AR) là hợp lý cho mô hình ARIMA, vì giá trị quá khứ tại lag 1 có ảnh hưởng rõ rệt đến giá trị hiện tại của chuỗi.

```

Performing stepwise search to minimize aic
ARIMA(2,1,2)(0,0,0)[0] intercept : AIC=2993.678, Time=0.11 sec
ARIMA(0,1,0)(0,0,0)[0] intercept : AIC=2988.262, Time=0.01 sec
ARIMA(1,1,0)(0,0,0)[0] intercept : AIC=2988.802, Time=0.04 sec
ARIMA(0,1,1)(0,0,0)[0] intercept : AIC=2988.910, Time=0.06 sec
ARIMA(0,1,0)(0,0,0)[0] : AIC=2989.491, Time=0.01 sec
ARIMA(1,1,1)(0,0,0)[0] intercept : AIC=2989.629, Time=0.14 sec

Best model: ARIMA(0,1,0)(0,0,0)[0] intercept
Total fit time: 0.370 seconds
Tìm thấy mô hình ARIMA(0, 1, 0)

```

Hình 4.7. Kết quả lựa chọn tham số mô hình qua AutoARIMA

Nguồn: Tác giả tự tổng hợp

Dựa trên kết quả phân tích các biểu đồ ACF và PACF, mô hình ARIMA ban đầu được lựa chọn là ARIMA(1,1,0) cho cổ phiếu HPG, với tham số $p = 1$ (tự hồi quy tại độ trễ 1) và $d = 1$ (sai phân để chuỗi trở nên dừng). Tuy nhiên, khi áp dụng công cụ AutoARIMA để tối ưu hóa mô hình, kết quả cho thấy mô hình ARIMA tối ưu là ARIMA(0,1,0), với $p = 0$, $d = 1$, và $q = 0$. Sự khác biệt này xuất phát từ cách mà AutoARIMA tối ưu hóa mô hình, không chỉ dựa trên các biểu đồ ACF và PACF mà còn cân nhắc các yếu tố khác như AIC. AutoARIMA tìm kiếm mô hình có AIC

thấp nhất và điều này giúp lựa chọn mô hình đơn giản nhưng vẫn đạt được hiệu quả dự báo chính xác.

Dù biểu đồ PACF gợi ý rằng tham số $p = 1$ có thể hợp lý, AutoARIMA đã chọn mô hình ARIMA(0,1,0) vì mô hình này có giá trị AIC thấp nhất. Việc chọn mô hình này cho thấy rằng, mặc dù tham số AR (tự hồi quy) có thể có tác dụng đối với chuỗi, nhưng không cần thiết phải sử dụng tham số $p = 1$ trong mô hình ARIMA khi kết quả từ AutoARIMA chỉ ra rằng mô hình ARIMA(0,1,0) cho kết quả tối ưu với độ phức tạp thấp và độ chính xác cao. Quá trình tối ưu hóa của AutoARIMA giúp giảm độ phức tạp của mô hình mà vẫn duy trì được độ chính xác cao trong việc dự báo. Mặc dù các phân tích ACF và PACF có thể gợi ý tham số $p = 1$, nhưng việc chọn mô hình ARIMA đơn giản hơn là một chiến lược để tránh quá khớp dữ liệu và đạt được kết quả tối ưu trong việc dự báo giá cổ phiếu HPG.

Bảng 4.4 trình bày các tham số p , d , và q của mô hình ARIMA cho từng mã cổ phiếu. Phần lớn các mã trong bảng có tham số $d = 1$, điều này cho thấy chuỗi giá của các cổ phiếu cần phải thực hiện sai phân một lần để trở nên dừng, một đặc điểm phổ biến trong dữ liệu giá tài chính. Các chuỗi dữ liệu giá cổ phiếu thường có sự biến động lớn và không ổn định, do đó, việc sai phân giúp loại bỏ xu hướng và mùa vụ, làm cho chuỗi trở nên ổn định hơn, từ đó có thể áp dụng mô hình ARIMA hiệu quả.

Bảng 4.5. Bảng tham số ước lượng ARIMA(p,d,q) của các mã cổ phiếu

Mã cổ phiếu	ARIMA p	ARIMA d	ARIMA q
CTR	0	1	1
DBD	0	1	1
FPT	0	1	0
HPG	1	1	0
HVN	1	1	1
MSN	1	1	1
MWG	0	1	0
PVS	1	1	1
REE	2	1	2

VCB	0	1	0
VIC	0	1	0

Nguồn: Tác giả tự tổng hợp

Các tham số p và q lại khác nhau giữa các mã cổ phiếu, phản ánh mức độ phụ thuộc của giá cổ phiếu vào quá khứ và ảnh hưởng từ các sai số trước đó. Ví dụ, các mã cổ phiếu như VCB và VIC có $p = 0$ và $q = 0$, cho thấy chuỗi dữ liệu của những mã này có cấu trúc đơn giản, ít phụ thuộc vào các giá trị quá khứ và dễ dự báo. Ngược lại, REE có tham số $p = 2$ và $q = 2$, cho thấy chuỗi dữ liệu của mã này có sự phụ thuộc phức tạp vào nhiều yếu tố quá khứ và ảnh hưởng từ các sai số trước đó, điều này có thể do các yếu tố ngành nghề hoặc các sự kiện đặc biệt tác động đến dữ liệu. Việc lựa chọn chính xác tham số ARIMA giúp mô hình phù hợp với đặc tính của từng chuỗi dữ liệu, nâng cao hiệu quả dự báo. Các mã cổ phiếu có tham số đơn giản như VCB và VIC thường cho kết quả dự báo ổn định và chính xác, vì chuỗi của chúng ít bị ảnh hưởng bởi các yếu tố quá khứ. Trong khi đó, các mã như REE có tham số phức tạp hơn, cần mô hình với tham số cao hơn để phản ánh chính xác sự biến động dài hạn và ảnh hưởng từ các yếu tố đặc thù.

Bảng tham số ARIMA không chỉ giúp xác định mô hình phù hợp cho từng mã cổ phiếu, mà còn làm rõ sự khác biệt trong hiệu suất dự báo giữa các mã. Nó giải thích lý do tại sao các tham số ARIMA khác nhau sẽ ảnh hưởng đến hiệu quả dự báo, đồng thời giúp minh bạch kết quả nghiên cứu và làm cơ sở cho các phân tích, đề xuất trong báo cáo.

Để hiểu rõ hơn về hiệu quả của mô hình ARIMA đối với các mã cổ phiếu khác nhau, ta cần xem xét các chỉ số đánh giá như MAE, RMSE và MAPE, nhằm phân tích độ chính xác của dự báo cho từng cổ phiếu.

Bảng 4.5 trình bày các giá trị trung bình của các chỉ số của mô hình ARIMA cho từng mã cổ phiếu. Có thể nhận thấy rằng hiệu quả dự báo của mô hình thay đổi đáng kể tùy thuộc vào đặc điểm của từng mã cổ phiếu, cho thấy những đặc điểm tương tự Prophet, nhưng với mức độ ổn định khác nhau tùy theo mã cổ phiếu. Cụ thể, MAE cho thấy sự sai lệch trung bình giữa giá trị thực tế và giá trị dự báo,

RMSE phản ánh sai lệch bình quân giữa các giá trị dự báo và thực tế, còn MAPE cung cấp sai số tỷ lệ phần trăm, cho phép đánh giá mức độ chính xác của mô hình dưới dạng phần trăm.

Kết quả phân tích trong bảng 4.5 cho thấy mô hình ARIMA đạt hiệu quả dự báo khác nhau tùy theo đặc điểm biến động của từng mã cổ phiếu. Nhìn chung, ARIMA hoạt động hiệu quả hơn với các cổ phiếu có xu hướng ổn định và ít nhiễu, trong khi mô hình này gặp khó khăn với các chuỗi có biến động mạnh hoặc chứa yếu tố phi tuyến và mùa vụ. Cụ thể, các cổ phiếu như VCB và DBD có kết quả dự báo tốt nhất với các chỉ số lỗi rất thấp. VCB đạt $MAE = 3.593$, $RMSE = 4.278$, và $MAPE = 7,261\%$, thấp nhất trong số các mã được nghiên cứu, cho thấy khả năng dự báo ổn định và chính xác của ARIMA đối với các chuỗi giá ít biến động.

Bảng 4.6. Kết quả các chỉ số đánh giá của mô hình ARIMA

Mã cổ phiếu	ARIMA MAE (VND)	ARIMA RMSE (VND)	ARIMA MAPE (%)
CTR	14.836,574	17.314,763	23,842
DBD	3.825,089	4.869,562	9,371
FPT	7.513,544	9.701,384	13,503
HPG	5.897,813	6.986,957	23,818
HVN	3.302,324	4.133,275	19,196
MSN	11.306,206	14.175,938	14,129
MWG	8.551,196	10.127,430	17,556
PVS	5.031,674	5.833,332	17,924
REE	11.281,531	13.339,102	26,923
VCB	3.593,448	4.278,421	7,261
VIC	7.735,753	8.980,400	12,728

Nguồn: Tác giả tự tổng hợp

Tương tự, DBD cũng có MAPE chỉ ở mức 9,371%, phản ánh mức sai số chấp nhận được trong thực tế. Ngược lại, các mã như CTR, REE, MWG và HPG lại cho thấy mô hình ARIMA gặp hạn chế. Trong đó, REE có MAPE cao nhất là 26,923%, cho thấy độ sai lệch lớn giữa giá dự báo và giá thực tế. Điều này có thể xuất phát từ đặc điểm phi tuyến, tính mùa vụ hoặc biến động ngắn hạn mạnh, vốn

không phải là điểm mạnh của ARIMA. CTR và HPG cũng lần lượt có MAPE lên đến 23,842% và 23,818%, xác nhận rằng với các cổ phiếu có sự dao động cao, mô hình ARIMA không duy trì được độ chính xác mong muốn. Một số cổ phiếu như MSN, MWG và PVS có kết quả trung bình, với MAPE dao động từ 14 – 18%, phản ánh rằng mô hình vẫn có thể hoạt động hiệu quả ở mức tương đối, nhất là trong điều kiện thị trường không có nhiều cú sốc bất ngờ.

Đặc biệt, trường hợp của HPG cho thấy một điểm thú vị. Mặc dù MAPE tương đối cao (23,818%), song MAE và RMSE lại ở mức thấp (lần lượt là 5.897 và 6.986). Điều này có thể được lý giải bởi đặc điểm cấu trúc giá cổ phiếu có những thời điểm dao động lớn, làm tăng tỷ lệ MAPE, trong khi tổng thể xu hướng vẫn được mô hình mô phỏng khá sát, là một hạn chế vốn có của chỉ số MAPE khi đối chiếu với các cổ phiếu có giá trị thấp trong một số giai đoạn.

Nhìn tổng thể, ARIMA phù hợp hơn với các chuỗi thời gian tuyến tính, ít biến động hoặc có xu hướng ổn định theo thời gian. Các cổ phiếu như VCB, DBD, HVN và một phần FPT là ví dụ điển hình cho mức độ phù hợp này. Trong khi đó, với các mã chịu tác động mạnh từ yếu tố mùa vụ, xu hướng phi tuyến hoặc nhiễu cao, như REE, CTR, MWG, việc áp dụng ARIMA có thể dẫn đến sai số lớn hơn, từ đó ảnh hưởng đến chất lượng dự báo. Đây cũng là một trong những lý do khiến các mô hình như Prophet, vốn được thiết kế để xử lý dữ liệu có đặc điểm phi tuyến và yếu tố mùa vụ thường được cân nhắc như một giải pháp thay thế hiệu quả trong các nghiên cứu tương tự.


4.4. So sánh hiệu quả hai mô hình

4.4.1. Kết quả dự báo

Trong phần này, nghiên cứu tiến hành so sánh hiệu quả dự báo giữa hai mô hình chuỗi thời gian Prophet và ARIMA thông qua các chỉ số sai số gồm RMSE, MAE và MAPE. Mục tiêu là xác định mô hình nào mang lại kết quả dự báo chính xác hơn cho từng mã cổ phiếu cụ thể. Mặc dù cả hai mô hình đều có những điểm mạnh riêng, ARIMA thường được đánh giá phù hợp với chuỗi dữ liệu ổn định và có

tính dừng, trong khi Prophet tỏ ra linh hoạt hơn trong việc xử lý các chuỗi có xu hướng phi tuyến, yếu tố mùa vụ hoặc biến động bất ngờ.

Biểu đồ trong hình 4.8 so sánh RMSE giữa hai mô hình Prophet và ARIMA, cho thấy sự khác biệt rõ rệt về hiệu quả dự báo đối với từng mã cổ phiếu. Cụ thể, Prophet cho thấy hiệu quả dự báo tốt hơn trên 5 mã cổ phiếu, bao gồm CTR, DBD, MSN, REE và HVN. Tại mã CTR, Prophet đạt RMSE ở mức 16.122 VND, thấp hơn ARIMA khoảng 1.193 VND, tương ứng mức chênh lệch gần 7%, cho thấy sai số có phần nhỉnh hơn nhưng không quá khác biệt. Đối với DBD, Prophet cho kết quả tốt hơn rõ rệt khi sai số giảm 1.113 VND, tương ứng mức cải thiện hơn 22%, một sự chênh lệch đáng kể. Với chuỗi giá cổ phiếu MSN, Prophet cũng thể hiện mức sai số thấp hơn khoảng 1.475 VND (tương đương 10,4%), cho thấy sự khác biệt tương đối rõ. Mã REE ghi nhận mức RMSE = 11.002 từ Prophet thấp hơn khoảng 2.337 VND, tức giảm gần 17,5%, thể hiện chênh lệch rõ rệt. Riêng với HVN, Prophet có sai số thấp hơn khoảng 644 VND, tương ứng mức cải thiện 13,5%, tuy không lớn nhưng vẫn cho thấy một sự khác biệt nhất định về độ chính xác.



Hình 4.8. Biểu đồ so sánh RMSE giữa Prophet và ARIMA của các mã cổ phiếu

Nguồn: Tác giả tự tổng hợp

Ngược lại, 6 mã cổ phiếu còn lại gồm FPT, MWG, VIC, PVS, VCB và HPG cho thấy ARIMA hoạt động hiệu quả hơn. Tại FPT, mô hình ARIMA dự báo với RMSE thấp hơn gần 2.425 VND (tương đương 20%), cho thấy sự chênh lệch rõ ràng. Đặc biệt tại MWG, Prophet có RMSE cao hơn ARIMA tới 3.272 VND, tương ứng mức khác biệt lên đến 32,3%, cho thấy hiệu suất dự báo giữa hai mô hình khác biệt một cách đáng kể. Với chuỗi giá cổ phiếu VIC, Prophet ghi nhận sai số cao hơn 1.939 VND, tức khoảng 21,6%, một khoảng cách đáng lưu ý. Đối với ba mã còn lại gồm HPG, PVS và VCB, Prophet cũng có sai số cao hơn ARIMA nhưng chênh lệch ở mức vừa phải, lần lượt là 572 VND (8,2%), 991 VND (14,5%) và 914 VND (17,6%). Trong đó, chỉ VCB có mức chênh lệch gần với ngưỡng đáng kể, còn lại là các sai số không quá lớn.

Tổng quan cho thấy Prophet cho kết quả tốt hơn tại 5 mã cổ phiếu, trong khi ARIMA vượt trội hơn tại 6 mã còn lại. Điều này phản ánh rằng không có mô hình nào chiếm ưu thế tuyệt đối trong mọi trường hợp. Hiệu quả dự báo bị chi phối bởi đặc điểm nội tại của từng chuỗi thời gian, chẳng hạn như cường độ biến động, tính tuyến tính hay sự tồn tại của các yếu tố mùa vụ. Do đó, trong thực tiễn, việc lựa chọn mô hình nên dựa trên đặc điểm cụ thể của chuỗi dữ liệu, thay vì áp dụng một phương pháp cố định. Cách tiếp cận linh hoạt không chỉ giúp nâng cao độ chính xác trong dự báo, mà còn đảm bảo kết quả phân tích có cơ sở và độ tin cậy cao hơn trong bối cảnh thị trường tài chính biến động như tại Việt Nam.

Bảng 4.7. Kết quả các chỉ số đánh giá của hai mô hình Prophet và ARIMA

Mô hình	RMSE	MAE	MAPE (%)
Prophet	9.385,273	7.938,165	16,853%
ARIMA	9.067,324	7.534,105	16,932%


Nguồn: Tác giả tự tổng hợp

Bảng 4.6 trình bày kết quả tổng hợp ba chỉ số đánh giá của hai mô hình Prophet và ARIMA. Các chỉ số này được tính toán trung bình trên toàn bộ 11 mã cổ phiếu trong mẫu nghiên cứu, nhằm phản ánh hiệu suất tổng thể của mỗi mô hình dự báo trong toàn bộ tập dữ liệu.

Kết quả cho thấy, mô hình ARIMA đạt giá trị RMSE trung bình là 9.067 VND, thấp hơn so với mức 9.385 VND của Prophet. Mức chênh lệch khoảng 318 VND, tương ứng với tỷ lệ giảm gần 3,4%, cho thấy ARIMA có xu hướng dự báo gần hơn với giá trị thực tế tại các điểm sai số lớn, do RMSE nhấn mạnh vào các sai lệch nghiêm trọng thông qua bình phương hóa sai số. Điều này phần nào phản ánh hiệu quả của ARIMA trong việc xử lý các chuỗi có biến động mạnh hoặc nhiễu dữ liệu cao. Tương tự, chỉ số MAE trung bình của ARIMA cũng thấp hơn Prophet, lần lượt là 7.534 VND và 7.938 VND. Mức chênh lệch khoảng 404 VND, tương ứng 5,1%, cho thấy tính trung bình, các dự báo từ ARIMA có sai số tuyệt đối nhỏ hơn Prophet, phản ánh sự ổn định trong dự báo theo chiều ngang.

Ngược lại, nếu xét đến MAPE – chỉ số phản ánh mức sai số theo tỷ lệ phần trăm, Prophet lại có ưu thế nhẹ với giá trị trung bình là 16,853%, thấp hơn một chút so với 16,932% của ARIMA. Mặc dù chênh lệch này chỉ khoảng 0,079 điểm phần trăm, nhưng vẫn phần nào cho thấy Prophet có khả năng duy trì mức sai lệch tương đối thấp hơn trong các chuỗi có quy mô giá nhỏ hoặc biến động nhẹ.

Tổng hợp ba chỉ số cho thấy, ARIMA có xu hướng hoạt động tốt hơn về sai số tuyệt đối trên toàn tập dữ liệu, trong khi Prophet lại nhỉnh hơn đôi chút về sai số tương đối. Tuy nhiên, mức chênh lệch giữa hai mô hình nhìn chung là không lớn, cho thấy không có mô hình nào thể hiện sự vượt trội tuyệt đối. Việc lựa chọn mô hình phù hợp nên được cân nhắc dựa trên mục tiêu phân tích cụ thể: nếu mục tiêu là giảm thiểu sai số tuyệt đối, ARIMA là lựa chọn hợp lý, trong khi đó, nếu ưu tiên là duy trì độ chính xác tương đối ổn định, Prophet có thể là phương án thay thế phù hợp hơn.




Hình 4.9. Biểu đồ so sánh chỉ số MAE và RMSE giữa Prophet và ARIMA

Nguồn: Tác giả tự tổng hợp

Biểu đồ tại hình 4.9 trực quan hóa sự so sánh giữa hai mô hình Prophet và ARIMA dựa trên hai chỉ số RMSE và MAE trung bình của toàn bộ mã cổ phiếu được nghiên cứu. Dữ liệu sử dụng trong biểu đồ được tổng hợp từ bảng 4.6 nhằm giúp làm nổi bật sự khác biệt giữa các mô hình dưới góc nhìn trực quan. Kết quả cho thấy, mô hình ARIMA có giá trị MAE và RMSE đều thấp hơn Prophet.

Cụ thể, với chỉ số MAE, Prophet ghi nhận mức sai số trung bình là 7.938 VND, trong khi ARIMA chỉ ở mức 7.534 VND, tức thấp hơn 404 VND. Mức chênh lệch này tương ứng với khoảng 5,1%, cho thấy ARIMA dự báo chính xác hơn một cách tương đối về mặt sai số tuyệt đối. Đối với chỉ số RMSE, Prophet đạt mức

9.385 VND, trong khi ARIMA thấp hơn với 9.067 VND, tức chênh lệch 318 VND (khoảng 3,4%). Vì RMSE nhấn mạnh đến các sai số lớn, kết quả này cũng gợi ý rằng ARIMA có phần kiểm soát tốt hơn đối với các sai số cực trị. Mặc dù mức chênh lệch giữa hai mô hình là rõ ràng về mặt thứ bậc (ARIMA thấp hơn ở cả hai chỉ số), nhưng xét về giá trị tuyệt đối, sự khác biệt vẫn chưa thật sự đáng kể trong bối cảnh giá cổ phiếu dao động ở mức vài chục nghìn đến hàng trăm nghìn VND. Do đó, biểu đồ này tiếp tục củng cố nhận định trước đó rằng không có mô hình nào vượt trội một cách tuyệt đối, và hiệu quả dự báo của từng mô hình cần được đánh giá trong mối tương quan với đặc điểm dữ liệu cụ thể, cũng như mục tiêu phân tích mà nhà nghiên cứu hoặc nhà đầu tư đặt ra.



Hình 4.10. Biểu đồ so sánh chỉ số MAPE giữa Prophet và ARIMA

Nguồn: Tác giả tự tổng hợp

Biểu đồ hình 4.10 thể hiện sự so sánh giữa hai mô hình Prophet và ARIMA dựa trên chỉ số MAPE trung bình, đo lường mức độ sai lệch tuyệt đối theo tỷ lệ phần trăm giữa giá trị dự báo và giá trị thực tế. MAPE là một trong những chỉ số quan trọng phản ánh tính ổn định của mô hình dự báo trong nhiều bối cảnh, đặc biệt hữu ích khi dữ liệu có quy mô khác nhau hoặc giá trị tuyệt đối nhỏ.


Kết quả cho thấy Prophet ghi nhận MAPE trung bình là 16,853%, thấp hơn nhẹ so với mức 16,932% của ARIMA. Mức chênh lệch 0,079 điểm phần trăm là rất nhỏ và có thể coi là không đáng kể về mặt thực tiễn. Tuy nhiên, về mặt kỹ thuật,

Prophet vẫn cho thấy một lợi thế nhẹ trong việc duy trì độ chính xác tương đối, đặc biệt trong những trường hợp các cổ phiếu có giá trị tuyệt đối thấp, nơi chỉ cần một sai lệch nhỏ về giá trị cũng có thể gây ra tỷ lệ sai số lớn.

Sự chênh lệch này một lần nữa củng cố kết luận rằng hai mô hình có hiệu suất tương đối cân bằng, và không có mô hình nào thể hiện sự vượt trội rõ rệt trên cả ba chỉ số đánh giá. Trong khi ARIMA tỏ ra hiệu quả hơn về độ chính xác tuyệt đối (qua RMSE và MAE), Prophet lại có ưu thế nhẹ về tỷ lệ sai số tương đối (MAPE), mặc dù sự khác biệt này là rất hạn chế.

Để minh họa cụ thể cho sự khác biệt trong khả năng dự báo giữa hai mô hình, hình 4.11 trình bày trực quan kết quả dự báo giá cổ phiếu HPG từ Prophet và ARIMA tại Fold 1. Trên biểu đồ, đường xanh đứt nét thể hiện dữ liệu huấn luyện (train data), đường xanh lá đứt nét thể hiện dữ liệu kiểm tra (test data), trong khi đường cam và đỏ lần lượt là dự báo từ Prophet và ARIMA.

Quan sát biểu đồ cho thấy, Prophet mô phỏng đường giá theo xu hướng lên và xuống một cách tương đối mềm mại và có chu kỳ hơn so với ARIMA. Mô hình Prophet bắt được phần nào biến động phức tạp trong đoạn dữ liệu test từ cuối năm 2020 đến giữa năm 2021, tuy chưa hoàn toàn chính xác về biên độ.



Hình 4.11. Biểu đồ so sánh dự báo Prophet và ARIMA của mã HPG – Fold 1

Nguồn: Tác giả tự tổng hợp

Ngược lại, đường dự báo của ARIMA có xu hướng tuyến tính hơn, thể hiện rõ qua độ dốc đều và không phản ánh được tính dao động mạnh mẽ của giá cổ phiếu HPG trong giai đoạn kiểm tra. Điều này dẫn đến sai lệch lớn giữa đường dự báo ARIMA và giá trị thực tế khi giá cổ phiếu tăng vọt trong giai đoạn đầu năm 2021. Sự khác biệt về hình dạng dự báo giữa hai mô hình phù hợp với bản chất kỹ thuật: Prophet được thiết kế để xử lý dữ liệu có tính chất mùa vụ, phi tuyến và biến động theo chu kỳ, trong khi ARIMA tỏ ra hiệu quả hơn trong các chuỗi có tính ổn định hoặc tuyến tính. Đây cũng là lý do vì sao Prophet cho sai số thấp hơn ARIMA ở mã cổ phiếu HPG, như đã được thể hiện trong phân tích chỉ số RMSE và MAE trước đó.

Nhìn chung, biểu đồ cho thấy Prophet có khả năng thích nghi tốt hơn với các chuỗi dữ liệu có nhiều biến động phi tuyến như HPG, trong khi ARIMA tỏ ra kém linh hoạt khi mô hình hóa các giai đoạn chuyển biến mạnh của thị trường. Biểu đồ này góp phần minh chứng cho lập luận rằng hiệu quả mô hình phụ thuộc vào đặc trưng cụ thể của từng chuỗi thời gian, thay vì áp dụng một mô hình duy nhất cho toàn bộ dữ liệu.

4.4.2. Kết quả kiểm định Ljung – Box và Diebold – Mariano

Nhằm đánh giá tính ngẫu nhiên trong phần dư và so sánh độ chính xác giữa hai mô hình dự báo Prophet và ARIMA, nghiên cứu tiến hành hai kiểm định thống kê phổ biến: Ljung – Box và Diebold – Mariano (DM). Đây là hai công cụ hỗ trợ đánh giá định lượng quan trọng, giúp xác nhận mức độ phù hợp và hiệu quả của mô hình dự báo trong thực tiễn.

Mã cổ phiếu	DM Statistic	DM p-value
CTR	24,9507	0,0000
DBD	3,1113	0,0019
FPT	-22,6465	0,0000
HPG	-18,1364	0,0000

Mã cổ phiếu	DM Statistic	DM p-value
HVN	3,3516	0,0008
MSN	8,3392	0,0000
MWG	-16,2048	0,0000
PVS	-16,8111	0,0000
REE	-2,2018	0,0277
VCB	4,0638	0,0000
VIC	-3,1237	0,0018

Ljung-Box Prophet p-value (lag=10): 0.0000
 Ljung-Box ARIMA p-value (lag=10): 0.0000

Hình 4.12. Kết quả kiểm định Ljung – Box của mã cổ phiếu HPG (Fold 1) và Diebold – Mariano của tất cả mã cổ phiếu

Nguồn: Tác giả tự tổng hợp

Trước tiên, kiểm định Ljung – Box được áp dụng nhằm kiểm tra giả thuyết không có tự tương quan trong phần dư của hai mô hình. Kết quả kiểm định tại độ trễ (lag = 10) được trình bày trong hình 4.12 cho thấy p-value của cả hai mô hình đều bằng 0,0000. Vì giá trị p đều nhỏ hơn mức ý nghĩa 0,05, có thể bác bỏ giả thuyết H_0 và kết luận rằng phần dư vẫn tồn tại tự tương quan. Điều này đồng nghĩa với việc chuỗi dữ liệu không hoàn toàn ngẫu nhiên, một đặc điểm điển hình trong dữ liệu tài chính, nơi mà các quan sát hiện tại thường chịu ảnh hưởng từ các giá trị trong quá khứ. Kết quả này cũng cho thấy rằng các mô hình dự báo cần có khả năng xử lý được tính phụ thuộc theo thời gian nhằm đạt độ chính xác cao hơn trong thực tế.

Tiếp theo, kiểm định Diebold–Mariano được sử dụng để so sánh sai số dự báo của hai mô hình Prophet và ARIMA trên cùng một chuỗi dữ liệu. Nghiên cứu đã thực hiện kiểm định DM cho toàn bộ 11 mã cổ phiếu trong mẫu, sử dụng sai số dự báo tại tập kiểm tra. Kết quả cho thấy có sự khác biệt có ý nghĩa thống kê (p-value < 0,05) về hiệu quả dự báo giữa hai mô hình đối với tất cả các mã cổ phiếu được phân tích.

Cụ thể, Prophet thể hiện hiệu quả vượt trội hơn tại 5 mã cổ phiếu, bao gồm CTR ($p = 0,0000$), DBD ($p = 0,0019$), HVN ($p = 0,0008$), MSN ($p = 0,0000$) và VCB ($p = 0,0000$). Trong các trường hợp này, giá trị thống kê DM dương và p-value nhỏ cho thấy Prophet có sai số dự báo thấp hơn ARIMA một cách đáng kể. Ngược lại, ARIMA lại cho kết quả chính xác hơn tại 6 mã cổ phiếu còn lại là FPT, HPG, MWG, PVS, REE và VIC. Các mã này đều có thống kê DM âm với p-value nhỏ hơn 0,05, cho thấy sự khác biệt có ý nghĩa thống kê nghiêng về phía ARIMA.

Tóm lại, cả hai kiểm định thống kê đều cho thấy sự khác biệt đáng kể giữa hai mô hình Prophet và ARIMA về khả năng dự báo giá cổ phiếu. Kết quả kiểm định Ljung – Box xác nhận sự tồn tại tự tương quan trong dữ liệu, làm nổi bật tính cần thiết của các mô hình chuỗi thời gian. Trong khi đó, kiểm định Diebold – Mariano khẳng định rằng không có mô hình nào vượt trội tuyệt đối trong mọi hoàn cảnh – việc lựa chọn mô hình cần dựa trên đặc điểm cụ thể của từng chuỗi dữ liệu và mục tiêu ứng dụng. Những phân tích này đóng vai trò quan trọng trong việc tối ưu hóa chiến lược dự báo và hỗ trợ ra quyết định trong lĩnh vực tài chính.

4.5. Thảo luận và liên hệ thực tiễn

Kết quả nghiên cứu đã chỉ ra sự khác biệt rõ rệt giữa hai mô hình Prophet và ARIMA trong việc dự báo giá cổ phiếu của các công ty niêm yết trên sàn HOSE. Việc so sánh hiệu quả của hai mô hình này thông qua các chỉ số sai số RMSE, MAE, và MAPE cho thấy rằng mỗi mô hình có những ưu điểm riêng và phù hợp với các loại dữ liệu khác nhau. Cụ thể, ARIMA hoạt động hiệu quả hơn với các chuỗi thời gian ổn định, ít biến động, trong khi Prophet lại tỏ ra vượt trội khi xử lý các chuỗi dữ liệu có tính phi tuyến hoặc bị tác động bởi các yếu tố mùa vụ và ngoại lai.

Trong quá trình phân tích, HPG (Fold 1) và VCB (Fold 4) đã được chọn làm ví dụ tiêu biểu để minh họa cho kết quả của hai mô hình. HPG (Fold 1) đại diện cho một chuỗi thời gian ngắn hạn, có tính ổn định và ít biến động, nơi mà mô hình ARIMA thể hiện hiệu quả vượt trội. Biểu đồ dự báo cho thấy ARIMA đã nắm bắt chính xác xu hướng giá cổ phiếu trong giai đoạn ngắn, phản ánh tính phù hợp của

mô hình trong các chuỗi dữ liệu ổn định. Tuy nhiên, khi xét đến các kết quả dự báo của các fold khác và các mã cổ phiếu khác, đặc biệt là với ARIMA, biểu đồ cho thấy hầu hết các kết quả dự báo đều chỉ thể hiện một đường thẳng, không thể phản ánh được sự biến động thực tế của giá cổ phiếu. Điều này là do ARIMA chỉ có thể dự báo chính xác khi dữ liệu có tính ổn định và xu hướng rõ ràng, nhưng lại gặp khó khăn khi chuỗi thời gian có sự thay đổi đột ngột hoặc yếu tố mùa vụ tác động mạnh mẽ. Các fold còn lại cũng như của các mã khác thể hiện rõ sự hạn chế của ARIMA, khi mô hình này chỉ cho một đường thẳng hoặc không phản ánh được sự thay đổi trong xu hướng giá cổ phiếu.

Ngược lại, VCB (Fold 4) đại diện cho một chuỗi thời gian dài hơn, nơi mà Prophet lại thể hiện sự vượt trội. Prophet có khả năng mô hình hóa xu hướng phi tuyến và các yếu tố mùa vụ, giúp dự báo chính xác hơn trong trường hợp của VCB. Mặc dù VCB có ít biến động, nhưng sự linh hoạt của Prophet trong việc mô hình hóa xu hướng dài hạn và các yếu tố ngoại lai đã giúp mô hình này có hiệu quả hơn so với ARIMA, đặc biệt là khi xét đến dữ liệu dài hạn và tác động từ các yếu tố vĩ mô. Một điểm đặc biệt cần lưu ý là Prophet tại VCB (Fold 4) không chỉ thể hiện sự linh hoạt trong việc mô hình hóa xu hướng dài hạn mà còn có kết quả dự báo rất sát với giá trị thực tế, không có sự chênh lệch nhiều như các fold và mã khác. Điều này thể hiện rõ trong biểu đồ minh họa, khi đường dự báo trung tâm của Prophet khá khớp với xu hướng giá thực tế, và khoảng tin cậy bao phủ gần như toàn bộ chuỗi quan sát. Sự chính xác của Prophet trong VCB (Fold 4) được lý giải bởi khả năng mô hình hóa các yếu tố phi tuyến và xu hướng dài hạn mà ARIMA khó có thể bắt được. Mặc dù VCB có ít biến động trong thời gian ngắn, nhưng trong dài hạn, Prophet đã phản ánh chính xác hơn các thay đổi nhẹ trong giá trị cổ phiếu, giúp mô hình có kết quả dự báo sát với thực tế.

Các kết quả từ chỉ số đánh giá cũng cho thấy ARIMA hoạt động hiệu quả hơn với các cổ phiếu có sự ổn định cao và ít biến động, với các sai số thấp hơn so với Prophet. Ngược lại, Prophet lại tỏ ra hiệu quả hơn trong việc bắt được xu hướng và thay đổi đột ngột của giá cổ phiếu. Điều này cho thấy rằng không có mô hình

nào hoàn toàn vượt trội trong tất cả các trường hợp, và việc lựa chọn mô hình dự báo phù hợp cần phải dựa trên đặc điểm của từng mã cổ phiếu và tính chất của dữ liệu. Mặc dù ARIMA cho kết quả chính xác hơn trong ngắn hạn và đối với các chuỗi dữ liệu ổn định, nhưng Prophet lại thể hiện ưu thế vượt trội khi xử lý các chuỗi thời gian dài hạn hoặc có sự thay đổi mạnh.

Tổng kết lại, mặc dù ARIMA thể hiện hiệu quả trong việc dự báo các chuỗi dữ liệu ổn định và có ít biến động, Prophet lại tỏ ra vượt trội trong các chuỗi dữ liệu có tính phi tuyến, yếu tố mùa vụ và sự biến động mạnh. Các kiểm định thống kê cho thấy sự khác biệt giữa hai mô hình, nhưng cũng chỉ ra rằng không có mô hình nào hoàn toàn phù hợp với mọi trường hợp. Việc lựa chọn mô hình dự báo phụ thuộc vào đặc điểm của từng chuỗi dữ liệu và điều kiện thị trường, và cần được điều chỉnh linh hoạt để tối ưu hóa độ chính xác và tăng cường hiệu quả đầu tư.

Bên cạnh đó, các công ty trong nghiên cứu này được lựa chọn từ các ngành khác nhau trên sàn HOSE cho thấy sự đa dạng trong các ngành nghề này làm nổi bật sự khác biệt trong cách các mô hình Prophet và ARIMA xử lý các chuỗi dữ liệu có mức độ biến động và các yếu tố vĩ mô ảnh hưởng khác nhau. Việc lựa chọn các công ty đại diện cho nhiều ngành khác nhau cũng phản ánh sự phân hóa trong thị trường chứng khoán Việt Nam, nơi mỗi ngành có đặc thù riêng về mức độ biến động và ảnh hưởng của các yếu tố bên ngoài đến giá cổ phiếu. Điều này giúp làm rõ hơn lý do tại sao kết quả dự báo của hai mô hình lại có sự khác biệt rõ rệt trong quá trình áp dụng vào dữ liệu thực tế.

Bảng 4.7 trình bày tổng hợp kết quả so sánh hiệu quả giữa hai mô hình của tất cả mã cổ phiếu trong nghiên cứu, làm rõ hơn sự khác biệt giữa hai mô hình trong các điều kiện thị trường khác nhau. ARIMA phù hợp với các chuỗi thời gian ổn định, ít biến động, và khi dữ liệu có xu hướng dài hạn rõ rệt. Tuy nhiên, khi có sự thay đổi đột ngột hoặc yếu tố ngoại lai tác động, ARIMA gặp khó khăn trong việc phản ánh chính xác. Ngược lại, Prophet lại phát huy tối đa hiệu quả trong những tình huống này nhờ khả năng mô hình hóa xu hướng phi tuyến, yếu tố mùa vụ và các sự kiện bất ngờ. Các đặc điểm chuỗi dữ liệu trong bảng được tổng hợp từ ba

nguồn: (i) kết quả sai số, (ii) kiểm định DM với $p\text{-value} < 0,05$ ở tất cả mã, và (iii) quan sát thực nghiệm từ một số biểu đồ minh họa. Việc đánh giá mô hình hiệu quả hơn ở từng mã chỉ được đưa ra khi có đủ cơ sở định lượng và kiểm định thống kê nhằm đảm bảo tính khách quan và chính xác học thuật.

Việc lựa chọn mô hình phù hợp phụ thuộc vào đặc điểm của từng mã cổ phiếu và điều kiện thị trường. Trong bối cảnh thị trường chứng khoán Việt Nam, nơi có sự phân hóa rõ rệt giữa các ngành và mức độ biến động, ARIMA là lựa chọn lý tưởng cho các chuỗi thời gian ổn định, trong khi Prophet lại mang lại kết quả chính xác hơn trong các chuỗi có sự biến động mạnh hoặc có yếu tố mùa vụ tác động. Việc kết hợp linh hoạt giữa ARIMA và Prophet sẽ giúp các nhà đầu tư tối ưu hóa chiến lược dự báo và đưa ra quyết định đầu tư chính xác hơn, từ đó nâng cao hiệu quả đầu tư trong bối cảnh thị trường chứng khoán đầy biến động hiện nay.

Bảng 4.8. Tổng hợp kết quả so sánh hiệu quả giữa ARIMA và Prophet

Mã cổ phiếu	Đặc điểm chuỗi dữ liệu	Mô hình hiệu quả (theo kiểm định DM)	Cơ sở đánh giá
CTR	Biến động lớn, nhiễu cao	Prophet	Prophet có RMSE thấp hơn (~1.193 VND), kiểm định DM khẳng định Prophet vượt trội ($p < 0,001$).
DBD	Biến động thấp, xu hướng rõ	Prophet	Prophet có MAPE thấp nhất toàn bộ (8,498%), cả 3 chỉ số sai số thấp hơn, DM ủng hộ Prophet ($p = 0,0019$).
FPT	Xu hướng mạnh, giá cao	ARIMA	ARIMA cho MAE, RMSE và MAPE thấp hơn, DM xác nhận khác biệt rõ rệt nghiêng về ARIMA ($p < 0,001$).
HPG	Dao động mạnh, chuỗi không dừng	Prophet	ARIMA sai số cao, Prophet ổn định hơn ở cả 3 chỉ số.
HVN	Biến động trung bình, phụ thuộc vĩ mô	ARIMA	ARIMA cho sai số thấp hơn toàn diện, kiểm định DM ủng hộ ARIMA ($p = 0,0008$).
MSN	Biến động vừa, giá cao	Prophet	Prophet có MAE, RMSE, MAPE đều thấp hơn, kiểm định DM cho thấy Prophet hiệu quả hơn ($p < 0,001$).
MWG	Chuỗi phức tạp, nhiễu mạnh	ARIMA	Prophet không theo kịp xu hướng, sai số cao, DM nghiêng về ARIMA ($p < 0,001$).
PVS	Biến động theo chu kỳ (ngành năng lượng)	ARIMA	Prophet không tận dụng tốt chu kỳ mùa vụ, ARIMA sai số thấp hơn, DM xác nhận ($p < 0,001$).
REE	Ổn định vừa phải, xu hướng rõ	Prophet	Prophet cho cả ba chỉ số đều thấp, DM ủng hộ ARIMA ($p = 0,0277$).
VCB	Ổn định cao, độ lệch chuẩn thấp	ARIMA	Cả ba chỉ số đều ủng hộ ARIMA, kiểm định DM khẳng định ($p < 0,001$).
VIC	Giá trị cao, biến động khó lường	ARIMA	Prophet có MAPE thấp hơn, nhưng RMSE và MAE nghiêng ARIMA, kiểm định DM khẳng định ARIMA hiệu quả hơn ($p = 0,0018$).

Nguồn: Tác giả tự tổng hợp

KẾT LUẬN CHƯƠNG 4

Chương 4 đã so sánh chi tiết hai mô hình Prophet và ARIMA trong việc dự báo giá cổ phiếu trên sàn HOSE, sử dụng các chỉ số sai số RMSE, MAE, và MAPE. Kết quả nghiên cứu cho thấy Prophet vượt trội hơn ARIMA trong việc dự báo giá cổ phiếu, đặc biệt khi thị trường có sự biến động mạnh hoặc có yếu tố mùa vụ và ngoại lai.

ARIMA hoạt động hiệu quả trong các chuỗi ổn định và ít biến động, nhưng gặp khó khăn khi xử lý các chuỗi dữ liệu có sự thay đổi đột ngột. Ngược lại, Prophet linh hoạt hơn, có khả năng mô hình hóa các xu hướng phi tuyến và yếu tố mùa vụ, giúp cải thiện độ chính xác trong các giai đoạn biến động mạnh. Qua các ví dụ như HPG và VCB, Prophet đã chứng tỏ sự vượt trội trong việc dự báo chính xác các thay đổi đột ngột và xu hướng dài hạn. Mặc dù ARIMA có ưu thế trong các chuỗi ổn định, nhưng Prophet lại tỏ ra phù hợp hơn khi dữ liệu có sự biến động mạnh hoặc yếu tố ngoại lai tác động.

Tóm lại, Prophet là mô hình tối ưu cho dữ liệu có tính phi tuyến và biến động mạnh, trong khi ARIMA vẫn hiệu quả cho chuỗi thời gian ổn định. Việc kết hợp linh hoạt giữa hai mô hình có thể giúp tối ưu hóa kết quả dự báo trong bối cảnh thị trường chứng khoán hiện nay.

Chương tiếp theo sẽ tổng kết kết quả nghiên cứu, đưa ra các đóng góp, hạn chế và đề xuất hướng nghiên cứu tiếp theo.

CHƯƠNG 5. KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ

Chương 5 sẽ tổng kết lại kết quả nghiên cứu và đưa ra các hàm ý quản trị, giúp làm rõ các kết luận từ quá trình so sánh hiệu quả của mô hình Prophet và ARIMA trong việc dự báo giá cổ phiếu trên sàn HOSE. Chương này sẽ trình bày các kết luận chính từ nghiên cứu, chỉ ra những đóng góp của nghiên cứu đối với lý thuyết và thực tiễn, đồng thời nêu lên các hạn chế và đề xuất hướng nghiên cứu tiếp theo. Ngoài ra, chương cũng đưa ra các khuyến nghị dành cho nhà đầu tư và các tổ chức tài chính, nhằm hỗ trợ việc lựa chọn mô hình dự báo phù hợp để tối ưu hóa chiến lược đầu tư.

5.1. Kết luận và đóng góp của nghiên cứu

Kết quả nghiên cứu này đã chỉ ra rằng cả hai mô hình dự báo chuỗi thời gian phổ biến là ARIMA và Prophet đều có những ưu điểm và hạn chế riêng biệt, và việc lựa chọn mô hình phù hợp phụ thuộc vào đặc điểm của dữ liệu và bối cảnh thị trường chứng khoán.

ARIMA là lựa chọn tối ưu khi dữ liệu có xu hướng ổn định, ít bị tác động bởi các yếu tố ngoại lai, với khả năng nắm bắt các yếu tố tự hồi quy và sai phân. Mô hình này cho thấy độ chính xác cao khi dự báo giá cổ phiếu của các công ty có mức độ ổn định giá cao, như VCB, DBD, và HPG, nơi mà chuỗi dữ liệu có tính dừng rõ rệt và cấu trúc tuyến tính. Tuy nhiên, ARIMA gặp khó khăn khi xử lý dữ liệu có tính phi tuyến hoặc có yếu tố mùa vụ mạnh, cũng như khi có sự thay đổi đột ngột do các sự kiện ngoại lai. Ngược lại, Prophet thể hiện sự linh hoạt vượt trội trong việc dự báo giá cổ phiếu khi dữ liệu có sự biến động mạnh hoặc bị tác động bởi các yếu tố ngoại lai, như các sự kiện kinh tế hoặc chính trị. Prophet có khả năng tự động phát hiện các điểm thay đổi trong xu hướng và xử lý tốt các yếu tố mùa vụ, điều này giúp cải thiện độ chính xác trong các giai đoạn có sự thay đổi đột ngột, như trong trường hợp của các cổ phiếu FPT, MSN, và VIC. Mặc dù trong các giai đoạn thị trường ổn định, ARIMA vẫn vượt trội hơn về độ chính xác, nhưng Prophet lại là lựa chọn phù

hợp hơn khi thị trường có sự biến động mạnh, yếu tố mùa vụ rõ rệt, hoặc khi gặp cú sốc từ các sự kiện bất ngờ.

Nghiên cứu này cũng chỉ ra rằng kết hợp ARIMA và Prophet có thể giúp tối ưu hóa kết quả dự báo, đặc biệt là trong môi trường thị trường đầy biến động và không ổn định. Việc lựa chọn mô hình phải linh hoạt, tùy thuộc vào đặc điểm cụ thể của dữ liệu và mục tiêu dự báo. ARIMA thích hợp để dự báo xu hướng dài hạn trong các giai đoạn ổn định, trong khi Prophet sẽ phát huy tối đa hiệu quả khi có sự thay đổi đột ngột hoặc yếu tố bên ngoài tác động. Một đóng góp quan trọng của nghiên cứu này là việc đánh giá độ chính xác của hai mô hình ARIMA và Prophet trong bối cảnh thị trường chứng khoán Việt Nam, nơi mà các yếu tố ngoại lai có ảnh hưởng lớn đến biến động giá cổ phiếu. Mặc dù ARIMA vẫn có vai trò quan trọng trong các chuỗi dữ liệu ổn định, Prophet lại tỏ ra linh hoạt hơn trong các tình huống không chắc chắn, khi các yếu tố mùa vụ hoặc sự thay đổi đột ngột trong xu hướng giá cổ phiếu là vấn đề quan trọng.

Ngoài ra, việc sử dụng các chỉ số đánh giá như RMSE, MAE, và MAPE trong nghiên cứu này cung cấp cho các nhà đầu tư một công cụ hữu ích để đánh giá độ chính xác của các mô hình dự báo trong những điều kiện thị trường cụ thể, giúp đưa ra các quyết định đầu tư chính xác hơn trong bối cảnh thị trường đầy biến động. Tùy thuộc vào mục tiêu dự báo và đặc điểm của chuỗi thời gian, việc kết hợp linh hoạt cả Prophet và ARIMA có thể giúp nhà đầu tư tối ưu hóa hiệu quả dự báo trong các điều kiện thị trường khác nhau.

5.2. Các khuyến nghị

Dựa trên kết quả nghiên cứu, đưa ra một số khuyến nghị sau. Đối với nhà đầu tư và các tổ chức tài chính, cần lựa chọn mô hình dự báo phù hợp với đặc điểm của từng cổ phiếu và tình hình thị trường. ARIMA là lựa chọn tối ưu khi dự báo cho các cổ phiếu có xu hướng ổn định, ít biến động và không chịu tác động mạnh từ các yếu tố bên ngoài. Tuy nhiên, đối với các cổ phiếu có yếu tố mùa vụ mạnh mẽ hoặc bị tác động bởi các sự kiện bất ngờ, Prophet sẽ là mô hình dự báo chính xác hơn. Do đó, nhà đầu tư cần phải hiểu rõ đặc điểm của dữ liệu và tình hình thị trường để

đưa ra quyết định dự báo chính xác nhất. Đối với các nhà nghiên cứu, các nghiên cứu tiếp theo có thể mở rộng phạm vi và nâng cao độ chính xác của các mô hình dự báo bằng cách tích hợp các yếu tố vĩ mô vào trong mô hình Prophet và ARIMA.

Ngoài ra, việc kết hợp các mô hình học máy với các mô hình thống kê sẽ giúp nâng cao khả năng dự báo và cải thiện hiệu quả khi đối mặt với các chuỗi dữ liệu phức tạp và phi tuyến. Đối với các chuyên gia phân tích tài chính, các chuyên gia nên sử dụng kết hợp nhiều mô hình dự báo để tối ưu hóa dự báo, đặc biệt khi đối mặt với các chuỗi dữ liệu có sự biến động mạnh hoặc yếu tố mùa vụ rõ rệt. Việc kết hợp các mô hình như ARIMA và Prophet với các phương pháp học máy hoặc mô hình kết hợp sẽ giúp cải thiện độ chính xác trong các dự báo dài hạn và ngắn hạn, từ đó hỗ trợ các quyết định đầu tư chính xác hơn.

Chính vì thế, nghiên cứu này đã làm sáng tỏ những ưu nhược điểm của mô hình ARIMA và Prophet trong việc dự báo giá cổ phiếu tại thị trường chứng khoán Việt Nam. Các nhà đầu tư, tổ chức tài chính, và các chuyên gia phân tích tài chính có thể sử dụng kết quả nghiên cứu này để đưa ra quyết định đầu tư chính xác hơn, tối ưu hóa lợi nhuận và giảm thiểu rủi ro trong môi trường thị trường đầy biến động. Nghiên cứu cũng góp phần mở rộng khả năng ứng dụng của các mô hình dự báo trong các thị trường mới nổi như Việt Nam, đồng thời tạo tiền đề cho các nghiên cứu tiếp theo về ứng dụng mô hình học máy và mô hình kết hợp trong dự báo giá cổ phiếu.

5.3. Hạn chế của nghiên cứu

Mặc dù nghiên cứu đã đạt được các mục tiêu đề ra và cung cấp những kết luận quan trọng về việc so sánh mô hình ARIMA và Prophet trong dự báo giá cổ phiếu tại thị trường chứng khoán Việt Nam, nhưng vẫn còn một số hạn chế cần được lưu ý.

Thứ nhất, chưa xem xét sự tương tác giữa các yếu tố nội tại và ngoại lai. Các yếu tố nội tại như kết quả kinh doanh của doanh nghiệp, chiến lược quản lý, hoặc yếu tố ngoại lai như sự thay đổi chính sách kinh tế, sự kiện chính trị quan trọng có thể có ảnh hưởng mạnh mẽ đến giá cổ phiếu. Tuy nhiên, trong nghiên cứu này, các

yếu tố này chưa được mô hình hóa và đưa vào phân tích. Việc kết hợp các yếu tố này vào mô hình dự báo có thể giúp cải thiện độ chính xác và tính thực tiễn của kết quả dự báo, đặc biệt là trong các giai đoạn có sự biến động lớn từ các yếu tố ngoại lai.

Thứ hai, việc lựa chọn các chỉ số đánh giá mô hình có thể chưa đầy đủ hoặc có sự hạn chế nhất định. Mặc dù RMSE, MAE, và MAPE là các chỉ số phổ biến và hữu ích trong việc đánh giá độ chính xác của các mô hình dự báo, nhưng chúng không thể phản ánh hết mọi yếu tố cần thiết trong dự báo thị trường chứng khoán. Các chỉ số này có thể không đánh giá đúng mức độ ổn định của mô hình khi đối mặt với các cú sốc lớn hoặc khả năng xử lý dữ liệu thiếu, yếu tố có thể đặc biệt quan trọng trong dự báo giá cổ phiếu. Việc bổ sung các chỉ số khác như AIC, BIC, hoặc sử dụng các kiểm định đa chiều về sự thay đổi của mô hình qua các thời kỳ có thể mang lại cái nhìn toàn diện hơn về hiệu quả dự báo của mỗi mô hình.

Thứ ba, việc đánh giá độ chính xác chỉ thông qua các chỉ số sai số đơn lẻ có thể không phản ánh đầy đủ hiệu quả của các mô hình trong các tình huống cụ thể của thị trường. Đặc biệt trong thị trường chứng khoán, các sai số lớn tại những thời điểm quan trọng có thể gây tổn thất lớn cho nhà đầu tư. Do đó, một đánh giá toàn diện hơn về mô hình cần phải bao gồm các yếu tố như tính ổn định của mô hình trong các giai đoạn thị trường biến động mạnh và khả năng thích nghi của mô hình với sự thay đổi đột ngột. Điều này đặc biệt quan trọng trong các bối cảnh không thể dự đoán trước sự kiện lớn tác động mạnh đến thị trường.

Cuối cùng, khả năng áp dụng mô hình trong thời gian thực là một hạn chế quan trọng. Mặc dù các mô hình như ARIMA và Prophet có thể cung cấp các dự báo chính xác trong môi trường thử nghiệm, nhưng khi triển khai trong điều kiện thị trường thực tế, nơi có sự thay đổi liên tục và tác động mạnh từ các yếu tố ngoại lai, những mô hình này có thể gặp phải vấn đề với độ trễ trong dự báo, đặc biệt là trong các trường hợp dữ liệu thiếu hoặc không đồng đều. Việc áp dụng các phương pháp cải tiến như học máy hay mô hình kết hợp có thể giúp giảm thiểu các vấn đề này và làm cho dự báo trở nên linh hoạt hơn trong môi trường thị trường thực.

Vì vậy, ngoài các hạn chế liên quan đến phạm vi và dữ liệu cần được mở rộng hơn thì các vấn đề như chưa tích hợp đầy đủ các yếu tố nội tại và ngoại lai, việc lựa chọn chỉ số đánh giá mô hình chưa toàn diện, và khả năng áp dụng mô hình trong điều kiện thực tế đều cần được xem xét và cải thiện trong các nghiên cứu tiếp theo. Những cải tiến này sẽ giúp nâng cao độ chính xác và khả năng ứng dụng của các mô hình dự báo trong bối cảnh thị trường chứng khoán đầy biến động.

5.4. Đề xuất hướng nghiên cứu tiếp theo

Dựa trên các kết quả và hạn chế đã chỉ ra, nghiên cứu này mở ra nhiều hướng nghiên cứu tiếp theo có thể giúp mở rộng và nâng cao độ chính xác của các mô hình dự báo trong thị trường chứng khoán Việt Nam. Một số hướng nghiên cứu tiếp theo bao gồm tích hợp các yếu tố vĩ mô vào mô hình dự báo. Trong nghiên cứu này, các yếu tố vĩ mô như chính sách tiền tệ, tỷ giá, lãi suất, và các sự kiện kinh tế toàn cầu chưa được tích hợp vào mô hình. Các yếu tố này có thể có ảnh hưởng lớn đến giá cổ phiếu và cần được xem xét để cải thiện độ chính xác của dự báo. Việc tích hợp các yếu tố vĩ mô vào mô hình Prophet và ARIMA sẽ giúp mô hình phản ánh đúng hơn tác động của các yếu tố bên ngoài lên giá cổ phiếu và cải thiện tính ổn định trong dự báo.

Thứ hai, mở rộng ứng dụng mô hình học máy. Mặc dù ARIMA và Prophet là những mô hình thống kê phổ biến, nhưng trong bối cảnh dữ liệu tài chính phức tạp, việc sử dụng các mô hình học máy như Random Forest, XGBoost, hoặc Mạng Nơ - ron Nhân tạo có thể giúp khai thác được các đặc điểm phi tuyến và sự phụ thuộc không rõ ràng trong chuỗi thời gian. Việc kết hợp các mô hình học máy với các mô hình thống kê truyền thống sẽ là một hướng nghiên cứu hứa hẹn, giúp nâng cao hiệu quả dự báo và giảm thiểu sai số.

Thứ ba, ứng dụng các mô hình kết hợp (ensemble models). Các mô hình kết hợp như stacking, bagging, hoặc boosting có thể giúp kết hợp sức mạnh của nhiều mô hình khác nhau để tăng cường độ chính xác dự báo. Nghiên cứu các mô hình kết hợp này có thể giúp tận dụng được những điểm mạnh của cả ARIMA và Prophet

cùng các mô hình học máy khác, mang lại một giải pháp dự báo toàn diện hơn cho thị trường chứng khoán Việt Nam.

Cuối cùng, ứng dụng mô hình trong bối cảnh chuỗi dữ liệu không hoàn chỉnh. Các mô hình Prophet và ARIMA trong nghiên cứu này được áp dụng với dữ liệu đầy đủ và được làm sạch. Tuy nhiên, trong thực tế, dữ liệu chứng khoán có thể bị thiếu hoặc bị nhiễu. Do đó, nghiên cứu tiếp theo có thể tìm cách phát triển các phương pháp xử lý dữ liệu thiếu và không đồng đều, đồng thời tối ưu hóa các mô hình dự báo để hoạt động hiệu quả ngay cả khi dữ liệu không hoàn chỉnh.

KẾT LUẬN CHƯƠNG 5

Chương 5 đã trình bày kết luận và các khuyến nghị từ nghiên cứu so sánh mô hình Prophet và ARIMA trong dự báo giá cổ phiếu. Nghiên cứu cho thấy cả hai mô hình đều có ưu điểm và hạn chế riêng, tùy thuộc vào đặc điểm của dữ liệu và tình hình thị trường. Mô hình ARIMA tỏ ra hiệu quả hơn trong các chuỗi dữ liệu ổn định, trong khi Prophet có ưu thế trong những giai đoạn có sự biến động mạnh hoặc các yếu tố mùa vụ. Các nhà đầu tư và tổ chức tài chính có thể sử dụng kết quả nghiên cứu này để đưa ra quyết định đầu tư chính xác hơn và tối ưu hóa lợi nhuận. Đồng thời, chương cũng đã nêu ra các hạn chế của nghiên cứu và đề xuất hướng nghiên cứu tiếp theo để cải thiện độ chính xác của các mô hình dự báo trong bối cảnh thị trường chứng khoán đầy biến động. Các khuyến nghị từ nghiên cứu này sẽ giúp các chuyên gia phân tích tài chính, nhà đầu tư và các tổ chức tài chính nâng cao hiệu quả dự báo và quản lý rủi ro trong môi trường thị trường đầy thay đổi.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

1. Chu Đăng Bình An, Hoàng Đình Thăng, & Trần Minh Thái. (2025). So sánh các mô hình dự báo trong dự đoán giá chứng khoán. *Tạp Chí Khoa học HUFLIT*, 9(1). <https://hjs.huflit.edu.vn/index.php/hjs/article/view/223>
2. Giang Ngọc Hà Linh, Nguyễn Thị Việt Nga, Lê Nguyễn Hà Phương, & Ngô Thị Thu Hiền. (2024). Application of ARIMA model for forecasting prices of some banking stocks. *Journal of Finance & Accounting Research*.
3. Nguyễn Hồ Diệu Uyên, & Nguyễn Thị Thanh Huyền. (2014). *Ứng dụng mô hình ARIMA trong dự báo chỉ số VN-Index*.
4. Nguyễn Thị Thanh Huyền, & Nguyễn Tuấn Sơn. (2022). *Ứng dụng mô hình ARIMA trong dự báo giá cổ phiếu tại Việt Nam*.
5. Nguyễn Thị Thúy Hạnh. (2023). *Improving and optimizing the performance of the supply chain: The case of coffee production in Vietnam*. <https://theses.hal.science/tel-04265675v1>
6. Trần Kim Toại, Võ Thị Xuân Hạnh, & Võ Minh Huân. (2024). Dự báo dài hạn và ngắn hạn chỉ số chứng khoán Việt Nam sử dụng mô hình học máy. *Tạp chí Kinh tế và Ngân hàng châu Á*, 222, 22–34. <https://doi.org/10.63065/ajeb.vn.2024.222.102811>
7. Trần Quang Quý, Nguyễn Vũ Hải, Hà Văn Ninh, & Nguyễn Thị Thúy. (2024). Sử dụng mô hình học sâu LSTM trong dự đoán giá trị cổ phiếu. *TNU Journal of Science and Technology*, 229(15), 103–111. <https://doi.org/10.34238/tnu-jst.11554>

Tài liệu tiếng Anh

1. Adebisi, A. A., Adewumi, A. O., & Ayo, C. K. (2014). Comparison of ARIMA and Artificial Neural Networks Models for Stock Price Prediction. *Journal of Applied Mathematics*, 2014, 1–7. <https://doi.org/10.1155/2014/614342>
2. Angelo, M. D., Fadhiilrahman, I., & Purnama, Y. (2023). Comparative Analysis of ARIMA and Prophet Algorithms in Bitcoin Price Forecasting. *Procedia Computer Science*, 227, 490–499. <https://doi.org/10.1016/j.procs.2023.10.550>
3. Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
4. Box, G. E. P., & Jenkins, G. M. (1976). *Time Series Analysis: Forecasting and Control* (Revised Edition). Holden-Day.
5. Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2016). *Time Series Analysis: Forecasting and Control, 5th Edition* (5th a.b). John Wiley & Sons, Inc.
6. Burnham, K. P., & Anderson, D. R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach* (K. P. Burnham & D. R. Anderson, B.t.v; 2nd a.b). Springer New York. <https://doi.org/10.1007/b97636>
7. Chai, T., & Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7(3), 1247–1250. <https://doi.org/10.5194/gmd-7-1247-2014>
8. Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236. <https://doi.org/10.1080/713665670>
9. De Myttenaere, A., Golden, B., Grand, B. Le, & Rossi, F. (2016). *Mean Absolute Percentage Error for regression models*. <https://doi.org/10.1016/j.neucom.2015.12.114>

10. Dickey, D. A., & Fuller, W. A. (1979). Distribution of the Estimators for Autoregressive Time Series With a Unit Root. *Journal of the American Statistical Association*, 74(366), 427. <https://doi.org/10.2307/2286348>
11. Diebold, F. X., & Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
12. Garlapati, A., Krishna, D. R., Garlapati, K., Srikara Yaswanth, N. mani, Rahul, U., & Narayanan, G. (2021). Stock Price Prediction Using Facebook Prophet and Arima Models. *2021 6th International Conference for Convergence in Technology (I2CT)*, 1–7. <https://doi.org/10.1109/I2CT51068.2021.9418057>
13. Huang, Q. (2022). Forecasting Stock Prices Using Multi-Macroeconomic Regressors Based on the Facebook Prophet Model. *BCP Business & Management*, 25, 231–242. <https://doi.org/10.54691/bcpbm.v25i.1762>
14. Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd a.b). OTexts. <https://otexts.org/fpp2/>
15. Kohavi, R. (1995). A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. Trong *Proceedings of the 14th International Joint Conference on Artificial Intelligence - Volume 2* (tr 1137–1143). Morgan Kaufmann Publishers Inc. [http://roboticsStanfordedu/"ronnyk](http://roboticsStanfordedu/)
16. Lukauskas, M., Pilinkienė, V., Bruneckienė, J., Stundžienė, A., Grybauskas, A., & Ruzgas, T. (2022). Economic Activity Forecasting Based on the Sentiment Analysis of News. *Mathematics*, 10(19), 3461. <https://doi.org/10.3390/math10193461>
17. Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PLOS ONE*, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>
18. Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74. <https://doi.org/10.1016/j.ijforecast.2019.04.014>

19. McKinney, W. (2017). *Python for Data Analysis Data Wrangling with Pandas, NumPy, and IPython* (Second). O'Reilly Media.
20. MSCI, & S&P Dow Jones Indices. (2023). *Global Industry Classification Standard (GICS®) Methodology*. <https://www.msci.com/indexes/index-resources/gics>
21. Shen, Q., Zhang, Y., Xiao, J., Dong, X., & Lin, Z. (2023). Research of daily stock closing price prediction for new energy companies in China. *Data Science in Finance and Economics*, 3(1), 14–29. <https://doi.org/10.3934/DSFE.2023002>
22. Shumway, R. H., & Stoffer, D. S. (2011). *Time Series Analysis and Its Applications*. Springer New York. <https://doi.org/10.1007/978-1-4419-7865-3>
23. Taylor, S. J., & Letham, B. (2017). Forecasting at Scale. *The American Statistician*, 72(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>
24. Tsay, R. S. (2010). *Analysis of Financial Time Series*. Wiley. <https://doi.org/10.1002/9780470644560>
25. Wang, Y., Wei, Y., Lucey, B. M., & Vigne, S. A. (2023). Cryptocurrency uncertainty and volatility forecasting of precious metal futures markets. *Journal of Commodity Markets*, 29, 100305. <https://doi.org/10.1016/j.jcomm.2022.100305>
26. Willmott, C., & Matsuura, K. (2005a). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, 30, 79–82. <https://doi.org/10.3354/cr030079>
27. Willmott, C., & Matsuura, K. (2005b). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, 30, 79–82. <https://doi.org/10.3354/cr030079>
28. Zhang, G., Eddy Patuwo, B., & Y. Hu, M. (1998). Forecasting with artificial neural networks: *International Journal of Forecasting*, 14(1), 35–62. [https://doi.org/10.1016/S0169-2070\(97\)00044-7](https://doi.org/10.1016/S0169-2070(97)00044-7)

29. Zhou, Y., Xie, C., Wang, G. J., Gong, J., & Zhu, Y. (2025). Forecasting cryptocurrency volatility: a novel framework based on the evolving multiscale graph neural network. *Financial Innovation*, 11(1). <https://doi.org/10.1186/s40854-025-00768-x>
30. Zivot, E., & Wang, J. (2006). *Modeling Financial Time Series with S-PLUS®*. Springer-Verlag. <https://doi.org/10.1007/0-387-32348-1>

PHỤ LỤC

Để đảm bảo tính minh bạch, tái lập và tăng độ tin cậy cho nghiên cứu, phần phụ lục dưới đây trình bày toàn bộ mã nguồn được sử dụng để xử lý dữ liệu, huấn luyện mô hình ARIMA và Prophet, cũng như thực hiện các kiểm định thống kê

Mã nguồn được viết bằng ngôn ngữ Python, kết hợp các thư viện phổ biến như pandas, statsmodels, fbprophet, pmdarima, matplotlib, v.v. Các đoạn mã dưới đây được tổ chức theo thứ tự logic của quá trình nghiên cứu, từ bước tiền xử lý dữ liệu đến đánh giá mô hình.

1. THƯ VIỆN SỬ DỤNG

```
# Cài thư viện cần thiết (chạy lần đầu)
get_ipython().system('pip install pandas matplotlib prophet pmdarima openpyxl statsmodels')

# In[2]:

# import tất cả thư viện cần thiết
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from prophet import Prophet
from pmdarima import auto_arima
from sklearn.metrics import mean_absolute_error, mean_squared_error
import numpy as np
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.stats.diagnostic import acorr_ljungbox
from sklearn.model_selection import TimeSeriesSplit
from scipy import stats
import warnings
warnings.filterwarnings("ignore")
```

2. TIỀN XỬ LÝ DỮ LIỆU

```
# ===== 1. Đọc và tiền xử lý dữ liệu =====

# Đọc dữ liệu từ file Excel
df = pd.read_excel("Data.xlsx", sheet_name="Data")

# Chuẩn hóa tên cột
df.columns = df.columns.str.strip().str.lower()

# Ép kiểu dữ liệu
df['date'] = pd.to_datetime(df['date'], errors='coerce')
df['close_price'] = pd.to_numeric(df['close_price'], errors='coerce')

# Loại bỏ dòng thiếu dữ liệu
df.dropna(subset=['date', 'close_price', 'stock_code'], inplace=True)

# Loại bỏ trùng lặp
df.drop_duplicates(inplace=True)

# Sắp xếp và reset index
df.sort_values(by=['stock_code', 'date'], inplace=True)
df.reset_index(drop=True, inplace=True)

# In 5 dòng đầu để kiểm tra dữ liệu
df.head()
```

3. PHÂN PHỐI GIÁ CỔ PHIẾU (TRƯỚC KHI XỬ LÝ NGOẠI LAI)

```
import matplotlib.pyplot as plt

# Vẽ histogram cho giá cổ phiếu (close_price)
plt.hist(df['close_price'], bins=30, edgecolor='black')
plt.title('Biểu đồ Histogram phân phối giá cổ phiếu')
plt.xlabel('Giá cổ phiếu')
plt.ylabel('Tần suất')
plt.show()

# In[5]:

# Vẽ Box Plot cho giá cổ phiếu (close_price)
sns.boxplot(df['close_price'])
plt.title('Biểu đồ Boxplot phân phối giá cổ phiếu trước khi xử lý ngoại lai')
plt.xlabel('Giá đóng cửa')
plt.show()

# In[6]:

print(f"Số lượng dữ liệu trước khi xử lý ngoại lai: {len(df)}")
```

4. XỬ LÝ NGOẠI LAI

```
# Xử lý ngoại lai với phương pháp IQR
Q1 = df['close_price'].quantile(0.25)
Q3 = df['close_price'].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

# Lọc dữ liệu sau khi Loại bỏ ngoại lai với IQR
df_cleaned = df[(df['close_price'] >= lower_bound) & (df['close_price'] <= upper_bound)]

# Xử lý ngoại lai với phương pháp Z-score
from scipy.stats import zscore
df_cleaned['z_score'] = zscore(df_cleaned['close_price'])

# Loại bỏ các ngoại lai có Z-score > 3 hoặc < -3
df_final = df_cleaned[df_cleaned['z_score'].abs() <= 3]

# Số lượng ngoại lai đã được Loại bỏ
print(f"Số lượng ngoại lai sau khi sử dụng cả IQR và Z-score: {len(df_final)}")

# In[8]:

# Thực hiện thống kê mô tả sau khi xử lý ngoại lai
df_cleaned.describe() # Cung cấp các chỉ số thống kê mô tả

# Vẽ lại Boxplot sau khi xử lý ngoại lai
sns.boxplot(df_cleaned['close_price'])
plt.title('Boxplot sau khi xử lý ngoại lai')
plt.xlabel('Giá đóng cửa')
plt.show()
```

5. THỐNG KÊ MÔ TẢ

```
# ===== 2. Thống kê mô tả (toàn bộ dữ liệu) =====

# Tính thống kê mô tả cho cột 'close_price'
description = df_cleaned['close_price'].describe()

# In kết quả thống kê mô tả
print("\nThống kê mô tả cho cột 'close_price':")
print(description)

# In[12]:

# ===== 3. Thống kê mô tả (từng mã cổ phiếu) =====

# Tính thống kê mô tả cho từng mã cổ phiếu
summary_stats = df_cleaned.groupby("stock_code")["close_price"].agg(
    mean_price="mean",
    min_price="min",
    max_price="max",
    std_dev="std",
    count="count"
).reset_index().round(2)

# In kết quả
print(summary_stats)
```

7. BIẾN ĐỘNG GIÁ CỔ PHIẾU VÀ KIỂM ĐỊNH TÍNH DỪNG

4. Vẽ biểu đồ biến động giá cổ phiếu theo thời gian cho tất cả các mã cổ phiếu

```
plt.figure(figsize=(15, 6))
for stock_code in df_cleaned['stock_code'].unique():
    stock_data = df_cleaned[df_cleaned['stock_code'] == stock_code]
    plt.plot(stock_data['date'], stock_data['close_price'], label=stock_code)

plt.title("Biến động giá của các mã cổ phiếu (2020-2025)")
plt.xlabel("Thời gian")
plt.ylabel("Giá đóng cửa (VND)")
plt.legend(loc="upper left")
plt.grid(True)
plt.xticks(rotation=45) # Xoay nhãn thời gian nếu cần
plt.tight_layout() # Điều chỉnh tự động để không bị tràn
plt.show()
```

In[14]:

===== 2. Kiểm định tính dừng ADF =====

```
def adf_test(series):
    """Kiểm tra tính dừng ADF"""
    result = adfuller(series)
    print(f"ADF Statistic: {result[0]}")
    print(f"p-value: {result[1]}")
    if result[1] < 0.05:
        print("Dữ liệu là dừng.")
        return True
    else:
        print("Dữ liệu không dừng.")
        return False
# Kiểm tra tính dừng của giá cổ phiếu
adf_test(df_cleaned['close_price'])
```

8. XÁC ĐỊNH THAM SỐ VÀ KIỂM ĐỊNH DIEBOLD – MARIANO

===== 3. Chọn tham số ARIMA từ ACF/PACF =====

```
def select_arima_params(series):
    """Chọn tham số ARIMA dựa trên ACF, PACF và AIC/BIC"""
    plot_acf(series)
    plt.title("ACF of Stock Prices")
    plt.show()

    plot_pacf(series)
    plt.title("PACF of Stock Prices")
    plt.show()

    # Tự động chọn tham số ARIMA (p, d, q)
    model_arima = auto_arima(series, seasonal=False, trace=False, error_action='ignore', suppress_warnings=True)
    return model_arima.order # Trả về thông số ARIMA (p, d, q)
```

In[16]:

```
from scipy.stats import norm
import numpy as np

def diebold_mariano(residuals_model1, residuals_model2):
    """
    Kiểm định Diebold-Mariano giữa 2 mô hình dự báo.
    :param residuals_model1: Phần dư mô hình 1 (ARIMA).
    :param residuals_model2: Phần dư mô hình 2 (Prophet).
    :return: Statistic và p-value.
    """
    e1 = residuals_model1
    e2 = residuals_model2
    d = e1**2 - e2**2
    mean_d = np.mean(d)
    var_d = np.var(d) / len(d)
    dm_stat = mean_d / np.sqrt(var_d)
    p_value = 2 * (1 - norm.cdf(abs(dm_stat)))
    return dm_stat, p_value
```

9. HÀM DỰ BÁO PROPHET

```

from prophet import Prophet
from sklearn.metrics import mean_absolute_error, mean_squared_error
from sklearn.model_selection import TimeSeriesSplit
import numpy as np
import pandas as pd
from statsmodels.stats.diagnostic import acorr_ljungbox
import matplotlib.pyplot as plt

def prophet_forecast(stock_code, df_cleaned, fold_to_plot=1):
    # Lọc dữ liệu theo mã cổ phiếu
    stock_df = df_cleaned[df_cleaned['stock_code'] == stock_code].copy()

    # Kiểm tra xem dữ liệu có đủ không
    if len(stock_df) < 30:
        print(f"\n⚠ Không đủ dữ liệu cho mã: {stock_code}")
        return None, None, None, None

    # Chia dữ liệu thành các fold (cross-validation)
    tscv = TimeSeriesSplit(n_splits=5)

    # Danh sách chứa các chỉ số lỗi
    maes_prophet = []
    rmse_prophet = []
    mapes_prophet = []

    # Biến lưu các kết quả
    test_plot = None
    y_pred_plot = None
    forecast_plot = None

    # Vòng lặp cross-validation
    fold_count = 1
    for train_index, test_index in tscv.split(stock_df):
        train, test = stock_df.iloc[train_index], stock_df.iloc[test_index]

        # Đặt tên cột cho Prophet
        train_prophet = train.rename(columns={'date': 'ds', 'close_price': 'y'})

        # Huấn luyện mô hình Prophet
        model_prophet = Prophet(daily_seasonality=True)
        model_prophet.fit(train_prophet)

        # Dự báo cho tập kiểm tra (test set)
        last_date = train_prophet['ds'].max()
        future_dates = pd.date_range(start=last_date, periods=len(test) + 1, freq='D')[1:]
        future = pd.DataFrame(future_dates, columns=['ds'])

        # Dự báo
        forecast = model_prophet.predict(future)
        y_pred_prophet = forecast['yhat'].values

        # Dữ liệu thực tế
        y_true = test['close_price'].values

        # Tính toán các chỉ số lỗi
        mae = mean_absolute_error(y_true, y_pred_prophet)
        rmse = np.sqrt(mean_squared_error(y_true, y_pred_prophet))
        mape = np.mean(np.abs((y_true - y_pred_prophet) / y_true)) * 100

        print(f"\n📊 Mã cổ phiếu: {stock_code} - Fold {fold_count}")
        print(f"Prophet - MAE: {mae:.2f}, RMSE: {rmse:.2f}, MAPE: {mape:.2f}%")

        # Lưu lại kết quả lỗi
        maes_prophet.append(mae)
        rmse_prophet.append(rmse)
        mapes_prophet.append(mape)

    # Lưu kết quả cho fold_to_plot
    if fold_count == fold_to_plot:
        test_plot = test
        y_pred_plot = y_pred_prophet
        forecast_plot = forecast

```

```

# Tính phần dư và kiểm định Ljung-Box
residuals = y_true - y_pred_prophet
ljung_result = acorr_ljungbox(residuals, lags=[10], return_df=True)
p_value_lb = ljung_result['lb_pvalue'].values[0]
print(f"Ljung-Box p-value: {p_value_lb:.4f}")

fold_count += 1

# Tạo bảng tóm tắt cho Prophet
summary_prophet = pd.DataFrame({
    "Mã cổ phiếu": [stock_code],
    "Prophet MAE": [np.mean(maes_prophet)],
    "Prophet RMSE": [np.mean(rmses_prophet)],
    "Prophet MAPE": [np.mean(mapes_prophet)]
})

# Vẽ biểu đồ nếu yêu cầu
if test_plot is not None:
    plt.figure(figsize=(14, 6))
    plt.plot(train['date'], train['close_price'], color='blue', label='Train Data')
    plt.plot(test_plot['date'], test_plot['close_price'], color='green', label='Test Data')
    plt.plot(test_plot['date'], y_pred_plot, color='red', label='Forecast (yhat)')
    plt.fill_between(test_plot['date'],
                     forecast_plot['yhat_lower'],
                     forecast_plot['yhat_upper'],
                     color='orange', alpha=0.2, label='Confidence Interval')
    plt.title(f'{stock_code} Closing Prices - Prophet Forecast (Fold {fold_to_plot})')
    plt.xlabel('Date')
    plt.ylabel('Closing Price')
    plt.legend()
    plt.grid(True)
    plt.xticks(rotation=45)
    plt.tight_layout()
    plt.show()

# Vẽ biểu đồ residuals
residuals = test_plot['close_price'].values - y_pred_plot # Tính phần dư
plt.figure(figsize=(12, 6))
plt.plot(test_plot['date'], residuals, label='Residuals (Prophet)', color='orange')
plt.axhline(0, color='red', linestyle='--')
plt.title(f'Residuals của Prophet - {stock_code}')
plt.xlabel('Ngày')
plt.ylabel('Phần dư')
plt.legend()
plt.grid(True)
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

return summary_prophet, test_plot, y_pred_plot, forecast_plot

# In[46]:

# Gọi hàm để dự báo và vẽ biểu đồ residuals cho một mã cổ phiếu cụ thể
summary_prophet, test_plot, y_pred_plot, forecast_plot = prophet_forecast(stock_code="VCB", df_cleaned=df_cleaned,
, fold_to_plot=4)

```

10. HÀM DỰ BÁO ARIMA

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import TimeSeriesSplit
from statsmodels.tsa.stattools import adfuller
from pmdarima import auto_arima
from sklearn.metrics import mean_absolute_error, mean_squared_error

# Hàm kiểm tra tính dừng và thực hiện sai phân nếu cần
def difference_until_stationary(series):
    d = 0
    p_value = 1
    while p_value > 0.05 and d < 3:
        series = series.diff().dropna()
        d += 1
        p_value = adfuller(series)[1]
    return series, d, p_value

def arima_forecast(stock_code, df_cleaned, fold_to_plot=1, plot_acf_pacf=True):
    # Lọc dữ liệu theo mã cổ phiếu
    stock_df = df_cleaned[df_cleaned['stock_code'] == stock_code].copy()

    # Kiểm tra nếu có đủ dữ liệu
    if len(stock_df) < 30:
        print(f"\n⚠ Không đủ dữ liệu cho mã: {stock_code}")
        return None, None, None, None

    tscv = TimeSeriesSplit(n_splits=5) # Chia dữ liệu thành 5 phần (folds)
    maes_arima = []
    rmse_arima = []
    mapes_arima = []
    arima_params = []

    test_plot = None
    y_pred_plot = None
    train_plot = None

    fold_count = 1 # Đếm số fold
    for train_index, test_index in tscv.split(stock_df):
        train = stock_df.iloc[train_index].copy()
        test = stock_df.iloc[test_index].copy()

        train_series = train['close_price']
        test_series = test['close_price']

        # 1. KIỂM TRA TÍNH DỪNG VÀ IN KẾT QUẢ CHI TIẾT
        adf_result = adfuller(train_series)
        adf_statistic = adf_result[0]
        p_value_adf = adf_result[1]
        print(f"\n📊 Mã cổ phiếu: {stock_code} - Fold {fold_count}")
        print(f"ADF Statistic: {adf_statistic:.5f}")
        print(f"p-value: {p_value_adf:.5f}")

        if p_value_adf < 0.05:
            d_manual = 0
            transformed_series = train_series
            print(f"✅ Dữ liệu đã dừng, tiếp tục xây dựng mô hình...")
        else:
            transformed_series, d_manual, final_pval = difference_until_stationary(train_series)
            print(f"⚠ Dữ liệu không dừng, thực hiện sai phân {d_manual} lần. ADF sau khi sai phân: {final_pval:.5f}")

        try:
            # 2. XÂY DỰNG MÔ HÌNH ARIMA VỚI THAM SỐ TỰ ĐỘNG
            model_arima = auto_arima(
                train_series,
                d=d_manual,
                seasonal=False,
                trace=True,
                error_action='ignore',
                suppress_warnings=True
            )
            p, d_auto, q = model_arima.order
            print(f"🔍 Tìm thấy mô hình ARIMA({p}, {d_auto}, {q})")
```

```

# 3. DỰ BÁO
forecast = model_arima.predict(n_periods=len(test_series))
y_true = test_series.values

# 4. ĐÁNH GIÁ MÔ HÌNH
mae = mean_absolute_error(y_true, forecast)
rmse = np.sqrt(mean_squared_error(y_true, forecast))
mape = np.mean(np.abs((y_true - forecast) / y_true)) * 100

maes_arima.append(mae)
rmse_arima.append(rmse)
mape_arima.append(mape)
arima_params.append([stock_code, p, d_auto, q])

if fold_count == fold_to_plot:
    test_plot = test
    y_pred_plot = forecast
    train_plot = train

    plt.figure(figsize=(10, 6))
    plt.plot(train['date'], train['close_price'], label='Train')
    plt.plot(test['date'], test['close_price'], label='Test')
    plt.plot(test['date'], forecast, label='Forecast', linestyle='--')
    plt.title(f'{stock_code} - ARIMA Forecast (Fold {fold_count})')
    plt.xlabel('Date')
    plt.ylabel('Price')
    plt.grid(True)
    plt.legend()
    plt.show()

    print(f"Fold {fold_count} - {stock_code}:")
    print(f"   MAE: {mae:.4f}")
    print(f"   RMSE: {rmse:.4f}")
    print(f"   MAPE: {mape:.4f}%")

except Exception as e:
    print(f"❌ Lỗi fold {fold_count}: {e}")

fold_count += 1

# TỔNG KẾT KẾT QUẢ TRUNG BÌNH
summary_arima = pd.DataFrame({
    "Mã cổ phiếu": [stock_code],
    "ARIMA MAE": [np.mean(maes_arima)],
    "ARIMA RMSE": [np.mean(rmse_arima)],
    "ARIMA MAPE": [np.mean(mape_arima)]
})

print("\nTổng hợp kết quả các chỉ số đánh giá mô hình ARIMA:")
print(f"   ARIMA MAE (Trung bình): {np.mean(maes_arima):.4f}")
print(f"   ARIMA RMSE (Trung bình): {np.mean(rmse_arima):.4f}")
print(f"   ARIMA MAPE (Trung bình): {np.mean(mape_arima):.4f}%")

arima_params_df = pd.DataFrame(arima_params, columns=['stock_code', 'ARIMA p', 'ARIMA d', 'ARIMA q'])

return summary_arima, test_plot, y_pred_plot, train_plot, arima_params_df

fold_count += 1

# TỔNG KẾT KẾT QUẢ TRUNG BÌNH
summary_arima = pd.DataFrame({
    "Mã cổ phiếu": [stock_code],
    "ARIMA MAE": [np.mean(maes_arima)],
    "ARIMA RMSE": [np.mean(rmse_arima)],
    "ARIMA MAPE": [np.mean(mape_arima)]
})

print("\nTổng hợp kết quả các chỉ số đánh giá mô hình ARIMA:")
print(f"   ARIMA MAE (Trung bình): {np.mean(maes_arima):.4f}")
print(f"   ARIMA RMSE (Trung bình): {np.mean(rmse_arima):.4f}")
print(f"   ARIMA MAPE (Trung bình): {np.mean(mape_arima):.4f}%")

arima_params_df = pd.DataFrame(arima_params, columns=['stock_code', 'ARIMA p', 'ARIMA d', 'ARIMA q'])

return summary_arima, test_plot, y_pred_plot, train_plot, arima_params_df

```

11. SO SÁNH MÔ HÌNH VÀ TỔNG HỢP KẾT QUẢ

```
def compare_models_with_dm_full(df_cleaned, fold_to_plot=4):
    stock_codes = df_cleaned['stock_code'].unique()

    dm_results = []
    all_summary_prophet = []
    all_summary_arima = []

    for code in stock_codes:
        print(f"\n🔍 Đang xử lý mã: {code}")

        try:
            # Prophet forecast
            summary_p, test_p, y_pred_p, _ = prophet_forecast(code, df_cleaned, fold_to_plot)

            # ARIMA forecast
            summary_a, test_a, y_pred_a, _ = arima_forecast(code, df_cleaned, fold_to_plot)
        except Exception as e:
            print(f"⚠️ Lỗi dự báo cho mã {code}: {e}")
            continue

        # Kiểm tra dữ liệu đầu ra
        if test_p is None or test_a is None or y_pred_p is None or y_pred_a is None:
            print(f"⚠️ Bỏ qua {code} do thiếu dữ liệu.")
            continue

        # Tính phần dư
        try:
            residuals_arima = test_a['close_price'].values - y_pred_a
            residuals_prophet = test_p['close_price'].values - y_pred_p
        except Exception as e:
            print(f"⚠️ Lỗi tính phần dư cho {code}: {e}")
            continue

        # Kiểm định Diebold-Mariano
        try:
            dm_stat, dm_pvalue = diebold_mariano(residuals_arima, residuals_prophet)
        except Exception as e:
            print(f"❌ Lỗi kiểm định DM cho {code}: {e}")
            dm_stat, dm_pvalue = np.nan, np.nan

        # Lưu kết quả kiểm định và dự báo
        try:
            row = {
                "Mã cổ phiếu": code,
                "ARIMA MAE": summary_a["ARIMA MAE"].values[0],
                "ARIMA RMSE": summary_a["ARIMA RMSE"].values[0],
                "ARIMA MAPE": summary_a["ARIMA MAPE"].values[0],
                "Prophet MAE": summary_p["Prophet MAE"].values[0],
                "Prophet RMSE": summary_p["Prophet RMSE"].values[0],
                "Prophet MAPE": summary_p["Prophet MAPE"].values[0],
                "DM Statistic": dm_stat,
                "DM p-value": dm_pvalue
            }
            dm_results.append(row)
            all_summary_prophet.append(summary_p)
            all_summary_arima.append(summary_a)
        except Exception as e:
            print(f"⚠️ Lỗi khi tổng hợp kết quả cho {code}: {e}")
            continue

    # Tạo bảng kết quả cuối cùng
    df_dm_summary = pd.DataFrame(dm_results)
    summary_prophet_df = pd.concat(all_summary_prophet, ignore_index=True)
    summary_arima_df = pd.concat(all_summary_arima, ignore_index=True)

    return df_dm_summary, summary_prophet_df, summary_arima_df
```

```

# Gọi hàm để so sánh mô hình
summary_prophet_df, summary_arima_df, arima_params_df_all = compare_models_with_dm_full(df_cleaned, fold_to_plot=4)

# In kết quả sau khi hàm đã chạy xong
if summary_prophet_df is not None and summary_arima_df is not None:
    print("Kết quả Prophet:")
    print(summary_prophet_df)
    print("\nKết quả ARIMA:")
    print(summary_arima_df)
else:
    print("Không có kết quả phù hợp để in.")

# In[28]:

# Gọi hàm so sánh ARIMA vs Prophet + kiểm định Diebold-Mariano
df_dm_summary, summary_prophet_df, summary_arima_df = compare_models_with_dm_full(df_cleaned, fold_to_plot=4)

# Thiết lập hiển thị số với 4 chữ số thập phân
pd.set_option('display.float_format', '{:.4f}'.format)

# Hiển thị bảng so sánh + kiểm định Diebold-Mariano
print("\n📊 BẢNG SO SÁNH HIỆU SUẤT MÔ HÌNH VÀ KIỂM ĐỊNH DIEBOLD-MARIANO:")
display(df_dm_summary)

# Hiển thị bảng riêng mô hình Prophet
print("\n📊 BẢNG TỔNG HỢP HIỆU SUẤT MÔ HÌNH PROPHET:")
display(summary_prophet_df.round(2))

# Hiển thị bảng riêng mô hình ARIMA
print("\n📊 BẢNG TỔNG HỢP HIỆU SUẤT MÔ HÌNH ARIMA:")
display(summary_arima_df.round(2))

# Chỉ chọn 2 cột cần thiết: tên mã và kết quả kiểm định
dm_test_result = df_dm_summary[["Mã cổ phiếu", "DM Statistic", "DM p-value"]].copy()

# Làm tròn cho dễ đọc
dm_test_result["DM Statistic"] = dm_test_result["DM Statistic"].round(4)
dm_test_result["DM p-value"] = dm_test_result["DM p-value"].round(4)

# Hiển thị kết quả
print("\n📊 KẾT QUẢ KIỂM ĐỊNH DIEBOLD-MARIANO:")
display(dm_test_result)

```

12. BẢNG THAM SỐ TRUNG BÌNH VÀ GIÁ TRỊ TRUNG BÌNH CÁC CHỈ SỐ ĐÁNH GIÁ CỦA TOÀN BỘ DỮ LIỆU

```

if arima_params_df_all is not None:
    arima_params_mean = arima_params_df_all.groupby('stock_code').agg({
        'ARIMA p': 'mean',
        'ARIMA d': 'mean',
        'ARIMA q': 'mean'
    }).round().astype(int).reset_index()

    print("Bảng tham số ARIMA trung bình mỗi mã cổ phiếu:")
    print(arima_params_mean)
else:
    print("Không có dữ liệu tham số ARIMA để xử lý.")

# Tính trung bình các chỉ số từ summary_arima_df và summary_prophet_df
df_combined = pd.merge(summary_arima_df, summary_prophet_df, on='Mã cổ phiếu', how='inner')

# Tính trung bình các chỉ số ARIMA và Prophet cho toàn bộ dữ liệu
avg_row = pd.DataFrame({
    'Mã cổ phiếu': ['Trung bình'],
    'ARIMA MAE': [df_combined['ARIMA MAE'].mean()],
    'ARIMA RMSE': [df_combined['ARIMA RMSE'].mean()],
    'ARIMA MAPE': [df_combined['ARIMA MAPE'].mean()],
    'Prophet MAE': [df_combined['Prophet MAE'].mean()],
    'Prophet RMSE': [df_combined['Prophet RMSE'].mean()],
    'Prophet MAPE': [df_combined['Prophet MAPE'].mean()]
})

# Gộp kết quả vào DataFrame cuối cùng
df_final = pd.concat([df_combined, avg_row], ignore_index=True)

# Kiểm tra lại kết quả
print(df_final)

```

13. TRỰC QUAN HÓA QUA CÁC BIỂU ĐỒ

```
# Giả sử summary_arima_df và summary_prophet_df là DataFrame chứa kết quả của ARIMA và Prophet
# Lấy RMSE từ cả hai mô hình
prophet_rmse = summary_prophet_df['Prophet RMSE']
arima_rmse = summary_arima_df['ARIMA RMSE']

# Lấy tên mã cổ phiếu
stock_codes = summary_arima_df['Mã cổ phiếu']

# Tạo biểu đồ cột cho Prophet và ARIMA
fig, ax = plt.subplots(figsize=(12, 6))
width = 0.35 # Chiều rộng của các cột

# Vẽ biểu đồ cho Prophet và ARIMA
ax.bar(stock_codes, prophet_rmse, width, label='Prophet', color='lightblue')
ax.bar([x for x in range(len(stock_codes))], arima_rmse, width, label='ARIMA', color='steelblue', align='edge')

# Ghi giá trị lên mỗi cột
for i, (prophet, arima) in enumerate(zip(prophet_rmse, arima_rmse)):
    ax.text(i, prophet + 150, f'{prophet:.2f}', ha='center', va='bottom', color='black')
    ax.text(i, arima + 150, f'{arima:.2f}', ha='center', va='bottom', color='black')

# Thêm tiêu đề và nhãn cho trục
ax.set_title('So sánh RMSE giữa Prophet và ARIMA')
ax.set_xlabel('Mã cổ phiếu')
ax.set_ylabel('RMSE')
ax.legend()

# Hiển thị biểu đồ
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()

# Lấy các giá trị MAE, RMSE, MAPE từ summary_arima_df và summary_prophet_df
maes_arima = summary_arima_df['ARIMA MAE']
maes_prophet = summary_prophet_df['Prophet MAE']
rmse_arima = summary_arima_df['ARIMA RMSE']
rmse_prophet = summary_prophet_df['Prophet RMSE']
mape_arima = summary_arima_df['ARIMA MAPE']
mape_prophet = summary_prophet_df['Prophet MAPE']

# Mã cổ phiếu
stock_codes = summary_arima_df['Mã cổ phiếu']

# Linechart so sánh các chỉ số MAE giữa ARIMA và Prophet
plt.figure(figsize=(12, 6))
plt.plot(stock_codes, maes_arima, label='ARIMA MAE', color='teal', marker='o')
plt.plot(stock_codes, maes_prophet, label='Prophet MAE', color='lightblue', marker='o')

# Thêm giá trị vào mỗi điểm dữ liệu trên biểu đồ
for i, txt in enumerate(maes_arima):
    plt.annotate(f'{txt:.2f}', (stock_codes[i], maes_arima[i]), textcoords="offset points", xytext=(-5,6), ha='center', fontsize=10)
for i, txt in enumerate(maes_prophet):
    plt.annotate(f'{txt:.2f}', (stock_codes[i], maes_prophet[i]), textcoords="offset points", xytext=(30,6), ha='center', fontsize=10)

plt.xlabel('Mã cổ phiếu')
plt.ylabel('MAE')
plt.title('So sánh MAE giữa ARIMA và Prophet')
plt.xticks(rotation=45)
plt.legend()
plt.show()
```

```

# Lấy dữ liệu từ summary_arima_df và summary_prophet_df
mae_arima = summary_arima_df['ARIMA MAE'].mean()
rmse_arima = summary_arima_df['ARIMA RMSE'].mean()
mape_arima = summary_arima_df['ARIMA MAPE'].mean()

mae_prophet = summary_prophet_df['Prophet MAE'].mean()
rmse_prophet = summary_prophet_df['Prophet RMSE'].mean()
mape_prophet = summary_prophet_df['Prophet MAPE'].mean()

# Các chỉ số
labels = ['MAE', 'RMSE']
prophet_values = [mae_prophet, rmse_prophet]
arima_values = [mae_arima, rmse_arima]

# Vị trí trên trục x
x = np.arange(len(labels))
width = 0.35 # Độ rộng của các cột

# Vẽ biểu đồ cột cho MAE và RMSE
fig, ax = plt.subplots(figsize=(10, 6))

# Vẽ biểu đồ cột cho Prophet và ARIMA
rects1 = ax.bar(x - width/2, prophet_values, width, label='Prophet', color='lightblue')
rects2 = ax.bar(x + width/2, arima_values, width, label='ARIMA', color='steelblue')

# Thêm giá trị lên trên các cột
def add_values(rects):
    for rect in rects:
        height = rect.get_height()
        ax.annotate(f'{height:.2f}',
                    xy=(rect.get_x() + rect.get_width() / 2, height),
                    xytext=(0, 3), # Đẩy giá trị lên trên cột
                    textcoords="offset points",
                    ha='center', va='bottom')

# Thêm giá trị vào các cột
add_values(rects1)
add_values(rects2)

# Thiết lập các nhãn và tiêu đề
ax.set_ylabel('Giá trị')
ax.set_title('So sánh MAE và RMSE giữa Prophet và ARIMA')
ax.set_xticks(x)
ax.set_xticklabels(labels)
ax.legend()

# Hiển thị biểu đồ
plt.tight_layout()
plt.show()

# Biểu đồ MAPE (riêng biệt)
plt.figure(figsize=(8, 6))
plt.bar(['Prophet', 'ARIMA'], [mape_prophet, mape_arima], color=['lightblue', 'steelblue'])
plt.ylabel('MAPE (%)')
plt.title('So sánh MAPE giữa Prophet và ARIMA')

# Thêm giá trị lên trên các cột
for i, v in enumerate([mape_prophet, mape_arima]):
    plt.text(i, v + 0.5, f'{v:.2f}%', ha='center', va='bottom')

plt.tight_layout()
plt.show()

```