

BỘ GIÁO DỤC VÀ ĐÀO TẠO

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM

TRƯỜNG ĐẠI HỌC NGÂN HÀNG THÀNH PHỐ HỒ CHÍ MINH



**KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC**

**ỨNG DỤNG CÁC MÔ HÌNH MACHINE LEARNING VÀO DỰ
ĐOÁN GIÁ CỔ PHIẾU TRONG NGÀNH NGÂN HÀNG
TẠI VIỆT NAM**

NGÀNH: TÀI CHÍNH NGÂN HÀNG

MÃ SỐ: 7340201

KIẾN THỊ TRÚC LINH

TP. HỒ CHÍ MINH, NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM

TRƯỜNG ĐẠI HỌC NGÂN HÀNG THÀNH PHỐ HỒ CHÍ MINH



**KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC**

**ỨNG DỤNG CÁC MÔ HÌNH MACHINE LEARNING VÀO DỰ
ĐOÁN GIÁ CỔ PHIẾU TRONG NGÀNH NGÂN HÀNG
TẠI VIỆT NAM**

NGÀNH: TÀI CHÍNH NGÂN HÀNG

MÃ SỐ: 7340201

Họ và tên sinh viên : KIẾN THỊ TRÚC LINH

Mã số sinh viên : 050609212007

Lớp sinh hoạt: HQ9 - GE22

**NGƯỜI HƯỚNG DẪN KHOA HỌC
PGS.TS LƯU THU QUANG**

TP. HỒ CHÍ MINH, NĂM 2025

TÓM TẮT

Dự đoán giá cổ phiếu là một vấn đề cơ bản trong lĩnh vực đầu tư tài chính, đặc biệt trong bối cảnh thị trường chứng khoán Việt Nam đang phát triển nhanh chóng và đầy biến động. Ngành ngân hàng, với vai trò là "xương sống" của nền kinh tế, rất quan trọng; do đó, sự thay đổi trong giá cổ phiếu của các ngân hàng không chỉ ảnh hưởng đến quyết định đầu tư của cá nhân và tổ chức mà còn tác động đến sự ổn định và tăng trưởng chung của thị trường. Việc dự đoán chính xác giá cổ phiếu trong ngành ngân hàng không chỉ giúp nhà đầu tư tối ưu hóa lợi nhuận và giảm thiểu rủi ro, mà còn cung cấp thông tin quan trọng cho các tổ chức tài chính trong việc xây dựng kế hoạch kinh doanh và quản lý danh mục đầu tư một cách hiệu quả. Tuy nhiên, giá cổ phiếu ngành ngân hàng chịu ảnh hưởng từ nhiều yếu tố đa dạng và phi tuyến tính, bao gồm biến động thị trường, các chỉ số tài chính, và các yếu tố kinh tế vĩ mô như lạm phát, lãi suất và tỷ giá. Sự phức tạp này đòi hỏi các phương pháp dự đoán truyền thống cần được thay thế hoặc kết hợp với các công nghệ tiên tiến hơn để nâng cao độ chính xác và khả năng phản ứng với thị trường hiện đại. Nghiên cứu này ứng dụng các mô hình học máy hiện đại như Long Short-Term Memory (LSTM), Random Forest, XGBoost và Transformer để dự đoán giá cổ phiếu của các ngân hàng được niêm yết trên sàn chứng khoán HOSE và HNX. Dữ liệu nghiên cứu, bao gồm giá cổ phiếu lịch sử, chỉ báo kỹ thuật, chỉ số tài chính và các yếu tố vĩ mô khác, được thu thập từ ngày 01/01/2014 đến 31/12/2024. Các thước đo như MAPE (Mean Absolute Percentage Error) và RMSE (Root Mean Square Error) được sử dụng để đánh giá hiệu suất của các mô hình và xác định mô hình nào có khả năng dự đoán tốt nhất. Qua đó, nghiên cứu đưa ra các đề xuất cải thiện và ứng dụng phù hợp trong việc dự đoán giá cổ phiếu cho các ngân hàng trên thị trường chứng khoán Việt Nam.

ABSTRACT

Stock price forecasting is a fundamental issue in the field of financial investment, especially in the context of the rapidly developing and volatile Vietnamese stock market. The banking industry, as the "backbone" of the economy, is very important; therefore, changes in bank stock prices not only affect the investment decisions of individuals and organizations but also affect the overall stability and growth of the market. Accurately forecasting stock prices in the banking industry not only helps investors optimize profits and minimize risks, but also provides important information for financial institutions in building business plans and managing investment portfolios effectively. However, banking stock prices are affected by many diverse and non-linear factors, including market fluctuations, financial indicators, and macroeconomic factors such as inflation, interest rates, and exchange rates. This complexity requires traditional forecasting methods to be replaced or combined with more advanced technologies to improve accuracy and responsiveness to modern markets. This study applies modern machine learning models such as Long Short-Term Memory (LSTM), Random Forest, XGBoost and Transformer to forecast stock prices of banks listed on the HOSE and HNX stock exchanges. Research data, including historical stock prices, technical indicators, financial ratios and other macro factors, is collected from January 1, 2014 to December 31, 2024. Metrics such as MAPE (Mean Absolute Percentage Error) and RMSE (Root Mean Square Error) are used to evaluate the performance of the models and determine which model has the best forecasting ability. Thereby, the study provides recommendations for improvement and appropriate applications in forecasting stock prices for banks on the Vietnamese stock market.

LỜI CAM ĐOAN

Tôi tên là Kiến Thị Trúc Linh, hiện đang là sinh viên Khóa 9 Chương trình CLC – Ngành Tài chính – Ngân Hàng.

Tôi xin cam đoan đề tài khóa luận tốt nghiệp: “Ứng dụng các mô hình Machine learning vào dự đoán giá cổ phiếu trong ngành Ngân hàng tại Việt Nam” là Khóa luận này là công trình nghiên cứu riêng của tác giả, kết quả nghiên cứu là trung thực, trong đó không có các nội dung đã được công bố trước đây hoặc các nội dung do người khác thực hiện ngoại trừ các trích dẫn được dẫn nguồn đầy đủ trong khóa luận.

TP.HCM, ngày.....tháng.....năm 2025

Tác giả

Kiến Thị Trúc Linh

LỜI CẢM ƠN

Trước hết, Tôi xin gửi lời cảm ơn chân thành đến Ban Giám hiệu Trường Đại học Ngân hàng TP. Hồ Chí Minh đã tạo điều kiện để tôi hoàn thành chương trình đào tạo trình độ Đại học chính quy – Chương trình Chất lượng cao, chuyên ngành Tài chính - Ngân hàng. Tôi cũng xin bày tỏ lòng biết ơn sâu sắc đến Quý Thầy Cô đã tận tâm giảng dạy, chia sẻ kiến thức và kinh nghiệm quý báu, cùng các Thầy Cô phụ trách quản lý đã luôn đồng hành, hỗ trợ tôi trong suốt thời gian học tập tại trường.

Tôi cũng xin cảm ơn quý Thầy Cô giảng dạy tại Trường Đại học Ngân hàng Thành phố Hồ Chí Minh đã tận tình truyền đạt những kiến thức để tôi thực hiện nghiên cứu. Tuy nhiên, với những hạn chế về thời gian, kiến thức và kinh nghiệm, tôi hiểu rằng khóa luận này còn tồn tại những thiếu sót. Vì vậy, tôi rất mong nhận được sự góp ý từ Quý Thầy Cô và Hội đồng phản biện để tiếp tục hoàn thiện hơn trong học tập và nghiên cứu.

Đặt biệt để hoàn thành bài khóa luận tốt nghiệp này thật tốt, tôi xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy Lưu Thu Quang vì đã hướng dẫn và hỗ trợ tôi hoàn thiện bài khóa luận tốt nghiệp..

Cuối cùng, tôi xin cảm ơn tất cả các thành viên trong gia đình, người thân, bạn bè và đồng nghiệp đã động viên và giúp đỡ tôi rất nhiều trong suốt thời gian tôi nghiên cứu và hoàn thành khóa luận này.

PHỤ LỤC

DANH MỤC CÁC TỪ VIẾT TẮT	ix
DANH MỤC CÁC BẢNG	x
DANH MỤC HÌNH	xi
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU	1
1.1. LÝ DO CHỌN ĐỀ TÀI.....	1
1.2. MỤC TIÊU CỦA ĐỀ TÀI	2
1.2.1. Mục tiêu chung.....	2
1.2.2. Mục tiêu cụ thể.....	3
1.3. CÂU HỎI NGHIÊN CỨU.....	3
1.4. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU	3
1.4.1. Đối tượng nghiên cứu.....	3
1.4.2. Phạm vi nghiên cứu.....	3
1.5. PHƯƠNG PHÁP NGHIÊN CỨU	4
1.6. ĐÓNG GÓP CỦA ĐỀ TÀI	5
KẾT LUẬN CHƯƠNG 1	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU	8
2.1. Tổng quan về dự đoán giá chứng khoán.....	8
2.1.1. Khái niệm về dự đoán chứng khoán.....	8
2.1.2. Các lý thuyết hỗ trợ dự đoán	10
2.1.3. Phân tích cơ bản và phân tích kỹ thuật.....	13

2.2.	Tổng quan chung về dữ liệu	14
2.2.1.	Chỉ báo kỹ thuật	14
2.2.2.	Chỉ số tài chính.....	15
2.2.3.	Chỉ số vĩ mô	16
2.2.4.	Các biến số khác.....	17
2.3.	Tổng quan về Machine learning	18
2.3.1.	Khái niệm Machine learning	18
2.3.2.	Mô hình học máy.....	21
2.4.	Lược khảo các nghiên cứu liên quan	27
2.4.1.	Các nghiên cứu nước ngoài.....	27
2.4.2.	Các nghiên cứu trong nước	29
2.5.	Khoảng trống nghiên cứu	33
KẾT LUẬN CHƯƠNG 2		33
CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU		35
3.1.	Thu thập và xử lý dữ liệu.....	35
3.1.1.	Thu thập dữ liệu	35
3.1.2.	Xử lý dữ liệu.....	37
3.2.	Phương pháp nghiên cứu	42
3.2.1.	Mô hình LSTM.....	42
3.2.2.	Mô hình Random Forest.....	43
3.2.3.	Mô hình XGBoost	43

3.3. Đánh giá hiệu suất của các mô hình	44
KẾT LUẬN CHƯƠNG 3	45
CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN KẾT QUẢ.....	46
4.1. Hiệu suất của các mô hình đã xây dựng	46
4.1.1. Hiệu suất mô hình LSTM.....	46
4.1.2. Hiệu suất mô hình Tranformer	52
4.1.3. Hiệu suất của mô hình Random Forest	56
4.1.4. Hiệu suất mô hình XGBoost	61
4.2. So sánh và phân tích kết quả giữa các mô hình.....	66
4.3. Ưu điểm và khuyết điểm của các mô hình dự đoán:	68
KẾT LUẬN CHƯƠNG 4	69
CHƯƠNG 5. KẾT LUẬN VÀ ĐỀ XUẤT	70
5.1. Kết luận.....	70
5.2. Đề xuất chiến lược đầu tư.....	71
5.3. Hạn chế của đề tài và hướng nghiên cứu mở rộng	72
KẾT LUẬN CHƯƠNG 5	73
TÀI LIỆU THAM KHẢO.....	i
PHỤ LỤC 1 – KẾT QUẢ CHẠY MÔ HÌNH	vi
1. Dữ liệu lịch sử giá cổ phiếu các ngân hàng	vi
2. Dữ liệu các chỉ số tài chính và vĩ mô.....	vi
3. Dữ liệu chạy mô hình tổng hợp	vi

PHỤ LỤC 2 – CHẠY MÔ HÌNH.....	xxxiv
-------------------------------	-------

DANH MỤC CÁC TỪ VIẾT TẮT

STT	TỪ VIẾT TẮT	TỪ ĐƯỢC VIẾT TẮT	GIẢI THÍCH
1	LSTM	Long Short-Term Memory	Mạng nơ – ron học sâu chuyên xử lý chuỗi thời gian, dữ liệu tuần tự.
2	SMA	Simple Moving Average	Đường trung bình động đơn giản
3	RMSE	Root Mean Square Error	Sai trung bình bình phương gốc, đánh giá độ chênh lệch dự đoán
4	MAPE	Mean Absolute Percentage Error	Sai số phần trăm tuyệt đối trung bình, đo độ chính xác dự đoán

DANH MỤC CÁC BẢNG

Bảng 2-1: Bảng chỉ báo kỹ thuật.....	15
Bảng 2-2: Bảng chỉ số tài chính.....	16
Bảng 2-3: Bảng các yếu tố vĩ mô.....	17
Bảng 2-4: Các biến số khác	18
Bảng 2-5: Tổng hợp các nghiên cứu liên quan	30
Bảng 4-1: Hiệu suất dự đoán mô hình LSTM.....	47
Bảng 4-2: Hiệu suất dự đoán mô hình Tranformer.....	52
Bảng 4-3: Bảng hiệu suất mô hình Random Forest	56
Bảng 4-4: Bảng kết quả hiệu suất mô hình XGBoost.....	61
Bảng 4-5: Bảng so sánh kết quả hiệu suất của các mô hình	66
Bảng 4-6: Ưu điểm và khuyết điểm của 4 mô hình	68

DANH MỤC HÌNH

Hình 4-1: Biểu đồ giá đóng cửa của các cổ phiếu	46
Hình 4-2: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng ACB.....	49
Hình 4-3: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng CTG	50
Hình 4-4: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng MBB	50
Hình 4-5: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng VCB.....	51
Hình 4-6: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng VIB	51
Hình 4-7: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng BAB.....	52
Hình 4-8: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Transformer ngân hàng VPB	54
Hình 4-9: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng LPB.....	54
Hình 4-10: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng NVB.....	55
Hình 4-11: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng BAB	55
Hình 4-12: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng ACB	58

Hình 4-13: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng CTG	58
Hình 4-14: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng MBB	59
Hình 4-15: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng VCB	59
Hình 4-16: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng VIB	60
Hình 4-17: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng BAB	60
Hình 4-18: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng MBB	63
Hình 4-19: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng TCB	64
Hình 4-20: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng TPB	64
Hình 4-21: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng LPB	65
Hình 4-22: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng BAB	65
Hình 4-23: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng OCB	66

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU

1.1. LÝ DO CHỌN ĐỀ TÀI

Trong bối cảnh toàn cầu hóa và sự bùng nổ của công nghệ thông tin, thị trường chứng khoán Việt Nam đang nổi lên như một điểm đến hấp dẫn cho các nhà đầu tư. Việc dự đoán xu hướng giá cổ phiếu đã trở thành một lĩnh vực thu hút sự chú ý từ cả các nhà nghiên cứu và những người tham gia thị trường. Tuy nhiên, với sự đa dạng và phong phú của các yếu tố và nguồn thông tin, việc dự đoán hành vi giá cổ phiếu trong tương lai trở nên cực kỳ phức tạp. Nhiều ý kiến cho rằng giá cổ phiếu là một hiện tượng khó có thể dự đoán chính xác.

Ngành ngân hàng đóng vai trò then chốt trong nền kinh tế, không chỉ cung cấp dịch vụ tài chính mà còn góp phần vào sự ổn định và phát triển của thị trường tài chính, đảm bảo sự thông suốt trong hoạt động kinh tế. Tuy nhiên, giá cổ phiếu của các ngân hàng thường xuyên biến động do nhiều yếu tố, bao gồm chính sách kinh tế, tình hình tài chính nội bộ và các yếu tố vĩ mô khác.

Dự đoán chính xác giá cổ phiếu là một thách thức lớn đối với các nhà đầu tư và chuyên gia tài chính. Nhiều phương pháp đã được áp dụng để giải quyết vấn đề này. Các phương pháp phân tích cơ bản và kỹ thuật đã được sử dụng, nhưng chúng thường gặp khó khăn trong việc xử lý khối lượng dữ liệu lớn và phức tạp. Nhờ vào sự phát triển của công nghệ, các phương pháp dự đoán mới đã xuất hiện, trong đó các mô hình machine learning với khả năng học hỏi từ dữ liệu và tự động điều chỉnh theo biến động thị trường đang trở thành xu hướng nổi bật trong lĩnh vực tài chính.

Theo Chen & Guestrin (2016) sự ra đời của các mô hình học máy đã mở ra những cơ hội mới trong dự đoán tài chính. Kể từ những năm 2000, các thuật toán ML đã cho phép phân tích khối lượng lớn dữ liệu và phát hiện các mẫu tiềm ẩn, mang lại độ chính xác cao hơn so với các phương pháp truyền thống. Hochreiter và Schmidhuber (1997) đã chỉ ra rằng các mô hình như LSTM (Long Short-Term

Memory), Random Forest, XGBoost và Transformer chứng minh khả năng dự đoán hiệu quả, đặc biệt trong các thị trường có sự biến động liên tục và phi tuyến tính.

Mô hình machine learning không chỉ cải thiện độ chính xác trong dự đoán giá cổ phiếu mà còn hỗ trợ các nhà đầu tư đưa ra quyết định kịp thời và hiệu quả hơn. Các nghiên cứu trước đây đã chỉ ra rằng các mô hình như hồi quy logistic, cây quyết định và mạng nơ-ron có thể mang lại kết quả khả quan trong việc dự đoán xu hướng giá cổ phiếu.

Trong bối cảnh thị trường chứng khoán Việt Nam đang phát triển nhanh chóng và đối mặt với nhiều biến động kinh tế, việc áp dụng machine learning vào dự đoán giá cổ phiếu của các ngân hàng trở nên cực kỳ cần thiết. Các yếu tố như lãi suất, tỷ giá, lạm phát và hiệu quả hoạt động của các ngân hàng đều có tác động lớn đến giá cổ phiếu, khiến cho việc dự đoán trở nên cấp thiết hơn bao giờ hết. Theo Filiz và cộng sự (2021), việc ứng dụng ML không chỉ giúp nhà đầu tư tối ưu hóa lợi nhuận và giảm thiểu rủi ro mà còn hỗ trợ các tổ chức tài chính đưa ra quyết định đúng đắn trong điều kiện thị trường biến động.

Với những lý do nêu trên, đề tài “Ứng dụng các mô hình machine learning vào dự đoán giá cổ phiếu trong ngành ngân hàng tại Việt Nam” trở thành một vấn đề nghiên cứu cần thiết trong bối cảnh hiện nay. Nghiên cứu này nhằm đánh giá hiệu suất dự đoán của các mô hình học máy hiện đại, từ đó tìm ra mô hình phù hợp hơn cho việc dự đoán chỉ số chứng khoán trên thị trường chứng khoán Việt Nam

1.2. MỤC TIÊU CỦA ĐỀ TÀI

1.2.1. Mục tiêu chung

Mục tiêu chính của nghiên cứu là ứng dụng các mô hình học máy vào dự đoán giá cổ phiếu của một số ngân hàng tại Việt Nam. Từ đó, so sánh để tìm ra mô hình có kết quả dự đoán giá cổ phiếu tốt nhất nhằm hỗ trợ nhà đầu tư đưa ra quyết định đầu tư hiệu quả nhất.

1.2.2. Mục tiêu cụ thể

Từ mục tiêu chung sẽ được cụ thể hóa thành các mục tiêu sau:

- Thứ nhất, phát triển các mô hình machine learning nhằm dự đoán giá cổ phiếu của các ngân hàng.
- Thứ hai, đánh giá hiệu suất của các mô hình đã xây dựng để xác định mô hình nào mang lại hiệu quả dự đoán tốt nhất.

1.3. CÂU HỎI NGHIÊN CỨU

Nhằm giải quyết được những mục tiêu nghiên cứu cụ thể nêu trên, đề tài được thực hiện cùng với các câu hỏi sau:

Thứ nhất, Mô hình nào trong số các mô hình machine learning được phát triển có khả năng dự đoán giá cổ phiếu của các ngân hàng một cách chính xác nhất?

Thứ hai, Các yếu tố nào ảnh hưởng đến hiệu suất dự đoán của các mô hình học máy trong việc dự đoán giá cổ phiếu?

1.4. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu trong bài là các mô hình Machine learning được ứng dụng vào dự đoán giá cổ phiếu của các ngân hàng niêm yết trên thị trường chứng khoán Việt Nam.

1.4.2. Phạm vi nghiên cứu

Phạm vi nghiên cứu về mặt thời gian: nghiên cứu sẽ thu thập dữ liệu về giá cổ phiếu, các chỉ số tài chính và vĩ mô của các ngân hàng trong khoảng thời gian từ 01/01/2014 đến 31/12/2024. Một trong các lý do lựa chọn khoảng thời gian trên: Đầu tiên, thời gian này đủ dài, cho phép phân tích các xu hướng dài hạn trong giá cổ phiếu và các chỉ số tài chính, từ đó nhận diện được các mô hình và biến động trên thị trường. Thứ hai, nó bao gồm nhiều sự kiện kinh tế quan trọng, như khủng hoảng tài chính và

thay đổi chính sách tiền tệ, có tác động lớn đến ngành ngân hàng và giá cổ phiếu. Hơn nữa, khoảng thời gian này cung cấp một lượng lớn dữ liệu phong phú, giúp xây dựng và kiểm tra các mô hình machine learning một cách hiệu quả.

Phạm vi nghiên cứu về mặt không gian: nghiên cứu sẽ tập trung vào các ngân hàng niêm yết trên sàn giao dịch chứng khoán HOSE và HNX của Việt Nam.

Phạm vi nghiên cứu nội dung: nội dung nghiên cứu sẽ chủ yếu xoay quanh việc áp dụng các mô hình Machine Learning để dự đoán giá cổ phiếu, dựa trên dữ liệu lịch sử giá, các chỉ số tài chính cũng như các yếu tố kinh tế vĩ mô

1.5. PHƯƠNG PHÁP NGHIÊN CỨU

Để giải quyết các câu hỏi nghiên cứu liên quan đến dự đoán giá cổ phiếu của các ngân hàng trên hai sàn chứng khoán là HOSE và HNX, phương pháp nghiên cứu chủ yếu được lựa chọn là phương pháp định lượng. Phương pháp này kết hợp với các mô hình học máy hiện đại, được triển khai bằng ngôn ngữ lập trình Python. Quá trình thực hiện được hỗ trợ bởi Google Colaboratory cùng với các thư viện sẵn có trong Python, nhằm nâng cao độ chính xác của mô hình.

Trong nghiên cứu này, biến phụ thuộc là giá đóng cửa trong bước thời gian tiếp theo (close). Mục tiêu của mô hình là dự đoán chính xác giá đóng cửa của cổ phiếu các ngân hàng trong tương lai.

Các biến độc lập trong nghiên cứu được chia thành ba nhóm chính: dữ liệu giá cổ phiếu, các chỉ báo kỹ thuật, và các chỉ số tài chính cùng kinh tế vĩ mô. Tác giả thu thập dữ liệu từ các thư viện trong môi trường Google Colab dựa trên ngôn ngữ lập trình Python. Cụ thể, giá cổ phiếu được thu thập thông qua thư viện VnStock, chỉ số tài chính từ thư viện yfinance, và các chỉ số vĩ mô từ World Bank thông qua thư viện pandas. Tất cả dữ liệu này sẽ được làm sạch và chuẩn hóa để phù hợp với các mô hình Machine Learning. Dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ thời gian để đánh giá hiệu suất của mô hình.

Khóa luận tiến hành xây dựng các mô hình học máy để dự đoán giá cổ phiếu trên nền tảng Google Colab. Các mô hình được sử dụng bao gồm Random Forest, LSTM, Tranformer, XGBoost được huấn luyện bằng các thuật toán Machine Learning.

Để đánh giá hiệu suất của các mô hình, các thước đo như RMSE (Root Mean Square Error) và MAPE (Mean Absolute Percentage Error) sẽ được áp dụng. Cuối cùng, dựa trên kết quả thu được, nghiên cứu sẽ kiểm định các giả thuyết liên quan đến hiệu quả của các mô hình dự đoán và xác định yếu tố nào ảnh hưởng lớn nhất đến sự biến động giá cổ phiếu.

1.6. ĐÓNG GÓP CỦA ĐỀ TÀI

Nghiên cứu này cung cấp một góc nhìn khách quan bổ sung về quá trình đầu tư thông qua các phương pháp học máy, đồng thời đóng góp vào sự phát triển ứng dụng học máy trong lĩnh vực tài chính cả trong nước và quốc tế. Ngoài việc giúp các nhà đầu tư phát triển các chiến lược đầu tư thành công và tối ưu hóa quản lý rủi ro, nghiên cứu này còn cung cấp một công cụ hữu ích cho việc đưa ra các quyết định hợp lý. Những đóng góp của nghiên cứu không chỉ có giá trị học thuật mà còn mang lại những lợi ích thực tiễn.

Nghiên cứu cung cấp cho các nhà đầu tư quyền truy cập vào các kỹ thuật học máy tiên tiến để hỗ trợ quá trình ra quyết định. Nhờ đó, các nhà đầu tư có thể xây dựng các kế hoạch đầu tư phù hợp, chủ động kiểm soát rủi ro và tối đa hóa lợi nhuận từ vốn đầu tư của mình. Ngoài ra, nghiên cứu còn đề xuất những hướng đi tiềm năng cho sự phát triển, khuyến khích việc áp dụng rộng rãi hơn học máy trong ngành tài chính nói chung và trong lĩnh vực chứng khoán đặc biệt tại thị trường Việt Nam. Trong bối cảnh toàn cầu hóa và cách mạng công nghệ, điều này không chỉ nâng cao hiệu quả của các hoạt động đầu tư mà còn thúc đẩy sự phát triển và đổi mới của thị trường tài chính trong nước.

BỐ CỤC NGHIÊN CỨU

Nghiên cứu này được chia thành 5 chương chính, mỗi chương tập trung vào một khía cạnh cụ thể nhằm đảm bảo tính logic và mạch lạc trong quá trình thực hiện:

Chương 1: Giới thiệu đề tài

Chương này trình bày một cái nhìn tổng quan về các mục tiêu, câu hỏi nghiên cứu và lý do lựa chọn đề tài. Việc làm rõ đối tượng và phạm vi nghiên cứu giúp xác định trọng tâm của nghiên cứu một cách rõ ràng. Hơn nữa, các phương pháp nghiên cứu và ý nghĩa thực tiễn của nghiên cứu cũng được xem xét, nhấn mạnh những lợi ích mà nghiên cứu mang lại cho các bên liên quan

Chương 2: Cơ sở lý thuyết và tổng quan nghiên cứu

Chương này trình bày các cơ sở lý thuyết và nghiên cứu liên quan. Nội dung bao gồm cơ sở lý thuyết về dự đoán tài chính và các mô hình học máy, cùng với cái nhìn tổng quan về thị trường chứng khoán Việt Nam và ngành ngân hàng. Ngoài ra, chương này còn tóm tắt các nghiên cứu trước đây nhằm xác định những khoảng trống nghiên cứu cần được chú ý.

Chương 3: Dữ liệu và phương pháp nghiên cứu

Chương này cung cấp cái nhìn tổng quan chi tiết về các nguồn dữ liệu được thu thập và các phương pháp xử lý dữ liệu. Việc phát triển các mô hình dự đoán và quy trình huấn luyện cho các mô hình này là những chủ đề chính trong phương pháp nghiên cứu. Để đảm bảo tính khách quan trong phân tích kết quả, chương cũng đề cập đến các chỉ số đánh giá hiệu suất như RMSE và MAPE.

Chương 4: Kết quả và phân tích

Chương này trình bày các kết quả thực nghiệm từ quy trình dự đoán. Tác giả sẽ đánh giá hiệu suất của từng mô hình và so sánh các kết quả để xác định mô hình tốt nhất. Ngoài ra, các yếu tố ảnh hưởng đến độ chính xác của dự đoán cũng được làm rõ,

nhằm giúp các nhà đầu tư hiểu rõ hơn về tác động của các biến số khác nhau trong thị trường tài chính.

Chương 5: Kết luận và khuyến nghị

Chương cuối cùng tóm tắt những kết luận chính của nghiên cứu, nhấn mạnh cả những đóng góp về mặt học thuật và thực tiễn. Dựa trên các phát hiện, chương này đưa ra các khuyến nghị đầu tư nhằm tối ưu hóa lợi nhuận và giảm thiểu rủi ro cho nhà đầu tư. Bên cạnh đó, các hạn chế của nghiên cứu cũng được đề cập, cùng với những gợi ý cho các hướng nghiên cứu trong tương lai nhằm cải thiện và mở rộng công trình.

KẾT LUẬN CHƯƠNG 1

Chương 1 đã đặt nền tảng cho nghiên cứu bằng cách nêu rõ lý do chọn đề tài, mục tiêu, câu hỏi nghiên cứu, đối tượng và phạm vi nghiên cứu, phương pháp, cũng như tầm quan trọng của nghiên cứu đối với các nhà đầu tư và tổ chức tài chính. Do đó, chương này không chỉ xác định rõ hướng đi của nghiên cứu mà còn mở ra một lộ trình mới trong việc sử dụng các mô hình máy học để dự đoán giá cổ phiếu trong ngành ngân hàng.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

2.1. Tổng quan về dự đoán giá chứng khoán

2.1.1. Khái niệm về dự đoán chứng khoán

Định nghĩa về dự đoán giá chứng khoán:

Theo Kranthi (2018), dự đoán thị trường chứng khoán là hoạt động nhằm xác định giá trị tương lai của một cổ phiếu hoặc công cụ tài chính được giao dịch trên sàn chứng khoán. Quá trình này bao gồm việc sử dụng các phương pháp và công cụ để ước lượng giá trị hoặc xu hướng biến động trong tương lai.

Vai trò của việc dự báo giá chứng khoán:

Trong lĩnh vực tài chính, dự đoán sự thay đổi trong giá cổ phiếu trên thị trường là một chủ đề quan trọng. Các dự đoán chính xác sẽ giúp nhà đầu tư xây dựng các kế hoạch đầu tư tốt nhất có thể và giảm thiểu rủi ro. Theo Lê Văn Tuấn và các cộng sự (2021), một số chỉ số tài chính có thể được dự đoán dễ dàng dựa trên nhiều yếu tố tác động khác nhau. Tuy nhiên, kết quả có thể không chính xác do các yếu tố khác không được đưa vào mô hình nhưng vẫn có ảnh hưởng đáng kể đến sự biến động của các chỉ số tài chính này.

Theo Cohen và các cộng sự (2011), các nhà đầu tư đã sử dụng nhiều phương pháp khác nhau để hỗ trợ quyết định mua hoặc bán cổ phiếu. Hai phương pháp phổ biến nhất là phân tích cơ bản và phân tích kỹ thuật. Phân tích cơ bản sử dụng dữ liệu kinh tế để xác định giá trị nội tại của cổ phiếu dựa trên các yếu tố ngành, các chỉ số kinh tế vĩ mô như lãi suất, lạm phát, tỷ giá, giá vàng và giá dầu, cùng với các khía cạnh tài chính và kinh tế của công ty như doanh thu, lợi nhuận, tài sản và tỷ lệ chi trả cổ tức. Ngược lại, phân tích kỹ thuật dựa trên nghiên cứu của Murphy (1999) về Lý thuyết Dow. Phương pháp này đưa ra dự đoán về xu hướng giá trong tương lai, cho dù giá sẽ

tăng hay giảm, bằng cách sử dụng khối lượng giao dịch, các biến động giá trong quá khứ, cùng với nhiều công thức toán học, biểu đồ và chỉ báo khác nhau.

Từ những điều trên có thể thấy rằng, Dự đoán giá chứng khoán là một quá trình phức tạp, liên quan đến việc phân tích nhiều yếu tố khác nhau, bao gồm dữ liệu lịch sử, tình hình kinh tế vĩ mô, và tâm lý thị trường. Các nhà đầu tư thường sử dụng các phương pháp phân tích kỹ thuật và phân tích cơ bản để đưa ra dự đoán. Phân tích kỹ thuật tập trung vào biểu đồ giá và các chỉ báo thị trường để nhận diện xu hướng, trong khi phân tích cơ bản xem xét các yếu tố như doanh thu, lợi nhuận, và tình hình tài chính của công ty. Ngoài ra, sự biến động giá còn chịu ảnh hưởng của các sự kiện bên ngoài như tin tức kinh tế, chính trị, và các yếu tố tâm lý từ các nhà đầu tư. Do đó, việc dự đoán giá chứng khoán không chỉ đòi hỏi kiến thức chuyên sâu mà còn cần khả năng đánh giá và phản ứng nhanh với các thay đổi trong môi trường thị trường.

Kỹ thuật phân tích và dự đoán xu hướng tương lai của giá cổ phiếu bằng cách sử dụng dữ liệu lịch sử và hiện tại được gọi là dự đoán cổ phiếu. Mục tiêu chính của quá trình này là hỗ trợ các nhà đầu tư dự đoán liệu giá cổ phiếu sẽ tăng hay giảm trong một khoảng thời gian nhất định, từ đó giúp họ đưa ra các quyết định đầu tư thông minh. Các nhà đầu tư cần đánh giá hiệu suất và tiềm năng phát triển của các khoản đầu tư trong lĩnh vực quan trọng này của chiến lược đầu tư dài hạn (Milosevic, 2016).

Để đánh giá hiệu suất và tình trạng sức khỏe của một công ty, quá trình dự đoán thường sử dụng phân tích các chỉ số tài chính quan trọng như ROA, ROE, EPS và P/E. Các nhà đầu tư có thể sử dụng thông tin này để xác định giá trị nội tại của cổ phiếu và đưa ra quyết định đầu tư thông minh. Cách dự đoán cổ phiếu đã thay đổi trong những năm gần đây nhờ vào sự phát triển của các thuật toán và công nghệ học máy. Các mô hình học máy hiện đại có khả năng xử lý khối lượng dữ liệu lớn, từ đó tạo ra các dự đoán xu hướng giá chính xác hơn. Điều này cung cấp cho các nhà đầu tư các công cụ

hiệu quả hơn để đánh giá thị trường và tối ưu hóa các kế hoạch đầu tư, đặc biệt trong một thị trường ngày càng cạnh tranh và biến động.

2.1.2. Các lý thuyết hỗ trợ dự đoán

2.1.2.1. Lý thuyết hành vi tài chính

Tài chính hành vi nghiên cứu cách các yếu tố tâm lý ảnh hưởng đến quyết định tài chính, thách thức giả thuyết thị trường hiệu quả (EMH) bằng cách chứng minh rằng các nhà đầu tư không phải lúc nào cũng hành động một cách hợp lý. Theo Shiller (2003), sự biến động của giá cổ phiếu phản ánh sự không ổn định của thị trường ở cấp độ vĩ mô, trái ngược với quan điểm truyền thống cho rằng giá cổ phiếu luôn phản ánh giá trị nội tại. Kể từ những năm 1980, các nhà nghiên cứu đã quan sát thấy các hành vi phi lý như giao dịch theo đám đông và sự ác cảm thua lỗ, đồng thời bắt đầu đặt câu hỏi về tính hợp lý tuyệt đối của EMH. Daniel Kahneman và Amos Tversky đã phát triển Lý thuyết Tương lai (Prospect Theory), theo đó các nhà đầu tư có xu hướng đưa ra quyết định dựa trên cảm xúc thay vì các tính toán kinh tế. Sau đó, Richard Thaler đã giới thiệu khái niệm "kế toán tâm lý" (mental accounting), giải thích lý do tại sao các nhà đầu tư phân bổ quỹ của họ dựa trên cảm xúc thay vì lý trí. Điều này dẫn đến những lựa chọn kém, bao gồm việc đặt mục tiêu quá mức hoặc đầu tư dựa trên cảm xúc nhất thời thay vì kế hoạch dài hạn.

Các hiện tượng tâm lý khác thường gặp bao gồm tâm lý bầy đàn, trong đó các nhà đầu tư có xu hướng đi theo đám đông hơn là thực hiện nghiên cứu độc lập của riêng họ, và sự tự tin thái quá, khi các nhà đầu tư đánh giá quá cao khả năng dự đoán thị trường của mình. Sự ác cảm đối với thua lỗ cũng dẫn đến việc các nhà đầu tư bán cổ phiếu khi giá tăng nhằm giảm thiểu khả năng thua lỗ thêm, đồng thời giữ lại các cổ phiếu thua lỗ để tránh "chốt lỗ" (Kahneman & Tversky, 1979). Những yếu tố này làm giảm hiệu quả của thị trường và góp phần vào sự xuất hiện của các cuộc khủng hoảng tài chính cũng như bong bóng thị trường chứng khoán. Vào năm 2015, Hammond đã

chỉ ra rằng bên cạnh việc nâng cao kiến thức tài chính, nghiên cứu tài chính hành vi cũng giúp các nhà đầu tư tránh được những sai lầm do tâm lý gây ra bằng cách nâng cao nhận thức về các thiên lệch trong quyết định đầu tư .

Các hiện tượng tâm lý phổ biến khác bao gồm quá tự tin, khi nhà đầu tư đánh giá quá cao khả năng dự đoán thị trường của mình, và tâm lý bầy đàn, khi nhà đầu tư dễ dàng làm theo đám đông thay vì tự phân tích độc lập. Theo Kumar & Thenmozhi, 2014, sự ác cảm đối với thua lỗ cùng khiến nhà đầu tư thường giữ lại các cổ phiếu đang lỗ để tránh "chốt lỗ" và có xu hướng bán ra cổ phiếu khi giá tăng nhằm giảm thiểu nguy cơ thua lỗ thêm. Những yếu tố này làm giảm hiệu quả thị trường và góp phần vào sự hình thành bong bóng thị trường chứng khoán hoặc các cuộc khủng hoảng tài chính (Hammond, 2015). Nghiên cứu về hành vi tài chính không chỉ mở rộng hiểu biết về tài chính mà còn giúp nhà đầu tư ý thức hơn về các thiên kiến trong quyết định đầu tư, từ đó tránh các sai lầm do yếu tố tâm lý gây ra.

2.1.2.2. Lý thuyết chuỗi thời gian

Một thành phần quan trọng của phân tích tài chính, lý thuyết chuỗi thời gian đặc biệt hữu ích trong việc dự đoán sự biến động và xu hướng giá cổ phiếu. Mô hình ARIMA, được sử dụng để phân tích các chuỗi dữ liệu ổn định, có khả năng xử lý dữ liệu xu hướng và chu kỳ nhằm dự đoán cả sự thay đổi ngắn hạn và dài hạn, theo Box và Jenkins (1976). Theo Harvey & Todd (1983), ARIMA, kết hợp các yếu tố tự hồi quy (AR), tích phân (I) và trung bình trượt (MA) để mô hình hóa và dự đoán dữ liệu, đặc biệt phù hợp với dữ liệu giá cổ phiếu khi cấu trúc là không đổi. Các mô hình ARCH và GARCH được phát triển bởi (Engle, 1982) nhằm phân tích và dự đoán sự biến động cho dữ liệu tài chính có mức độ biến động cao. Điều này giúp định lượng rủi ro khi giá cổ phiếu thay đổi theo thời gian. Trong quản lý rủi ro tài chính và đầu tư, những mô hình này thường được sử dụng, đặc biệt để tính toán độ lệch chuẩn và các chỉ số biến động nhằm xác định sự biến động của một tài sản.

Hơn nữa, mô hình mạng LSTM, được đề xuất bởi Hochreiter, S. and Schmidhuber, J., (1997), đã cho phép xác định các mẫu phi tuyến tính lâu dài trong dữ liệu tài chính thông qua các chuỗi dữ liệu phức tạp và dài hạn. Nhờ khả năng nhớ lại các trạng thái trước đó, LSTM có thể xử lý dữ liệu liên tục một cách hiệu quả và ước lượng giá cổ phiếu cũng như xu hướng tài chính một cách chính xác hơn, đặc biệt khi có nhiều thành phần không ổn định. Những mô hình chuỗi thời gian này thường được sử dụng trong dự đoán tài chính và đầu tư nhằm hỗ trợ các nhà đầu tư trong việc lựa chọn quyết định dựa trên các mẫu dự đoán và xu hướng biến đổi được xác định qua thời gian trong dữ liệu giá cổ phiếu.

2.1.2.3. Lý thuyết thị trường hiệu quả

Theo Giả thuyết Thị trường Hiệu quả (EMH) của Eugene Fama, trong một thị trường tài chính hiệu quả, giá cổ phiếu luôn phản ánh chính xác tất cả thông tin liên quan (Fama, 1970). Điều này gợi ý rằng thị trường sẽ ngay lập tức điều chỉnh giá của mình để phản ứng với từng thông tin mới, ngăn chặn việc tạo ra lợi nhuận bất thường. Mỗi một trong ba hình thức của lý thuyết—yếu, trung bình và mạnh—đề cập đến một mức độ khác nhau của khả năng của thị trường trong việc phản ánh thông tin. Phiên bản yếu của EMH cho rằng phân tích kỹ thuật là vô nghĩa vì giá hiện tại đã phản ánh tất cả thông tin có sẵn. Hình thức bán mạnh đi một bước xa hơn và cho rằng giá cổ phiếu đã tính đến thông tin từ công chúng, khiến cho phân tích kỹ thuật và cơ bản trở nên ít hữu ích hơn trong việc dự đoán giá. Theo phiên bản mạnh nhất của EMH, ngay cả thông tin nội bộ cũng ảnh hưởng đến giá, có nghĩa là không có thông tin nào có thể giúp các nhà đầu tư vượt trội hơn so với lợi nhuận trung bình của thị trường (Fama, 1970). Mặc dù có sự ủng hộ từ nhiều học giả, nhưng các nghiên cứu thực nghiệm cũng đã phát hiện ra những bất thường trên thị trường mà lý thuyết này không thể giải thích. Ví dụ, Wachtel (1942) khẳng định rằng thị trường chứng khoán thường tăng mạnh vào tháng Giêng và hiện tượng này có thể được tận dụng để kiếm lời. Fama & French

(1992) phát hiện rằng các cổ phiếu có tỷ lệ P/E thấp thường mang lại lợi suất cao hơn mức trung bình, cho thấy rằng thị trường không phải lúc nào cũng phản ánh chính xác tất cả thông tin có sẵn.

2.1.3. Phân tích cơ bản và phân tích kỹ thuật

- Phân tích cơ bản:

Graham, B., & Dodd, D. L. F (1934) định nghĩa phân tích cơ bản là một kỹ thuật đánh giá giá trị nội tại của cổ phiếu nhằm xác định giá trị thực sự của một công ty dựa trên các yếu tố tài chính và chức năng kinh doanh thiết yếu. Phương pháp này được Graham và Dodd phát triển để giúp các nhà đầu tư nhìn nhận cổ phiếu dựa trên các yếu tố dài hạn thay vì chỉ dựa vào những biến động giá ngắn hạn. Sự phát triển của phương pháp này đánh dấu một bước tiến quan trọng, vì nó cho phép các nhà đầu tư đánh giá rủi ro và tiềm năng tăng trưởng của doanh nghiệp bằng cách tập trung vào phân tích báo cáo tài chính và các yếu tố định lượng. Buffett (1984) khẳng định rằng phân tích cơ bản là một thành phần chính của đầu tư giá trị, giúp các nhà đầu tư tập trung vào hiệu suất và chiến lược kinh doanh của công ty để đưa ra quyết định đầu tư dài hạn. Bằng cách sử dụng phương pháp này, các nhà đầu tư có thể xác định các công ty có tiềm năng tăng trưởng mạnh nhưng bị định giá thấp trên thị trường, từ đó có cái nhìn rõ ràng hơn về tình trạng tài chính và các chỉ số hiệu suất của công ty, chẳng hạn như ROE (lợi suất trên vốn chủ sở hữu), P/E (tỷ lệ giá trên lợi nhuận) và EPS (lợi nhuận trên mỗi cổ phiếu).

- Phân tích kỹ thuật

Từ đó, các công cụ phân tích như đường trung bình động, chỉ báo MACD và RSI đã ra đời, giúp các nhà đầu tư xác định các điểm mua và bán tiềm năng. Lịch sử cho thấy, vai trò của phân tích kỹ thuật là hỗ trợ trong việc đưa ra quyết định ngắn hạn dựa trên các mô hình giá cả và khối lượng giao dịch mà không cần phân tích các yếu tố nội tại của doanh nghiệp. Ngày nay, với sự phát triển của công nghệ và thuật toán,

phân tích kỹ thuật đã tiến hóa đáng kể. Lo, A. W (2004) cho rằng sự kết hợp giữa trí tuệ nhân tạo và học máy đã cải thiện đáng kể khả năng nhận diện và dự đoán xu hướng trong dữ liệu tài chính. Các mô hình hiện đại có khả năng học hỏi và nhận diện các mẫu phức tạp mà các phương pháp truyền thống không thể thực hiện, từ đó nâng cao độ chính xác trong phân tích và dự đoán giá cổ phiếu.

Do đó, vai trò của phân tích kỹ thuật không chỉ giới hạn ở việc cung cấp thông tin về các biến động ngắn hạn mà còn mở rộng ra việc phân tích dữ liệu tài chính phức tạp trong bối cảnh của các thị trường hiện đại. Để hỗ trợ các nhà đầu tư trong việc xác định các điểm mua và bán tiềm năng, các công cụ phân tích như đường trung bình động, chỉ báo MACD và RSI đã được phát triển. Trong quá khứ, phân tích kỹ thuật được sử dụng để giúp đưa ra các quyết định ngắn hạn bằng cách xem xét khối lượng giao dịch và các mô hình giá cả, thay vì các hoạt động nội bộ của công ty. Khi công nghệ và thuật toán đã tiến bộ, phân tích kỹ thuật đã thay đổi một cách đáng kể trong thời đại hiện đại. Theo Lo, A. W (2004), sự kết hợp giữa học máy và trí tuệ nhân tạo đã nâng cao khả năng nhận diện và dự đoán các mẫu trong dữ liệu tài chính. Khả năng của các mô hình hiện đại trong việc học hỏi và nhận diện các mẫu phức tạp đã giúp tăng cường độ chính xác trong phân tích và dự đoán giá cổ phiếu, mở rộng vai trò của phân tích kỹ thuật từ việc thông báo cho các nhà giao dịch về các biến động tạm thời đến việc phân tích dữ liệu tài chính phức tạp trong khuôn khổ của các thị trường hiện đại.

2.2. Tổng quan chung về dữ liệu

2.2.1. Chỉ báo kỹ thuật

Chỉ báo kỹ thuật là công cụ quan trọng giúp nhà đầu tư phân tích và dự đoán xu hướng giá cổ phiếu thông qua dữ liệu thị trường lịch sử.

Bảng 2-1: Bảng chỉ báo kỹ thuật

Chỉ báo kỹ thuật	Ý nghĩa
Chỉ số giá (Price Index)	Theo dõi sự thay đổi giá cổ phiếu, đánh giá xu hướng thị trường qua các mức cao, thấp và giá đóng cửa
Khối lượng giao dịch (Volume)	Phản ánh mức độ giao dịch, khối lượng cao xác nhận xu hướng giá
Trung bình động (Moving Average)	Xác định xu hướng giá qua SMA (trung bình động đơn giản) và EMA (trung bình động hàm số mũ)
Chỉ số dao động (Oscillators)	Chỉ báo như RSI (Relative Strength Index) giúp xác định tình trạng quá mua hoặc quá bán
Chỉ báo theo xu hướng (trend Indicators)	Chỉ báo như MACD (moving Average Convergence Divergence) xác định xu hướng dài hạn và tín hiệu mua/bán.

Nguồn: Tác giả tổng hợp

2.2.2. Chỉ số tài chính

Các chỉ số tài chính giúp nhà đầu tư đánh giá tình trạng tài chính và tiềm năng tăng trưởng của công ty, từ đó ảnh hưởng trực tiếp đến giá cổ phiếu. Các chỉ số tài chính được sử dụng rộng rãi trong việc dự đoán giá cổ phiếu bao gồm các chỉ số về lợi nhuận, tỷ suất sinh lời, và các chỉ số thanh khoản.

Bảng 2-2: Bảng chỉ số tài chính

Chỉ số tài chính	Ý nghĩa
Lợi nhuận trên mỗi cổ phiếu (EPS)	Đo lường lợi nhuận trên mỗi cổ phiếu, giúp đánh giá khả năng sinh lời của công ty.
Lợi nhuận ròng trên vốn chủ sở hữu (ROE)	Tỷ lệ lợi nhuận trên vốn chủ sở hữu, phản ánh hiệu quả sử dụng vốn của công ty trong việc tạo ra lợi nhuận
Hệ số giá trên lợi nhuận một cổ phiếu (P/E)	Tỷ lệ giữa giá cổ phiếu và lợi nhuận, dùng để đánh giá mức độ định giá của cổ phiếu so với lợi nhuận của công ty.
Lợi nhuận trên tài sản (ROA)	Tỷ suất lợi nhuận trên tài sản, đo lường khả năng sử dụng tài sản của công ty để tạo ra lợi nhuận
Chỉ số thanh khoản nhanh (Quick Ratio)	Đo khả năng thanh toán nợ ngắn hạn mà không cần bán hàng tồn kho, phản ánh khả năng đáp ứng nghĩa vụ tài chính của công ty.

Nguồn: Tác giả tổng

hợp

2.2.3. Chỉ số vĩ mô

Chỉ số vĩ mô là những yếu tố tác động đến toàn bộ nền kinh tế và có ảnh hưởng sâu rộng đến thị trường chứng khoán. Những thay đổi trong các yếu tố này có thể tạo ra

sự biến động lớn trong giá cổ phiếu do chúng ảnh hưởng đến tâm lý của các nhà đầu tư và môi trường kinh tế toàn cầu.

Bảng 2-3: Bảng các yếu tố vĩ mô

Yếu tố vĩ mô	Ý nghĩa
Tỷ giá hối đoái (Exchange Rate)	Là sự thay đổi giá trị giữa các đồng tiền của các quốc gia khác nhau, ảnh hưởng đến xuất khẩu, nhập khẩu và lợi nhuận của công ty
Lạm phát (Inflation)	Mức độ tăng giá chung của hàng hóa và dịch vụ, có thể ảnh hưởng đến chi phí sản xuất, tiêu dùng và lợi nhuận doanh nghiệp.
Lãi suất (Interest Rate)	Mức lãi suất do ngân hàng trung ương quy định, tác động đến chi phí vay vốn và quyết định đầu tư của doanh nghiệp và nhà đầu tư

Nguồn: Tác giả tổng hợp

2.2.4. Các biến số khác

Ngoài các yếu tố tài chính và vĩ mô, một số nghiên cứu cũng xem xét các nguồn dữ liệu không truyền thống như tin tức tài chính, thông báo đặc biệt, hoặc dữ liệu từ các nền tảng mạng xã hội. Những dữ liệu này có thể giúp phản ánh cảm xúc thị trường và những sự kiện bất ngờ có tác động mạnh đến giá cổ phiếu.

Bảng 2-4: Các biến số khác

Biến số khác	Ý nghĩa
Tin tức tài chính (Financial News)	Tin tức về công ty, ngành nghề hoặc nền kinh tế có thể ảnh hưởng lớn đến giá cổ phiếu
Thông báo đặc biệt (Ad hoc Announcements)	Các thông báo bất ngờ từ công ty hoặc chính phủ, chẳng hạn như thông báo hợp tác mới, thay đổi trong quản lý, hay quyết định chính sách của ngân hàng trung ương.
Dữ liệu từ email và mạng xã hội	Dữ liệu từ email và mạng xã hội có thể phản ánh cảm xúc thị trường, ảnh hưởng mạnh đến giá cổ phiếu.

Nguồn: Tác giả tổng

hợp

2.3. Tổng quan về Machine learning

2.3.1. Khái niệm Machine learning

Nghiên cứu các kỹ thuật cho phép máy tính thực hiện một hoạt động nhất định mà không cần lập trình nhiều được gọi là học máy (Mahesh, B, 2020). Học máy được sử dụng để nâng cao hiệu quả xử lý dữ liệu của máy tính. Nhiều ứng dụng, bao gồm khai thác dữ liệu, xử lý hình ảnh và dự đoán tương lai, sử dụng các phương pháp học máy. Lợi ích chính của học máy là khả năng tự động hoạt động sau khi đã học cách phân tích dữ liệu đầu vào.

Theo Ryabtsev, A (2024), trí tuệ nhân tạo và học máy là những phát triển mới nhất trong ngành công nghệ thông tin. Các nhà phát triển đang mở rộng kỹ năng và sức mạnh của các mô hình học máy và trí tuệ nhân tạo để áp dụng vào nhiều lĩnh vực khác nhau, bao gồm tài chính, xã hội và y tế, mặc dù các cuộc tranh luận về tính an toàn của sự phát triển này ngày càng gia tăng. Với khối lượng và cường độ ngày càng tăng, chúng được sử dụng rộng rãi để xử lý và phân tích khối lượng lớn dữ liệu, hỗ trợ giải quyết các vấn đề mà con người không còn có thể hoàn thành bằng tay.

Một trong những ứng dụng phổ biến nhất của trí tuệ nhân tạo và học máy trên thị trường chứng khoán hiện nay là khả năng phân tích dữ liệu để tạo ra các chỉ số đại diện cho thị trường và dự đoán giá cổ phiếu. Những công cụ này giúp người dùng hiểu các xu hướng biến động, phát triển các chiến lược phù hợp và xác định các giải pháp hiệu quả hơn. Kubat (2017) định nghĩa học máy là quá trình rút ra kết luận từ dữ liệu. Là một lĩnh vực con của trí tuệ nhân tạo (AI), học máy cho phép máy tính học hỏi từ kinh nghiệm và cải thiện bản thân mà không cần lập trình lại chuyên biệt cho từng nhiệm vụ.

Để phân tích và rút ra kiến thức từ dữ liệu, học máy sử dụng các mô hình và thuật toán thống kê. Mahesh, B (2020) phân loại các kỹ thuật này thành ba loại chính:

Học Có Giám Sát: Trong học máy, học có giám sát là quá trình mà một hệ thống học cách liên kết các biến đầu vào và đầu ra bằng cách sử dụng các cặp dữ liệu. Mỗi mẫu dữ liệu đầu vào đều có một đầu ra mong muốn liên quan, vì mô hình được huấn luyện trên một tập dữ liệu mẫu. Tập dữ liệu đầu vào được chia thành tập huấn luyện và tập kiểm tra, và các thuật toán học máy có giám sát cần sự trợ giúp bên ngoài. Tập huấn luyện chứa các biến đầu ra mà chúng ta phải phân loại hoặc dự đoán. Sau khi học từ các mẫu trong tập huấn luyện, các thuật toán sử dụng những gì đã học để dự đoán hoặc phân loại tập kiểm tra. Các phương pháp học máy có giám sát bao gồm Support Vector Machine và Decision Tree.

Học Không Có Giám Sát: Khi một mô hình được huấn luyện trên một tập dữ liệu không có đầu ra—tức là chỉ có dữ liệu đầu vào—học không có giám sát xảy ra. Các thuật toán tự do khám phá cấu trúc của dữ liệu mà không có sự trợ giúp. Chúng xác định lớp dữ liệu khi dữ liệu mới được trình bày bằng cách sử dụng những đặc điểm đã học trước đó. Hai ứng dụng chính của học không có giám sát là phân cụm và giảm chiều. Mục tiêu của phương pháp này là tìm ra một cấu trúc hoặc mẫu nhất định trong dữ liệu đã chuẩn bị—chẳng hạn như nhóm các điểm dữ liệu có đặc điểm liên quan hoặc giảm chiều dữ liệu. Một phương pháp là giảm chiều dữ liệu hình ảnh bằng cách nhóm khách hàng theo thói quen mua sắm của họ. Các thuật toán nổi tiếng bao gồm Phân Tích Thành Phần Chính (Principal Component Analysis), Phân Cụm K-Means, và nhiều thuật toán khác.

Học Tăng Cường: Cùng với học có giám sát và học không có giám sát, học tăng cường là một trong ba mô hình cơ bản của học máy. Khi một tác nhân học cách tương tác với môi trường của nó theo cách tối ưu hóa khả năng định dạng và phân tích dữ liệu thu thập theo thời gian, nó được coi là đang sử dụng học tăng cường. Mô hình này học thông qua nhiều lần thử và sai, nhận phản hồi dưới dạng phần thưởng hoặc hình phạt, và điều chỉnh hành vi của chính nó để đạt được kết quả tối ưu.

Một ứng dụng điển hình của học tăng cường có thể được mô tả qua các trò chơi điện tử, giúp phát triển các mô hình có khả năng chơi và chiến thắng trong cờ vua và cờ vây. Học tăng cường cũng được áp dụng trong lĩnh vực robot để dạy cho các robot tự động cách di chuyển và tránh những chướng ngại vật mà chúng thường gặp phải ở nhiều mức độ khác nhau.

Quá trình chuẩn bị dữ liệu là rất quan trọng để tối đa hóa hiệu suất dự đoán của các thuật toán học máy. Quy trình này bắt đầu bằng việc thu thập và lựa chọn dữ liệu chuỗi thời gian tài chính, bao gồm giá cổ phiếu, lợi nhuận, hoặc các thông tin liên quan khác trong một khoảng thời gian nhất định.

Dữ liệu liên quan trước tiên phải được tiền xử lý, bao gồm việc làm sạch và loại bỏ bất kỳ thông tin thừa hoặc thiếu sót nào. Sau đó, dữ liệu chuỗi thời gian cơ bản, bao gồm giá đóng cửa, có thể được sử dụng để tính toán các chỉ số kỹ thuật. Sau khi thu thập dữ liệu "sạch", bao gồm các chỉ số kỹ thuật, dữ liệu sẽ trải qua quá trình tiền xử lý bổ sung thông qua chuẩn hóa và giảm chiều, bao gồm lựa chọn đặc trưng, trích xuất đặc trưng và tạo đặc trưng nhằm xác định các biến liên quan và loại bỏ những biến không cần thiết.

2.3.2. Mô hình học máy

2.3.2.1. LSTM (Long Short-Term Memory)

LSTM (Long Short-Term Memory) là một loại mạng nơ-ron hồi quy (RNN) được phát triển nhằm khắc phục một trong những nhược điểm lớn nhất của các RNN truyền thống: vấn đề về độ dốc biến mất khi xử lý các chuỗi đầu vào dài. Theo Hochreiter, S. and Schmidhuber, J., (1997), LSTM được thiết kế để quản lý và lưu trữ thông tin một cách chọn lọc thông qua các thành phần như cổng đầu vào, cổng đầu ra và cổng quên. Điều này cho phép mô hình quyết định thông tin nào nên được giữ lại hoặc loại bỏ trong quá trình huấn luyện, từ đó nâng cao khả năng nhận diện các mẫu dài hạn trong dữ liệu. LSTM bao gồm các ô nhớ, giúp lưu trữ thông tin qua các bước thời gian, và các cổng điều khiển, quản lý luồng thông tin vào và ra. Các thành phần chính của kiến trúc LSTM bao gồm:

- Cell State (Trạng thái bộ nhớ): Đây là thành phần trung tâm của LSTM, giữ lại thông tin dài hạn qua các bước thời gian. Cell state hoạt động như một "đường cao tốc," cho phép thông tin được truyền đi với sự thay đổi tối thiểu nhờ vào các cổng điều khiển. Các cổng (Forget, Input, Output) giúp thêm, xóa hoặc điều chỉnh thông tin trong cell state

- Các cổng điều khiển: Các cổng trong LSTM điều chỉnh luồng thông tin bằng cách sử dụng các phép nhân và cộng ma trận, kết hợp với hàm kích hoạt sigmoid, với đầu ra nằm trong khoảng từ 0 đến 1. Bao gồm:

+ Forget Gate (Cổng quên): Quyết định loại bỏ một số phần dữ liệu trong trạng thái bộ nhớ. Để điều chỉnh mức độ giữ lại thông tin, cổng quên tạo ra một giá trị f_t (từ 0 đến 1) dựa trên đầu vào hiện tại và trạng thái ẩn trước đó.

+ Input Gate (Cổng đầu vào): Chọn dữ liệu mới sẽ được thêm vào trạng thái bộ nhớ từ đầu vào hiện tại. Để xác định mức độ mà thông tin mới được thêm vào cell state, cổng này tạo ra một vector thông tin mới C và một trọng số i_t .

+ Output Gate (Cổng đầu ra): Xác định các thành phần của trạng thái bộ nhớ sẽ được sử dụng để tạo ra đầu ra tại thời điểm hiện tại. Để điều chỉnh đầu ra cuối cùng h_t , cổng này tạo ra một trọng số o_t .

- Hidden State (Trạng thái ẩn): Là dữ liệu tạm thời được sử dụng làm đầu vào cho giai đoạn tiếp theo và để tạo ra kết quả tại mỗi bước thời gian. Cổng đầu ra và trạng thái bộ nhớ được sử dụng để tính toán trạng thái ẩn..

- Hàm kích hoạt:

+ Hàm sigmoid (σ): Được sử dụng trong các cổng điều khiển (Forget, Input, Output) để tạo trọng số điều chỉnh (giá trị từ 0 đến 1).

+ Hàm tanh: Được sử dụng để tạo ra thông tin mới (C) và điều chỉnh giá trị của cell state và hidden state (đầu ra nằm trong khoảng -1 đến 1).

LSTM đã được ứng dụng sớm để giải quyết các vấn đề chuỗi thời gian và đã chứng minh hiệu quả vượt trội, đặc biệt trong các lĩnh vực phức tạp như tài chính. Theo Fischer & Krauss (2018), LSTM có khả năng xử lý và phát hiện các mẫu ẩn trong dữ liệu tài chính, cho phép nó nắm bắt cả biến động thị trường ngắn hạn và dài hạn trong lĩnh vực dự đoán giá cổ phiếu. Phương pháp này giúp các nhà đầu tư đưa ra dự đoán chính xác hơn về xu hướng giá cổ phiếu so với các kỹ thuật truyền thống.

Ngoài ra, theo Chen & Guestrin (2019), LSTM thường được kết hợp với các mô hình khác như mạng nơ-ron tích chập (CNN) hoặc tự mã hóa (autoencoder) để nâng cao hiệu quả dự đoán trong các bài toán phức tạp. Sự kết hợp này cho phép mô hình nắm bắt tốt hơn các đặc điểm đa dạng và phức tạp của dữ liệu tài chính, từ đó đưa ra các dự đoán chính xác và đáng tin cậy hơn.

2.3.2.2. Transformer

Transformer là một loại mạng nơ-ron sâu sử dụng cơ chế tự chú ý để xử lý dữ liệu tuần tự, chẳng hạn như văn bản hoặc chuỗi dữ liệu. Kiến trúc này đã thể hiện hiệu suất xuất sắc trong nhiều tác vụ xử lý ngôn ngữ tự nhiên (NLP) cũng như trong các lĩnh vực khác. Kể từ khi ra mắt vào năm 2017, khả năng của Transformer trong việc mô hình hóa ngữ cảnh toàn cục đã giúp nó trở thành nền tảng cho nhiều mô hình học máy tiên tiến. Khác với các mô hình truyền thống như RNN hay LSTM, Transformer cho phép tính toán song song trên toàn bộ chuỗi, từ đó tăng tốc độ và hiệu suất xử lý.

Mô hình Transformer được cấu thành từ các thành phần cơ bản cho phép nó khám phá những mối liên kết ngữ nghĩa phức tạp và xử lý các chuỗi dữ liệu một cách hiệu quả. Các thành phần này bao gồm:

- Embedding:
 - Token Embedding: Các token được biểu diễn dưới dạng vector số học.
 - Positional Embedding: Cung cấp thông tin về vị trí để giữ thứ tự của chuỗi.
- Attention:
 - Self-Attention: Xác định mức độ quan trọng tương đối của các token trong chuỗi.

- Multi-Head Attention: Học các mối quan hệ khác nhau bằng cách sử dụng nhiều khối attention.
- Feed-Forward Network (FFN): Một mạng nơ-ron kết nối hoàn toàn, tạo ra các biểu diễn mới bằng cách xử lý từng token một cách độc lập.
- Normalization và Dropout:
 - Layer Normalization: Giúp ổn định quá trình huấn luyện.
 - Dropout: Giảm hiện tượng overfitting bằng cách loại bỏ ngẫu nhiên các kết nối.
- Encoder và Decoder:
 - Encoder: Gồm nhiều lớp self-attention và FFN, học từ chuỗi đầu vào.
 - Decoder: Dự đoán đầu ra bằng cách kết hợp thông tin từ self-attention và encoder.

Sự kết hợp của các thành phần này tạo nên sức mạnh và hiệu quả của mô hình Transformer trong việc xử lý ngôn ngữ tự nhiên.

2.3.2.3. Random Forest:

Mô hình học có giám sát Random Forest sử dụng thuật toán cây quyết định (Decision Tree) làm nền tảng. Trong mô hình này, các cây quyết định được huấn luyện trên một tập con ngẫu nhiên của bộ dữ liệu. Kết quả cuối cùng được tạo ra bằng cách kết hợp đầu ra từ nhiều cây khác nhau. Đối với các bài toán phân loại, kết quả cuối cùng của Random Forest (RF) sẽ được xác định dựa trên "bầu cử" của các cây quyết định. Tuy nhiên, vì mục tiêu của nghiên cứu là cung cấp các giá trị liên tục, mô hình sẽ đưa ra kết quả cuối cùng là giá trị trung bình của các giá trị mà các cây quyết định dự đoán.

Cây quyết định đầu tiên chia tập dữ liệu theo các giá trị của các đặc điểm (features) chứa thông tin quan trọng nhất về biến mục tiêu. Các đặc điểm này giúp tạo ra các tập con "thuần khiết" nhất có thể.

Thông thường, một cây bao gồm một nút gốc, các nút nội tại và các nút lá được nối với nhau bằng các nhánh. Qua đó, mô hình sẽ học được cấu trúc cơ bản của dữ liệu huấn luyện và có khả năng dự đoán các giá trị chưa biết bằng cách suy đoán các đặc điểm của chúng.

Một nhược điểm lớn của cây quyết định là có xu hướng overfit (quá khớp) với dữ liệu huấn luyện. Do đó, cần phải có một tập hợp lớn các cây quyết định để tìm và tách thành nhiều tập dữ liệu "thuần khiết". Về cơ bản, Random Forest là một tập hợp các cây quyết định, mỗi cây có sự khác biệt nhất định so với các cây khác.

Khi mô hình "trồng" nhiều cây, thuật toán RF đảm bảo rằng mỗi cây hoạt động độc lập với nhau và lựa chọn một tập huấn luyện riêng cho mỗi cây. Vì vậy, việc quyết định số lượng cây cần "trồng" trong "khu rừng ngẫu nhiên" này là rất quan trọng.

Nhờ vào tính "dân chủ" của mô hình và số lượng tham gia lớn, RF được coi là một phương pháp chính xác và mạnh mẽ. Vấn đề overfitting được giảm thiểu do RF lấy trung bình tất cả các dự đoán, từ đó loại bỏ các sai số. Tuy nhiên, khối lượng tính toán sẽ tăng lên khi số lượng cây tăng, và nếu "khu rừng" trở nên quá dày, mô hình RF có thể trở nên chậm và tốn thời gian hơn.

Trong một "khu rừng", mỗi cây sẽ đưa ra các dự đoán khá chính xác, mặc dù một số dữ liệu có thể bị overfit. Bằng cách lấy trung bình các dự đoán của nhiều cây, tất cả chúng có thể hoạt động tốt và nổi bật theo nhiều cách khác nhau, từ đó giúp giảm thiểu hiện tượng overfitting.

2.3.2.4. XGBoost

XGBoost là một trong những thuật toán machine learning phổ biến và mạnh mẽ nhất, đặc biệt hiệu quả với các tập dữ liệu lớn và phức tạp. Được phát triển dựa trên phương pháp tăng cường (boosting), XGBoost cải thiện hiệu suất dự đoán bằng cách kết hợp các cây quyết định yếu thành một mô hình mạnh mẽ. Theo Chen & Guestrin (2016), XGBoost đã tối ưu hóa tốc độ và độ chính xác bằng cách sử dụng các chiến lược tính toán song song và quản lý bộ nhớ hiệu quả, khiến cho mô hình này phù hợp với các ứng dụng thực tế và các cuộc thi yêu cầu hiệu suất cao.

XGBoost sử dụng một tập hợp các cây quyết định để cải thiện độ chính xác của dự đoán và được xây dựng dựa trên kỹ thuật tăng cường cây gradient. Các bước chính trong hoạt động của nó bao gồm điều chỉnh độ phức tạp, giúp ngăn chặn hiện tượng overfitting bằng cách phạt các mô hình quá phức tạp, và một hàm mục tiêu có điều chỉnh $L(\theta)$, bao gồm hàm lỗi đo lường sự khác biệt giữa giá trị thực y_i và giá trị dự đoán $\hat{y}_i$. Bước tiếp theo là xây dựng cây quyết định. XGBoost sử dụng kỹ thuật tối ưu hóa bậc hai khi xây dựng cây quyết định. Cụ thể, XGBoost tận dụng các đạo hàm bậc nhất và bậc hai (gradient và hessian) để tối ưu hóa hàm mục tiêu một cách nhanh chóng và chính xác hơn. Phương pháp này đảm bảo rằng các cây quyết định được xây dựng một cách hiệu quả và cải thiện hiệu suất của mô hình. Sử dụng thuật toán greedy để tìm điểm chia tốt nhất dựa trên giảm thiểu lỗi.

Để ngăn ngừa overfitting:

- Giảm ảnh hưởng (Shrinkage): Để cho phép các cây sau có thể cải thiện dần dần mô hình, XGBoost sử dụng một hệ số học η để giảm trọng số của các cây mới.
- Chọn ngẫu nhiên đặc trưng (Column Subsampling): Để giảm thiểu hiện tượng overfitting và tăng tốc độ tính toán, XGBoost

chọn một tập con các đặc trưng tại mỗi giai đoạn trong quá trình xây dựng cây.

Cải tiến hệ thống bao gồm việc Xử lý dữ liệu thừa: Phương pháp nhận diện giá trị thiếu và thiết lập hướng mặc định trong cây của XGBoost cho phép nó xử lý dữ liệu thừa. Tối ưu hóa bộ nhớ: Các phương pháp prefetching giúp giảm thiểu lỗi đọc/ghi bộ nhớ. Cuối cùng, Xử lý dữ liệu ngoài bộ nhớ: Để xử lý các tập dữ liệu lớn hơn bộ nhớ chính, XGBoost sử dụng các thuật toán nén và chia nhỏ dữ liệu.

Với yêu cầu dữ liệu linh hoạt và khả năng xử lý dữ liệu đa chiều, XGBoost là một công cụ quan trọng trong lĩnh vực dự đoán giá cổ phiếu. Theo (Zhang và Cộng Sự (2020), XGBoost có khả năng phân tích các yếu tố ảnh hưởng đến giá cổ phiếu và điều chỉnh mô hình để phù hợp với những biến động lớn trên thị trường, từ đó đưa ra những dự đoán khá chính xác về xu hướng giá trong tương lai. Nhờ tính linh hoạt cao, XGBoost không chỉ hỗ trợ trong việc phân tích xu hướng mà còn dự đoán các sự kiện tài chính quan trọng, trở thành một công cụ thiết yếu trong các mô hình phân tích cổ phiếu.

2.4. Lược khảo các nghiên cứu liên quan

2.4.1. Các nghiên cứu nước ngoài

Để dự đoán lợi suất chỉ số chứng khoán, Kumar & Thenmozhi, 2014 đã phát triển ba mô hình khác nhau kết hợp mô hình tuyến tính ARIMA với các mô hình phi tuyến như máy vector hỗ trợ (SVM), mạng nơ-ron nhân tạo (ANN) và rừng ngẫu nhiên (RF). Hiệu suất của các mô hình ARIMA-SVM, ARIMA-ANN và ARIMA-RF đã được so sánh với hiệu suất của các mô hình ARIMA, SVM, ANN và RF độc lập. Thông qua một phương pháp giao dịch, các mô hình cạnh tranh đã được đánh giá dựa trên các chỉ số thống kê và tiêu chí hiệu suất giao dịch. Theo cuộc điều tra, mô hình lai

ARIMA-SVM là mô hình dự đoán hiệu quả nhất để đạt được độ chính xác dự đoán cao hơn và lợi suất tốt hơn.

Cao và Cộng Sự (2019) đã dự đoán xu hướng giá cổ phiếu bằng cách sử dụng các kỹ thuật mạng phức tạp và học máy. Ban đầu, tác giả đã đề xuất một phương pháp mới để xây dựng các mạng mô hình cho chuỗi thời gian cổ phiếu đa biến. Các mô hình đã tạo ra các mạng có hướng có trọng số bằng cách kết hợp các biến động giá của Chỉ số Dow Jones (DIA), NASDAQ và Chỉ số Standard & Poor's 500 (S&P 500). Những yếu tố này sau đó được sử dụng làm biến đầu vào cho các thuật toán máy vector hỗ trợ (SVM) và K-lân cận (KNN) để dự đoán các biến động giá của một cổ phiếu cụ thể vào ngày tiếp theo. Các phát hiện cho thấy thuật toán SVM vượt trội hơn so với phương pháp KNN về khả năng dự đoán.

Nghiên cứu "Dự đoán giá đóng cửa cổ phiếu bằng các kỹ thuật học máy" đã sử dụng hai mô hình, ANN và Random Forest, để dự đoán giá cổ phiếu cho ngày tiếp theo, theo *Mehar Vijh và Cộng Sự (2020)*. Các mô hình đã sử dụng các chỉ số như giá mở cửa, giá đóng cửa, giá cao nhất và giá thấp nhất làm dữ liệu đầu vào. Các phát hiện cho thấy độ tin cậy của cả hai mô hình trong việc dự đoán giá cổ phiếu ngắn hạn, với RMSE (Sai số bình phương trung bình) và MAPE (Sai số phần trăm tuyệt đối trung bình) thấp và độ chính xác cao. Nghiên cứu này không chỉ chứng minh rằng các mô hình học máy có khả năng dự đoán giá cổ phiếu tốt, mà còn gợi ý rằng các mô hình phức tạp hơn có thể tạo ra những dự đoán chính xác hơn, giúp các nhà đầu tư đưa ra quyết định tốt hơn.

Nhìn chung, các nghiên cứu đều chỉ ra rằng việc ứng dụng các kỹ thuật học máy và mô hình phức tạp trong dự đoán giá cổ phiếu và lợi suất chỉ số chứng khoán có khả năng mang lại độ chính xác cao và hiệu suất tốt hơn so với các phương pháp truyền thống. Cụ thể, các mô hình như ANN, Random Forest, SVM, và các mô hình lai như

ARIMA-SVM đều cho thấy tiềm năng trong việc giúp các nhà đầu tư đưa ra quyết định chính xác hơn dựa trên các chỉ số và dữ liệu lịch sử.

2.4.2. Các nghiên cứu trong nước

Lê Văn Tuấn và Cộng Sự (2021) đã sử dụng một số mô hình và thuật toán học máy để dự đoán xu hướng biến động (tăng/giảm) của chỉ số chứng khoán Việt Nam. Kết quả nghiên cứu cho thấy mô hình KNN(10) vượt trội hơn so với các mô hình khác, bao gồm Hồi quy Logistic, Phân tích phân biệt tuyến tính (LDA), Phân tích phân biệt toàn phương (QDA) và K-Nearest Neighbours (KNN), với độ chính xác khoảng 55,6%.

Vu Thi Loan và Cộng Sự (2023) cho rằng nghiên cứu "Dự đoán giá cổ phiếu trước các thông tin tài chính và phi tài chính: Áp dụng phân tích Event Study và Random Forest" đã xem xét cách thị trường phản ứng trước các loại thông tin khác nhau bằng cách kết hợp phân tích Event Study với thuật toán Random Forest. Nghiên cứu tập trung vào cả dữ liệu phi tài chính (như tin tức vĩ mô và sự kiện chính trị) và tài chính (như lợi nhuận và doanh thu). Kết quả cho thấy lợi nhuận bất thường cao hơn đối với thông tin phi tài chính, trong khi biến động giá cổ phiếu có thể được dự đoán từ các chỉ số tài chính, vốn hóa thị trường và các yếu tố kinh tế vĩ mô, khẳng định vai trò quan trọng của các yếu tố bên ngoài trong việc dự đoán giá cổ phiếu.

Nghiên cứu “Dự đoán chỉ số chứng khoán bằng học máy: Bằng chứng thực nghiệm từ thị trường chứng khoán Việt Nam” do Đào Lê Kiều Oanh và Nguyễn Thị Minh Châu (2024) thực hiện nhằm đánh giá hiệu suất so sánh của các mô hình LSTM và các Mạng Convolutional Thời gian (TCN) trong việc dự đoán biến động của chỉ số VNIndex. Trong nghiên cứu này, các nhà nghiên cứu đã sử dụng hai mô hình dự đoán chuỗi thời gian nổi tiếng, LSTM và TCN, để đo lường hiệu quả của từng mô hình trong việc dự đoán biến động của chỉ số VNIndex. Dữ liệu cho thấy mô hình LSTM vượt trội hơn TCN về hiệu suất dự đoán, từ đó cung cấp cho các nhà đầu tư và quản lý quỹ một

cơ sở khoa học vững chắc cho các quyết định đầu tư của họ. Phát hiện này chứng tỏ rằng, trong bối cảnh dữ liệu chuỗi thời gian, LSTM có thể là một công cụ hiệu quả hơn cho việc dự đoán chứng khoán so với TCN, đặc biệt khi cần xem xét các yếu tố ngẫu nhiên và biến động phức tạp của thị trường Việt Nam.

Kết luận từ ba nghiên cứu trên cho thấy rằng việc áp dụng các mô hình học máy trong dự đoán biến động của thị trường chứng khoán Việt Nam là rất hiệu quả, với từng mô hình mang lại những ưu điểm riêng. Mô hình KNN(10) được xác định là có độ chính xác cao trong việc dự đoán xu hướng chỉ số chứng khoán, trong khi LSTM vượt trội hơn TCN trong việc dự đoán biến động của chỉ số VNIndex. Đồng thời, nghiên cứu của *Vu Thi Loan và Cộng Sự (2023)* khẳng định rằng cả thông tin tài chính và phi tài chính đều đóng vai trò quan trọng trong việc dự đoán giá cổ phiếu. Từ đó, có thể khẳng định rằng việc kết hợp nhiều phương pháp và dữ liệu là cần thiết để nâng cao độ chính xác và hiệu quả trong dự đoán trên thị trường chứng khoán.

Bảng 2-5: Tổng hợp các nghiên cứu liên quan

Tác giả	Tên đề tài	Phương pháp nghiên cứu	Kết quả nghiên cứu
(Kumar & Thenmozhi, 2014)	“Dự đoán lợi nhuận chỉ số cổ phiếu sử dụng các mô hình kết hợp ARIMA-SVM, ARIMA-ANN và ARIMA-Random	Sử dụng kết hợp mô hình tuyến tính ARIMA với các mô hình phi tuyến như máy vector hỗ trợ (SVM), mạng nơ-ron nhân tạo	mô hình lai ARIMA-SVM là mô hình dự đoán hiệu quả nhất để đạt được độ chính xác dự đoán cao hơn và lợi suất tốt hơn.

	Forest”	(ANN) và rừng ngẫu nhiên (RF)	
<i>Cao và Cộng Sự (2019)</i>	“Dự đoán mô hình giá cổ phiếu dựa trên kỹ thuật mạng phức tạp (Complex Network) và học máy (Machine learning)”	Tác giả xây dựng các mạng mô hình cho chuỗi thời gian cổ phiếu đa biến với các mô hình học máy như: máy vector hỗ trợ (SVM) và K-lân cận (KNN)	Các phát hiện cho thấy thuật toán SVM vượt trội hơn so với phương pháp KNN về khả năng dự đoán
<i>Mehar Vijh và Cộng Sự (2020)</i>	“Dự đoán giá đóng cửa cổ phiếu bằng cách sử dụng các kỹ thuật học máy”	Sử dụng hai mô hình học máy là Random Forest và Mạng nơ – ron nhân tạo (ANN)	Các phát hiện cho thấy độ tin cậy của cả hai mô hình trong việc dự đoán giá cổ phiếu ngắn hạn, với RMSE (Sai số bình phương trung bình) và MAPE (Sai số phần trăm tuyệt đối trung bình) thấp và độ chính xác cao
<i>Lê Văn Tuấn và Cộng Sự (2021)</i>	“Ứng dụng một số mô hình học máy trong dự đoán chiều biến	Sử dụng các mô hình học máy: Hồi quy Logistic, Phân tích phân	Kết quả nghiên cứu cho thấy mô hình KNN(10) vượt trội hơn so với các mô hình khác với độ chính

	động của thị trường chứng khoán Việt Nam”	biệt tuyến tính (LDA), Phân tích phân biệt toàn phương (QDA) và K-Nearest Neighbours (KNN)	xác khoảng 55,6%
<i>Vu Thi Loan và cộng sự (2023)</i>	“Dự đoán giá cổ phiếu trước các thông tin tài chính và phi tài chính: Áp dụng phân tích Event Study và Random Forest”	Kết hợp phân tích Event Study với thuật toán Random Forest	Kết quả cho thấy lợi nhuận bất thường cao hơn đối với thông tin phi tài chính, trong khi biến động giá cổ phiếu có thể được dự đoán từ các chỉ số tài chính, vốn hóa thị trường và các yếu tố kinh tế vĩ mô
Đào Lê Kiều Oanh và Nguyễn Thị Minh Châu (2024)	“Dự đoán chỉ số chứng khoán bằng học máy: Bằng chứng thực nghiệm từ thị trường chứng khoán Việt Nam”	đánh giá hiệu suất so sánh của các mô hình LSTM và các Mạng Convolutional Thời gian (TCN) trong việc dự đoán biến động	LSTM cho thấy hiệu suất dự đoán tốt hơn TCN trong dự đoán biến động chỉ số VNIndex, giúp các nhà đầu tư và quản lý quỹ ra quyết định chính xác hơn

		của chỉ số VNIndex	
--	--	-----------------------	--

Nguồn: Tác giả tổng hợp

2.5. Khoảng trống nghiên cứu

Dựa trên các nghiên cứu trong và ngoài nước đã trình bày, có thể thấy rằng dù đã có nhiều nỗ lực trong việc ứng dụng các mô hình học máy vào dự đoán giá cổ phiếu, vẫn tồn tại một số khoảng trống nghiên cứu quan trọng. Trước hết, các nghiên cứu nước ngoài chủ yếu tập trung vào các mô hình dự đoán hiện đại như LSTM, XGBoost, và LightGBM nhưng thường áp dụng trong bối cảnh thị trường quốc tế hoặc các thị trường phát triển. Điều này tạo ra một khoảng trống khi chưa có nhiều nghiên cứu sâu rộng về ứng dụng các mô hình này trên thị trường Việt Nam, nơi có tính đặc thù cao và dễ bị ảnh hưởng bởi các yếu tố kinh tế vĩ mô và chính sách quản lý nhà nước. Phần lớn các nghiên cứu trong nước thường tập trung vào chỉ số VNIndex chung, mà chưa đi sâu vào phân tích riêng biệt cho các nhóm ngành, đặc biệt là ngành ngân hàng, vốn có sự tương tác phức tạp với các yếu tố vĩ mô như lãi suất, tỷ giá và lạm phát.

Từ những khoảng trống trên, có thể thấy rằng việc phát triển một mô hình dự đoán giá cổ phiếu cho ngành ngân hàng tại Việt Nam, kết hợp các yếu tố tài chính với các mô hình tiên tiến và tối ưu hóa, sẽ đóng góp đáng kể cho lĩnh vực này.

KẾT LUẬN CHƯƠNG 2

Chương 2 đã trình bày các nền tảng lý thuyết và tổng quan về các nghiên cứu liên quan trong và ngoài nước, tạo ra một khung vững chắc cho việc sử dụng các mô hình học máy trong việc dự đoán giá cổ phiếu của một số ngân hàng Việt Nam. Các phương pháp dự đoán đã phát triển từ những lý thuyết tài chính truyền thống đến các mô hình học máy tiên tiến như LSTM, XGBoost, Random Forest và Transformer,

chứng minh khả năng áp dụng mạnh mẽ của chúng trong những tình huống tài chính phức tạp và không ổn định.

CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Thu thập và xử lý dữ liệu

3.1.1. Thu thập dữ liệu

Dữ liệu sử dụng trong nghiên cứu này bao gồm lịch sử giá cổ phiếu của các ngân hàng đại diện, các chỉ số tài chính quan trọng, các yếu tố kinh tế vĩ mô được thu thập từ các nguồn đáng tin cậy, và thông tin về chỉ số VN-Index. Tất cả các dữ liệu này được xử lý và kết hợp nhằm phục vụ cho việc phân tích mối quan hệ giữa các yếu tố tài chính, kinh tế và thị trường trong giai đoạn nghiên cứu.

3.1.1.1. Dữ liệu lịch sử giá cổ phiếu

Dữ liệu lịch sử giá cổ phiếu của các ngân hàng được thu thập từ API Vnstock, với các mã cổ phiếu gồm ACB, BID, CTG, HDB, MBB, SSB, SHB, STB, TCB, TPB, VCB, VIB, VPB, EIB, LPB, MSB, BAB, NVB, OCB. Khoảng thời gian thu thập dữ liệu là từ ngày 01/01/2014 đến 31/12/2024. Quy trình thực hiện bao gồm việc sử dụng hàm `stock_historical_data` để lấy các thông tin như giá mở cửa, giá đóng cửa, giá cao nhất, giá thấp nhất và khối lượng giao dịch từng ngày của từng cổ phiếu trong trang web Vnstock thông thư viện trên Python. Sau khi thu thập dữ liệu, các giá trị bị thiếu được xử lý và dữ liệu thời gian được chuẩn hóa để đảm bảo tính nhất quán.

3.1.1.2. Dữ liệu chỉ số tài chính

Dữ liệu về các chỉ số tài chính, bao gồm ROA, ROE, EPS và P/E, được tác giả thu thập bằng trên Vnstock. Quy trình tải dữ liệu tài chính cho các công ty trong ngành ngân hàng bắt đầu bằng việc sử dụng hàm `listing_companies()` để lấy danh sách công ty, sau đó lọc ra các công ty thuộc ngành "Ngân hàng" có mã nhóm 'HOSE' và 'HNX'. Tiếp theo, dữ liệu tài chính theo quý được tải cho từng công ty và lưu vào một danh sách. Sau khi kết hợp các DataFrame thành một DataFrame duy nhất, thông tin dữ liệu được xem qua hàm `info()`, các chỉ mục được đặt lại và dữ liệu được lọc theo năm từ

2014 đến 2024. Cuối cùng, chọn dữ liệu, chuyển đổi sang kiểu số thực và xử lý dữ liệu thiếu bằng cách thay thế giá trị thiếu bằng giá trị trung bình.

3.1.1.3. Dữ liệu kinh tế vĩ mô

Thực hiện tải dữ liệu vĩ mô của Việt Nam từ Ngân hàng Thế giới (WB) bằng cách sử dụng thư viện `pandas_datareader` bao gồm ba chỉ số quan trọng: lạm phát (FP.CPI.TOTL.ZG), tỷ giá hối đoái (PA.NUS.FCRF), và lãi suất cho vay (FR.INR.LEND) trong khoảng thời gian từ năm 2014 đến 2024. Sau khi dữ liệu được tải thành công, các cột trong DataFrame được đặt tên lại cho dễ hiểu. Tiếp theo, toàn bộ dữ liệu được chuyển đổi sang kiểu số thực (float) để đảm bảo tính chính xác trong các phép toán. Cuối cùng, đoạn code xử lý các giá trị thiếu bằng cách thay thế chúng bằng giá trị trung bình của từng cột, nhằm cải thiện tính đầy đủ và độ tin cậy của dữ liệu.

3.1.1.4. Dữ liệu VN-Index

Quá trình thu thập dữ liệu chỉ số VNINDEX được thực hiện thông qua các bước có cấu trúc rõ ràng. Đầu tiên, biến symbol được khởi tạo với giá trị 'VNINDEX' nhằm xác định chỉ số cần thu thập dữ liệu. Tiếp theo, hàm `stock_historical_data` từ thư viện `vnstock` được sử dụng để truy xuất dữ liệu lịch sử của VNINDEX trong khoảng thời gian từ ngày 1 tháng 1 năm 2014 đến ngày 31 tháng 12 năm 2024, với độ phân giải hàng ngày (`resolution='1D'`). Toàn bộ quy trình này được bảo vệ bởi một khối `try-except`, cho phép xử lý các lỗi có thể xảy ra trong quá trình thu thập dữ liệu. Sau khi dữ liệu được thu thập thành công, các cột trong DataFrame Index được đổi tên để phản ánh rõ ràng nội dung. Cột time sau đó được chuyển đổi thành kiểu dữ liệu `datetime` nhằm tạo điều kiện thuận lợi cho việc xử lý và phân tích dữ liệu theo thời gian. Cuối cùng, dữ liệu được sắp xếp theo thứ tự thời gian và chỉ số được reset để loại bỏ các chỉ mục cũ.

3.1.2. Xử lý dữ liệu

Quá trình xử lý dữ liệu bao gồm việc tính lợi suất của cổ phiếu và tính toán các chỉ báo kỹ thuật:

- Xử lý dữ liệu giá cổ phiếu: Quá trình tính toán lợi suất cho VN-Index và các cổ phiếu được thực hiện thông qua việc đầu tiên tính lợi suất VN-Index bằng cách sử dụng phương pháp thay đổi tỷ lệ phần trăm (percentage change) trên cột Close, tạo ra một cột mới có tên VNIndex_Return trong DataFrame Index, phản ánh tỷ lệ thay đổi giá đóng cửa so với phiên giao dịch trước. Sau khi tính toán, dữ liệu VN-Index được in ra để kiểm tra, đảm bảo rằng thông tin đã được sắp xếp đúng thứ tự. Tiếp theo, đối với từng cổ phiếu trong tập dữ liệu stock_data, lợi suất hàng ngày cũng được tính toán bằng cách áp dụng phương pháp tương tự trên cột close của từng DataFrame cổ phiếu, và kết quả lợi suất hàng ngày cho mỗi cổ phiếu được in ra để kiểm tra. Quy trình này cho phép phân tích hiệu suất biến động giá của VN-Index và các cổ phiếu một cách có hệ thống và khoa học.

- Tính chỉ số Beta của các cổ phiếu: Lợi suất của các cổ phiếu được kết hợp với lợi suất VN- Index để tính chỉ số Beta, nhằm đo lường mức độ rủi ro hệ thống của từng cổ phiếu. Giá trị Beta được xác định thông qua ma trận hiệp phương sai giữa lợi suất cổ phiếu và lợi suất VN-Index, phản ánh mức độ nhạy cảm của cổ phiếu trước sự biến động của thị trường chung.

Công thức tính Beta:

$$\beta = \frac{Cov(R_i, R_m)}{Var(R_m)}$$

Trong đó:

- β : Hệ số Beta, đo lường độ nhạy của cổ phiếu i so với thị trường m
- R_i : Lợi suất hàng ngày của cổ phiếu i
- R_m : Lợi suất hàng ngày của thị trường

- $Cov(R_i, R_m)$: Hiệp phương sai giữa lợi suất cổ phiếu và lợi suất thị trường
- $Var(R_m)$: Phương sai của lợi suất thị trường
- Tính toán các chỉ báo kỹ thuật: Các chỉ báo kỹ thuật được sử dụng để phân tích xu hướng và động thái của giá cổ phiếu, bao gồm:

SMA (Simple Moving Average)

Định nghĩa: SMA là đường trung bình động đơn giản, tính bằng cách lấy trung bình cộng giá đóng cửa trong một số ngày nhất định.

Công thức:

$$SMA_n = \frac{\sum_{i=1}^n Close_i}{n}$$

Trong đó: n là số ngày (ví dụ: SMA 20 ngày và SMA 50 ngày)

EMA (Exponential Moving Average)

Định nghĩa: EMA là đường trung bình động hàm mũ, ưu tiên trọng số cao hơn cho các giá trị gần thời điểm hiện tại.

Công thức:

$$EMA_t = \alpha \times Close_t + (1 - \alpha) \times EMA_{t-1}$$

Trong đó: $\alpha = \frac{2}{n+1}$, với n là số ngày

ROC (Rate of Change)

Định nghĩa: ROC ăn mừng phần trăm thay đổi giá sau một khoảng thời gian nhất định.

Công thức:

$$ROC_n = \frac{Close_t - Close_{t-n}}{Close_{t-n}} \times 100$$

Với n là số ngày

RSI (Relative Strength Index)

Định nghĩa: RSI là chỉ báo dao động đo lường sức mạnh giá tăng và giá giảm trong một khoảng thời gian

Công thức: $RSI = 100 - \frac{100}{1+RS}$, $RS = \frac{Average\ Gain}{Average\ Loss}$

RSI thường tính cho 14 ngày

MACD (Moving Average Convergence Divergence)

Định nghĩa: MACD do sự khác biệt giữa hai đường EMA (thường là EMA. 12 và EMA 26)

Công thức: $MACD = EMA_{12} - EMA_{26}$

Đường tín hiệu là EMA 9 ngày MACD

Stochastic Oscillator

Định nghĩa: Chỉ báo này đo hướng vị trí giá đóng của hiện tại so với phạm vi giá trong một khoảng thời gian, thường dùng để đánh giá quá mua/quá bán.

Công thức: $\%K = \frac{Close - Low_{14}}{High_{14} - Low_{14}} \times 100$, $\%D = SMA_3(\%K)$

Bollinger Bands

Định nghĩa: Bollinger Bands là dải giá trên và dưới cách đường SMA một khoảng cách bằng bội số của độ lệch chuẩn.

Công thức: $Upper\ Band = SMA_{20} + 2 \times \sigma$

Với σ là độ lệch chuẩn của giá đóng cửa trong 20 ngày

ATR (Average True Range)

Định nghĩa: ATR đo lường độ biến động giá trung bình trong một khoảng thời gian.

Công thức: $TR = \max(High - Low, |High - Close_{t-1}|, |Low - Close_{t-1}|)$

$$ATR = SMA_{14}(TR)$$

OBV (On-Balance Volume)

Định nghĩa: OBV tích lũy khối lượng giao dịch dựa trên xu hướng giá, giúp đo dòng tiền vào/ra.

Công thức:

$$OBV_t = \begin{cases} OBV_{t-1} + Volume_t & \text{if } Close_t > Close_{t-1} \\ OBV_{t-1} - Volume_t & \text{if } Close_t < Close_{t-1} \\ OBV_{t-1} & \text{otherwise} \end{cases}$$

Momentum

Định nghĩa: Momentum đo lường sự thay đổi giá trong một khoảng thời gian.

Công thức: $Momentum_n = Close_t - Close_{t-n}$

Với n là số ngày

Close Lag1

Định nghĩa: Đây là giá đóng cửa của cổ phiếu trong phiên giao dịch liền trước (độ trễ 1 phiên). Biến này giúp mô hình nắm bắt được thông tin giá trong quá khứ gần nhất để dự đoán giá tương lai

Công thức: $Close_{Lag1_t} = Close_{t-1}$

Trong đó: $Close_t$ là giá đóng cửa tại phiên giao dịch t

$Close_{t-1}$ là giá đóng cửa tại phiên giao dịch trước đó

Close Lag2

Định nghĩa: Giá đóng cửa của Close Lag2 tại thời điểm t là giá đóng cửa của phiên giao dịch t-2.

Công thức: $Close_{Lag2_t} = Close_{t-2}$

Trong đó: $Close_t$ là giá đóng cửa tại phiên giao dịch t

$Close_{t-2}$ là giá đóng cửa tại phiên giao dịch trước đó 2 phiên

Close Diff

Định nghĩa: Close Diff là mức thay đổi (chênh lệch) giữa giá đóng cửa của phiên hiện tại và phiên trước đó. Biến này thể hiện xu hướng tăng/giảm của giá cổ phiếu trong ngắn hạn.

Công thức: $Close_{Diff_t} = Close_t - Close_{t-1}$

Trong đó: $Close_t$ là giá đóng cửa tại phiên giao dịch t

$Close_{t-1}$ là giá đóng cửa tại phiên giao dịch trước đó

Quá trình xử lý giá trị thiếu: Các phương pháp điền giá trị trước (forward fill) (lấy giá trị trước đó) và điền giá trị sau (backward fill) (lấy giá trị sau đó) được sử dụng để xử lý các giá trị thiếu nhằm duy trì tính toàn vẹn của dữ liệu. Phương pháp này giảm thiểu nguy cơ từ việc loại bỏ dữ liệu thiếu bằng cách đảm bảo tính liên tục và đầy đủ của dữ liệu được sử dụng trong phân tích, đồng thời lấp đầy các khoảng trống trong dữ liệu mà không làm mất thông tin quan trọng.

Thực hiện ghép nối các dữ liệu thành một tập dữ liệu duy nhất: Một tập dữ liệu tổng (final_data) kết hợp từ các chỉ số tài chính, chỉ số kỹ thuật, chỉ số kinh tế vĩ mô và dữ liệu giá cổ phiếu. Bảng dữ liệu được tổ chức theo ngày và bao gồm các thông tin quan trọng như giá cổ phiếu, các chỉ số kỹ thuật (SMA, RSI, MACD, v.v.), các tỷ lệ tài chính (ROA, ROE, EPS, P/E), các chỉ số vĩ mô (lạm phát, tỷ giá, lãi suất), và hệ số Beta đặc trưng cho từng ngân hàng. Tập dữ liệu này đóng vai trò là nền tảng cho các phân tích và mô hình dự đoán tiếp theo.

Chuẩn hóa dữ liệu: Việc chuẩn hóa Min-Max được sử dụng để đưa dữ liệu về cùng một thang đo, đảm bảo rằng các giá trị đặc trưng nằm trong khoảng $[0, 1]$. Việc này giúp các mô hình, đặc biệt là LSTM, không bị ảnh hưởng bởi những biến động lớn trong giá trị của các đặc trưng. Đây là một bước quan trọng nhằm tăng cường tính ổn định trong quá trình huấn luyện và nâng cao khả năng hội tụ của mô hình.

Chuẩn bị dữ liệu cho các mô hình: Mỗi mô hình yêu cầu một cách chuẩn bị dữ liệu đầu vào khác nhau. Để dự đoán giá cổ phiếu cho ngày tiếp theo, LSTM sử dụng phương pháp cửa sổ trượt, trong đó mỗi cửa sổ bao gồm n ngày liên tiếp (ví dụ: 20 ngày). Kỹ thuật này cho phép các mô hình học được các mối quan hệ theo chuỗi thời gian. Ngược lại, Random Forest không cần cửa sổ trượt và sử dụng dữ liệu ở dạng bảng phẳng. Điều này phù hợp với chiến lược xử lý của các mô hình dựa trên cây quyết định, vì các đặc trưng cho từng ngày được sử dụng trực tiếp để dự đoán giá cổ phiếu cho ngày đó.

3.2. Phương pháp nghiên cứu

Bốn mô hình học máy nổi tiếng—LSTM, Random Forest, XGBoost và Transformer—được sử dụng trong nghiên cứu này để dự đoán giá cổ phiếu. Việc thiết kế và tối ưu hóa từng mô hình đã được thực hiện dựa trên các đặc điểm của dữ liệu chuỗi thời gian cũng như khả năng học tập của từng thuật toán. Dữ liệu đầu vào cho mỗi mô hình đã được chuẩn bị một cách phù hợp, và quy trình huấn luyện được xây dựng một cách cẩn thận nhằm đảm bảo tính khách quan trong việc đánh giá hiệu suất. Các lý thuyết và cơ chế hoạt động của những mô hình này được trình bày chi tiết trong Chương 2.

3.2.1. Mô hình LSTM

Thực hiện việc chuẩn bị dữ liệu cho các ngân hàng bằng cách sử dụng phương pháp sliding window. Đầu tiên, nó lặp qua từng ngân hàng trong tập dữ liệu `final_data` và lọc dữ liệu tương ứng. Dữ liệu được chia thành hai phần: 80% cho tập huấn luyện và 20% cho tập kiểm tra. Sau đó, mã kiểm tra xem tất cả các đặc trưng cần thiết có tồn tại trong dữ liệu huấn luyện không. Nếu có, nó sẽ tiến hành chuẩn hóa dữ liệu bằng cách sử dụng scaler và kiểm tra xem dữ liệu đã chuẩn hóa có đủ mẫu cho kích thước cửa sổ (window size) đã định hay không. Nếu đủ, nó sẽ gọi hàm `prepare_data_with_window` để tạo ra dữ liệu đầu vào và đầu ra cho mô hình. Cuối cùng, dữ liệu đã chuẩn hóa sẽ được lưu vào một dictionary theo ngân hàng, bao gồm các thông tin như dữ liệu huấn luyện, dữ liệu kiểm tra và scaler đã được fitted. Nếu không đủ dữ liệu hoặc không tìm thấy đặc trưng hợp lệ, mã sẽ bỏ qua ngân hàng đó và thông báo lý do.

Thực hiện việc huấn luyện mô hình LSTM cho từng ngân hàng trong tập dữ liệu đã được chuẩn hóa. Đầu tiên, lấy dữ liệu đầu vào và đầu ra cho mỗi ngân hàng, xác định kích thước cửa sổ và số lượng đặc trưng. Sau đó, tiến hành xây dựng mô hình LSTM bằng cách sử dụng API Sequential và thiết lập các callback như EarlyStopping, ModelCheckpoint và ReduceLROnPlateau để cải thiện quá trình huấn luyện. Mô hình

được huấn luyện với 50 epochs và kích thước batch là 64, đồng thời thực hiện đánh giá hiệu suất bằng cách tính toán RMSE và MAPE trên tập kiểm tra.

3.2.2. Mô hình Random Forest

Chuẩn bị dữ liệu cho các ngân hàng mà không sử dụng phương pháp sliding window, nhằm phục vụ cho việc huấn luyện các mô hình Random Forest (RF). Đầu tiên, mã lặp qua từng ngân hàng, lọc dữ liệu tương ứng và chia thành tập huấn luyện (80%) và tập kiểm tra (20%) theo thời gian. Sau đó, dữ liệu được chuẩn hóa bằng cách sử dụng scaler và chỉ giữ lại các đặc trưng hợp lệ có trong dữ liệu huấn luyện. Nếu có đủ đặc trưng, đoạn mã sẽ lưu trữ dữ liệu đã chuẩn hóa vào một dictionary, trong đó đầu vào (X) không bao gồm cột giá đóng cửa (close) đã chuẩn hóa, và cột giá đóng cửa sẽ được sử dụng làm đầu ra (y).

Thiết lập và huấn luyện mô hình Random Forest cho từng ngân hàng trong tập dữ liệu đã được chuẩn bị trước. Đầu tiên, nó định nghĩa các tham số cơ bản cho mô hình Random Forest, bao gồm số lượng cây, độ sâu tối đa và trạng thái ngẫu nhiên để tái lập kết quả. Sau đó, mã lặp qua từng ngân hàng, lấy dữ liệu đầu vào và đầu ra đã chuẩn bị, đồng thời xác định các đặc trưng hợp lệ cho mô hình. Mô hình Random Forest được huấn luyện trên dữ liệu huấn luyện, và sau đó thực hiện dự đoán trên tập kiểm tra.

3.2.3. Mô hình XGBoost

Quy trình chuẩn bị dữ liệu tương tự với mô hình Random Forest. Đầu vào sử dụng dữ liệu bảng phẳng, không cần sliding window.

Đối với mô hình XGBoost thì tập dữ liệu của từng ngân hàng cũng được thiết lập và huấn luyện bằng cách cố định các hạt giống ngẫu nhiên bằng cách sử dụng `np.random.seed(42)`, `tf.random.set_seed(42)`, và `random.seed(42)` để đảm bảo rằng các kết quả huấn luyện có thể tái lập được. Sau đó, các tham số như số lượng cây

(`n_estimators`), độ sâu tối đa của cây (`max_depth`), tỷ lệ học (`learning_rate`), và các tham số liên quan đến việc chọn mẫu (`subsample`, `colsample_bytree`) được định nghĩa trong `xgb_params`. Mã lặp qua từng ngân hàng, lấy dữ liệu đầu vào và đầu ra đã chuẩn bị, xác định danh sách các đặc trưng hợp lệ và đảm bảo rằng cột giá đóng cửa (`close`) có mặt trong danh sách này. Mô hình `XGBRegressor` được khởi tạo với các tham số đã định nghĩa và được huấn luyện trên dữ liệu huấn luyện (`X_train`, `y_train`), sau đó thực hiện dự đoán trên tập kiểm tra (`X_test`). Các chỉ số đánh giá như RMSE (Root Mean Squared Error) và MAPE (Mean Absolute Percentage Error) được tính toán để đánh giá hiệu suất của mô hình.

Cuối cùng, ở cả hai mô hình Random Forest và XGBoost, giá trị thực tế (`y_test`) và giá trị dự đoán (`y_pred`) đều sẽ được ngược chuẩn hóa về giá trị gốc bằng cách sử dụng scaler đã lưu trữ trong, với các mảng giả (dummy arrays) được tạo ra để kết hợp với giá trị thực và giá trị dự đoán, đảm bảo rằng thứ tự các đặc trưng phù hợp với quá trình chuẩn hóa ban đầu từ đó làm cơ sở để so sánh.

3.3. Đánh giá hiệu suất của các mô hình

Để đánh giá hiệu suất của mô hình dự đoán sử dụng hai chỉ số phổ biến là độ lệch tuyệt đối trung bình theo phần trăm (MAPE) và độ lệch bình phương trung bình (RMSE).

Root Mean Square Error (RMSE) là căn bậc hai của MSE, thường được sử dụng để đo lường mức độ sai lệch giữa giá trị dự đoán và giá trị thực tế. RMSE càng thấp, mô hình càng chính xác.

Công thức tính RMSE:
$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n ((y_i - \hat{y}_i)^2)}$$

Trong đó:

y_i là giá trị thực tế

$\hat{y}_i$ là giá trị dự đoán, và n là số lượng dữ liệu.

Mean Absolute Percentage Error (MAPE) dùng để tính toán phần trăm sai số tuyệt đối giữa giá trị dự đoán và giá trị thực tế giúp dễ dàng so sánh hiệu suất của các mô hình.

$$\text{Công thức tính MAPE: } MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

Trong đó:

y_i là giá trị thực tế

$\hat{y}_i$ là giá trị dự đoán

n là số lượng dữ liệu.


KẾT LUẬN CHƯƠNG 3

Chương 3 đã xây dựng nền tảng dữ liệu và lựa chọn các phương pháp nghiên cứu để dự đoán giá cổ phiếu của nhiều ngân hàng Việt Nam. Quá trình nghiên cứu, bao gồm thu thập và xử lý dữ liệu cũng như ứng dụng các mô hình dự đoán, nhằm mục tiêu tạo ra các dự đoán có độ chính xác cao, phản ánh đúng những phức tạp và các yếu tố ảnh hưởng trong thị trường. Kết quả từ các mô hình này không chỉ hỗ trợ trong việc đánh giá hiệu suất mà còn cung cấp những hiểu biết sâu sắc hơn về cách mà cả các yếu tố vĩ mô và vi mô tác động đến sự biến động của giá cổ phiếu.

CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN KẾT QUẢ

4.1. Hiệu suất của các mô hình đã xây dựng

Dữ liệu giá lịch sử của các ngân hàng trong giai đoạn từ ngày 01/01/2014 đến 01/01/2024 đã cho thấy khái quát sự biến động về giá của các cổ phiếu ngành Ngân hàng. Từ dữ liệu cho thấy VCB dẫn đầu về giá trị cũng như là mức độ tăng trưởng so với các ngân hàng khác. Các ngân hàng còn lại cũng cho thấy được tiềm năng tăng trưởng ổn định. Dù vậy, các cổ phiếu trên vẫn chịu sự ảnh hưởng từ các biến động ngắn hạn trên thị trường.



Hình 4-1: Biểu đồ giá đóng cửa của các cổ phiếu

4.1.1. Hiệu suất mô hình LSTM

Sau quá trình chạy mô hình LSTM, thu được kết quả sau:

Bảng 4-1: Hiệu suất dự đoán mô hình LSTM

Ngân hàng	RMSE	MAPE
ACB	0.0290	2.36%
BID	0.0378	2.79%
CTG	0.287	3.32%
HDB	0.0439	2.92%
MBB	0.0267	2.77%
SSB	0.0748	13.84%
SHB	0.0323	5.29%
STB	0.0294	3.2%
TCB	0.0229	2.92%
TPB	0.0261	3.61%
VCB	0.0239	1.85%
VIB	0.0215	2.34%
VPB	0.0263	3.06%
EIB	0.0564	7.99%
LPB	0.2173	12.81%

MSB	0.0331	6.28%
BAB	0.0165	63.91%
NVB	0.0352	12.34%
OCB	0.0526	9.29%

Nguồn: Tác giả tổng hợp


Bảng kết quả cho thấy các chỉ số RMSE (Root Mean Square Error) và MAPE (Mean Absolute Percentage Error) của 19 ngân hàng.

Trong số các ngân hàng, VIB nổi bật với RMSE là (0.0215) và MAPE là 2.34%. Điều này cho thấy mô hình LSTM hoạt động hiệu quả trong việc dự đoán giá cổ phiếu của ngân hàng này. Nguyên nhân có thể là do dữ liệu lịch sử của MBB có tính ổn định và ít biến động, giúp mô hình dễ dàng học và đưa ra dự đoán chính xác.


Ngược lại, BAB là ngân hàng có hiệu suất kém nhất với RMSE cao (0.0165) và MAPE lên đến 63.91%. Sự chênh lệch lớn này cho thấy mô hình không thể dự đoán chính xác giá cổ phiếu của ngân hàng này. Nguyên nhân có thể liên quan đến sự biến động mạnh trong giá cổ phiếu của BAB hoặc do thiếu dữ liệu lịch sử đáng tin cậy.

Có nhiều nguyên nhân dẫn đến sự khác biệt trong hiệu suất dự đoán giữa các ngân hàng. Đầu tiên, biến động thị trường có thể ảnh hưởng lớn đến giá cổ phiếu của từng ngân hàng, đặc biệt là trong bối cảnh kinh tế không ổn định. Thứ hai, chất lượng dữ liệu lịch sử cũng đóng vai trò quan trọng; những ngân hàng có dữ liệu chất lượng cao thường có hiệu suất dự đoán tốt hơn. Thêm vào đó, chiến lược kinh doanh rõ ràng và ổn định của một ngân hàng cũng giúp giá cổ phiếu ít biến động hơn, từ đó tạo điều kiện thuận lợi cho mô hình dự đoán.


Cuối cùng, tình hình tài chính của mỗi ngân hàng cũng là yếu tố quyết định. Những ngân hàng có sức khỏe tài chính tốt thường có xu hướng giá cổ phiếu ổn định hơn, giúp mô hình dễ dàng đưa ra dự đoán chính xác. Nhìn chung, để cải thiện độ chính xác của mô hình LSTM, cần xem xét và cải thiện các yếu tố như chất lượng dữ liệu, biến động thị trường và tình hình tài chính của từng ngân hàng




Hình 4-2: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng ACB




Hình 4-3: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng CTG




Hình 4-4: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng MBB



Hình 4-5: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng VCB



Hình 4-6: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng VIB



Hình 4-7: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng BAB

4.1.2. Hiệu suất mô hình Tranformer

Bảng 4-2: Hiệu suất dự đoán mô hình Tranformer


Ngân hàng	RMSE	MAPE
ACB	0.0594	4.98%
BID	0.0892	6.96%
CTG	0.0418	5.05%
HDB	0.1445	9.86%
MBB	0.0247	2.57%
SSB	0.0663	13.01%

SHB	0.0640	10.54%
STB	0.0723	8.06%
TCB	0.0445	6.52%
TPB	0.0309	4.64%
VCB	0.0555	4.13%
VIB	0.0732	9.26%
VPB	0.0170	1.88%
EIB	0.0499	5.44%
LPB	0.3336	16.09%
MSB	0.0466	8.70%
BAB	0.0126	28.09%
NVB	0.1860	48.86%
OCB	0.0496	9.59%


Nguồn: Tác giả tổng hợp

Ngân hàng VPB nổi bật với RMSE chỉ 0.017 và MAPE 1.88%, cho thấy mô hình đã dự đoán rất gần với giá thực tế. Ngược lại, ngân hàng LPB có hiệu suất kém nhất với RMSE cao nhất là 0.3336 và MAPE lên đến 16.09%, cho thấy mô hình gặp khó khăn trong việc dự đoán giá cổ phiếu của ngân hàng này, có thể do các yếu tố nội tại hoặc biến động thị trường không được nắm bắt tốt. Đặc biệt, một số ngân hàng như


NVB và BAB có MAPE lần lượt là 48.86% và 28.09%, cho thấy mô hình không hiệu quả trong việc dự đoán giá cổ phiếu của họ, điều này có thể liên quan đến sự biến động lớn trong giá cổ phiếu hoặc thiếu dữ liệu phù hợp.




Hình 4-8: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Transformer ngân hàng VPB



Hình 4-9: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng LPB



Hình 4-10: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng NVB



Hình 4-11: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình LSTM ngân hàng BAB

4.1.3. Hiệu suất của mô hình Random Forest

Bảng 4-3: Bảng hiệu suất mô hình Random Forest

Ngân hàng	RMSE	MAPE
ACB	0.1417	8.2%
BID	0.1437	8.98%
CTG	0.0395	3.06%
HDB	0.2688	16.64%
MBB	0.0382	2.9%
SSB	0.0844	15.14%
SHB	0.0115	1.63%
STB	0.0173	1.42%
TCB	0.0152	1.78%
TPB	0.0116	1.51%
VCB	0.1822	14.18%
VIB	0.0111	1.17%
VPB	0.0157	1.69%
EIB	0.0274	3.61%

LPB	0.7060	30.08%
MSB	0.0124	1.9%
BAB	0.0353	139.27%
NVB	0.0404	17.92%
OCB	0.129	2.11%


Nguồn: Tác giả tổng hợp

Dựa trên bảng số liệu thể hiện hiệu suất của mô hình Random Forest trong dự đoán giá cổ phiếu, có sự khác biệt rõ rệt giữa các ngân hàng. Đầu tiên, xét về chỉ số RMSE, ngân hàng VIB nổi bật với chỉ số thấp nhất (0.0111), cho thấy mô hình dự đoán của ngân hàng này có độ chính xác cao nhất trong việc dự đoán giá trị thực tế. Ngược lại, ngân hàng LPB có chỉ số RMSE cao nhất (0.7060), điều này cho thấy mô hình dự đoán của ngân hàng này kém chính xác nhất, có thể do dữ liệu không ổn định hoặc đặc điểm riêng của ngân hàng. Một số ngân hàng khác như SHB, TPB, và TCB cũng có chỉ số RMSE thấp, cho thấy khả năng dự đoán tốt của họ.


Khi xem xét chỉ số MAPE, ngân hàng VIB tiếp tục khẳng định hiệu suất tốt với chỉ số chỉ 1.17%, cho thấy sai số tuyệt đối trung bình trong dự đoán là rất nhỏ. Ngược lại, ngân hàng BAB có chỉ số MAPE cao nhất (139.27%), cho thấy mô hình của ngân hàng này gặp phải mức sai số rất lớn, có thể do sự không ổn định trong dữ liệu hoặc mô hình không phù hợp. Các ngân hàng như SHB, STB, và TPB cũng đạt được chỉ số MAPE thấp, điều này cho thấy hiệu suất dự đoán của họ cũng khá tốt.

Tổng thể, ngân hàng VIB nổi bật với cả hai chỉ số RMSE và MAPE, chứng tỏ mô hình của họ hoạt động hiệu quả. Trong khi đó, ngân hàng LPB và BAB cần xem xét lại mô hình và dữ liệu của mình để cải thiện độ chính xác trong dự đoán. Những chỉ


số này cung cấp cái nhìn rõ ràng về hiệu suất của các mô hình dự đoán của từng ngân hàng và có thể giúp các nhà quản lý đưa ra quyết định cải thiện mô hình trong tương lai.




Hình 4-12: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng ACB




Hình 4-13: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng CTG




Hình 4-14: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng MBB



Hình 4-15: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng VCB



Hình 4-16: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng VIB



Hình 4-17: Biểu đồ thể hiện giá thực tế và giá dự đoán của mô hình Random Forest ngân hàng BAB

4.1.4. Hiệu suất mô hình XGBoost

Bảng 4-4: Bảng kết quả hiệu suất mô hình XGBoost

Ngân hàng	RMSE	MAPE
ACB	0.1513	8.79%
BID	0.1512	9.71%
CTG	0.0540	5.61%
HDB	0.2764	17.30%
MBB	0.0469	3.79%
SSB	0.1006	17.76%
SHB	0.0422	4.95%
STB	0.0411	4.74%
TCB	0.0212	2.55%
TPB	0.139	1.63%
VCB	0.1827	14.25%
VIB	0.0274	3.36%
VPB	0.250	2.46%
EIB	0.0641	9.96%

LPB	0.6798	29.79%
MSB	0.0199	3.46%
BAB	0.0193	74.64%
NVB	0.0431	17.99%
OCB	0.0165	2.97%

Nguồn: Tác giả tổng hợp


Đầu tiên, về chỉ số RMSE, đây là một thước đo độ chính xác của mô hình. Giá trị RMSE thấp hơn cho thấy mô hình có độ chính xác cao hơn trong việc dự đoán. Trong bảng, ngân hàng OCB dẫn đầu với RMSE thấp nhất là 0.0165, cho thấy mô hình đã dự đoán giá cổ phiếu của ngân hàng này rất chính xác. Ngược lại, ngân hàng LPB có RMSE cao nhất là 0.6798, điều này chỉ ra rằng mô hình gặp khó khăn trong việc dự đoán giá cổ phiếu của ngân hàng này, có thể do các yếu tố không lường trước được trong dữ liệu.

Tiếp theo, chỉ số MAPE cũng rất quan trọng trong việc đánh giá độ chính xác của dự đoán. MAPE cho biết độ sai lệch của dự đoán so với giá thực tế dưới dạng phần trăm, với giá trị thấp hơn thể hiện độ chính xác cao hơn. Ngân hàng TPB nổi bật với MAPE thấp nhất là 1.63%, cho thấy dự đoán của mô hình rất gần với giá thực tế. Trong khi đó, ngân hàng BAB có MAPE cao nhất lên tới 74.64%, cho thấy mô hình không thể dự đoán chính xác giá cổ phiếu của ngân hàng này, điều này có thể gây ra những rủi ro lớn cho nhà đầu tư.


Khi so sánh giữa các ngân hàng, chúng ta thấy rằng một số ngân hàng có hiệu suất dự đoán tốt hơn những ngân hàng khác. TCB, MBB, và SHB đều có RMSE và MAPE thấp, cho thấy mô hình hoạt động hiệu quả trong việc dự đoán giá cổ phiếu của

các ngân hàng này. Ngược lại, LPB và BAB có chỉ số cao hơn, cho thấy mô hình không thể phản ánh chính xác biến động giá cổ phiếu của những ngân hàng này, điều này cần được xem xét để cải thiện độ chính xác trong tương lai.


Kết quả từ mô hình XGBoost cho thấy rằng không phải tất cả các ngân hàng đều có hiệu suất dự đoán giống nhau. Các ngân hàng như TCB và TPB cho thấy khả năng dự đoán tốt hơn, trong khi LPB và BAB cần được xem xét lại để cải thiện độ chính xác của mô hình. Việc tối ưu hóa mô hình cho các ngân hàng có hiệu suất kém có thể là một bước cần thiết để nâng cao độ chính xác trong dự đoán giá cổ phiếu.




Hình 4-18: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng MBB




Hình 4-19: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng TCB




Hình 4-20: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng TPB



Hình 4-21: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng LPB



Hình 4-22: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng BAB



Hình 4-23: Biểu đồ thể hiện giá thực tế và giá dự đoán của XGBoost ngân hàng OCB

4.2. So sánh và phân tích kết quả giữa các mô hình

Bảng 4-5: Bảng so sánh kết quả hiệu suất của các mô hình

Ngân hàng	Mô hình LSTM		Mô hình Transformer		Mô hình Random		Mô hình XGBoost	
	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE	RMSE	MAPE
ACB	0.0290	2.36%	0.0594	4.98%	0.1417	8.2%	0.1513	8.79%
BID	0.0378	2.79%	0.0892	6.96%	0.1437	8.98%	0.1512	9.71%
CTG	0.287	3.32%	0.0418	5.05%	0.0395	3.06%	0.0540	5.61%
HDB	0.0439	2.92%	0.1445	9.86%	0.2688	16.64%	0.2764	17.30%
MBB	0.0267	2.77%	0.0247	2.57%	0.0382	2.9%	0.0469	3.79%

SSB	0.0748	13.84%	0.0663	13.01%	0.0844	15.14%	0.1006	17.76%
SHB	0.0323	5.29%	0.0640	10.54%	0.0115	1.63%	0.0422	4.95%
STB	0.0294	3.2%	0.0723	8.06%	0.0173	1.42%	0.0411	4.74%
TCB	0.0229	2.92%	0.0445	6.52%	0.0152	1.78%	0.0212	2.55%
TPB	0.0261	3.61%	0.0309	4.64%	0.0116	1.51%	0.139	1.63%
VCB	0.0239	1.85%	0.0555	4.13%	0.1822	14.18%	0.1827	14.25%
VIB	0.0215	2.34%	0.0732	9.26%	0.0111	1.17%	0.0274	3.36%
VPB	0.0263	3.06%	0.0170	1.88%	0.0157	1.69%	0.250	2.46%
EIB	0.0564	7.99%	0.0499	5.44%	0.0274	3.61%	0.0641	9.96%
LPB	0.2173	12.81%	0.3336	16.09%	0.7060	30.08%	0.6798	29.79%
MSB	0.0331	6.28%	0.0466	8.70%	0.0124	1.9%	0.0199	3.46%
BAB	0.0165	63.91%	0.0126	28.09%	0.0353	139.27%	0.0193	74.64%
NVB	0.0352	12.34%	0.1860	48.86%	0.0404	17.92%	0.0431	17.99%
OCB	0.0526	9.29%	0.0496	9.59%	0.129	2.11%	0.0165	2.97%

Nguồn: Tác giả tổng hợp

Kết quả phân tích hiệu suất của các mô hình dự đoán giá cổ phiếu cho thấy mô hình Long Short-Term Memory (LSTM) đạt được kết quả tốt nhất ở hầu hết các ngân hàng, với chỉ số RMSE và MAPE thấp nhất, đặc biệt là đối với ACB (RMSE: 0.0290,

MAPE: 2.36%) và MBB (RMSE: 0.0267, MAPE: 2.77%). Mô hình Transformer cũng cho thấy hiệu suất khả quan tại một số ngân hàng như CTG (RMSE: 0.0418, MAPE: 5.05%) và MBB, nhưng lại kém hiệu quả ở ngân hàng LPB (RMSE: 0.3336, MAPE: 16.09%). Mô hình Random Forest có độ ổn định tương đối tốt, với kết quả khả quan ở ngân hàng CTG (RMSE: 0.0395, MAPE: 3.06%), nhưng không đạt được độ chính xác cao nhất. Ngược lại, mô hình XGBoost thể hiện hiệu suất kém hơn, với nhiều ngân hàng có chỉ số RMSE và MAPE cao, đặc biệt là LPB (RMSE: 0.6798, MAPE: 29.79%) và BAB (RMSE: 0.0165, MAPE: 63.91%). Từ những phân tích trên, có thể kết luận rằng mô hình LSTM là lựa chọn tối ưu cho việc dự đoán giá cổ phiếu trong ngành ngân hàng Việt Nam, trong khi các mô hình khác cần được cải thiện để nâng cao hiệu suất, đặc biệt cho những ngân hàng có kết quả kém.

4.3. Ưu điểm và khuyết điểm của các mô hình dự đoán:

Trong quá trình chạy mô hình có thể thấy mỗi mô hình có những ưu điểm và nhược điểm khác nhau:

Bảng 4-6: Ưu điểm và khuyết điểm của 4 mô hình

Mô hình	Ưu điểm	Khuyết điểm
LSTM	- Hiệu suất tốt với RMSE và MAPE thấp - Mạnh mẽ trong việc phát hiện mẫu và xu hướng	- Cần nhiều tài nguyên tính toán và thời gian huấn luyện lâu - Khó khăn trong việc tối ưu hóa tham số
Transformer	- Khả năng xử lý dữ liệu song song	- Yêu cầu nhiều tài nguyên tính toán và bộ nhớ lớn

	- Hiệu suất cao trong một số trường hợp	- Khó khăn trong việc giải thích kết quả
Random Forest	- Đơn giản và dễ hiểu - Chống overfitting tốt	- Hiệu suất không cao bằng LSTM và Transformer - Không hiệu quả với dữ liệu chuỗi thời gian
XGBoost	- Hiệu suất cao và tốc độ huấn luyện nhanh - Kết quả tốt trong nhiều bài toán dự đoán	- Cần tối ưu hóa tham số cẩn thận - Khó khăn trong việc xử lý dữ liệu chuỗi thời gian

Nguồn: Tác giả tổng hợp

Tóm lại, mỗi mô hình học máy đều có những ưu điểm và nhược điểm riêng. LSTM và Transformer nổi bật trong việc xử lý dữ liệu chuỗi thời gian, trong khi Random Forest và XGBoost có thể phù hợp hơn cho các bài toán khác với dữ liệu tĩnh hơn. Sự lựa chọn giữa các mô hình này nên dựa trên yêu cầu cụ thể của bài toán, dữ liệu sẵn có và nguồn lực tính toán, để đạt được hiệu quả dự đoán tốt nhất.

KẾT LUẬN CHƯƠNG 4

Trong chương 4, tác giả thực hiện tổng hợp, phân tích hiệu suất của các mô hình. Kết quả cho thấy mô hình LSTM có hiệu suất dự đoán tốt nhất trong 4 mô hình, trong khi Random Forest và XGBoost gặp khó khăn, nhất là đối với các cổ phiếu có biến động giá lớn.

CHƯƠNG 5. KẾT LUẬN VÀ ĐỀ XUẤT

5.1. Kết luận

Bốn mô hình—LSTM, Transformer, Random Forest và XGBoost—được sử dụng trong nghiên cứu này để dự đoán giá cổ phiếu của các ngân hàng ở Việt Nam trong khoảng thời gian từ 01/01/2014 đến ngày 31/12/2024. Các mô hình học sâu như LSTM và Transformer hoạt động tốt hơn so với các mô hình học giám sát như Random Forest và XGBoost, theo kết quả đánh giá sử dụng các chỉ số RMSE và MAPE. Cụ thể, LSTM đã đạt được kết quả tốt nhất với sai số thấp nhất, chứng tỏ khả năng học các đặc tính của chuỗi thời gian và theo dõi sát sao các xu hướng giá cổ phiếu trong cả ngắn hạn và dài hạn. Với khả năng nắm bắt các mối quan hệ phức tạp giữa các yếu tố đầu vào và biến động thị trường, đặc biệt trong các giai đoạn ổn định, Transformer đứng thứ hai.

Ngược lại với các mô hình học sâu, Random Forest và XGBoost có tỷ lệ sai số cao hơn và gặp khó khăn trong việc xử lý dữ liệu có sự biến động lớn. Chúng cũng không thể hiểu các mối quan hệ phụ thuộc theo thời gian. Các chỉ báo kỹ thuật như SMA_20, SMA_50 và EMA_20, cũng như các biến giá lịch sử như close_lag1 và close_lag2, đóng vai trò quan trọng trong việc xác định tầm quan trọng của các thành phần đầu vào. Hơn nữa, một số chỉ số tài chính như ROE và EPS đã góp phần nâng cao độ chính xác của dự đoán, đặc biệt là đối với một số tổ chức nhất định. Tuy nhiên, do tần suất cập nhật dữ liệu của chúng thấp hơn nhiều so với dữ liệu giá cổ phiếu, các biến như Beta và một số chỉ số tài chính khác đã đóng góp rất ít cho mô hình. Mô hình không thể khai thác hiệu quả mối quan hệ giữa rủi ro hệ thống và biến động giá ngắn hạn, vì chẳng hạn, Beta thường được tính toán hàng năm, trong khi giá cổ phiếu thay đổi hàng ngày. Tầm quan trọng của một số biến kinh tế vĩ mô trong các mô hình dự đoán theo ngày cũng bị giảm sút do tần suất cập nhật không đồng nhất của chúng.

Do đó, các phát hiện của nghiên cứu hỗ trợ ý tưởng rằng các mô hình học sâu—như LSTM và Transformer—phù hợp hơn và thành công hơn trong việc dự đoán giá cổ phiếu, đặc biệt là trong các thị trường có độ biến động cao. Trong khi các yếu tố tài chính và kinh tế vĩ mô đóng vai trò hỗ trợ, nghiên cứu cũng nhấn mạnh tầm quan trọng của dữ liệu chuỗi thời gian và các chỉ báo kỹ thuật trong việc dự đoán giá cổ phiếu. Tác động của các thành phần này thay đổi dựa trên tần suất cập nhật dữ liệu và các đặc điểm riêng biệt của mỗi ngân hàng. Những phát hiện này càng củng cố tiềm năng sử dụng các mô hình học sâu trong lĩnh vực tài chính và đầu tư.

5.2. Đề xuất chiến lược đầu tư

Dựa trên kết quả từ các mô hình LSTM và Transformer, nghiên cứu đề xuất các chiến lược đầu tư cụ thể cho từng giai đoạn thị trường trong ngành ngân hàng. Giá cổ phiếu trong ngành này chịu ảnh hưởng lớn từ các chỉ báo kỹ thuật, chỉ số tài chính và yếu tố kinh tế vĩ mô.

Trong giai đoạn thị trường ổn định hoặc ít biến động, mô hình Transformer có khả năng theo dõi xu hướng giá ngắn hạn, giúp nhà đầu tư tận dụng cơ hội giao dịch nhanh. Các yếu tố như giá đóng cửa gần nhất (`close_lag1`, `close_lag2`) và các chỉ báo kỹ thuật như `SMA_20` và `EMA_20` là rất quan trọng trong dự đoán ngắn hạn, đặc biệt khi có tin tức tích cực như công bố lợi nhuận.

Chiến lược trung hạn có thể dựa vào mô hình LSTM, vốn học tốt các xu hướng dài hạn. Nhà đầu tư nên chú trọng đến các yếu tố tài chính như ROE (lợi nhuận trên vốn chủ sở hữu) và EPS (lợi nhuận trên mỗi cổ phiếu), cùng với các chỉ báo kỹ thuật như `SMA_20` và `SMA_50`, để lựa chọn cổ phiếu có triển vọng tăng trưởng ổn định.

Trong bối cảnh thị trường biến động, việc chọn cổ phiếu có nền tảng tài chính vững chắc và tiềm năng tăng trưởng dài hạn là rất quan trọng. Các mô hình LSTM và Transformer có thể giúp duy trì danh mục đầu tư dài hạn, tập trung vào các cổ phiếu

ngân hàng có chỉ số tài chính ổn định như ROE và P/E. Các ngân hàng đầu ngành như Vietcombank (VCB) và VietinBank (CTG) là lựa chọn phù hợp.

Cuối cùng, nhà đầu tư có thể kết hợp mô hình Transformer để dự đoán biến động giá ngắn hạn và mô hình LSTM để nhận diện xu hướng dài hạn, tối ưu hóa lợi nhuận trong ngắn hạn và đảm bảo sự ổn định cho danh mục đầu tư. Các chiến lược này cho thấy việc ứng dụng các mô hình học máy, đặc biệt là LSTM và Transformer, có thể hỗ trợ hiệu quả trong việc dự đoán, giúp nhà đầu tư tối ưu hóa lợi nhuận, giảm thiểu rủi ro và xây dựng danh mục đầu tư bền vững trong môi trường thị trường đầy biến động.

5.3. Hạn chế của đề tài và hướng nghiên cứu mở rộng

Nghiên cứu này đã đạt được kết quả tích cực trong việc áp dụng các mô hình LSTM, Transformer, Random Forest và XGBoost để dự đoán giá cổ phiếu ngành ngân hàng Việt Nam từ 01/01/2014 đến 31/12/2024. Tuy nhiên, vẫn còn một số hạn chế cần khắc phục để nâng cao hiệu quả dự đoán trong tương lai. Mặc dù LSTM và Transformer có hiệu suất tốt, chúng vẫn nhạy cảm với biến động ngẫu nhiên trong dữ liệu. Việc tối ưu hóa tham số hoặc áp dụng các kỹ thuật ổn định như Ensemble Learning có thể giúp giảm sai số dự đoán trong các giai đoạn thị trường biến động mạnh. Bên cạnh đó, hiện tại, các yếu tố dự đoán đã bao gồm nhiều chỉ báo kỹ thuật và chỉ số tài chính, nhưng việc tích hợp thêm các yếu tố định tính như tin tức thị trường và tâm lý nhà đầu tư có thể nâng cao độ chính xác của mô hình. Cuối cùng, để triển khai các mô hình này vào thực tiễn, cần đầu tư vào hệ thống tính toán và nguồn lực công nghệ, đặc biệt trong các hệ thống giao dịch tự động. Với tiềm năng đã được chứng minh, các mô hình học sâu như LSTM và Transformer có thể trở thành công cụ hỗ trợ đắc lực cho nhà đầu tư và tổ chức tài chính, khi kết hợp với các chiến lược quản lý rủi ro phù hợp.

KẾT LUẬN CHƯƠNG 5

Chương 5 của nghiên cứu này tóm tắt các kết quả đạt được từ việc áp dụng bốn mô hình—LSTM, Transformer, Random Forest và XGBoost—để dự đoán giá cổ phiếu ngành ngân hàng Việt Nam trong giai đoạn từ 01/01/2014 đến 31/12/2024. Các mô hình học sâu như LSTM và Transformer cho thấy hiệu suất vượt trội so với các mô hình học giám sát, với LSTM đạt kết quả tốt nhất. Nghiên cứu đề xuất các chiến lược đầu tư dựa trên kết quả của các mô hình này, nhấn mạnh tầm quan trọng của các chỉ báo kỹ thuật và yếu tố tài chính. Tuy nhiên, nghiên cứu cũng chỉ ra một số hạn chế, như sự nhạy cảm của các mô hình với biến động ngẫu nhiên và tần suất cập nhật dữ liệu không đồng nhất. Để nâng cao hiệu quả dự đoán, cần tối ưu hóa tham số và tích hợp thêm các yếu tố định tính. Cuối cùng, việc triển khai các mô hình này vào thực tiễn đòi hỏi đầu tư vào công nghệ và hệ thống giao dịch tự động

TÀI LIỆU THAM KHẢO

1. **Tài liệu tham khảo tiếng việt:**
2. Đào Lê Kiều Oanh & Nguyễn Thị Minh Châu. (2024). Dự đoán chỉ số chứng khoán bằng học máy: Bằng chứng thực nghiệm từ thị trường chứng khoán Việt Nam. *Tạp chí Kinh tế và Dự đoán*, 6.
3. Lê Văn Tuấn, Nguyễn Thu Thủy, & Lê Thị Thu Giang. (2021, January 13). ỨNG DỤNG MỘT SỐ MÔ HÌNH HỌC MÁY TRONG DỰ ĐOÁN CHIỀU BIẾN ĐỘNG CỦA THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM. MFEDE. <https://tuanvanle.wordpress.com/2021/01/13/ung-dung-mot-so-mo-hinh-hoc-may- trong-du-bao-chieu-bien-dong-cua-thi-truong-chung-khoan-viet-nam/>
4. Minh Lâm. (2024). Cơ hội đầu tư cổ phiếu ngân hàng: Phù hợp đầu tư dài hạn—*Tạp chí Tài chính*. <https://tapchitaichinh.vn/co-hoi-dau-tu-co-phieu-ngan-hang-phu-hop-dau-tu-dai-han.html>
5. Thu Minh. (2024). Cổ phiếu ngân hàng đã “hết vị”? - *Nhịp sống kinh tế Việt Nam & Thế giới*. <https://vneconomy.vn/co-phieu-ngan-hang-da-het-vi.htm>
6. Vu Thi Loan, Nguyen Thi Anh Thu, Nong Thi Huong Ly, & Vu Mai Linh. (2023). Dự đoán giá cổ phiếu trước các thông tin tài chính và phi tài chính: Áp dụng phân tích Event Study và Random Forest. *VNU JOURNAL OF ECONOMICS AND BUSINESS*, 3(3).
7. Lê Văn Tuấn, Nguyễn Thu Thủy, & Lê Thị Thu Giang. (2021, January 13). ỨNG DỤNG MỘT SỐ MÔ HÌNH HỌC MÁY TRONG DỰ ĐOÁN CHIỀU BIẾN ĐỘNG CỦA THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM. MFEDE. <https://tuanvanle.wordpress.com/2021/01/13/ung-dung-mot-so-mo->

hinh-hoc-may- trong-du-bao-chieu-bien-dong-cua-thi-truong-chung-khoan-viet-nam/

8. Nguyễn Tất Bảo Thiện và Nguyễn Quốc Huy 2022, *Trí tuệ nhân tạo học máy và ứng dụng*, NXB Thanh Niên, TP. HCM

9. Trần Đăng Tuyên. (2024). *Đánh giá hiệu suất mô hình phức hợp LSTM-GRU: nghiên cứu điển hình về dự đoán chỉ số đo lường xu hướng biến động giá cổ phiếu trên sàn giao dịch chứng khoán Hồ Chí Minh*. *Tạp chí Khoa học Đại học Cần Thơ*, 60(1), 235-249.

10. Doan, T. N. T. T. (2011). *Ảnh hưởng của thông tin kế toán và các chỉ số tài chính đến giá cổ phiếu trên thị trường chứng khoán Việt Nam*

Tài liệu tham khảo tiếng nước ngoài:

11. Bodie, Z., & Briere, M. (2013). *Optimal Asset Allocation for Sovereign Wealth Funds: Theory and Practice* (SSRN Scholarly Paper 2344747). Social Science Research Network. <https://doi.org/10.2139/ssrn.2344747>

12. Buffett, W. E. (1984). The superinvestors of Graham-and-Doddsville. *Hermes*, 4- 15.

13. Cao, H., Lin, T., Li, Y., & Zhang, H. (2019). *Stock Price Pattern Prediction Based on Complex Network and Machine Learning*. *Complexity*, 2019, 1-12. <https://doi.org/10.1155/2019/4132485>.

14. Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*.

15. Engle, R. F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. *Econometrica*, 50(4), 987–1007. <https://doi.org/10.2307/1912773>

16. Fabozzi, F. J. (2008). Handbook of finance, financial markets and instruments (Vol.1): John Wiley & Sons.
17. Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417. <https://doi.org/10.2307/2325486>
18. Fama, E. F., & French, K. R. (1992). The Cross-Section of Expected Stock Returns. *The Journal of Finance*, 47(2), 427–465. <https://doi.org/10.2307/2329112>
19. Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654–669. <https://doi.org/10.1016/j.ejor.2017.11.054>
20. Graham, B., & Dodd, D. L. F. (1934). *Security Analysis, Seventh Edition: Principles and Techniques*. <https://www.mheducation.com/highered/mhp/product/security-analysis-seventh-edition-principles-techniques.html>
21. Hafer, R. W., & Hein, S. E. (2006). *The Stock Market: : Greenwood Guides to Business and Economics Rik W. Hafer Greenwood*. <https://www.bloomsbury.com/us/stock-market-9780313081682/>
22. Hammond, R. C. (2015). Behavioral finance: Its history and its future. *BEHAVIORAL FINANCE*.
23. Harvey, A. C., & Todd, P. H. J. (1983). Forecasting Economic Time Series with Structural and Box-Jenkins Models: A Case Study. *Journal of Business & Economic Statistics*, 1(4), 299–307. <https://doi.org/10.2307/1391661>



24. Hochreiter, S. and Schmidhuber, J. (1997). *(PDF) Long Short-Term Memory*.
https://www.researchgate.net/publication/13853244_Long_Short-Term_Memory
25. Kahneman, D., & Tversky, A. (1979). Prospect Theory: An Analysis of Decision under Risk. *Econometrica*, 47(2), 263–291.
<https://doi.org/10.2307/1914185>
26. Kubat. (2017). *An Introduction to Machine Learning | SpringerLink*. <https://link.springer.com/book/10.1007/978-3-319-63913-0>
27. Kumar, M., & Thenmozhi, M. (2014). Forecasting stock index returns using ARIMA-SVM, ARIMA-ANN, and ARIMA-random forest hybrid models. *International Journal of Banking, Accounting and Finance*.
<https://www.inderscienceonline.com/doi/10.1504/IJBAAF.2014.064307>
28. Lo, A. W. (2004). *(PDF) The Adaptive Markets Hypothesis: Market Efficiency from an Evolutionary Perspective*.
https://www.researchgate.net/publication/228183756_The_Adaptive_Markets_Hypothesis_Market_Efficiency_from_an_Evolutionary_Perspective
29. *Long Short-Term Memory | Neural Computation | MIT Press*. (n.d.). Retrieved June 18, 2025, from <https://direct.mit.edu/neco/article-abstract/9/8/1735/6109/Long-Short-Term-Memory?redirectedFrom=fulltext>
30. Mahesh, B. (2020). *(PDF) Machine Learning Algorithms -A Review*.
https://www.researchgate.net/publication/344717762_Machine_Learning_Algorithms_-_A_Review



31. Malkiel, B. G. (2011). The efficient-market hypothesis and the financial crisis. Paper presented at the Rethinking finance: perspectives on the crisis (Proceedings of a conference). Russel Sage Foundation.
32. Vijh, M., Chandola, D., Tikkiwal, V. A., & Kumar, A. (2020). *Stock Closing Price Prediction using Machine Learning Techniques*. *Poedia Computer Science*, 167, 599-606. <https://doi.org/10.1016/j.procs.2020.03.326>.
33. Milosevic, N. (2016). *Equity forecast: Predicting long term stock price movement using machine learning*.
34. Ryabtsev, A. (2024). *Why Python is Good for AI and ML: The Major 8 Reasons*. <https://djangostars.com/blog/why-python-is-good-for-artificial-intelligence-and-machine-learning/>
35. Wachtel, S. B. (1942). Certain Observations on Seasonal Movements in Stock Prices. *The Journal of Business of the University of Chicago*, 15(2), 184–193.
36. Zhang, Y., Feng, T., Wang, S., Dong, R., Yang, J., Su, J., & Wang, B. (2020). *A novel XGBoost method to identify cancer tissue-of-origin based on copy number variations*. *Frontiers in genetics*, 11, 585029.
37. Phuong, M., & Hutter, M. (2022). *Formal algorithms for transformers*. *arXiv preprint arXiv:2207.09238*.
38. Hodson, T. O. (2022). *Root mean square error (RMSE) or mean absolute error (MAE): When to use them or not*. *Geoscientific Model Development Discussions*, 2022, 1-10.



PHỤ LỤC 1 – KẾT QUẢ CHẠY MÔ HÌNH

1. **Dữ liệu lịch sử giá cổ phiếu các ngân hàng**
https://colab.research.google.com/drive/1Q2rmlhHTOLsOriBI_svjSoS0TDz3gBEf#scrollTo=49tFpd7kWBA_&line=1&uniqifier=1
2. **Dữ liệu các chỉ số tài chính và vĩ mô**
https://colab.research.google.com/drive/1Q2rmlhHTOLsOriBI_svjSoS0TDz3gBEf#scrollTo=HujeLp84XecF&line=1&uniqifier=1
3. **Dữ liệu chạy mô hình tổng hợp**
https://colab.research.google.com/drive/1Q2rmlhHTOLsOriBI_svjSoS0TDz3gBEf#scrollTo=kL64bx-5gQjG&line=2&uniqifier=1
4. **Biểu đồ giá đóng cửa và giá dự đoán của các ngân hàng còn lại**



Mô hình LSTM












X


















Mô hình Tranformer

































Mô hình Random Forest
























Mô hình XGBoost














PHỤ LỤC 2 – CHẠY MÔ HÌNH

CODE CHẠY MÔ HÌNH LSTM

https://colab.research.google.com/drive/1Q2rmlhHTOLsOriBI_svjSoS0TDz3gBEf?usp=sharing

CODE CHẠY MÔ HÌNH TRANSFORMER

https://colab.research.google.com/drive/1oSKS5MAYdH8bxwfvqtF0k_0wVqJF_Nhq?usp=sharing

CODE CHẠY MÔ HÌNH RANDOM FOREST VÀ XGBOOST

https://colab.research.google.com/drive/1ParZ1HGt_L3fqTYC2IgvZ87ZFLpyqjZ_?usp=sharing