

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

ỨNG DỤNG HỌC MÁY TRONG DỰ BÁO GIÁ CỔ
PHIẾU: NGHIÊN CỨU THỰC NGHIỆM Ở VIỆT NAM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG

MÃ SỐ: 7340201

ĐINH THỊ PHƯƠNG

TP. HỒ CHÍ MINH, NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

ỨNG DỤNG HỌC MÁY TRONG DỰ BÁO GIÁ CỔ
PHIẾU: NGHIÊN CỨU THỰC NGHIỆM Ở VIỆT NAM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG

MÃ SỐ: 7340201

Họ và tên sinh viên: ĐINH THỊ PHƯƠNG

Mã số sinh viên: 030138220320

Lớp sinh hoạt: DH38CT02

NGƯỜI HƯỚNG DẪN KHOA HỌC

TS. NGUYỄN MINH NHẬT

TP. HỒ CHÍ MINH, NĂM 2025

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN KHÓA LUẬN

.....

.....

.....

.....

.....

.....

.....

.....

TP. HCM, ngày.....tháng.....năm 2025

Giảng viên hướng dẫn

TÓM TẮT

Hiện nay, với sự tiến bộ vượt bậc của khoa học và công nghệ, trí tuệ nhân tạo cùng học máy đã được ứng dụng rộng rãi trong hầu hết các lĩnh vực. Đặc biệt trong ngành tài chính, nơi các quyết định phụ thuộc nhiều vào dữ liệu. Học máy mang lại khả năng xử lý, phân tích khối lượng dữ liệu lớn và phức tạp, giúp tiết kiệm thời gian, giảm chi phí và nâng cao hiệu quả công việc. Nhận thấy được tiềm năng này, đề tài “Ứng dụng học máy trong dự báo giá cổ phiếu: Nghiên cứu thực nghiệm ở Việt Nam” được tác giả thực hiện với mục đích tìm ra mô hình có khả năng dự báo chính xác giá đóng cửa của cổ phiếu TCB được niêm yết trên thị trường chứng khoán Việt Nam. Tác giả sử dụng dữ liệu giá lịch sử của ngân hàng Techcombank từ ngày 4 tháng 6 năm 2018 tới ngày 31 tháng 3 năm 2025. Trong nghiên cứu này, dữ liệu được chia theo phương pháp Walk Forward Optimization, một kỹ thuật phân chia đặc thù cho chuỗi thời gian, đảm bảo mô hình thích nghi với các kịch bản thị trường đa dạng và giảm thiểu nguy cơ overfitting. Phương pháp này mô phỏng môi trường thực tế bằng cách liên tục mở rộng cửa sổ huấn luyện và đánh giá mô hình trên dữ liệu ngoài mẫu (out-of-sample), giúp tăng cường khả năng tổng quát hóa. Kết quả dự báo cho thấy được mô hình MLP có hiệu suất tốt hơn so với mô hình LSTM trên từng mẫu dữ liệu và thể hiện mức độ hiệu quả trong việc dự báo ngắn ngày.

Từ khóa: Học máy, dự báo, Walk Forward Optimization, MLP, LSTM.

ABSTRACT

Currently, with the remarkable advancements in science and technology, artificial intelligence (AI) and machine learning have been widely applied across nearly all sectors. In the financial industry, where decisions heavily rely on data, machine learning offers the capability to process and analyze large, complex datasets, enabling time and cost savings while enhancing operational efficiency. Recognizing this potential, the research titled “Application of Machine Learning in Stock Price Forecasting: An Empirical Study in Vietnam” was conducted with the aim of identifying a model capable of accurately predicting the closing price of TCB stock, listed on the Vietnam stock market. The study utilizes historical price data of Techcombank from June 4, 2018, to March 31, 2025. In this research, the data is segmented using the Walk Forward Optimization (WFO) method, a specialized technique for time-series data that ensures the model adapts to diverse market scenarios and mitigates the risk of overfitting. This approach simulates real-world conditions by progressively expanding the training window and evaluating the model on out-of-sample data, thereby improving its generalization ability. The project results show that the MLP model has better performance than the LSTM model on each sample data and can show the effectiveness in short-term daily forecasting of the project.

Keywords: *Machine Learning, Forecasting, Walk Forward Optimization, MLP, LSTM*

LỜI CAM ĐOAN

Tôi tên là: Đinh Thị Phương; Mã số sinh viên: 030138220320

Lớp DH38CT02, Trường Đại học Ngân hàng Thành phố Hồ Chí Minh

Tôi xin cam kết đề tài “Ứng dụng học máy trong dự báo giá cổ phiếu: Nghiên cứu thực nghiệm ở Việt Nam” là do tác giả thực hiện. Đề tài này chưa từng được công bố hoặc đăng tải ở bất kỳ nơi nào khác. Số liệu trong bài nghiên cứu là hoàn toàn trung thực, mọi nguồn thông tin được trích dẫn trong bài này đều được ghi rõ và chính xác theo quy tắc trích dẫn khoa học đảm bảo quyền lợi và công bằng cho tác giả gốc.

TP. HCM, ngày.....tháng.....năm 2025

Sinh viên

Đinh Thị Phương

LỜI CẢM ƠN

Tôi xin bày tỏ lòng biết ơn sâu sắc đến Ban Giám hiệu Trường Đại học Ngân hàng TP. Hồ Chí Minh vì đã tổ chức và tạo điều kiện thuận lợi để tôi hoàn thành chương trình đào tạo trình độ Đại học chính quy – Chương trình Chính quy chuẩn, chuyên ngành Công nghệ tài chính. Đồng thời, tôi xin gửi lời tri ân đến toàn thể Quý Thầy cô đã tham gia giảng dạy, chia sẻ kiến thức cho tôi, cũng như các Thầy cô quản lý thuộc các Khoa trong suốt thời gian tôi tham gia lớp học.

Kính chúc toàn thể Quý Thầy Cô luôn dồi dào sức khỏe để tiếp tục sự nghiệp giáo dục, góp phần đào tạo các thế hệ tiếp theo một cách hiệu quả nhất. Đặc biệt, tôi xin bày tỏ lòng biết ơn sâu sắc và lời cảm ơn chân thành nhất đến Tiến sĩ Nguyễn Minh Nhật, người đã trực tiếp hướng dẫn, truyền đạt kiến thức, chia sẻ kinh nghiệm quý báu và tận tình hỗ trợ tôi trong suốt quá trình nghiên cứu, giúp tôi hoàn thành tốt khóa luận tốt nghiệp này. Cuối cùng, tôi xin gửi lời cảm ơn chân thành đến gia đình và toàn thể các bạn trong lớp DH38CT02, cùng những người bạn của tôi, những người đã luôn động viên, khích lệ tôi trong những thời điểm khó khăn và đồng hành, hỗ trợ tôi trong quá trình học tập cũng như nghiên cứu trên giảng đường đại học. Các bạn đã tạo điều kiện thuận lợi nhất để tôi hoàn thành khóa luận tốt nghiệp đại học này. Do kinh nghiệm, kiến thức và thời gian còn hạn chế, khóa luận này không thể tránh khỏi những thiếu sót. Tôi rất mong nhận được những ý kiến đóng góp từ Quý Thầy Cô và Hội đồng phản biện để hoàn thiện thêm vốn kiến thức của mình.

MỤC LỤC

TÓM TẮT	ii
ABSTRACT	iii
LỜI CAM ĐOAN	iv
LỜI CẢM ƠN	v
MỤC LỤC	vi
DANH MỤC TỪ VIẾT TẮT	ix
DANH MỤC BẢNG	x
DANH MỤC HÌNH ẢNH	xi
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI NGHIÊN CỨU	1
1.1 Tính cấp thiết của đề tài nghiên cứu	1
1.2 Mục tiêu nghiên cứu	2
1.3 Câu hỏi nghiên cứu	3
1.4 Đối tượng và phạm vi nghiên cứu	3
1.4.1 Đối tượng nghiên cứu	3
1.4.2 Phạm vi nghiên cứu	3
1.5 Phương pháp nghiên cứu	3
1.6 Những đóng góp của nghiên cứu	4
1.7 Bố cục bài nghiên cứu	4
KẾT LUẬN CHƯƠNG 1	6
PHẦN 2: CƠ SỞ LÝ THUYẾT	7
2.1 Tổng quan về học máy	7
2.2 Tổng quan lý thuyết về các mô hình học máy	9
2.2.1 Mạng nơ ron nhân tạo	9
2.2.2 Mô hình Multilayer Perceptron	12
2.2.3 Mô hình Long Short-Term Memory	13
2.3 Tổng quan về Walk-Forward Optimization	14
2.4 Khái niệm dự báo giá cổ phiếu	16

2.4.1 Phân tích cơ bản	17
2.4.2 Phân tích kỹ thuật	18
2.5 Các nghiên cứu có liên quan	20
2.5.1 Các nghiên cứu nước ngoài	20
2.5.2 Các nghiên cứu trong nước	24
2.5.3. Khoảng trống nghiên cứu	27
KẾT LUẬN CHƯƠNG 2.....	29
CHƯƠNG 3: XÂY DỰNG MÔ HÌNH NGHIÊN CỨU.....	30
3.1 Quy trình nghiên cứu	30
3.2 Thực hiện nghiên cứu	31
3.2.1 Thu thập và tiền xử lý dữ liệu	31
3.2.1.1 Thu thập dữ liệu.....	31
3.2.1.2 Tiền xử lý dữ liệu	32
3.2.1.3 Chuẩn hóa dữ liệu	32
3.2.1.4 Tính toán các chỉ báo kỹ thuật.....	33
3.2.2 Phân tích khai phá dữ liệu	37
3.2.3 Lựa chọn mô hình và huấn luyện mô hình	37
3.2.3.1 Phân chia tập huấn luyện và tập kiểm tra	38
3.2.3.2 Xây dựng mô hình MLP	38
3.2.3.3 Xây dựng mô hình LSTM	40
3.2.4 Kiểm tra và đánh giá	40
KẾT LUẬN CHƯƠNG 3.....	42
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU.....	43
4.1 Đánh giá tác động của COVID-19	43
4.2 Thông tin bộ dữ liệu	45
4.2.1 Thống kê dữ liệu đầu vào	45
4.2.2 Ma trận tương quan	46

4.2.3 Chia dữ liệu thành tập huấn luyện và kiểm tra.....	49
4.3 Kết quả huấn luyện và hiệu suất của các mô hình.....	49
4.3.1 Kết quả xây dựng mô hình Multilayer Perceptron.....	50
4.3.2 Kết quả xây dựng mô hình Long Short - Term Memory.....	55
4.3.3 So sánh hiệu suất của các mô hình.....	60
KẾT LUẬN CHƯƠNG 4.....	63
CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ	64
5.1 Kết luận	64
5.2 Khuyến nghị.....	66
5.2.1 Đối với nhà đầu tư.....	66
5.2.2 Đối với các công ty chứng khoán.....	66
5.3 Hạn chế của nghiên cứu.....	67
5.4 Đề xuất cho các nghiên cứu trong tương lai	67
KẾT LUẬN CHƯƠNG 5.....	69
TÀI LIỆU THAM KHẢO	70
PHỤ LỤC 1 – KẾT QUẢ CHẠY MÔ HÌNH	73
PHỤ LỤC 2 – CODE PYTHON	76

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Tên tiếng Việt	Tên tiếng Anh
HOSE	Sở Giao dịch Chứng khoán thành phố Hồ Chí Minh	Ho Chi Minh Stock Exchange
ANN	Mạng nơ-ron nhân tạo	Artificial Neural Network
MLP	Perceptron đa tầng	Multilayer Layer Perceptron
LSTM	Bộ nhớ dài hạn ngắn hạn	Long Short-Term Memory
ML	Học máy	Machine Learning
TMCP	Thương mại cổ phần	Commercial Joint Stock
TCB	Ngân hàng TMCP Kỹ thương Việt Nam	Vietnam Technological and Commercial Joint Stock Bank
TSSL	Tỷ suất sinh lợi	Return
MAE	Sai số tuyệt đối trung bình	Mean Absolute Error
MSE	Sai số bình phương trung bình	Mean Squared Error
RMSE	Sai số toàn phương trung bình	Root Mean Square Error
ATR	Khoảng dao động trung bình thực tế	Average True Range
RSI	Chỉ số sức mạnh tương đối	Relative Strength Index
MACD	Đường trung bình động hội tụ phân kỳ	Moving Average Convergence Divergence
OBV	Dòng tiền theo khối lượng	On-Balance Volume
WFO	Tối ưu hóa bước tiến	Walk Forward Optimization

DANH MỤC BẢNG

Bảng 2.1: So sánh các loại học máy	9
Bảng 2.2: Ưu và nhược điểm của ANN	12
Bảng 2.3: Ưu và nhược điểm của mô hình MLP	13
Bảng 2.4: Ưu điểm và nhược điểm của mô hình LSTM.....	14
Bảng 2.5: So sánh WFO với phương pháp truyền thống	16
Bảng 2.6: Tổng hợp các nghiên cứu liên quan.....	25
Bảng 4.1: Dữ liệu lịch sử giá.....	45
Bảng 4.2: Dữ liệu thống kê	45
Bảng 4.3: Kết quả so sánh giá thực tế và giá dự báo của mô hình MLP	50
Bảng 4.4: Các siêu tham số MLP	52
Bảng 4.5: Kết quả đánh giá từng sample - MLP.....	52
Bảng 4.6: Kết quả đánh giá trung bình của mô hình MLP.....	53
Bảng 4.7: Kết quả so sánh giá thực tế và giá dự báo của mô hình LSTM.....	55
Bảng 4.8: Các siêu tham số của LSTM	57
Bảng 4.9: Kết quả đánh giá của từng sample - LSTM	57
Bảng 4.10: Kết quả đánh giá trung bình của mô hình LSTM	58
Bảng 4.11: So sánh hiệu suất của mô hình MLP và LSTM.....	60
Bảng 4.12 So sánh MLP và LSTM với mô hình baseline	61

DANH MỤC HÌNH ẢNH

Hình 2.1: Cấu trúc mạng nơ ron đơn giản.....	11
Hình 2.2: Mô hình WFO.....	15
Hình 3.1: Quy trình nghiên cứu.....	30
Hình 4.1 Giá đóng cửa trong thời kì COVID-19.....	43
Hình 4.2: Phân phối lợi nhuận trong thời kì COVID-19.....	44
Hình 4.3: Ma trận tương quan.....	47
Hình 4.4: Chia dữ liệu WFO	49
Hình 4.5: Giá đóng cửa TCB.....	50
Hình 4.6: Trực quan hóa kết quả so sánh giá thực tế và giá dự báo của MLP .	51
Hình 4.7 Phân phối lợi nhuận thực tế và dự báo (MLP).....	54
Hình 4.8: Trực quan hóa kết quả so sánh giữa giá thực tế và giá dự báo của LSTM.....	56
Hình 4.9 Phân phối lợi nhuận thực tế và dự báo (LSTM)	59
Hình 4.10 Phân phối lợi nhuận thực tế và dự báo (SARIMAX).....	61

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI NGHIÊN CỨU

1.1 Tính cấp thiết của đề tài nghiên cứu

Trong những năm gần đây, thị trường chứng khoán Việt Nam đã có những bước phát triển đáng chú ý cả về quy mô và tính thanh khoản, trở thành một kênh đầu tư hấp dẫn đối với đông đảo nhà đầu tư. Theo dữ liệu từ Tổng Công ty Lưu ký và Bù trừ Chứng khoán Việt Nam (VSDC), tính đến ngày 31/7/2024, số lượng tài khoản nhà đầu tư cá nhân trong nước đã vượt 8,31 triệu tài khoản, chiếm tới 99,2% tổng số tài khoản trên thị trường (Minh Lâm, 2024). Điều này cho thấy nhà đầu tư cá nhân đang đóng vai trò chủ đạo trong hoạt động giao dịch và tác động mạnh đến xu hướng thị trường.

Sự tham gia đông đảo của nhà đầu tư không chỉ giúp thị trường trở nên sôi động hơn mà còn tạo điều kiện để các doanh nghiệp huy động vốn thuận lợi thông qua việc phát hành cổ phiếu, nâng cao tính minh bạch trong quản trị và gia tăng giá trị thương hiệu. Tuy nhiên, đặc điểm nổi bật của thị trường chứng khoán Việt Nam là sự chi phối bởi nhà đầu tư cá nhân – trong đó phần lớn thiếu kiến thức chuyên sâu, dễ bị tác động bởi tâm lý đám đông và xu hướng đầu cơ ngắn hạn. Điều này khiến giá cổ phiếu thường xuyên biến động mạnh và khó lường. Bên cạnh đó, giá cả trên thị trường còn chịu ảnh hưởng từ nhiều yếu tố khác như hiệu suất hoạt động doanh nghiệp, các chỉ số kinh tế vĩ mô, chính sách điều hành của Nhà nước, cũng như các sự kiện địa chính trị toàn cầu.

Hiện nay, các đề tài nghiên cứu về thị trường chứng khoán đặc biệt là dự báo giá cổ phiếu, luôn thu hút sự quan tâm của các nhà tư vấn trên thị trường. Việc dự báo giá trên thị trường chứng khoán Việt Nam vẫn đối mặt nhiều công thức đặc thù của thị trường mới nổi, bao gồm: sự biến động cao và ảnh hưởng của các yếu tố kinh tế không ổn định. Sự bất ngờ và đột biến của chứng khoán Việt Nam mang lại không ít rủi ro cho các nhà đầu tư (Đào Lê Kiều Oanh & Nguyễn Thị Minh Châu, 2024). Bên cạnh những khó khăn gặp phải, học máy vẫn luôn thể hiện sự vượt trội trong việc dự báo. Các mô hình học máy không chỉ giúp nhận diện xu hướng giá một cách khách quan dựa trên dữ liệu lịch sử, mà còn có khả năng tích hợp và xử lý các yếu tố đa

chiều như phân tích kỹ thuật, tin tức, tâm lý thị trường, dòng tiền và các chỉ báo kinh tế vĩ mô – điều mà con người khó quan sát cùng lúc. Cụ thể, có nhiều nghiên cứu nghiên cứu như: Quý và cộng sự (2024) đã sử dụng mô hình LSTM để dự báo giá cổ phiếu và cho thấy đây là một phương pháp hứa hẹn trong việc dự báo giá cổ phiếu ở Việt Nam. Hai tác giả (Đào Lê Kiều Oanh và Nguyễn Thị Minh Châu, 2024) đã so sánh 2 phương pháp học máy dự báo chỉ số chứng khoán bằng LSTM và TCN và chứng minh rằng LSTM có hiệu quả dự báo tốt trên thị trường chứng khoán Việt Nam.

Xuất phát từ thực tiễn đó, tác giả lựa chọn thực hiện đề tài “ỨNG DỤNG HỌC MÁY TRONG DỰ BÁO GIÁ CỔ PHIẾU: NGHIÊN CỨU THỰC NGHIỆM Ở VIỆT NAM” với mục tiêu xây dựng một mô hình dự báo hiệu quả, hoạt động tốt trên thị trường chứng khoán Việt Nam. Nghiên cứu không chỉ có giá trị thực tiễn cao, mà còn đóng góp vào nền tảng học thuật trong lĩnh vực tài chính định lượng, đồng thời mở ra những hướng tiếp cận mới phù hợp với xu thế chuyển đổi số trong ngành tài chính – ngân hàng dưới tác động của cuộc Cách mạng công nghiệp 4.0.

1.2 Mục tiêu nghiên cứu

Mục tiêu tổng quát: Ứng dụng các mô hình học máy trong dự báo giá cổ phiếu TCB – Ngân hàng Techcombank được niêm yết trên thị trường chứng khoán Việt Nam. Từ đó đề xuất ra các mô hình học máy phù hợp có thể đưa ra các dự báo giá đóng cửa chính xác.

Để đạt được mục tiêu tổng quát, nghiên cứu có các mục tiêu cụ thể sau:

Thứ nhất, xây dựng được các mô hình học máy dự báo giá cổ phiếu phù hợp, tiến hành quá trình huấn luyện trên dữ liệu đã được tiền xử lý và kết hợp cùng các chỉ báo kỹ thuật trong phương pháp phân tích kỹ thuật để xây dựng các mô hình có khả năng dự đoán tốt trên thị trường chứng khoán Việt Nam.

Thứ hai, so sánh các mô hình dự báo dựa trên các tiêu chí như sai số trung bình (RMSE, MAE, MSE), độ chính xác (R^2), và khả năng thích ứng với biến động thị trường để xác định mức độ hiệu quả của chúng trong việc dự đoán giá cổ phiếu.

1.3 Câu hỏi nghiên cứu

Để đạt được các mục tiêu nghiên cứu trên, bài nghiên cứu đặt ra một số câu hỏi như sau:

Thứ nhất, ưu điểm và nhược điểm của các mô hình dự báo giá chứng khoán trong ngữ cảnh của bài nghiên cứu?

Thứ hai, dựa vào các chỉ số đánh giá hiệu suất thu được, mô hình nào có hiệu suất tốt nhất?

1.4 Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

Thứ nhất, đối tượng nghiên cứu là các mô hình học máy có khả năng dự báo giá cổ phiếu ngân hàng Techcombank được niêm yết trên thị trường chứng khoán Việt Nam.

Thứ hai, các chỉ báo kỹ thuật của phương pháp Phân tích kỹ thuật.

1.4.2 Phạm vi nghiên cứu

Phạm vi nghiên cứu về không gian: dữ liệu nghiên cứu được thu thập là dữ liệu giá lịch sử của ngân hàng Techcombank. Bao gồm giá đóng cửa (close) và khối lượng giao dịch (volume) trong ngày.

Phạm vi nghiên cứu về thời gian: Dữ liệu nghiên cứu được thu thập là các phiên giao dịch theo ngày, trong khoảng thời gian từ ngày 4 tháng 6 năm 2018 đến ngày 31 tháng 3 năm 2025.

1.5 Phương pháp nghiên cứu

Khóa luận được thực hiện theo phương pháp định lượng, sử dụng ngôn ngữ lập trình bậc cao Python, với sự hỗ trợ từ Google Colaboratory, một môi trường lập trình trực tuyến cung cấp các thư viện Python sẵn có. Dữ liệu sử dụng bao gồm lịch sử giá cổ phiếu và các chỉ số kỹ thuật được tính toán từ dữ liệu giá lịch sử. Dữ liệu giá trong nghiên cứu được thu thập từ thư viện Vnstock của Python. Kết hợp cùng các biến đầu vào là các chỉ báo kỹ thuật. Những dữ liệu này sau đó được xử lý và đưa vào các mô hình học máy, cụ thể là thuật toán MLP và LSTM, để tiến hành huấn luyện và phát triển. Hơn nữa, nghiên cứu áp dụng các thước đo đánh giá như R^2 , MAE, MSE và

RMSE để đánh giá và lựa chọn mô hình dự báo giá chứng khoán phù hợp. Cuối cùng, dựa trên dữ liệu đã huấn luyện, các mô hình học máy sẽ cung cấp kết quả dự báo giá cổ phiếu của các doanh nghiệp trong tương lai.

1.6 Những đóng góp của nghiên cứu

Kết quả nghiên cứu của khóa luận có ý nghĩa khoa học và thực tiễn trên các mặt sau:

- Đề xuất mô hình dự báo giá cổ phiếu phù hợp, đề xuất và gợi ý mở ra nhiều hướng cải thiện và phát triển các nghiên cứu mới.
- Làm rõ, phân tích có hệ thống các lý thuyết cơ bản, lý thuyết về các chỉ số kỹ thuật và nền tảng liên quan tới các mô hình dự báo giá cổ phiếu và các tiêu chí để đánh giá và lựa chọn các mô hình phù hợp.
- Làm phong phú kiến thức và hiểu biết về ML trong tài chính và cung cấp một công cụ hữu ích giúp nhà đầu tư đưa ra quyết định đầu tư thông minh, xây dựng chiến lược đầu tư và đối mặt với rủi ro, tối ưu hóa lợi nhuận.

1.7 Bố cục bài nghiên cứu

Khóa luận được chia thành 5 chương: Giới thiệu về đề tài nghiên cứu, cơ sở lý thuyết và tổng quan nghiên cứu, phương pháp nghiên cứu, kết quả nghiên cứu, kết luận và khuyến nghị. Chi tiết cụ thể như sau:

CHƯƠNG 1: GIỚI THIỆU VỀ ĐỀ TÀI NGHIÊN CỨU

Chương 1 sẽ giới thiệu về đề tài, làm rõ tính cấp thiết của vấn đề nghiên cứu. Mục tiêu nghiên cứu được đề cập chi tiết, bao gồm mục tiêu tổng quát và các mục tiêu cụ thể, đồng thời câu hỏi nghiên cứu được đưa ra để định hướng cách tiếp cận vấn đề. Đối tượng và phạm vi nghiên cứu được xác định rõ ràng, cùng với những đóng góp quan trọng mà nghiên cứu mang lại. Ngoài ra, phương pháp nghiên cứu và cấu trúc tổng thể của nghiên cứu cũng được giới thiệu một cách khái quát.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN NGHIÊN CỨU

Chương 2 định nghĩa về các phương pháp dự báo sự thay đổi của giá chứng khoán bao gồm: phương pháp phân tích cơ bản và phương pháp phân tích kỹ thuật, đưa ra cái nhìn tổng quan về học máy. Các mô hình học máy quan trọng như Long

Short-Term Memory, và Multilayer Perceptron được giới thiệu về lý thuyết. Chương cũng tập trung vào các nghiên cứu liên quan để xây dựng cơ sở lý thuyết mạnh mẽ.

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

Chương 3 trình bày quy trình nghiên cứu, bao gồm các bước thu thập và tiền xử lý dữ liệu và khai phá dữ liệu, đồng thời nêu rõ lý thuyết các chỉ số kỹ thuật. Ngoài ra, chương này cũng đề cập đến việc xây dựng các mô hình học máy, một bước quan trọng trong quá trình nghiên cứu.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

Chương 4 trình bày kết quả nghiên cứu thông qua thống kê mô tả và phân tích tương quan. Kết quả của các mô hình thông qua Long Short-Term Memory và Multilayer Perceptron được trực quan hóa và phân tích chi tiết. Hiệu suất của mỗi mô hình được đánh giá và so sánh để cung cấp cái nhìn toàn diện về khả năng dự báo của mô hình.

CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ

Chương 5 là phần kết luận, tổng hợp các kết quả đạt được, đánh giá mức độ hiệu quả của các mô hình, và đưa ra các hạn chế. Các khuyến nghị được đề xuất cho các nhà đầu tư ứng dụng vào, nhấn mạnh sự quan trọng của nghiên cứu trong việc đóng góp vào sự phát triển của lĩnh vực học máy trong tài chính tại Việt Nam.

KẾT LUẬN CHƯƠNG 1

Trong chương 1, tác giả đã trình bày được vấn đề nghiên cứu, tính cấp thiết, mục tiêu nghiên cứu, câu hỏi nghiên cứu, đối tượng và phạm vi nghiên cứu, phương pháp nghiên cứu, nội dung nghiên cứu, đóng góp của đề tài, bố cục bài nghiên cứu. Đồng thời cũng xác định được mục tiêu cụ thể cho các chương sau.

PHẦN 2: CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về học máy

Trong bài nghiên cứu của Khoa và cộng sự (2022): Học máy (Machine Learning) là một phần của ngành khoa học dữ liệu. “Học máy” đề cập đến các nghiên cứu tập trung vào việc đưa ra dự báo bằng các mô hình. Có sẵn các công cụ cho phép phân phối các tác vụ tính toán giữa các nút khác nhau trong một cụm máy tính, giảm thời gian xử lý và cân bằng lượng công việc. Những công cụ này cho phép giảm thời gian xử lý và cân bằng lượng công việc.

Tác giả Andriy Burkov (2019) định nghĩa học máy là một lĩnh vực phụ của khoa học máy tính liên quan đến việc xây dựng các thuật toán, để hữu ích, dựa trên một tập hợp các ví dụ về một số hiện tượng. Những ví dụ này có thể được tìm thấy trong tự nhiên, được tạo ra thủ công bởi con người hoặc có thể được tạo ra bằng thuật toán. ML có thể sử dụng cho hầu hết các lĩnh vực, và tài chính không phải là ngoại lệ. Phân tích tín dụng bằng các thuật toán phân loại, tối ưu hóa danh mục đầu tư, phát hiện gian lận tài chính, tư vấn đầu tư tự động,... là một số ứng dụng của máy học trong lĩnh vực này.

Tác giả Mitchell (1997), đã chia thành ba loại mô hình học máy: Học có giám sát (Supervised learning), học không có giám sát (Unsupervised learning) và học tăng cường (Reinforce learning).

Học có giám sát (Supervised learning) là việc mô hình sẽ được huấn luyện dựa trên các dữ liệu có dán nhãn, qua đó nhằm dự đoán hay phân loại khi có một quan sát mới được truyền vào. Học có giám sát được ứng dụng như dự đoán rủi ro tín dụng, dự đoán giá cổ phiếu, dự đoán rủi ro vỡ nợ của công ty,...

Trong học có giám sát, mô hình được chia làm 2 loại: Hồi quy (Regression) và Phân loại (Classification).

- Hồi quy là bài toán nhằm dự đoán các giá trị liên tục. Mô hình hồi quy được sử dụng để tìm mối quan hệ giữa các biến đầu vào và biến đầu ra là một giá trị thực. Mô hình hồi quy được sử dụng trong các vấn đề tài chính như dự đoán khả năng cho vay của khách hàng, dự báo giá cổ phiếu,...

- Phân loại là dạng mô hình nhằm dự đoán nhãn và phân loại đối tượng vào các nhóm riêng biệt. Mục tiêu của mô hình là dự đoán nhãn của dữ liệu mới dựa trên dữ liệu đã được học trước đó. Một số ứng dụng của mô hình có thể kể đến như phân loại thư rác, phân loại doanh nghiệp có khả năng gặp kiệt quệ tài chính trong tương lai,...

Học không giám sát (Unsupervised learning) là dạng mô hình mà dữ liệu sử dụng để huấn luyện mô hình sẽ không được dán nhãn. Mục tiêu của các mô hình này là nhằm khai phá các cấu trúc tiềm ẩn hay phân cụm các dữ liệu có điểm chung. Một số ứng dụng của các mô hình này có thể kể đến như phân cụm khách hàng, đề xuất sản phẩm,...

Học tăng cường (Reinforcement learning) là hệ thống mà sẽ tự huấn luyện liên tục thông qua quá trình thử nghiệm và liên tục điều chỉnh các tham số của mô hình dựa trên phần thưởng hay hình phạt. Học tăng cường được ứng dụng trong tài chính có thể kể đến như các mô hình tự động giao dịch.

Bảng 2.1: So sánh các loại học máy

	Học có giám sát	Học không giám sát	Học tăng cường
Dữ liệu	X là dữ liệu, Y là nhãn.	X là dữ liệu không được gán nhãn.	X là trạng thái của môi trường, Y là phần thưởng nhận được sau khi thực hiện hành động.
Mục tiêu	Tìm ra mối quan hệ giữa biến X và Y.	Tìm ra cấu trúc ẩn của dữ liệu.	Tối đa hóa phần thưởng và tối thiểu hóa hình phạt từ môi trường.
Chức năng	Dự đoán	Mô tả	Đề xuất
Ví dụ	Phân lớp, hồi quy.	Phân cụm.	Quá trình quyết định, khuyến nghị, RewardSystem.

(Nguồn : Tác giả tổng hợp)

Chung quy lại, học máy trong lĩnh vực tài chính là sự ứng dụng của các thuật toán ML để phân tích dữ liệu tài chính, dự đoán xu hướng thị trường, quản lý danh mục đầu tư, và tối ưu hóa các quyết định tài chính. ML giúp tự động hóa quá trình ra quyết định dựa trên dữ liệu lịch sử và hiện tại, mang lại khả năng dự đoán và tối ưu hóa hiệu suất trong các lĩnh vực như giao dịch chứng khoán, quản lý rủi ro tín dụng, và tư vấn đầu tư.

2.2 Tổng quan lý thuyết về các mô hình học máy

2.2.1 Mạng nơ ron nhân tạo

Mạng nơ ron nhân tạo là một mô hình xử lý thông tin được lấy cảm hứng từ cách thức hoạt động của hệ thần kinh sinh học, đặc biệt là não bộ con người. ANN bao gồm một tập hợp lớn các phần tử xử lý (neuron nhân tạo) được kết nối chặt chẽ


với nhau, hoạt động phối hợp để giải quyết các vấn đề cụ thể như nhận dạng mẫu hoặc phân loại dữ liệu (Maind và cộng sự, 2014). ANN được ứng dụng rộng rãi trong các lĩnh vực như nhận dạng hình ảnh, phân tích ngôn ngữ tự nhiên và dự báo, nhờ khả năng tự động phát hiện các đặc trưng quan trọng từ dữ liệu đầu vào.

ANN được xem là một công cụ mạnh mẽ trong việc xử lý các vấn đề có tính phi tuyến và dữ liệu phức tạp mà các phương pháp truyền thống khó giải quyết hiệu quả. Theo nghiên cứu của Liu và Jiang (2021) ANN đã chứng minh ưu thế vượt trội trong các lĩnh vực như nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên, dự báo tài chính, và y học. Các mạng neural sâu (deep neural networks) với nhiều lớp ẩn đã mở rộng khả năng học và trích xuất đặc trưng từ dữ liệu lớn, tạo nên bước đột phá trong trí tuệ nhân tạo hiện đại. Ngoài ra, ANN còn có khả năng học theo cả phương pháp giám sát (supervised learning) và không giám sát (unsupervised learning), giúp mạng tự động nhận diện cấu trúc dữ liệu mà không cần nhãn.

Mạng nơ-ron nhân tạo được cấu thành từ ba thành phần chính, bao gồm:

1. Lớp đầu vào (Input Layer) là nơi tiếp nhận dữ liệu ban đầu từ môi trường hoặc tập dữ liệu huấn luyện. Mỗi nút trong lớp này tương ứng với một đặc trưng hoặc một biến của dữ liệu đầu vào. Lớp đầu vào chỉ đóng vai trò truyền dữ liệu tới các lớp tiếp theo mà không thực hiện tính toán phức tạp.
2. Các lớp ẩn (Hidden Layers) là phần trung tâm quan trọng nhất trong ANN. Đây là những lớp nằm giữa lớp đầu vào và lớp đầu ra, chịu trách nhiệm xử lý, biến đổi và trích xuất các đặc trưng phức tạp từ dữ liệu. Mạng có thể có một hoặc nhiều lớp ẩn tùy thuộc vào độ sâu và kiến trúc của mạng. Trong mỗi lớp ẩn, các nút nhận tín hiệu từ lớp trước đó, thực hiện phép tính trọng số cộng với một giá trị bù (bias), sau đó đưa qua hàm kích hoạt (activation function) để tạo ra tín hiệu mới. Quá trình này giúp mạng học được các mối quan hệ phi tuyến tính và các mẫu đặc trưng phức tạp, nâng cao khả năng phân loại và dự đoán.
3. Lớp đầu ra (Output Layer) là lớp cuối cùng của mạng, có nhiệm vụ cung cấp kết quả dự đoán sau cùng. Tùy từng bài toán cụ thể sẽ quyết định số lượng nút

trong lớp này. Với bài toán phân loại nhị phân, lớp đầu ra thường chỉ có một nút duy nhất để đưa ra xác suất hoặc nhãn của hai lớp. Còn đối với bài toán phân loại nhiều lớp, lớp đầu ra sẽ có nhiều nút tương ứng với số lớp cần phân biệt. Kết quả từ lớp này sẽ được giải mã để đưa ra quyết định cuối cùng về phân loại hoặc dự đoán của mạng nơ-ron nhân tạo.



Hình 2.1: Cấu trúc mạng nơ ron đơn giản

(Nguồn: Trần Thị Kiều và cộng sự, 2020)

Bảng 2.2: Ưu và nhược điểm của ANN

Ưu điểm	Nhược điểm
Có khả năng nhận diện các mối quan hệ phi tuyến tính phức tạp trong dữ liệu.	Yêu cầu tập dữ liệu lớn để đạt hiệu quả huấn luyện tối ưu.
Mô hình linh hoạt, phù hợp áp dụng cho nhiều loại bài toán khác nhau (phân loại, hồi quy).	Có nguy cơ bị overfitting nếu không được tinh chỉnh phù hợp.
Được sử dụng rộng rãi trong các nghiên cứu về học sâu.	Cần nhiều tài nguyên tính toán.

(Nguồn: Tác giả tổng hợp)

2.2.2 Mô hình Multilayer Perceptron

Mô hình Multilayer Perceptron (MLP) là một dạng mạng nơ-ron nhân tạo truyền thẳng (feedforward neural network) bao gồm nhiều lớp neuron được xếp chồng lên nhau, gồm lớp đầu vào, một hoặc nhiều lớp ẩn và lớp đầu ra. Theo giáo trình Trường Đại học Sư phạm Kỹ thuật TP.HCM (2021) MLP có khả năng học các hàm phi tuyến phức tạp nhờ vào các lớp ẩn sử dụng hàm kích hoạt phi tuyến như sigmoid, tanh hoặc ReLU, giúp mô hình hóa các mối quan hệ phi tuyến trong dữ liệu mà các mô hình tuyến tính đơn giản không thể xử lý được. Cấu trúc mạng gồm các neuron trong mỗi lớp liên kết đầy đủ với các neuron ở lớp kế tiếp, tạo thành mạng lưới truyền thẳng từ đầu vào đến đầu ra.

Trong quá trình huấn luyện mạng nơ-ron nhân tạo, khi một mẫu dữ liệu được đưa vào, tín hiệu sẽ lan truyền từ lớp đầu vào qua các lớp ẩn đến lớp đầu ra để tạo thành một kết quả dự đoán. Sai số giữa đầu ra dự đoán và giá trị thực tế được tính toán bằng các hàm mất mát, trong đó hàm Mean Squared Error – MSE và Root Mean Squared Error - RMSE là những hàm phổ biến cho các bài toán hồi quy (Goodfellow và cộng sự, 2016). Hàm mất mát đóng vai trò như một thước đo đánh giá độ chính

xác của mô hình, giúp định hướng quá trình tối ưu hóa trọng số mạng. Để giảm sai số, mạng điều chỉnh trọng số thông qua lan truyền ngược (backpropagation), kết hợp với thuật toán tối ưu hóa, phổ biến là Giảm dần theo Độ dốc (gradient descent). Quá trình huấn luyện được lặp lại qua nhiều vòng (epoch), mỗi vòng nhằm tinh chỉnh trọng số để mô hình ngày càng dự đoán chính xác hơn.

Nhờ vào cấu trúc nhiều lớp và khả năng học phi tuyến tính, MLP có thể học được các mối quan hệ phức tạp giữa đầu vào và đầu ra, trở thành một công cụ mạnh mẽ trong các bài toán phân loại, hồi quy và nhận dạng mẫu (Haykin, 1994; Goodfellow và cộng sự, 2016). Khả năng này giúp MLP vượt trội hơn các mô hình tuyến tính truyền thống trong việc xử lý dữ liệu phi tuyến và phức tạp. Ưu và nhược điểm của mô hình MLP đã được tác giả tổng hợp trong bảng 2.3.

Bảng 2.3: Ưu và nhược điểm của mô hình MLP

Ưu điểm	Nhược điểm
Khả năng học phi tuyến tốt, xử lý các mối quan hệ phức tạp trong dữ liệu.	Cần lượng dữ liệu lớn để tránh overfitting.
Thích hợp cho cả bài toán phân loại và hồi quy.	Khó giải thích kết quả, hoạt động như một “hộp đen”.
Huấn luyện nhanh hơn so với các mô hình phức tạp hơn như LSTM hay Transformer.	Có thể không phù hợp khi dữ liệu có tính tuần tự hoặc phụ thuộc thời gian dài.

(Nguồn: Tác giả tổng hợp)

2.2.3 Mô hình Long Short-Term Memory

Mô hình Long Short-Term Memory được phát minh bởi Sepp Hochreiter và Jürgen Schmidhuber vào năm 1997 nhằm khắc phục những hạn chế của mạng nơ-ron hồi tiếp truyền thống (RNN) như "quên thông tin lâu dài" và đặc biệt là vấn đề biến mất đạo hàm (vanishing gradient) khi học các phụ thuộc dài hạn trong chuỗi dữ liệu (Hochreiter và Schmidhuber, 1997). LSTM giới thiệu cấu trúc tế bào nhớ (memory cell) và các cổng điều khiển (gates) như cổng quên (forget gate), cổng đầu vào (input gate) và cổng đầu ra (output gate), cho phép mạng kiểm soát luồng thông tin đi vào,

lưu trữ và truyền ra ngoài một cách hiệu quả, giúp duy trì thông tin quan trọng trong suốt chuỗi thời gian dài. Nhờ cấu trúc đặc biệt này, LSTM có thể học được các phụ thuộc dài hạn mà RNN truyền thống không thể xử lý hiệu quả.

Thành phần trung tâm của LSTM là trạng thái tế bào (cell state), hoạt động như một dây chuyền vận chuyển thông tin xuyên suốt dãy thời gian, hỗ trợ duy trì khả năng ghi nhớ dài hạn bằng cách giảm thiểu sự thay đổi của thông tin. Ngoài ra, LSTM tích hợp cơ chế các cổng điều khiển, bao gồm cổng quên (forget gate), cổng nhập (input gate), và cổng xuất (output gate), mỗi cổng đảm nhận vai trò kiểm soát lượng thông tin được lưu giữ, loại bỏ hoặc truyền ra, qua đó hỗ trợ mạng học tập và ghi nhớ các mối quan hệ dài hạn một cách hiệu quả, khắc phục nhược điểm mất độ dốc của các mạng nơ-ron hồi tiếp truyền thống. Nhờ những ưu điểm này, LSTM được ứng dụng rộng rãi trong các bài toán liên quan đến chuỗi thời gian, chẳng hạn như nhận diện giọng nói, dịch thuật tự động, và phân tích dữ liệu thời gian, trở thành một công cụ thiết yếu trong lĩnh vực học sâu và trí tuệ nhân tạo. Ngoài ra tác giả trình bày tóm tắt ưu và nhược điểm của LSTM trong bảng 2.4 sau đây.

Bảng 2.4: Ưu điểm và nhược điểm của mô hình LSTM


Ưu điểm	Nhược điểm
Thích hợp với các bài toán có dữ liệu theo chuỗi như dịch máy, nhận diện giọng nói, phân tích cảm xúc.	Cần nhiều tài nguyên tính toán và thời gian huấn luyện.
Khả năng nhớ thông tin trong chuỗi dài mà không bị mất đi (so với RNN truyền thống).	Mô hình phức tạp và khó giải thích.
Dễ dàng xử lý các dữ liệu không có cấu trúc như văn bản và âm thanh.	Đôi khi không đạt được hiệu quả tốt khi dữ liệu quá đơn giản.

(Nguồn: Tác giả tổng hợp)

2.3 Tổng quan về Walk-Forward Optimization

Tác giả Pardo (1992) trong cuốn sách *Design, Testing and Optimization of Trading Systems* đã mô tả Walk-Forward Optimization như "tiêu chuẩn vàng" trong

việc kiểm định và tối ưu hóa các hệ thống giao dịch, nhấn mạnh tính hiệu quả của phương pháp trong việc đánh giá độ bền vững và khả năng thích ứng của mô hình trên dữ liệu mới. WFO là một phương pháp đánh giá mô hình học máy và tối ưu hóa chiến lược dựa trên dữ liệu chuỗi thời gian, trong đó dữ liệu được chia thành các khoảng thời gian huấn luyện (in-sample) và kiểm tra (out-of-sample) liên tiếp nhau. Mô hình được huấn luyện trên một khoảng dữ liệu nhất định, sau đó được kiểm tra trên khoảng dữ liệu kế tiếp không trùng lặp. Quá trình này được lặp lại bằng cách dịch chuyển cửa sổ huấn luyện và kiểm tra về phía trước theo thời gian, thay vì chỉ sử dụng một điểm cắt duy nhất để chia dữ liệu thành tập huấn luyện và kiểm thử, WFO liên tục điều chỉnh các tham số chiến lược dựa trên dữ liệu, giúp mô hình thích ứng với các xu hướng và mô hình thị trường mới nhất. Trong ảnh 2.2 mô tả minh họa cách chia dữ liệu của mô hình WFO.



Hình 2.2: Mô hình WFO

(Nguồn: Chojnacki và Ślepaczuk, 2023)

Lợi thế nổi bật của WFO so với cách chia dữ liệu theo phương pháp truyền thống sẽ được tác giả mô tả trong bảng 2.5.

Bảng 2.5: So sánh WFO với phương pháp truyền thống

Tiêu chí	Walk-Forward Optimization (WFO)	Phương pháp chia dữ liệu truyền thống
Cách thức chia dữ liệu	Dữ liệu chia thành các cửa sổ huấn luyện và kiểm tra, di chuyển liên tục theo thời gian	Dữ liệu được chia một lần thành các tập huấn luyện, kiểm tra, xác thực cố định
Mô phỏng thực tế	Mô phỏng dòng chảy thời gian thực tế, gần với điều kiện triển khai thực tiễn.	Không phản ánh đầy đủ biến động thời gian, đặc biệt với dữ liệu không ổn định.
Mức độ overfitting/underfitting	Liên tục kiểm tra trên dữ liệu mới giúp phát hiện sớm các vấn đề hiệu suất.	Phụ thuộc vào chất lượng tập kiểm tra, dễ bỏ sót các vấn đề tiềm ẩn.
Tính khái quát mô hình	Cao, mô hình được đánh giá qua nhiều chu kỳ kiểm tra, tăng khả năng thích nghi.	Thấp hơn, hiệu suất phụ thuộc vào tập kiểm tra duy nhất, dễ thiên lệch.
Tính thích nghi	Thích nghi tốt với xu hướng và biến động thay đổi theo thời gian.	Không xử lý tốt dữ liệu có tính chu kỳ hoặc thay đổi liên tục.
Độ tin cậy của mô hình	Cao, cung cấp cái nhìn toàn diện qua nhiều lần kiểm tra.	Thấp hơn, kết quả có thể không đại diện nếu tập kiểm tra không đủ đa dạng.

(Nguồn: Tác giả tổng hợp)

2.4 Khái niệm dự báo giá cổ phiếu

Dự báo giá cổ phiếu là quá trình sử dụng các phương pháp định lượng và định tính để ước đoán giá trị tương lai của một cổ phiếu dựa trên các dữ liệu lịch sử, xu hướng biến động giá, các yếu tố kinh tế vĩ mô, thông tin doanh nghiệp và các tín hiệu thị trường.

Bài nghiên cứu của tác giả Vương và cộng sự, (2024): Dự báo giá cổ phiếu là một lĩnh vực nghiên cứu nhằm tìm hiểu và ứng dụng các mô hình thống kê, học máy, hoặc học sâu để phân tích và dự đoán mức giá tương lai của cổ phiếu, thường dựa vào chuỗi thời gian giá, các đặc trưng của cổ phiếu, hoặc các yếu tố kinh tế liên quan. Mục tiêu là giúp nhà đầu tư và các tổ chức tài chính tối ưu hóa quyết định đầu tư, quản trị rủi ro và khai thác cơ hội sinh lời thông qua việc đưa ra các dự đoán sát thực tế hơn đối với biến động giá của thị trường chứng khoán.

Dự báo giá cổ phiếu là quá trình áp dụng các công cụ, mô hình và kỹ thuật phân tích để ước tính giá trị tương lai của cổ phiếu hoặc tài sản tài chính. Mục đích là hỗ trợ nhà đầu tư ra quyết định mua, bán hoặc giữ cổ phiếu, tối đa hóa lợi nhuận và giảm thiểu rủi ro. Các phương pháp dự báo giá cổ phiếu bao gồm phân tích cơ bản dựa trên dữ liệu tài chính và kinh doanh của công ty và dự báo bằng phân tích kỹ thuật dựa trên biểu đồ, chỉ số kỹ thuật.

2.4.1 Phân tích cơ bản

Phân tích cơ bản: Là phương pháp dùng để xác định giá trị nội tại của cổ phiếu trên thị trường qua việc đánh giá các yếu tố cơ bản ảnh hưởng đến giá, rồi so sánh với giá giao dịch trên thị trường để xác định cổ phiếu bị định giá thấp hay cao. Nếu giá thị trường thấp hơn giá trị thực, cổ phiếu được coi là bị định giá thấp (undervalued) và nên mua; ngược lại, nếu giá cao hơn giá trị thực, cổ phiếu bị định giá cao (overvalued) và nên bán (Damodaran, 2012). Các nhà phân tích cơ bản thường tập trung xem xét các báo cáo tài chính, phân tích các tác nhân vĩ mô như tăng trưởng kinh tế, chính sách tiền tệ, tài khóa, cán cân thanh toán, cán cân thương mại, lạm phát, lãi suất và tỷ giá, phân tích ngành, phân tích mô hình hoạt động và hiệu quả quản lý của công ty để ra quyết định đầu tư (Drakopoulou, 2016).

Trong thực tiễn đầu tư, phân tích cơ bản được ứng dụng rộng rãi trong nhiều chiến lược khác nhau. Phương pháp này giúp xác định những cổ phiếu có giá thị trường thấp hơn đáng kể so với giá trị nội tại. Các quỹ đầu tư dài hạn thường sử dụng phân tích cơ bản để đánh giá triển vọng tăng trưởng ổn định của doanh nghiệp qua

nhiều năm. Ngoài ra, phương pháp này còn giúp các nhà quản lý rủi ro đánh giá sức khỏe tài chính của doanh nghiệp thông qua các chỉ số tài chính then chốt.

Phân tích cơ bản mang lại nhiều lợi thế quan trọng cho nhà đầu tư. Ưu điểm nổi bật nhất là tính khách quan khi dựa trên các dữ liệu tài chính và kinh tế có thể kiểm chứng. Phương pháp này đặc biệt phù hợp cho chiến lược đầu tư dài hạn, giúp nhà đầu tư vượt qua được các biến động ngắn hạn của thị trường. Khác với phân tích kỹ thuật chỉ tập trung vào biểu đồ giá, phân tích cơ bản cung cấp cái nhìn toàn diện về tiềm năng phát triển, lợi thế cạnh tranh và rủi ro tiềm ẩn của doanh nghiệp. Hơn nữa, nguyên tắc phân tích này có thể áp dụng linh hoạt cho nhiều loại tài sản khác nhau từ cổ phiếu, trái phiếu đến bất động sản.

Bên cạnh những ưu điểm, phân tích cơ bản cũng tồn tại một số hạn chế đáng kể. Quá trình phân tích đòi hỏi nhiều thời gian và công sức để thu thập, xử lý thông tin từ nhiều nguồn khác nhau. Phương pháp này tỏ ra kém hiệu quả trong các tình huống thị trường ngắn hạn khi giá cả bị chi phối bởi yếu tố tâm lý hoặc tin đồn. Một thách thức khác là nguy cơ dựa vào thông tin tài chính không chính xác do các thủ thuật kế toán hoặc báo cáo bị làm đẹp. Đặc biệt, phân tích cơ bản khó lường trước được các sự kiện bất ngờ như khủng hoảng chính trị, thiên tai hay đại dịch - những yếu tố có thể tác động mạnh đến giá cổ phiếu trong ngắn hạn.

2.4.2 Phân tích kỹ thuật

Phân tích kỹ thuật: Theo tác giả Brown và Jennings (1989) phân tích kỹ thuật là phương pháp dự báo giá thông qua nghiên cứu dữ liệu lịch sử thị trường, nhà phân tích sử dụng biểu đồ giá, khối lượng giao dịch để đánh giá biến động cung-cầu với cổ phiếu từ đó có thể đưa ra khuyến nghị mua-bán cổ phiếu trên thị trường.

Phân tích kỹ thuật là phương pháp dự báo biến động giá cổ phiếu dựa trên việc nghiên cứu các dữ liệu lịch sử về giá và khối lượng giao dịch nhằm xác định xu hướng và mô hình giá trong tương lai. Theo nghiên cứu của (Inani và cộng sự, 2024), phân tích kỹ thuật tập trung vào hành vi thị trường được phản ánh qua giá và khối lượng giao dịch, giúp nhà đầu tư xác định các điểm mua bán hợp lý dựa trên các chỉ báo kỹ thuật và mô hình giá.

Nguyên lý cơ bản của phân tích kỹ thuật dựa trên ba quan điểm chính. Thứ nhất, giá cổ phiếu được xem là phản ánh toàn bộ thông tin, nghĩa là tất cả các yếu tố ảnh hưởng đến giá, bao gồm thông tin nội bộ, tâm lý của nhà đầu tư và các yếu tố kinh tế, đều đã được thể hiện đầy đủ trong giá thị trường hiện tại. Do đó, việc phân tích biến động giá và khối lượng giao dịch là đủ để dự đoán xu hướng trong tương lai. Thứ hai, giá chứng khoán không biến động ngẫu nhiên mà thường di chuyển theo các xu hướng rõ ràng như tăng, giảm hoặc đi ngang; phân tích kỹ thuật nhằm mục đích xác định và theo dõi các xu hướng này để giúp nhà đầu tư lựa chọn thời điểm mua hoặc bán hợp lý (Carol Dmello và cộng sự, 2025). Thứ ba, lịch sử có xu hướng lặp lại do tâm lý nhà đầu tư mang tính chu kỳ và dễ bị ảnh hưởng bởi các cảm xúc như sợ hãi hoặc tham lam. Do đó, việc nhận diện các mẫu hình giá và hành vi thị trường trong quá khứ đóng vai trò quan trọng trong việc dự báo các biến động giá trong tương lai.

Với những ưu điểm nổi bật là dễ áp dụng và phản ánh nhanh các biến động giá trên thị trường, phân tích kỹ thuật giúp nhà đầu tư đưa ra quyết định giao dịch trong thời gian ngắn mà không cần chờ đợi các báo cáo tài chính. Công cụ này phù hợp với nhiều khung thời gian giao dịch khác nhau, từ ngắn hạn đến dài hạn, và có thể kết hợp đa dạng các chỉ báo kỹ thuật để tăng tính chính xác trong việc xác định xu hướng và điểm mua bán. Ngoài ra, việc sử dụng các chỉ báo kỹ thuật còn giúp nhà đầu tư phát hiện sớm các tín hiệu đảo chiều và xu hướng mạnh mẽ trên thị trường (Carol Dmello và cộng sự, 2025).

Mặc dù có nhiều ưu điểm, phân tích kỹ thuật cũng tồn tại những hạn chế nhất định. Do phụ thuộc vào hành vi và tâm lý nhà đầu tư, các chỉ báo kỹ thuật có thể bị ảnh hưởng bởi các yếu tố tâm lý, dẫn đến tín hiệu không chính xác hoặc sai lệch trong những giai đoạn thị trường biến động mạnh hoặc không có xu hướng rõ ràng. Một số chỉ báo như SMA có độ trễ do dựa trên dữ liệu quá khứ, làm chậm phản ứng với biến động giá mới. Đồng thời, việc sử dụng hiệu quả các công cụ này đòi hỏi người dùng phải có kiến thức chuyên sâu và kinh nghiệm để tránh những sai lầm trong phân tích.

2.5 Các nghiên cứu có liên quan

Dự đoán chuỗi thời gian tài chính, đặc biệt là giá cổ phiếu, đã thu hút sự chú ý của nhiều nhà nghiên cứu nhờ tính ứng dụng cao trong đầu tư và quản lý rủi ro. Các phương pháp dựa trên học sâu, đặc biệt là mạng LSTM, đã được sử dụng rộng rãi do khả năng học các mẫu phức tạp trong dữ liệu thời gian. Dưới đây, tác giả sẽ khảo lược các công trình liên quan, tập trung vào các phương pháp học máy như MLP, LSTM,... và việc sử dụng chỉ báo kỹ thuật trong dự đoán giá cổ phiếu.

2.5.1 Các nghiên cứu nước ngoài

Mehtab và cộng sự (2020) thực hiện nghiên cứu về Dự đoán giá cổ phiếu bằng cách sử dụng máy học và các mô hình học sâu dựa trên LSTM. Nghiên cứu được thực hiện với dữ liệu sử dụng giá trị chỉ số NIFTY 50 của Sở giao dịch chứng khoán quốc gia (NSE) của Ấn Độ, trong khoảng thời gian từ ngày 29 tháng 12 năm 2014 đến ngày 31 tháng 7 năm 2020. Tác giả xây dựng tám mô hình hồi quy bằng cách sử dụng dữ liệu đào tạo bao gồm các bản ghi chỉ số NIFTY 50 từ ngày 29 tháng 12 năm 2014 đến ngày 28 tháng 12 năm 2018. Sử dụng các mô hình hồi quy này, để dự đoán giá trị mở cửa của NIFTY 50 trong khoảng thời gian từ ngày 31 tháng 12 năm 2018 đến ngày 31 tháng 7 năm 2020. Tác giả triển khai nghiên cứu thành nhóm mô hình:

- Mô hình học máy: Bao gồm tám mô hình hồi quy (hồi quy tuyến tính đa biến, MARS, cây quyết định, bagging, XGBoost, rừng ngẫu nhiên, mạng nơ-ron nhân tạo, và máy vector hỗ trợ).
- Mô hình học sâu: Bốn mô hình LSTM với các kiến trúc khác nhau, bao gồm mô hình đơn biến (univariate) sử dụng dữ liệu một tuần hoặc hai tuần trước, và mô hình mã hóa-giải mã (encoder-decoder) với dữ liệu đơn biến hoặc đa biến.

Các mô hình học máy dự đoán giá trị mở cửa hàng ngày, trong khi các mô hình LSTM dự đoán giá trị mở cửa cho cả tuần (5 ngày) bằng phương pháp walk-forward validation. Hiệu suất được đánh giá bằng hai chỉ số: hệ số tương quan Pearson giữa giá trị thực tế và dự đoán, và tỷ lệ RMSE trên giá trị trung bình của giá mở cửa. Kết quả cho thấy các mô hình học sâu dựa trên LSTM vượt trội so với các mô hình học

máy về độ chính xác. Trong số các mô hình học máy, hồi quy tuyến tính đa biến và rừng ngẫu nhiên đạt hiệu suất tốt nhất trên tập kiểm tra, với hệ số tương quan 0.99 và RMSE thấp (0.42). Trong số các mô hình LSTM, mô hình đơn biến sử dụng dữ liệu một tuần trước (LSTM 1) là hiệu quả nhất, với tỷ lệ RMSE/trung bình là 0.0311 và thời gian thực thi trung bình 18.64 giây. Ngược lại, mô hình LSTM mã hóa-giải mã đa biến (LSTM 4) có hiệu suất kém nhất (tỷ lệ RMSE/trung bình là 0.1711) và thời gian thực thi lâu (66.91 giây), cho thấy dữ liệu NIFTY 50 không phù hợp với phân tích đa biến.

Tác giả Khare và cộng sự (2017) nghiên cứu so sánh giữa mô hình LSTM và mô hình MLP trong dự báo giá chứng khoán ngắn hạn. Bài báo thảo luận về Mạng Nơ-ron Tiến và Mạng Nơ-ron Tái phát. Dữ liệu sử dụng là giá cổ phiếu từng phút cho tất cả các ngày giao dịch của 10 cổ phiếu, được niêm yết trên New York Stock Exchange, trong khoảng thời gian 1 năm. Với mô hình LSTM, tác giả đã sử dụng phương pháp cửa sổ trượt của 20 giá trước đó được xem xét. Kiến trúc LSTM, MLP sử dụng một mạng nơ-ron sâu với bốn lớp ẩn, trong đó lớp đầu vào và lớp đầu ra có số nơ-ron tương tự và chức năng tương tự như LSTM. Mô hình MLP không thể được sử dụng để giải quyết các vấn đề dự đoán dưới dạng các vấn đề chuỗi thời gian. Vì vậy, tác giả đã sử dụng chiến lược dự đoán là dự đoán phút thứ hai từ thời điểm hiện tại. Các chỉ báo tài chính kỹ thuật khác nhau đã được chọn làm đặc điểm trong mô hình. EWMA, MAD, MACD, RSI... Kết quả RMSE của MLP là 0.0025 và LSTM là 0.048 cho thấy rõ ràng rằng MLP đã hoạt động tốt hơn LSTM ở dự đoán giá cổ phiếu ngắn hạn.

Theo nghiên cứu của Noorbakhsh và Shaygani (2024), tác giả sử dụng các mô hình học sâu để dự đoán giá cổ phiếu, tập trung vào dữ liệu từ năm công ty niêm yết trên Sở Giao dịch Chứng khoán Tehran trong khoảng thời gian từ 2001 đến 2022. Năm mô hình được áp dụng, bao gồm hai mô hình lai (CNN-LSTM, CNN-GRU) và ba mô hình đơn (CNN, LSTM, GRU). Mô hình CNN-LSTM lai được sử dụng làm mô hình chính, với độ chính xác dự đoán được so sánh với bốn mô hình còn lại. Kết quả cho thấy mô hình CNN-LSTM thể hiện hiệu suất vượt trội so với các mô hình

khác, mặc dù mô hình lai CNN-GRU cũng cho kết quả khả quan. Trong số các mô hình đơn, mô hình CNN vượt trội hơn cả mô hình LSTM và GRU. Độ chính xác của các mô hình bị ảnh hưởng đáng kể bởi các yếu tố như biến động, làm tăng sự không chắc chắn. Nghiên cứu này, chỉ dựa vào các chỉ báo kỹ thuật, cho thấy rằng việc đạt được kết quả tối ưu không chỉ phụ thuộc vào việc chọn mạng nơ-ron phù hợp mà còn vào việc xác định số lượng lớp thích hợp trong mỗi mô hình. Tổng thể, mô hình CNN-LSTM mang lại hiệu suất tốt nhất trên bốn trong năm cổ phiếu, với mô hình CNN-GRU hơi vượt trội hơn một cổ phiếu. Trong số các mô hình đơn, mô hình CNN luôn vượt trội hơn các mô hình khác.

Hiransha và cộng sự (2018) nghiên cứu tập trung vào việc áp dụng các mô hình học sâu (deep learning) để dự đoán giá cổ phiếu trên Sàn Giao dịch Chứng khoán Quốc gia Ấn Độ (NSE) và kiểm tra khả năng áp dụng các mô hình này trên một thị trường khác, cụ thể là Sàn Giao dịch Chứng khoán New York (NYSE). Nghiên cứu nhằm so sánh hiệu suất của bốn kiến trúc học sâu: MLP, Recurrent Neural Network (RNN), LSTM, và Convolutional Neural Network (CNN), với mô hình tuyến tính truyền thống ARIMA trong việc dự đoán giá đóng cửa hàng ngày của cổ phiếu. Mục tiêu là xác định liệu các mô hình học sâu có thể vượt qua các hạn chế của mô hình tuyến tính như ARIMA. Nghiên cứu cũng kiểm tra khả năng khái quát hóa của các mô hình khi được huấn luyện trên dữ liệu NSE và thử nghiệm trên dữ liệu NYSE, nhằm khám phá các động lực chung (common dynamics) giữa hai thị trường. Dữ liệu chuỗi thời gian được chia thành các cửa sổ (window) có kích thước 200 ngày để dự đoán giá cổ phiếu trong 10 ngày tiếp theo. Hiệu suất được đo lường bằng Mean Absolute Percentage Error (MAPE). Kết quả thu được là các mô hình học sâu vượt trội hơn ARIMA trong việc dự đoán giá cổ phiếu, nhờ khả năng xử lý dữ liệu phi tuyến. Đối với Maruti: CNN (4.07%), MLP (4.81%), RNN (5.82%), LSTM (6.03%), ARIMA(20.66)%.

Bài nghiên cứu của Duan (2025) nghiên cứu tập trung vào việc so sánh hiệu suất của hai mô hình học sâu phổ biến, MLP và LSTM, trong việc dự đoán giá cổ phiếu dựa trên dữ liệu lịch sử của Google (GOOG). Từ 19/8/2004 đến 5/12/2023,

gồm 8,853 bản ghi và Dữ liệu giá cổ phiếu từ nhiều công ty thuộc các ngành và quốc gia khác nhau, thời gian: Từ 3/1/2000 đến 28/2/2025 với 304,180 bản ghi. Mục đích phân tích phụ để đánh giá hiệu suất trên dữ liệu quy mô lớn và đa dạng. Nghiên cứu nhằm đánh giá khả năng của hai mô hình này trong việc xử lý dữ liệu chuỗi thời gian tài chính phi tuyến và biến động cao, vốn là thách thức lớn đối với các phương pháp thống kê truyền thống như ARIMA và GARCH. Mục tiêu là xác định mô hình nào hiệu quả hơn trong các điều kiện thị trường khác nhau (giá cao/thấp, biến động cao/thấp, dữ liệu quy mô nhỏ/lớn) và cung cấp thông tin hữu ích để hỗ trợ các nhà đầu tư, quản lý quỹ, và tổ chức tài chính đưa ra quyết định đầu tư thông minh hơn, giảm thiểu rủi ro tài chính. Kết quả đạt được tổng thể là LSTM hiệu quả hơn trong các kịch bản biến động thấp, nhờ khả năng nắm bắt các mẫu dài hạn. MLP vượt trội trong các kịch bản giá thấp và dữ liệu nhỏ, nhờ cấu trúc đơn giản hơn, ít bị overfitting. Cả hai mô hình đều mạnh mẽ trên dữ liệu lớn, nhưng MLP có lợi thế về độ ổn định.

Bài nghiên cứu của Vijh và cộng sự (2020) thực hiện nghiên cứu về dự đoán giá đóng cửa cổ phiếu bằng cách sử dụng hai kỹ thuật học máy: Mạng nơ-ron nhân tạo (Artificial Neural Network) và Rừng ngẫu nhiên (Random Forest). Các mô hình được xây dựng dựa trên tập hợp các biến mới được tạo từ dữ liệu tài chính, bao gồm giá mở cửa, giá cao nhất, giá thấp nhất và giá đóng cửa. Nghiên cứu được thực hiện với dữ liệu nghiên cứu được thu thập là dữ liệu lịch sử của 5 công ty được lấy từ Yahoo Finance từ 04/05/2009 đến 04/05/2019 bao gồm Nike, Goldman Sachs, Johnson and Johnson, Pfizer và JP Morgan Chase and Co. Bộ dữ liệu được chia thành hai tập: tập huấn luyện từ 04/06/2009 đến 04/03/2017 và tập kiểm tra từ 04/04/2017 đến 04/05/2019. Mô hình Mạng nơ-ron nhân tạo đạt kết quả tốt hơn Rừng ngẫu nhiên ở hầu hết các công ty (Nike, JP Morgan, Johnson & Johnson, Pfizer). Giá trị RMSE thấp nhất là 0.42 (Pfizer), MAPE thấp nhất là 0.77% (Pfizer), và MBE thấp nhất là -0.013 (Johnson & Johnson). Phân tích cho thấy Mạng nơ-ron nhân tạo có khả năng dự đoán chính xác hơn Rừng ngẫu nhiên, đặc biệt với các công ty có dữ liệu biến động thấp. Các biến mới được tạo ra từ dữ liệu tài chính đóng vai trò quan trọng trong việc cải thiện độ chính xác của mô hình.

Bài nghiên cứu của Saputra (2023) thực hiện nghiên cứu về hệ thống dự đoán cổ phiếu sử dụng các chỉ số kỹ thuật với phương pháp LSTM. Nghiên cứu được thực hiện với dữ liệu nghiên cứu được thu thập từ cổ phiếu của 4 ngân hàng lớn: Bank Central Asia (BBCA), Bank Mandiri (BMRI), Bank Rakyat Indonesia (BBRI), Bank Negara Indonesia (BBNI), dữ liệu được tải xuống từ Yahoo Finance trong khoảng thời gian từ 09/11/2017 đến 08/08/2022, với khung thời gian phân tích từ 15/12/2017 đến 08/08/2022, sau đó bộ dữ liệu được thêm vào các chỉ số kỹ thuật như RSI, MACD, MA. Bằng phương pháp LSTM và hệ thống được đánh giá bằng Average Absolute Percentage Error (MAPE). Quá trình xử lý dữ liệu được thực hiện trên Excel, bổ sung các trường như Gain, Loss, Average Gain, Average Loss, RS, EMA12, EMA26, và MA. Tập dữ liệu được chia thành 80% tập huấn luyện và 20% tập kiểm tra. Ba thử nghiệm được thực hiện với các đầu vào khác nhau: Thử nghiệm 1 (Close, Open), Thử nghiệm 2 (Close, RSI, MACD, MA), và Thử nghiệm 3 (Close, Open, RSI, MACD, MA). Nghiên cứu của Saputra đạt MAPE trung bình 0,70% chứng minh hiệu quả của LSTM trong dự đoán giá cổ phiếu. Việc tích hợp các chỉ số kỹ thuật (RSI, MACD, MA) và sử dụng dữ liệu từ bốn ngân hàng LQ45 tăng tính thực tiễn, hỗ trợ nhà đầu tư.

2.5.2 Các nghiên cứu trong nước

Theo bài nghiên cứu của (Đào Lê Kiều Oanh & Nguyễn Thị Minh Châu, 2024) các tác giả sử dụng dữ liệu nghiên cứu là giá đóng cửa hàng ngày của chỉ số VNIndex từ năm 2001 đến năm 2023, được thu thập từ Vietstock, nghiên cứu đã so sánh hai phương pháp học máy TCN, LSTM để đánh giá hiệu quả của hai mô hình học máy trong việc dự đoán biến động của chỉ số VNIndex. Kết quả đánh giá mô hình cho ra kết quả là mô hình LSTM dự báo chính xác hơn so với TCN với WAPE cải thiện của LSTM là 0.041 và TCN là 0.05.

Bài nghiên cứu của Quý và cộng sự (2024) sử dụng mô hình học sâu LSTM trong dự đoán giá trị của cổ phiếu. Dữ liệu nghiên cứu trong bài báo là giá cổ phiếu của Amazon với mã thị trường là AMZN, dữ liệu cổ phiếu gồm 25 năm dữ liệu. Kết quả chỉ ra rằng phương pháp được đề xuất có thể dự đoán xu hướng giá cổ phiếu của

giá đóng cửa đã điều chỉnh với RMSE là 0.1387 và MAE 0.1007. Mặc dù phương pháp Long Short-Term Memory có thể không đạt được những dự đoán chính xác cao, nhưng nó có thể cung cấp một sự gần đúng tương đối gần với xu hướng dữ liệu thực tế.

Bảng 2.6: Tổng hợp các nghiên cứu liên quan

Tác giả (năm công bố)	Dữ liệu nghiên cứu	Mô hình	Kết quả nghiên cứu
Mehtab và cộng sự (2020)	Chỉ số NIFTY 50 của NSE -Ấn Độ, từ 29/12/2014 đến 31/7/2020.	Tám mô hình hồi quy và bốn mô hình LSTM với các kiến trúc khác nhau.	Các mô hình học sâu vượt trội so với các mô hình học máy về độ chính xác.
Kaustubh Khare và cộng sự (2018)	Sàn Giao dịch Chứng khoán NSE và kiểm tra khả năng áp dụng các mô hình này trên thị trường khác NYSE.	Sử dụng 2 mô hình: MLP và LSTM.	MLP đã hoạt động tốt hơn LSTM ở dự đoán giá cổ phiếu ngắn hạn.
(Noorbakhsh và Shaygani, 2024)	Dữ liệu của năm công ty niêm yết trên Sở Giao dịch Chứng khoán Tehran từ năm 2001 đến 2022.	Xây dựng 5 mô hình bao gồm 3 mô hình đơn, và 2 mô hình lai.	Tổng thể, CNN-LSTM mang lại hiệu suất tốt nhất. Trong các mô hình đơn, mô hình CNN vượt trội hơn .
(Duan, 2025)	Dữ liệu lịch sử của GOOG từ	Sử dụng 2 mô hình là LSTM và MLP.	LSTM hiệu quả hơn trong các

	2004 đến 2023, và dữ liệu giá cổ phiếu từ nhiều công ty thuộc các ngành và quốc gia khác nhau, từ năm 2000 đến năm 2025.		kịch bản biến động thấp. MLP vượt trội trong các kịch bản giá thấp và dữ liệu nhỏ.
Hiransha và cộng sự (2018)	Huấn luyện trên dữ liệu NSE và thử nghiệm trên dữ liệu NYSE	Sử dụng 4 mô hình: MLP, LSTM, CNN, RNN.	Các mô hình học sâu vượt trội hơn ARIMA trong việc dự đoán giá cổ phiếu.
Vijh và cộng sự (2020)	Dữ liệu lịch sử của 5 công ty được lấy từ Yahoo Finance từ 04/05/2009 đến 04/05/2019	Mô hình ANN và Rừng ngẫu nhiên (Random Forest).	Mô hình ANN đạt kết quả tốt hơn Rừng ngẫu nhiên ở hầu hết các công ty.
Saputra R (2023)	Giá cổ phiếu của 4 ngân hàng: Bank Central Asia, Bank Aandiri Bank Rakyat Indonesia, Bank Negara Indonesia từ	Xây dựng LSTM với ba thử nghiệm được thực hiện với các đầu vào khác nhau: Thử nghiệm 1 (Close, Open), Thử nghiệm 2 (Close, RSI, MACD, MA), và Thử nghiệm 3	Hệ thống dự đoán cho chuỗi thời gian tối ưu hơn khi chỉ sử dụng các trường Close, RSI, MACD và MA.

	09/11/2017 đến 08/08/2022, với khung thời gian phân tích từ 15/12/2017 đến 08/08/2022	(Close, Open, RSI, MACD, MA).	
(Đào Lê Kiều Oanh & Nguyễn Thị Minh Châu, 2024)	Giá đóng cửa hàng ngày của chỉ số VNIndex từ năm 2001 đến năm 2023, được thu thập từ Vietstock.	Sử dụng thuật toán TCN với 2 mô hình. Mô hình LSTM	Các chỉ số ở thuật toán LSTM thấp hơn so với TCN.
Quý và cộng sự (2024)	Giá cổ phiếu của Amazon gồm 25 năm dữ liệu.	Mô hình LSTM sẽ được áp dụng nhằm dự đoán giá trị cổ phiếu cho ngày tiếp theo.	Phương pháp LSTM cung cấp một sự gần đúng tương đối gần với xu hướng dữ liệu thực tế.

(Nguồn: Tác giả tổng hợp)

2.5.3. Khoảng trống nghiên cứu

Qua quá trình tìm hiểu, phân tích và lược khảo các nghiên cứu trước có liên quan đến việc xây dựng và ứng dụng các mô hình học máy trong dự báo cổ phiếu, các chỉ số chứng khoán, tác giả nhận ra rằng hầu hết các mô hình được các tác giả xây dựng trong các nghiên cứu dự báo giá cổ phiếu chưa chú trọng đến phương pháp xây dựng mô hình theo hướng Walk-Forward Optimization – một kỹ thuật đặc thù, phù hợp với tính chất của dữ liệu chuỗi thời gian. Thay vì huấn luyện mô hình trên toàn bộ tập dữ liệu lịch sử và đánh giá trên một phần cố định, chưa xem xét trật tự thời gian điều này có thể dẫn tới không phản ánh thực tế được dữ liệu. Ngoài ra có

thể gây ra lãng phí dữ liệu vì tập train và test chỉ được sử dụng 1 lần trong quá trình xây dựng mô hình. WFO mô phỏng quá trình thời gian trong thực tế bằng cách mở rộng dần tập huấn luyện theo thời gian và kiểm định mô hình trên các tập dữ liệu mới nhất, không trùng lặp. Điều này cho phép đánh giá hiệu quả mô hình một cách liên tục và sát với bối cảnh vận hành thực tế của thị trường tài chính, nơi dữ liệu luôn biến động và không thể quan sát toàn bộ trong tương lai. Vì vậy, bài viết được thực hiện nhằm mục đích lấp đầy khoảng trống nghiên cứu này.


KẾT LUẬN CHƯƠNG 2

Trong chương 2, tác giả đã trình bày tổng quan lý thuyết về các phương pháp dự báo chứng khoán, tổng quan về dữ liệu, giới thiệu về học máy, một số mô hình máy học và giới thiệu về Walk-forward optimization bên cạnh đó là lược khảo các nghiên cứu trước đây đã được công bố để làm rõ tính cấp thiết của đề tài, tìm ra các khoảng trống nghiên cứu và làm cơ sở cho việc đề xuất mô hình nghiên cứu và phân tích kết quả nghiên cứu được trình bày ở các chương sau.

CHƯƠNG 3: XÂY DỰNG MÔ HÌNH NGHIÊN CỨU

3.1 Quy trình nghiên cứu

Để đảm bảo tính hệ thống, logic của nghiên cứu cũng như tăng độ tin cậy của kết quả đạt được, tác giả đã thiết kế một quy trình nghiên cứu rõ ràng, khoa học. Từng bước thực hiện nghiên cứu này được minh họa trong hình 3.1



Hình 3.1: Quy trình nghiên cứu

(Nguồn: Tác giả tổng hợp)

Bước 1: Thu thập và xử lý dữ liệu: tác giả tiến hành thu thập dữ liệu lịch sử giá cổ phiếu của ngân hàng Techcombank (TCB) trong khoảng thời gian từ ngày 4 tháng 6 năm 2018 đến ngày 31 tháng 3 năm 2025, sau đó kiểm tra các giá trị thiếu, trùng lặp, ngoại lai, nhiễu và xử lý các giá trị này. Cuối cùng là tính toán các chỉ báo kỹ thuật dùng làm biến đầu vào cho mô hình.

Bước 2: Phân tích và khai phá dữ liệu bằng các phương pháp thống kê mô tả, trực quan hóa dữ liệu bằng biểu đồ. Từ đó có thể phát hiện được các xu hướng giá, các mối quan hệ giữa các chỉ số kỹ thuật và giá cổ phiếu. Lựa chọn các biến đầu vào (feature) phù hợp cho mô hình nghiên cứu, tránh bị đa cộng tuyến làm cho mô hình khó nắm bắt được các kỹ thuật.

Bước 3: Tiến hành xây dựng và huấn luyện trên các mô hình học máy dự báo đã được lựa chọn. Các mô hình được chọn bao gồm MLP và LSTM. Ở đây, tác giả sẽ sử dụng mô hình Walk forward optimization với chiến lược Expanding window để huấn luyện mô hình.

Bước 4: Sử dụng các thước đo để kiểm tra và đánh giá hiệu suất của mô hình. Trên cơ sở đó tác giả có thể chọn ra được mô hình dự báo giá cổ phiếu phù hợp và đạt được kết quả tốt như mong đợi.

3.2 Thực hiện nghiên cứu

3.2.1 Thu thập và tiền xử lý dữ liệu

Đối với các mô hình học máy, kích thước mẫu lớn là một lợi thế rất lớn. Các mô hình ML, nếu càng có nhiều dữ liệu, sẽ học được nhiều hơn, kiểm soát sai số tốt hơn, do đó có thể ước lượng chính xác và đưa ra dự báo chính xác hơn. Bên cạnh đó, kích thước mẫu nhỏ có thể dẫn tới hiện tượng “overfitting”, nghĩa là mô hình dự báo quá tốt nhưng chỉ trên tập dữ liệu huấn luyện, với các tập dữ liệu khác thì mô hình không thể duy trì khả năng dự báo như trên tập huấn luyện.

3.2.1.1 Thu thập dữ liệu

Trong bài nghiên cứu tác giả sử dụng ngôn ngữ lập trình là Python. Đây là một ngôn ngữ lập trình bậc cao, đa năng và mã nguồn mở, được thiết kế với triết lý ưu tiên sự dễ đọc và đơn giản. Ra đời vào năm 1991 bởi Guido van Rossum, Python đã nhanh chóng trở thành một trong những ngôn ngữ lập trình phổ biến nhất thế giới, đặc biệt trong các lĩnh vực như khoa học dữ liệu, học máy, trí tuệ nhân tạo và phân tích tài chính. Python có cú pháp gần với ngôn ngữ tự nhiên, dễ học và dễ sử dụng, phù hợp cả với người mới bắt đầu lẫn các chuyên gia công nghệ. Không giống như các ngôn ngữ lập trình truyền thống thiên về cấu trúc phức tạp như C++ hay Java, Python cho phép triển khai các thuật toán phức tạp chỉ với vài dòng mã, điều này đặc biệt hữu ích khi xây dựng mô hình phân tích hoặc dự báo.

Tác giả dùng thư viện Vnstock để thu thập dữ liệu lịch sử giá cổ phiếu. Thư viện vnstock là một thư viện Python mã nguồn mở được phát triển nhằm hỗ trợ thu thập, xử lý và khai thác dữ liệu thị trường chứng khoán Việt Nam một cách dễ dàng và hiệu

quả. Đây là một công cụ cực kỳ hữu ích cho các nhà đầu tư, nhà phân tích dữ liệu tài chính, nhà phát triển hệ thống giao dịch tự động, cũng như các nghiên cứu sinh, sinh viên chuyên ngành tài chính hoặc khoa học dữ liệu quan tâm đến thị trường chứng khoán Việt Nam.

3.2.1.2 Tiền xử lý dữ liệu

Trong quá trình thu thập dữ liệu, việc gặp phải các giá trị thiếu (NaN) và giá trị trùng lặp (Duplicate) là một vấn đề phổ biến và có thể gây ảnh hưởng nghiêm trọng đến tính toàn vẹn và độ tin cậy của các phân tích sau này. Để đảm bảo chất lượng dữ liệu và duy trì độ ổn định cho các mô hình dự báo, việc điền các giá trị thiếu là bước quan trọng trong tiền xử lý dữ liệu. Tác giả sử dụng lệnh `isnull().sum()` và lệnh `duplicated().sum()` để kiểm tra các giá trị thiếu và trùng lặp trong dữ liệu lịch sử giá.

Ngoài ra bộ dữ liệu lịch sử giá bao gồm các quan sát không thể tránh khỏi có các giá trị ngoại lai (outliers), gây ảnh hưởng tiêu cực đến chất lượng và hiệu suất của các mô hình.

3.2.1.3 Chuẩn hóa dữ liệu

Chuẩn hóa dữ liệu là một bước quan trọng trong quá trình xử lý và xây dựng mô hình dự báo giá chứng khoán. Cả hai mô hình MLP và LSTM đều rất nhạy cảm với dữ liệu chưa chuẩn hóa. Khi dữ liệu không chuẩn hóa, đầu vào neuron có thể quá lớn hoặc quá nhỏ, khiến hàm kích hoạt như sigmoid hay tanh rơi vào vùng bão hòa, nơi đạo hàm gần bằng 0. Điều này gây ra hiện tượng độ dốc biến mất (vanishing gradient), làm mô hình MLP hoặc LSTM không học được, dẫn đến hội tụ chậm hoặc dự báo sai lệch lớn. Vì vậy, chuẩn hóa giúp giữ đầu vào trong phạm vi phù hợp, đảm bảo gradient truyền ngược hiệu quả và mô hình học chính xác. Trong bài nghiên cứu, tác giả chọn phương pháp Min-Max Scaler làm phương pháp chuẩn hóa dữ liệu. Đây là một kỹ thuật phổ biến trong tiền xử lý dữ liệu cho các thuật toán học máy, giúp đưa các giá trị của biến về cùng một khoảng xác định, thường là từ 0 đến 1. Việc chuẩn hóa này đặc biệt hữu ích khi các biến đầu vào có phạm vi giá trị chênh lệch lớn, giúp loại bỏ sự ảnh hưởng quá mức của các biến có giá trị lớn và đảm bảo các biến đều có mức độ đóng góp tương đương vào mô hình. Sau khi các biến được chuẩn hóa bằng

Min-Max Scaler, các giá trị của chúng sẽ được đưa về cùng một thang đo. Điều này giúp mô hình học máy hoạt động hiệu quả hơn và tránh tình trạng một số biến chi phối kết quả dự đoán vì có giá trị lớn vượt trội so với các biến khác..

Cách thực hiện là xác định giá trị nhỏ nhất (min) và giá trị lớn nhất (max) của từng biến trong tập dữ liệu, sau đó áp dụng công thức:

$$X_{scaled} = \frac{X - min}{max - min} ;$$

trong đó:

X_{scaled} là giá trị đã được chuẩn hóa

X là giá trị gốc

Min và Max lần lượt là giá trị nhỏ nhất và giá trị lớn nhất của biến trong dữ liệu.

3.2.1.4 Tính toán các chỉ báo kỹ thuật

Việc chọn các biến đặc trưng phù hợp và yếu tố rất quan trọng trong bất kì mô hình dự đoán nào. Các chỉ báo kỹ thuật được sử dụng có thể phân loại thành 3 loại chính:

- Loại chỉ báo xu hướng (Trend Type) giúp xác định hướng đi chính của giá tăng, giảm hay đi ngang trong một khoảng thời gian nhất định. Bao gồm Moving average (MA), Average Directional Index (ADX)...
- Loại chỉ báo dao động (Oscillator Type), những chỉ báo này chỉ ra khả năng đảo ngược một xu hướng đang diễn ra. Loại này bao gồm các chỉ báo như Moving average convergence/divergence (MACD), Rank Correlation Index (RCI) và Relative strength index (RSI)...
- Loại chỉ báo động lượng (Momentum Type) đưa ra tỷ lệ thay đổi của giá của chứng khoán. Điều này bao gồm các động lượng với các kích thước cửa sổ khác nhau. Bao gồm: Rate of Change (ROC), Commodity Channel Index (CCI)...

Các chỉ số kỹ thuật được sử dụng trong bài nghiên cứu bao gồm:

- “ SMA_{15} ”: Trung bình động giản đơn của thuộc tính Close chu kỳ 15 ngày.
- “ ROC ”: Tốc độ thay đổi giá dưới dạng phần trăm.

- “RSI”: Chỉ số sức mạnh tương đối RSI chu kỳ 14 ngày.
- “OBV”: Khối lượng giao dịch tích lũy.
- “MACD”: Trung bình động hội tụ phân kì.
- “Stochastic”: Chỉ báo dao động ngẫu nhiên chu kỳ 14 ngày.
- “ATR”: Khoảng dao động thực tế trung bình chu kỳ 14 ngày.

1) Trung bình động giản đơn (SMA) – Simple moving average

SMA là trung bình cộng của giá đóng cửa thị trường (hoặc có thể là giá mở cửa, giá cao nhất, giá thấp nhất tùy vào chiến lược) trong một khoảng thời gian xác định. Mục đích của SMA là loại bỏ biến động ngắn hạn và làm rõ xu hướng tổng thể của dữ liệu, giúp nhà đầu tư dễ dàng nhận biết hướng đi của thị trường. Đường trung bình động giản đơn có chu kỳ dài thường cung cấp hình ảnh về xu hướng tổng thể, trong khi đường SMA có chu kỳ ngắn sẽ phản ứng nhanh hơn đối với các biến đổi giá gần.

Công thức tính SMA:

$$SMA = \frac{P_1 + P_2 + P_3 + \dots + P_n}{n};$$

trong đó:

P_n : giá đóng cửa của cổ phiếu từ “n” ngày trước đó.

n: số ngày trong chu kỳ.

2) Khoảng dao động thực tế trung bình (ATR) - (Average True Range)

ATR là chỉ báo đo độ biến động của giá trên thị trường, giúp đánh giá mức độ rủi ro và biến động trong một khoảng thời gian nhất định bằng cách tính trung bình chu kỳ 14 ngày của chỉ số True Range (Vùng biên độ thực). ATR cho biết mức độ biến động giá, giúp nhà đầu tư điều chỉnh chiến lược giao dịch, đặt điểm dừng lỗ phù hợp và đánh giá rủi ro thị trường.

Công thức tính ATR:

$$TR = \text{Max}[(H - L), \text{Abs}(H - Cp), \text{Abs}(L - Cp)];$$

$$ATR = \frac{1}{n} \times \sum_{i=1}^n TR_i;$$

trong đó:

TR_i : Vùng biên độ tại thời điểm i.

n : Số kì thanh toán.

3) Chỉ số sức mạnh tương đối (RSI) – Relative Strength Index

Chỉ số sức mạnh tương đối là chỉ báo động lượng dùng để đo lường cường độ thay đổi giá nhằm đánh giá trạng thái quá mua/ quá bán của cổ phiếu, RSI có giá trị từ 0 đến 100, giúp xác định xem tài sản có bị quá mua hay quá bán. (>70 thể hiện tài sản bị quá mua và có thể thị trường sắp điều chỉnh giảm, <30 cho thấy tài sản bị quá bán và thị trường sắp hồi phục tăng giá). Công thức RSI:

$$RSI = 100 - \left[\frac{100}{1 + \frac{\text{trung bình giá tăng}}{\text{trung bình giá giảm}}} \right]$$

4) Trung bình hội tụ phân kỳ (MACD)- Moving Average Convergence Divergence

MACD là chỉ báo động lượng theo xu hướng, dựa trên mối quan hệ giữa hai đường trung bình động của giá cổ phiếu, phổ biến nhất là giá trị trung bình động 12 ngày (EMA12) và 26 ngày (EMA26). Công thức MACD:

MACD = EMA chu kì ngắn hạn – EMA chu kì dài hạn;

trong đó:

EMA chu kì ngắn hạn: trung bình trượt số mũ của giá đóng cửa chu kỳ ngắn.

EMA chu kì dài hạn: trung bình trượt số mũ của giá đóng cửa chu kỳ dài.

5) (OBV) - On-Balance Volume

OBV là chỉ báo tích lũy khối lượng, đo dòng tiền vào và ra khỏi cổ phiếu dựa trên biến động giá và khối lượng giao dịch. giúp nhà đầu tư đánh giá lực mua và bán của cổ phiếu trong giai đoạn nhất định, sử dụng sự tăng giảm của khối lượng để dự đoán những thay đổi trong giá cổ phiếu. Khi giá tăng, OBV tăng ngược lại khi giá giảm, OBV giảm điều này thể hiện xu hướng của giá, nếu giá cả thay đổi mà OBV không thay đổi nhiều thể hiện xu hướng đang yếu dần. Công thức tính của OBV được chia thành 3 trường hợp:

<i>Trường hợp 1: $Close(t) > Close(t-1)$</i>	$OBV(t) = OBV(t-1) + Volume(t)$
<i>Trường hợp 2: $Close(t) < Close(t-1)$</i>	$OBV(t) = OBV(t-1) - Volume(t)$
<i>Trường hợp 3: $Close(t) = Close(t-1)$</i>	$OBV(t) = OBV(t-1) = Volume(t)$

Trong đó:

$Close(t)$: giá đóng cửa tại thời điểm t.

$Close(t-1)$: giá đóng cửa tại thời điểm trước t, thời điểm t-1.

$Volume(t)$: khối lượng giao dịch tại thời điểm t.

$OBV(t)$: khối lượng cân bằng tại thời điểm t.

$OBV(t-1)$: khối lượng cân bằng tại thời điểm trước t, thời điểm t-1.

6) *ROC - Rate of Change*

ROC đo tốc độ thay đổi giá dưới dạng phần trăm so với giá n phiên trước và phản ánh sức mạnh xu hướng. Nó cho biết giá đang tăng nhanh, giảm nhanh hay chậm lại. $ROC > 0$: giá tăng so với quá khứ và ngược lại $ROC < 0$: giá giảm.

$$ROC_{(t)} = \frac{Close_{(t)} - Close_{(t-n)}}{Close_{(t-n)}} \times 100 ;$$

trong đó:

$Close_{(t)}$: giá hiện tại.

$Close_{(t-n)}$: giá đóng cửa cách n phiên trước.

7) *Stochastic Oscillator*

Stochastic Oscillator (chỉ báo dao động ngẫu nhiên) được phát triển bởi George C. Lane vào cuối thập niên 1950. Nó đo lường vị trí giá đóng cửa hiện tại so với biên độ dao động giá (cao nhất – thấp nhất) trong một khoảng thời gian nhất định. Ý tưởng chính: khi giá tăng, giá đóng cửa có xu hướng nằm gần đỉnh của vùng giá; khi giá giảm, giá đóng cửa gần đáy. Stochastic gồm 2 thành phần chính:

$$\%K (\text{dòng chính}) = 100 \times \frac{Close - Lowest Low}{Highest High - Lowest Low} ;$$

$$\%D (\text{dòng tín hiệu}) = SMA \text{ của } \%K \text{ trong 3 phiên gần nhất} ;$$

trong đó:

Lowest Low: giá thấp nhất trong n phiên gần nhất.

Highest High: giá cao nhất trong n phiên gần nhất.

3.2.2 Phân tích khai phá dữ liệu

Phân tích khai phá dữ liệu là bước quan trọng nhằm hiểu rõ đặc điểm của dữ liệu trước khi tiến hành xây dựng mô hình dự báo. Trong bước này, dữ liệu sẽ được tổng hợp bằng các thống kê mô tả như giá trị trung bình, độ lệch chuẩn, giá trị lớn nhất, nhỏ nhất và phân vị, đồng thời trực quan hóa qua các biểu đồ như đường giá, histogram, boxplot, heatmap để nhận diện biến động bất thường và mối tương quan giữa các biến. Quá trình khai phá dữ liệu cũng giúp phát hiện dữ liệu thiếu, giá trị ngoại lai (outlier) hoặc những vấn đề bất thường cần xử lý trước khi modeling. Kết quả từ việc khai phá cung cấp cái nhìn tổng quan, hỗ trợ chọn lọc các biến phù hợp, loại bỏ biến dư thừa và thiết kế chiến lược xử lý dữ liệu, từ đó nâng cao hiệu quả và độ chính xác của mô hình dự báo.

3.2.3 Lựa chọn mô hình và huấn luyện mô hình

Trong bài nghiên cứu, tác giả lựa chọn 2 mô hình để xây dựng mô hình dự báo giá cổ phiếu là MLP và LSTM. Thứ nhất, Mô hình MLP là lựa chọn phù hợp khi làm việc với dữ liệu bảng tĩnh như các chỉ báo kỹ thuật, thông tin cơ bản, tỷ suất sinh lời. Với khả năng học được các mối quan hệ phi tuyến giữa đầu vào và đầu ra, MLP giúp phát hiện các mẫu ẩn trong dữ liệu mà các mô hình tuyến tính không thể nắm bắt. MLP cũng có cấu trúc đơn giản, dễ triển khai, huấn luyện nhanh và thường mang lại hiệu quả tốt trong các bài toán dự báo ngắn hạn, đặc biệt khi không cần ghi nhớ chuỗi thời gian dài. Thứ hai, LSTM nổi bật với khả năng xử lý dữ liệu chuỗi thời gian, phù hợp với những đặc tính lịch sử và tuần hoàn của giá cổ phiếu. Với cơ chế ghi nhớ thông tin trong quá khứ xa, LSTM có thể học được các xu hướng dài hạn, chu kỳ thị trường, hay các mối quan hệ phức tạp giữa các phiên giao dịch. Điều này giúp LSTM vượt trội hơn trong việc nắm bắt động lực thị trường, đặc biệt là khi biến động giá không chỉ phụ thuộc vào phiên gần nhất mà còn do các tín hiệu tiềm ẩn trong chuỗi thời gian dài.

3.2.3.1 Phân chia tập huấn luyện và tập kiểm tra

Việc chia dữ liệu thành các tập huấn luyện và kiểm tra là bước quan trọng trong việc xây dựng mô hình học máy, giúp đảm bảo mô hình không bị khớp quá mức (overfitting) và có thể đánh giá một cách khách quan. Trong bài nghiên cứu này tác giả sẽ sử dụng phương pháp Walk-Forward Optimization kết hợp với kỹ thuật Expanding Window.

Walk-Forward Optimization kết hợp với kỹ thuật Expanding Window là một phương pháp phổ biến trong việc đánh giá và kiểm tra mô hình học máy, đặc biệt hữu ích trong các bài toán dự báo chuỗi thời gian. Phương pháp này mô phỏng quá trình triển khai mô hình trong thực tế, khi mô hình được huấn luyện trên một tập dữ liệu ban đầu và sau đó kiểm tra trên một tập dữ liệu chưa từng thấy. Sau mỗi lần kiểm tra, tập huấn luyện sẽ được mở rộng thêm dữ liệu mới, và được kiểm tra trên một tập dữ liệu hoàn toàn mới, tạo nên đặc trưng của kỹ thuật Expanding Window.

Cơ chế hoạt động của Expanding Window là ở mỗi bước, tập huấn luyện được cập nhật bằng cách thêm vào các quan sát mới nhất từ dữ liệu gốc. Điều này phản ánh thực tế khi dữ liệu liên tục được bổ sung và mô hình cần học từ cả dữ liệu cũ lẫn dữ liệu mới. Quá trình này tiếp tục cho đến khi mô hình được kiểm tra trên toàn bộ tập dữ liệu, giúp mô hình thích ứng và cải thiện khả năng dự báo theo thời gian. Tuy nhiên, phương pháp này cũng đặt ra thách thức về mặt tính toán, khi số lượng bước và kích thước tập huấn luyện ngày càng tăng, dẫn đến chi phí huấn luyện mô hình cao hơn.

Nhờ khả năng đánh giá hiệu suất mô hình theo thời gian một cách chính xác, WFO với Expanding Window giúp nâng cao độ tin cậy của mô hình khi áp dụng vào thực tế, đặc biệt trong các lĩnh vực như dự báo tài chính, nơi dữ liệu mới luôn được cập nhật liên tục và mô hình cần duy trì hiệu quả dự báo trong điều kiện biến động.

3.2.3.2 Xây dựng mô hình MLP

Trong nghiên cứu này, mô MLP được xây dựng để dự báo giá đóng cửa 1 ngày sau của giá cổ phiếu. Dữ liệu đầu vào bao gồm khối lượng giao dịch và các đặc trưng

kỹ thuật SMA, RSI, ATR, MACD, v.v., được xử lý dưới dạng chuỗi thời gian và chuẩn hóa trước khi đưa vào mô hình.

Quy trình huấn luyện sử dụng phương pháp Walk-Forward Optimization với Expanding window trong đó các bước được lặp qua theo thời gian. Ở giai đoạn đầu, mô hình sẽ tự động tối ưu tham số cho từng bước dự báo bằng Bayesian Optimization. Sau khi hoàn thành, hiệu suất dự báo trên tập kiểm tra của mỗi mẫu dữ liệu sẽ được đánh giá bằng các chỉ số như MSE, MAE, R^2 , và RMSE.

Quy trình tối ưu và đánh giá mô hình được thực hiện bằng phương pháp Walk-Forward Optimization với Expanding window, bắt đầu huấn luyện trên 50% tập dữ liệu, sau đó chia thành nhiều mẫu dữ liệu với tập train mở rộng dần; ở mỗi sample, dữ liệu được chia thành tập train, validation, và test. Ở các bước nhất định mô hình tiến hành tối ưu hóa siêu tham số tự động bằng thuật toán Bayesian Optimization thông qua thư viện Keras Tuner.

Mô hình MLP được xây dựng linh hoạt với số tầng ẩn (1–3 tầng) và số lượng nơ-ron thay đổi từ 32 đến 256, sử dụng các hàm kích hoạt (ReLU, tanh, ELU) và regularization L1/L2 để tránh overfitting. Mô hình được huấn luyện bằng hàm mất mát MSE với tối ưu Adam, có áp dụng kỹ thuật sớm dừng (EarlyStopping) và giảm tốc độ học (ReduceLROnPlateau) để cải thiện quá trình hội tụ. Sau mỗi bước, dự báo trên tập test được lưu lại và tính toán các chỉ số đánh giá như MSE, MAE, R^2 , và RMSE. Kết quả của từng bước được tổng hợp lại, cho phép đánh giá hiệu suất dự báo trong toàn bộ quá trình.

Tại các bước cho kết quả dự báo tốt, các siêu tham số tối ưu tìm được sẽ được lưu lại và sử dụng làm tham số cố định cho chính bước đó. Ở các sample còn lại có hiệu suất chưa tốt, mô hình tiếp tục được tự động tối ưu tham số để cải thiện chất lượng dự báo. Quy trình này được lặp lại cho đến khi tất cả các sample đều đạt hiệu suất cao, đảm bảo mỗi bước có một bộ tham số tối ưu riêng, phù hợp với đặc điểm dữ liệu tại thời điểm đó. Nhờ vậy, mô hình vừa duy trì được khả năng thích ứng trước sự biến động của dữ liệu theo thời gian, vừa tối đa hóa độ chính xác dự báo cho từng giai đoạn.

3.2.3.3 Xây dựng mô hình LSTM

Tác giả đã xây dựng mô hình LSTM trong bài nghiên cứu bằng cách sử dụng các lớp chính để xử lý chuỗi thời gian và học được các mối quan hệ phức tạp giữa các đặc trưng. Mô hình LSTM được xây dựng và tối ưu thông qua các bước sau:

Mô hình LSTM gồm các tham số quan trọng, bao gồm số lượng neuron trong lớp LSTM và các lớp Dense, tỷ lệ dropout để giảm thiểu overfitting, và một số tham số khác như learning rate của bộ tối ưu Adam. Quy trình tìm kiếm tham số trong mô hình này được thực hiện thông qua Keras Tuner, một thư viện mạnh mẽ giúp tối ưu hóa các siêu tham số của mô hình. Các tham số quan trọng như sequence_length, lstm_units, dropout_rate, và learning_rate được tối ưu hóa để tìm ra sự kết hợp tốt nhất. Việc tìm kiếm này giúp cải thiện khả năng học của mô hình, đảm bảo rằng mô hình sẽ có cấu hình tối ưu để xử lý dữ liệu chuỗi thời gian phức tạp. Keras Tuner sẽ thử nghiệm với các giá trị khác nhau của các tham số và đánh giá hiệu suất của mô hình qua các bước huấn luyện và kiểm tra, giúp chọn ra tham số tốt nhất để tăng cường độ chính xác dự đoán.

Một phần quan trọng trong quá trình huấn luyện mô hình LSTM là WFO. Đây là một kỹ thuật quan trọng để huấn luyện mô hình dự báo trong bối cảnh dữ liệu chuỗi thời gian. Được áp dụng cách chia dữ liệu giống với mô hình MLP.

3.2.4 Kiểm tra và đánh giá

Để đánh giá được mức độ phù hợp của các mô hình dự báo giá cổ phiếu, một vài thước đo được sử dụng như R-Squared (R^2), Median Absolute Error (MAE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE)

a) Mean square error

Mean Squared Error (MSE) là một phép đo đánh giá độ chính xác của mô hình dự báo bằng cách tính trung bình bình phương sai số giữa giá trị thực tế và giá trị dự báo. MSE càng nhỏ thì mô hình có độ chính xác càng cao.

$$\text{Cơ sở toán học: } MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_i)^2;$$

trong đó:

n: số lượng mẫu

y_i : giá trị thực tế

$\bar{y}_i$: giá trị dự đoán

b) Coefficient of determination

Coefficient of determination (hệ số xác định), hay R^2 , là hệ số giúp đo lường khả năng giải thích biến động của mô hình đối với bộ dữ liệu. R^2 có giá trị từ 0 đến 1, trong đó 0 có nghĩa là mô hình không giải thích được biến động của dữ liệu và 1 cho thấy mô hình hoàn toàn giải thích được các biến động này.

Cơ sở toán học: $R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2}$;

trong đó:

R^2 : hệ số xác định.

$\sum_i e_i^2$: tổng bình phương sai số của dự án.

$\sum_i (y_i - \bar{y})^2$: tổng bình phương của hiệu giữa giá trị thực tế và giá trị trung bình của biến phụ thuộc.

c) Root mean square error

Root Mean Squared Error (RMSE) là căn bậc hai của Mean Squared Error (MSE), được sử dụng để đánh giá độ chính xác của mô hình dự báo RMSE giúp đo lường mức độ sai số trung bình giữa giá trị thực tế và giá trị dự báo, giữ nguyên đơn vị đo lường của biến gốc, do đó dễ diễn giải hơn so với MSE.

Cơ sở toán học: $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_i)^2}$.

d) Mean absolute error

Mean Absolute Error (MAE) là một phép đo sai số trung bình giữa giá trị thực tế và giá trị dự báo của một mô hình. Không giống như MSE hay RMSE, MAE không bình phương sai số mà chỉ lấy giá trị tuyệt đối, giúp đánh giá sai số trung bình theo đơn vị gốc của dữ liệu. MAE không quan tâm tới hướng của sai số, chỉ số này nhạy cảm với các sai số, không như MSE thường tập trung vào các sai số lớn.

Cơ sở toán học: $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}_i|$.

KẾT LUẬN CHƯƠNG 3

Dựa trên nền tảng lý thuyết được trình bày trong chương 2, trong chương 3 tác giả đã mô tả chi tiết quy trình nghiên cứu, các bước để tiến hành, mô tả đầy đủ dữ liệu thu thập được, cùng với việc đưa các biến vào sử dụng trong mô hình, và lựa chọn các mô hình phù hợp để xây dựng. Ngoài ra, chương này cũng giới thiệu các thước đo dùng để đánh giá hiệu suất mô hình, hỗ trợ việc so sánh và phân tích kết quả dự báo giá chứng khoán. Trong chương tiếp theo, tác giả sẽ tập trung đánh giá độ tin cậy của mô hình, với các mô hình được áp dụng bao gồm LSTM và MLP.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

4.1 Đánh giá tác động của COVID-19

Bộ dữ liệu trong bài nghiên cứu tác giả đã sử dụng từ ngày 4 tháng 6 năm 2018 đến ngày 31 tháng 3 năm 2025. Trong khoảng thời gian này có sự kiện dịch COVID-19 gây ảnh hưởng lớn tới thị trường chứng khoán nói chung và mã cổ phiếu TCB nói riêng, từ đó tác giả sẽ đánh giá tác động của đại dịch bắt đầu trong năm 2020 tới giá cổ phiếu TCB.




(Nguồn: Kết quả từ Google Colab)

Hình 4.1 Giá đóng cửa trong thời kì COVID-19

Trong hình 4.1 thể hiện giá đóng cửa của TCB trong năm 2020 nơi đỉnh của đại dịch, ta thấy rằng giá cổ phiếu ghi nhận mức giảm mạnh trong quý I/2020, với mức đáy rơi vào khoảng cuối tháng 3, cho thấy ảnh hưởng tiêu cực ngay lập tức khi đại dịch bùng phát. Bên cạnh đó có một số giai đoạn ghi nhận chuỗi ngày giảm giá liên tiếp như tháng 8/2020, cuối tháng 10/2022...

Tiếp theo tác giả kiểm tra phân phối của lợi suất hằng ngày bằng công thức `pct_change()` thể hiện trong hình 4.2



(Nguồn: Kết quả từ Google Colab)

Hình 4.2: Phân phối lợi nhuận trong thời kì COVID-19

Biểu đồ phân phối lợi suất hàng ngày năm 2020 cho thấy lợi nhuận có xu hướng phân bố bất đối xứng, nghiêng về phía âm, với phần đuôi trái kéo dài hơn. Phân phối lợi suất cũng thể hiện rõ tính không chuẩn (non-normal), với sự xuất hiện của nhiều giá trị ngoại lai ở cả hai phía. Phần lớn lợi suất hàng ngày tập trung quanh giá trị xấp xỉ 0, điều này cho thấy phần lớn các phiên giao dịch trong năm chỉ biến động nhẹ. Tuy nhiên, với biến động hàng ngày (độ lệch chuẩn lợi suất hàng ngày) năm 2020 là 0.0236 ở mức cao so với bình thường điều này phản ánh rằng giá cổ phiếu dao động mạnh, không ổn định là một đặc trưng tiêu biểu trong giai đoạn khủng hoảng thể trong dịch COVID-19.

Qua phân tích và đánh giá tác động của COVID-19 cho thấy rằng đặc điểm này có ý nghĩa quan trọng khi áp dụng hai mô hình học máy được sử dụng trong bài nghiên cứu là MLP và LSTM, bởi dữ liệu có tính biến động cao và chứa nhiều nhiễu dễ gây quá khớp (overfitting). Do đó, tác giả đã xử lý các giá trị ngoại lai trước khi đưa vào mô hình để cải thiện độ ổn định và khả năng dự báo.

4.2 Thông tin bộ dữ liệu

Tổng quan về bộ dữ liệu giá lịch sử của mã cổ phiếu TCB được tác giả thu thập từ thư viện Vnstock từ ngày 4 tháng 6 năm 2018 tới ngày 31 tháng 3 năm 2025. Bao gồm các cột: Time, Open, High, Low, Close, Volume được thể hiện trong bảng 4.1.

Bảng 4.1: Dữ liệu lịch sử giá

	Date	Open	High	Low	Close	Volume
0	2018-06-04	16550	16970	16550	16550	2811840
1	2018-06-05	16020	17130	15520	15520	1357500
2	2018-06-06	15350	15520	14710	14870	1605480
3	2018-06-07	15270	15900	15050	15900	1376540
...	...	...	...	...	...	...
1703	2025-03-26	27900	28500	27800	28000	24089300
1704	2025-03-27	28000	28150	27750	27750	7518900
1705	2025-03-28	27750	27800	27450	27550	12353600
1706	2025-03-31	27400	27500	27200	27500	12983300

(Nguồn: Kết quả từ Google Colab)

4.2.1 Thống kê dữ liệu đầu vào

Bảng 4.2: Dữ liệu thống kê

Biến	Count	Mean	Std	Min	Max
Close	1683	16732.9055	5565.9693	7230	28120
Volume	1683	7152648	6050758	920491	21519610
Return	1683	0.0791	1.5852	-3.2383	3.2611
SMA_15	1683	16677.1884	5495.7485	7877.3333	27636.6667
RSI	1683	51.8009	12.4471	28.0535	73.1832
Stochastic	1683	52.6774	30.7715	0.0000	100.0000
ATR	1683	420.2090	163.5808	190.2799	753.6895
OBV	1683	720693476	550015593	-6037533	1901201120
ROC	1683	51.5838	348.6046	-672.4145	729.4445

MACD	1683	46.608416	422.553356	-1574.0440	1303.346025
------	------	-----------	------------	------------	-------------

(Nguồn: Kết quả từ Google Colab)


Bảng 4.2 trình bày các giá trị của 10 biến về số lượng quan sát (Count), giá trị trung bình (Mean), độ lệch chuẩn (Std), giá trị nhỏ nhất (Min), giá trị lớn nhất (Max) để giúp chúng ta hiểu tập dữ liệu được sử dụng để phát triển các mô hình dự báo giá chứng khoán.

Trong đó, số lượng giá trị không bị thiếu (non-null) của các biến là 1683 quan sát. Biến có giá trị trung bình (Mean) lớn nhất là OBV, với giá trị trung bình lên tới 720693476, phản ánh tổng khối lượng giao dịch cộng dồn rất cao. Trong khi đó, biến có giá trị trung bình nhỏ nhất là Return, chỉ ở mức 0.0791, cho thấy mức sinh lời trung bình hằng ngày tương đối thấp. Đối với độ lệch chuẩn (Std), biến OBV cũng có độ lệch chuẩn lớn nhất, đạt 550015593, thể hiện mức biến động rất mạnh của chỉ báo này theo thời gian. Ngược lại, biến Return có độ lệch chuẩn nhỏ nhất, chỉ ở mức 1.5852, phản ánh mức dao động tương đối ổn định hơn so với các biến còn lại. Về giá trị tối thiểu (Min), biến có giá trị nhỏ nhất là Return, ở mức -3.2383, cho thấy mức sụt giảm sâu nhất trong chuỗi dữ liệu. Trong khi đó, biến có giá trị tối thiểu lớn nhất là Stochastic với mức 0.00, phù hợp với đặc tính của chỉ báo dao động ngẫu nhiên vốn bị giới hạn trong khoảng từ 0 đến 100. Xét về giá trị tối đa (Max), biến OBV tiếp tục là biến có giá trị lớn nhất, đạt tới 1901021120, phản ánh quy mô khối lượng giao dịch cộng dồn rất lớn trong dữ liệu. Trái lại, biến có giá trị tối đa nhỏ nhất là Return, chỉ ở mức 3.2611, cho thấy mức tăng lớn nhất của lợi suất trong chuỗi dữ liệu vẫn còn tương đối khiêm tốn.

4.2.2 Ma trận tương quan

Ma trận tương quan là một công cụ thống kê dùng để đánh giá mức độ và hướng của mối quan hệ giữa các biến trong tập dữ liệu. Giá trị của ma trận dao động từ -1 đến 1, trong đó: 1 biểu thị mối quan hệ thuận tuyệt đối (một biến tăng thì biến kia cũng tăng theo tỷ lệ cố định), -1 biểu thị mối quan hệ nghịch tuyệt đối (một biến tăng thì biến kia giảm theo tỷ lệ cố định), và 0 cho thấy không có mối liên hệ tuyến tính giữa hai biến. Ma trận này giúp nhận diện các biến có mối quan hệ mạnh hoặc yếu,

hỗ trợ hiệu quả cho việc phân tích dữ liệu, đặc biệt trong dự báo, lựa chọn đặc trưng và đánh giá tác động giữa các yếu tố.



Hình 4.3: Ma trận tương quan

(Nguồn: Kết quả từ Google Colab)

Trong ma trận tương quan của Ngân hàng TMCP Kỹ Thương Việt Nam – TCB hình 4.3, khi quan sát mối quan hệ giữa các chỉ báo kỹ thuật như Volume, SMA_15, RSI, Stochastic, ATR, OBV, ROC và MACD, có thể nhận thấy nhiều mối quan hệ đồng biến đáng chú ý.

Cụ thể, RSI cho thấy tương quan cao với Stochastic (0.82), ROC (0.82) và MACD (0.80). Điều này phản ánh mối liên hệ chặt chẽ giữa các chỉ báo động lượng, vốn thường di chuyển cùng chiều khi thị trường hình thành xu hướng rõ rệt. Những


mối tương quan cao này gợi ý rằng các chỉ báo này có thể cung cấp thông tin bổ sung lẫn nhau hoặc cùng phản ánh một đặc điểm chung của thị trường.

Bên cạnh đó, SMA_15 (trung bình động 15 phiên) có mức tương quan khá mạnh với OBV (0.77) và ATR (0.61). Điều này cho thấy xu hướng giá trung bình có mối liên hệ với khối lượng giao dịch tích lũy (OBV) cũng như mức độ biến động giá (ATR). Những mối quan hệ này gợi ý rằng khi giá duy trì xu hướng ổn định, khối lượng giao dịch cũng tăng dần và biến động giá có xu hướng cao hơn.

Ngoài ra, Volume có tương quan trung bình với SMA_15 (0.53) và ATR (0.51), cho thấy khối lượng giao dịch phản ánh phần nào xu hướng giá và mức độ biến động của thị trường, dù mức độ không quá mạnh. Ngược lại, Return – đại diện cho lợi suất ngắn hạn – có tương quan rất thấp với hầu hết các biến còn lại (dao động từ -0.02 đến 0.44), cho thấy biến động lợi suất hằng ngày gần như độc lập và ít liên hệ với các chỉ báo kỹ thuật truyền thống.

Mặc dù có sự xuất hiện của một số cặp biến có hệ số tương quan cao (trên 0.8), điều này không nhất thiết dẫn đến ảnh hưởng nghiêm trọng do đa cộng tuyến, đặc biệt khi sử dụng các mô hình phi tuyến hoặc có khả năng học tự động các quan hệ phức tạp như LSTM hay MLP. Hơn nữa, sự trùng lặp thông tin giữa các chỉ báo động lượng cũng có thể giúp tăng độ tin cậy khi những tín hiệu kỹ thuật độc lập đưa ra cùng một xu hướng. Dù vậy, việc theo dõi và kiểm soát mối quan hệ giữa các biến vẫn cần được xem xét trong bước lựa chọn đặc trưng, nhằm nâng cao tính khái quát hóa của mô hình dự báo.

4.2.3 Chia dữ liệu thành tập huấn luyện và kiểm tra



Hình 4.4: Chia dữ liệu WFO

(Nguồn: Kết quả từ Google Colab)

Trong hình 4.4, tác giả trình bày khách quan mô phỏng quá trình chia dữ liệu theo Walk-Forward Optimization với Expanding Window cho hai mô hình MLP và LSTM trong bài toán dự báo giá cổ phiếu. Dữ liệu được chia thành ba phần: train, validation, và test. Qua các bước huấn luyện, tập huấn luyện mở rộng và tập kiểm tra di chuyển qua các phần khác nhau. Mô hình được huấn luyện và kiểm tra trong từng mẫu dữ liệu, và sau mỗi bước, dữ liệu huấn luyện lại được mở rộng ra để huấn luyện tiếp với các dữ liệu mới nhất.

4.3 Kết quả huấn luyện và hiệu suất của các mô hình

Hình 4.5 thể hiện biểu đồ sự biến động giá đóng cửa của TCB trong khoảng thời gian từ 4 tháng 6 năm 2018 tới 31 tháng 3 năm 2025 bao gồm 1707 ngày giao dịch, trong đó có giá đóng cửa thấp nhất là 7230 (VND) và giá đóng cửa cao nhất là 28120 (VND).



Hình 4.5: Giá đóng cửa TCB

(Nguồn: Kết quả từ Google Colab)


4.3.1 Kết quả xây dựng mô hình Multilayer Perceptron

Bảng 4.3: Kết quả so sánh giá thực tế và giá dự báo của mô hình MLP

Ngày	Giá thực tế	Giá dự báo
2022-07-20	17870.0	17862.580078
2022-07-21	17990.0	17998.234375
2022-07-22	17840.0	18064.824219
...	...	...
2025-03-26	27750.0	27172.035156
2025-03-27	27550.0	26844.167969
2025-03-28	27500.0	27011.656250

(Nguồn: Kết quả từ Google Colab)

Bảng 4.3 thể hiện sự so sánh giữa giá đóng cửa thực tế và giá đóng cửa dự báo của mô hình MLP trong phạm vi tập kiểm tra của TCB. Từ những điểm giá trị này nối lại với nhau tác giả đã vẽ được biểu đồ so sánh giá thực tế và giá dự báo của mô hình MLP.



Hình 4.6: Trực quan hóa kết quả so sánh giá thực tế và giá dự báo của MLP

(Nguồn: Kết quả từ Google Colab)

Hình 4.6 trực quan hóa dữ liệu giá đóng cửa thực tế trong phạm vi tập dữ liệu kiểm tra của TCB và giá đóng cửa mà mô hình MLP đã dự báo thành biểu đồ đường. Đường minh họa màu xanh đại diện cho giá đóng cửa thực tế và đường minh họa màu đỏ đại diện cho giá đóng cửa mà mô hình MLP dự báo được.

Bảng 4.4: Các siêu tham số MLP

Hyperparameter	Sample 1	Sample 2	Sample 3	Sample 4
Activation	Tanh	Tanh + Relu	Relu + Relu	Tanh+ Tanh
Hidden_layer_sizes	128	160, 32	224, 96	160, 128
Alpha	0.0020677866	0.003034058	0.001932	0.000688
Dropout	0.2	0.2 (Lớp 0), 0.1 (Lớp 1)	0.3 (Lớp 0), 0.3 (Lớp 1)	0.2 (Lớp 0), 0.1 (Lớp 1)
Learning rate	0.001991	0.003034058	0.001932	0.000612
Batch_size	64	64	64	64
Max_iter	150	150	150	150

(Nguồn: Kết quả từ Google Colab)

Trong bảng 4.4, tác giả liệt kê các siêu tham số tối ưu được của mô hình MLP, ứng với từng sample sẽ có một bộ siêu tham số phù hợp với từng giai đoạn, giúp mô hình thích nghi với các đặc điểm riêng biệt của từng kịch bản thị trường.

Bảng 4.5: Kết quả đánh giá từng sample - MLP

	<i>MSE</i>	<i>MAE</i>	<i>R²</i>	<i>RMSE</i>
Sample 1	757961.698	630.94	0.891	870.61
Sample 2	326792.321	458.79	0.650	571.66
Sample 3	437095.89	489.08	0.964	661.13
Sample 4	723708.06	733.30	0.745	850.71

(Nguồn: Kết quả từ Google Colab)

Bảng 4.5 cung cấp các chỉ số đánh giá hiệu suất mô hình dự báo trên bốn mẫu dữ liệu (Sample 1 đến Sample 4), bao gồm MSE, MAE, R^2 , và RMSE, ta có thể rút ra một số nhận xét quan trọng.

Sample 1,2 : Mô hình cho thấy khả năng dự báo tương đối ổn định trong các giai đoạn thị trường biến động vừa phải. Với MSE lần lượt là 757961.70 và 326792.32, MAE giảm từ 630.94 xuống 458.79, và RMSE giảm tương ứng từ 870.61 xuống 571.66. Tuy nhiên, hệ số R^2 lại giảm từ 0.891 xuống 0.650, cho thấy mặc dù sai số tuyệt đối cải thiện, khả năng giải thích biến động dữ liệu của mô hình lại giảm. Điều

này phản ánh có thể thị trường trong Sample 2 xuất hiện những yếu tố phi tuyến hoặc bất định mà mô hình chưa nắm bắt được hoàn toàn.

Sample 3: Với R^2 đạt 0.964, MSE là 437095.89, mô hình cho thấy hiệu quả dự báo rất cao trong giai đoạn có xu hướng rõ rệt. R^2 gần 1 cho thấy mô hình có thể giải thích gần như toàn bộ biến thiên giá trong giai đoạn này, phản ánh khả năng mạnh trong việc xử lý dữ liệu có cấu trúc tốt hoặc xu hướng ổn định.


Sample 4: Mô hình giữ được R^2 :0.745, cùng MSE là 723,708.06, MAE :733.30, và RMSE 850.71. Dù hiệu quả giảm nhẹ so với Sample 3, mô hình vẫn duy trì mức giải thích khá, nhưng độ chính xác bị ảnh hưởng bởi các yếu tố có thể nằm ngoài phạm vi dữ liệu huấn luyện như sự kiện đột biến, tin tức bất ngờ hoặc thay đổi cấu trúc thị trường.

Bảng 4.6: Kết quả đánh giá trung bình của mô hình MLP

Mean Squared Error (MSE)	561389.4940
Mean Absolute Error (MAE)	578.0262
R-Squared (R^2)	0.9737
Root Mean Squared Error (RMSE)	749.2593

(Nguồn: Kết quả từ Google Colab)

Bảng 4.6 thể hiện kết quả dự báo của mô hình MLP trên tập kiểm tra gồm 672 mẫu quan sát. MSE của mô hình là 561389.4940 cho thấy dự đoán của mô hình lệch so với giá trị thực tế khoảng 561389.4940 đơn vị bình phương. MAE của mô hình là 578.0262 cho thấy độ lệch trung bình giữa giá trị thực tế và giá trị dự báo là khoảng 578.0262 đơn vị. R^2 của mô hình là 0.9737 cho thấy mô hình giải thích được 97,37% phương sai của dữ liệu. RMSE của mô hình là 749.2593 cho thấy dự đoán của mô hình lệch so với giá trị thực tế khoảng 749.2593 đơn vị.



(Nguồn: Kết quả từ Google Colab)

Hình 4.7 Phân phối lợi nhuận thực tế và dự báo (MLP)

Biểu đồ hình 4.7 minh họa phân phối của return thực tế (màu xanh) và return dự báo bằng mô hình MLP (màu đỏ) cho thấy cả hai phân phối có hình dạng khá tương đồng, đều tập trung mạnh quanh vùng trung tâm (gần 0%). Phân phối dự báo MLP mô phỏng khá sát phần đỉnh và phần hai bên sườn của phân phối thực tế, đồng thời vẫn duy trì được phần đuôi phân phối một cách tương đối. Không có sự lệch lớn về vị trí trung tâm hay hình dạng tổng thể giữa hai phân phối như ở các mô hình dự báo kém hơn.

Ưu điểm nổi bật của mô hình MLP là khả năng dự báo chính xác hơn so với mô hình LSTM ở cả trung tâm và đuôi phân phối. Điều này được xác nhận qua các chỉ số: Kullback-Leibler Divergence có giá trị thấp ở cả hai chiều ($\text{Actual} \parallel \text{Predicted} = 0.2706$ và $\text{Predicted} \parallel \text{Actual} = 0.2662$), cho thấy thông tin mất mát là nhỏ và mô hình có khả năng tái tạo đặc trưng của phân phối thực tế tương đối tốt. Wasserstein Distance cũng khá thấp với giá trị 0.3044, phản ánh sự tương đồng hình dạng giữa hai phân phối. Đây là dấu hiệu cho thấy mô hình MLP đã học được cấu trúc thị trường một cách hiệu quả hơn.

Tuy nhiên, mô hình vẫn còn một số nhược điểm. Mặc dù phân phối dự báo đã bao phủ được phần lớn đặc điểm của dữ liệu thực tế, nhưng ở những phần đuôi xa hơn (trên $\pm 6\%$), return thực tế vẫn có một số điểm vượt ngoài phạm vi dự báo. Điều này cho thấy MLP vẫn có xu hướng “làm mượt” và giảm nhẹ độ nhạy với các sự kiện cực đoan, mặc dù đã cải thiện rõ rệt so với mô hình ban đầu. Ngoài ra, sự tập trung hơi quá mức quanh trung tâm làm cho mô hình bỏ qua những tín hiệu mạnh của thị trường.


4.3.2 Kết quả xây dựng mô hình Long Short - Term Memory

Bảng 4.7: Kết quả so sánh giá thực tế và giá dự báo của mô hình LSTM

Ngày	Giá thực tế	Giá dự báo
2022-07-26	17750.0	18833.552734
2022-07-27	18090.0	18818.199219
2022-07-28	18380.0	18737.695312
...	...	...
2025-03-26	27750.0	27308.341797
2025-03-27	27550.0	27356.125000
2025-03-28	27500.0	27462.933594

(Nguồn: Kết quả từ Google Colab)

Bảng 4.7 thể hiện sự so sánh giữa giá thực tế và giá dự báo của mô hình LSTM trong phạm vi tập kiểm tra của TCB. Từ những điểm giá trị này nối lại với nhau tác giả đã vẽ được biểu đồ so sánh giá thực tế và giá dự báo của mô hình LSTM.



Hình 4.8: Trực quan hóa kết quả so sánh giữa giá thực tế và giá dự báo của LSTM

(Nguồn: Kết quả từ Google Colab)

Trong hình 4.8 tác giả đã trực quan hóa dữ liệu giá đóng cửa thực tế trong phạm vi tập dữ liệu kiểm tra của TCB và giá đóng cửa mà mô hình LSTM đã dự báo thành biểu đồ đường. Đường minh họa màu xanh đại diện cho giá đóng cửa thực tế và đường minh họa màu đỏ đại diện cho giá đóng cửa mà mô hình LSTM dự báo được. Các đường này càng trùng nhau biểu thị mô hình dự báo càng chính xác, ở mô hình LSTM có thể nhận thấy được ở khoảng thời gian tháng 9 năm 2022 cho tới tháng 4 năm 2023 mô hình dường như chỉ dự báo đúng xu hướng của giá và cái sai số trong khoảng này có thể lớn. Đường dự báo sau này có sự dao động chênh lệch khá ít, một vài đoạn có tập hợp các điểm dữ liệu giữa giá trị thực tế và giá trị dự báo trùng nhau thể hiện mô hình dự báo khá chính xác.

Bảng 4.8: Các siêu tham số của LSTM

<i>Chỉ số</i>	<i>Sample 1</i>	<i>Sample 2</i>	<i>Sample 3</i>	<i>Sample 4</i>
Units (Input Layer)	224	192	224	160
Dense (Output Layer)	1	1	1	1
Epochs (Walk Forward)	150	150	150	150
Batch Size	64	64	64	64
Loss	MSE	MSE	MSE	MSE
Optimizer	Adam	Adam	Adam	Adam
Learning Rate	0.000360	0.000976	0.003385	0.006283
Batch Size	64	64	64	64
Dropout	0.2	0.3	0.3	0.1

(Nguồn: Kết quả từ Google Colab)

Trong bảng 4.8, tác giả liệt kê các siêu tham số tối ưu được của mô hình LSTM đã được tối ưu hóa và mang lại hiệu suất tốt nhất cho mô hình này.

Bảng 4.9: Kết quả đánh giá của từng sample - LSTM

	<i>MSE</i>	<i>MAE</i>	<i>RMSE</i>	R^2
Sample 1	3498556	1616.840	1870.443	0.478
Sample 2	219257.7	359.515	468.250	0.739
Sample 3	588600.0	598.047	767.203	0.950
Sample 4	474351.8	559.618	688.732	0.833

(Nguồn: Kết quả từ Google Colab)

Trong bảng 4.9 là kết quả đánh giá của từng sample trên tập test. Nhìn chung mô hình cũng học và dự báo tốt khi dữ liệu đã đủ và ổn định hơn. Cụ thể tác giả sẽ phân tích ở từng sample:

Sample 1: MSE: 3498556 Đây là mẫu có sai số lớn nhất (MSE và RMSE cao nhất), cho thấy mô hình dự báo kém chính xác so với các mẫu khác. R^2 chỉ ở mức 0.478 cho thấy mô hình chỉ giải thích được khoảng 47% biến động của dữ liệu, hiệu suất dự báo chưa tốt, độ phù hợp thấp.


Sample 2,3,4: đều cho thấy mô hình dự báo hoạt động khá tốt, với sai số tương đối thấp (RMSE lần lượt chỉ khoảng 468.250, 767.203, và 688.732) và hệ số xác định R^2 ở mức cao (từ 0.73 đến 0.95), cho thấy khả năng giải thích từ 73% đến 95% biến động dữ liệu thực tế. Sample 2, 3 và 4 cho thấy mô hình dự báo ổn định, sai số thấp, khả năng dự đoán khá chính xác. Nhìn chung, kết quả của ba mẫu này cho thấy mô hình có tiềm năng dự báo tốt trong đa số trường hợp.

Bảng 4.10: Kết quả đánh giá trung bình của mô hình LSTM

Mean Squared Error (MSE)	1195191.3760
Mean Absolute Error (MAE)	783.5051
R-Squared (R^2)	0.9444
Root Mean Squared Error (RMSE)	1093.2481

(Nguồn: Kết quả từ Google Colab)

Bảng 4.10 thể hiện kết quả dự báo của mô hình LSTM trên tập kiểm tra gồm 668 mẫu quan sát. MSE của mô hình là 1195191.3760 cho thấy dự đoán của mô hình lệch so với giá trị thực tế khoảng 1195191.3760 đơn vị bình phương. MAE của mô hình là 783.5051 cho thấy độ lệch trung bình giữa giá trị thực tế và giá trị dự báo là khoảng 783.5051 đơn vị. R^2 của mô hình là 0.9444 cho thấy mô hình giải thích được 94,4% phương sai của dữ liệu. RMSE của mô hình là 1093.2481 cho thấy dự đoán của mô hình lệch so với giá trị thực tế khoảng 1093.2481 đơn vị.



(Nguồn: Kết quả từ Google Colab)

Hình 4.9 Phân phối lợi nhuận thực tế và dự báo (LSTM)

Trong hình 4.9 trình bày phân phối của các giá trị thực tế so với các giá trị dự báo được. Cho thấy cả hai đều có dạng gần chuẩn, tập trung chủ yếu quanh mức 0%, phần sườn dốc đứng. Tuy nhiên, phân phối thực tế có đuôi dài hơn, đặc biệt về phía âm, phản ánh sự tồn tại của các cú sốc hoặc biến động mạnh trên thị trường mà mô hình chưa dự báo được. Trong khi đó, phân phối dự báo nhỏ gọn hơn, có đuôi mỏng và không mô phỏng được đầy đủ các biến động lớn, cho thấy mô hình có xu hướng dự đoán an toàn và trung bình hóa.

Ưu điểm của mô hình là khả năng dự báo tốt ở vùng trung tâm của phân phối nơi tập trung phần lớn giá trị return nhờ đó giúp mô hình hoạt động ổn định trong điều kiện thị trường bình thường. Phân phối dự báo khá mượt và không bị ảnh hưởng nhiều bởi nhiễu, điều này có thể hữu ích trong các ứng dụng yêu cầu độ ổn định cao như quản trị rủi ro cơ bản hoặc định giá trong thị trường ít biến động. Ngoài ra, mức KL Divergence thấp ở chiều “Predicted || Actual là 0.1844” và độ chênh lệch trung bình tương đối thấp cho thấy mô hình nắm bắt khá tốt xu hướng chính.

Tuy nhiên, mô hình cũng bộc lộ những nhược điểm rõ rệt. Việc không phản ánh được các giá trị outlier và đuôi phân phối dài khiến mô hình đánh giá sai về rủi ro thực tế, đặc biệt trong các giai đoạn thị trường biến động mạnh. KL Divergence ở chiều “Actual || Predicted” khá cao 1.5804 cho thấy sự sai lệch lớn khi dùng mô hình thay thế phân phối thực tế. Hơn nữa, Wasserstein Distance có giá trị 0.5729 cũng cho thấy hai phân phối khác nhau về mặt hình dạng, phản ánh rằng mô hình thiếu khả năng mô phỏng toàn diện thị trường, đặc biệt là các tình huống cực đoan.


4.3.3 So sánh hiệu suất của các mô hình

Bảng 4.11: So sánh hiệu suất của mô hình MLP và LSTM

	MLP	LSTM
MSE	561389.4940	1195191.3760
MAE	578.0262	783.5051
R2	0.9737	0.9444
RMSE	749.2593	1093.2481

(Nguồn: Kết quả từ Google Colab)

Dựa trên bảng dữ liệu 4.11 so sánh hiệu suất giữa mô hình MLP và LSTM, ta nhận thấy sự khác biệt rõ rệt giữa hai mô hình qua các chỉ số MSE, MAE, R^2 , và RMSE. Kết quả so sánh hiệu suất giữa hai mô hình MLP và LSTM cho thấy MLP hoạt động tốt hơn rõ rệt. Cụ thể, mô hình MLP đạt giá trị MSE chỉ 561389.4940 thấp hơn nhiều so với LSTM với MSE lên tới 1195191.3760 đơn vị. Về MAE, MLP cũng có kết quả ưu việt với 578.0262 trong khi LSTM đạt 783.5. Giá trị R^2 cho MLP rất cao đạt 0.974, phản ánh khả năng giải thích tốt hơn so với R^2 của LSTM chỉ ở mức 0.944. Cuối cùng, RMSE của MLP là 749.2593 nhỏ hơn đáng kể so với RMSE của LSTM là 1093.2481. Những kết quả này cho thấy mô hình MLP mang lại dự báo chính xác hơn so với LSTM trên tập dữ liệu này. Tổng kết lại, MLP tỏ ra vượt trội hơn LSTM trong tập dữ liệu này, đặc biệt phù hợp cho dự báo ngắn hạn như giá đóng cửa TCB, nhờ hiệu suất ổn định và sai số thấp.



(Nguồn: Kết quả từ Google Colab)

Hình 4.10 Phân phối lợi nhuận thực tế và dự báo (SARIMAX)

Qua quá trình đánh giá và so sánh 2 mô hình MLP và LSTM, để thêm phân khách quan cho mô hình, tác giả đã xây dựng mô hình SARIMAX để làm baseline. Thông qua kiểm định Kullback-Leibler Divergence chiều (Thực tế || Dự báo) là 1.5144 mô hình không tái hiện tốt các đặc điểm phân phối thực của dữ liệu dự báo của mô hình bỏ sót và đánh giá sai nhiều đặc trưng quan trọng trong dữ liệu thực tế và chiều (Dự báo || Thực tế) có giá trị 0.3918 cho thấy mô hình có xu hướng dự báo "an toàn", mô hình quá mượt và không phản ánh đầy đủ rủi ro thực sự. Wasserstein Distance là 0.7978 cũng khẳng định khoảng cách tổng thể giữa hai phân phối là lớn, cho thấy SARIMAX không mô phỏng tốt toàn bộ cấu trúc phân phối lợi nhuận.

Bảng 4.12 So sánh MLP và LSTM với mô hình baseline

	SARIMAX	LSTM	MLP
Kullback-Leibler Divergence (Thực tế Dự báo)	1.5144	1.5804	0.2706
Kullback-Leibler Divergence (Dự báo Thực tế)	0.3918	0.1844	0.2662
Wasserstein Distance	0.7978	0.5729	0.3044

(Nguồn: Kết quả từ Google Colab)

Trong bảng 4.12 trình bày các chỉ số so sánh, mô hình SARIMAX được sử dụng là một mô hình baseline so sánh cho các mô hình học máy tiên tiến như MLP và LSTM. SARIMAX là mô hình tuyến tính truyền thống, thường được dùng để dự báo chuỗi thời gian có yếu tố mùa vụ và quan hệ ngoại sinh. Tuy nhiên, kết quả cho thấy SARIMAX có hiệu suất thấp nhất trong cả ba mô hình, với KL Divergence (Thực tế || Dự báo) đạt 1.5144 và Wasserstein Distance lên đến 0.7978 – đều là những giá trị cao nhất, cho thấy mô hình này dự báo phân phối giá cổ phiếu sai lệch đáng kể so với thực tế. Điều này phản ánh hạn chế rõ rệt của các mô hình thống kê tuyến tính khi áp dụng vào thị trường tài chính, vốn có tính phi tuyến cao và thường xuyên biến động. Việc SARIMAX hoạt động kém hiệu quả như vậy nhấn mạnh sự cần thiết của các mô hình học sâu như MLP, LSTM, vốn có khả năng học tốt hơn các quan hệ phi tuyến và động lực ẩn trong dữ liệu thị trường. Trong tương lai, việc kết hợp thêm yếu tố ngoài thị trường có thể tiếp tục cải thiện độ chính xác.

KẾT LUẬN CHƯƠNG 4

Trong chương 4, tác giả đã trình bày các kết quả nghiên cứu thu được khi chạy các mô hình dự báo giá chứng khoán, sử dụng các thước đo để đánh giá, so sánh và thảo luận hiệu quả của từng mô hình trong khả năng dự báo giá chứng khoán.

CHƯƠNG 5: KẾT LUẬN VÀ KHUYẾN NGHỊ

5.1 Kết luận

Nghiên cứu về việc ứng dụng học máy trong dự báo giá cổ phiếu: nghiên cứu thực nghiệm ở Việt Nam với mục tiêu chính là ứng dụng các mô hình học máy trong dự báo giá cổ phiếu TCB – Ngân hàng Techcombank được niêm yết trên thị trường chứng khoán Việt Nam. Từ đó đề xuất ra các mô hình học máy phù hợp có thể đưa ra các dự báo giá đóng cửa chính xác.

Để đạt được mục tiêu chính này tác giả đã phát triển các mô hình học máy, bao gồm MLP và LSTM, nhằm dự đoán giá cổ phiếu của Ngân hàng TMCP Kỹ thương Việt Nam (TCB), được niêm yết trên Sở Giao dịch Chứng khoán thành phố Hồ Chí Minh. Bộ dữ liệu sử dụng bao gồm 1707 quan sát, thu thập từ ngày 4 tháng 6 năm 2018 đến ngày 31 tháng 3 năm 2025, với 9 biến độc lập và 1 biến phụ thuộc.

Nghiên cứu trả lời cho hai câu hỏi chính: *Thứ nhất*, ưu điểm và nhược điểm của các mô hình dự báo giá chứng khoán trong ngữ cảnh của bài nghiên cứu?

Ưu điểm:

Đối với mô hình MLP, mặc dù không được thiết kế đặc biệt cho dữ liệu chuỗi thời gian như các mô hình hồi tiếp như LSTM, MLP vẫn có những ưu điểm đáng kể trong bài nghiên cứu này bằng việc kết hợp với các kỹ thuật tiền xử lý phù hợp, các chỉ báo kỹ thuật đa dạng. Cụ thể mô hình có các chỉ số đánh giá cao, $R^2 > 95\%$, điều này có chứng tỏ MLP tận dụng tốt các đặc trưng đầu vào: khối lượng giao dịch, chỉ số kỹ thuật như RSI, SMA.. để học các mối quan hệ phi tuyến trong dữ liệu. Qua kiểm định về phân phối cho thấy rằng mô hình MLP có phân phối dự báo gần khớp với dữ liệu thực tế, với KL Divergence cân bằng ở cả hai chiều (khoảng 0.27) và Wasserstein Distance là 0.3044. Điều này chứng tỏ mô hình đã học được cấu trúc tổng thể của dữ liệu tốt hơn và có thể mô phỏng gần đúng các mức sinh lời thực tế, kể cả ở phần đuôi. MLP cũng đã giữ được sự ổn định trong vùng trung tâm và vùng sườn. Ngoài ra do không có cơ chế hồi tiếp, MLP huấn luyện nhanh hơn LSTM, giúp tiết kiệm tài nguyên tính toán.

Ưu thế của LSTM đó là có kiến trúc đặc biệt của nó, được thiết kế để xử lý hiệu quả các dữ liệu chuỗi thời gian. LSTM có khả năng ghi nhớ các thông tin dài hạn. Điều này cho phép LSTM nắm bắt được các mối quan hệ phức tạp và các phụ thuộc theo thời gian trong dữ liệu giá cổ phiếu, vốn có tính chất phi tuyến và biến động không ngừng. Mặc dù hiệu suất thấp hơn MLP trong nghiên cứu này, LSTM cũng đã chứng minh được hiệu quả trong bài toán dự báo giá cổ phiếu trong ngữ cảnh dự báo cho mã cổ phiếu TCB được niêm yết trên thị trường chứng khoán Việt Nam. LSTM còn cải thiện đáng kể độ phù hợp của mô hình ($R^2 > 90\%$) chứng tỏ LSTM vẫn nắm bắt được phần lớn biến động giá.

Nhược điểm của mô hình MLP và LSTM

Cả LSTM và MLP đều có một nhược điểm lớn nhất đó là khả năng mô phỏng các biến động lớn còn kém. Cụ thể được biểu hiện trên biểu đồ phân phối lợi nhuận cho thấy cả hai mô hình đều dự báo phân phối bị thu hẹp ở trung tâm và thiếu độ phủ ở phần đuôi, đặc biệt là đuôi âm. Điều này làm giảm khả năng phát hiện rủi ro khi thị trường đối diện với nhiều biến động. Một điểm yếu khác là cả hai mô hình vẫn có xu hướng “trung bình hóa” dữ liệu, tức là làm mờ mô hình và làm giảm biến động tự nhiên của thị trường bằng cách đưa dự báo về gần trung tâm.

Để trả lời cho câu hỏi nghiên cứu: *Thứ hai*, dựa vào các chỉ số đánh giá hiệu suất thu được, mô hình nào có hiệu suất tốt nhất? Tác giả so sánh các mô hình dự báo dựa trên các tiêu chí như sai số trung bình (RMSE, MAE), độ chính xác, và khả năng thích ứng với biến động thị trường để xác định mức độ hiệu quả của chúng trong việc dự đoán giá cổ phiếu. Kết quả phân tích hồi quy trình bày ở chương 4 cho thấy cả hai mô hình học máy được xây dựng đều có khả năng dự báo giá cổ phiếu hiệu quả. Cụ thể qua các đường mô tả giá thực tế và giá dự báo trong biểu đồ cho thấy mô hình cũng đã nắm bắt được được các xu hướng tăng, giảm của dữ liệu một cách hiệu quả. Đặc biệt hơn là mô hình MLP có khả năng dự báo tốt giá ngắn hạn, hiệu suất qua từng sample có phần nhỉnh hơn đối với mô hình LSTM.

5.2 Khuyến nghị

5.2.1 Đối với nhà đầu tư

Việc áp dụng các mô hình học máy như MLP và LSTM kết hợp với kỹ thuật Walk Forward Optimization với expanding window là một công cụ hỗ trợ hiệu quả trong việc dự báo cổ phiếu. Những mô hình này có khả năng xử lý khối lượng dữ liệu lớn và chọn lọc các yếu tố quan trọng, từ đó nâng cao độ chính xác trong dự báo giá đóng cửa. Tuy nhiên, các mô hình này không nên được sử dụng độc lập mà cần được tích hợp với các phương pháp phân tích truyền thống như phân tích cơ bản (dựa trên báo cáo tài chính) và phân tích kỹ thuật (sử dụng RSI, MACD) để đảm bảo tính toàn diện trong quá trình ra quyết định. Nhà đầu tư nên theo dõi sát sao các biến động toàn cầu và các yếu tố kinh tế vĩ mô (như lãi suất hoặc tin tức kinh tế gần đây), kết hợp với dự báo từ mô hình học máy, để phát hiện sớm xu hướng thị trường, từ đó giảm thiểu rủi ro và tối ưu hóa lợi nhuận. Trong những giai đoạn khủng hoảng hoặc bất ổn kinh tế, việc trang bị công cụ dự báo hiện đại này sẽ mang lại lợi thế cạnh tranh lớn, giúp nhà đầu tư chủ động điều chỉnh chiến lược.

5.2.2 Đối với các công ty chứng khoán

Đối với mục tiêu dự báo ngắn hạn, mô hình MLP là lựa chọn phù hợp và nên được ưu tiên cải thiện, thực tế trong bài nghiên cứu ta thấy được với việc kết hợp các kỹ thuật tiền xử lý phù hợp và sử dụng hiệu quả các chỉ báo kỹ thuật như RSI, SMA, khối lượng giao dịch..., mô hình đã đạt được hiệu suất rất cao ($R^2 > 95\%$) và phân phối dự báo gần khớp với dữ liệu thực tế (KL Divergence là 0.27, Wasserstein Distance là 0.3044). Thêm vào đó, MLP có tốc độ huấn luyện nhanh và tiêu tốn ít tài nguyên hơn so với LSTM, rất phù hợp với các bài toán cần cập nhật thường xuyên và đưa ra quyết định trong thời gian ngắn.

Đối với mục tiêu dự báo dài hạn, công ty nên tận dụng thế mạnh của mô hình LSTM. Với kiến trúc được thiết kế chuyên biệt để xử lý dữ liệu chuỗi thời gian, LSTM có khả năng ghi nhớ các mối quan hệ dài hạn và mô hình hóa tốt sự phụ thuộc theo thời gian. Mặc dù hiệu suất tổng thể thấp hơn MLP ($R^2 > 90\%$), mô hình LSTM

vẫn cho thấy độ mượt cao, ít bị nhiễu và phù hợp với các chiến lược đầu tư dài hạn trong điều kiện thị trường bình ổn. Điều này giúp mô hình hỗ trợ duy trì sự ổn định trong các quyết định chiến lược.

5.3 Hạn chế của nghiên cứu

Dù nghiên cứu đã đạt được một vài kết quả tích cực, và tương đối khả quan so với mục tiêu ban đầu, song không có công trình nào đạt được sự hoàn hảo tuyệt đối. Với những ảnh hưởng khách quan nhất định, đề tài vẫn tồn tại các hạn chế sau:

Cấu trúc khá phức tạp và thời gian huấn luyện dài, đặc biệt là LSTM có cấu trúc phức tạp và thời gian huấn luyện dài đối với các chuỗi thời gian dài với lượng dữ liệu lớn. Hiệu suất của MLP và LSTM phụ thuộc rất nhiều vào các siêu tham số tham gia vào mô hình như: số lượng lớp ẩn, số lượng đơn vị trong mỗi lớp... việc tìm ra cấu trúc và các tham số tối ưu cho các mô hình này đã làm tốn rất nhiều thời gian.

Do giới hạn về thời gian và khả năng thu thập dữ liệu, bộ dữ liệu huấn luyện mô hình chỉ bao gồm 1707 ngày giao dịch, được ghi nhận từ ngày 4 tháng 6 năm 2018 đến ngày 31 tháng 3 năm 2025, mẫu dữ liệu này được coi là nhỏ và do đó chỉ mang lại kết quả khách quan và tương đối. Bên cạnh đó, các mô hình dự báo giá chứng khoán được tác giả trình bày trong đề tài chỉ được xây dựng một cách đơn giản, huấn luyện chủ yếu dựa trên dữ liệu kỹ thuật, chưa tích hợp các dữ liệu vĩ mô và vĩ mô.

Các mô hình dự báo đều chưa có khả năng mô phỏng tốt các biến động lớn trên thị trường chứng khoán và đang có hiện tượng làm giảm biến động tự nhiên của thị trường cụ thể trong giai đoạn COVID-19.

5.4 Đề xuất cho các nghiên cứu trong tương lai

Để khắc phục, giúp mô hình có thể dự báo tốt hơn khi có những biến động lớn trên thị trường chứng khoán, tác giả đề xuất một số phương pháp có thể cải thiện mô hình bằng sử dụng các hàm mất mát khác, thay vì sử dụng Mean Squared Error (MSE) truyền thống, có thể chuyển sang Quantile Loss, Huber Loss hoặc Asymmetric Loss Function để tăng độ nhạy với các sai số lớn và rủi ro ở phần đuôi phân phối. Ngoài ra có thể sử dụng các mô hình kết hợp như ARIMA-LSTM, CNN-LSTM,

Transformer-based models để khai thác mối quan hệ phụ thuộc thời gian và thích ứng tốt hơn với tính phi tuyến của dữ liệu tài chính.

Ngoài ra khóa luận khuyến nghị các bài nghiên cứu sau này nghiên cứu tập trung vào việc phát triển mô hình sử dụng nhiều bộ dữ liệu hơn, như dữ liệu từ HOSE, HNX.. hay xa hơn là dự báo được tiền mã hóa (Crypto), thêm về những nguồn truy xuất dữ liệu đáng tin cậy, mở rộng bộ dữ liệu, tích hợp thêm các dữ liệu vĩ mô, dữ liệu chỉ số cơ bản, dữ liệu phi tài chính để nâng cao phạm vi phân tích. Đồng thời, nên nghiên cứu việc tối ưu hóa tỷ lệ phân chia tập dữ liệu và tinh chỉnh siêu tham số để cải thiện hiệu quả dự báo, đảm bảo kết quả đáng tin cậy, từ đó thúc đẩy ứng dụng học máy trên thị trường chứng khoán Việt Nam.

KẾT LUẬN CHƯƠNG 5

Trong chương 5, tác giả tổng kết các kết quả nghiên cứu, đề cập tới ưu và nhược điểm của các mô hình học máy khi dự đoán giá cổ phiếu, đồng thời đề xuất giải pháp nâng cao hiệu quả dự báo và gợi mở một số định hướng nghiên cứu cho tương lai.

TÀI LIỆU THAM KHẢO

Tài liệu tham khảo Tiếng Việt

- Đào Lê Kiều, Oanh., & Nguyễn Thị Minh, Châu. (2024). Dự báo chỉ số chứng khoán bằng học máy. *Tạp chí Kinh tế và Dự báo*. https://kinhtevadubao.vn/apicenter@/print_article&i=29030
- Khoa, B. T., Huỳnh, T. T., Tùng, T. D., Dũng, N. N., & Đức, N. V. (2022). Các yếu tố ảnh hưởng đến sai số trong dự báo tỷ suất sinh lời của cổ phiếu đơn lẻ: Ứng dụng học máy với Spark MLlib. *HCMCOUJS-Kỹ thuật và Công nghệ*, 17(1), 5–19. <https://doi.org/10.46223/HCMCOUJS.tech.vi.17.1.2245.2022>
- Minh Lâm. (2024, Tháng Tám 28). *Tỷ lệ nhà đầu tư cá nhân lớn dễ tác động tiêu cực tới thị trường chứng khoán - Tạp chí Tài chính*. <https://tapchitaichinh.vn/ty-le-nha-dau-tu-ca-nhan-lon-de-tac-dong-tieu-cuc-toi-thi-truong-chung-khoan.html>
- Quý, T. Q., Hải, N. V., Ninh, H. V., & Thúy, N. T. (2024). SỬ DỤNG MÔ HÌNH HỌC SÂU LSTM TRONG DỰ ĐOÁN GIÁ TRỊ CỔ PHIẾU. *TNU Journal of Science and Technology*, 229(15), 103–111. <https://doi.org/10.34238/tnu-jst.11554>
- Trần Thị Kiều, Đặng Xuân Vinh, & Vương Quang Phước. (2020). Nghiên cứu mạng nơ-ron nhân tạo và ứng dụng vào nhận dạng chữ số viết tay. *Tạp chí Khoa học và Công nghệ, Trường Đại học Khoa học, Đại học Huế, Nghiên cứu mạng nơ-ron nhân tạo và ứng dụng vào nhận dạng chữ số viết tay*.
- Trường Đại học Sư phạm Kỹ thuật TP.HCM. (2021). *Giáo trình Mạng Nơron học sâu và ứng dụng*.
- Vuong, P. H., Phu, L. H., Van Nguyen, T. H., Duy, L. N., Bao, P. T., & Trinh, T. D. (2024). A bibliometric literature review of stock price forecasting: From statistical model to deep learning approach. *Science Progress*, 107(1). <https://doi.org/10.1177/00368504241236557>

Tài liệu tham khảo Tiếng Anh

- Andriy Burkov, B. (2019). *The Hundred-Page Machine Learning*.
- Brown, D. P., & Jennings, R. H. (1989). (1989). *On Technical Analysis. Review of Financial Studies*. doi:10.1093/rfs/2.4.527
- Carol Dmello, A., Utkarsha Naik, A., & Narayan, S. (2025). A DETAIL STUDY ON USING TECHNICAL ANALYSIS FOR STOCK MARKET FORECASTING.

www.irjmets.com @International Research Journal of Modernization in Engineering. www.irjmets.com

- Chojnacki, K., & Ślepaczuk, R. (2023). *Ensembled lstm with walk forward optimization in algorithmic trading*. University of Warsaw, Faculty of Economic Sciences.
- Damodaran, A. (2012). *Investment valuation: Tools and techniques for determining the value of any asset*. John Wiley & Sons.
- Drakopoulou, V. (2016). A Review of Fundamental and Technical Stock Analysis Techniques. *Journal of Stock & Forex Trading*, 05(01). <https://doi.org/10.4172/2168-9458.1000163>
- Duan, Y. (2025). Stock Price Prediction Using Deep Neural Networks: A Comparative Study Between MLP and LSTM. *Advances in Economics, Management and Political Sciences*, 193(1), 1–13. <https://doi.org/10.54254/2754-1169/2025.lh24149>
- Goodfellow, I., Bengio, Y., Courville, A., & Bengio, Y. (2016). *Deep learning* (Vol 1, Sô 2). MIT press Cambridge.
- Haykin, S. (1994). *Neural networks: a comprehensive foundation*. Prentice Hall PTR.
- Hiransha, M., Gopalakrishnan, E. A., Menon, V. K., & Soman, K. P. (2018). NSE Stock Market Prediction Using Deep-Learning Models. *Procedia Computer Science*, 132, 1351–1362. <https://doi.org/10.1016/j.procs.2018.05.050>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8), 1735–1780.
- Inani, S. K., Pradhan, H., Kumar, S., & Biswas, B. (2024). NAVIGATING THE TECHNICAL ANALYSIS IN STOCK MARKETS: INSIGHTS FROM BIBLIOMETRIC AND TOPIC MODELING APPROACHES. *Investment Management and Financial Innovations*, 21(1), 275–288. [https://doi.org/10.21511/imfi.21\(1\).2024.21](https://doi.org/10.21511/imfi.21(1).2024.21)
- Khare, K., Darekar, O., Gupta, P., & Attar, V. Z. (2017). Short term stock price prediction using deep learning. *2017 2nd IEEE International Conference on Recent Trends in Electronics, Information & Communication Technology (RTEICT)*, 482–486. <https://doi.org/10.1109/RTEICT.2017.8256643>
- Liu, M. Y., & Jiang, Y. B. (2021). *Review of neural network algorithms* (Vol 21).

- Maind, Sonali B, Wankar, & Priyanka. (2014). Research paper on basic of artificial neural network. *International Journal on Recent and Innovation Trends in Computing and Communication*, 2, 96–100. <http://www.ijritcc.org>
- Mehtab, S., Sen, J., & Dutta, A. (2020). *Stock Price Prediction Using Machine Learning and LSTM-Based Deep Learning Models*. <https://doi.org/10.13140/RG.2.2.23846.34880>
- Mitchell, T. M. . (1997). *Machine Learning*. McGraw-Hill.
- Noorbakhsh, A., & Shaygani, M. (2024). Deep Learning Approach for Stock Price Prediction: Comparing Single and Hybrid Models. *Advances in Industrial Engineering*, 58(1), 237–249. <https://doi.org/10.22059/aie.2024.372470.1889>
- Pardo, R. (1992). *Design, testing, and optimization of trading systems* (Vol 2). John Wiley & Sons.
- Saputra, R. A. (2023). A STOCK PREDICTION SYSTEM USING TEKNIKAL INDICATORS WITH THE LSTM METHOD. *International Journal on Information and Communication Technology (IJoICT)*, 9(1), 27–43.
- Vijh, M., Chandola, D., Tikkiwal, V. A., & Kumar, A. (2020). Stock Closing Price Prediction using Machine Learning Techniques. *Procedia Computer Science*, 167, 599–606. <https://doi.org/10.1016/j.procs.2020.03.326>

PHỤ LỤC 1 – KẾT QUẢ CHẠY MÔ HÌNH DỮ LIỆU GIÁ LỊCH SỬ

	Time	Open	High	Low	Close	Volume
0	2018-06-04	16550.0	16970.0	16550.0	16550.0	2811840
1	2018-06-05	16020.0	17130.0	15520.0	15520.0	1357500
2	2018-06-06	15350.0	15520.0	14710.0	14870.0	1605480
3	2018-06-07	15270.0	15900.0	15050.0	15900.0	1376540
4	2018-06-08	16320.0	17000.0	16080.0	17000.0	2008500
...	...	...	...	...	...	...
1703	2025-03-26	27900.0	28500.0	27800.0	28000.0	24089300
1704	2025-03-27	28000.0	28150.0	27750.0	27750.0	7518900
1705	2025-03-28	27750.0	27800.0	27450.0	27550.0	12353600
1706	2025-03-31	27400.0	27500.0	27200.0	27500.0	12983300
1707	2025-04-01	27500.0	28000.0	27400.0	27950.0	9054500

1708 rows × 6 columns

THỐNG KÊ MÔ TẢ CÁC BIẾN ĐẦU VÀO

	Volume	Return	SMA_15	RSI	Stochastic \
count	1.683000e+03	1683.000000	1683.000000	1683.000000	1683.000000
mean	7.152648e+06	0.079112	16677.188354	51.800935	52.677422
std	6.050758e+06	1.585191	5495.748546	12.447016	30.771451
min	9.204910e+05	-3.233805	7877.333333	28.053535	0.000000
25%	2.289102e+06	-0.843759	11755.000000	42.878950	24.838036
50%	4.899644e+06	0.000000	15088.666667	51.737263	54.679803
75%	1.087325e+07	1.024590	22867.666667	61.860469	80.947703
max	2.151916e+07	3.261063	27636.666667	73.183174	100.000000

	ATR	OBV	ROC	MACD	Close
count	1683.000000	1.683000e+03	1683.000000	1683.000000	1683.000000
mean	420.209027	7.206935e+08	0.773983	51.583781	16732.905526
std	163.580717	5.500156e+08	6.326937	348.604551	5565.698823
min	190.279877	-6.037533e+06	-11.117236	-672.414491	7230.000000
25%	292.722400	7.052578e+07	-3.447221	-166.728800	11870.000000
50%	391.199587	9.553490e+08	0.441826	43.581334	15300.000000
75%	535.383457	1.088409e+09	4.918766	266.067463	23000.000000
max	753.689469	1.901021e+09	14.173934	729.444457	28120.000000

SO SÁNH KẾT QUẢ GIÁ THỰC TẾ VÀ GIÁ DỰ BÁO CỦA MÔ HÌNH MLP

	Date	Giá trị thực tế	Giá trị dự báo (MLP)
0	2022-07-20	17870.0	17862.580078
1	2022-07-21	17990.0	17998.234375
2	2022-07-22	17840.0	18064.824219
3	2022-07-25	17750.0	18163.171875
4	2022-07-26	17750.0	17871.972656
...	...	...	...
667	2025-03-24	27900.0	27042.644531
668	2025-03-25	28000.0	26918.066406
669	2025-03-26	27750.0	27172.035156
670	2025-03-27	27550.0	26844.167969
671	2025-03-28	27500.0	27011.656250

672 rows × 3 columns

SO SÁNH KẾT QUẢ GIÁ THỰC TẾ VÀ GIÁ DỰ BÁO CỦA MÔ HÌNH LSTM

So sánh Giá trị thực tế và Giá trị dự báo:

	Date	Giá trị thực tế	Giá trị dự báo
0	2022-07-26	17750.0	18833.552734
1	2022-07-27	18090.0	18818.199219
2	2022-07-28	18380.0	18737.695312
3	2022-07-29	18720.0	18764.585938
4	2022-08-01	18570.0	18968.013672
...	...	...	...
663	2025-03-24	27900.0	26998.544922
664	2025-03-25	28000.0	26981.779297
665	2025-03-26	27750.0	27308.341797
666	2025-03-27	27550.0	27356.125000
667	2025-03-28	27500.0	27462.933594

668 rows × 3 columns

KẾT QUẢ ĐÁNH GIÁ CỦA 2 MÔ HÌNH

- Mô hình MLP

=== Tổng hợp kết quả trên toàn bộ các sample (MLP) ===
Mean Squared Error (MSE): 561,389.4940
Root Mean Squared Error (RMSE): 749.2593
Mean Absolute Error (MAE): 578.0262
R-squared (R^2): 0.9737

- Mô hình LSTM

=== Tổng hợp kết quả trên toàn bộ các sample ===
 Mean Squared Error (MSE): 1,195,191.3760
 Root Mean Squared Error (RMSE): 1,093.2481
 Mean Absolute Error (MAE): 783.5051
 R-squared (R^2): 0.9444

PHỤ LỤC 2 – CODE PYTHON

- Chuẩn bị dữ liệu đầu vào

```
FEATURES = ['Volume', 'Return', 'SMA_15', 'RSI', 'Stochastic', 'ATR', 'OBV', 'ROC', 'MACD']
TARGET = 'Close'

df_clean = df[['Time'] + FEATURES + [TARGET]].copy()
df_clean[FEATURES] = df_clean[FEATURES].shift(1)
df_clean['Target_Next_Close'] = df_clean[TARGET].shift(-1)
df_clean = df_clean.dropna()

X = df_clean[FEATURES].values
y = df_clean['Target_Next_Close'].values.reshape(-1, 1)
dates = df_clean['Time'].values

n_total = len(X)
initial_train_size = int(n_total * 0.5)
val_size = int(n_total * 0.1)
test_size = int(n_total * 0.1)
step_size = val_size
```

- Xây dựng mô hình MLP

```
def build_simple_mlp(hp):
    model = Sequential()
    model.add(Dense(
        units=hp.Int('units1', 32, 256, step=32),
        activation=hp.Choice('activation1', ['relu', 'tanh'])
    ))
    if hp.Boolean('use_second_layer'):
        model.add(Dense(
            units=hp.Int('units2', 32, 128, step=32),
            activation=hp.Choice('activation2', ['relu', 'tanh'])
        ))
    model.add(Dense(1, activation='linear'))
    model.compile(
        optimizer=Adam(hp.Float('lr', 1e-4, 1e-2, sampling='log')),
        loss='mse',
        metrics=['mae']
    )
    return model
```

```
print("\nRunning Walk-Forward Optimization with simplified MLP...")
results, preds_all, actuals_all, dates_all = [], [], [], []
step = 0

if os.path.exists('mlp_tuning'):
    shutil.rmtree('mlp_tuning')

while True:
    train_end = initial_train_size + step * step_size
    val_end = train_end + val_size
    test_end = val_end + test_size
    if test_end > len(X):
        break

    print(f"\nStep {step+1} | Train end: {train_end}, Val end: {val_end}, Test end: {test_end}")

    X_train, y_train = X[:train_end], y[:train_end]
    X_val, y_val = X[train_end:val_end], y[train_end:val_end]
    X_test, y_test = X[val_end:test_end], y[val_end:test_end]
    test_dates = dates[val_end:test_end]

    # Normalize
    scaler_X, scaler_y = MinMaxScaler(), MinMaxScaler()
    X_train_scaled = scaler_X.fit_transform(X_train)
    y_train_scaled = scaler_y.fit_transform(y_train)
    X_val_scaled = scaler_X.transform(X_val)
    y_val_scaled = scaler_y.transform(y_val)
    X_test_scaled = scaler_X.transform(X_test)
```

```

# Hyperparameter tuning
tuner = kt.BayesianOptimization(
    build_simple_mlp,
    objective='val_loss',
    max_trials=20,
    directory='mlp_tuning',
    project_name=f'walk_step_{step+1}',
    overwrite=True
)

tuner.search(X_train_scaled, y_train_scaled,
             validation_data=(X_val_scaled, y_val_scaled),
             epochs=100,
             callbacks=[
                 EarlyStopping(patience=15, restore_best_weights=True),
                 ReduceLROnPlateau(patience=7, factor=0.5, min_lr=1e-5)
             ],
             verbose=0)

best_hps = tuner.get_best_hyperparameters(1)[0]
best_model = tuner.hypermodel.build(best_hps)

best_model.fit(X_train_scaled, y_train_scaled,
               validation_data=(X_val_scaled, y_val_scaled),
               epochs=200,
               batch_size=64,
               callbacks=[EarlyStopping(patience=20, restore_best_weights=True)],
               verbose=0)

# Predict
y_pred_scaled = best_model.predict(X_test_scaled).flatten()
y_pred = scaler_y.inverse_transform(y_pred_scaled.reshape(-1, 1)).flatten()
y_true = y[val_end:test_end].flatten()

preds_all.extend(y_pred)
actuals_all.extend(y_true)
dates_all.extend(test_dates)

```

```

# Metrics
mse = mean_squared_error(y_true, y_pred)
mae = mean_absolute_error(y_true, y_pred)
r2 = r2_score(y_true, y_pred)
rmse = np.sqrt(mse)

results.append({
    'step': step + 1,
    'train_size': train_end,
    'val_size': val_size,
    'test_size': test_size,
    'mse': mse,
    'mae': mae,
    'r2': r2,
    'rmse': rmse,
    **best_hps.values
})

step += 1

# === Tổng hợp kết quả ===
results_df = pd.DataFrame(results)
print("\nWalk-Forward Results Summary:")
print(results_df)

```

- Xây dựng mô hình LSTM

```
# Tạo sequences
def create_sequences(X, y, dates, time_steps=TIME_STEPS):
    X_seq, y_seq, date_seq = [], [], []
    for i in range(time_steps, len(X)):
        X_seq.append(X[i-time_steps:i])
        y_seq.append(y[i])
        date_seq.append(dates[i])
    return np.array(X_seq), np.array(y_seq), np.array(date_seq)

X_seq, y_seq, dates_seq = create_sequences(X_raw, y_raw, dates)

# Walk-Forward Settings
n_total = len(X_seq)
initial_train_size = int(n_total * 0.5)
val_size = int(n_total * 0.1)
test_size = int(n_total * 0.1)
step_size = val_size

results = []
preds_all, actuals_all, dates_all = [], [], []
```

```
# Tham số cố định cho bước 2, 3, 4
fixed_params = {
    2: {'units': 192, 'l1': 0.000383, 'l2': 0.000247, 'dropout': 0.3, 'learning_rate': 0.000976},
    3: {'units': 224, 'l1': 0.000450, 'l2': 0.003213, 'dropout': 0.3, 'learning_rate': 0.003385},
    4: {'units': 160, 'l1': 0.000256, 'l2': 0.000350, 'dropout': 0.1, 'learning_rate': 0.006283},
}

# Walk-forward loop
step = 0

while True:
    train_end = initial_train_size + step * step_size
    val_end = train_end + val_size
    test_end = val_end + test_size
    if test_end > len(X_seq):
        break

    print(f"\nStep {step+1} | Train: {train_end}, Val: {val_end}, Test: {test_end}")

    X_train, y_train = X_seq[:train_end], y_seq[:train_end]
    X_val, y_val = X_seq[train_end:val_end], y_seq[train_end:val_end]
    X_test, y_test = X_seq[val_end:test_end], y_seq[val_end:test_end]
    test_dates = dates_seq[val_end:test_end]
```

```

X_train, y_train = X_seq[:train_end], y_seq[:train_end]
X_val, y_val = X_seq[train_end:val_end], y_seq[train_end:val_end]
X_test, y_test = X_seq[val_end:test_end], y_seq[val_end:test_end]
test_dates = dates_seq[val_end:test_end]

# Scale dữ liệu
scaler_X, scaler_y = MinMaxScaler(), MinMaxScaler()
X_train_2d = X_train.reshape(-1, X_train.shape[2])
X_val_2d = X_val.reshape(-1, X_val.shape[2])
X_test_2d = X_test.reshape(-1, X_test.shape[2])

X_train_scaled = scaler_X.fit_transform(X_train_2d).reshape(X_train.shape)
y_train_scaled = scaler_y.fit_transform(y_train)

X_val_scaled = scaler_X.transform(X_val_2d).reshape(X_val.shape)
y_val_scaled = scaler_y.transform(y_val)

X_test_scaled = scaler_X.transform(X_test_2d).reshape(X_test.shape)

```

```

if step == 0:
    best_params = {
        'units': 224,
        'l1': 0.000425,
        'l2': 0.000316,
        'dropout': 0.2,
        'learning_rate': 0.000360
    }
    model = Sequential()
    model.add(LSTM(
        units=best_params['units'],
        activation='tanh',
        kernel_regularizer=l1_l2(
            l1=best_params['l1'],
            l2=best_params['l2']
        ),
        input_shape=(TIME_STEPS, X_seq.shape[2])
    ))
    model.add(Dropout(best_params['dropout']))
    model.add(Dense(1, activation='linear'))
    model.compile(
        optimizer=Adam(learning_rate=best_params['learning_rate']),
        loss='mse',
        metrics=['mae']
    )

```

```

else:
    best_params = fixed_params[step+1]
    model = Sequential()
    model.add(LSTM(
        units=best_params['units'],
        activation='tanh',
        kernel_regularizer=l1_l2(
            l1=best_params['l1'],
            l2=best_params['l2']
        ),
        input_shape=(TIME_STEPS, X_seq.shape[2])
    ))
    model.add(Dropout(best_params['dropout']))
    model.add(Dense(1, activation='linear'))
    model.compile(
        optimizer=Adam(learning_rate=best_params['learning_rate']),
        loss='mse',
        metrics=['mae']
    )

```

```

# Huấn luyện
model.fit(
    X_train_scaled, y_train_scaled,
    validation_data=(X_val_scaled, y_val_scaled),
    epochs=150,
    batch_size=64,
    callbacks=[
        EarlyStopping(patience=15, restore_best_weights=True),
        ReduceLROnPlateau(patience=7)
    ],
    verbose=0
)

y_pred_scaled = model.predict(X_test_scaled).flatten()
y_pred = scaler_y.inverse_transform(y_pred_scaled.reshape(-1, 1)).flatten()
y_true = y_test.flatten()

preds_all.extend(y_pred)
actuals_all.extend(y_true)
dates_all.extend(test_dates)

mse = mean_squared_error(y_true, y_pred)
mae = mean_absolute_error(y_true, y_pred)
r2 = r2_score(y_true, y_pred)
rmse = np.sqrt(mse)

print(f"Best Hyperparameters at Step {step+1}:")
for k, v in best_params.items():
    print(f"  {k}: {v}")

```



```

else: # Bước 2, 3, 4: dùng tham số đã tìm được
    best_params = fixed_params[step+1]
    model = Sequential()
    model.add(LSTM(
        units=best_params['units'],
        activation='tanh',
        kernel_regularizer=l1_l2(
            l1=best_params['l1'],
            l2=best_params['l2']
        ),
        input_shape=(TIME_STEPS, X_seq.shape[2])
    ))
    model.add(Dropout(best_params['dropout']))
    model.add(Dense(1, activation='linear'))
    model.compile(
        optimizer=Adam(learning_rate=best_params['learning_rate']),
        loss='mse',
        metrics=['mae']
    )

# Huấn luyện
model.fit(
    X_train_scaled, y_train_scaled,
    validation_data=(X_val_scaled, y_val_scaled),
    epochs=150,
    batch_size=64,
    callbacks=[
        EarlyStopping(patience=15, restore_best_weights=True),
        ReduceLROnPlateau(patience=7)
    ],
    verbose=0
)

```

```

y_pred_scaled = model.predict(X_test_scaled).flatten()
y_pred = scaler_y.inverse_transform(y_pred_scaled.reshape(-1, 1)).flatten()
y_true = y_test.flatten()

preds_all.extend(y_pred)
actuals_all.extend(y_true)
dates_all.extend(test_dates)

mse = mean_squared_error(y_true, y_pred)
mae = mean_absolute_error(y_true, y_pred)
r2 = r2_score(y_true, y_pred)
rmse = np.sqrt(mse)

print(f"Best Hyperparameters at Step {step+1}:")
for k, v in best_params.items():
    print(f"    {k}: {v}")

results.append({
    'step': step + 1,
    'train_size': train_end,
    'val_size': val_size,
    'test_size': test_size,
    'mse': mse,
    'mae': mae,
    'r2': r2,
    'rmse': rmse,
    **best_params
})

step += 1

```

