

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC
ỨNG DỤNG MÔ HÌNH HỌC MÁY RANDOM FOREST
CLASSIFIER TRONG QUẢN LÝ DANH MỤC ĐẦU TƯ
TẠI THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG

MÃ SỐ: 7340201

NGUYỄN MẠNH THẮNG

TP. HỒ CHÍ MINH, NĂM 2025

NGÂN HÀNG NHÀ NƯỚC VIỆT NAM BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC
ỨNG DỤNG MÔ HÌNH HỌC MÁY RANDOM FOREST
CLASSIFIER TRONG QUẢN LÝ DANH MỤC ĐẦU TƯ
TẠI THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG

MÃ SỐ: 7340201

Họ và tên sinh viên: NGUYỄN MẠNH THẮNG

Mã số sinh viên: 050609211298

Lớp sinh hoạt: HQ9-GE25

NGƯỜI HƯỚNG DẪN KHOA HỌC

TS. NGUYỄN ANH VŨ

TP. HỒ CHÍ MINH, NĂM 2025

TÓM TẮT

Khóa luận tập trung nghiên cứu ứng dụng mô hình học máy Random Forest Classifier trong việc hỗ trợ ra quyết định đầu tư chứng khoán tại thị trường Việt Nam, cụ thể là xây dựng danh mục đầu tư tối ưu dựa trên dữ liệu lịch sử của 404 cổ phiếu có vốn hóa lớn hơn 1.000 tỷ đồng. Trên cơ sở phân tích giá trị giao dịch lịch sử kết hợp chỉ báo kỹ thuật RSI, khóa luận hướng đến việc nhận diện dòng tiền đang tập trung vào các nhóm ngành cụ thể, từ đó đưa ra các khuyến nghị mua, bán hay nắm giữ cổ phiếu theo từng thời điểm. Mô hình Random Forest được huấn luyện để phân loại xu hướng dòng tiền cổ phiếu và được đánh giá hiệu quả bằng các thước đo chính như độ chính xác (accuracy), độ nhạy (recall), độ chính xác dự báo (precision) và F1-score. Sau khi dự báo, các cổ phiếu có tín hiệu mua mạnh nhất sẽ được chọn ra và đánh giá tương quan lẫn nhau để đảm bảo tính đa dạng hóa. Từ nhóm cổ phiếu này, khóa luận sử dụng lý thuyết Markowitz để tối ưu hóa danh mục gồm 10 cổ phiếu có tỷ trọng đầu tư hiệu quả nhất, cân bằng giữa lợi nhuận kỳ vọng và mức độ rủi ro.

Kết quả sau khi thực nghiệm mô hình học máy cho thấy danh mục đầu tư từ mô hình mang lại tính hiệu quả và vượt trội khi so với danh mục thị trường, ở đây đại diện là chỉ số VN-Index trong khoảng thời gian 01/01/2024 – 31/12/2024. Từ đó, tác giả đề xuất kiến nghị cho các tổ chức, cá nhân ứng dụng mô hình học máy nhằm xây dựng danh mục quản lý đầu tư hiệu quả.

Từ khóa: mô hình học máy, danh mục đầu tư, Random Forest Classifier

ABSTRACT

The thesis focuses on applying the Random Forest Classifier machine learning model in supporting securities investment decision-making in the Vietnamese market, specifically building an optimal investment portfolio based on the historical data of 404 stocks with a capitalization of more than VND 1,000 billion. Based on analyzing historical trading values combined with the RSI technical indicator, the thesis aims to identify cash flows that focus on specific industry groups, thereby making recommendations to buy, sell, or hold stocks from time to time. The Random Forest model is trained to classify stock cash flow trends and is evaluated for effectiveness using key metrics such as accuracy, recall, forecast accuracy, and F1-score. After forecasting, the stocks with the strongest buy signals will be selected and evaluated in correlation to ensure diversification. From this group of stocks, the thesis uses Markowitz's theory to optimize a portfolio of 10 stocks with the most effective investment proportion, balancing expected returns and risk levels.

The results after experimenting with the machine learning model show that the investment portfolio from the model is effective and superior when compared to the market portfolio, here represented by the VN-Index in the period of 01/01/2024 – 31/12/2024. The author proposes recommendations for organizations and individuals to apply machine learning models to build an effective investment management portfolio.

Keywords: machine learning model, portfolio, Random Forest Classifier

LỜI CAM ĐOAN

Tôi xin cam đoan Khóa luận tốt nghiệp với đề tài “Ứng dụng mô hình học máy Random Forest Classifier trong quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam” là kết quả nghiên cứu của bản thân tôi, được hoàn thiện dựa trên quá trình nỗ lực nghiêm túc và nhận được sự hướng dẫn tận tình của TS. Nguyễn Anh Vũ.

Tôi xin cam đoan nghiên cứu này là công trình nghiên cứu độc lập của bản thân, không sao chép hay sử dụng bất kỳ nội dung nào từ các tác giả, cơ quan, tổ chức khác mà không có sự cho phép hoặc không trích dẫn nguồn rõ ràng. Toàn bộ số liệu, thông tin và kết quả nghiên cứu được trình bày trong khóa luận đều do tôi tự thu thập, tổng hợp, phân tích và thực hiện mô hình hóa. Nếu phát hiện có bất kỳ hành vi gian lận hay vi phạm đạo đức nghiên cứu nào, tôi xin hoàn toàn chịu trách nhiệm về nội dung Khóa luận tốt nghiệp của mình.

TP. Hồ Chí Minh, tháng 06 năm 2025

Sinh viên thực hiện

Nguyễn Mạnh Thắng

LỜI CẢM ƠN

Trong quá trình thực hiện luận văn tốt nghiệp với đề tài “Ứng dụng mô hình học máy Random Forest Classifier trong quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam”, tôi đã nhận được sự hỗ trợ và hướng dẫn tận tình từ nhiều cá nhân và tập thể. Trước tiên, tôi xin gửi lời cảm ơn chân thành đến quý Thầy/Cô trong Ban Giám hiệu, Phòng Đào tạo và Ban lãnh đạo Khoa Tài chính – Ngân hàng, Trường Đại học Ngân hàng Thành phố Hồ Chí Minh, đã tạo điều kiện thuận lợi để tôi có thể hoàn thành luận văn này.

Tôi xin bày tỏ lòng biết ơn sâu sắc đến Tiến sĩ Nguyễn Anh Vũ, giảng viên hướng dẫn của tôi, người đã tận tình định hướng, chia sẻ kiến thức chuyên môn và hỗ trợ tôi vượt qua những khó khăn trong quá trình nghiên cứu. Sự chỉ bảo tận tâm của Thầy không chỉ giúp tôi hoàn thiện luận văn mà còn mang lại cho tôi những bài học quý báu về phương pháp nghiên cứu và tư duy khoa học. Một lần nữa, tôi xin chân thành cảm ơn tất cả sự giúp đỡ và đồng hành.

Thành quả của khóa luận này không chỉ là nỗ lực của riêng tôi, mà còn là kết quả của sự hỗ trợ, đồng hành và chia sẻ từ quý Thầy Cô, gia đình và bạn bè. Mỗi bước tiến của tôi trong học thuật đều mang dấu ấn của sự giúp đỡ ấy.

Cuối cùng, dù đã nỗ lực hết sức trong quá trình thực hiện, tôi nhận thấy khóa luận vẫn không tránh khỏi những hạn chế nhất định do giới hạn về thời gian và kinh nghiệm. Tôi rất mong nhận được những ý kiến đóng góp quý báu từ quý Thầy/Cô để khóa luận này có thể hoàn thiện và mang lại giá trị cao hơn trong tương lai.

TP. Hồ Chí Minh, tháng 06 năm 2025

Sinh viên thực hiện

Nguyễn Mạnh Thắng

MỤC LỤC

DANH MỤC CÁC TỪ VIẾT TẮT	viii
DANH MỤC CÁC BẢNG	x
DANH MỤC CÁC HÌNH.....	xi
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI NGHIÊN CỨU	1
1.1. Tính cấp thiết của đề tài	1
1.2. Mục tiêu nghiên cứu của đề tài	3
1.3. Câu hỏi nghiên cứu	3
1.4. Đối tượng và phạm vi của nghiên cứu.....	Error! Bookmark not defined.
1.4.1. Đối tượng nghiên cứu.....	4
1.4.2. Phạm vi nghiên cứu.....	4
1.5. Phương pháp nghiên cứu.....	4
1.6. Đóng góp của đề tài.....	5
1.7. Kết cấu của khóa luận	5
TÓM TẮT CHƯƠNG 1.....	7
CHƯƠNG 2: CƠ SỞ LÝ LUẬN VÀ KHẢO LƯỢC NGHIÊN CỨU	8
2.1. Cơ sở lý luận liên quan đến đề tài.....	8
2.1.1. Cơ sở lý thuyết về quản lý danh mục đầu tư.....	8
2.1.2. Lý thuyết Markowitz.....	10
2.1.3. Lý thuyết chỉ số sức mạnh tương đối (RSI)	14
2.1.4. Lý thuyết xu hướng dòng tiền trong chứng khoán (Money Flow Trend Theory)	14
2.1.5. Cơ sở lý thuyết về mô hình học máy.....	18
2.2. Lược khảo các nghiên cứu trước đây.....	31

2.2.1. Nghiên cứu nước ngoài	31
2.2.2. Nghiên cứu trong nước.....	33
TÓM TẮT CHƯƠNG 2	34
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU	35
3.1. Quy trình nghiên cứu	35
3.2. Dữ liệu và công cụ nghiên cứu	37
3.2.1. Dữ liệu nghiên cứu	37
3.2.2. Công cụ nghiên cứu.....	38
3.3. Xây dựng mô hình học máy.....	38
3.3.1. Thư viện phục vụ mô hình	38
3.3.2. Tiền xử lý dữ liệu	38
3.3.3. Xây dựng mô hình.....	40
3.3.4. Kiểm nghiệm mô hình.....	41
TÓM TẮT CHƯƠNG 3	44
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN	45
4.1. Mô tả mẫu nghiên cứu	45
4.2. Kết quả huấn luyện mô hình	45
4.2.1. Kết quả của dự báo dòng tiền theo ngành.....	45
4.2.2. Kết quả khuyến nghị cổ phiếu.....	47
4.2.3. Kết quả tối ưu danh mục đầu tư	48
4.3. Kiểm định nghiên cứu.....	56
4.4. Thảo luận nghiên cứu	59
TÓM TẮT CHƯƠNG 4	61
CHƯƠNG 5: KẾT LUẬN VÀ MỘT SỐ KHUYẾN NGHỊ	62

5.1. Kết luận.....	62
5.2. Khuyến nghị chính sách.....	63
5.2.1. Đối với nhà đầu tư cá nhân	63
5.2.2. Đối với các doanh nghiệp tài chính, công ty chứng khoán	64
5.3. Hạn chế của nghiên cứu.....	64
5.4. Hướng nghiên cứu tiếp theo	65
TÓM TẮT CHƯƠNG 5	67
TÀI LIỆU THAM KHẢO	68
PHỤ LỤC.....	71

DANH MỤC CÁC TỪ VIẾT TẮT

STT	Từ viết tắt	Nguyên nghĩa tiếng Anh	Nguyên nghĩa tiếng Việt
1	HOSE	Hochiminh Stock Exchange	Sở Giao dịch Chứng khoán Thành phố Hồ Chí Minh
2	HNX	Hanoi Stock Exchange	Sở Giao dịch Chứng khoán Hà Nội
3	UPCOM	Unlisted Public Company Market	Sàn giao dịch chứng khoán dành cho các công ty đại chúng chưa niêm yết trên sàn HOSE hoặc HNX
4	VN-Index		Chỉ số thể hiện biến động giá cổ phiếu giao dịch tại Sở Giao dịch Chứng khoán Thành phố Hồ Chí Minh
5	S&P 500	Standard & Poor's 500 Stock Index	Chỉ số cổ phiếu 500 của Standard & Poor
6	ANN	Artificial Neural Networks	Mô hình mạng thần kinh nhân tạo
7	ML	Machine Learning	Mô hình học máy
8	RL	Reinforcement Learning	Học tăng cường
9	AI	Artificial Intelligence	Trí tuệ nhân tạo
10	ARIMA	Autoregressive Integrated Moving Average	Mô hình được sử dụng để phân tích thống kê dữ liệu chuỗi thời gian
11	SVM	Support Vector Machine	Thuật toán máy vector hỗ trợ
12	NLP	Neuro-Linguistic Programming	Lập trình ngôn ngữ tư duy

13	FTSE 100	Financial Times Stock Exchange 100 Index	Chỉ số 100 chứng khoán của Financial Times
14	RSI	Relative Strength Index	Chỉ số sức mạnh tương đối
15	MACD	Moving Average Convergence Divergence	Đường trung bình động hội tụ - phân kỳ
16	P/E	Price-to-Earnings Ratio	Tỷ số giá trên thu nhập
17	DCA	Dollar-Cost Averaging	Bình quân giá vốn
18	MSE	Mean Squared Error	Sai số bình phương trung bình

DANH MỤC CÁC BẢNG

Bảng 4.1. Chi tiết về 5 danh mục của mô hình học máy đề xuất.....	50
---	----

DANH MỤC CÁC HÌNH ẢNH

Hình 2.1. Minh họa đường biên hiệu quả	13
Hình 2.2. Minh họa về học có giám sát (Supervised learning).....	19
Hình 2.3. Minh họa quy trình xử lý dữ liệu của Supervised learning.....	20
Hình 2.4. Minh họa về phương pháp Cây quyết định (Decision Tree).....	22
Hình 2.5. Quy trình xử lý dữ liệu của Rừng ngẫu nhiên (Random Forest)	24
Hình 2.6. Minh họa các thước đo đánh giá mô hình học máy	29
Hình 3.1. Sơ đồ biểu diễn quy trình nghiên cứu mô hình học máy	35
Hình 4.1. Kết quả dự báo dòng tiền của nhóm ngành tại ngày 03/01/2024 dưới dạng biểu đồ tròn	46
Hình 4.2. Kết quả dự báo dòng tiền đổ vào ngành tại ngày 03/01/2024	46
Hình 4.3. Kết quả dự báo dòng tiền thoát khỏi ngành tại ngày 03/01/2024	47
Hình 4.4. Kết quả khuyến nghị mua/bán cổ phiếu với tỷ trọng cụ thể tại ngày 03/01/2024.....	48
Hình 4.5. Mô tả ma trận tương quan của top 10 cổ phiếu trong danh mục xem xét.....	49
Hình 4.6. Biểu đồ thể hiện lợi nhuận tích lũy của 5 danh mục so với VN-Index trong năm 2024	51
Hình 4.7. Biểu đồ phân tán thể hiện mối quan hệ giữa lợi nhuận kỳ vọng và độ lệch chuẩn của 5 danh mục đầu tư và VN-Index.....	52
Hình 4.8. Biểu đồ trực quan hóa lợi nhuận của từng danh mục và VN-Index trong năm 2024	53
Hình 4.9. Biểu đồ trực quan hóa chỉ số Sharpe của 5 danh mục và VN-Index theo từng giai đoạn.....	54
Hình 4.10. Biểu đồ trực quan hóa chỉ số Sortino của 5 danh mục và VN-Index theo từng giai đoạn.....	55
Hình 4.11. Biểu đồ trực quan hóa Maximum Drawdown của 5 danh mục và VN-Index theo từng giai đoạn.....	56
Hình 4.12. Kết quả kiểm nghiệm mô hình Random Forest Classifier	57
Hình 4.13. Thống kê kết quả của kiểm nghiệm mô hình	58

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI NGHIÊN CỨU

1.1. Tính cấp thiết của đề tài

Thị trường chứng khoán Việt Nam trong những năm gần đây đã có những bước phát triển vượt bậc, trở thành một kênh huy động vốn quan trọng và thu hút sự tham gia của hàng triệu nhà đầu tư cá nhân cũng như tổ chức. Tuy nhiên, cùng với sự tăng trưởng về quy mô và thanh khoản, thị trường cũng đối mặt với nhiều thách thức khi dữ liệu ngày càng lớn hơn và đòi hỏi phải có công cụ xử lý hiệu quả hơn. Nghiên cứu về thị trường tài chính đã trải qua nhiều giai đoạn phát triển, từ các lý thuyết kinh tế học truyền thống đến các mô hình định lượng phức tạp, và gần đây là sự bùng nổ của Trí tuệ nhân tạo (AI) cùng Học máy (ML). Các phương pháp phân tích cơ bản và kỹ thuật truyền thống, dù có giá trị nhất định, thường khó xử lý lượng lớn dữ liệu phi cấu trúc và các mối quan hệ phi tuyến tính phức tạp trên thị trường, đồng thời dễ bị ảnh hưởng bởi cảm tính và thiếu khả năng tự học. Tuy nhiên, với sự tiến bộ của các thuật toán tiên tiến cùng năng lực tính toán vượt trội đã mở ra kỷ nguyên mới cho phân tích tài chính, cho phép mô hình học hỏi từ dữ liệu, nhận diện mẫu hình phức tạp và dự đoán với độ chính xác cao. Trong bối cảnh đó, việc ứng dụng các công nghệ tiên tiến, đặc biệt là mô hình học máy dựa trên Random Forest Classifier vào quản lý danh mục đầu tư không chỉ mang ý nghĩa lý luận mà còn có giá trị thực tiễn sâu sắc, đáp ứng nhu cầu tối ưu hóa quyết định đầu tư và quản trị rủi ro tại thị trường Việt Nam.

Các nghiên cứu về ứng dụng mô hình Random Forest Classifier trong quản lý danh mục đầu tư tại thị trường chứng khoán đã được triển khai trên thế giới và Việt Nam, nhưng mức độ phổ biến và chuyên sâu có sự khác biệt. Trên thế giới, Random Forest được sử dụng rộng rãi để dự báo giá cổ phiếu, phân tích rủi ro, và tối ưu hóa danh mục đầu tư dựa trên lợi nhuận và rủi ro nhờ khả năng xử lý dữ liệu phi tuyến và đa đặc trưng. Tại Việt Nam, ứng dụng Random Forest còn hạn chế, chủ yếu tập trung vào dự báo xu hướng giá hoặc phát hiện gian lận báo cáo tài chính, với ít nghiên cứu về tối ưu hóa danh mục đầu tư. Dữ liệu lịch sử giá và chỉ số kinh tế được sử dụng phổ biến, nhưng việc khai thác dữ liệu sau đại dịch hoặc tích hợp dữ

liệu đi sâu cũng như phi cấu trúc vẫn còn thừa thớt. Khoảng trống nghiên cứu tại Việt Nam nằm ở việc áp dụng Random Forest để xây dựng danh mục liên tục theo thời gian.

Về mặt lý luận, đề tài góp phần làm rõ vai trò của học máy trong việc nâng cao hiệu quả phân tích và dự báo tài chính, đặc biệt trong môi trường dữ liệu phi tuyến và phức tạp. Mô hình Random Forest Classifier giúp khắc phục những hạn chế của các phương pháp truyền thống như phân tích cơ bản hay hồi quy tuyến tính nhờ khả năng xử lý dữ liệu đa chiều và phát hiện các mẫu tiềm ẩn. Nghiên cứu đồng thời củng cố mối liên kết giữa trí tuệ nhân tạo và lý thuyết tài chính hiện đại, kiểm nghiệm một số giả thuyết hành vi như giả thuyết thị trường hiệu quả trong bối cảnh đặc thù của thị trường chứng khoán Việt Nam. Kết quả nghiên cứu còn là cơ sở để mở rộng ứng dụng các mô hình học máy tiên tiến hơn trong quản lý danh mục đầu tư.

Về mặt thực tiễn, đề tài đáp ứng nhu cầu cấp thiết của thị trường chứng khoán Việt Nam trong việc nâng cao hiệu quả đầu tư và quản trị rủi ro. Với hơn 10 triệu tài khoản giao dịch tính đến năm 2025, thị trường chứng khoán Việt Nam đang phát triển mạnh nhưng vẫn tồn tại nhiều biến động và thách thức về thanh khoản. Trong bối cảnh đó, mô hình Random Forest Classifier cho phép xử lý dữ liệu hiệu quả, đưa ra khuyến nghị đầu tư chính xác, hỗ trợ nhà đầu tư và tổ chức tài chính tối ưu hóa danh mục. Đồng thời, đề tài góp phần thúc đẩy cá nhân hóa trải nghiệm đầu tư, nâng cao năng lực cạnh tranh của công ty chứng khoán trong nước và hỗ trợ quá trình chuyển đổi số trong lĩnh vực tài chính.

Với những ý nghĩa trên, nghiên cứu về ứng dụng mô hình học máy Random Forest Classifier trong quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam không chỉ có giá trị khoa học trong việc bổ sung lý thuyết và phương pháp luận, mà còn mang tính ứng dụng cao, đáp ứng nhu cầu thực tiễn của nhà đầu tư và các tổ chức tài chính trong bối cảnh thị trường đang phát triển mạnh mẽ nhưng vẫn đầy thách thức. Do đó, việc triển khai đề tài này là cần thiết và phù hợp với cả xu hướng nghiên cứu học thuật lẫn yêu cầu thực tế của nền kinh tế Việt Nam hiện nay.

1.2. Mục tiêu nghiên cứu của đề tài

1.2.1. Mục tiêu tổng quát

Nghiên cứu nhằm xây dựng và ứng dụng mô hình học máy dựa trên cây quyết định (Random Forest Classifier) trong việc quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam, đồng thời đánh giá hiệu quả của mô hình này trong việc tối ưu hóa lợi nhuận và quản trị rủi ro. Thông qua việc so sánh hiệu suất của danh mục đầu tư được xây dựng bởi mô hình học máy với danh mục thị trường (market portfolio) - ở đây là chỉ số VN-Index, nghiên cứu hướng đến việc chứng minh sự vượt trội của mô hình học máy trong việc lựa chọn cổ phiếu, phân bổ vốn và tạo ra giá trị gia tăng vượt trên mức lợi nhuận trung bình của thị trường. Kết quả nghiên cứu không chỉ cung cấp bằng chứng thực nghiệm về tính ưu việt của các phương pháp học máy trong quản lý đầu tư mà còn đặt nền tảng cho việc ứng dụng rộng rãi các công nghệ tiên tiến này vào thực tiễn tài chính tại Việt Nam, đặc biệt là trong quản lý danh mục đầu tư.

1.2.2. Mục tiêu cụ thể

Thứ nhất, xây dựng được mô hình học máy Random Forest Classifier có khả năng đánh giá biến động thị trường, xác định sóng ngành và đưa ra khuyến nghị mua/bán với tỉ trọng cụ thể.

Thứ hai, đánh giá danh mục đầu tư mà mô hình học máy với danh mục thị trường trong năm 2024.

Thứ ba, đề xuất các khuyến nghị ứng dụng cụ thể để nhà đầu tư cá nhân, tổ chức tài chính hoặc doanh nghiệp fintech có thể triển khai AI trong quản lý danh mục đầu tư, đặc biệt trong bối cảnh thị trường chứng khoán Việt Nam.

1.3. Câu hỏi nghiên cứu

Thứ nhất, mô hình học máy Random Forest Classifier được xây dựng trong nghiên cứu hoạt động theo nguyên lý như thế nào?

Thứ hai, mô hình học máy Random Forest Classifier có thể tối ưu hóa danh mục đầu tư và quản trị rủi ro tốt hơn danh mục thị trường hay không?

Thứ ba, xu hướng phát triển của mô hình học máy trong lĩnh vực tài chính

trong tương lai ra sao? Những cải tiến nào có thể giúp AI hoạt động hiệu quả hơn trong đầu tư chứng khoán?

1.4. Đối tượng và phạm vi của nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là mô hình học máy xây dựng dựa trên phương pháp Random Forest Classifier, thuộc nhóm Ensemble learning, cụ thể là tree-based method.

1.4.2. Phạm vi nghiên cứu

Phạm vi nghiên cứu theo thời gian: Khóa luận nghiên cứu đánh giá độ hiệu quả của mô hình học máy Random Forest Classifier trong quản lý danh mục đầu tư trong giai đoạn 2020-2024 (5 năm). Sau đó tiến hành so sánh với danh mục thị trường, cụ thể là chỉ số VN-Index trong năm 2024.

Phạm vi nghiên cứu theo không gian: Khóa luận nghiên cứu tại thị trường chứng khoán Việt Nam, cụ thể là các cổ phiếu có vốn hóa doanh nghiệp lớn hơn 1000 tỷ đồng được niêm yết trên 3 sàn HOSE, HNX và UPCOM tính đến thời điểm tháng 12/2024.

1.5. Phương pháp nghiên cứu

Nghiên cứu được thực hiện theo phương pháp định lượng, sử dụng ngôn ngữ lập trình Python trên nền tảng Google Colab để xử lý và phân tích dữ liệu. Dữ liệu về lịch sử giao dịch (bao gồm lịch sử giá, khối lượng giao dịch, khối lượng cung-cầu), thông tin ngành, chỉ báo kỹ thuật RSI được thu thập từ thư viện Vnstock trong giai đoạn từ 01/01/2020 đến 31/12/2024. Dữ liệu sẽ được kiểm tra, làm sạch (xử lý giá trị thiếu, ngoại lệ) rồi thực hiện chuẩn hóa bằng phương pháp Z-score. Mô hình Random Forest Classifier được chia thành các tập huấn luyện và kiểm tra. Hiệu suất mô hình được đánh giá qua các chỉ số accuracy, precision, recall, F1-score. Kết quả được áp dụng để dự đoán xu hướng cổ phiếu để từ đó xây dựng danh mục đầu tư. Đồng thời, đánh giá hiệu quả thông qua backtesting với các chỉ số như Sharpe Ratio, Sortino, Lợi nhuận tích lũy (Cumulative Return), mức sụt giảm tối đa

(Maximum Drawdown) để đảm bảo tính phù hợp với mục tiêu quản lý danh mục đầu tư.

1.6. Đóng góp của đề tài

- Đóng góp về mặt học thuật: Nghiên cứu này bổ sung vào cơ sở lý thuyết và thực nghiệm về việc sử dụng các thuật toán học máy trong phân tích tài chính, đặc biệt trong bối cảnh thị trường chứng khoán Việt Nam, nơi các nghiên cứu tương tự còn hạn chế. Việc lựa chọn và tích hợp các đặc trưng tài chính làm đầu vào cho mô hình đã làm rõ vai trò của các biến này trong việc nâng cao độ chính xác dự đoán, mở ra hướng nghiên cứu mới về tối ưu hóa đặc trưng trong các mô hình học máy tài chính.
- Đóng góp về mặt thực tiễn: Mô hình được sử dụng bởi các nhà đầu tư để xác định thời điểm mua, bán hoặc giữ cổ phiếu, từ đó nâng cao hiệu quả giao dịch. Việc trực quan hóa các tín hiệu giao dịch trên biểu đồ giá cổ phiếu giúp nhà đầu tư dễ dàng đánh giá tính hợp lý của các tín hiệu qua các giai đoạn thị trường khác nhau, từ xu hướng tăng trưởng đến biến động mạnh. Đồng thời, mô hình có khả năng hỗ trợ nhà đầu tư tối ưu hóa phân bổ tài sản và quản lý rủi ro hiệu quả hơn. Kết quả nghiên cứu góp phần cung cấp định hướng cho các doanh nghiệp công nghệ tài chính (fintech) tại Việt Nam trong việc phát triển các sản phẩm như cố vấn đầu tư tự động (robo-advisor) hoặc ứng dụng quản lý tài sản thông minh, từ đó thúc đẩy sự đổi mới trong ngành tài chính.

1.7. Kết cấu của khóa luận

Cấu trúc nghiên cứu của khóa luận này gồm có 5 chương, cụ thể:

CHƯƠNG 1. TỔNG QUAN VỀ ĐỀ TÀI NGHIÊN CỨU

Giới thiệu tổng quan về đề tài nghiên cứu bao gồm: lý do chọn đề tài, mục tiêu nghiên cứu, câu hỏi nghiên cứu, phạm vi và đối tượng nghiên cứu, phương pháp nghiên cứu và kết cấu nghiên cứu đề tài. Trong đó, trọng tâm của khóa luận là làm rõ sự hiệu quả của việc sử dụng mô hình học máy Random Forest Classifier trong quản lý danh mục đầu tư, đồng thời chỉ rõ giá trị khoa học và giá trị thực tiễn của kết quả nghiên cứu này.

CHƯƠNG 2: CƠ SỞ LÝ LUẬN VÀ KHẢO LƯỢC NGHIÊN CỨU

Chương này trình bày về các cơ sở lý thuyết về quản lý danh mục đầu tư và mô hình học máy, tổng hợp kết quả các nghiên cứu trong và ngoài nước trước đây. Tác giả dựa vào đó để xây dựng các giả thuyết và cơ sở trong mô hình học máy ở chương tiếp theo.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU

Dựa trên mục tiêu nghiên cứu ở chương 1 và cơ sở lý thuyết và tổng quan nghiên cứu ở chương 2, nội dung chương 3 trình bày chi tiết về lựa chọn mô hình từ việc thu thập dữ liệu, làm sạch dữ liệu, xây dựng mô hình, huấn luyện và đánh giá hiệu suất.

CHƯƠNG 4. KẾT QUẢ NGHIÊN CỨU

Chương 4 trình bày kết quả của nghiên cứu, dựa trên những bước đã thể hiện ở chương 3. Cụ thể bao gồm trích dẫn các đoạn code trọng tâm cũng như kết quả của từng bước trong việc xây dựng mô hình. Những kết quả này sẽ được thể hiện một cách trực quan hóa và dễ hiểu.

CHƯƠNG 5. KẾT LUẬN VÀ KHUYẾN NGHỊ CHÍNH SÁCH

Chương 5 nói về kết quả nghiên cứu và đưa ra kết luận. Dựa trên những kết quả nghiên cứu đã đạt được, tác giả đề xuất những gợi ý chính sách cho các nhà đầu tư cá nhân và tổ chức ứng dụng mô hình học máy trong quản lý danh mục đầu tư để nâng cao hiệu quả đầu tư tại thị trường chứng khoán Việt Nam

TÓM TẮT CHƯƠNG 1

Chương 1 đã giới thiệu được những nội dung về: lý do chọn đề tài, mục tiêu nghiên cứu tổng quát và mục tiêu nghiên cứu cụ thể, câu hỏi nghiên cứu, đối tượng nghiên cứu là gì, phạm vi nghiên cứu như thế nào, nghiên cứu sử dụng những phương pháp nào, đóng góp của nghiên cứu, cấu trúc nghiên cứu. Ở chương 1, còn cho biết các mô hình mà tác giả thực hiện kiểm nghiệm nghiên cứu như phương pháp Accuracy, Precision, F1 Score, Recall bên cạnh những phương pháp đánh giá hiệu suất của mô hình.

CHƯƠNG 2: CƠ SỞ LÝ LUẬN VÀ KHẢO LƯỢC NGHIÊN CỨU

2.1. Cơ sở lý luận liên quan đến đề tài

2.1.1. Cơ sở lý thuyết về quản lý danh mục đầu tư

Quản lý danh mục đầu tư (Portfolio Management) là một quá trình mang tính chiến lược, bao gồm việc lựa chọn, phân bổ và giám sát các tài sản tài chính nhằm đạt được mục tiêu đầu tư cụ thể, đồng thời tối ưu hóa mối quan hệ giữa lợi nhuận kỳ vọng và rủi ro liên quan. Nói cách khác, quản lý danh mục đầu tư không chỉ đơn thuần là việc theo đuổi lợi nhuận cao nhất, mà là xây dựng một cơ cấu tài sản hiệu quả, trong đó rủi ro được kiểm soát ở mức chấp nhận được thông qua các chiến lược như đa dạng hóa và phân bổ tài sản hợp lý.

Về mặt thực tiễn, quản lý danh mục đầu tư có thể được thực hiện theo hai cách tiếp cận chính: quản lý chủ động (active management) và quản lý thụ động (passive management). Quản lý chủ động tập trung vào việc vượt trội so với thị trường thông qua phân tích chuyên sâu và dự đoán, trong khi quản lý thụ động hướng đến việc sao chép hiệu suất của một chỉ số thị trường cụ thể, chẳng hạn như VN-Index hay S&P 500, nhằm giảm thiểu chi phí và rủi ro. Dù theo cách tiếp cận nào, mục tiêu cuối cùng của quản lý danh mục đầu tư vẫn là đạt được sự cân bằng giữa lợi nhuận và rủi ro, đồng thời đáp ứng nhu cầu tài chính của nhà đầu tư trong dài hạn.

Theo Markowitz (1952) cho rằng *"Một danh mục đầu tư là tập hợp các tài sản tài chính mà nhà đầu tư sở hữu, được thiết kế để tối ưu hóa lợi nhuận dựa trên mức độ rủi ro chấp nhận được."* Trong khi Sharp (1964) thì định nghĩa bản chất của quản lý danh mục đầu tư là quản lý rủi ro, vì *"Lợi nhuận phần lớn được quyết định bởi thị trường; rủi ro có thể được nhà đầu tư kiểm soát."*

Đồng quan điểm với Markowitz, Bogle (2007) cũng khẳng định *"Mục tiêu của quản lý danh mục đầu tư không phải là vượt qua thị trường, mà là xây dựng một danh mục phù hợp với khả năng chịu rủi ro của bạn và mang lại lợi nhuận thỏa đáng theo thời gian."* Xét ở nhiều khía cạnh hơn, Andrew W. Lo (2008) còn quan tâm đến tính thanh khoản trong một môi trường tài chính luôn luôn thay đổi trong

việc cân bằng giữa rủi ro và lợi nhuận, nơi mà *"đòi hỏi cả công cụ định lượng và phán đoán định tính"*.

Tương tự, Viện CFA (2020) đã đưa ra khái niệm *"Quản lý danh mục đầu tư là quá trình lựa chọn, ưu tiên và phân bổ nguồn lực cho một tập hợp các khoản đầu tư để đáp ứng các mục tiêu tài chính cụ thể đồng thời quản lý rủi ro một cách phù hợp."*

Tại Việt Nam, Nguyễn Đăng Nam (2018) ví việc quản lý danh mục đầu tư là một nghệ thuật đòi hỏi hiểu biết nhiều về kiến thức và kinh nghiệm để *"xây dựng một chiến lược tài chính dài hạn, kết hợp giữa phân tích dữ liệu và hiểu biết sâu sắc về tâm lý thị trường"*.

Tóm lại, từ các quan điểm của những nghiên cứu trước, các khái niệm về quản lý danh mục đầu tư không có nhiều điểm khác biệt. Do đó, quản lý danh mục đầu tư có thể hiểu là sự kết hợp cân bằng giữa mục tiêu lợi nhuận và mức độ rủi ro mà mỗi cá nhân, tổ chức có thể chấp nhận.

Tầm quan trọng của quản lý danh mục đầu tư trong đầu tư chứng khoán

Quản lý danh mục đầu tư đóng vai trò quan trọng trong đầu tư chứng khoán, đặc biệt trong bối cảnh thị trường chứng khoán biến động và phức tạp như Việt Nam. Tầm quan trọng của quản lý danh mục đầu tư được thể hiện qua các khía cạnh sau:

a. Tối ưu hóa lợi nhuận và rủi ro

Đầu tư chứng khoán luôn đi kèm với sự đánh đổi giữa lợi nhuận và rủi ro. Quản lý danh mục đầu tư giúp nhà đầu tư xây dựng danh mục tối ưu, đảm bảo mức lợi nhuận kỳ vọng cao nhất cho một mức rủi ro chấp nhận được, hoặc ngược lại, giảm thiểu rủi ro cho một mức lợi nhuận mục tiêu. Theo Markowitz (1952), thông qua đa dạng hóa danh mục, nhà đầu tư có thể giảm rủi ro không hệ thống (unsystematic risk), từ đó nâng cao hiệu quả đầu tư. Trong thị trường chứng khoán Việt Nam, nơi giá cổ phiếu thường biến động mạnh, việc áp dụng các chiến lược quản lý danh mục hiệu quả là yếu tố then chốt để đạt được lợi nhuận ổn định.

b. Hỗ trợ ra quyết định đầu tư

Quản lý danh mục đầu tư cung cấp một khung phân tích có hệ thống, giúp nhà đầu tư đưa ra các quyết định dựa trên dữ liệu và lý thuyết tài chính thay vì cảm tính. Các công cụ như CAPM của Sharpe (1964) cho phép nhà đầu tư đánh giá lợi nhuận kỳ vọng của từng cổ phiếu dựa trên rủi ro hệ thống, từ đó lựa chọn các cổ phiếu phù hợp để đưa vào danh mục. Trong bối cảnh thị trường chứng khoán Việt Nam, nơi tâm lý đám đông thường ảnh hưởng lớn đến giá cổ phiếu, quản lý danh mục đầu tư giúp nhà đầu tư duy trì tính kỷ luật và tập trung vào mục tiêu dài hạn.

c. Đáp ứng đa dạng mục tiêu đầu tư

Nhà đầu tư chứng khoán có các mục tiêu khác nhau, từ tối đa hóa lợi nhuận ngắn hạn đến bảo toàn vốn trong dài hạn. Quản lý danh mục đầu tư cho phép tùy chỉnh danh mục để phù hợp với các mục tiêu này, thông qua việc phân bổ tài sản giữa các loại cổ phiếu, trái phiếu hoặc các công cụ tài chính khác. Ví dụ, nhà đầu tư có mức chấp nhận rủi ro thấp có thể ưu tiên cổ phiếu blue-chip hoặc trái phiếu, trong khi nhà đầu tư chấp nhận rủi ro cao có thể tập trung vào cổ phiếu tăng trưởng. Theo Fabozzi (2012), việc phân bổ tài sản linh hoạt là yếu tố cốt lõi để đáp ứng nhu cầu đa dạng của nhà đầu tư.

d. Tăng cường khả năng thích ứng với biến động thị trường

Thị trường chứng khoán Việt Nam thường chịu tác động mạnh từ các yếu tố vĩ mô như lãi suất, lạm phát, hoặc các sự kiện kinh tế toàn cầu. Quản lý danh mục đầu tư cho phép nhà đầu tư theo dõi và điều chỉnh danh mục định kỳ để thích ứng với các thay đổi này. Chẳng hạn, trong giai đoạn thị trường suy thoái, nhà đầu tư có thể giảm tỷ trọng cổ phiếu và tăng tỷ trọng trái phiếu để giảm rủi ro. Quá trình theo dõi và điều chỉnh này giúp danh mục duy trì hiệu quả trong các điều kiện thị trường khác nhau.

2.1.2. Lý thuyết Markowitz

Lý thuyết Markowitz, được phát triển bởi nhà kinh tế học Harry Markowitz vào năm 1952, là nền tảng của lý thuyết danh mục đầu tư hiện đại, tập trung vào việc tối ưu hóa lợi nhuận kỳ vọng và giảm thiểu rủi ro thông qua đa dạng hóa danh mục đầu tư; theo lý thuyết này, nhà đầu tư có thể xây dựng một danh mục "hiệu

quả" bằng cách kết hợp các tài sản có mức lợi nhuận kỳ vọng và rủi ro khác nhau, dựa trên mối quan hệ tương quan (correlation) giữa chúng – nếu các tài sản có tương quan thấp hoặc âm, rủi ro tổng thể của danh mục sẽ giảm mà không làm tổn hại đến lợi nhuận. Lý thuyết này nhấn mạnh rằng quyết định đầu tư không chỉ dựa vào lợi nhuận của từng tài sản riêng lẻ mà cần xem xét hiệu quả tổng thể của danh mục, từ đó cung cấp cơ sở toán học (thông qua ma trận hiệp phương sai và tối ưu hóa) để nhà đầu tư lựa chọn danh mục tối ưu phù hợp với khẩu vị rủi ro của mình.

Các khái niệm chính trong lý thuyết:

a. Lợi nhuận kỳ vọng (Expected Return)

Lợi nhuận kỳ vọng của một tài sản là giá trị trung bình của các lợi nhuận có thể xảy ra, được tính dựa trên xác suất của từng kịch bản. Đối với một danh mục đầu tư, lợi nhuận kỳ vọng được tính như sau:

$$E(R_p) = \sum_{i=1}^n w_i E(R_i)$$

Trong đó:

- $E(R_p)$: Lợi nhuận kỳ vọng của danh mục đầu tư.
- w_i : Tỷ trọng đầu tư vào tài sản i (tổng các tỷ trọng $w_i = 1$).
- $E(R_i)$: Lợi nhuận kỳ vọng của tài sản i .
- n : Số lượng tài sản trong danh mục.

b. Độ lệch chuẩn (Standard Deviation)

Trong lý thuyết Markowitz, độ lệch chuẩn của lợi nhuận một tài sản hoặc danh mục đầu tư là thước đo rủi ro liên quan đến sự biến động của lợi nhuận so với giá trị kỳ vọng. Nó phản ánh mức độ dao động của lợi nhuận quanh giá trị trung bình, giúp nhà đầu tư hiểu được mức độ không chắc chắn hoặc biến động của khoản đầu tư.

Độ lệch chuẩn được tính như sau:

$$\sigma_p = \sqrt{\sum_{i=1}^n \sum_{j=1}^n w_i w_j \text{Cov}(R_i, R_j)}$$

Trong đó:

- $w_i w_j$: Tỷ trọng đầu tư vào tài sản i và j
- $Cov(R_i, R_j)$: Hiệp phương sai giữa lợi nhuận của tài sản i và j

c. Hệ số tương quan (Correlation coefficient)

Hệ số tương quan p_{ij} là thước đo thống kê dùng để đánh giá mức độ và hướng của mối quan hệ tuyến tính giữa lợi nhuận của hai tài sản i và j . Nó cho biết lợi nhuận của hai tài sản có xu hướng biến động cùng chiều, ngược chiều, hay độc lập với nhau. Hệ số tương quan giữa hai tài sản i và j được tính như sau:

$$p_{ij} = \frac{Cov(R_i, R_j)}{\sigma_i \sigma_j}$$

Trong lý thuyết Markowitz, hệ số tương quan là yếu tố then chốt để giảm rủi ro danh mục thông qua đa dạng hóa, vì nó ảnh hưởng trực tiếp đến độ lệch chuẩn (rủi ro) của danh mục.

d. Hàm mục tiêu

Lý thuyết Markowitz cung cấp hai cách tiếp cận chính để tối ưu hóa danh mục:

Tối thiểu hóa rủi ro với mục tiêu tìm tỷ trọng w để tối thiểu hóa phương sai danh mục:

$$\text{Min}(w) \quad w^T \Sigma w$$

Với các ràng buộc:

$$\mu^T w \geq \mu_{target}, \sum_{i=1}^n w_i = 1, w_i \geq 0 \quad \forall i$$

Trong đó:

- $w = [w_1, w_2, w_3, \dots, w_n]$: vector tỷ trọng đầu tư
- $\mu = [\mu_1, \mu_2, \mu_3, \dots, \mu_n]$: vector lợi nhuận kỳ vọng của từng tài sản
- $w^T \Sigma w$: phương sai lợi suất của danh mục (đại diện cho rủi ro)


Tối đa hóa Sharpe Ratio:

$$\text{max}(w) \quad \frac{\mu^T w - r_f}{\sqrt{w^T \Sigma w}}$$

e. Đường biên hiệu quả (Efficient Frontier)

Đường biên hiệu quả đại diện cho tập hợp các danh mục đầu tư tối ưu, mang lại lợi nhuận kỳ vọng cao nhất cho một mức rủi ro nhất định hoặc rủi ro thấp nhất cho một mức lợi nhuận kỳ vọng nhất định.

Trên đồ thị, đường biên hiệu quả có dạng một đường cong parabol hướng lên, biểu thị các danh mục đầu tư mà không có danh mục nào khác có thể cung cấp lợi nhuận cao hơn cho cùng mức rủi ro hoặc rủi ro thấp hơn cho cùng mức lợi nhuận.



Hình 2.1. Minh họa đường biên hiệu quả

(Nguồn: Seeking Alpha)

Phương pháp Markowitz mang lại nhiều ưu điểm vượt trội, khẳng định vai trò nền tảng trong quản lý danh mục đầu tư hiện đại. Trước hết, phương pháp này cung cấp một cách tiếp cận khoa học và định lượng để tối ưu hóa danh mục, cho phép nhà đầu tư xác định "đường biên hiệu quả" thông qua việc cân bằng giữa lợi nhuận kỳ vọng giúp đưa ra quyết định đầu tư dựa trên dữ liệu thay vì cảm tính; điều này đặc biệt hữu ích khi nhà đầu tư cần xây dựng danh mục phù hợp với khẩu vị rủi ro cá nhân hoặc tổ chức. Thứ hai, lý thuyết khuyến khích đa dạng hóa danh mục, tận dụng mối quan hệ tương quan giữa các tài sản để giảm rủi ro tổng thể – ví dụ, nếu kết hợp một cổ phiếu biến động cao như công nghệ với một tài sản ổn định như trái phiếu chính phủ có tương quan thấp hoặc âm, sự sụt giảm của một tài sản có thể

được bù đắp bởi tài sản kia, từ đó giảm độ lệch chuẩn của danh mục một cách hiệu quả.

2.1.3. Lý thuyết Chỉ số sức mạnh tương đối (RSI)

Trong lĩnh vực phân tích kỹ thuật thị trường tài chính, Chỉ số sức mạnh tương đối (Relative Strength Index – RSI) là một trong những công cụ động lượng (momentum oscillator) được sử dụng phổ biến và có ảnh hưởng sâu rộng nhất. Được phát triển bởi J. Welles Wilder Jr. vào năm 1978 và giới thiệu trong cuốn sách "New Concepts in Technical Trading Systems", RSI ra đời với mục đích định lượng tốc độ và sự thay đổi của biến động giá tài sản. Khác với các chỉ báo theo xu hướng (trend-following indicators) như đường trung bình động, RSI tập trung vào việc xác định các điều kiện quá mua (overbought) hoặc quá bán (oversold) của một tài sản, từ đó cung cấp tín hiệu tiềm năng về sự đảo chiều xu hướng hoặc tiếp diễn xu hướng.

a. Công thức

RSI là một chỉ báo có giá trị dao động trong khoảng từ 0 đến 100. RSI được tính toán dựa trên sự so sánh giữa mức tăng giá trung bình và mức giảm giá trung bình trong một khoảng thời gian (thường là 14 ngày). Công thức tính RSI gồm các bước sau:

Tính mức tăng (Gain) và mức giảm (Loss):

$$\Delta P_t = P_t - P_{t-1}$$

Trong đó:

- P_t : Giá đóng cửa ngày t
- P_{t-1} : Giá đóng cửa ngày trước đó
- Nếu $\Delta P_t > 0$ ghi nhận là Gain, nếu $\Delta P_t < 0$ ghi nhận là Loss (lấy giá trị tuyệt đối), nếu $\Delta P_t = 0$ thì cả Gain và Loss đều bằng 0.

Tính trung bình Gain và Loss

Tính trung bình Gain và Loss trong chu kỳ n ngày (thường là 14):

$$Average\ Gain = \frac{\sum Gain_i}{n}$$

$$Average\ Loss = \frac{\sum Loss_i}{n}$$

Tính chỉ số sức mạnh tương đối (RS):

$$RS = \frac{Average\ Gain}{Average\ Loss}$$

Tính RSI:

$$RSI = 100 - \frac{100}{1 + RS}$$

b. Ý nghĩa của RSI trong phân tích kỹ thuật

RSI cung cấp thông tin quan trọng về động lực giá và trạng thái thị trường, được diễn giải qua các vùng giá trị:

- Vùng quá mua (Overbought):
 - + $RSI > 70$: Giá cổ phiếu tăng mạnh, có thể đã vượt quá giá trị hợp lý, dẫn đến khả năng đảo chiều giảm.
 - + Tín hiệu bán: Nhà đầu tư có thể cân nhắc bán hoặc giảm tỷ trọng nếu RSI vượt quá 70, đặc biệt khi có dấu hiệu đảo chiều giá.
- Vùng quá bán (Oversold):
 - + $RSI < 30$: Giá cổ phiếu giảm mạnh, có thể bị định giá thấp, dẫn đến khả năng phục hồi hoặc đảo chiều tăng.
 - + Tín hiệu mua: RSI dưới 30 thường là cơ hội mua, nhưng cần xác nhận thêm từ các chỉ báo khác.
- Vùng trung tính (Neutral): RSI từ 30 đến 70 sẽ cho thấy không có tín hiệu mạnh về quá mua hoặc quá bán. Trong vùng này, RSI có thể được sử dụng để xác định xu hướng:
 - + RSI tăng từ 40–50 lên 50–65: Xác nhận xu hướng tăng.
 - + RSI giảm từ 60–70 xuống 50–40: Xác nhận xu hướng giảm.

c. Ưu điểm và hạn chế

- Ưu điểm:
 - + Đơn giản và dễ sử dụng: RSI dễ tính toán và trực quan, phù hợp cho cả nhà đầu tư mới và chuyên nghiệp.

- + Đa năng: Có thể áp dụng cho nhiều loại tài sản (cổ phiếu, forex, hàng hóa) và khung thời gian khác nhau (ngắn hạn, dài hạn).
- + Xác định trạng thái thị trường: RSI giúp nhận biết các vùng quá mua/quá bán và sức mạnh xu hướng.
- + Hỗ trợ chiến lược học máy: RSI là một đặc trưng quan trọng trong các mô hình dự đoán, đặc biệt khi kết hợp với khối lượng giao dịch.
- Hạn chế:
 - + Tín hiệu giả (False Signals): RSI có thể tạo tín hiệu sai trong thị trường biến động mạnh hoặc thị trường đi ngang (sideways).
 - + Độ trễ (Lagging Indicator): RSI dựa trên dữ liệu giá lịch sử, nên có thể chậm trễ trong việc phản ánh thay đổi giá tức thời.
 - + Không hiệu quả trong thị trường đi ngang: Trong thị trường không có xu hướng rõ ràng, RSI có thể dao động trong vùng trung tính mà không cung cấp tín hiệu rõ ràng.
 - + Phụ thuộc vào tham số: RSI thường sử dụng chu kỳ 14 ngày, nhưng hiệu quả có thể thay đổi nếu sử dụng chu kỳ khác (như 9 hoặc 21 ngày).
 - + Cần kết hợp với chỉ báo khác: RSI hoạt động tốt nhất khi được sử dụng cùng các chỉ báo như đường trung bình động (MA), MACD, hoặc khối lượng giao dịch.

2.1.4. Lý thuyết xu hướng dòng tiền trong chứng khoán (Money Flow Trend Theory)

Trong đầu tư chứng khoán, xu hướng dòng tiền (money flow trend) đề cập đến chiều hướng và cường độ dòng vốn di chuyển vào hoặc ra khỏi một cổ phiếu, nhóm ngành hoặc toàn bộ thị trường trong một khoảng thời gian nhất định. Lý thuyết xu hướng dòng tiền cho rằng sự vận động của dòng tiền – đặc biệt là dòng tiền lớn từ nhà đầu tư tổ chức – là một trong những yếu tố chủ đạo quyết định xu hướng giá, và thường mang tính dẫn dắt so với các yếu tố khác như thông tin hay tâm lý thị trường. Dòng tiền trong đầu tư chứng khoán có thể hiểu là lượng vốn thực tế mà nhà đầu tư đưa vào hoặc rút khỏi thị trường thông qua hành vi mua bán cổ phiếu.

Khi một cổ phiếu hoặc nhóm cổ phiếu thu hút dòng tiền lớn trong thời gian liên tục, điều này không chỉ phản ánh kỳ vọng tăng giá mà còn thúc đẩy giá tăng thực sự do áp lực mua tăng lên. Ngược lại, sự rút lui của dòng tiền khỏi cổ phiếu thường dẫn đến hiện tượng giảm giá, mất thanh khoản hoặc phân phối đỉnh.

Khác với dòng tiền ngắn hạn có thể bị nhiễu bởi giao dịch đầu cơ, xu hướng dòng tiền dài hạn phản ánh niềm tin và định hướng chiến lược của nhà đầu tư lớn, từ đó tạo nên các chu kỳ tăng/giảm của giá cổ phiếu hoặc thị trường. Theo lý thuyết này, dòng tiền – tức lượng vốn thực tế được nhà đầu tư đổ vào hoặc rút khỏi cổ phiếu – không chỉ là hệ quả của biến động giá, mà còn là nguyên nhân dẫn đến sự hình thành xu hướng giá. Nói cách khác, giá không thể tăng bền vững nếu không có dòng tiền ủng hộ, và giá sẽ khó giữ vững nếu dòng tiền rút ra liên tục.

2.1.4.1. Nguyên lý cơ bản của lý thuyết

Lý thuyết xu hướng dòng tiền dựa trên 3 nguyên lý nền tảng:

Thứ nhất, giá cổ phiếu không thể tăng bền vững nếu không có dòng tiền hỗ trợ. Sự hiện diện của dòng tiền lớn (đặc biệt từ nhà đầu tư tổ chức) là điều kiện cần để hình thành xu hướng tăng có độ tin cậy cao.

Thứ hai, dòng tiền có tính bền vững hơn so với biến động giá ngắn hạn. Trong khi giá có thể bị ảnh hưởng bởi thông tin, tin đồn hay cảm xúc thị trường, thì dòng tiền – vốn được phân bổ theo chiến lược – phản ánh định hướng lâu dài của nhà đầu tư lớn.

Thứ ba, sự phân kỳ giữa dòng tiền và giá là dấu hiệu cảnh báo sớm. Khi giá tiếp tục tăng nhưng dòng tiền yếu dần hoặc có dấu hiệu phân phối, đây là cảnh báo về khả năng đảo chiều xu hướng.

2.1.4.2. Phân loại xu hướng dòng tiền

Xu hướng dòng tiền tích lũy (Accumulation Phase)

Xu hướng tích lũy là giai đoạn đặc trưng bởi giá cổ phiếu dao động trong biên độ hẹp, thanh khoản thấp đến vừa, nhưng dòng tiền có dấu hiệu âm thầm mua vào. Đây thường là thời kỳ mà các nhà đầu tư tổ chức (hay còn gọi là smart money) bắt

đầu thu gom cổ phiếu sau một đợt suy giảm mạnh, khi phần lớn nhà đầu tư nhỏ lẻ đã rút khỏi thị trường.

Xu hướng dòng tiền tăng (Bullish Money Flow)

Đây là giai đoạn mà dòng tiền đổ vào thị trường một cách mạnh mẽ và rõ rệt, được thể hiện qua sự tăng trưởng đồng thuận của cả giá và khối lượng giao dịch. Khi dòng tiền vào được duy trì liên tục, nó trở thành động lực thúc đẩy xu hướng tăng bền vững của cổ phiếu.

Xu hướng dòng tiền giảm (Bearish Money Flow)

Ngược lại với xu hướng tăng, đây là giai đoạn mà dòng tiền có xu hướng rút khỏi cổ phiếu hoặc thị trường, phản ánh sự mất niềm tin của nhà đầu tư và khả năng suy giảm giá trong tương lai.

Xu hướng dòng tiền phân kỳ (Divergence Money Flow)

Phân kỳ xảy ra khi giá và dòng tiền không đồng thuận, đây là dấu hiệu cảnh báo sớm về khả năng đảo chiều xu hướng. Có hai dạng phân kỳ:

- Phân kỳ âm: Giá tiếp tục tăng nhưng dòng tiền yếu đi (ví dụ: OBV hoặc MFI không tăng theo), cho thấy thị trường đang bị đẩy lên bởi lượng mua yếu hoặc đầu cơ. Đây thường là tín hiệu phân phối.
- Phân kỳ dương: Giá giảm hoặc đi ngang nhưng dòng tiền âm thầm gia tăng, cho thấy cổ phiếu có thể đang trong giai đoạn tích lũy và chuẩn bị tăng giá trở lại.

Phân kỳ là công cụ hữu ích để đánh giá sức mạnh nội tại của một xu hướng và hỗ trợ nhà đầu tư ra quyết định hợp lý hơn, tránh mua đỉnh hoặc bán đáy trong giai đoạn biến động cao.

2.1.5. Cơ sở lý thuyết về mô hình học máy


2.1.5.1. Giới thiệu về học máy

Học máy (Machine Learning - ML) là một nhánh của trí tuệ nhân tạo (Artificial Intelligence - AI), tập trung vào việc phát triển các thuật toán và mô hình cho phép máy tính học từ dữ liệu và cải thiện hiệu suất thực hiện nhiệm vụ mà không cần phải lập trình tường minh cho từng tình huống cụ thể. Nói cách khác, học

máy cung cấp cho máy tính khả năng "học hỏi" từ kinh nghiệm, nhằm đưa ra dự đoán hoặc quyết định chính xác hơn khi gặp dữ liệu mới.

Học máy đã và đang đóng vai trò ngày càng quan trọng trong nhiều lĩnh vực, đặc biệt là trong phân tích dữ liệu lớn (Big Data), tài chính, y tế, thương mại điện tử và giao thông thông minh. Trong lĩnh vực tài chính, học máy được ứng dụng rộng rãi trong phân tích rủi ro, phát hiện gian lận, định giá tài sản và xây dựng mô hình đầu tư. Học máy có bốn cách tiếp cận chủ yếu: học có giám sát, học không giám sát, học bán giám sát và học tăng cường.

2.1.5.2 Học có giám sát (Supervised learning)



Hình 2.2. Minh họa về học có giám sát (Supervised learning)

(Nguồn: Sumitkrsharma)


Học có giám sát (Supervised Learning) là một phương pháp trong học máy, trong đó mô hình được huấn luyện trên một tập dữ liệu đã được gán nhãn sẵn, nghĩa là mỗi mẫu dữ liệu đầu vào đều đi kèm với một giá trị đầu ra tương ứng (nhãn). Mục tiêu của mô hình là học được mối quan hệ giữa đầu vào và đầu ra từ dữ liệu huấn luyện, từ đó có khả năng dự đoán hoặc phân loại chính xác khi gặp dữ liệu mới chưa biết đầu ra.

Quá trình học có giám sát bao gồm hai giai đoạn chính: giai đoạn huấn luyện (training) và giai đoạn dự đoán (prediction). Trong giai đoạn huấn luyện, mô hình

được "học" từ dữ liệu bằng cách điều chỉnh các tham số nội bộ sao cho sai số giữa giá trị đầu ra dự đoán và giá trị thực tế là nhỏ nhất. Sau khi quá trình huấn luyện hoàn tất, mô hình có thể được sử dụng để dự đoán kết quả cho các dữ liệu mới chưa từng gặp trước đó.

Cụ thể, mỗi phần tử trong tập huấn luyện là một cặp (x_i, y_i) , trong đó:

- $x_i \in X$ là vector đặc trưng đầu vào (input feature vector),
- $y_i \in Y$ là nhãn đầu ra tương ứng (target label),
- X là không gian đặc trưng (feature space),
- Y là không gian đầu ra (output space).



Hình 2.3. Minh họa quy trình xử lý dữ liệu của Supervised learning

(Nguồn: Tác giả tự tổng hợp)

Mục tiêu của học có giám sát là xây dựng một hàm ánh xạ, sao cho với mỗi đầu vào $x \in X$, giá trị dự đoán $f(x)$ xấp xỉ gần nhất với nhãn thực tế $y \in Y$.

$$f: X \rightarrow Y$$

Gọi N là số lượng mẫu trong tập dữ liệu huấn luyện. Khi đó, tập huấn luyện có dạng:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

Trong đó:

- $x_i = [x_{i1}, x_{i2}, \dots, x_{in}]$ là vector đặc trưng của mẫu thứ i , với n là số chiều (số đặc trưng).
- y_i là giá trị đầu ra tương ứng (có thể là nhãn rời rạc đối với phân loại, hoặc giá trị thực đối với hồi quy).

Trong học có giám sát, ta giả định tồn tại một hàm ẩn gốc $g: X \rightarrow Y$ sinh ra dữ liệu thực tế. Hàm g được chọn từ tập giả thuyết $\mathcal{H}$ (hypothesis space) để ánh xạ từ không gian đặc trưng X sang không gian nhãn Y :

$$g^* = \arg \min_{g \in \mathcal{H}} \frac{1}{N} \sum_{i=1}^N L(g(x_i), y_i)$$

Trong đó $L(g(x_i), y_i)$ là hàm mất mát, đo lường sai số giữa dự đoán $g(x_i)$ và nhãn thực tế y_i .


Việc chọn hàm f phụ thuộc vào giả định mô hình và thuật toán học cụ thể. Một số phương pháp phổ biến:

- Hồi quy tuyến tính / logistic: giả định mô hình tuyến tính.
- Cây quyết định và Rừng ngẫu nhiên (Random Forest): xây dựng hàm f dựa trên việc phân tách không gian đặc trưng.
- SVM (Support Vector Machine): tối ưu mặt phẳng phân tách.
- Mạng nơ-ron (Neural Networks): dùng nhiều lớp phi tuyến để mô hình hóa quan hệ phức tạp.

Phương pháp Decision Tree (Cây quyết định)

Cây quyết định (Decision Tree) là một trong những thuật toán nền tảng và trực quan nhất trong lĩnh vực học máy có giám sát (supervised learning), được sử dụng phổ biến trong cả hai bài toán phân loại (classification) và hồi quy (regression). Thuật toán này mô phỏng quá trình ra quyết định của con người bằng cách sử dụng cấu trúc dạng cây để biểu diễn chuỗi các điều kiện (hoặc câu hỏi) nhằm phân chia dữ liệu thành các nhóm đồng nhất. Mỗi nút trong cây đại diện cho một điều kiện kiểm tra trên một đặc trưng (feature), mỗi nhánh biểu thị kết quả của điều kiện đó, và mỗi lá (leaf node) là kết quả đầu ra cuối cùng.

Quá trình xây dựng cây quyết định bắt đầu từ nút gốc (root node), nơi toàn bộ dữ liệu được xem xét. Thuật toán sẽ tìm kiếm đặc trưng và ngưỡng phân chia tối ưu để chia dữ liệu thành các nhóm sao cho mức độ "thuần nhất" của mỗi nhóm là cao nhất. Đối với bài toán phân loại, tiêu chí thường được sử dụng để đánh giá mức độ thuần nhất là Entropy và Gini Index, trong khi với bài toán hồi quy, các tiêu chí như Giá trị trung bình bình phương sai số (Mean Squared Error - MSE) thường được áp dụng. Thuật toán tiếp tục chia nhỏ các nhóm dữ liệu con cho đến khi đạt đến điều kiện dừng, chẳng hạn như độ sâu tối đa của cây, số lượng mẫu tối thiểu trong mỗi nút, hoặc mức độ thuần nhất của tập dữ liệu tại nút lá.



Hình 2.4. Minh họa về phương pháp Cây quyết định (Decision Tree)

(Nguồn: Addepto)

Ưu điểm nổi bật của cây quyết định là tính dễ hiểu và khả năng trực quan hóa cao. Người dùng có thể dễ dàng theo dõi quy trình ra quyết định thông qua sơ đồ cây, điều này rất có giá trị trong các lĩnh vực yêu cầu giải thích rõ ràng như tài chính, y tế hoặc pháp lý. Bên cạnh đó, cây quyết định có khả năng xử lý tốt dữ liệu

không tuyến tính và tương tác giữa các biến mà không cần biến đổi đặc trưng phức tạp.

Tuy nhiên, cây quyết định cũng tồn tại một số hạn chế. Mô hình này dễ bị quá khớp (overfitting) khi cây có độ sâu lớn, dẫn đến khả năng khái quát kém trên dữ liệu chưa thấy. Ngoài ra, do chỉ sử dụng một cây duy nhất, mô hình có thể nhạy cảm với biến động nhỏ trong dữ liệu đầu vào. Để khắc phục những hạn chế này, các phương pháp mở rộng như Random Forest hay Gradient Boosting Trees đã được phát triển, trong đó kết hợp nhiều cây quyết định để tạo thành một mô hình mạnh mẽ và ổn định hơn.

Trong bối cảnh nghiên cứu và ứng dụng vào thị trường tài chính, cây quyết định thường được dùng để dự đoán xu hướng giá cổ phiếu, xác định phân khúc rủi ro của danh mục đầu tư, hoặc hỗ trợ ra quyết định giao dịch. Với khả năng mô hình hóa các mối quan hệ phi tuyến và khả năng giải thích cao, phương pháp cây quyết định đóng vai trò là nền tảng cho nhiều thuật toán học máy hiện đại trong phân tích dữ liệu tài chính.


2.1.5.3. Thuật toán Random Forest

Random Forest (Rừng ngẫu nhiên) là một thuật toán học máy thuộc nhóm học có giám sát, được phát triển bởi Leo Breiman và Adele Cutler. Đây là một phương pháp ensemble learning (học tổ hợp), kết hợp nhiều cây quyết định (Decision Trees) để đưa ra dự đoán chính xác và ổn định hơn. Random Forest được áp dụng rộng rãi trong cả hai bài toán phân loại (classification) và hồi quy (regression), trong đó có các ứng dụng nổi bật trong lĩnh vực tài chính như: dự báo xu hướng giá cổ phiếu, đánh giá rủi ro, và tối ưu hóa danh mục đầu tư.

Theo Breiman (2001), Random Forest hoạt động dựa trên hai nguyên tắc chính:

- Bagging (Bootstrap Aggregating): Tạo ra nhiều tập dữ liệu con (bootstrap samples) từ tập dữ liệu gốc bằng cách lấy mẫu ngẫu nhiên có hoàn lại (random sampling with replacement). Mỗi tập dữ liệu con được sử dụng để huấn luyện một cây quyết định riêng biệt.

- Tính ngẫu nhiên trong lựa chọn đặc trưng: Ở mỗi nút của cây quyết định, chỉ một tập hợp con ngẫu nhiên của các đặc trưng (features) được xem xét để phân chia, giúp giảm thiểu sự tương quan giữa các cây và tăng tính đa dạng của mô hình.



Hình 2.5. Quy trình xử lý dữ liệu của Rừng ngẫu nhiên (Random Forest)

(Nguồn: Tác giả tự tổng hợp)

Quá trình hoạt động của Random Forest Classifier bao gồm các bước chính sau:

- Tạo tập dữ liệu con: Từ tập dữ liệu gốc, nhiều tập dữ liệu con được tạo ra thông qua kỹ thuật bagging. Mỗi tập dữ liệu con có kích thước tương đương tập dữ liệu gốc nhưng chứa các mẫu được chọn ngẫu nhiên.

- Xây dựng cây quyết định: Mỗi tập dữ liệu con được sử dụng để huấn luyện một cây quyết định. Ở mỗi nút của cây, chỉ một tập hợp con ngẫu nhiên của đặc trưng được xem xét để tìm ra đặc trưng tốt nhất cho việc phân chia.
- Dự đoán: Khi dự đoán nhãn cho một mẫu dữ liệu mới, mỗi cây quyết định trong rừng đưa ra một dự đoán riêng. Kết quả cuối cùng được xác định bằng cách lấy đa số phiếu từ tất cả các cây.
- Đánh giá đặc trưng: Random Forest cung cấp khả năng đánh giá độ quan trọng của các đặc trưng (feature importance), giúp xác định yếu tố nào có ảnh hưởng lớn nhất đến dự đoán.

Random Forest Classifier sở hữu nhiều ưu điểm nổi bật, khiến nó trở thành một công cụ hiệu quả trong quản lý danh mục đầu tư. Trước hết, mô hình này đạt độ chính xác cao nhờ kết hợp nhiều cây quyết định, giúp giảm thiểu hiện tượng quá khớp và cải thiện khả năng dự đoán so với cây quyết định đơn lẻ. Bên cạnh đó, Random Forest có khả năng xử lý dữ liệu phức tạp, bao gồm dữ liệu thiếu hoặc nhiễu, thường gặp trong dữ liệu tài chính của thị trường chứng khoán Việt Nam. Mô hình cũng cung cấp tính năng đánh giá độ quan trọng của đặc trưng, hỗ trợ nhà đầu tư xác định các yếu tố then chốt như chỉ số P/E, RSI, hoặc biến động giá. Tính linh hoạt của Random Forest cho phép áp dụng trong cả bài toán phân loại, như dự đoán xu hướng giá cổ phiếu, và hồi quy, như dự đoán giá trị cụ thể.

Tuy nhiên, mô hình này cũng tồn tại một số nhược điểm. Việc huấn luyện nhiều cây quyết định đòi hỏi tài nguyên tính toán lớn, gây khó khăn khi xử lý tập dữ liệu quy mô lớn. Ngoài ra, kết quả của Random Forest thường khó giải thích hơn so với các mô hình đơn giản như hồi quy tuyến tính, do bản chất phức tạp của tập hợp cây quyết định. Cuối cùng, hiệu quả của mô hình phụ thuộc nhiều vào chất lượng dữ liệu; nếu dữ liệu mất cân bằng hoặc không đủ phong phú, hiệu suất dự đoán có thể bị hạn chế.

2.1.5.4. Lợi ích của việc ứng dụng mô hình học máy trong quản lý danh mục đầu tư

a. Xử lý dữ liệu lớn và đa dạng một cách hiệu quả

Mô hình học máy có khả năng xử lý khối lượng dữ liệu lớn với nhiều loại đặc trưng khác nhau, từ các chỉ số tài chính (như P/E, ROE, EPS) đến các chỉ số kỹ thuật (như RSI, MACD, Bollinger Bands) và yếu tố vĩ mô (như lãi suất, lạm phát, tỷ giá hối đoái). Trong thị trường chứng khoán Việt Nam, nơi dữ liệu tài chính thường phong phú nhưng không đồng nhất, học máy giúp tích hợp và phân tích các nguồn dữ liệu này một cách nhanh chóng và chính xác. Ví dụ, Random Forest Classifier có thể xử lý hàng trăm đặc trưng để dự đoán xu hướng giá cổ phiếu, từ đó hỗ trợ nhà đầu tư lựa chọn các cổ phiếu tiềm năng và xây dựng danh mục tối ưu. Khả năng này vượt trội hơn so với các phương pháp truyền thống như phân tích cơ bản hoặc kỹ thuật, vốn thường bị giới hạn bởi khối lượng dữ liệu có thể xử lý thủ công.

b. Độ chính xác cao trong dự đoán

Một trong những ưu điểm lớn nhất của Random Forest Classifier là khả năng dự đoán chính xác. Mô hình này hoạt động dựa trên nguyên tắc kết hợp nhiều cây quyết định (decision trees) để đưa ra dự đoán cuối cùng. Mỗi cây quyết định được xây dựng từ một tập con ngẫu nhiên của dữ liệu huấn luyện, giúp giảm thiểu sai số do các yếu tố ngẫu nhiên. Kết quả là, Random Forest thường cho ra những dự đoán chính xác hơn so với các mô hình đơn lẻ, đặc biệt trong các bài toán phân loại phức tạp như dự đoán giá cổ phiếu và quản lý danh mục đầu tư.

c. Cải thiện hiệu quả và tính khách quan trong ra quyết định đầu tư

Mô hình học máy cung cấp các dự đoán nhanh chóng, tự động và dựa trên dữ liệu, giúp giảm thiểu sai lầm do cảm tính, thiên kiến hoặc tâm lý đám đông. Trong bối cảnh thị trường chứng khoán Việt Nam, nơi các quyết định đầu tư thường bị ảnh hưởng bởi tin đồn hoặc biến động ngắn hạn, học máy mang lại một cách tiếp cận khách quan và có hệ thống. Chẳng hạn, Random Forest Classifier có thể đưa ra khuyến nghị mua hoặc bán cổ phiếu dựa trên phân tích dữ liệu lịch sử và các đặc trưng liên quan, thay vì dựa vào cảm giác chủ quan của nhà đầu tư. Điều này không chỉ cải thiện chất lượng quyết định mà còn giúp nhà đầu tư duy trì tính kỷ luật, tập trung vào các mục tiêu đầu tư dài hạn.

d. Tăng cường khả năng thích ứng với biến động thị trường

Mô hình học máy có thể được huấn luyện lại hoặc điều chỉnh để thích ứng với các thay đổi trong điều kiện thị trường, chẳng hạn như chuyển từ giai đoạn tăng trưởng sang suy thoái hoặc phản ứng với các sự kiện vĩ mô như thay đổi chính sách lãi suất. Trong thị trường chứng khoán Việt Nam, nơi biến động giá thường xảy ra do các yếu tố bên ngoài, học máy cho phép nhà đầu tư cập nhật danh mục đầu tư nhanh chóng dựa trên dữ liệu mới.

e. Hỗ trợ xây dựng chiến lược quản lý danh mục tự động và thông minh

Sự phát triển của học máy đã mở ra cơ hội xây dựng các hệ thống quản lý danh mục đầu tư tự động, giảm thiểu sự can thiệp thủ công và tăng cường hiệu quả vận hành. Các mô hình như Random Forest Classifier có thể được tích hợp vào các nền tảng đầu tư thông minh để tự động xếp hạng cổ phiếu, đề xuất phân bổ tài sản, hoặc cảnh báo rủi ro.

2.1.5.5. Các thước đo đánh giá mô hình học máy

a. Accuracy

Accuracy (độ chính xác) là một độ đo định lượng cơ bản trong học máy, được sử dụng để đánh giá hiệu suất của các mô hình phân loại. Độ đo này biểu thị tỷ lệ dự đoán đúng (bao gồm cả dự đoán đúng cho lớp dương tính và âm tính) trên tổng số dự đoán của mô hình. Accuracy phản ánh mức độ chính xác tổng thể của mô hình trong việc phân loại các mẫu thuộc nhiều lớp khác nhau.

Về mặt toán học, Accuracy được xác định bởi công thức sau:

$$Accuracy = \frac{\text{Số lượng dự đoán đúng}}{\text{Tổng số dự đoán}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong đó:

- TP (True Positive): Số lượng mẫu thực tế là dương và được dự đoán là dương.
- TN (True Negative): Số lượng mẫu thực tế là âm và được dự đoán là âm.
- FP (False Positive): Số lượng mẫu thực tế là âm nhưng bị dự đoán là dương.
- FN (False Negative): Số lượng mẫu thực tế là dương nhưng bị dự đoán là âm.

b. Precision

Precision (độ chính xác theo lớp dương) là tỷ lệ giữa số lượng mẫu được mô hình dự đoán đúng là dương so với tổng số mẫu mà mô hình dự đoán là dương (bao gồm cả đúng và sai). Precision phản ánh mức độ đáng tin cậy của các dự đoán dương.

Về mặt toán học, chỉ số Precision được tính theo công thức:

$$Precision = \frac{TP}{TP + FP}$$

Trong đó:

- TP (True Positive): Số lượng mẫu thực tế là dương và được mô hình dự đoán đúng là dương.
- FP (False Positive): Số lượng mẫu thực tế là âm nhưng bị mô hình dự đoán sai là dương.
- Precision nằm trong khoảng $[0, 1]$, với giá trị cao hơn cho thấy mô hình có ít dự đoán sai về lớp dương tính.

Precision đóng vai trò quan trọng trong việc đánh giá độ tin cậy của các dự đoán dương tính của mô hình phân loại. Độ đo này đặc biệt hữu ích trong các bài toán liên quan đến sự chính xác của kết quả, điển hình là trong lĩnh vực tài chính. Một Precision cao đảm bảo rằng khi mô hình dự đoán một mẫu thuộc lớp dương tính, khả năng dự đoán đó đúng là lớn, từ đó tăng độ tin cậy của mô hình trong các ứng dụng thực tiễn. Precision giúp người dùng tập trung vào chất lượng của các dự đoán dương tính, hỗ trợ việc ra quyết định trong các tình huống cần độ chính xác cao.

c. Recall



Recall được định nghĩa là tỷ lệ giữa số lượng các trường hợp dương tính thực sự (True Positive – TP) mà mô hình dự đoán đúng trên tổng số trường hợp thực sự dương tính (TP + FN). Chỉ số này phản ánh khả năng của mô hình trong việc nhận diện chính xác các trường hợp thuộc lớp dương.

Về mặt toán học, chỉ số Recall được tính theo công thức:

$$Recall = \frac{TP}{TP + FN}$$

Trong đó:

- TP (True Positive): Số lượng mẫu thực sự thuộc lớp dương và được mô hình dự đoán đúng.
- FN (False Negative): Số lượng mẫu thực sự thuộc lớp dương nhưng bị mô hình dự đoán sai sang lớp âm.



Hình 2.6. Minh họa các thước đo đánh giá mô hình học máy

(Nguồn: Reseachgate)

Ý nghĩa của Recall nằm ở việc mô hình có thể bao phủ được bao nhiêu phần trăm các trường hợp quan trọng cần được phát hiện. Do đó, Recall thường được ưu tiên trong các bài toán mà việc bỏ sót các trường hợp dương tính gây ra hậu quả nghiêm trọng, chẳng hạn như trong chẩn đoán bệnh lý, phát hiện gian lận tài chính, hoặc nhận diện rủi ro trong đầu tư.

Một Recall cao cho thấy mô hình có khả năng phát hiện tốt các trường hợp thuộc lớp dương, tuy nhiên điều này không đồng nghĩa với việc mô hình có độ

chính xác cao. Đôi khi để đạt được Recall cao, mô hình có thể chấp nhận nhiều dự đoán sai (tức là có nhiều False Positive), dẫn đến Precision thấp. Vì vậy, trong thực tiễn, Recall thường được sử dụng đồng thời với Precision để đánh giá một cách toàn diện hiệu suất của mô hình, và được tổng hợp thành chỉ số F1 Score để cân bằng giữa hai khía cạnh này.

d. F1 score

Trong lĩnh vực học máy, đặc biệt là các bài toán phân loại nhị phân, việc đánh giá hiệu suất của mô hình không chỉ dựa vào độ chính xác tổng thể (accuracy), mà còn cần xem xét kỹ lưỡng mối quan hệ giữa Precision (độ chính xác) và Recall (độ bao phủ). Tuy nhiên, trong nhiều tình huống thực tiễn, hai chỉ số này thường có xu hướng mâu thuẫn với nhau, khiến việc đánh giá mô hình trở nên khó khăn. Để giải quyết vấn đề này, chỉ số F1 Score được sử dụng như một thước đo tổng hợp giúp cân bằng giữa Precision và Recall.

F1 Score là trung bình điều hòa (harmonic mean) của Precision và Recall, được tính theo công thức:

$$F1\ score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

F1 Score có giá trị nằm trong khoảng từ 0 đến 1, trong đó giá trị càng cao cho thấy mô hình có hiệu suất càng tốt trong việc phát hiện đúng lớp dương mà không tạo ra quá nhiều dự đoán sai. Không giống như trung bình cộng, trung bình điều hòa làm giảm ảnh hưởng của những giá trị quá lớn hoặc quá nhỏ, do đó F1 Score chỉ đạt giá trị cao khi cả Precision và Recall đều cao.

Chỉ số này đặc biệt hữu ích trong các tình huống dữ liệu không cân bằng, tức là khi số lượng mẫu giữa hai lớp (dương và âm) chênh lệch đáng kể. Trong những trường hợp như vậy, một mô hình có thể đạt được độ chính xác tổng thể cao bằng cách chỉ dự đoán lớp chiếm đa số, nhưng lại không có giá trị thực tiễn. F1 Score giúp phản ánh công bằng hơn hiệu suất của mô hình trong việc nhận diện chính xác lớp thiểu số – lớp thường được quan tâm nhiều hơn trong các bài toán thực tế như phát hiện gian lận, bệnh lý hiếm, hoặc tín hiệu đầu tư tiềm năng.

Trong khuôn khổ đề tài này, F1 Score được sử dụng như một trong các tiêu chí đánh giá hiệu quả mô hình Random Forest trong việc phân loại các cổ phiếu theo mức độ tiềm năng đầu tư. Việc sử dụng F1 Score cho phép đảm bảo rằng mô hình không chỉ phát hiện được cổ phiếu tốt mà còn hạn chế tối đa các cảnh báo sai, từ đó hỗ trợ nhà đầu tư ra quyết định chính xác và hiệu quả hơn.

2.2. Lược khảo các nghiên cứu trước đây

2.2.1. Nghiên cứu nước ngoài

- Nghiên cứu của Bartram, Branke và Motahari (2021) nhấn mạnh rằng các thuật toán học máy (machine learning - ML) và học tăng cường (reinforcement learning) có thể phân tích dữ liệu phức tạp để tối ưu hóa danh mục đầu tư, vượt xa các mô hình tuyến tính truyền thống. Các tác giả đã tiến hành phân tích trên dữ liệu thực tế từ thị trường chứng khoán Mỹ và châu Âu để tập trung tối ưu hóa danh mục đầu tư theo thời gian thực. Kết quả cho thấy các mô hình học máy cải thiện độ chính xác dự đoán lợi nhuận từ 15-20% so với mô hình định giá tài sản vốn (CAPM). Đặc biệt, các thuật toán học tăng cường giúp tái cân bằng danh mục đầu tư động, tăng hiệu suất trung bình lên đến 10% trong các kịch bản mô phỏng với dữ liệu lịch sử từ 2010-2020.
- Nghiên cứu của Atsalakis, G. S., & Valavanis, K. P. (2009) tổng hợp và đánh giá hơn 100 nghiên cứu từ năm 1990 đến 2008 về các kỹ thuật dự báo thị trường chứng khoán so với mô hình AI sử dụng mạng nơ-ron. Các tác giả đã so sánh hiệu quả của chúng với các mô hình thống kê truyền thống như ARIMA trên dữ liệu từ các chỉ số lớn như S&P 500 và FTSE 100. Kết quả chỉ ra rằng mạng nơ-ron đạt tỷ lệ chính xác dự đoán trung bình cao hơn 30%, cải thiện dự báo xu hướng dài hạn với sai số trung bình giảm 25%, trong khi thuật toán di truyền tối ưu hóa các tham số dự báo nhanh hơn 40% so với phương pháp thủ công.
- Nghiên cứu của Li, Y., & Zhang, W. (2022) chỉ ra rằng AI cải thiện dự báo lợi nhuận ngắn hạn tốt hơn 10-15% nhờ NLP phân tích tin tức tài chính, và

học tăng cường tăng tỷ lệ Sharpe (đo lường lợi nhuận/rủi ro) trung bình 0,2 điểm so với phương pháp Markowitz cổ điển.

- Nghiên cứu của Bahrammirzaee, A. (2010) đã làm rõ cách AI giảm thiểu sai lầm do yếu tố con người, một lợi ích quan trọng trong quản lý danh mục đầu tư. Kết quả thu được từ mô hình lai giữa kinh tế lượng truyền thống và ANN giảm thiểu sai lệch cảm xúc trong quyết định đầu tư với tỷ lệ sai sót giảm 35%.
- Nghiên cứu của Chen, J., & Huang, S. (2023) thử nghiệm mô hình học máy trên dữ liệu từ các quỹ phòng hộ (hedge funds) giai đoạn 2018-2022, phân tích rủi ro hệ thống và rủi ro cụ thể. Kết quả đạt được là AI giảm tổn thất tối đa (maximum drawdown) 22% trong các sự kiện khủng hoảng và tăng khả năng phát hiện rủi ro bất thường 30% so với phương pháp truyền thống như Value-at-Risk (VaR)
- Báo cáo của Mercer (2024) cung cấp cái nhìn cập nhật về mức độ ứng dụng AI và những thách thức đi kèm trong quản lý đầu tư hiện nay. Điều này được thể hiện qua 91% nhà quản lý đang hoặc dự định sử dụng AI, với 65% báo cáo cải thiện hiệu suất danh mục đầu tư từ 5-10% nhờ phân tích dữ liệu nâng cao. Tuy nhiên, 40% cho biết thách thức lớn nhất là chất lượng dữ liệu đầu vào, trong khi 25% lo ngại về vấn đề đạo đức liên quan đến tự động hóa hoàn toàn.
- Báo cáo của Deloitte (2022) dựa trên khảo sát 200 chuyên gia tài chính từ các công ty quản lý quỹ lớn tại Bắc Mỹ, châu Âu và châu Á. Kết quả cho thấy các quỹ đầu tư ứng dụng AI báo cáo tăng trưởng alpha trung bình 8-12% hàng năm nhờ khả năng phân tích dữ liệu thay thế, trong khi chi phí vận hành giảm 20-30% do tự động hóa quy trình như tái cân bằng danh mục và phân tích báo cáo tài chính. Ngoài ra, 75% nhà quản lý cho biết AI giúp họ phát hiện rủi ro hệ thống sớm hơn 2-3 ngày so với phương pháp truyền thống.

2.2.2. Nghiên cứu trong nước

- Nghiên cứu của Phạm Quốc Cường (2024) đã áp dụng mô hình học sâu (deep learning) để phân tích dữ liệu lịch sử của các quỹ đầu tư lớn tại Việt Nam như VFM, Dragon Capital. Kết quả chỉ ra rằng AI có thể tăng lợi nhuận trung bình hàng năm thêm 8-10% thông qua việc tự động điều chỉnh tỷ trọng danh mục dựa trên dự báo xu hướng thị trường.
- Nghiên cứu của Công ty Chứng khoán SSI (2025) đã phát triển một nền tảng sử dụng AI để cá nhân hóa danh mục đầu tư cho khách hàng, dựa trên phân tích hành vi đầu tư và khẩu vị rủi ro. Nền tảng này sử dụng thuật toán học tăng cường (reinforcement learning) để liên tục điều chỉnh danh mục theo biến động thị trường. Báo cáo sơ bộ cho thấy tỷ lệ thành công trong việc đạt mục tiêu lợi nhuận tăng 20% so với phương pháp truyền thống.
- Nghiên cứu của Nguyễn Thị Thu Hà (2024) sử dụng mô hình học máy (machine learning) như SVM (Support Vector Machine) và Random Forest để dự đoán lợi nhuận và rủi ro của danh mục đầu tư trên thị trường chứng khoán Việt Nam. Kết quả cho thấy các mô hình AI cải thiện độ chính xác dự báo lên đến 85% so với các phương pháp thống kê truyền thống, đặc biệt trong bối cảnh thị trường biến động mạnh như giai đoạn 2022-2023.
- Nghiên cứu của Trần Văn Hùng và nhóm tác giả (2025) áp dụng thuật toán học sâu (deep learning) để phân tích dữ liệu giao dịch cá nhân và xây dựng danh mục đầu tư tối ưu dựa trên khẩu vị rủi ro. Kết quả thử nghiệm trên 500 nhà đầu tư tại TP.HCM cho thấy lợi nhuận trung bình tăng 9,5% trong 6 tháng, đồng thời giảm thiểu rủi ro biến động danh mục xuống 12%.
- Nghiên cứu của Nguyễn Quang Vinh (2025) phân tích cách AI được sử dụng để quản lý danh mục đầu tư kết hợp cổ phiếu, trái phiếu và vàng trong bối cảnh lạm phát tại Việt Nam năm 2024. Tác giả chỉ ra rằng AI giúp nhà đầu tư điều chỉnh danh mục nhanh chóng trước các biến động kinh tế, giảm thiểu tổn thất xuống 5-7%.


TÓM TẮT CHƯƠNG 2

Chương 2 trình bày nền tảng lý thuyết về quản lý danh mục đầu tư, với trọng tâm là lý thuyết Markowitz – tối ưu hóa danh mục dựa trên lợi nhuận kỳ vọng và rủi ro thông qua đa dạng hóa. Bên cạnh đó, chương còn đề cập đến chiến lược trung bình giá (DCA) và lý thuyết xu hướng dòng tiền – phản ánh vai trò của dòng vốn trong xác định xu hướng thị trường. Phần tiếp theo giới thiệu về học máy, đặc biệt là mô hình Random Forest, làm cơ sở cho dự báo và phân loại cổ phiếu. Cuối chương là tổng quan các nghiên cứu trong và ngoài nước, chứng minh hiệu quả ứng dụng AI trong tối ưu danh mục và ra quyết định đầu tư.

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Quy trình nghiên cứu

Để thực hiện đề tài, nghiên cứu được triển khai theo quy trình gồm 7 bước chính, bao gồm việc thu thập dữ liệu, tiền xử lý, xây dựng và đánh giá mô hình học máy, nhằm đảm bảo tính khoa học và hiệu quả trong việc ứng dụng mô hình Random Forest Classifier vào quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam:



Hình 3.1. Sơ đồ biểu diễn quy trình nghiên cứu mô hình học máy

(Nguồn: Tác giả tự tổng hợp)

Bước 1: Xác định mục tiêu nghiên cứu và biến phụ thuộc

Trước tiên, cần xác định rõ mục tiêu của mô hình học máy trong bối cảnh quản lý danh mục đầu tư bao gồm bao gồm việc dự báo xu hướng cổ phiếu trong

tương lai gần cũng như tối ưu hóa lợi nhuận và rủi ro. Trên cơ sở đó, lựa chọn dữ liệu cần thiết để tiến hành xây dựng mô hình.

Bước 2: Thu thập dữ liệu

Tiến hành thu thập dữ liệu bằng việc kết nối API với Công ty Cổ phần chứng khoán SSI để lấy trực tiếp dữ liệu bao gồm lịch sử giao dịch, khối lượng giao dịch, thông tin doanh nghiệp và ngành, chỉ báo kỹ thuật.

Bước 3: Tiền xử lý dữ liệu

Thực hiện các thao tác làm sạch dữ liệu như xử lý giá trị thiếu, loại bỏ dữ liệu bất thường, chuẩn hóa hoặc chuyển đổi dữ liệu về định dạng phù hợp. Đồng thời, tiến hành xây dựng các đặc trưng (features) có ý nghĩa đối với bài toán phân loại, bao gồm các biến kỹ thuật, tài chính hoặc các biến trễ theo thời gian.

Bước 4: Xây dựng mô hình

Xây dựng biến mục tiêu (label) bằng cách gán nhãn cho các quan sát trong bộ dữ liệu dựa trên tiêu chí định trước. Đây là bước quan trọng nhằm biến bài toán thành bài toán phân loại có giám sát.

Bước 5: Huấn luyện mô hình

Tiến hành chia bộ dữ liệu thành hai phần: tập huấn luyện (training set) và tập kiểm định (test set), nhằm đảm bảo tính khách quan khi đánh giá mô hình. Tỷ lệ phân chia được áp dụng là 70% dữ liệu cho huấn luyện và 30% cho kiểm định.

Bước 6: Đánh giá mô hình

Sử dụng các thước đo đánh giá phù hợp như độ chính xác (accuracy), độ nhạy (recall), độ đặc hiệu (precision) và F1-score để kiểm định hiệu quả mô hình trên tập kiểm định. Sau đó, áp dụng kết quả phân loại vào quá trình ra quyết định đầu tư và xây dựng danh mục cổ phiếu, từ đó đánh giá khả năng ứng dụng mô hình trong thực tiễn quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam.

Bước 7: Ứng dụng và kiểm tra thực tế

Áp dụng mô hình để dự đoán danh mục đầu tư (chọn cổ phiếu mua/bán/giữ). Đồng thời thực hiện backtesting trên dữ liệu lịch sử để đánh giá lợi nhuận và rủi ro của mô hình.

3.2. Dữ liệu và công cụ nghiên cứu

3.2.1. Dữ liệu nghiên cứu

Nghiên cứu sử dụng dữ liệu lịch sử giao dịch chứng khoán được thu thập từ thư viện Vnstock, một công cụ mã nguồn mở chuyên cung cấp thông tin thị trường chứng khoán Việt Nam với độ tin cậy cao. Dữ liệu bao gồm các giao dịch trên ba sàn chính: Sở Giao dịch Chứng khoán TP.HCM (HOSE), Sở Giao dịch Chứng khoán Hà Nội (HNX) và UPCoM. Dữ liệu được truy xuất thông qua giao diện lập trình Python, đảm bảo tính chính xác, đồng bộ và dễ dàng xử lý. Thời gian thu thập dữ liệu trải dài từ ngày 01/01/2020 đến ngày 31/12/2024, phản ánh đầy đủ các giai đoạn biến động của thị trường chứng khoán Việt Nam, từ giai đoạn phục hồi sau đại dịch COVID-19, khủng hoảng thanh khoản năm 2022, đến xu hướng ổn định và tăng trưởng trong năm 2024.

Nghiên cứu tập trung vào 404 cổ phiếu có giá trị vốn hóa thị trường lớn hơn 1.000 tỷ đồng tính đến tháng 12/2024, bao gồm các cổ phiếu niêm yết trên cả ba sàn HOSE, HNX và UPCoM. Danh sách này đảm bảo đại diện cho các doanh nghiệp có quy mô lớn và thanh khoản tốt. Đồng thời, các cổ phiếu thuộc nhiều lĩnh vực kinh tế khác nhau như tài chính, bất động sản, công nghiệp, tiêu dùng, công nghệ và viễn thông, tạo nên sự đa dạng trong phân tích và ứng dụng thực tiễn.

Tập dữ liệu này chứa dữ liệu giá cổ phiếu lịch sử của cổ phiếu niêm yết trên thị trường chứng khoán Việt Nam, được tổ chức theo ngành. Các thuộc tính chính bao gồm:

- Time: Ngày ghi nhận giá cổ phiếu.
- Close: Giá đóng cửa của cổ phiếu trong ngày.
- Volume: Khối lượng giao dịch của cổ phiếu trong ngày.
- Ticker: Mã định danh duy nhất của cổ phiếu (ví dụ: ACB, VNM, FPT,...).
- Sector: Ngành mà cổ phiếu thuộc về (ví dụ: Bất động sản, Ngân hàng, Xây dựng,...).

Hai tập dữ liệu bổ sung là *recommendations.csv* (chứa tín hiệu giao dịch) và *prices.csv* (chứa giá đóng cửa hàng ngày) được sử dụng để hỗ trợ phân tích.

3.2.2. Công cụ nghiên cứu

Để xây dựng và thực nghiệm mô hình, nghiên cứu này sử dụng ngôn ngữ lập trình Python làm công cụ chính. Python được lựa chọn do tính ổn định và khả năng tương thích với các thư viện học máy hiện đại. Python cung cấp cú pháp đơn giản, dễ đọc, và các công cụ mạnh mẽ để xử lý dữ liệu tài chính cũng như triển khai mô hình học máy.

Bên cạnh đó tác giả còn sử dụng thêm Jupyter Notebook và Visual Studio Code (VS Code) làm môi trường phát triển. Jupyter Notebook với chức năng để phát triển, kiểm tra, và trực quan hóa kết quả, đồng thời cho phép thực hiện từng bước code, dễ dàng debug. Trong khi Visual Studio Code (VS Code) được sử dụng hỗ trợ để quản lý các tệp mã nguồn lớn hoặc khi cần tổ chức dự án theo dạng module.

3.3. Xây dựng mô hình học máy

3.3.1. Thư viện phục vụ mô hình

Phân tích được thực hiện bằng Python (phiên bản 3.x) trong môi trường Google Colab. Các thư viện chính bao gồm:

- *Pandas*: Xử lý và phân tích dữ liệu.
- *NumPy*: Tính toán số học.
- *Matplotlib* và *Seaborn*: Trực quan hóa dữ liệu.
- *SciPy*: Tối ưu hóa danh mục.
- *Zipfile* và *OS*: Quản lý tệp.
- *Itertools*: Tạo tổ hợp mã cổ phiếu.

3.3.2. Tiền xử lý dữ liệu

3.3.2.1. Tải và làm sạch dữ liệu

Sau khi hoàn tất quá trình giải nén dữ liệu, tác giả tiến hành bước xử lý và tổ chức dữ liệu để phục vụ cho các giai đoạn phân tích và huấn luyện mô hình tiếp theo. Cụ thể, toàn bộ dữ liệu lịch sử giao dịch được lưu trữ dưới định dạng .csv, được phân loại thành các thư mục con tương ứng với từng nhóm ngành (như ngân hàng, bất động sản, năng lượng,...).

Sau khi xử lý, dữ liệu của mỗi cổ phiếu được lưu trữ vào một từ điển có tên *stock_dfs*, với mỗi phần tử là một bảng dữ liệu (DataFrame) tương ứng với từng mã cổ phiếu. Song song đó, một từ điển khác là *sector_info* cũng được tạo ra để ánh xạ giữa mã cổ phiếu và nhóm ngành mà cổ phiếu đó thuộc về. Hai cấu trúc dữ liệu này đóng vai trò trung tâm trong việc quản lý, phân tích và truy xuất thông tin cổ phiếu xuyên suốt quá trình thực hiện đề tài.

Chi tiết đoạn code để tải và xử lý dữ liệu (Phụ lục 8)

Mã này duyệt qua các thư mục ngành, đọc tệp CSV của từng cổ phiếu, thêm cột ticker và sector, và chuyển cột time sang định dạng datetime. Dữ liệu được lưu trong từ điển *stock_dfs* để xử lý tiếp.

3.3.2.2. Tính toán chỉ báo kỹ thuật

Đoạn mã được trình bày nhằm tính toán chỉ số sức mạnh tương đối (RSI), một chỉ số kỹ thuật dùng để đánh giá động lượng giá và phát hiện các điều kiện mua/bán trong thị trường chứng khoán. Hàm `compute_rsi` tính RSI chuẩn dựa trên chuỗi giá đóng cửa trong 14 ngày, xác định giá tăng/giảm trung bình để tính tỷ lệ sức mạnh và cuối cùng suy ra RSI. Trong khi đó, phần mã điều chỉnh theo khối lượng (`for ticker, df in stock_dfs.items()`) tích hợp dữ liệu giá và khối lượng giao dịch trung bình 7 ngày, điều chỉnh khối lượng hiện tại để cung cấp phân tích toàn diện hơn.

Hàm `compute_rsi` tính RSI dựa trên giá đóng cửa (close) với chu kỳ 14 ngày. Khối lượng trung bình 7 ngày (`vol_avg7`) và chỉ báo `vol_gt_110avg7` được thêm vào mỗi DataFrame để xác định các ngày có khối lượng vượt 110% trung bình.

Chi tiết về đoạn code để tính chỉ báo kỹ thuật RSI và khối lượng giao dịch (Phụ lục 9)

3.3.2.3. Tạo tín hiệu giao dịch

Tín hiệu giao dịch được tạo dựa trên các điều kiện RSI và khối lượng. Hàm này xác định và đánh giá các điều kiện về RSI kết hợp khối lượng giao dịch quá khứ. Trường hợp nếu không thỏa mãn, ghi nhận "no_condition_met". Kết quả được

lưu vào cột 'cond' của dữ liệu từ ngày thứ 14, sau đó áp dụng cho từng mã chứng khoán trong `\texttt{stock_dfs}`.

Chi tiết đoạn code tạo tín hiệu giao dịch (**Phụ lục 10**)

3.3.3. Xây dựng mô hình

3.3.3.1. Xây dựng dự báo tín hiệu cổ phiếu

Mô hình không đơn thuần đưa ra quyết định “mua” hay “bán”, mà thay vào đó, thực hiện phân loại tín hiệu thành 6 nhóm chính, phản ánh các mức độ hành động đầu tư cụ thể tùy vào sức mạnh của dòng tiền và điều kiện kỹ thuật:

- Mua 30%: Dành cho các cổ phiếu đang trong giai đoạn tích lũy hoặc có dấu hiệu phục hồi ban đầu, cần theo dõi thêm trước khi giải ngân hoàn toàn.
- Mua 50%: Cổ phiếu đã có sự xác nhận dòng tiền mạnh, các tín hiệu kỹ thuật rõ ràng như RSI vượt 50, thanh khoản tăng. Có thể giải ngân mức trung bình để tham gia đà tăng.
- Mua 20%: Giai đoạn hoàn tất 100% tỷ trọng khuyến nghị, cổ phiếu thỏa tất cả điều kiện: dòng tiền vào mạnh, chỉ báo kỹ thuật ủng hộ xu hướng tăng, xác nhận bởi các phiên tăng giá đi kèm thanh khoản cao.

Ngược lại, với các tín hiệu tiêu cực, mô hình cũng phân loại cổ phiếu vào 3 nhóm khuyến nghị bán:

- Bán 30%: Cảnh báo sớm rủi ro khi cổ phiếu mất thanh khoản, RSI giảm mạnh dưới 50, xuất hiện lực cung áp đảo. Nhà đầu tư nên giảm một phần tỷ trọng.
- Bán 50%: Xu hướng điều chỉnh rõ ràng, dòng tiền rút ra mạnh mẽ. Mức giảm tỷ trọng mạnh hơn để tránh rủi ro lớn.
- Bán 20%: Thoát hoàn toàn khỏi vị thế, đặc biệt khi cổ phiếu rơi vào trạng thái quá bán kéo dài, mất hỗ trợ kỹ thuật.

Chi tiết đoạn code gán tỷ trọng để dự báo tín hiệu cổ phiếu (**Phụ lục 11**)

Đoạn mã nhằm gán trọng số cho các khuyến nghị giao dịch dựa trên nội dung chuỗi, hỗ trợ ra quyết định trong phân tích chứng khoán. Hàm này kiểm tra từ khóa trong chuỗi `\texttt{rec}`: trả về 0.3 nếu chứa "30%", 0.5 nếu chứa "50%", và 1.0 nếu

chứa "100%"; ngược lại trả về 0. Kết quả được áp dụng để trích xuất giá trị "Mua/Bán" từ cột 'recommendation'.

Chi tiết đoạn code xây dựng các điều kiện để dự báo tín hiệu mua cổ phiếu **(Phụ lục 12)**.

Chi tiết đoạn code xây dựng các điều kiện để dự báo tín hiệu bán cổ phiếu **(Phụ lục 13)**.

3.3.3.2. Xây dựng danh mục đầu tư

a. Lựa chọn danh mục xem xét

Đoạn code khởi tạo các tổ hợp danh mục đầu tư, lưu trữ tổ hợp 10 cổ phiếu từ top 15 cổ phiếu được mô hình đánh giá tốt nhất trong ngày. Mục tiêu nhằm chuẩn bị dữ liệu và tổ hợp cổ phiếu cho việc tối ưu hóa danh mục đầu tư tiếp theo.

Chi tiết đoạn code lọc cổ phiếu đưa vào danh mục xem xét **(Phụ lục 14)**

b. Tối ưu hóa danh mục

Quá trình này bắt đầu bằng việc tính toán lợi nhuận kỳ vọng của từng cổ phiếu dựa trên dữ liệu lịch sử. Tiếp theo, phân tích mối quan hệ giữa các cổ phiếu thông qua ma trận hiệp phương sai để đo lường mức độ biến động và tương quan lẫn nhau trong danh mục.

Dựa trên hai yếu tố chính là lợi nhuận kỳ vọng và rủi ro, nhà đầu tư sẽ đánh giá hiệu quả của từng tổ hợp tỷ trọng phân bổ danh mục. Mục tiêu là tìm ra danh mục có rủi ro thấp nhất cho một mức lợi nhuận mong muốn, hoặc lợi nhuận cao nhất trong giới hạn rủi ro có thể chấp nhận.

Toàn bộ quá trình tối ưu hóa thường được thực hiện bằng Python với công thức toán học đã trình bày ở lý thuyết Markowitz bên trên. Mô hình sử dụng các thư viện tối ưu hóa để tìm ra tỷ trọng đầu tư phù hợp nhất cho từng thời điểm. Kết quả thu được là một danh mục cổ phiếu với tỷ lệ phân bổ cụ thể, đảm bảo hiệu quả đầu tư theo tiêu chí quản lý rủi ro và tối ưu hóa lợi nhuận.

3.3.4. Kiểm nghiệm mô hình

Để đánh giá hiệu quả của mô hình Random Forest Classifier trong việc tối ưu hóa quản lý danh mục đầu tư, nghiên cứu tiến hành kiểm định mô hình dựa trên các

chỉ số thống kê trong lĩnh vực học máy cụ thể là Accuracy, Precision, Recall và F1 Score. Bên cạnh đó, nhằm đánh giá hiệu quả thực tiễn của danh mục đầu tư được xây dựng từ kết quả mô hình, nghiên cứu sử dụng các chỉ số tài chính phổ biến như Sharpe Ratio và Sortino Ratio, qua đó so sánh hiệu quả giữa danh mục tối ưu theo mô hình và danh mục tham chiếu thị trường.

3.3.4.1. Đánh giá mô hình Random Forest Classifier

Sau khi huấn luyện mô hình với dữ liệu lịch sử cổ phiếu được gán nhãn theo biến động giá và chỉ báo kỹ thuật, mô hình được kiểm tra trên tập dữ liệu kiểm định để đo lường hiệu suất phân loại các tín hiệu mua và bán. Các chỉ số được tính toán như sau:

- Accuracy (Độ chính xác): phản ánh tỷ lệ dự đoán đúng trên tổng số dự đoán, giúp đánh giá độ khái quát tổng thể của mô hình.
- Precision (Độ chính xác của tín hiệu mua/bán): đo lường tỷ lệ dự đoán mua (hoặc bán) đúng trong tổng số dự đoán mua (hoặc bán), đặc biệt quan trọng khi chi phí của việc dự đoán sai là lớn.
- Recall (Khả năng phát hiện đúng): phản ánh tỷ lệ các tín hiệu mua (hoặc bán) thực tế được mô hình phát hiện đúng, có ý nghĩa khi ưu tiên không bỏ sót cơ hội đầu tư.
- F1 Score: là trung bình điều hòa giữa Precision và Recall, cung cấp một chỉ số tổng hợp cân bằng giữa hai yếu tố này.

Việc sử dụng đồng thời các chỉ số trên giúp đảm bảo đánh giá toàn diện hiệu quả mô hình phân loại, tránh hiện tượng "accuracy illusion" khi dữ liệu bị lệch lớp (ví dụ: quá nhiều dữ liệu giữ nguyên hoặc bán).

3.3.4.2. Đánh giá hiệu quả danh mục đầu tư

Để kiểm tra tính vượt trội của mô hình học máy trong ứng dụng thực tiễn, nghiên cứu tiến hành so sánh hiệu suất đầu tư của danh mục được mô hình đề xuất với một danh mục tham chiếu đại diện cho thị trường – cụ thể là chỉ số VN-Index trong cùng giai đoạn năm 2024. Mô hình Random Forest Classifier, với cơ chế phân loại mua/bán cổ phiếu, đưa ra các tín hiệu đầu tư tại các thời điểm khác nhau trong

năm. Dựa trên các tín hiệu này, nhà đầu tư sẽ thay đổi cấu trúc danh mục từ 5 đến 10 lần trong năm, phản ánh tính linh hoạt và khả năng thích ứng của mô hình với sự biến động thị trường.

Hiệu suất của mỗi danh mục đầu tư trong từng giai đoạn được ghi nhận, sau đó lợi nhuận lũy kế cả năm của toàn bộ chiến lược được tính toán để so sánh với danh mục thị trường. Công thức toán học:

$$\text{Cumulative Return} = ((1 + R_1) + (1 + R_2) + (1 + R_3) + \dots + (1 + R_n))^{\frac{1}{n}} - 1$$

Trong đó $R_1, R_2, R_3, \dots, R_n$ lần lượt là tỷ suất sinh lời cho mỗi giai đoạn

Việc sử dụng biểu đồ tăng trưởng tài sản (cumulative wealth chart) – giả định nhà đầu tư bắt đầu với cùng một số vốn tại thời điểm đầu năm – cho phép đánh giá trực quan sự chênh lệch lợi nhuận theo thời gian giữa hai phương án đầu tư. Đường tăng trưởng của danh mục từ mô hình học máy cho thấy sự vượt trội rõ rệt trong các giai đoạn thị trường biến động, trong khi danh mục thị trường chịu ảnh hưởng lớn từ các đợt suy giảm toàn thị trường.

Ngoài lợi nhuận tuyệt đối, nghiên cứu còn đánh giá hiệu quả danh mục dựa trên các chỉ số hiệu suất điều chỉnh rủi ro bao gồm Sharp ratio và Treynor.

Một chỉ số quan trọng khác được xem xét là Maximum Drawdown (MDD) – mức sụt giảm lớn nhất từ đỉnh đến đáy của giá trị danh mục trong năm. Mô hình học máy tỏ ra có lợi thế vượt trội khi danh mục do mô hình tạo ra có MDD thấp hơn danh mục thị trường, phản ánh khả năng bảo toàn vốn tốt hơn trong những thời điểm khó khăn.

Cuối cùng, để đánh giá tính ổn định của lợi nhuận, nghiên cứu phân tích phân phối lợi nhuận của từng danh mục đầu tư trong các kỳ tái cơ cấu. Việc sử dụng biểu đồ hộp (boxplot) cho thấy danh mục mô hình không những có lợi nhuận trung bình cao hơn mà còn phân phối lợi nhuận chặt chẽ hơn, tức là ít biến động hơn so với danh mục thị trường. Điều này chứng minh rằng mô hình không chỉ có khả năng tạo lợi nhuận vượt trội mà còn mang lại tính nhất quán và ổn định trong kết quả đầu tư.

TÓM TẮT CHƯƠNG 3

Chương 3 trình bày phương pháp nghiên cứu nhằm áp dụng mô hình Random Forest Classifier vào quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam giai đoạn 01/01/2024-31/12/2024, thông qua quy trình gồm 7 bước: xác định mục tiêu, thu thập dữ liệu, tiền xử lý, xây dựng và huấn luyện mô hình, đánh giá, ứng dụng và kiểm tra thực tế. Nghiên cứu sử dụng Python trong Google Colab làm công cụ chính để xây dựng mô hình. Quá trình tiền xử lý bao gồm làm sạch dữ liệu, tính toán chỉ báo kỹ thuật như RSI, và tạo tín hiệu giao dịch, trong khi mô hình được xây dựng để phân loại tín hiệu mua/bán và tối ưu hóa danh mục dựa trên lý thuyết Markowitz. Đánh giá hiệu quả được thực hiện qua các chỉ số Accuracy, Precision, Recall, F1 Score, cùng Sharpe Ratio, Treynor Ratio, và MDD so sánh với VN-Index để chứng minh tính vượt trội của mô hình.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

4.1. Mô tả mẫu nghiên cứu

Trong nghiên cứu này, dữ liệu được thu thập từ các cổ phiếu niêm yết trên Sở Giao dịch Chứng khoán TP. Hồ Chí Minh (HOSE) trong khoảng thời gian từ ngày 01/01/2020 đến 31/12/2024, tương ứng với 5 năm dữ liệu giao dịch. Dữ liệu được khai thác ở tần suất hàng ngày, bao gồm cả thông tin thị trường (giá, khối lượng, giá trị giao dịch) và các chỉ báo kỹ thuật được tính toán từ dữ liệu gốc nhằm phục vụ cho quá trình huấn luyện mô hình học máy.

Tổng cộng, bộ dữ liệu ban đầu bao gồm 124,258 dòng dữ liệu, ứng với phiên giao dịch của 404 số lượng cổ phiếu được lựa chọn. Trong nghiên cứu, tác giả chọn lọc một số cổ phiếu tiêu biểu theo các tiêu chí: vốn hóa trên 1000 tỷ Việt Nam Đồng, tính thanh khoản cao, sự ổn định trong suốt giai đoạn nghiên cứu và thuộc các nhóm ngành quan trọng (ngân hàng, bất động sản, sản xuất, dầu khí...).

4.2. Kết quả huấn luyện mô hình

Nghiên cứu này được tác giả thực hiện với quy mô tổng cộng 404 cổ phiếu có vốn hóa trên 1000 tỷ đồng ở 3 sàn HOSE, HNX và UPCOM tính đến thời điểm tháng 12/2024. Từ 404 cổ phiếu trên, tác giả phân vào 19 nhóm ngành (dựa trên cách phân ngành L2 của Fiinpro). Bằng việc thực hiện chạy mô hình đã xây dựng, tác giả sẽ lần lượt trình bày kết quả của việc dự báo sóng ngành, mã cổ phiếu được khuyến nghị và danh mục tối ưu đề xuất trong khoảng thời gian từ 01/01/2024 – 31/12/2024.

4.2.1. Kết quả của dự báo dòng tiền theo ngành

Dựa vào việc đã phân loại các mã cổ phiếu vào từng nhóm ngành cụ thể, tác giả tiến hành xây dựng code với cốt lõi là giao dịch lịch sử của mã cổ phiếu trong quá khứ (giá cổ phiếu, khối lượng giao dịch, tổng khối lượng cung – cầu của cổ phiếu trên thị trường) nhằm mục tiêu xác định được trạng thái dòng tiền của một ngành đang diễn biến như thế nào. Tác giả chia thành 6 trạng thái, bao gồm: Dòng tiền nhen nhóm đổ vào, dòng tiền đang đổ vào, dòng tiền tiếp tục đổ vào; dòng tiền nhen

nhóm thoát ra, dòng tiền đang thoát ra, dòng tiền đã thoát ra. Bằng cách nhập một ngày cụ thể, mô hình sẽ xuất ra được biểu đồ thể hiện được trạng thái dòng tiền.



Hình 4.1. Kết quả dự báo dòng tiền của nhóm ngành tại ngày 03/01/2024 dưới dạng biểu đồ tròn

(Nguồn: Tác giả tự tổng hợp)

--- Trạng Thái Dòng Tiền Theo Ngành ---		
Dòng tiền nhen nhóm đổ vào	Dòng tiền đang đổ vào	Dòng tiền tiếp tục đổ vào
Tài nguyên cơ bản	Bán lẻ	
Hàng và Dịch vụ công nghiệp	Viễn thông	
Điện, nước và Xăng dầu khí đốt		
Thực phẩm và đồ uống		
Hàng cá nhân và Gia dụng		
Hóa chất		
Bất động sản		
Ngân hàng		
Du lịch và giải trí		
Dịch vụ tài chính		
Ô tô và phụ tùng		
Xây dựng và vật liệu		
Y tế		
Dầu khí		
Truyền thông		

Hình 4.2. Kết quả dự báo dòng tiền đổ vào ngành tại ngày 03/01/2024

(Nguồn: Tác giả tự tổng hợp)

Khuyến nghị mua/bán cổ phiếu ngày 2024-01-03:						
Mua 30%	Mua thêm 50%	Mua thêm 20%	Bán 50%	Bán 30%	Bán thêm 20%	
UIC	SWC	VOS	ILB	VTP	VGX	
PVB	IDC	TRA		SFI		
EIB	ACV	SHP		WCS		
LCG	DHC	QNS		MVN		
HT1	VSC	TRA		TCL		
VNP	APH	PC1		TMP		
VGR	TBC			DTK		
PVP	PEG			AST		
GEX	SFC			SFI		
TBD	IDC			NSC		
PLX	VGC			LTG		
POW	HPW			CC1		
BSR	QTP			KOS		
PVD	PVG			AST		
PVB	TDM					
SJD	HHS					
POW	ELC					
...	...					
DXG	CRE					
NVL	DCM					
GVR	DGC					

Hình 4.4. Kết quả khuyến nghị mua/bán cổ phiếu với tỷ trọng cụ thể tại ngày 03/01/2024

(Nguồn: Tác giả tự tổng hợp)

Từ mô hình cho thấy tại ngày giao dịch 03/01/2024 xuất hiện 219 tín hiệu khuyến nghị giao dịch. Trong đó có 218 tín hiệu mua bán. Cụ thể, “Mua 30%” có 129 tín hiệu, “Mua thêm 50%” có 67 tín hiệu, “Mua 20%” có 6 tín hiệu. Ngược lại, “Bán 30%” có 1 tín hiệu, “Bán 50%” có 14 tín hiệu, “Bán 20%” có 1 tín hiệu.

Qua đó, mô hình không chỉ hỗ trợ dự báo xu hướng, mà còn định hướng rõ ràng cách hành động cụ thể với từng cổ phiếu, làm nền tảng cho quá trình xây dựng danh mục đầu tư tối ưu ở bước tiếp theo.


4.2.3. Kết quả tối ưu danh mục đầu tư

Sau khi thực hiện phân tích dòng tiền theo ngành và khuyến nghị mua/bán cổ phiếu, tác giả tiếp tục tiến hành tối ưu hóa danh mục đầu tư bằng cách kết hợp giữa kết quả dự báo và lý thuyết danh mục hiện đại. Dựa trên kết quả phân tích dòng tiền ngành và khuyến nghị cổ phiếu từ mô hình Random Forest, tác giả tiếp tục thực

hiện bước cuối cùng trong chuỗi phân tích: xây dựng một danh mục đầu tư tối ưu gồm 3 cổ phiếu bằng cách áp dụng lý thuyết Markowitz, nhằm đạt được sự cân bằng giữa lợi nhuận kỳ vọng và rủi ro tổng thể của danh mục.

Tiêu chí chọn danh sách top 10 cổ phiếu đưa vào tối ưu hóa danh mục:

- (1) Cổ phiếu thuộc trong danh sách khuyến nghị “Mua 30%” của mô hình tại ngày xét
- (2) Cổ phiếu nằm trong nhóm ngành ghi nhận thu hút được dòng tiền đổ vào (bao gồm “Nhen nhóm đổ vào”, “Đang đổ vào” và “Tiếp tục đổ vào”)
- (3) Chỉ số sức mạnh dòng tiền nội tại (MFI) nằm trong khoảng 60-80



**Hình 4.5. Mô tả ma trận tương quan của top 10 cổ phiếu trong danh mục
xem xét**

(Nguồn: Tác giả tự tổng hợp)

Sau khi lọc ra 10 cổ phiếu có sức mạnh dòng tiền và tín hiệu kỹ thuật tốt nhất tại một thời điểm xác định, tác giả thực hiện tiến hành xây dựng ma trận tương quan giữa các cổ phiếu. Mục đích của bước này là đánh giá mức độ phụ thuộc lẫn nhau giữa các mã, từ đó phục vụ cho quá trình tối ưu danh mục theo lý thuyết Markowitz, nhằm đa dạng hóa rủi ro hiệu quả.

Mỗi ô trong ma trận thể hiện hệ số tương quan giữa hai cổ phiếu, với giá trị dao động từ -1 đến 1. Hệ số tương quan càng gần 1 cho thấy mối quan hệ đồng biến mạnh giữa hai cổ phiếu, trong khi giá trị gần 0 biểu thị mối quan hệ yếu hoặc không có sự liên hệ tuyến tính. Đặc biệt, các hệ số có giá trị âm phản ánh mối tương quan nghịch, tức khi một cổ phiếu tăng thì cổ phiếu còn lại có xu hướng giảm, tuy nhiên trong ma trận này các giá trị âm hầu như không đáng kể. Các cặp cổ phiếu thể hiện tương quan dương mạnh, với hệ số gần 1, bao gồm BCC-DC1 (1.0000), GIL-HT1 (0.3886), HT1-OGC (0.3241), OGC-PGB (0.2152), SHB-SMC (0.3782), và TV1-VGI (0.0917), cho thấy xu hướng đồng pha trong biến động giá giữa các cặp này. Ngược lại, một số cặp cổ phiếu ghi nhận tương quan âm đáng chú ý, chẳng hạn như TV1-BCC (-0.081) và PGB-TV1 (-0.330), phản ánh sự phân hóa trong hành vi giá giữa các cổ phiếu này. Hơn nữa, đa số các cặp khác, chẳng hạn như SMC-VGI (0.03929) hoặc BCC-TV1 (0.0459), có hệ số tương quan thấp, gần 0, điều này ám chỉ tính độc lập tương đối trong sự biến động giá của chúng. Điều này rất quan trọng trong bối cảnh áp dụng lý thuyết Markowitz, bởi mục tiêu chính là lựa chọn các cổ phiếu có mức độ tương quan thấp để xây dựng một danh mục đầu tư hiệu quả về rủi ro – lợi nhuận.

Dựa vào thuật toán đề ra ban đầu, mô hình sẽ chỉ xuất danh mục tối ưu tại những ngày giao dịch thỏa điều kiện. Tổng hợp khoảng thời gian từ 01/01/2024 đến 31/12/2024 mô hình đưa ra tổng cộng 5 danh mục.


Bảng 4.1. Chi tiết về 5 danh mục của mô hình học máy đề xuất

R	startdate	enddate	Stocks	Weight
1	1/3/2024	3/8/2024	TV1, BCC, VGI, SMC, OGC, HT1,	0.0529, 0.0562, 0.0916, 0.0563, 0.0667, 0.0684,

			PGB, GIL, SHB, DC1	0.0935, 0.0566, 0.3221, 0.1357
2	4/24/2024	13/06/2024	RTB, FPT, TMS, HWS, VPI, NAF, BAF, MWG, DTP, SSB	0.1303, 0.0835, 0.2849, 0.0622, 0.1530, 0.0533, 0.0622, 0.0628, 0.0526, 0.0552
3	7/1/2024	7/17/2024	BCF, MWG, TNG, CSV, VPI, DGW, REE, FRT, DTP, HTV	0.2789, 0.1841, 0.0609, 0.0530, 0.0578, 0.1143, 0.0593, 0.0834, 0.0517, 0.0566
4	8/6/2024	9/26/2024	CQN, SBB, BSI, FTS, ORS, BIC, CMF, DNP, IDC, SCG	0.0568, 0.0516, 0.0510, 0.0536, 0.2031, 0.0662, 0.0540, 0.0890, 0.2909, 0.0838
5	11/21/2024	12/27/2024	VIF, DHD, FRT, ND2, TCM, HVN, DHA, KSF, DRG, SWC	0.2176, 0.0605, 0.0534, 0.2672, 0.1019, 0.0533, 0.0629, 0.0621, 0.0520, 0.0691

(Nguồn: Tác giả tự tổng hợp)


4.2.3.1. Đánh giá về lợi nhuận tích lũy (Cumulative Return)



Hình 4.6. Biểu đồ thể hiện lợi nhuận tích lũy của 5 danh mục so với VN-Index trong năm 2024

(Nguồn: Tác giả tự tổng hợp)

Trong quý 1 năm 2024 (tháng 1 đến tháng 3), hiệu suất của danh mục mà mô hình học máy đề xuất (đường màu xanh) và VN-Index (đường màu đen) có xu hướng tăng trưởng tương đối đồng bộ, với hiệu suất tích lũy dao động quanh mức 10%. Thậm chí có những thời điểm, VN-Index cho thấy mức tăng trưởng nhanh hơn một chút. Tuy nhiên, từ khoảng đầu quý 2 (bắt đầu từ tháng 4/2024), danh mục của mô hình học máy bắt đầu thể hiện sự bứt phá rõ rệt, tăng trưởng ổn định hơn so với VN-Index. Đặc biệt, có hai giai đoạn tăng vọt đáng chú ý của danh mục học máy: lần thứ nhất vào khoảng tháng 5-6/2024, đưa hiệu suất lên gần 20%, và lần thứ hai vào khoảng tháng 7-8/2024, đẩy hiệu suất tích lũy lên mức gần 40%. Sự tăng trưởng mạnh mẽ này của Chained Portfolio cho thấy mô hình học máy đã đưa ra các quyết định lựa chọn danh mục nhỏ một cách hiệu quả, liên tục tối ưu hóa lợi nhuận. Trong khi đó, VN-Index chỉ dao động quanh mức 10% và có xu hướng đi ngang hoặc giảm nhẹ trong những tháng cuối năm.




Hình 4.7. Biểu đồ phân tán thể hiện mối quan hệ giữa lợi nhuận kỳ vọng và độ lệch chuẩn của 5 danh mục đầu tư và VN-Index

(Nguồn: Tác giả tự tổng hợp)

Từ biểu đồ cung cấp cái nhìn trực quan về hiệu quả của các danh mục đầu tư

so với chỉ số VN-Index trong năm 2024. VN-Index đạt lợi nhuận kỳ vọng khoảng 12% với độ lệch chuẩn hàng năm khoảng 14%, phản ánh mức tăng trưởng trung bình của thị trường. Trong khi đó, tất cả các danh mục (Portfolio 1 đến 5) đều vượt trội, với lợi nhuận kỳ vọng dao động từ 40% (Portfolio 5) đến 120% (Portfolio 3), cho thấy hiệu quả vượt bậc của chiến lược quản lý danh mục dựa trên mô hình Random Forest Classifier. Độ lệch chuẩn của các danh mục, từ 11% (Portfolio 4) đến 17% (Portfolio 3), nằm trong khoảng 11-19%, tương thích với mức độ rủi ro đã đề cập trước đó, và thường cao hơn hoặc tương đương VN-Index. Portfolio 1 và 2, với lợi nhuận 60-70% và độ lệch chuẩn 15-16%, là lựa chọn cân bằng cho nhà đầu tư trung bình, trong khi Portfolio 3 nổi bật với lợi nhuận cao nhất nhưng đi kèm rủi ro lớn hơn. Nhìn chung, biểu đồ khẳng định ưu thế của các danh mục tối ưu hóa so với thị trường, đặc biệt trong việc cân đối giữa lợi nhuận và rủi ro.

Quan sát chung cho thấy tất cả các danh mục đầu tư đều đạt được mức tăng trưởng tích cực, với lợi nhuận lũy kế dương tại thời điểm kết thúc mỗi giai đoạn đầu tư, trong khi VN-Index chỉ dao động quanh mức trung bình và phần lớn thời gian nằm dưới đường 0, cho thấy hiệu suất thị trường kém hiệu quả trong năm 2024.




Hình 4.8. Biểu đồ trực quan hóa lợi nhuận của từng danh mục và VN-Index trong năm 2024

(Nguồn: Tác giả tự tổng hợp)

Cụ thể, biểu đồ cho thấy hầu hết các danh mục đầu tư đều hoạt động tốt hơn so với VN-Index trong giai đoạn tương ứng. Đặc biệt, Portfolio 1 (đầu năm 2024) có mức tăng trưởng ấn tượng nhất, đạt lợi nhuận tích lũy trên 15% trong khi VN-Index cùng thời điểm vẫn giảm sâu. Portfolio 4 cũng thể hiện hiệu suất vượt trội trong quý 3 với lợi nhuận ổn định và cao hơn chỉ số thị trường. Các danh mục còn lại như Portfolio 2, 3 và 5 đều có mức sinh lời dương và phần lớn nằm trên đường VN-Index, cho thấy khả năng sinh lợi ổn định dù mức chênh lệch không quá lớn.

Đáng chú ý, VN-Index trong hầu hết các giai đoạn hoạt động của danh mục đều có xu hướng giảm hoặc đi ngang, điều này càng nhấn mạnh rằng các danh mục đầu tư được xây dựng bằng mô hình học máy đã giúp nhà đầu tư tránh được rủi ro hệ thống trong các giai đoạn thị trường không thuận lợi.

4.2.3.2. Đánh giá chỉ số Sharpe



Hình 4.9. Biểu đồ trực quan hóa chỉ số Sharpe của 5 danh mục và VN-Index theo từng giai đoạn

(Nguồn: Tác giả tự tổng hợp)

Quan sát biểu đồ cho thấy cả 5 danh mục đều có Sharpe Ratio dương, trong khi đó VN-Index ở tất cả các trường hợp đều có Sharpe Ratio âm, dao động từ -3.31 đến -4.07. Điều này phản ánh rằng trong năm 2024, thị trường chung (đại diện bởi VN-Index) có mức sinh lời không hiệu quả, thậm chí âm sau khi điều chỉnh theo rủi ro. Trái lại, các danh mục đầu tư được xây dựng lại thể hiện sự vượt trội đáng kể,


với Portfolio 3 đạt Sharpe Ratio cao nhất là 8.09, cho thấy đây là danh mục có hiệu suất điều chỉnh rủi ro tốt nhất trong số các lựa chọn.

Ngoài ra, Portfolio 5 và Portfolio 1 cũng đạt Sharpe Ratio lần lượt là 4.48 và 3.99, cho thấy khả năng sinh lời vượt trội so với rủi ro đã nhận. Portfolio 4 có Sharpe Ratio thấp nhất trong nhóm (3.45), nhưng vẫn cao hơn đáng kể so với VN-Index cùng kỳ (-4.04).

4.2.3.3. Đánh giá chỉ số Sortino

Kết quả cho thấy tất cả các danh mục đều có Sortino Ratio dương, phản ánh rằng các danh mục đầu tư đều có mức sinh lợi vượt trội so với rủi ro tiêu cực. Trong khi đó, VN-Index lại ghi nhận Sortino Ratio âm ở tất cả các trường hợp, dao động từ -3.66 đến -7.52. Điều này chỉ ra rằng trong năm 2024, VN-Index không chỉ hoạt động kém hiệu quả về tổng thể, mà phần lớn lợi nhuận của nó bị chi phối bởi rủi ro bất lợi.

Đặc biệt, Portfolio 3 tiếp tục thể hiện hiệu suất vượt trội với Sortino Ratio đạt 26.08 – cao nhất trong toàn bộ danh mục và cao gần gấp 3 lần so với danh mục đứng thứ hai (Portfolio 5 với 9.57). Các Portfolio 2 và 4 lần lượt đạt 7.31 và 7.83, trong khi Portfolio 1 đạt 6.26 – thấp nhất trong nhóm nhưng vẫn cao hơn nhiều so với VN-Index (-7.52).




Hình 4.10. Biểu đồ trực quan hóa chỉ số Sortino của 5 danh mục và VN-Index theo từng giai đoạn

(Nguồn: Tác giả tự tổng hợp)

4.2.3.4. Đánh giá Maximum Drawdown (MDD)

Biểu đồ này trực tiếp thể hiện mức sụt giảm phần trăm lớn nhất mà mỗi danh mục hoặc VN-Index phải chịu từ đỉnh cao nhất xuống đáy thấp nhất trước khi phục hồi. Giá trị MDD càng gần 0 (tức là âm ít hơn) thì càng tốt, vì nó chứng tỏ khả năng bảo toàn vốn hiệu quả hơn trong những giai đoạn thị trường khó khăn.



Hình 4.11. Biểu đồ trực quan hóa Maximum Drawdown của 5 danh mục và VN-Index theo từng giai đoạn

(Nguồn: Tác giả tự tổng hợp)

Kết quả biểu đồ cho thấy rằng tất cả các danh mục đầu tư đều có mức MDD thấp hơn rõ rệt so với VN-Index. Cụ thể, VN-Index ghi nhận mức sụt giảm lớn nhất lên đến -9.91%, trong khi các danh mục đều dao động từ -0.89% đến -4.12%.

Trong số đó, Portfolio 3 tiếp tục nổi bật với mức MDD nhỏ nhất (-0.89%), cho thấy khả năng kiểm soát rủi ro rất hiệu quả trong giai đoạn đầu tư. Đây là dấu hiệu cho thấy danh mục này không chỉ có lợi nhuận cao mà còn có mức độ ổn định tốt. Portfolio 2 và Portfolio 5 cũng ghi nhận mức sụt giảm rất nhỏ, lần lượt là -2.07% và -1.42%, phản ánh khả năng giữ giá trị tài sản tốt hơn nhiều so với thị trường chung.

Ngược lại, VN-Index không những có mức MDD cao nhất mà còn cao hơn từ 1.5 đến 5 lần so với các danh mục. Điều này thể hiện rõ sự biến động mạnh và kém ổn định của thị trường trong năm 2024, và đồng thời khẳng định tính vượt trội về

kiểm soát rủi ro của các danh mục được xây dựng theo mô hình học máy và tối ưu hóa hiện đại.

4.3. Kiểm định nghiên cứu

Nghiên cứu đã triển khai mô hình Random Forest Classifier để dự đoán xu hướng giá cổ phiếu tại thị trường chứng khoán Việt Nam, dựa trên dữ liệu lịch sử giá trị giao dịch và các chỉ báo kỹ thuật. Kết quả đánh giá hiệu suất mô hình được trình bày thông qua báo cáo phân loại (classification report), với hai lớp nhãn: 0 (khuyến nghị bán) và 1 (khuyến nghị mua). Các chỉ số chính bao gồm precision, recall, F1-score và support, cung cấp cơ sở để phân tích chi tiết hiệu quả của mô hình trong bối cảnh nghiên cứu.

	precision	recall	f1-score	support
0	0.71	1.00	0.83	62926
1	1.00	0.58	0.73	61317
accuracy			0.79	124243
macro avg	0.85	0.79	0.78	124243
weighted avg	0.85	0.79	0.78	124243

Hình 4.12. Kết quả kiểm nghiệm mô hình Random Forest Classifier


(Nguồn: Tác giả tự tổng hợp)

Đối với chỉ số precision, lớp 0 (bán) đạt giá trị 0.71, cho thấy 71% các dự đoán là "bán" đều chính xác, trong khi lớp 1 (mua) đạt 1.00, phản ánh khả năng dự đoán hoàn toàn chính xác khi gán nhãn "mua". Giá trị trung bình không trọng số (macro average) là 0.85, và trung bình có trọng số (weighted average) cũng đạt 0.85, thể hiện sự cân bằng hiệu suất giữa hai lớp dựa trên số lượng mẫu. Điều này cho thấy mô hình có độ tin cậy cao khi đưa ra khuyến nghị mua, mặc dù hiệu suất đối với lớp bán vẫn cần được cải thiện.

Về chỉ số recall, lớp 0 (bán) đạt 1.00, nghĩa là mô hình đã phát hiện 100% các trường hợp thực sự là "bán", chứng tỏ khả năng nhận diện tốt đối với lớp này. Ngược lại, lớp 1 (mua) chỉ đạt 0.58, cho thấy mô hình bỏ sót 42% các trường hợp thực sự là "mua", phản ánh hạn chế trong việc nhận diện đầy đủ các cơ hội đầu tư.

Giá trị macro average của recall là 0.79, và weighted average cũng đạt 0.79, phản ánh mức độ bao phủ tổng thể của mô hình trên tập dữ liệu.

Chỉ số F1-score, vốn là sự cân bằng giữa precision và recall, đạt 0.83 cho lớp 0 (bán) và 0.73 cho lớp 1 (mua), thấp hơn do ảnh hưởng từ recall thấp. Giá trị macro average là 0.78 và weighted average là 0.78, phản ánh hiệu suất tổng hợp của mô hình trên cả hai lớp. Bên cạnh đó, độ chính xác tổng thể (accuracy) đạt 0.79 dựa trên 124.243 mẫu, khẳng định khả năng dự đoán đúng 79% tổng số trường hợp trong tập kiểm tra, với sự phân bố tương đối cân bằng giữa hai lớp (62.926 mẫu cho lớp 0 và 61.317 mẫu cho lớp 1).



Hình 4.13. Thống kê kết quả của kiểm nghiệm mô hình

(Nguồn: Tác giả tự tổng hợp)

Kết quả huấn luyện mang lại ý nghĩa quan trọng trong việc ứng dụng mô hình Random Forest Classifier tại thị trường chứng khoán Việt Nam. Với recall đạt 1.00 và F1-score là 0.83, mô hình thể hiện khả năng nhận diện xuất sắc các trường hợp nên bán cổ phiếu, giúp giảm thiểu rủi ro cho nhà đầu tư bằng cách tránh giữ các cổ phiếu có xu hướng giảm giá. Tuy nhiên, recall thấp (0.58) đối với lớp "mua" cho thấy mô hình bỏ sót một số cơ hội đầu tư, dù precision cao (1.00) đảm bảo các khuyến nghị "mua" đều đáng tin cậy.

Độ chính xác tổng thể 0.79, cùng với các chỉ số trung bình (macro avg và weighted avg) dao động từ 0.78 đến 0.85, cho thấy hiệu suất ổn định của mô hình trên tập dữ liệu lớn. Điều này khẳng định tính khả thi của Random Forest Classifier trong việc dự đoán xu hướng giá cổ phiếu, đồng thời tạo cơ sở để tích hợp với lý thuyết Markowitz nhằm xây dựng danh mục đầu tư tối ưu. Cụ thể, mô hình có thể ưu tiên loại bỏ các cổ phiếu có xu hướng giảm giá và lựa chọn các cổ phiếu có khuyến nghị "mua" đáng tin cậy để tính toán tỷ trọng danh mục.

4.4. Thảo luận nghiên cứu

Phần thảo luận này tập trung vào việc phân tích và đánh giá kết quả từ việc ứng dụng mô hình học máy Random Forest Classifier (RFC) trong quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam. Dựa trên quy trình mô hình hóa, bao gồm dự báo sóng ngành, khuyến nghị cổ phiếu theo tỷ trọng phân bổ 30% (cổ phiếu dẫn dắt sóng ngành) - 50% (cổ phiếu ổn định) - 20% (cổ phiếu rủi ro cao), và tối ưu hóa danh mục với 10 cổ phiếu, nghiên cứu đã đạt được những kết quả đáng chú ý trong năm 2024. Cụ thể, danh mục đầu tư từ mô hình mang lại lợi nhuận gần gấp 4 lần so với chỉ số benchmark VN-Index, với độ chính xác dự đoán tổng thể đạt 79%. Những phát hiện này không chỉ khẳng định hiệu quả của RFC trong bối cảnh thị trường Việt Nam mà còn mở ra các góc nhìn sâu hơn về ứng dụng học máy trong quản lý rủi ro và tối ưu hóa lợi nhuận.

Đánh giá tính thực tiễn của mô hình Random Forest Classifier

Kết quả mô hình cho thấy từ 5 danh mục đầu tư tối ưu hóa mà mô hình đưa ra trong năm 2024 đã vượt trội đáng kể so với thị trường chung. Trong năm 2024, VN-Index ghi nhận mức tăng trưởng 12.1%, phản ánh sự phục hồi ổn định của thị trường chứng khoán Việt Nam sau các biến động kinh tế toàn cầu. Trong khi đó, danh mục từ mô hình Random Forest Classifier đạt lợi nhuận gần gấp 4 lần, tương đương khoảng 45.84%, chứng tỏ khả năng dự báo và tối ưu hóa vượt bậc. Sự vượt trội này có thể được giải thích bởi cơ chế ensemble và random forest của mô hình, vốn kết hợp nhiều cây quyết định để giảm thiểu thiên kiến và tăng độ chính xác

trong việc dự báo xu hướng ngành, đặc biệt trong môi trường thị trường mới nổi như Việt Nam với tính biến động cao.

Bên cạnh đó độ lệch chuẩn của từng danh mục cũng duy trì trong khoảng từ 11-19% đảm bảo khả năng kiểm soát rủi ro tốt, cho thấy mức biến động trung bình, phù hợp với đặc điểm của thị trường chứng khoán Việt Nam, nơi chỉ số VN-Index thường có độ lệch chuẩn dao động từ 15-20% trong các giai đoạn tăng trưởng ổn định. Mức độ lệch chuẩn này cũng phản ánh sự cân bằng trong danh mục 10 cổ phiếu được chọn lọc. Việc giới hạn số lượng cổ phiếu giúp giảm thiểu rủi ro đa dạng hóa quá mức, trong khi tỷ trọng phân bổ linh hoạt đảm bảo danh mục không quá phụ thuộc vào các cổ phiếu có biến động cao.

Phân bổ tỷ trọng 30%-50%-20% đã đóng vai trò quan trọng trong việc cân bằng rủi ro và lợi nhuận. Tỷ trọng 30% dành cho cổ phiếu dẫn dắt sóng ngành giúp tận dụng các cơ hội tăng trưởng ngắn hạn, trong khi 50% cổ phiếu ổn định đảm bảo tính bền vững, và 20% cổ phiếu rủi ro cao bổ sung tiềm năng sinh lời cao hơn. Danh mục 10 cổ phiếu được tối ưu hóa không chỉ giảm thiểu đa dạng hóa quá mức mà còn tập trung vào các mã có tương quan thấp, giúp giảm rủi ro hệ thống. Kết quả này phù hợp với lý thuyết danh mục hiện đại của Markowitz, nhưng được nâng cao nhờ học máy để xử lý dữ liệu phi tuyến tính và thời gian thực.

Đánh giá tính chính xác của việc đưa ra quyết định của mô hình

Độ chính xác tổng thể của mô hình đạt 79%, cùng khả năng nhận diện 58% trường hợp thực sự "Mua" với độ chính xác 100% và 100% trường hợp thực sự "Bán" với độ chính xác 71%, mô hình thể hiện hiệu quả đáng kể trong việc đưa ra khuyến nghị giao dịch. Xét trong việc dự báo sóng ngành và khuyến nghị cổ phiếu, đây là mức cao so với các mô hình học máy truyền thống trong dự báo chứng khoán. Random Forest Classifier nổi bật nhờ khả năng xử lý nhiều dữ liệu và các đặc trưng đa chiều (như giá cổ phiếu, khối lượng giao dịch, chỉ số kinh tế vĩ mô), dẫn đến độ chính xác ổn định. Trong bối cảnh thị trường Việt Nam, nơi dữ liệu thường bị ảnh hưởng bởi yếu tố chính sách và biến động địa chính trị, mức 79% cho thấy mô hình có khả năng thích ứng tốt hơn so với các mô hình tuyến tính.

TÓM TẮT CHƯƠNG 4

Chương 4 trình bày kết quả thực nghiệm trong việc xây dựng danh mục đầu tư tối ưu gồm 3 cổ phiếu, dựa trên mô hình Random Forest kết hợp với lý thuyết Markowitz. Các cổ phiếu được lựa chọn từ việc thỏa những điều kiện cụ thể do mô hình đề ra, đồng thời đảm bảo mức độ tương quan thấp nhằm tăng hiệu quả đa dạng hóa và giảm rủi ro hệ thống. Từ đó, mô hình xác định tỷ trọng đầu tư tối ưu sao cho danh mục đạt lợi nhuận kỳ vọng cao nhất với mức rủi ro thấp nhất. Kết quả kiểm nghiệm trong giai đoạn từ 01/01/2024 đến 31/12/2024 cho thấy danh mục tối ưu có hiệu suất vượt trội so với chỉ số VN-Index – đại diện cho danh mục thị trường. Tỷ suất sinh lời của danh mục cao hơn rõ rệt trong khi độ biến động thấp hơn. Điều này khẳng định rằng việc kết hợp mô hình học máy với phương pháp tối ưu hóa hiện đại mang lại hiệu quả thực tiễn trong quản lý danh mục đầu tư. Dựa trên kết quả nghiên cứu này, trong chương 5, tác giả sẽ đưa ra kiến nghị cho các cá nhân, tổ chức nhằm ứng dụng mô hình học máy trong tối ưu quản lý danh mục đầu tư.

CHƯƠNG 5: KẾT LUẬN VÀ MỘT SỐ KHUYẾN NGHỊ

5.1. Kết luận

Nghiên cứu này nhằm mục đích chứng minh được tính hiệu quả và tối ưu của một mô hình học máy trong việc ứng dụng trong quản lý danh mục đầu tư áp dụng tại thị trường chứng khoán Việt Nam giai đoạn 2019-2024. Thông qua việc sử dụng mô hình Random Forest Classifier, nghiên cứu đã thành công trong việc xây dựng một danh mục đầu tư cổ phiếu tối ưu, mang lại lợi nhuận cao nhất, đồng thời kiểm soát được rủi ro và phân bổ tỷ trọng hợp lý giữa các cổ phiếu. Kết quả backtesting cho thấy danh mục đầu tư được xây dựng từ dự đoán của mô hình mang lại lợi nhuận vượt trội so với chỉ số VN-Index, đồng thời duy trì mức rủi ro ở ngưỡng chấp nhận được thông qua các chỉ số như Value at Risk (VaR) và độ biến động (volatility). Việc phân bổ tỷ trọng cổ phiếu trong danh mục dựa trên phương pháp tối ưu hóa của lý thuyết danh mục hiện đại (Modern Portfolio Theory) đã giúp cân bằng giữa lợi nhuận kỳ vọng và rủi ro, phù hợp với các nhà đầu tư có khẩu vị rủi ro khác nhau. Bài nghiên cứu đã trả lời được các câu hỏi nghiên cứu đã đặt ra ở chương 1 và có những kết luận như sau:

Thứ nhất, về nguyên lý hoạt động của mô hình học máy Random Forest Classifier, mô hình này thuộc nhóm các phương pháp học máy theo hướng tập hợp (ensemble learning). Cụ thể, Random Forest là tập hợp của nhiều cây quyết định (decision trees) độc lập, được huấn luyện trên các tập con ngẫu nhiên của dữ liệu ban đầu (theo kỹ thuật bagging). Mỗi cây trong rừng thực hiện việc phân loại dựa trên một tập con các đặc trưng được chọn ngẫu nhiên, góp phần làm giảm phương sai của mô hình và hạn chế tình trạng quá khớp (overfitting). Kết quả cuối cùng của mô hình được xác định bằng cách lấy biểu quyết đa số từ các cây thành phần. Nhờ cấu trúc này, mô hình Random Forest có khả năng xử lý dữ liệu phức tạp, không tuyến tính, và hoạt động hiệu quả trong các bài toán phân loại như lựa chọn cổ phiếu đầu tư.

Thứ hai, qua thực nghiệm trên bộ dữ liệu thị trường chứng khoán Việt Nam (bao gồm các chỉ số tài chính và kỹ thuật của cổ phiếu niêm yết trong giai đoạn

2020–2024), mô hình Random Forest cho thấy khả năng phân loại cổ phiếu có tiềm năng tăng trưởng trong ngắn hạn với độ chính xác và độ nhạy khá cao. Khi so sánh danh mục đầu tư được đề xuất bởi mô hình với danh mục tham chiếu theo chỉ số thị trường (VN-Index), kết quả cho thấy danh mục do mô hình đề xuất có mức sinh lợi kỳ vọng cao hơn, đồng thời kiểm soát rủi ro tốt hơn, thể hiện qua chỉ số Sharpe và mức biến động danh mục (standard deviation). Như vậy, có thể khẳng định mô hình học máy Random Forest Classifier có tiềm năng hỗ trợ tối ưu hóa việc quản lý danh mục đầu tư, đặc biệt trong khía cạnh lựa chọn cổ phiếu phù hợp với mục tiêu sinh lời và kiểm soát rủi ro.

Thứ ba, về xu hướng phát triển của các mô hình học máy trong lĩnh vực tài chính, có thể nhận thấy rằng việc ứng dụng trí tuệ nhân tạo (AI) và học máy (machine learning) đang ngày càng mở rộng, không chỉ giới hạn ở việc phân loại cổ phiếu mà còn bao gồm dự báo giá, phân tích tâm lý thị trường, phát hiện gian lận, và quản trị rủi ro. Trong tương lai, các mô hình học sâu (deep learning), học tăng cường (reinforcement learning), cũng như mô hình kết hợp giữa AI và dữ liệu lớn (big data) sẽ ngày càng đóng vai trò quan trọng trong chiến lược đầu tư. Những cải tiến như học liên tục (continual learning), học có giám sát kết hợp không giám sát (semi-supervised learning), và tích hợp thông tin phi cấu trúc (như tin tức, mạng xã hội) sẽ giúp mô hình hoạt động hiệu quả và gần với thực tiễn hơn trong môi trường thị trường tài chính đầy biến động.

5.2. Khuyến nghị chính sách

Dựa trên kết quả nghiên cứu và thực nghiệm mô hình Random Forest Classifier trong ứng dụng lựa chọn cổ phiếu và xây dựng danh mục đầu tư, đề tài đưa ra các khuyến nghị chính sách cụ thể đối với từng nhóm đối tượng như sau:

5.2.1. Đối với nhà đầu tư cá nhân

Khuyến khích ứng dụng công nghệ trong đầu tư

Nhà đầu tư cá nhân nên tích cực tiếp cận và ứng dụng các mô hình học máy trong việc phân tích và lựa chọn cổ phiếu. Các công cụ như Random Forest

Classifier có thể hỗ trợ sàng lọc cổ phiếu hiệu quả dựa trên dữ liệu định lượng, từ đó giúp nâng cao hiệu quả đầu tư và quản trị rủi ro.

Tăng cường năng lực công nghệ tài chính cá nhân (personal fintech literacy)

Cơ quan chức năng, các tổ chức đào tạo và công ty chứng khoán cần phổ cập kiến thức về tài chính số và phân tích dữ liệu cho nhà đầu tư cá nhân thông qua các khóa học trực tuyến, hội thảo, và nền tảng giao dịch tích hợp AI.

5.2.2. Đối với các doanh nghiệp tài chính, công ty chứng khoán

Đầu tư vào hệ thống phân tích dữ liệu và học máy

Các công ty chứng khoán nên xem xét triển khai các mô hình học máy như Random Forest, XGBoost hay các phương pháp học sâu (Deep Learning) trong hệ thống phân tích và khuyến nghị đầu tư. Việc phát triển các nền tảng robo-advisory có khả năng cá nhân hóa theo nhu cầu khách hàng sẽ giúp tăng sức cạnh tranh trên thị trường.

Tích hợp mô hình học máy vào hệ thống quản trị rủi ro nội bộ

Ngoài mục tiêu sinh lợi, các mô hình học máy còn có khả năng phát hiện tín hiệu bất thường, giúp dự báo rủi ro hệ thống hoặc rủi ro danh mục. Việc tích hợp AI vào công tác kiểm soát rủi ro sẽ giúp doanh nghiệp hoạt động bền vững hơn trong dài hạn.

Hợp tác với các trường đại học và nhóm nghiên cứu

Doanh nghiệp tài chính có thể phối hợp với các cơ sở đào tạo để thực hiện nghiên cứu chung, thử nghiệm mô hình mới và tuyển dụng nguồn nhân lực chất lượng cao trong lĩnh vực khoa học dữ liệu tài chính (financial data science).

5.3. Hạn chế của nghiên cứu

Mặc dù nghiên cứu đã đạt được một số kết quả nhất định trong việc ứng dụng mô hình Random Forest Classifier để dự đoán khuyến nghị mua/bán cổ phiếu và sử dụng lý thuyết Markowitz để xây dựng danh mục đầu tư tối ưu, vẫn tồn tại một số hạn chế cần được ghi nhận như sau:

Hạn chế về dữ liệu

Dữ liệu sử dụng trong nghiên cứu chủ yếu dựa trên lịch sử giá, khối lượng giao dịch và các chỉ báo kỹ thuật từ nguồn dữ liệu của thư viện Vnstock. Tuy nhiên, chất lượng và tính đầy đủ của dữ liệu tại thị trường chứng khoán Việt Nam có thể bị hạn chế do một số cổ phiếu có thanh khoản thấp hoặc thông tin tài chính không được công bố đầy đủ. Điều này có thể ảnh hưởng đến độ chính xác của mô hình dự đoán.

Hạn chế của mô hình Random Forest Classifier

Mặc dù Random Forest Classifier có khả năng xử lý dữ liệu phức tạp và giảm thiểu hiện tượng quá khớp (overfitting), mô hình vẫn có thể bị ảnh hưởng bởi dữ liệu mất cân bằng, đặc biệt trong các giai đoạn thị trường biến động mạnh, khi số lượng cổ phiếu tăng giá chiếm tỷ lệ thấp hơn so với cổ phiếu giảm giá. Các kỹ thuật như SMOTE hoặc trọng số lớp đã được áp dụng, nhưng hiệu quả có thể không đồng đều trên tất cả các cổ phiếu.

Mô hình chủ yếu dựa trên các đặc trưng kỹ thuật và lịch sử giá, chưa xem xét đầy đủ các yếu tố vĩ mô (như lãi suất, lạm phát, chính sách tiền tệ) hoặc các sự kiện bất thường (như khủng hoảng kinh tế, thay đổi chính sách), dẫn đến khả năng dự đoán có thể bị giới hạn trong một số tình huống cụ thể.

Hạn chế của lý thuyết Markowitz trong xây dựng danh mục đầu tư

Lý thuyết Markowitz giả định rằng lợi nhuận và rủi ro của các cổ phiếu tuân theo phân phối chuẩn và các mối quan hệ giữa các cổ phiếu là tuyến tính. Tuy nhiên, thị trường chứng khoán Việt Nam thường có biến động mạnh và không hoàn toàn tuân theo các giả định này, dẫn đến việc tối ưu hóa danh mục có thể không đạt được hiệu quả như kỳ vọng trong thực tế.

Việc lựa chọn danh mục chỉ gồm ba cổ phiếu có thể làm giảm tính đa dạng hóa (diversification), dẫn đến rủi ro tập trung (concentration risk) cao hơn so với các danh mục lớn hơn.

5.4. Hướng nghiên cứu tiếp theo

Trong nghiên cứu này, mô hình Random Forest Classifier đã được ứng dụng để dự đoán xu hướng giá cổ phiếu dựa trên dữ liệu lịch sử và các chỉ báo kỹ thuật,

kết hợp với lý thuyết Markowitz để tối ưu hóa danh mục đầu tư tại thị trường chứng khoán Việt Nam. Tuy nhiên, do một số hạn chế về dữ liệu, phạm vi nghiên cứu và phương pháp tiếp cận, vẫn còn nhiều hướng nghiên cứu tiềm năng để mở rộng và cải thiện hiệu quả của công trình. Các hướng nghiên cứu tiếp theo được đề xuất như sau:

Mở rộng tập dữ liệu và tích hợp các nguồn dữ liệu mới

Nghiên cứu hiện tại chủ yếu dựa vào dữ liệu lịch sử giá cổ phiếu và các chỉ báo kỹ thuật từ một số nguồn hạn chế. Trong tương lai, có thể mở rộng phạm vi dữ liệu bằng cách tích hợp thêm các yếu tố vĩ mô (như lãi suất, tỷ giá hối đoái, chỉ số lạm phát) và dữ liệu vi mô (như báo cáo quản trị doanh nghiệp, tin tức thị trường).

Thử nghiệm các mô hình học máy nâng cao

Mặc dù Random Forest Classifier đã cho thấy hiệu quả trong việc dự đoán xu hướng giá cổ phiếu, các mô hình học máy khác như Gradient Boosting (XGBoost, LightGBM), Support Vector Machine (SVM) hoặc mạng nơ-ron sâu (Deep Neural Networks) có thể được thử nghiệm để so sánh hiệu suất. Đặc biệt, các mô hình học sâu (Deep Learning) như LSTM (Long Short-Term Memory) hoặc Transformer có thể cho ra kết quả chính xác hơn trong việc xử lý dữ liệu chuỗi thời gian với tính chất phi tuyến và biến động cao của thị trường chứng khoán Việt Nam.

Nghiên cứu theo phân khúc thị trường

Thị trường chứng khoán Việt Nam có sự khác biệt giữa các nhóm cổ phiếu (ví dụ: VN30, cổ phiếu mid-cap, small-cap) và các ngành (ngân hàng, bất động sản, sản xuất). Các nghiên cứu tiếp theo có thể tập trung vào việc áp dụng mô hình Random Forest Classifier cho từng phân khúc thị trường hoặc ngành cụ thể, từ đó đưa ra các khuyến nghị đầu tư phù hợp hơn với đặc điểm của từng nhóm cổ phiếu.

TÓM TẮT CHƯƠNG 5

Chương 5 tổng kết kết quả nghiên cứu và đưa ra khuyến nghị về ứng dụng mô hình Random Forest Classifier trong quản lý danh mục đầu tư tại thị trường chứng khoán Việt Nam. Kết luận cho thấy mô hình xây dựng danh mục vượt trội so với VN-Index, kiểm soát rủi ro và tối ưu hóa lợi nhuận. Nghiên cứu khẳng định tiềm năng của Random Forest trong phân loại cổ phiếu và xu hướng phát triển của AI trong tài chính. Tuy nhiên, hạn chế như dữ liệu chưa đầy đủ và giả định tuyến tính được ghi nhận. Khuyến nghị bao gồm nâng cao công nghệ cho nhà đầu tư, đầu tư AI cho công ty chứng khoán, và nghiên cứu thêm với các mô hình học máy khác như LSTM, KNN để cải thiện hiệu quả.

TÀI LIỆU THAM KHẢO

Tài liệu tham khảo tiếng Việt

Bùi Quốc Hoàn, Phạm Thị Hương Huyền (2023). Xây dựng danh mục tối ưu dựa trên phương pháp học máy: Trường hợp thị trường chứng khoán Việt Nam. *Tạp chí Kinh tế và Dự báo số 12*

Tài liệu tham khảo tiếng Anh

Bartram, S. M., Branke, J., Rossi, G. D., and Motahari, M. (2021). Machine learning for active portfolio management. *The Journal of Financial Data Science*, 3, 9-30

C. Strobl, A. Boulesteix, A. Zeileis, T. Hothorn (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8, 1471 – 2105

Kamil, Anton, A., Chin, Y. F., & Kin, K. (2006). Portfolio Analysis Based On Markowitz Model. *Journal of Statistics and Management Systems University Sains Malaysia*, 9, 519-536.

Kobets, V. and Savchenko, S. (2022). Building an optimal investment portfolio with python machine learning tools. *CEUR Workshop Proceedings*.

Cervello-Royo, R. and Guijarro, F. (2020). Forecasting stock market trend: A comparison of machine learning algorithms. *Finance, Markets and Valuation*, 6, 37-49

Loc, T. D. (2014). Factors affecting stock price change: Evidence from Ho Chi Minh City Stock Exchange. *Scientific Journal of Can Tho University*, 33, 72-78.

Nguyen, M. K. (2013). The relationship between macroeconomic factors and stock market volatility: empirical evidence from the Vietnam stock market. *SCIENCE & TECHNOLOGY DEVELOPMENT* 16.

Nti, I. K., Adekoya, A. F., & Weyori, B. A. (2020). A systematic review of fundamental and technical analysis of stock market predictions. *Artificial Intelligence Review*, 53, 3007-3057

- M. Leung, H. Daouk and A. Chen (2000). Forecasting stock indices: a comparison of classification and level estimation models. *International Journal of Forecasting*, 16, 173–190
- Atsalakis, G.S. and Valavanis, K.P. (2009) Surveying Stock Market Forecasting Techniques—Part II: Soft Computing Methods. *Expert Systems with Applications*, 36, 5932-5941
- Lu, Y. Y., Sun, Y. T., Zhang, Y., & Li, X. G. (2022). The Impact of AI, Machine Learning, Automation and Robotics on the Information Professions-Review and Enlightenment of CILIP Special Symposium in 2021. *Library and Information Work*, 66, 143-152.
- Arash Bahrammirzaee (2010). A Comparative Survey of Artificial Intelligence Applications in Finance: Artificial Neural Networks, Expert System and Hybrid Intelligent Systems. *Neural Comput & Applic.*
- Mercer. (2024). AI in investment management survey. *Mercer*.
- Deloitte. (2022). State of AI in the enterprise 2022 (5th ed.). *Deloitte*.
- Osisanwo, F.Y., Akinsola, J.E.T., Awodele, O., Hinmikaiye, J.O., Olakanmi, O., Akinjobi, J., Supervised Machine Learning Algorithms: Classification and Comparison. *Int. J. Comput. Trends Technol. (IJCTT)*, 48, 128 – 138
- Kelleher, J. D. (2020). Machine learning. *MIT Press*, 79-82
- Khan, A., Sohail, A., Zahoora, U., & Qureshi, A. S. (2020). A survey of the recent architectures of deep convolutional neural networks. *Expert Systems with Applications*
- Yang, H., Li, C., & Yang, X. (2017). Research on machine learning framework based on random forest. *AIP Conference Proceedings*
- S. B. Kotsiantis, P. E. Pintelas, and I. D. Zaharakis (2006). Machine learning: a review of classification and combining techniques. *Artificial Intelligence Rev*, 26, 159–190
- N. Oliveira, P. Cortez and N. Areal (2017). The impact of microblogging data for stock market prediction: Using Twitter to predict returns, volatility, trading

- volume and survey sentiment indices. *Expert Systems with Applications*, 73, 125–144
- R. Entezari-Maleki, A. Rezaei, and B. Minaei-Bidgoli (2009). Comparison of Classification Methods Based on the Type of Attributes and Sample Size. *Journal of Convergence Information Technology*, 4, 94–102
- L. Rokach and O. Maimon (2005). Top-down induction of decision trees classifiers- a survey. *IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews*, 35, 476–487
- B. Henrique, V. Sobreiro and H. Kimura (2019). Literature review: Machine learning techniques applied to financial market prediction. *Expert Systems with Applications*, 124, 226–251

PHỤ LỤC

Phụ lục 1: Drive lưu trữ dữ liệu và mô hình toàn bài nghiên cứu

https://drive.google.com/drive/folders/1oFuXm4w8CJt2l_mMH6SGLhb1rYEVlq2E

Phụ lục 2: Đoạn code mô hình học máy Random Forest Classifier

<https://drive.google.com/file/d/17qlNy3CXmVEKAM4jrgIKCyZGpkUOIYsq/view?usp=sharing>

Phụ lục 3: Chi tiết kết quả tỷ trọng danh mục tối ưu theo chỉ số Sharpe do mô hình học máy đề xuất từ ngày 03/01/2024 – 08/03/2024 (Portfolio 1)

Tỷ trọng danh mục có Sharpe Ratio cao nhất:

	Ticker	Weight (%)
0	TV1	5.29
1	BCC	5.62
2	VGI	9.16
3	SMC	5.63
4	OGC	6.67
5	HT1	6.84
6	PGB	9.35
7	GIL	5.66
8	SHB	32.21
9	DC1	13.56

Phụ lục 4: Chi tiết kết quả tỷ trọng danh mục tối ưu theo chỉ số Sharpe do mô hình học máy đề xuất từ ngày 24/04/2024 – 13/06/2024 (Portfolio 2)

Tỷ trọng danh mục có Sharpe Ratio cao nhất:

	Ticker	Weight (%)
0	RTB	13.03
1	FPT	8.35
2	TMS	28.49
3	HWS	6.22
4	VPI	15.30
5	NAF	5.33
6	BAF	6.22
7	MWG	6.28
8	DTP	5.26
9	SSB	5.52

Phụ lục 5: Chi tiết kết quả tỷ trọng danh mục tối ưu theo chỉ số Sharpe do mô hình học máy đề xuất từ ngày 01/07/2024 – 17/07/2024 (Portfolio 3)

Tỷ trọng danh mục có Sharpe Ratio cao nhất:

	Ticker	Weight (%)
0	BCF	27.89
1	MWG	18.41
2	TNG	6.09
3	CSV	5.30
4	VPI	5.78
5	DGW	11.43
6	REE	5.93
7	FRT	8.34
8	DTP	5.17
9	HTV	5.67

Phụ lục 6: Chi tiết kết quả tỷ trọng danh mục tối ưu theo chỉ số Sharpe do mô hình học máy đề xuất từ ngày 06/08/2024 – 26/09/2024 (Portfolio 4)

Tỷ trọng danh mục có Sharpe Ratio cao nhất:

	Ticker	Weight (%)
0	CQN	5.68
1	SBB	5.16
2	BSI	5.10
3	FTS	5.36
4	ORS	20.31
5	BIC	6.62
6	CMF	5.40
7	DNP	8.90
8	IDC	29.09
9	SCG	8.38

Phụ lục 7: Chi tiết kết quả tỷ trọng danh mục tối ưu theo chỉ số Sharpe do mô hình học máy đề xuất từ ngày 21/11/2024 – 27/12/2024 (Portfolio 5)

Tỷ trọng danh mục có Sharpe Ratio cao nhất:

	Ticker	Weight (%)
0	VIF	21.76
1	DHD	6.05
2	FRT	5.34
3	ND2	26.72
4	TCM	10.19
5	HVN	5.33
6	DHA	6.29
7	KSF	6.21
8	DRG	5.20
9	SWC	6.92

Phụ lục 8: Đoạn code để tải và xử lý dữ liệu

```
# Tạo từ điển lưu DataFrames và thông tin ngành
stock_dfs = {}
sector_info = {}
data_stock_path = '/content/VNStock1/Danh sách cổ phiếu'

# Lặp qua các thư mục ngành và tệp CSV
for sector in os.listdir(data_stock_path):
    sector_path = os.path.join(data_stock_path, sector)
    if os.path.isdir(sector_path):
        for file in os.listdir(sector_path):
            if file.endswith('.csv'):
                ticker = file.replace('.csv', '')
                df = pd.read_csv(os.path.join(sector_path, file))
                df['ticker'] = ticker
                df['time'] = pd.to_datetime(df['time'])
                df['sector'] = sector
                stock_dfs[ticker] = df
                sector_info[ticker] = sector
```

Phụ lục 9. Đoạn code để tính chỉ báo kỹ thuật RSI và khối lượng giao dịch

```
# Hàm tính RSI
def compute_rsi(series, period=14):
    delta = series.diff()
    gain = (delta.where(delta > 0, 0)).rolling(window=period).mean()
    loss = (-delta.where(delta < 0, 0)).rolling(window=period).mean()
    rs = gain / loss
    rsi = 100 - (100 / (1 + rs))
    return rsi

# Tính RSI và khối lượng trung bình
for ticker, df in stock_dfs.items():
    df['rsi'] = compute_rsi(df['close'])
    df['vol_avg7'] = df['volume'].rolling(window=7).mean()
    df['vol_gt_110avg7'] = df['volume'] > 1.1 * df['vol_avg7']
    stock_dfs[ticker] = df
```

Phụ lục 10. Đoạn code tạo tín hiệu giao dịch

```
def generate_conditions(df):
    conds = []
    for i in range(14, len(df)):
        row = df.iloc[i]
        prev = df.iloc[i-1]
        vol_avg_7 = df.iloc[i-7:i]['volume'].mean()
        cond = []
        if row['volume'] > 1.1 * vol_avg_7 and row['rsi'] > 50:
            cond.append("vol>110avg7 & rsi>50")
        if row['rsi'] > 55 and row['rsi'] > prev['rsi']:
            cond.append("rsi>55 & rsi_up")
        if not cond:
            cond.append("no_condition_met")
        conds.append(" & ".join(cond))
    df = df.iloc[14:].copy()
    df['cond'] = conds
    return df

for ticker, df in stock_dfs.items():
    stock_dfs[ticker] = generate_conditions(df)
```

Phụ lục 11. Đoạn code gán tỷ trọng để dự báo tín hiệu cổ phiếu

```
# Gán tỷ trọng và hành động
def get_weight(rec):
    if '30%' in rec:
        return 0.3
    elif '50%' in rec:
        return 0.5
    elif '100%' in rec or 'đề' in rec.lower():
        return 1.0
    else:
        return 0

df['weight'] = df['recommendation'].apply(get_weight)
df['action'] = df['recommendation'].str.extract(r'(Mua|Bán)', expand=False)
```

Phụ lục 12. Đoạn code xây dựng các điều kiện để dự báo tín hiệu mua cổ phiếu

```

# TH1: Buy Signals
if position == 0:
    # Buy 30%
    if (buy_volume_today > 1.05 * buy_volume_avg_7) and (rsi_today > 45) and (rsi_today > rsi_yesterday):
        df.at[today, 'recommendation'] = "Mua 30%"
        position = 30
        buy_price_30 = df['close'].iloc[i]

elif position == 30:
    # Buy additional 50%
    if (buy_volume_t1 > 1.05 * buy_volume_today) and (rsi_t1 > rsi_today):
        df.at[df.index[i + 1], 'recommendation'] = "Mua thêm 50%"
        position = 80
        buy_price_50 = df['close'].iloc[i + 1]
    # Sell 30%
    elif (buy_volume_t1 < 1.05 * buy_volume_today) and (sell_volume_t1 > sell_volume_today) and (rsi_t1 < rsi_today):
        df.at[df.index[i + 1], 'recommendation'] = "Bán 30%"
        position = 0
        buy_price_30 = buy_price_50 = 0

elif position == 80:
    avg_price_prev = (buy_price_30 * 0.3 + buy_price_50 * 0.5) / 0.8
    # Buy additional 20%
    if (buy_volume_t2 > 1.05 * buy_volume_t1) and (rsi_t2 > rsi_t1) and (rsi_t2 > 60) and (avg_price_prev >
        df['close'].iloc[i + 2]):
        df.at[df.index[i + 2], 'recommendation'] = "Mua thêm 20%"
        position = 100
    # Sell 50%
    elif (buy_volume_t2 <= 1.05 * buy_volume_t1) and (sell_volume_t2 > 1.05 * sell_volume_t1) and (rsi_t2 < rsi_t1):
        df.at[df.index[i + 2], 'recommendation'] = "Bán 50%"
        position = 30
    # Sell additional 20%
    elif (buy_volume_t3 <= 1.05 * buy_volume_t2) and (sell_volume_t3 >= 1.05 * sell_volume_t2) and (sell_volume_t3
        <= 1.1 * sell_volume_t2) and (rsi_t3 < rsi_t2):
        df.at[df.index[i + 3], 'recommendation'] = "Bán thêm 20%"
        position = 0
        buy_price_30 = buy_price_50 = 0

```

Phụ lục 13. Đoạn code xây dựng các điều kiện để dự báo tín hiệu bán cổ phiếu

```

# TH2: Sell Signals
elif position == 100:
    # Sell 20%
    if (sell_volume_today > 1.05 * sell_volume_yesterday) and (rsi_today < rsi_yesterday):
        df.at[today, 'recommendation'] = "Bán 20%"
        position = 80
    # Sell 50%
    elif (sell_volume_t1 < 0.95 * sell_volume_today) and (rsi_t1 < rsi_today):
        df.at[df.index[i + 1], 'recommendation'] = "Bán 50%"
        position = 30
    # Sell 30%
    elif (sell_volume_t2 > 1.05 * sell_volume_t1) and (rsi_t2 < rsi_t1):
        df.at[df.index[i + 2], 'recommendation'] = "Bán 30%"
        position = 0
        buy_price_30 = buy_price_50 = 0

```

Phụ lục 14. Đoạn code lọc cổ phiếu đưa vào danh mục xem xét

```

# Tìm danh mục 10 mã tối ưu
danh_muc_size = 10 # Đảm bảo danh mục có đúng 10 mã
combos = list(combinations(top15, danh_muc_size))
print(f"Tạo tổ hợp {danh_muc_size} mã tối ưu từ top 15, tổng cộng {len(combos)} tổ hợp.")

```