

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

ỨNG DỤNG MÔ HÌNH HỌC MÁY TRONG DỰ BÁO KIẾT
QUỆ TÀI CHÍNH CỦA CÁC DOANH NGHIỆP PHI TÀI
CHÍNH NIÊM YẾT TRÊN THỊ TRƯỜNG CHỨNG KHOÁN
VIỆT NAM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG
MÃ SỐ: 7340201

MÃ PHƯƠNG DÂN

TP. HỒ CHÍ MINH, NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO NGÂN HÀNG NHÀ NƯỚC VIỆT NAM
TRƯỜNG ĐẠI HỌC NGÂN HÀNG TP. HỒ CHÍ MINH



KHÓA LUẬN
TỐT NGHIỆP ĐẠI HỌC

ỨNG DỤNG MÔ HÌNH HỌC MÁY TRONG DỰ BÁO KIẾT
QUỆ TÀI CHÍNH CỦA CÁC DOANH NGHIỆP PHI TÀI
CHÍNH NIÊM YẾT TRÊN THỊ TRƯỜNG CHỨNG KHOÁN
VIỆT NAM

NGÀNH: TÀI CHÍNH – NGÂN HÀNG
MÃ SỐ: 7340201

Họ và tên sinh viên: MÃ PHƯƠNG DÂN
Mã số sinh viên: 050609210181
Lớp sinh hoạt: HQ9-GE06

NGƯỜI HƯỚNG DẪN KHOA HỌC
PGS. TS. LÊ HOÀNG ANH
TP. HỒ CHÍ MINH, NĂM 2025

TÓM TẮT

Khóa luận này được thực hiện với mục tiêu xây dựng mô hình dự báo kiệt quệ tài chính cho các doanh nghiệp phi tài chính niêm yết trên thị trường chứng khoán Việt Nam thông qua việc ứng dụng các thuật toán học máy hiện đại. Nghiên cứu sử dụng bộ dữ liệu được thu thập từ 476 doanh nghiệp niêm yết trên hai sàn HOSE và HNX trong giai đoạn 2015 – 2024. Các biến được đưa vào mô hình là sự kết hợp giữa

cả ba nhóm tài chính, thị trường và vĩ mô nhằm tăng cường khả năng dự báo cũng như phản ánh toàn diện thực trạng tài chính của doanh nghiệp. Năm mô hình học máy được triển khai trong nghiên cứu này bao gồm: Hồi quy Logistic, Cây quyết định, Rừng ngẫu nhiên, XGBoost và Mạng nơ-ron nhân tạo (ANN). Kết quả nghiên cứu cho thấy mô hình XGBoost cho kết quả dự báo vượt trội nhất với độ chính xác là 97.07%. Bên cạnh đó, nghiên cứu cũng tìm thấy ba biến đóng vai trò quan trọng trong việc dự báo kiệt quệ tài chính là Tỷ lệ lợi nhuận trước lãi vay và thuế trên tổng tài sản (EBITTA), Tỷ lệ doanh thu trên tổng tài sản (SALESTA) và Tỷ lệ tổng nợ trên tổng tài sản (TLTA). Các biến này lần lượt phản ánh ba khía cạnh tài chính quan trọng của doanh nghiệp về khả năng sinh lời, hiệu suất tài sản và đòn bẩy tài chính.

Từ khóa: kiệt quệ tài chính, dự báo kiệt quệ tài chính, học máy.

ABSTRACT

This research aims to develop a model for predicting financial distress in non-financial companies listed on the Vietnamese stock market by applying machine learning algorithms. The study uses data collected from 476 firms listed on the HOSE and HNX exchanges during the period from 2015 to 2024. The model combines three groups of variables includes financial ratios, market factors and macroeconomic factors to enhance predictive accuracy and provide a comprehensive reflection of firms' financial conditions. Five machine learning models are implemented in this study, including Logistic Regression, Decision Tree, Random Forest, XGBoost and Artificial Neural Network (ANN). The results show that XGBoost deliver the highest predictive performance with accuracies 97.07% respectively. In addition, the study also identifies three key variables that play an important role in predicting financial distress: Earnings before interest and taxes to total assets (EBITTA), Sales to total assets (SALESTA), Total liabilities to total assets (TLTA). These variables represent three core financial dimensions of a firm, namely profitability, asset efficiency and financial leverage.

Keywords: *financial distress, financial distress prediction, machine learning.*

LỜI CAM ĐOAN

Em xin cam đoan rằng khóa luận này là công trình nghiên cứu do chính em thực hiện. Toàn bộ nội dung và kết quả nghiên cứu được trình bày trong khóa luận là trung thực, trong đó không chứa các nội dung từng được công bố trước đây hoặc do người khác thực hiện ngoại trừ các tài liệu được trích dẫn rõ ràng và đầy đủ trong khóa luận.

TP. Hồ Chí Minh, ngày tháng năm 2025

Sinh viên thực hiện

Mã Phương Dân

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu cùng toàn thể quý thầy, cô Trường Đại học Ngân hàng TP. Hồ Chí Minh vì đã tận tình giảng dạy và truyền đạt cho em những kiến thức và kinh nghiệm quý báu trong suốt quá trình học tập tại trường. Chính nhờ sự chỉ dạy tận tình của quý thầy cô mà em có được nền tảng vững chắc để thực hiện và hoàn thành khóa luận tốt nghiệp này.

Hơn hết, em xin bày tỏ lòng biết ơn sâu sắc đến PGS. TS. Lê Hoàng Anh, người đã luôn tận tình hướng dẫn, hỗ trợ và định hướng cho em trong suốt quá trình thực hiện khóa luận. Sự tận tâm, nghiêm túc và những góp ý sâu sắc của thầy là nguồn động lực to lớn giúp em hoàn thiện được khóa luận này.

Bên cạnh đó, em cũng xin gửi lời cảm ơn đến gia đình và bạn bè thân thiết vì đã luôn ở bên và tiếp thêm động lực cho em trong suốt quá trình học tập và thực hiện khóa luận. Sự quan tâm và ủng hộ của mọi người là nguồn sức mạnh tinh thần to lớn giúp em vượt qua những giai đoạn khó khăn.

Vì kiến thức cũng như kinh nghiệm của em còn nhiều hạn chế, khóa luận sẽ không tránh khỏi những thiếu sót. Vì thế, em rất mong nhận được những góp ý quý giá từ quý thầy cô để em có thể tiếp tục hoàn thiện hơn trong những nghiên cứu sau này.

Em xin chân thành cảm ơn!

MỤC LỤC

TÓM TẮT	i
ABSTRACT	ii
LỜI CAM ĐOAN	iii
LỜI CẢM ƠN	iv
MỤC LỤC.....	v
DANH MỤC TỪ VIẾT TẮT	viii
DANH MỤC HÌNH ẢNH VÀ SƠ ĐỒ.....	ix
DANH MỤC BẢNG.....	x
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU	1
1.1 LÝ DO CHỌN ĐỀ TÀI.....	1
1.2 MỤC TIÊU NGHIÊN CỨU	2
1.2.1 Mục tiêu tổng quát.....	2
1.2.2 Mục tiêu cụ thể	2
1.3 CÂU HỎI NGHIÊN CỨU	3
1.4 ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU	3
1.4.1 Đối tượng nghiên cứu	3
1.4.2 Phạm vi nghiên cứu	3
1.5 PHƯƠNG PHÁP NGHIÊN CỨU	3
1.6 ĐÓNG GÓP ĐỀ TÀI.....	4
1.7 BỐ CỤC KHÓA LUẬN TỐT NGHIỆP	4
KẾT LUẬN CHƯƠNG 1.....	6
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN CÁC NGHIÊN CỨU	
TRƯỚC	7
2.1 CƠ SỞ LÝ THUYẾT	7
2.1.1 Khái quát về kiệt quệ tài chính	7
2.1.2 Dấu hiệu nhận diện kiệt quệ tài chính	11
2.1.3 Các yếu tố tác động đến kiệt quệ tài chính	12

2.1.3.1 Các yếu tố bên ngoài doanh nghiệp	12
2.1.3.2 Các yếu tố nội tại doanh nghiệp.....	14
2.1.4 Các phương pháp dự báo kiệt quệ tài chính	14
2.1.4.1 Phương pháp truyền thống	14
2.1.4.2 Phương pháp học máy.....	19
2.2 TỔNG QUAN CÁC NGHIÊN CỨU TRƯỚC	20
2.2.1 Các nghiên cứu quốc tế.....	20
2.2.2 Các nghiên cứu trong nước.....	25
2.3 KHOẢNG TRỐNG NGHIÊN CỨU	29
KẾT LUẬN CHƯƠNG 2.....	30
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU	31
3.1 QUY TRÌNH NGHIÊN CỨU	31
3.2 XÂY DỰNG MÔ HÌNH NGHIÊN CỨU	32
3.2.1 Thu thập và xử lý dữ liệu.....	32
3.2.1.1 Thu thập dữ liệu	32
3.2.1.2 Xử lý dữ liệu	33
3.2.2 Biến nghiên cứu	34
3.2.2.1 Biến phụ thuộc	34
3.2.2.2 Biến độc lập	36
3.2.3 Mô hình nghiên cứu.....	42
3.2.3.1 Mô hình hồi quy Logistic.....	42
3.2.3.2 Mô hình Cây quyết định.....	43
3.2.3.3 Mô hình Rừng ngẫu nhiên	45
3.2.3.4 Mô hình XGBoost.....	45
3.2.3.5 Mô hình mạng nơ-ron nhân tạo.....	47
3.3 PHƯƠNG PHÁP ĐÁNH GIÁ HIỆU QUẢ MÔ HÌNH.....	47
3.4 PHƯƠNG PHÁP ĐÁNH GIÁ CÁC BIẾN ĐẶC TRƯNG QUAN TRỌNG	50
KẾT LUẬN CHƯƠNG 3.....	52
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU	53

4.1 THỐNG KÊ MÔ TẢ CÁC BIẾN	53
4.2 PHÂN TÍCH TƯƠNG QUAN GIỮA CÁC BIẾN.....	56
4.3 KẾT QUẢ MÔ HÌNH	59
4.3.1 Kết quả mô hình hồi quy Logistic	59
4.3.2 Kết quả mô hình Cây quyết định	60
4.3.3 Kết quả mô hình Rừng ngẫu nhiên	62
4.3.4 Kết quả mô hình XGBoost	63
4.3.5 Kết quả mô hình mạng nơ-ron nhân tạo	64
4.3.6 So sánh các mô hình	65
4.4 ĐÁNH GIÁ BIẾN ĐẶC TRƯNG QUAN TRỌNG	68
KẾT LUẬN CHƯƠNG 4.....	71
CHƯƠNG 5: KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ.....	72
5.1 KẾT LUẬN	72
5.2 HÀM Ý QUẢN TRỊ.....	72
5.3 HẠN CHẾ CỦA ĐỀ TÀI VÀ HƯỚNG NGHIÊN CỨU TIẾP THEO	75
5.3.1 Hạn chế của đề tài.....	75
5.3.2 Hướng nghiên cứu tiếp theo	75
KẾT LUẬN CHƯƠNG 5.....	76
TÀI LIỆU THAM KHẢO.....	
PHỤ LỤC.....	

DANH MỤC TỪ VIẾT TẮT

STT	Từ viết tắt	Nguyên nghĩa
1	AUC	Area Under The Curve
2	ANN	Artificial Neural Network
3	DT	Decision Tree
4	DN	Doanh nghiệp
5	EBITDA	Lợi nhuận trước thuế, lãi vay và khấu hao
6	GDP	Tổng sản phẩm quốc nội
7	HDKD	Hoạt động kinh doanh
8	HNX	Sở giao dịch chứng khoán Hà Nội
9	HOSE	Sở giao dịch chứng khoán TP. Hồ Chí Minh
10	KQTC	Kiệt quệ tài chính
11	LR	Logistic Regression
12	RF	Random Forest
13	ROC	Receiver Operating Characteristic
14	SHAP	SHapley Additive exPlanations
15	TS	Tài sản
16	TTCK	Thị trường chứng khoán
17	VCSH	Vốn chủ sở hữu
18	XGB	Extreme Gradient Boosting

DANH MỤC HÌNH ẢNH VÀ SƠ ĐỒ

Danh mục hình

Hình 3. 1 Dữ liệu sau khi được xử lý	33
Hình 3. 2 Dữ liệu trước và sau khi SMOTE	34
Hình 3. 3 Mô hình Decision Tree.....	44
Hình 3. 4 Mô hình Random Forest	45
Hình 3. 5 Mô hình XGBoost	46
Hình 3. 6 Mô hình ANN.....	47
Hình 3. 7 Minh họa bar plot và beeswarm plot.....	51
Hình 4. 1 Kết quả phân tích tương quan các biến	57
Hình 4. 2 Ma trận nhầm lẫn của mô hình Logistic Regression.....	59
Hình 4. 3 Ma trận nhầm lẫn của mô hình Decision Tree	60
Hình 4. 4 Ma trận nhầm lẫn của mô hình Random Forest	62
Hình 4. 5 Ma trận nhầm lẫn của mô hình XGBoost	63
Hình 4. 6 Ma trận nhầm lẫn của mô hình ANN	64
Hình 4. 7 Đường cong ROC của các mô hình	66
Hình 4. 8 Biểu đồ SHAP của mô hình XGBoost	68

Danh mục sơ đồ

Sơ đồ 3. 1 Quy trình nghiên cứu	31
---------------------------------------	----

DANH MỤC BẢNG

Bảng 2. 1 Tổng hợp các nghiên cứu quốc tế.....	24
Bảng 2. 2 Tổng hợp các nghiên cứu trong nước	28
Bảng 3. 1 Số lượng và tỷ trọng hai nhóm doanh nghiệp qua từng năm	35
Bảng 3. 2 Tổng hợp các biến độc lập.....	41
Bảng 3. 3 Cấu trúc ma trận nhàm lẫn.....	48
Bảng 4. 1 Kết quả thống kê mô tả các biến	53
Bảng 4. 2 Kết quả kiểm định VIF	58
Bảng 4. 3 Kết quả dự đoán của mô hình Logistic Regression	60
Bảng 4. 4 Kết quả dự đoán của mô hình Decision Tree.....	61
Bảng 4. 5 Kết quả dự đoán của mô hình Random Forest	62
Bảng 4. 6 Kết quả dự đoán của mô hình XGBoost.....	63
Bảng 4. 7 Kết quả dự đoán của mô hình ANN	64
Bảng 4. 8 Tổng hợp kết quả của các mô hình	65

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI NGHIÊN CỨU

Chương này trình bày những vấn đề cơ bản liên quan đến chủ đề nghiên cứu bao gồm lý do chọn đề tài, mục tiêu nghiên cứu, câu hỏi nghiên cứu, đối tượng và phạm vi nghiên cứu, phương pháp nghiên cứu, đóng góp và bố cục của đề tài.

1.1 LÝ DO CHỌN ĐỀ TÀI

Trong bối cảnh nền kinh tế Việt Nam ngày càng hội nhập và phát triển mạnh mẽ, sự ổn định tài chính của các doanh nghiệp (DN) đóng vai trò then chốt cho sự phát triển bền vững và ổn định của nền kinh tế vĩ mô. Tuy nhiên, thực tế cho thấy sức khỏe tài chính của các doanh nghiệp Việt Nam vẫn còn tiềm ẩn rất nhiều rủi ro. Theo số liệu từ Tổng cục Thống kê, trong năm 2024 có gần 100.1 nghìn DN tạm ngừng kinh doanh có thời hạn (tăng 12.4% so với năm trước đó), gần 76.2 nghìn DN ngừng hoạt động chờ làm thủ tục giải thể (tăng 16.3%) và hơn 21,6 nghìn DN hoàn tất thủ tục giải thể (tăng 20% so với năm 2023). Những con số này cho thấy các DN đang đối mặt với nhiều thách thức nghiêm trọng trong việc duy trì hoạt động. Trên thực tế, trước khi ngừng hoạt động hoặc giải thể, phần lớn các DN đều trải qua giai đoạn kiệt quệ tài chính (KQTC) – giai đoạn mà khả năng thanh toán, dòng tiền và hiệu quả hoạt động suy giảm nghiêm trọng. KQTC không chỉ gây thiệt hại nghiêm trọng đối với chính doanh nghiệp mà còn tác động tiêu cực đến các bên liên quan như nhà đầu tư, chủ nợ, người lao động và đối tác kinh doanh. Về lâu dài, nếu không được kiểm soát, tình trạng này có thể lan rộng và ảnh hưởng đến sự ổn định tài chính và tăng trưởng kinh tế của quốc gia (Wanke và cộng sự, 2015). Trong bối cảnh đó, việc phát hiện kịp thời nguy cơ KQTC của các doanh nghiệp là rất quan trọng, không những giúp cho các nhà và quản lý doanh nghiệp kịp thời phòng ngừa nguy cơ rơi vào tình trạng kiệt quệ tài chính của doanh nghiệp mà còn giúp cho các nhà đầu tư đánh giá được rủi ro khi đầu tư giúp họ phân nào đưa ra quyết định đầu tư đúng đắn hơn.

Dự báo kiệt quệ tài chính là một công cụ quan trọng giúp các bên liên quan nhận diện sớm rủi ro để đưa ra quyết định phù hợp. Tuy chủ đề này đã có nhiều nghiên cứu thực hiện trước đó nhưng chúng vẫn còn tồn tại những hạn chế nhất

định. Trước hết, phần lớn các nghiên cứu đều sử dụng các phương pháp dự báo truyền thống như phân tích phân biệt (MDA), hồi quy logistic hoặc mô hình xác suất tuyến tính. Các phương pháp này tuy dễ áp dụng và dễ diễn giải, nhưng lại tồn tại nhiều hạn chế trong việc xử lý dữ liệu có tính chất phi tuyến, phân phối không chuẩn hoặc có tương quan phức tạp giữa các biến đầu vào. Trong khi đó, các mô hình học máy như cây quyết định, rừng ngẫu nhiên, máy vector hỗ trợ,... đã được chứng minh có khả năng vượt trội trong việc nhận diện các mối quan hệ phi tuyến và khai thác dữ liệu lớn. Những mô hình này ngày càng được ứng dụng rộng rãi trong dự báo tài chính tại các nước phát triển nhờ vào khả năng thích nghi linh hoạt với cấu trúc dữ liệu đa chiều và cải thiện đáng kể độ chính xác dự báo.

Tại Việt Nam, việc ứng dụng học máy trong dự báo KQTC còn ít và chưa được khai thác toàn diện mặc dù tiềm năng của nó là rất lớn trong bối cảnh dữ liệu tài chính từ các doanh nghiệp ngày càng phong phú. Các nghiên cứu trong nước phần lớn vẫn giới hạn ở việc áp dụng đơn lẻ một số mô hình truyền thống mà chưa khai thác nhiều vào các thuật toán học máy hiện đại. Do đó, xuất phát từ thực tiễn và xu hướng nghiên cứu mới, tác giả đã quyết định lựa chọn đề tài “Ứng dụng học máy trong dự báo kiệt quệ tài chính của các doanh nghiệp phi tài chính niêm yết trên thị trường chứng khoán Việt Nam”.

1.2 MỤC TIÊU NGHIÊN CỨU

1.2.1 Mục tiêu tổng quát

Đề tài có mục tiêu tổng quát là ứng dụng học máy để xây dựng mô hình dự báo KQTC phù hợp cho các DN phi tài chính niêm yết trên thị trường chứng khoán (TTCK) Việt Nam. Từ đó, đề xuất các hàm ý quản trị giúp các DN giảm thiểu tình trạng rơi vào kiệt quệ tài chính.

1.2.2 Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát, đề tài có các mục tiêu cụ thể như sau:

Một là, xác định các yếu tố ảnh hưởng đến tình trạng kiệt quệ tài chính để xây dựng các mô hình học máy.

Hai là, so sánh hiệu quả và lựa chọn mô hình học máy phù hợp trong dự báo tình trạng KQTC của các DN phi tài chính niêm yết trên TTCK Việt Nam.

Ba là, từ kết quả nghiên cứu, đưa ra một số hàm ý quản trị để giảm thiểu khả năng kiệt quệ tài chính cho các doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam.

1.3 CÂU HỎI NGHIÊN CỨU

Thứ nhất, các yếu tố nào có tác động đến tình trạng kiệt quệ tài chính của các doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam?

Thứ hai, mô hình học máy nào mang lại hiệu quả dự báo tốt nhất cho các doanh nghiệp phi tài chính niêm yết trên sàn chứng khoán Việt Nam?

Thứ ba, các đề xuất nào nhằm giảm thiểu khả năng rơi vào tình trạng KQTC cho các doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam?

1.4 ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

1.4.1 Đối tượng nghiên cứu

Đề tài nghiên cứu về mô hình dự báo tình trạng kiệt quệ tài chính cho các doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam.

1.4.2 Phạm vi nghiên cứu

Phạm vi không gian: 476 doanh nghiệp phi tài chính được niêm yết trên Sở giao dịch chứng khoán TP. Hồ Chí Minh (HOSE) và Sở giao dịch chứng khoán Hà Nội (HNX).

Phạm vi thời gian: Dữ liệu nghiên cứu được thu thập trong giai đoạn 10 năm từ năm 2015 đến năm 2024. Giai đoạn này được lựa chọn vì giúp nhận diện được các đặc trưng dẫn tới kiệt quệ tài chính trong những điều kiện kinh tế khác nhau. Có thể thấy đây là khoảng thời gian vừa đủ dài để bao quát một chu kỳ kinh tế đồng thời vẫn đảm bảo tính cập nhật và phản ánh nền kinh tế hiện tại, đặc biệt là khi bao gồm cả giai đoạn trước và sau đại dịch Covid-19.

1.5 PHƯƠNG PHÁP NGHIÊN CỨU

Phương pháp nghiên cứu được sử dụng trong bài là phương pháp định lượng sử dụng mô hình học máy để huấn luyện trên dữ liệu đã dán nhãn thông qua Google

Colab bằng ngôn ngữ lập trình Python. Mẫu nghiên cứu được thu thập từ thư viện vnstock bao gồm 476 doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam trong giai đoạn từ năm 2015 đến 2024. Dữ liệu thu thập sẽ được xử lý bằng các kỹ thuật là điền giá trị thiếu, chuẩn hóa dữ liệu và xử lý mất cân bằng dữ liệu. Nghiên cứu này sử dụng kết hợp các mô hình học máy truyền thống và hiện đại để dự báo khả năng kiệt quệ tài chính của doanh nghiệp. Cụ thể, năm thuật toán được áp dụng bao gồm: Hồi quy Logistic (Logistic Regression - LR), Cây quyết định (Decision Tree - DT), Rừng ngẫu nhiên (Random Forest - RF), Extreme Gradient Boosting (XGBoost – XGB) và Mạng nơ-ron nhân tạo (Artificial Neural Network - ANN). Việc so sánh và lựa chọn mô hình dự báo tốt nhất sẽ dựa trên các chỉ số: Accuracy, Precision, Recall, F1-Score, AUC (Area Under the Curve) và đường cong ROC (Receiver Operating Characteristic). Sau khi lựa chọn mô hình phù hợp nhất, nghiên cứu tiếp tục áp dụng phương pháp SHAP (Shapley Additive exPlanations) để xác định độ quan trọng của từng biến đầu vào trong việc đóng góp vào quyết định dự đoán của mô hình.

1.6 ĐÓNG GÓP ĐỀ TÀI

Kết quả nghiên cứu sẽ cung cấp một công cụ hỗ trợ cho các doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam trong việc nhận diện và phát hiện kịp thời tình trạng kiệt quệ tài chính. Đồng thời, đưa ra các hàm ý quản trị giúp các doanh nghiệp trong việc giảm thiểu rủi ro kiệt quệ tài chính.

1.7 BỐ CỤC KHÓA LUẬN TỐT NGHIỆP

Chương 1: Giới thiệu đề tài nghiên cứu

Chương này nhằm xác định bối cảnh và vấn đề nghiên cứu, trình bày lý do chọn đề tài, mục tiêu, câu hỏi nghiên cứu, phạm vi, phương pháp tiếp cận và cấu trúc khóa luận. Nội dung chương giúp định hướng toàn bộ nghiên cứu và làm rõ cơ sở hình thành đề tài.

Chương 2: Cơ sở lý thuyết và tổng quan các nghiên cứu trước

Chương này cung cấp nền tảng lý thuyết về kiệt quệ tài chính, các yếu tố tác động cũng như phương pháp dự báo. Đồng thời qua việc tổng hợp các nghiên cứu

trong và ngoài nước, chương giúp xác định khoảng trống nghiên cứu và cơ sở lý luận cho việc lựa chọn biến và mô hình phân tích.

Chương 3: Phương pháp nghiên cứu

Chương này trình bày quy trình nghiên cứu, cách thức thu thập và xử lý dữ liệu, định nghĩa các biến và mô tả năm mô hình học máy được sử dụng.

Chương 4: Kết quả nghiên cứu

Chương này phản ánh toàn bộ kết quả thực nghiệm, bao gồm thống kê mô tả, phân tích tương quan, hiệu suất của từng mô hình và đánh giá mức độ ảnh hưởng của các biến đầu vào. Nội dung chương cung cấp bằng chứng thực nghiệm làm cơ sở cho kết luận và khuyến nghị.

Chương 5: Kết luận và hàm ý quản trị

Chương này tổng kết các kết quả nghiên cứu và dựa vào đó đề xuất một vài hàm ý quản trị nhằm giảm thiểu rủi ro KQTC của DN. Bên cạnh đó, chương này cũng nêu rõ những hạn chế và đề xuất hướng nghiên cứu tiếp theo.

KẾT LUẬN CHƯƠNG 1

Chương 1 đã trình bày tổng quan về lý do lựa chọn đề tài, tính cấp thiết và vai trò quan trọng của việc dự báo kiệt quệ tài chính đối với các doanh nghiệp phi tài chính trong bối cảnh thị trường Việt Nam hiện nay. Trên cơ sở đó, xác định rõ mục tiêu, câu hỏi nghiên cứu cũng như phạm vi và phương pháp thực hiện đề tài đồng thời nhấn mạnh việc ứng dụng các mô hình học máy để nâng cao độ chính xác và khả năng giải thích trong dự báo. Thông qua việc làm rõ đóng góp của nghiên cứu và bố cục triển khai, chương này đóng vai trò định hướng cho toàn bộ bài nghiên cứu.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ TỔNG QUAN CÁC NGHIÊN CỨU TRƯỚC

Chương này trình bày các nội dung về cơ sở lý thuyết cùng các phương pháp dự báo kiệt quệ tài chính đồng thời lược khảo các nghiên cứu liên quan để tìm ra khoảng trống nghiên cứu.

2.1 CƠ SỞ LÝ THUYẾT

2.1.1 Khái quát về kiệt quệ tài chính

Kiệt quệ tài chính là một thuật ngữ phổ biến trong tài chính doanh nghiệp, đã có nhiều nghiên cứu đưa ra các quan điểm khác nhau về tình trạng này. Một số nghiên cứu trước đây coi tình trạng khó khăn tài chính là đồng nghĩa với thất bại hoặc phá sản (Altman, 1968; Ball & Foster, 1982). Tuy nhiên, các nghiên cứu gần đây chỉ ra rằng KQTC không đồng nhất với phá sản và không phải tất cả các doanh nghiệp gặp khó khăn tài chính đều sẽ phá sản (Gilbert và cộng sự, 1990; He và cộng sự, 2010; Ward & Foster, 1997). Một DN bị rơi vào trạng thái căng thẳng tài chính thì chưa chắc sẽ rơi vào trạng thái phá sản, nhưng một DN phá sản thì chắc chắn sẽ rơi vào trạng thái kiệt quệ tài chính (Platt & Platt, 2006). Tình trạng kiệt quệ tài chính được xem như một tín hiệu cảnh báo sớm về nguy cơ phá sản và nếu không được khắc phục kịp thời sẽ dẫn doanh nghiệp đến con đường phá sản (Husein, 2015).

Theo Wruck (1990), kiệt quệ tài chính là thuật ngữ mô tả tình trạng dòng tiền của doanh nghiệp không đủ để đáp ứng các nghĩa vụ thanh toán hiện tại. Theo nghiên cứu của Andrade và Kaplan (1998), các doanh nghiệp có tỷ lệ đòn bẩy tài chính cao và rơi vào tình trạng vỡ nợ thường sẽ đối mặt với kiệt quệ tài chính trong giai đoạn tiếp theo. Whitaker (1999) nhận định thời điểm doanh nghiệp bắt đầu rơi vào tình trạng KQTC là năm đầu tiên mà dòng tiền hoạt động không đủ để trang trải các khoản nợ dài hạn đáo hạn trong kỳ. Theo Platt và Platt (2002), KQTC được định nghĩa là giai đoạn sau trong quá trình suy thoái của doanh nghiệp, xuất hiện trước khi xảy ra các sự kiện nghiêm trọng hơn như phá sản hoặc thanh lý tài sản (Turetsky & McEwen). Van Gestel và cộng sự (2006) cho rằng một doanh nghiệp

trong tình trạng KQTC thường có sự mất cân đối giữa tài sản và nợ phải trả và gặp khó khăn trong việc tiếp cận nguồn vốn mới và không có khả năng hấp thụ chi phí vốn gia tăng. Trần Ngọc Thơ và cộng sự (2007) định nghĩa kiệt quệ tài chính là tình trạng xảy ra khi doanh nghiệp không thể thực hiện đúng các cam kết thanh toán với chủ nợ hoặc thực hiện một cách khó khăn. Nhìn chung, đây là thuật ngữ mô tả tình trạng doanh nghiệp gặp phải khó khăn nghiêm trọng liên quan đến việc thực hiện các nghĩa vụ tài chính. Tình trạng này có thể dẫn đến phá sản doanh nghiệp nhưng đôi khi nó chỉ phản ánh việc doanh nghiệp đang gặp khó khăn hoặc rắc rối về tài chính.

Theo Altman và Hotchkiss (2010), có bốn khái niệm thường xuyên được đề cập khi nói đến kiệt quệ tài chính, đó là: thất bại (failure), mất khả năng thanh toán (insolvency), vỡ nợ (default) và phá sản (bankruptcy). Tuy đôi khi các khái niệm này được sử dụng thay thế cho nhau, nhưng trên thực tế mỗi khái niệm mang một ý nghĩa cụ thể và phản ánh một mức độ khác nhau trong quá trình KQTC của doanh nghiệp.

Thất bại

Thất bại có thể được hiểu theo “thất bại về mặt kinh tế” hay “thất bại về mặt tài chính”. Andrade và Kaplan (1998) cho rằng cần thiết phải phân biệt giữa thất bại tài chính và thất bại kinh tế. Họ định nghĩa doanh nghiệp vi phạm nghĩa vụ thanh toán nợ là doanh nghiệp thất bại về tài chính, trong khi doanh nghiệp liên tục chịu lỗ từ hoạt động kinh doanh (HDKD) được xem là thất bại về kinh tế.

Altman và Hotchkiss (2010) định nghĩa “thất bại về mặt kinh tế” là tình trạng doanh nghiệp có tỷ suất sinh lời đạt được từ vốn đầu tư liên tục thấp hơn đáng kể so với mức lợi nhuận trung bình của các khoản đầu tư tương tự. Ngoài ra, một số tiêu chí khác cũng được dùng để xác định tình trạng này như doanh thu không đủ để bù chi phí hoặc lợi nhuận liên tục thấp hơn chi phí sử dụng vốn. Tuy nhiên, những dấu hiệu này không đồng nghĩa với việc doanh nghiệp buộc phải dừng hoạt động, việc doanh nghiệp có tiếp tục hay không còn phụ thuộc vào kỳ vọng về lợi nhuận trong tương lai cũng như khả năng doanh nghiệp có thể chi trả các chi phí vận hành thiết

yếu (Gaughan, 2010). Một doanh nghiệp trong tình huống này vẫn có thể tiếp tục hoạt động nếu các nhà đầu tư chấp nhận mức lợi nhuận thấp. Trên thực tế, một doanh nghiệp có thể rơi vào trạng thái “thất bại về mặt kinh tế” trong nhiều năm nhưng vẫn duy trì hoạt động, miễn là không có nợ bắt buộc phải trả ngay hoặc gần như không có nghĩa vụ tài chính mang tính pháp lý nên rất khó để nhận biết được doanh nghiệp rơi vào tình trạng này đang gặp khó khăn tài chính (Altman & Hotchkiss, 2010).

“Thất bại về mặt tài chính” được hiểu là khi dòng tiền của DN không đủ để chi trả các khoản nợ tài chính hiện tại bao gồm các khoản nợ chưa trả cho nhà cung cấp và người lao động, các chi phí từ kiện tụng cũng như việc không thực hiện được các khoản thanh toán gốc hoặc lãi theo hợp đồng vay nợ (Wruck, 1990). Doanh nghiệp có thể không có đủ thanh khoản để thanh toán các khoản nợ ngắn hạn ngay cả khi có giá trị TS lớn hơn nợ phải trả (Gaughan, 2010). Có thể hiểu bên cạnh việc không có khả năng thanh toán nợ thì việc DN gặp khó khăn trong việc trả nợ đúng hạn cũng được coi là thất bại về mặt tài chính. Thế nhưng, thất bại về tài chính không đồng nghĩa với thanh lý hay phá sản doanh nghiệp, nếu dòng tiền vẫn đủ để vượt qua các khoản nợ đến hạn, doanh nghiệp đang rơi vào tình trạng thiếu thanh khoản tạm thời nhưng có thể khắc phục bằng cách sử dụng các nguồn thay thế khác.

Mất khả năng thanh toán

Theo Altman và Hotchkiss (2010), thuật ngữ này có thể hiểu theo hai dạng là mất khả năng thanh toán kỹ thuật (technical insolvency) và mất khả năng thanh toán theo nghĩa phá sản (insolvency in a bankruptcy sense). Wruck (1990) và Ross và cộng sự (2003) phân chia mất khả năng thanh toán thành hai dạng gồm: dựa trên tài sản (stock-based insolvency) và dựa trên dòng tiền (flow-based insolvency).

Mất khả năng thanh toán dựa trên dòng tiền, hay còn gọi là mất khả năng thanh toán kỹ thuật xảy ra khi doanh nghiệp không có đủ tiền mặt hoặc dòng tiền để trả nợ đúng hạn, dù tổng TS có thể vẫn lớn hơn nợ. Mất khả năng thanh toán kỹ thuật có thể chỉ xảy ra tạm thời và có thể khắc phục được, nhưng nó là bước đầu dẫn đến việc doanh nghiệp bị tuyên bố phá sản (Altman & Hotchkiss, 2010).

Mất khả năng thanh toán dựa trên tài sản, tương tự với định nghĩa mất khả năng thanh toán theo nghĩa phá sản theo quan điểm của Altman và Hotchkiss (2010) là tình trạng xảy ra khi tổng giá trị TS của doanh nghiệp thấp hơn tổng số nợ phải trả, tức là DN có giá trị tài sản ròng âm. Đây là một tình trạng nghiêm trọng và thường kéo dài, không dễ khắc phục trong ngắn hạn. So với mất khả năng thanh toán kỹ thuật thường dễ phát hiện, thì tình trạng này cần phải có một quá trình định giá toàn diện, thường chỉ thực hiện khi có ý định thanh lý TS. Loại mất khả năng thanh toán này thường là dấu hiệu sớm cho thấy doanh nghiệp đang có nguy cơ phá sản.

Vỡ nợ

Vỡ nợ được định nghĩa là khi DN không thực hiện đúng các nghĩa vụ tài chính với chủ nợ. Gilson (1990) và Altman và Hotchkiss (2010) phân loại vỡ nợ thành hai dạng: vỡ nợ thanh toán (payment default) và vỡ nợ kỹ thuật (technical default).

Vỡ nợ kỹ thuật xảy ra khi doanh nghiệp vi phạm các điều khoản trong hợp đồng vay, ví dụ như không giữ được tỷ lệ nợ hợp lý hoặc không đủ khả năng thanh toán ngắn hạn. Mặc dù những vi phạm này có thể là lý do bị kiện, nhưng trên thực tế, chúng thường được thương lượng lại và chủ yếu được xem là dấu hiệu cho thấy tình hình tài chính doanh nghiệp đang xấu đi. Hiếm khi những vi phạm kỹ thuật như vậy lại dẫn đến phá sản hoặc vỡ nợ chính thức. Vỡ nợ pháp lý thường xảy ra khi doanh nghiệp không trả được tiền vay hoặc tiền lãi đúng hạn. Tuy nhiên, trong một số trường hợp (ví dụ như vay ngân hàng), đôi khi việc chậm trả vẫn được chấp nhận mà không bị coi là vỡ nợ nếu hai bên tự thỏa thuận.

Điểm khác biệt chính giữa mất khả năng thanh toán và vỡ nợ là DN có thể rơi vào tình trạng mất thanh khoản trong thời gian dài nhưng đến ngày đáo hạn không thể thực hiện được nghĩa vụ nợ mới coi là vỡ nợ. Khi rơi vào tình trạng vỡ nợ, doanh nghiệp vẫn có thể tiếp tục hoạt động và cố gắng đàm phán lại với chủ nợ để tránh bị phá sản gọi là tái cấu trúc trong khủng hoảng (distressed restructuring), nếu hai bên đạt được thỏa thuận trước khi nộp đơn phá sản, thì thủ

tục này được gọi là phá sản theo kế hoạch định sẵn (prepackaged) (Altman & Hotchkiss, 2010).

Phá sản

Phá sản là quá trình pháp lý mà doanh nghiệp buộc phải thực hiện khi không còn khả năng tự khắc phục các vấn đề tài chính. Một dạng phá sản đã đề cập trước đó là khi giá trị ròng của doanh nghiệp âm. Dạng còn lại phổ biến hơn là tuyên bố phá sản chính thức trước tòa án, thường đi kèm với đơn yêu cầu thanh lý tài sản hoặc thực hiện tái cấu trúc (Altman & Hotchkiss, 2010). Trong thực tế, khi rơi vào tình trạng không thể thanh toán các khoản nợ đến hạn và mọi biện pháp tài chính hoặc thương lượng với chủ nợ đều không mang lại hiệu quả, phá sản được xem là giải pháp cuối cùng. Tòa án sẽ xem xét và quyết định áp dụng một trong hai hướng xử lý chính là thanh lý TS để trả nợ hoặc tái cấu trúc lại bộ máy tạo cơ hội phục hồi cho DN. Tuy nhiên, không phải mọi DN nộp đơn phá sản đều có thể tái sinh. Nếu tình hình quá nghiêm trọng và không còn khả năng hồi phục, doanh nghiệp sẽ bị giải thể – tức là chấm dứt hoàn toàn tư cách pháp nhân, mất đi sự tồn tại hợp pháp trên thị trường.

2.1.2 Dấu hiệu nhận diện kiệt quệ tài chính

Doanh nghiệp trong quá trình rơi vào tình trạng kiệt quệ tài chính thường trải qua nhiều giai đoạn, với các đặc điểm và dấu hiệu nhận diện khác nhau theo từng mức độ nghiêm trọng. Việc phân tích các giai đoạn này giúp nhận diện sớm rủi ro tài chính và đưa ra biện pháp ứng phó kịp thời.

Giai đoạn đầu của quá trình kiệt quệ tài chính thường chưa thể hiện rõ rệt nhưng có thể quan sát bởi những thay đổi trong hoạt động kinh doanh và quản trị. Cụ thể, doanh nghiệp có thể bắt đầu ghi nhận sự sụt giảm về doanh thu, lợi nhuận cổ phiếu âm (Opler & Titman, 1994) hoặc thu nhập từ HDKD suy giảm (Whitaker, 1999). Bên cạnh đó là xuất hiện một số biểu hiện phi tài chính như ghi nhận phản ánh tiêu cực từ khách hàng, mất các khách hàng quan trọng và sự trì hoãn trong công bố thông tin tài chính. Ngoài ra, tình trạng thiếu hụt tiền mặt cục bộ cùng với

việc gặp khó khăn trong thu hồi các khoản phải thu cũng là những tín hiệu đầu tiên của việc gặp khó khăn tài chính.

Giai đoạn giữa phản ánh sự suy yếu rõ ràng hơn về mặt tài chính. Doanh nghiệp bắt đầu đối mặt với tình trạng thua lỗ kéo dài, thiếu hụt thanh khoản nghiêm trọng do HDKD không còn tạo ra dòng tiền (Makridakis, 1991). Một số dấu hiệu khác có thể được ghi nhận ở giai đoạn này là cắt giảm hoặc tạm ngừng chi trả cổ tức (Turetsky & McEwen, 2001) hoặc việc bị các nhà cung cấp rút ngắn thời hạn thanh toán (Altman & Hotchkiss, 2010).

Giai đoạn cuối là thời điểm doanh nghiệp rơi vào khủng hoảng tài chính toàn diện. Doanh nghiệp chịu lỗ hoạt động kéo dài, tình trạng thiếu hụt dòng tiền trở nên trầm trọng hơn. Việc vi phạm điều khoản vay diễn ra thường xuyên và không thể khắc phục được bằng các giải pháp tài chính ngắn hạn. Trong nhiều trường hợp, doanh nghiệp buộc phải nộp đơn xin phá sản như một giải pháp cuối cùng (Altman & Hotchkiss, 2010).

2.1.3 Các yếu tố tác động đến kiệt quệ tài chính

Sự thành công hay thất bại của doanh nghiệp chịu ảnh hưởng từ hai nhóm chính gồm các yếu tố bên ngoài và bên trong DN. Các nhóm yếu tố bên ngoài bao gồm những điều kiện nằm ngoài khả năng kiểm soát của nhà quản trị, chẳng hạn như tốc độ tăng trưởng kinh tế, lạm phát,... cùng những biến động trong đặc điểm hoạt động của thị trường có tác động đáng kể đến lợi nhuận và sức mạnh thị trường của doanh nghiệp (Sharma & Mahajan, 1980). Ngược lại, nhóm yếu tố bên trong phản ánh những đặc điểm nội tại của doanh nghiệp và nằm trong tầm kiểm soát quản trị. Theo Wruck (1990), tình trạng kiệt quệ tài chính có thể xuất phát từ khó khăn kinh tế của ngành (nguyên nhân bên ngoài) hoặc từ sự yếu kém trong công tác quản lý (nguyên nhân bên trong).

2.1.3.1 Các yếu tố bên ngoài doanh nghiệp

Yếu tố kinh tế vĩ mô: Những biến động trong môi trường kinh tế như lãi suất, tỷ giá, lạm phát và chính sách tiền tệ có ảnh hưởng trực tiếp đến chi phí vốn và khả năng sinh lời của DN. Chẳng hạn, lãi suất tăng sẽ làm chi phí vay vốn tăng lên

khuyến DN khó mở rộng hoạt động hoặc đầu tư mới. Lạm phát cao không chỉ làm chi phí đầu vào tăng mà còn làm giảm sức mua của người tiêu dùng, khiến doanh thu giảm sút. Đặc biệt, trong các nền kinh tế đang phát triển như Việt Nam, sự biến động chính sách và môi trường tài chính thường tạo thêm rủi ro khó lường cho doanh nghiệp.

Yếu tố ngành: Ngành nghề mà doanh nghiệp hoạt động cũng chứa đựng nhiều rủi ro đặc thù. Những biến động về cung và cầu, xu hướng tiêu dùng thay đổi nhanh, cạnh tranh gay gắt hoặc sự phụ thuộc vào chuỗi cung ứng khiến doanh nghiệp dễ rơi vào khủng hoảng. Ví dụ, nếu nguyên liệu từ nhà cung cấp bị lỗi, sản phẩm đầu ra bị ảnh hưởng, làm giảm doanh số và uy tín. Tương tự, nếu doanh nghiệp có sản phẩm tốt nhưng kênh phân phối yếu, doanh số vẫn giảm dẫn đến thua lỗ.

Yếu tố xã hội và chính trị: Các biến động xã hội như thay đổi hành vi tiêu dùng, tâm lý thị trường tiêu cực, bất ổn chính trị hay mâu thuẫn quốc tế đều có thể tác động bất lợi đến hoạt động doanh nghiệp. Một số sự kiện có tác động mạnh như khủng bố, chiến tranh, hay thay đổi trong luật pháp quốc tế có thể khiến doanh nghiệp mất thị phần hoặc bị tẩy chay.

Yếu tố công nghệ và môi trường tự nhiên: Việc DN chậm thích ứng với công nghệ mới hoặc đầu tư sai vào công nghệ lỗi thời sẽ dẫn đến chi phí cao, sản phẩm kém cạnh tranh. Ngoài ra, sự hao mòn thiết bị, tai nạn máy móc và tác động tiêu cực từ quy trình sản xuất đến môi trường cũng có thể làm tăng rủi ro tài chính. Trong khi đó, rủi ro từ thiên tai như động đất, lũ lụt, dịch bệnh hoặc ô nhiễm môi trường có thể gây ra gián đoạn sản xuất kéo dài, làm tăng chi phí và giảm hiệu quả hoạt động.

Yếu tố pháp lý: Thay đổi trong luật thuế, luật lao động, quy định môi trường hoặc các chính sách hạn chế thương mại có thể tạo ra các chi phí phát sinh bất ngờ hoặc buộc doanh nghiệp phải điều chỉnh lại toàn bộ mô hình hoạt động. Những thay đổi trong các quy định pháp lý có thể làm phát sinh rủi ro tài chính hoặc ảnh hưởng đến danh tiếng doanh nghiệp nếu không tuân thủ đúng.

2.1.3.2 Các yếu tố nội tại doanh nghiệp

Năng lực quản trị yếu kém: Quản trị yếu được xem là nguyên nhân chính dẫn đến thất bại tài chính. Theo Altman và Hotchkiss (1993), hơn 44% các trường hợp doanh nghiệp thất bại có nguyên nhân từ việc thiếu kinh nghiệm, thiếu kiến thức hoặc do năng lực quản lý và vận hành doanh nghiệp yếu kém. Những biểu hiện của quản trị yếu kém có thể bao gồm lập kế hoạch đầu tư không khả thi, sử dụng đòn bẩy tài chính quá mức, kiểm soát chi phí yếu, chính sách tồn kho và thu hồi công nợ kém, không có sản phẩm mới phù hợp hoặc không phối hợp hiệu quả giữa các bộ phận.

Cơ cấu tài chính mất cân đối: Việc sử dụng đòn bẩy tài chính quá cao, phụ thuộc nhiều vào nợ vay nhưng không có nguồn thu ổn định để trả nợ khiến DN dễ rơi vào khủng hoảng thanh khoản. Thiếu vốn chủ sở hữu (VCSH) hoặc không có kế hoạch tài chính hợp lý khiến DN không đủ linh hoạt khi thị trường biến động.

Chu kỳ sống doanh nghiệp: Doanh nghiệp thường trải qua các giai đoạn từ khởi đầu, tăng trưởng, trưởng thành đến suy thoái. Trong giai đoạn khởi đầu, doanh nghiệp thường thiếu kinh nghiệm và vốn, làm tăng rủi ro thất bại. Khi bước vào giai đoạn suy thoái, nếu không kịp thích ứng hoặc tái cấu trúc, khả năng rơi vào kiệt quệ tài chính là rất lớn.

2.1.4 Các phương pháp dự báo kiệt quệ tài chính

2.1.4.1 Phương pháp truyền thống

Thực tiễn nghiên cứu về tình trạng KQTC đã bắt đầu từ những năm 1930, với phương pháp chủ yếu là so sánh trực tiếp các tỷ số tài chính giữa các cặp DN kiệt quệ và không kiệt quệ, tiêu biểu có thể kể đến nghiên cứu của Fitzpatrick (1932). Do hạn chế về kỹ thuật tính toán, các nghiên cứu ban đầu chỉ dừng lại ở việc phân tích sự khác biệt về các chỉ số tài chính giữa hai nhóm doanh nghiệp, qua đó chỉ ra rằng các doanh nghiệp rơi vào tình trạng KQTC thường có tỷ số tài chính yếu hơn đáng kể. Những nghiên cứu này đã đặt nền móng cho việc ứng dụng các tỷ số tài chính trong dự báo phá sản doanh nghiệp. Đến cuối thập niên 1960 và đầu thập niên 1970, lĩnh vực này phát triển mạnh mẽ với sự xuất hiện của các mô hình

định lượng dựa trên phân tích thống kê, tiêu biểu là nghiên cứu của Beaver (1966) và Altman (1968). Từ đó, hàng loạt công trình tiếp nối đã ra đời, mở rộng nghiên cứu dự báo KQTC tại nhiều quốc gia và trở thành chủ đề thu hút sự quan tâm sâu rộng của giới học thuật.

Phân tích phân biệt đơn biến (Beaver, 1966)

Phương pháp phân tích phân biệt đơn biến được tác giả Beaver dùng để xây dựng mô hình nghiên cứu dựa trên dữ liệu từ các công ty gặp thất bại và khỏe mạnh trong giai đoạn từ 1954 đến 1964. Mẫu nghiên cứu các công ty bị thất bại gồm 79 công ty từ 38 ngành nghề khác nhau. Đối với các công ty không bị thất bại, tác giả đã tiến hành phương pháp ghép cặp để lựa chọn, tức là đối với mỗi doanh nghiệp thất bại trong mẫu nghiên cứu, một DN không thất bại có cùng ngành nghề và quy mô tài sản tương đương sẽ được ghép cặp tương ứng.

Mô hình nghiên cứu sử dụng 30 tỷ số tài chính được chia thành 6 nhóm, mỗi nhóm sẽ lấy một chỉ số đại diện để tiến hành phân tích. Sáu tỷ số đại diện bao gồm: tỷ số dòng tiền trên tổng nợ, tỷ số lợi nhuận ròng trên tổng TS, tỷ số tổng nợ trên tổng tài sản, vốn lưu động trên tổng TS, tỷ số thanh toán hiện hành và khoảng thời gian không sử dụng tín dụng (được xác định bằng tỷ lệ tài sản ngắn hạn trừ nợ ngắn hạn trên chi phí hoạt động). Kết quả cho thấy tỷ lệ dòng tiền trên tổng nợ phải trả và tỷ lệ lợi nhuận ròng trên tổng TS lần lượt là hai chỉ số quan trọng nhất trong việc dự đoán các dấu hiệu khi DN gặp khó khăn tài chính, đặc biệt tỷ số dòng tiền hoạt động trên tổng nợ có khả năng dự báo lên đến 87% trước khi DN phá sản 1 năm.

Phương pháp này có ưu điểm là đơn giản và mang lại kết quả khá tốt. Tuy nhiên, dù các kết quả cho thấy tỷ số tài chính có khả năng phân biệt rõ ràng giữa doanh nghiệp phá sản và không phá sản nhưng thiên lệch mẫu có thể xảy ra làm khả năng đánh giá bị thấp hoặc cao hơn so với thực tế.

Mô hình Z-score (Altman, 1968)

Mô hình Z-score là một trong những phương pháp tiên phong và hiệu quả trong việc dự đoán rủi ro phá sản do Edward I. Altman xây dựng vào năm 1968. Mô hình này sử dụng tổ hợp các tỷ số tài chính được chọn lọc kỹ lưỡng và gán trọng số

tương ứng dựa trên phương pháp phân tích phân biệt đa biến (Multiple Discriminant Analysis – MDA).

Altman đã tiến hành nghiên cứu dựa trên mẫu gồm 66 doanh nghiệp sản xuất tại Hoa Kỳ, trong đó có 33 công ty đã phá sản trong những năm từ 1946 – 1965 và 33 công ty vẫn hoạt động bình thường đến năm 1966. Với 22 tỷ số tài chính, ông lựa chọn ra 5 chỉ số đại diện cho các khía cạnh gồm thanh khoản, khả năng sinh lời, đòn bẩy tài chính, giá trị thị trường và hiệu quả hoạt động để xây dựng mô hình có khả năng phân biệt mạnh mẽ giữa các doanh nghiệp có và không có nguy cơ phá sản.

$$\mathbf{Z\text{-}score} = 1.2\mathbf{X1} + 1.4\mathbf{X2} + 3.3\mathbf{X3} + 0.64\mathbf{X4} + 0.999\mathbf{X5} \quad (2.1)$$

Trong đó:

- X1: Vốn lưu động/Tổng TS
- X2: Lợi nhuận giữ lại/Tổng TS
- X3: Lợi nhuận trước thuế và lãi vay/Tổng TS
- X4: Giá trị thị trường vốn chủ sở hữu/Giá trị sổ sách của tổng nợ phải trả
- X5: Doanh thu/Tổng TS

Theo tiêu chí phân loại của mô hình Z-score:

- $Z\text{-}score \geq 2.99$: DN nằm trong vùng an toàn, chưa có nguy cơ phá sản
- $1.81 < Z\text{-}score < 2.99$: DN nằm trong vùng cảnh báo, có thể có nguy cơ phá sản
- $Z\text{-}score \leq 1.81$: DN nằm trong vùng nguy hiểm, nguy cơ phá sản cao

Mô hình phá sản của Altman đã trải qua nhiều lần cải tiến và điều chỉnh nhằm phù hợp với điều kiện thực tiễn và đặc thù của các loại hình doanh nghiệp khác nhau. Năm 2000, ông phát triển Z'-score cho doanh nghiệp sản xuất nhưng chưa niêm yết, bằng cách thay thế giá trị thị trường VCSH bằng giá trị ghi sổ. Năm 2002, ông tiếp tục điều chỉnh mô hình cho các doanh nghiệp phi sản xuất có đặc điểm hoạt động và cấu trúc tài chính khác biệt bằng việc loại bỏ biến thứ năm và vẫn giữ tên mô hình là Z'-score. Đến năm 2006, Altman cùng Edith Hotchkiss đã phát triển mô hình Z'-score điều chỉnh dành riêng cho các doanh nghiệp thuộc

nhóm phi sản xuất tại các thị trường mới nổi phục vụ việc xếp hạng chất lượng trái phiếu doanh nghiệp.

Những phiên bản cải tiến cho thấy mô hình Z-score không mang tính cố định, mà liên tục được tinh chỉnh nhằm tăng độ chính xác và tính linh hoạt khi ứng dụng trong thực tiễn. Đến nay, mô hình này vẫn giữ vai trò là một trong những công cụ tiêu chuẩn trong việc đánh giá rủi ro tài chính và dự báo phá sản doanh nghiệp ở nhiều quốc gia. Các nghiên cứu gần đây tiếp tục ứng dụng hoặc phát triển các mô hình kế thừa từ Z-score cho thấy giá trị bền vững và khả năng thích nghi của mô hình này trong nhiều bối cảnh kinh tế khác nhau.

Mô hình S-score (Springate, 1978)

Mô hình S-score do Gordon L.V. Springate phát triển vào năm 1978 là một phiên bản cải tiến từ mô hình Z-score của Altman (1968). Mục tiêu của mô hình là xác định khả năng mất khả năng thanh toán của doanh nghiệp thông qua việc sử dụng các tỷ số tài chính phản ánh toàn diện tình hình tài chính.

Từ tập hợp ban đầu gồm 19 tỷ số tài chính, Springate đã rút gọn mô hình còn 4 biến quan trọng nhất phản ánh tình hình tài chính của doanh nghiệp để tiến hành phân loại. Các tỷ số được lựa chọn đều đại diện cho các khía cạnh thiết yếu như khả năng sinh lời, thanh khoản, đòn bẩy tài chính và hiệu quả sử dụng tài sản. Springate đã kiểm định mô hình này trên mẫu 40 doanh nghiệp tại Canada với kết quả cho thấy độ chính xác lên tới 92.5% trong việc dự báo tình trạng tài chính của doanh nghiệp. Nhờ vào cấu trúc đơn giản, dễ áp dụng và hiệu quả dự báo cao, mô hình Springate được xem là một công cụ bổ sung hữu ích trong lĩnh vực phân tích rủi ro tài chính, đặc biệt trong bối cảnh dữ liệu hạn chế hoặc cần áp dụng nhanh chóng.

$$\text{S-score} = 1.03X1 + 3.07X2 + 0.66X3 + 0.4X4 \quad (2.2)$$

Trong đó:

- X1: Vốn lưu động / Tổng TS
- X2: Lợi nhuận trước lãi vay và thuế / Tổng TS
- X3: Lợi nhuận trước thuế / Nợ ngắn hạn
- X4: Doanh thu / Tổng TS

Theo mô hình S-score:

- Doanh nghiệp có tài chính ổn định khi S-score $> 0,862$
- Doanh nghiệp đang trong ngưỡng báo động nếu S-score $= 0,862$
- Doanh nghiệp có nguy cơ mất khả năng thanh toán khi S-score $< 0,862$

Mô hình O-score (Ohlson, 1980)

Ohlson (1980) là người tiên phong áp dụng mô hình logistic regression (logit) để xây dựng công cụ ước tính xác suất phá sản của doanh nghiệp dựa trên dữ liệu tài chính. Không giống như phương pháp phân tích phân biệt vốn chỉ phân chia doanh nghiệp thành hai nhóm (có hoặc không gặp khó khăn tài chính), mô hình logit còn ước lượng xác suất xảy ra sự kiện phá sản. Tác giả sử dụng xác suất đầu ra từ mô hình để phân loại doanh nghiệp với giá trị kết quả nằm trong khoảng từ 0 đến 1. Việc phân loại DN dựa trên giá trị tính toán của P (P là xác suất một công ty có nguy cơ phá sản). Nếu $p > 0,5$, công ty được xếp vào loại có khó khăn về tài chính và nếu $p < 0,5$ công ty không có khó khăn về tài chính.

Điểm mạnh của mô hình O-score nằm ở việc loại bỏ giả định phân phối chuẩn và đồng phương sai của các biến độc lập. Kết quả cho thấy mô hình có khả năng dự báo với độ chính xác lên đến hơn 90%. Tác giả đã sử dụng một tập dữ liệu lớn gồm 105 công ty phá sản và 2,058 công ty không phá sản tại Mỹ trong giai đoạn 1970 – 1976. Chín biến số độc lập được đưa vào mô hình là đại diện cho bốn nhóm chỉ tiêu tài chính cơ bản gồm quy mô, cấu trúc tài chính, hiệu suất và khả năng thanh khoản.

$$\begin{aligned} \text{O-score} = & -1.32 - 0.407X_1 + 6.03X_2 - 1.43X_3 + 0.0757X_4 - 2.37X_5 - 1.83X_6 + \\ & 0.285X_7 - 1.72X_8 - 0.521X_9 \end{aligned} \quad (2.3)$$

Trong đó:

- X1: Logarit của tổng TS
- X2: Tổng nợ/ Tổng TS
- X3: Vốn lưu động/ Tổng TS
- X4: Nợ ngắn hạn/ TS ngắn hạn
- X5: Nếu nợ lớn hơn tổng TS có giá trị là 1, nếu ngược lại nhận giá trị 0

- X6: Lợi nhuận ròng/ Tổng TS
- X7: Dòng tiền HDKD/ Tổng nợ
- X8: Nếu lợi nhuận ròng nhỏ hơn 0 trong hai năm thì ghi nhận giá trị là 1, nếu ngược lại thì có giá trị là 0
- X9: Chênh lệch lợi nhuận ròng năm t với năm t - 1/ Tổng của lợi nhuận ròng năm t với năm t - 1

Mô hình X-score (Zmijewski, 1984)

Mô hình X-score là một phiên bản mở rộng từ mô hình Z-score và được phát triển bởi Zmijewski. Không giống như các mô hình phân tích phân biệt hay hồi quy logit, Zmijewski sử dụng phương pháp hồi quy probit nhằm khắc phục một số nhược điểm của hồi quy tuyến tính cổ điển khi biến phụ thuộc có bản chất nhị phân.

Trong nghiên cứu ban đầu, Zmijewski sử dụng mẫu gồm 40 công ty phá sản và 400 công ty đang hoạt động, từ đó phát triển mô hình dựa trên ba biến số chính bao gồm tỷ số thanh khoản, tỷ suất sinh lợi trên tài sản và tỷ lệ đòn bẩy tài chính. Mô hình này được đánh giá cao nhờ khả năng đơn giản hóa các biến tài chính thành một hàm xác suất có thể lượng hóa được mức độ rủi ro kiệt quệ tài chính.

$$\text{X-score} = -4.336 - 4.513X1 + 5.679X2 - 0.004X3 \quad (2.4)$$

Trong đó:

- X1: Lợi nhuận ròng/ Tổng TS
- X2: Tổng nợ/ Tổng TS
- X3: TS ngắn hạn/ Nợ ngắn hạn

Theo tiêu chí phân loại của mô hình X-score, DN đang bị kiệt quệ tài chính nếu X-score > 0, ngược lại có nghĩa là DN đang có tài chính ổn định.

2.1.4.2 Phương pháp học máy

Trong những năm gần đây, học máy (machine learning) đã trở thành một xu hướng nổi bật trong lĩnh vực dự báo tình trạng kiệt quệ tài chính của doanh nghiệp. Không giống như các phương pháp truyền thống vốn chủ yếu dựa trên giả định tuyến tính và yêu cầu phân phối dữ liệu nghiêm ngặt, học máy cho phép mô hình hóa các mối quan hệ phi tuyến tính và phức tạp giữa các biến mà không yêu cầu

hiệu về dữ liệu. Sự phát triển của khoa học tính toán đã thúc đẩy các phương pháp học máy phát triển và được chứng minh là hiệu quả hơn với độ chính xác cao cùng sai số thấp hơn so với các phương pháp truyền thống (Yeh và cộng sự, 2014; Zhao và cộng sự, 2009). Theo Barboza và cộng sự (2017), các mô hình học máy cải thiện trung bình khoảng 10% độ chính xác so với các mô hình thống kê truyền thống.

Các mô hình học máy như Random Forest, Decision Tree, ANN, SVM, XGBoost,... đã được ứng dụng ngày càng phổ biến trong lĩnh vực dự báo tình trạng kiệt quệ tài chính của doanh nghiệp. Xu hướng này không chỉ cho thấy tiềm năng của học máy trong việc xử lý và khai thác dữ liệu tài chính phức tạp mà còn thu hút sự quan tâm mạnh mẽ từ cộng đồng học thuật (Zhang và cộng sự, 2022). Không chỉ phổ biến trong các nghiên cứu quốc tế, học máy cũng đã được ứng dụng tại Việt Nam trong lĩnh vực dự báo KQTC với hiệu suất vượt trội, điển hình là các nghiên cứu của Huỳnh Thị Cẩm Hà và cộng sự (2017), Tran Kim Long và cộng sự (2022) hay Lê Hồng Ngọc và cộng sự (2023). Điều này không chỉ khẳng định vai trò của học máy như một công cụ hỗ trợ ra quyết định hiệu quả, mà còn mở ra cơ hội để tích hợp các công nghệ thông minh vào quản trị DN, đặc biệt trong bối cảnh biến động kinh tế và môi trường kinh doanh ngày càng phức tạp.

2.2 TỔNG QUAN CÁC NGHIÊN CỨU TRƯỚC

2.2.1 Các nghiên cứu quốc tế

Tinoco và Wilson (2013) đã xây dựng mô hình dự báo rủi ro kiệt quệ tài chính và phá sản bằng phương pháp hồi quy logistic theo bảng cho các công ty niêm yết tại Vương quốc Anh. Sử dụng dữ liệu từ 23,218 quan sát từ 3,020 công ty phi tài chính giai đoạn 1980 – 2011, tác giả đã kết hợp ba nhóm biến kế toán, thị trường và chỉ số kinh tế vĩ mô vào mô hình dự báo. Từ 130 biến ban đầu, nghiên cứu đã tiến hành sàng lọc nghiêm ngặt dựa trên lý thuyết và loại trừ các ngoại lệ. Cuối cùng, mô hình đầy đủ sử dụng 10 biến gồm: tỷ lệ dòng tiền từ hoạt động so với tổng nợ phải trả, tỷ lệ tổng nợ trên tổng tài sản, chỉ số thanh khoản, khả năng chi trả lãi vay, lãi suất trái phiếu ngắn hạn đã điều chỉnh theo lạm phát, chỉ số giá bán lẻ, giá cổ phiếu, lợi suất bất thường hàng năm, quy mô doanh nghiệp so với thị trường và tỷ lệ

giữa giá trị vốn hóa thị trường và tổng nợ. Kết quả cho thấy mô hình tích hợp đầy đủ các nhóm biến đạt hiệu suất vượt trội với diện tích dưới đường cong ROC (AUC) lên tới 0.919 tại thời điểm một năm trước khi doanh nghiệp bị KQTC, so với chỉ 0.872 của mô hình chỉ sử dụng biến kế toán. Trong đó, nghiên cứu đã chỉ ra rằng các biến kế toán như khả năng chi trả lãi vay, tỷ lệ nợ trên tổng TS và khả năng tạo dòng tiền từ hoạt động là các chỉ số có sức mạnh phân biệt lớn và có tính ổn định qua thời gian. Đồng thời, các biến thị trường như giá cổ phiếu, lợi suất bất thường và quy mô doanh nghiệp đóng vai trò đặc biệt quan trọng trong việc nâng cao khả năng dự báo.

Nghiên cứu của Kim và Upneja (2014) tập trung vào việc xây dựng mô hình dự báo tình trạng kiệt quệ tài chính của các nhà hàng niêm yết tại Mỹ trong giai đoạn 1988 – 2010, Dữ liệu được thu thập từ 826 quan sát, trong đó có 42 quan sát từ 21 công ty được phân loại là gặp khó khăn tài chính và 784 quan sát còn lại từ 121 công ty được xếp vào nhóm không gặp khó khăn tái chính dựa theo thang đo Zmijewski. Nghiên cứu sử dụng hai phương pháp học máy là cây quyết định (DT) và cây quyết định tăng cường (AdaBoosted DT) với các biến là khả năng sinh lời, thanh khoản, đòn bẩy, hiệu quả hoạt động, tăng trưởng và một số biến bổ sung như EPS, tỷ lệ cổ đông nội bộ và xu hướng giá cổ phiếu. Mô hình AdaBoosted DT đạt độ chính xác tổng thể cao hơn (97.70%) và nhận diện đúng doanh nghiệp gặp khó khăn tài chính tốt hơn (73.81%) so với mô hình DT truyền thống. Kết quả chỉ ra rằng tỷ lệ nợ trên VCSH là yếu tố quan trọng nhất trong việc nhận diện rủi ro tài chính, bên cạnh đó là các yếu tố như hệ số thanh toán hiện hành, biên lợi nhuận ròng, tốc độ tăng trưởng tài sản và VCSH cũng đóng góp nhất định vào kết quả dự báo KQTC.

Taj và cộng sự (2017) đã thực hiện nghiên cứu nhằm so sánh hiệu quả dự báo tình trạng KQTC các DN Pakistan bằng hai phương pháp thống kê truyền thống là phân tích phân biệt đa biến (MDA) và hồi quy Logistic (LRA). Mục tiêu chính của nghiên cứu là xác định các biến tài chính có khả năng dự báo sức khỏe tài chính DN đồng thời đánh giá mô hình nào phù hợp hơn cho các nghiên cứu trong tương lai.

Dữ liệu nghiên cứu bao gồm 56 công ty lành mạnh có vốn hóa thị trường cao nhất và 56 công ty bị vỡ nợ trên sàn giao dịch chứng khoán Karachi (KSE) trong giai đoạn 2005 – 2010. Nghiên cứu kết luận rằng cả hai mô hình MDA và LRA đều có năng lực phân loại tốt, tuy nhiên LRA tỏ ra vượt trội hơn MDA nhờ khả năng giải thích nhiều biến phụ thuộc nhiều hơn (9 so với 6) và đạt độ chính xác dự báo cao hơn (87.1% so với 82.1%). Kết quả phân tích cho thấy các biến có ý nghĩa thống kê trong cả hai mô hình bao gồm: doanh thu trên tổng TS, phải trả người bán và nợ phải trả ngắn hạn trên tổng TS, doanh thu trên TS cố định hữu hình, lợi nhuận trên vốn chủ sở hữu, TS ngắn hạn trên nợ ngắn hạn và lợi nhuận trước thuế và lãi vay trên vốn góp. Ngoài ra, hồi quy Logistic còn phát hiện thêm các biến có ý nghĩa như: doanh thu trên vốn lưu động, vốn lưu động trên nợ dài hạn và vốn lưu động trên tổng tài sản.

Barboza và cộng sự (2017) đã thực hiện nghiên cứu nhằm phát triển các mô hình dự báo phá sản và vỡ nợ cho mục đích quản trị rủi ro tín dụng. Nhóm tác giả đã tiến hành so sánh hiệu quả của tám mô hình phân loại, bao gồm các phương pháp truyền thống như phân tích phân biệt tuyến tính (MDA), hồi quy logistic, mạng nơron nhân tạo và các kỹ thuật học máy hiện đại như máy vector hỗ trợ (SVM), Bagging, Boosting và Random Forest. Dữ liệu nghiên cứu gồm hơn 10,000 quan sát theo năm đến từ 449 công ty được thu thập từ cơ sở dữ liệu Salomon Center và Compustat trong thời gian từ 1985 – 2013 của các công ty Bắc Mỹ. Mô hình dự báo được xây dựng dựa trên năm khía cạnh tài chính cốt lõi trong mô hình Altman (1968) gồm thanh khoản, khả năng sinh lời, năng suất sử dụng TS, đòn bẩy tài chính và hiệu suất quay vòng tài sản. Bên cạnh đó, nghiên cứu đã mở rộng bằng cách bổ sung thêm sáu chỉ số phản ánh hiệu quả tài chính trong ngắn hạn bao gồm: tăng trưởng tổng TS, tăng trưởng doanh thu, tăng trưởng số lượng nhân viên, biên lợi nhuận hoạt động, biến động lợi nhuận trên VCSH và biến động tỷ lệ giá trị thị trường trên giá trị sổ sách. Kết quả nghiên cứu cho thấy các mô hình học máy, đặc biệt là Random Forest có hiệu suất dự báo vượt trội so với các phương pháp thống kê truyền thống. Cụ thể, khi sử dụng đầy đủ 11 biến đầu vào, Random Forest đạt độ

chính xác 87.1% trong khi hồi quy Logistic đạt 76.3% và MDA chỉ đạt 52.2%. Trung bình, các mô hình học máy cải thiện khoảng 10% độ chính xác so với các mô hình truyền thống. Bên cạnh đó, các mô hình Boosting, Bagging và Random Forest đều cho hiệu quả tốt hơn rõ rệt so với SVM, cả về độ chính xác lẫn thời gian huấn luyện mô hình. Kết quả cũng cho thấy rằng khi chỉ sử dụng 5 biến Z-score gốc, hiệu suất dự báo của tất cả các mô hình đều giảm đáng kể. Điều này nhấn mạnh vai trò quan trọng của các biến tài chính mang tính động như tăng trưởng tài sản, doanh thu, lao động hay biến động lợi nhuận trên vốn chủ sở hữu và biến động tỷ lệ giá trị thị trường trên giá trị sổ sách trong việc giúp mô hình học máy nắm bắt xu hướng trước khi doanh nghiệp rơi vào tình trạng phá sản.

Nghiên cứu của Sabela và cộng sự (2018) tiến hành xây dựng mô hình dự báo kiệt quệ tài chính cho các doanh nghiệp niêm yết trên Sở Giao dịch Chứng khoán Johannesburg (JSE) thông qua cách tiếp cận ba giai đoạn. Trong đó, giai đoạn 1 chỉ sử dụng các biến thị trường bao gồm tỷ lệ vốn lưu động trên tổng TS, lợi nhuận trước lãi vay và thuế trên tổng TS, doanh thu trên tổng TS, giá trị vốn hóa thị trường trên tổng nợ, giai đoạn 2 kết hợp thêm các biến thị trường như chỉ số P/E, P/S, giá cổ phiếu trên dòng tiền và ở giai đoạn 3 bổ sung thêm các biến vĩ mô là GDP và tỷ lệ thất nghiệp. Tác giả sử dụng mô hình hồi quy logistic đa thức để phân loại doanh nghiệp thành ba trạng thái: khỏe mạnh, suy giảm và kiệt quệ tài chính. Với mẫu nghiên cứu gồm 100 doanh nghiệp trong giai đoạn 2005 – 2014, kết quả cho thấy mô hình chỉ sử dụng biến kế toán (giai đoạn 1) đạt độ chính xác trung bình 85% và được cải thiện lên 88% khi bổ sung thêm biến thị trường (giai đoạn 2). Tuy nhiên, việc bổ sung các biến vĩ mô trong giai đoạn 3 không mang lại hiệu quả dự báo vượt trội. Trong số các biến được đưa vào mô hình, tỷ lệ vốn lưu động trên tổng TS và tỷ suất lợi nhuận trước lãi vay và thuế trên tổng TS là những biến có ý nghĩa thống kê ổn định và vai trò dự báo mạnh nhất. Tỷ lệ doanh thu trên tổng TS (TOTA) cũng thể hiện tác động tiêu cực đến rủi ro kiệt quệ tài chính, nhưng mức độ ảnh hưởng không ổn định qua các năm và chỉ có ý nghĩa thống kê tại một vài thời điểm. Nghiên cứu nhấn mạnh tầm quan trọng của thanh khoản, khả năng sinh lời và hiệu

quả sử dụng tài sản trong việc xác định rủi ro tài chính đồng thời cho thấy việc kết hợp dữ liệu kế toán với chỉ số thị trường giúp nâng cao hiệu quả dự báo.

Chen và Shen (2020) đã tiến hành xây dựng mô hình dự báo kiệt quệ tài chính cho các công ty niêm yết trên Sở Giao dịch Chứng khoán Đài Loan trong giai đoạn 2012 – 2018 bằng cách kết hợp các kỹ thuật học máy hiện đại. Tác giả sử dụng tổng cộng 20 biến đầu vào, bao gồm 15 biến tài chính và 5 biến phi tài chính trên mẫu gồm 1,048 công ty (262 công ty gặp khó khăn tài chính và 786 công ty bình thường). Nghiên cứu ứng dụng hai phương pháp chọn biến là hồi quy từng bước (Stepwise Regression) để chọn ra 4 biến quan trọng và LASSO để chọn 13 biến quan trọng, sau đó kết hợp với hai thuật toán cây quyết định là CART và Random Forest để xây dựng bốn mô hình dự báo. Trong đó, mô hình LASSO-CART đạt độ chính xác cao nhất (89.74%) khi sử dụng 13 biến quan trọng, bao gồm: tỷ suất lợi nhuận trên VCSH (ROE), tỷ lệ nợ, tỷ lệ dòng tiền từ HDKD trên nợ ngắn hạn, biên lợi nhuận gộp, tỷ lệ vốn dài hạn trên TS cố định, vòng quay khoản phải thu, các tỷ lệ liên quan đến sở hữu và thể chấp cổ phiếu của ban giám đốc và cổ đông lớn, tốc độ tăng trưởng doanh thu, hệ số thanh khoản nhanh và biến kiểm toán bởi Big4.

Bảng 2. 1 Tổng hợp các nghiên cứu quốc tế

Tác giả	Mẫu và phạm vi nghiên cứu	Mô hình	Biến sử dụng	Kết quả
Tinoco và Wilson (2013)	3020 công ty phi tài chính tại Anh (1980–2011)	Logistic Regression	Tài chính, thị trường, vĩ mô	AUC 0.919 (mô hình dùng 3 nhóm biến)
Kim và Upneja (2014)	142 nhà hàng niêm yết tại Mỹ (1988–2010)	DT, AdaBoosted DT	Tài chính, thị trường	Accuracy 97.7% (AdaBoosted DT)
Taj và cộng sự (2017)	112 công ty tại Pakistan (2005–2010)	MDA, Logistic Regression	Tài chính	Accuracy 87.1% (LRA)
Barboza và cộng sự (2017)	449 công ty Bắc Mỹ (1985 – 2013)	MDA, LR, ANN, SVM, RF, Bagging,	Tài chính	Accuracy 87.1% (Asquith và cộng sự)

		Boosting		
Sabela và cộng sự (2018)	100 DN tại Nam Phi (2005 – 2014)	Logistic đa thức	Tài chính, thị trường, vĩ mô	Accuracy 88% (mô hình dùng biến tài chính, thị trường)
Chen và Shen (2020)	1048 DN tại Đài Loan (2012–2018)	LASSO, CART, RF	Tài chính, thị trường	Accuracy 89.74% (LASSO-CART)

Nguồn: Tổng hợp từ tác giả

2.2.2 Các nghiên cứu trong nước

Bình và cộng sự (2018) đã thực hiện nghiên cứu về mô hình dự đoán nguy cơ kiệt quệ tài chính của các doanh nghiệp niêm yết tại Việt Nam trong giai đoạn từ 2003 - 2016 và chia theo hai giai đoạn trước và sau khủng hoảng tài chính toàn cầu. Mẫu nghiên cứu bao gồm 6,735 quan sát từ dữ liệu của 800 công ty được niêm yết trên HOSE và HNX. Tác giả đã sử dụng phương pháp hồi quy logistic với mô hình kết hợp ba nhóm biến bao gồm 4 biến kế toán, 2 biến thị trường và 2 biến vĩ mô. Kết quả cho thấy mô hình sử dụng biến kế toán và vĩ mô đạt hiệu quả tốt nhất với AUC đạt 0.9394. Trong đó, biến Lợi nhuận trước lãi vay và thuế trên tổng TS có tác động tiêu cực mạnh nhất đến khả năng kiệt quệ tài chính, thể hiện hiệu quả sinh lời từ TS là yếu tố cốt lõi để duy trì sự ổn định tài chính. Các biến vốn lưu động trên tổng TS, giá trị sổ sách VCSH trên tổng nợ, lợi nhuận giữ lại trên tổng TS, giá trị vốn hóa thị trường có quan hệ nghịch chiều với xác suất KQTC. Ngược lại, các biến tổng nợ trên tổng vốn, lạm phát và lãi suất tín phiếu kho bạc ngắn hạn có quan hệ cùng chiều với KQTC.

Huỳnh Thị Cẩm Hà và cộng sự (2017) đã tiến hành dự báo KQTC cho các doanh nghiệp Việt Nam bằng mô hình cây phân lớp dựa trên hai thuật toán là C4.5 và AdaBoost. Nghiên cứu sử dụng dữ liệu của 664 công ty phi tài chính được niêm yết trên hai sàn HSX và HNX trong khoảng thời gian từ năm 2009 đến năm 2015. Tổng cộng có 25 chỉ số được đưa vào mô hình và được chia thành 5 nhóm gồm: khả năng thanh toán, cấu trúc vốn và khả năng trả nợ, khả năng sinh lợi, hoạt động, tăng trưởng và các yếu tố phi tài chính như tỷ lệ sở hữu của Hội đồng quản trị, xu hướng

giá cổ phiếu, thu nhập trên mỗi cổ phiếu và thay đổi trong GDP. Kết quả của hai mô hình đều có mức độ dự báo chính xác trên 90% cho thấy việc sử dụng mô hình cây phân lớp cho dự báo KQTC cho các doanh nghiệp tại Việt Nam là hoàn toàn phù hợp, đặc biệt là Adaboost với cả độ chính xác tổng thể (0.9867) lẫn hệ số Kappa (0.9477) đều cao hơn C4.5 (lần lượt là 0.9851 và 0.9414). Ngoài ra, kết quả phân tích từ hai mô hình cũng cho thấy các yếu tố quan trọng nhất trong việc dự báo tình trạng KQTC là Quy mô VCSH, Đòn bẩy tài chính, Khả năng sinh lợi và Khả năng thanh toán.

Phạm Thị Hồng Vân (2018) đã dùng mô hình hồi quy Logit trên dữ liệu bảng gồm 1,512 quan sát từ 189 doanh nghiệp ngành công nghiệp niêm yết tại Việt Nam trong giai đoạn 2009 – 2016 nhằm dự báo xác suất xảy ra tình trạng kiệt quệ tài chính. Tác giả cho rằng doanh nghiệp rơi vào tình trạng KQTC do kết quả kinh doanh năm trước bị thua lỗ nên các biến độc lập được đo lường tại thời điểm trễ một kỳ. Mô hình dự báo đạt độ chính xác trên tổng thể ở mức cao với tỷ lệ là 93.12%. Kết quả nghiên cứu thực nghiệm cho thấy năm biến có ý nghĩa thống kê trong việc giải thích xác suất kiệt quệ tài chính bao gồm: tỷ lệ tiền mặt trên tổng TS, tỷ lệ nợ, hiệu suất sử dụng TS, tỷ lệ lợi nhuận để lại và quy mô doanh nghiệp. Trong đó, tỷ số nợ có tác động cùng chiều với KQTC trong khi các biến còn lại đều có tác động ngược chiều cho thấy vai trò tích cực của khả năng thanh khoản, hiệu quả sử dụng TS, năng lực sinh lời và quy mô trong việc giảm thiểu nguy cơ tài chính. Mặt khác, các biến về giá cổ phiếu, lãi suất trái phiếu chính phủ và tỷ lệ sở hữu của ban giám đốc không có ảnh hưởng đáng kể đến khả năng xảy ra KQTC.

Long và cộng sự (2023) đã thực hiện nghiên cứu so sánh hiệu suất của các mô hình học máy trong dự báo KQTC đồng thời dùng SHAP để xác định các biến đặc trưng có ảnh hưởng lớn đến kết quả dự báo. Nghiên cứu sử dụng tập dữ liệu gồm 3,277 quan sát là dữ liệu tài chính của 436 công ty niêm yết trên các sàn chứng khoán Việt Nam (HOSE, HNX, UPCOM) trong giai đoạn từ 2010 – 2021. Nhóm tác giả đã lựa chọn 25 tỷ số tài chính được kỳ vọng sẽ ảnh hưởng đến khả năng trả nợ của doanh nghiệp làm biến đầu vào cho các mô hình nghiên cứu, các tỷ

số này phản ánh các khía cạnh cốt lõi của doanh nghiệp như rủi ro thanh khoản, rủi ro tài chính, rủi ro kinh doanh, yếu tố thị trường và định giá. Trong bài, các mô hình học máy được triển khai bao gồm: Hồi quy Logistic, SVM, Cây quyết định, Rừng ngẫu nhiên, Mạng nơ-ron nhân tạo và XGBoost. Kết quả cho thấy mô hình XGBoost (Accuracy = 0.9566) và RF (Accuracy = 0.9529) cho ra kết quả dự báo tốt nhất với các giá trị Recall, F1-Score và AUC đều cao hơn so với các mô hình còn lại. Phân tích SHAP được áp dụng cho hai mô hình có hiệu suất tốt nhất cho thấy các biến có ảnh hưởng lớn nhất đến kết quả dự báo bao gồm: nợ dài hạn trên VCSH, các khoản phải trả trên VCSH, giá trị doanh nghiệp trên doanh thu và EPS pha loãng.

Nguyễn Thị Kim Oanh (2023) đã sử dụng hồi quy Logistic để dự báo kiệt quệ tài chính cho các doanh nghiệp niêm yết ngành khai khoáng tại Việt Nam. Dữ liệu trong bài là dữ liệu thứ cấp được lấy từ báo cáo tài chính của 26 công ty niêm yết trên HOSE và HNX trong giai đoạn từ 2012 đến năm 2021. Nghiên cứu sử dụng 3 mô hình nghiên cứu gồm: mô hình dùng tỷ số tài chính, mô hình dùng yếu tố vĩ mô, mô hình kết hợp yếu tố tài chính và vĩ mô. Cả ba mô hình đều có kết quả dự báo trung bình đạt trên 90% nhưng mô hình phù hợp nhất cho dự báo KQTC là mô hình kết hợp tỷ số tài chính và vĩ mô với hiệu suất cao nhất đạt 98.82% và thông số AIC thấp nhất đạt 0.153. Các biến có mối quan hệ nghịch chiều với khả năng KQTC bao gồm: thu nhập ròng trên TS, thay đổi thu nhập ròng, tỷ lệ dòng tiền thuần hoạt động trên nợ phải trả và tăng trưởng GDP. Trong khi đó, tỷ lệ nợ ngắn hạn trên TS ngắn hạn và tỷ lệ lạm phát lại có mối tương quan thuận chiều với rủi ro kiệt quệ.

Nghiên cứu của Thao và cộng sự (2023) đã thực hiện đánh giá tình trạng kiệt quệ tài chính của các doanh nghiệp niêm yết phi tài chính tại Việt Nam trong giai đoạn 2012–2021. Dữ liệu nghiên cứu bao gồm 500 DN niêm yết trên HOSE và HNX với 5000 quan sát được thu thập từ Thomson Reuters Eikon. Hai chỉ báo được sử dụng để xác định tình trạng kiệt quệ là tỷ số khả năng chi trả lãi vay (Interest Coverage Ratio – ICR) và số lần lãi vay được trang trải (Times Interest Earned –

TIE). Nghiên cứu kiểm định mô hình Z'-score của Altman (1983) thông qua hồi quy logistic và đánh giá hiệu suất mô hình bằng chỉ số diện tích dưới đường cong ROC (AUC). Kết quả cho thấy mô hình Z'-score hoạt động hiệu quả khi sử dụng cả khi dùng ICR (ROC từ 0.970 đến 0.973) và cả khi dùng TIE (ROC từ 0.974 đến 0.977), tuy nhiên số biến có ý nghĩa thống kê giảm đáng kể khi sử dụng TIE. Phân tích hồi quy logistic từng bước cho thấy bốn chỉ tiêu tài chính có khả năng dự báo mạnh nhất gồm: lợi nhuận trước lãi vay và thuế trên tổng TS, lợi nhuận sau thuế trên tổng TS, tổng nợ phải trả trên tổng TS và tổng VCSH trên tổng nợ phải trả.

Trong nghiên cứu của Lê Hồng Ngọc và cộng sự (2023), các thuật toán học máy đã được áp dụng để dự báo tình trạng KQTC cho các doanh nghiệp tại Việt Nam. Mẫu nghiên cứu được thu thập từ dữ liệu của 657 doanh nghiệp niêm yết trên hai sàn HOSE và HNX trong thời gian từ năm 2009 đến năm 2022. Nhằm xác định mô hình dự báo tối ưu, nhóm tác giả đã triển khai đồng thời nhiều thuật toán bao gồm: Hồi quy Logistic, K-Nearest Neighbors (KNN), Cây quyết định, Rừng ngẫu nhiên, AdaBoost và XGBoost. Kết quả của các mô hình trong nghiên cứu đều đạt hiệu suất khá cao, trong đó ba mô hình có độ chính xác cao nhất là RF, AdaBoost và XGBoost. Đặc biệt, mô hình XGBoost đạt hiệu suất cao nhất với độ chính xác lên đến 93.67% cho thấy mức độ phù hợp cao đối với bối cảnh thị trường Việt Nam. Bên cạnh đó, nhóm tác giả đã sử dụng phương pháp SHAP để giải thích mức độ ảnh hưởng của các biến đầu vào đến tình trạng KQTC. Kết quả chỉ ra rằng các biến có tác động lớn đến KQTC bao gồm: thu nhập trước lãi vay và thuế/tổng TS, lợi nhuận giữ lại/tổng TS, tổng nợ phải trả/vốn cổ đông, thu nhập trước lãi vay và thuế/tổng doanh thu, tăng trưởng thu nhập thông thường, nợ ngắn hạn/tổng doanh thu, thu nhập ròng/tổng doanh thu, nợ ngắn hạn/tổng nợ, tiền mặt và tương đương tiền/tổng TS, thu nhập trước lãi vay, thuế, khấu hao và phí trả dần/tổng TS và tăng trưởng tổng tài sản.

Bảng 2. 2 Tổng hợp các nghiên cứu trong nước

Tác giả	Mẫu và phạm vi nghiên cứu	Mô hình	Biến sử dụng	Kết quả
---------	---------------------------	---------	--------------	---------

Bình và cộng sự (2018)	800 DN tại Việt Nam (2003–2016)	Logistic Regression	Tài chính, thị trường, vĩ mô	AUC = 0.9394 (mô hình dùng biến tài chính, vĩ mô)
Huỳnh Thị Cẩm Hà và cộng sự (2017)	664 DN Việt Nam (2009–2015)	C4.5, AdaBoost	Tài chính, thị trường, vĩ mô	Accuracy 98.67% (AdaBoost)
Phạm Thị Hồng Vân (2018)	189 DN ngành công nghiệp VN (2009–2016)	Logistic Regression	Tài chính, vĩ mô	Accuracy 93.12%
Long và cộng sự (2023)	436 DN niêm yết VN (2010–2021)	LR, RF, SVM, ANN, XGBoost	Tài chính	Accuracy 0.9529 (Asquith và cộng sự)
Nguyễn Thị Kim Oanh (2023)	26 DN khai khoáng VN (2012–2021)	Logistic Regression	Tài chính, vĩ mô	Accuracy 98.82% (mô hình dùng tài chính, vĩ mô)
Thao và cộng sự (2023)	500 DN VN (2012–2021)	Logistic Regression	Tài chính	AUC = 0.977
Lê Hồng Ngọc và cộng sự (2023)	657 DN VN (2009–2022)	LR, KNN, RF, AdaBoost, XGBoost	Tài chính	Accuracy 93.67% (XGBoost)

Nguồn: Tổng hợp từ tác giả

2.3 KHOẢNG TRỐNG NGHIÊN CỨU

Hiện nay, các nghiên cứu quốc tế về dự báo kiệt quệ tài chính đã có bước phát triển mạnh mẽ với sự ứng dụng rộng rãi các mô hình học máy hiện đại. Tuy nhiên, tại Việt Nam, phần lớn các nghiên cứu vẫn còn tập trung vào các phương pháp truyền thống như hồi quy logistic trong khi việc ứng dụng các thuật toán học máy tiên tiến hay các kỹ thuật giải thích mô hình vẫn còn khá hạn chế.

Bên cạnh đó, nhiều nghiên cứu chỉ sử dụng nhóm biến tài chính trong dự báo tình trạng tài chính của doanh nghiệp. Việc kết hợp đầy đủ cả ba nhóm biến tài chính, thị trường và kinh tế vĩ mô tuy đã được đề cập ở một vài công trình, nhưng nhìn chung vẫn còn rất ít và chưa trở thành hướng tiếp cận phổ biến tại Việt Nam.

Ngoài ra, một hạn chế phổ biến trong các nghiên cứu sử dụng mô hình học máy là chưa chú trọng đến việc xác định và lý giải tầm quan trọng của các biến đầu vào. Trong khi các mô hình hồi quy truyền thống có thể cung cấp hệ số ước lượng để giải thích vai trò của từng biến, thì các nghiên cứu sử dụng mô hình học máy thường chỉ dừng lại ở việc báo cáo độ chính xác tổng thể mà thiếu đi công cụ phân tích sâu về cấu trúc ảnh hưởng của từng yếu tố.

Từ những hạn chế trên, nghiên cứu này hướng đến việc lấp đầy khoảng trống bằng cách ứng dụng các mô hình học máy hiện đại trong bối cảnh Việt Nam, đồng thời kết hợp cả ba nhóm biến tài chính, thị trường và vĩ mô và sử dụng các phương pháp giải thích mô hình để xác định rõ vai trò của từng biến trong dự báo kiệt quệ tài chính.

KẾT LUẬN CHƯƠNG 2

Chương 2 trước hết cung cấp nền tảng các quan điểm về kiệt quệ tài chính, các dấu hiệu nhận diện cũng như các yếu tố tác động đến kiệt quệ tài chính. Sau đó, các phương pháp và mô hình dự báo kiệt quệ được sử dụng trong các nghiên cứu trước đây cũng được đề cập tới. Bên cạnh đó, chương này cũng tổng hợp các nghiên cứu trước đây để từ đó rút ra được cơ sở cho việc lựa chọn các biến và xây dựng mô hình dự báo.


CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

Chương này trình bày nội dung về quy trình nghiên cứu, mô tả các biến sử dụng trong bài đồng thời giới thiệu về các mô hình nghiên cứu cũng như các chỉ số đánh giá mô hình và phương pháp đánh giá các biến đặc trưng quan trọng.

3.1 QUY TRÌNH NGHIÊN CỨU

Để tiến hành nghiên cứu dự báo kiệt quệ tài chính cho các doanh nghiệp phi tài chính niêm yết trên thị trường chứng khoán Việt Nam, tác giả đã ứng dụng các

Sơ đồ 3. 1 Quy trình nghiên cứu



mô hình học máy và thực hiện quy trình nghiên cứu theo các bước như sơ đồ 3.1.

Nguồn: Tổng hợp từ tác giả

Bước 1: Tiến hành lược khảo các nghiên cứu thực nghiệm trong và ngoài nước có liên quan đến chủ đề dự báo kiệt quệ tài chính để xác định vấn đề nghiên cứu cũng như xây dựng cơ sở lý thuyết cho đề tài.

Bước 2: Tiến hành thu thập dữ liệu từ 476 doanh nghiệp phi tài chính niêm yết trên TTCK Việt Nam từ 2015 – 2024 thông qua thư viện Vnstock sau đó xử lý và chuẩn hóa dữ liệu bằng Google Colab.

Bước 3: Sử dụng 10 biến đầu vào từ 3 nhóm biến gồm nhóm biến tài chính (khả năng thanh khoản, khả năng sinh lời, hiệu quả hoạt động, đòn bẩy tài chính, tỷ lệ dòng tiền hoạt động kinh doanh trên tổng nợ, quy mô DN, tăng trưởng doanh

thu), nhóm biến vĩ mô (tăng trưởng kinh tế, lạm phát) và nhóm biến thị trường (tỷ lệ giá thị trường trên giá trị sổ sách) để xây dựng năm mô hình học máy gồm Hồi quy Logistic (Logistic Regression), Cây quyết định (Decision Tree), Rừng ngẫu nhiên (Random Forest), XGBoost (Extreme Gradient Boosting) và Mạng nơ-ron nhân tạo (Artificial Neural Network).

Bước 4: Thực hiện thống kê mô tả và phân tích tương quan các biến. Sau đó, đánh giá hiệu suất của các mô hình dựa trên các chỉ số như Accuracy, Precision, Recall, F1-Score, AUC và đường cong ROC để tìm ra mô hình phù hợp nhất cho bài nghiên cứu đồng thời sử dụng phương pháp SHAP (Shapley Additive exPlanations) để tìm ra các biến có đóng góp quan trọng vào kết quả dự báo của mô hình.

Bước 5: Dựa trên kết quả thu được, tác giả tiến hành đưa ra kết luận và đưa ra một vài hàm ý quản trị nhằm giảm thiểu rủi ro KQTC cho các DN. Đồng thời, trình bày các hạn chế của đề tài và nêu hướng phát triển cho các nghiên cứu tiếp theo.

3.2 XÂY DỰNG MÔ HÌNH NGHIÊN CỨU

3.2.1 Thu thập và xử lý dữ liệu

3.2.1.1 Thu thập dữ liệu

Dữ liệu nghiên cứu là dữ liệu được thu thập từ báo cáo tài chính của các doanh nghiệp phi tài chính được niêm yết trên TTCK Việt Nam trong giai đoạn từ 2015 – 2024. Nguồn dữ liệu được trích xuất thông qua thư viện Vnstock, đây là một công cụ trên nền tảng Python giúp hỗ trợ truy cập và thu thập dữ liệu tài chính từ các doanh nghiệp niêm yết tại Việt Nam một cách nhanh chóng.

Tiêu chí lựa chọn mẫu nghiên cứu đầu tiên là các doanh nghiệp phải được niêm yết trên hai sàn HOSE và HNX đồng thời có đầy đủ thông tin dữ liệu trong 10 năm từ năm 2015 đến năm 2024. Bên cạnh đó, các công ty thuộc nhóm ngành tài chính như ngân hàng và bảo hiểm bị loại bỏ khỏi mẫu nghiên cứu vì các công ty này có đặc điểm cấu trúc tài chính và báo cáo tài chính khác biệt đáng kể so với các ngành sản xuất và dịch vụ thông thường. Mẫu nghiên cứu cuối cùng bao gồm dữ

liệu của 476 doanh nghiệp với 4760 quan sát với đầy đủ các biến cần thiết phục vụ cho quá trình

xây dựng mô hình dự báo KQTC cho các doanh nghiệp phi tài chính trên thị trường chứng khoán Việt Nam.

3.2.1.2 Xử lý dữ liệu

Trước tiên, các giá trị bị thiếu trong bộ dữ liệu được xử lý bằng phương pháp điền giá trị trung bình cho từng biến nhằm đảm bảo đầy đủ thông tin cho tất cả các biến đầu vào đồng thời tránh làm giảm số lượng mẫu phân tích.

Data columns (total 12 columns):				
#	Column	Non-Null Count	Dtype	
0	ticker	4760 non-null	object	
1	WCTA	4760 non-null	float64	
2	EBITTA	4760 non-null	float64	
3	SALESTA	4760 non-null	float64	
4	OCFTL	4760 non-null	float64	
5	TLTA	4760 non-null	float64	
6	SIZE	4760 non-null	float64	
7	GROWTH	4760 non-null	float64	
8	GDP	4760 non-null	float64	
9	CPI	4760 non-null	float64	
10	PTB	4760 non-null	float64	
11	FD	4760 non-null	int64	


Hình 3. 1 Dữ liệu sau khi được xử lý

Nguồn: Tổng hợp từ tác giả

Trong nghiên cứu này, tác giả không loại bỏ các giá trị ngoại lai (outliers) vì những dấu hiệu quan trọng phản ánh tình trạng của các doanh nghiệp đang bị KQTC thường ghi nhận những giá trị bất thường như lợi nhuận âm kéo dài, dòng tiền hoạt động âm hoặc tỷ lệ đòn bẩy cao. Nếu loại bỏ các quan sát này có thể khiến mô hình bỏ sót các tín hiệu có giá trị làm giảm khả năng nhận diện DN có rủi ro cao. Thay vào đó, tác giả tiến hành chuẩn hóa dữ liệu bằng kỹ thuật RobustScaler, đây là phương pháp sử dụng trung vị và khoảng tứ phân vị (IQR) để giảm ảnh hưởng của các giá trị outliers đồng thời đưa các biến về cùng một thang đo phù hợp cho mô hình học máy.

Ngoài ra, vì biến mục tiêu trong nghiên cứu là nhị phân và có sự mất cân đối nghiêm trọng giữa hai nhóm doanh nghiệp kiệt quệ và không kiệt quệ, tác giả đã áp dụng kỹ thuật SMOTE (Synthetic Minority Over-sampling Technique) để cân bằng dữ liệu. SMOTE hoạt động bằng cách tạo thêm các điểm dữ liệu mới cho nhóm thiểu

số thông qua nội suy tuyến tính giữa các quan sát lân cận giúp mô hình học được đầy đủ hơn các đặc trưng giữa hai nhóm DN giúp nâng cao độ chính xác khả năng



Hình 3. 2 Dữ liệu trước và sau khi SMOTE
phân biệt của mô hình.

Nguồn: Tổng hợp từ tác giả

3.2.2 Biến nghiên cứu

3.2.2.1 Biến phụ thuộc

Biến phụ thuộc trong nghiên cứu này là “Khả năng xảy ra kiệt quệ tài chính của doanh nghiệp” (ký hiệu là FD). Đây là biến nhị phân nhằm xác định doanh nghiệp có đang rơi vào tình trạng KQTC hay không và được chia thành hai nhóm:

- FD = 1: Nhóm các doanh nghiệp bị KQTC
- FD = 0: Nhóm các doanh nghiệp không bị KQTC

Việc xác định một DN có đang rơi vào tình trạng KQTC hay không tồn tại rất nhiều cách tiếp cận khác nhau. Theo Asquith và cộng sự (1994), một DN được xem là rơi vào tình trạng KQTC nếu có EBITDA (Lợi nhuận trước thuế, lãi vay và

khấu hao) thấp hơn chi phí lãi vay trong 2 năm liên tiếp hoặc EBITDA nhỏ hơn 80% chi phí lãi vay trong một năm bất kỳ. Tương tự, Pindado và cộng sự (2008) cũng cho rằng một công ty có chi phí tài chính lớn hơn EBITDA trong hai năm liên tiếp và có giá trị thị trường giảm trong hai năm liên tiếp là đang rơi vào tình trạng kiệt quệ tài chính. Trong khi đó, Aktan (2011) đưa ra quan điểm rằng một DN được xem là bị KQTC khi gặp phải 1 trong 3 dấu hiệu bao gồm thua lỗ trong 3 năm liên tiếp hoặc vốn chủ sở hữu âm hoặc buộc phải thanh lý toàn bộ tài sản để trả nợ, dẫn đến giải thể hoặc bị tòa án chấp thuận phá sản. Bên cạnh đó, nghiên cứu của Long và cộng sự (2023) đã xây dựng tiêu chí xác định doanh nghiệp rơi vào tình trạng KQTC bao gồm VCSH âm, tỷ lệ EBITDA trên chi phí lãi vay nhỏ hơn 1 trong 2 năm liên tiếp và thu nhập ròng âm trong 3 năm liên tiếp.

Trên cơ sở kế thừa và điều chỉnh từ các nghiên cứu trước, bài nghiên cứu này sử dụng bốn tiêu chí để xác định một doanh nghiệp có đang rơi vào tình trạng kiệt quệ tài chính hay không. Theo đó, một doanh nghiệp được cho là đang rơi vào kiệt quệ tài chính khi có 1 trong 4 dấu hiệu dưới đây:

- Vốn chủ sở hữu âm trong năm bất kỳ
- EBITDA nhỏ hơn chi phí lãi vay trong 2 năm liên tiếp
- EBITDA nhỏ hơn 80% chi phí lãi vay trong năm bất kỳ
- Thu nhập ròng âm trong 3 năm liên tiếp

Bảng 3. 1 Số lượng và tỷ trọng hai nhóm doanh nghiệp qua từng năm

Năm	DN không bị KQTC		DN bị KQTC	
	<i>Số lượng</i>	<i>Tỷ trọng</i>	<i>Số lượng</i>	<i>Tỷ trọng</i>
2015	451	94.75%	25	5.25%
2016	454	95.38%	22	4.62%
2017	454	95.38%	22	4.62%
2018	446	93.70%	30	6.30%
2019	448	94.12%	28	5.88%
2020	435	91.39%	41	8.61%

2021	434	91.18%	42	8.82%
2022	422	88.66%	54	11.34%
2023	405	85.08%	71	14.92%
2024	407	85.50%	69	14.50%
Tổng	4356	91.51%	404	8.49%

Nguồn: Tổng hợp từ tác giả

3.2.2.2 Biến độc lập

Các nghiên cứu trước đây hầu như chỉ tập trung sử dụng nhóm biến tài chính cho mô hình dự báo KQTC, điển hình như nghiên cứu của Beaver (1966) hay Ohlson (1980). Tuy nhiên, báo cáo tài chính chủ yếu phản ánh thông tin quá khứ và chịu sự ràng buộc bởi các chuẩn mực kế toán nên các biến tài chính trở nên chưa đầy đủ và thiếu tính kịp thời trong việc phản ánh rủi ro tài chính thực tế (Agarwal & Taffler, 2007). Để khắc phục hạn chế đó, nhiều nghiên cứu đã đề xuất đưa thêm nhóm biến thị trường vào mô hình vì các biến này có khả năng cung cấp thông tin từ bên ngoài DN và cải thiện đáng kể tính cập nhật cũng như độ nhạy của mô hình. Các nghiên cứu thực nghiệm của Chava và Jarrow (2004), Christidis và Gregory (2010) đều chứng minh rằng các biến thị trường như tỷ suất sinh lợi vượt trội, độ biến động cổ phiếu hay quy mô thị trường,... có khả năng cải thiện khả năng dự báo. Thêm vào đó, kết quả từ nghiên cứu của Qu (2008), Mare (2015) cho thấy việc tích hợp các yếu tố như lãi suất, tăng trưởng GDP hay lạm phát,... vào mô hình dự báo có thể giúp điều chỉnh xác suất vỡ nợ linh hoạt hơn, phản ánh kịp thời với biến động của chu kỳ kinh tế và điều kiện thị trường. Có thể thấy, việc kết hợp cả ba nhóm biến không chỉ khắc phục hạn chế riêng lẻ mà còn tạo nên một mô hình cảnh báo sớm toàn diện và có khả năng thích ứng cao với thực tế. Nghiên cứu của Tinoco và Wilson (2013), Bình và cộng sự (2018) đều chỉ ra rằng việc kết hợp đồng thời ba nhóm biến tài chính, thị trường và vĩ mô có thể nâng cao hiệu quả dự báo tình trạng KQTC của DN. Trên cơ sở đó, nghiên cứu này sẽ kết hợp dữ liệu tài chính, dữ liệu thị trường và dữ liệu kinh tế vĩ mô cho mô hình dự báo tình trạng KQTC cho các DN phi tài chính tại Việt Nam.

Nhóm biến tài chính

Khả năng thanh khoản (WCTA - Working Capital to Total Assets)

WCTA là tỷ lệ vốn lưu động trên tổng tài sản, được tính bằng cách lấy vốn lưu động (tài sản ngắn hạn trừ nợ ngắn hạn) chia cho tổng TS của doanh nghiệp. Chỉ số này đo lường mức độ thanh khoản ngắn hạn của doanh nghiệp so với quy mô tài sản, phản ánh khả năng sử dụng TS ngắn hạn để đáp ứng các nghĩa vụ tài chính ngắn hạn. WCTA cao cho thấy doanh nghiệp duy trì sự ổn định tài chính, giảm nguy cơ kiệt quệ tài chính nhờ khả năng chi trả nợ ngắn hạn và ứng phó với các cú sốc tài chính. Ngược lại, WCTA thấp hoặc âm là dấu hiệu cảnh báo về thanh khoản yếu, làm tăng nguy cơ mất khả năng thanh toán và dẫn đến KQTC. Biến này được Altman (1968) sử dụng trong mô hình Z-score nhằm đánh giá rủi ro tài chính thông qua khả năng thanh toán ngắn hạn, Ohlson (1980) cũng dùng chỉ số này cho mô hình logit với ý nghĩa tương tự. Beaver (1966) cho thấy có mối quan hệ ngược chiều giữa biến WCTA và KQTC, kết quả nghiên cứu Bình và cộng sự (2018) cũng chỉ ra rằng các doanh nghiệp có tỷ lệ thanh khoản cao sẽ có khả năng thanh toán các nghĩa vụ tài chính của mình tốt hơn.

Khả năng sinh lời (EBITTA - Earnings Before Interest and Taxes to Total Assets)

EBITTA là tỷ lệ lợi nhuận trước lãi vay và thuế trên tổng tài sản của doanh nghiệp. Chỉ số này đo lường hiệu quả sử dụng tài sản để tạo ra lợi nhuận từ hoạt động kinh doanh cốt lõi mà không bị ảnh hưởng bởi cấu trúc tài chính hoặc chính sách thuế. EBITTA cao cho thấy doanh nghiệp không chỉ tạo ra doanh thu mà còn quản lý chi phí hiệu quả để sinh lời. EBITTA thấp là dấu hiệu sử dụng TS kém hoặc chi phí quá cao, làm giảm dòng tiền và tăng nguy cơ kiệt quệ tài chính. Đây là một trong những biến số quan trọng trong mô hình của Altman (1968), tác giả đã chỉ ra rằng biến này có mối quan hệ ngược chiều với KQTC. Shumway (2001) cho rằng DN có thu nhập cao hơn so với tài sản thì ít có khả năng phá sản hơn. Nhiều nghiên cứu chỉ ra EBITTA là biến có tác động lớn nhất tới kết quả dự báo của mô hình (Bình và cộng sự, 2018; Thao và cộng sự, 2023; Lê Hồng Ngọc và cộng sự, 2023).

Hiệu quả hoạt động (SALESTA - Sales to Total Assets)

SALESTA là tỷ lệ doanh thu trên tổng tài sản, được tính bằng cách chia tổng doanh thu của doanh nghiệp cho tổng giá trị TS. Chỉ số này đo lường hiệu quả sử dụng TS của doanh nghiệp để tạo ra doanh thu, phản ánh mức độ khai thác TS trong hoạt động kinh doanh. SALESTA cao thể hiện rằng doanh nghiệp đang tối ưu hóa TS để tạo ra doanh thu. Ngược lại, SALESTA thấp cho thấy doanh nghiệp không tạo đủ doanh thu từ TS, có thể dẫn đến thiếu hụt dòng tiền để chi trả chi phí hoặc nợ. Đây là một trong những biến được sử dụng trong mô hình của Altman (1968) và Springate (1978). Gu (2002) chỉ ra rằng hiệu quả hoạt động cao nhưng đi kèm với lợi nhuận thấp có thể dẫn đến rủi ro tài chính tiềm ẩn. Widhiari và Merkusiwati (2015) cho thấy tỷ lệ doanh thu trên tài sản có mối quan hệ tiêu cực với KQTC, Phạm Thị Hồng Vân (2018) cũng cho kết quả tương tự.

Đòn bẩy tài chính (TLTA - Total Liabilities to Total Assets)

TLTA là tỷ lệ tổng nợ phải trả trên tổng tài sản của doanh nghiệp. Chỉ số này được tính bằng cách chia tổng nợ phải trả cho tổng giá trị tài sản, phản ánh mức độ sử dụng đòn bẩy tài chính và cấu trúc vốn của doanh nghiệp. TLTA thấp cho thấy doanh nghiệp có cấu trúc tài chính an toàn với ít nợ và có khả năng chống chịu tốt trước các cú sốc tài chính. Ngược lại, TLTA cao là dấu hiệu cảnh báo rằng DN đang sử dụng nợ lớn hơn so với quy mô TS, làm tăng rủi ro mất khả năng thanh toán nếu lợi nhuận và dòng tiền không đủ bù đắp. Andrade và Kaplan (1998) chỉ ra rằng đòn bẩy tài chính cao là yếu tố chính tác động đến KQTC. Tinoco và Wilson (2013) và Huỳnh Thị Cẩm Hà và cộng sự (2017) cũng chỉ ra rằng TLTA là biến có sức phân biệt lớn và ổn định trong mô hình dự báo. Trong nghiên cứu của Beaver (1966), Ohlson (1980), Zmijewski (1984), TLTA được cho là có quan hệ cùng chiều với xác suất KQTC, điều này cũng tương đồng với nghiên cứu của Phạm Thị Hồng Vân (2018).

Dòng tiền (OCFTL - Operating Cash Flow to Total Liabilities)

OCFTL là tỷ lệ dòng tiền từ hoạt động kinh doanh trên tổng nợ phải trả của doanh nghiệp, được xác định bằng cách chia dòng tiền HDKD cho tổng nợ phải trả.

OCFTL đo lường mức độ mà dòng tiền từ HDKD có thể đáp ứng các khoản nợ, thể hiện khả năng thanh toán nợ và sức khỏe tài chính của doanh nghiệp. OCFTL thấp nghĩa là dòng tiền tạo ra không đủ để trả nợ, DN sẽ phụ thuộc vào nguồn vốn vay hoặc TS thanh lý để duy trì hoạt động làm tăng nguy cơ mất kiểm soát dòng tiền. Ngược lại, OCFTL cao thể hiện năng lực tạo tiền mạnh mẽ, giúp doanh nghiệp chủ động về tài chính, duy trì niềm tin với chủ nợ và giảm thiểu rủi ro tài chính trong ngắn hạn lẫn dài hạn. Nghiên cứu của Ohlson (1980), Tinoco và Wilson (2013) đã chỉ ra rằng OCFTL là biến đóng vai trò quan trọng trong mô hình nghiên cứu. Có nhiều nghiên cứu đã chỉ ra mối quan hệ tiêu cực giữa biến này với rủi ro KQTC như Chen và Shen (2020) và Nguyễn Thị Kim Oanh (2023).

Quy mô doanh nghiệp (SIZE)

Biến SIZE đại diện cho quy mô doanh nghiệp và được đo lường bằng logarit tự nhiên của tổng tài sản để làm giảm sự chênh lệch lớn giữa các giá trị tài sản. SIZE là một chỉ số quan trọng thể hiện quy mô và sức mạnh tài chính của doanh nghiệp. Doanh nghiệp có SIZE lớn thường có khả năng chống chịu tốt hơn trước các cú sốc tài chính nhờ nguồn lực dồi dào trong khi doanh nghiệp có SIZE nhỏ có thể dễ bị tác động hơn làm tăng rủi ro tài chính. Trong mô hình O-score của Ohlson (1980), tác giả đã chỉ ra rằng các doanh nghiệp có quy mô nhỏ thường dễ bị tổn thương hơn. Campbell và cộng sự (2008) cũng nhấn mạnh vai trò ổn định của các doanh nghiệp lớn trong môi trường tài chính nhiều biến động. Tại Việt Nam, Phạm Thị Hồng Vân (2018) đã chứng minh tồn tại mối quan hệ ngược chiều giữa SIZE và xác suất KQTC. Tương tự, Thao và cộng sự (2023) cũng ghi nhận rằng quy mô doanh nghiệp có ảnh hưởng đáng kể đến khả năng KQTC của các doanh nghiệp tại Việt Nam.

Tăng trưởng doanh thu (GROWTH)

GROWTH đo lường mức độ tăng hoặc giảm doanh thu của doanh nghiệp, được tính bằng phần trăm thay đổi doanh thu giữa hai kỳ. Chỉ số này là chỉ số quan trọng thể hiện khả năng tạo ra dòng tiền từ hoạt động kinh doanh của DN. Khi GROWTH ở mức cao và ổn định, doanh nghiệp được đánh giá là đang trên đà phát

triển, có khả năng thu hút đầu tư, tiếp cận vốn thuận lợi và duy trì được niềm tin từ thị trường. Ngược lại, GROWTH thấp hoặc âm là dấu hiệu của sự suy giảm nội lực kinh doanh, cho thấy doanh nghiệp đang mất dần thị phần, gặp khó khăn trong mở rộng hoạt động, cảnh báo nguy cơ KQTC. Opler và Titman (1994) phát hiện rằng tăng trưởng doanh thu âm có mối liên hệ đáng kể với việc các doanh nghiệp gặp khó khăn trong HDKD hằng ngày. Barboza và cộng sự (2017) tìm thấy sự tác động đáng kể của biến GROWTH trong mô hình dự báo. Các nghiên cứu của Platt và Platt (2008), Kartika (2018) cho thấy tăng trưởng doanh thu có quan hệ ngược chiều với rủi ro KQTC.

Nhóm biến thị trường

Tỷ lệ giá thị trường trên giá sổ sách (PTB - Price to book)

PTB là tỷ lệ giữa giá thị trường của cổ phiếu và giá trị sổ sách trên mỗi cổ phiếu. Chỉ số này phản ánh nhận định của thị trường về giá trị thực của công ty so với giá trị ghi trên sổ sách. PTB cao thường gắn với kỳ vọng tích cực, thể hiện rằng thị trường tin tưởng vào năng lực tăng trưởng, hiệu quả hoạt động và sự ổn định tài chính của doanh nghiệp. Ngược lại, PTB thấp có thể được hiểu như một tín hiệu tiêu cực, cho thấy nhà đầu tư đánh giá thấp triển vọng hoặc cho rằng doanh nghiệp đang tiềm ẩn rủi ro tài chính đáng kể. Tỷ số PTB thấp thường đi kèm với các vấn đề như tài sản kém chất lượng, hiệu suất sử dụng tài sản thấp và khó khăn trong việc tiếp cận nguồn vốn. Campbell và cộng sự (2008) cho rằng các cổ phiếu bị thị trường định giá thấp so với giá trị sổ sách thường đi kèm với rủi ro tài chính lớn hơn. Nghiên cứu của Long và cộng sự (2022) đã chỉ ra PTB có tác động đáng kể đến xác suất xảy ra KQTC.

Nhóm biến vĩ mô

Tăng trưởng kinh tế (GDP)

Biến GDP đo lường tốc độ tăng trưởng kinh tế, được xác định bởi phần trăm thay đổi của tổng sản phẩm quốc nội (GDP) so với kỳ trước. GDP là giá trị tổng sản lượng hàng hóa và dịch vụ được sản xuất trong một nền kinh tế và tăng trưởng GDP phản ánh sức khỏe và xu hướng phát triển của nền kinh tế. GDP là một chỉ số kinh

tế vĩ mô quan trọng, ảnh hưởng gián tiếp đến khả năng tài chính của doanh nghiệp thông qua tác động đến nhu cầu thị trường, chi phí vốn, và điều kiện kinh doanh. Tăng trưởng GDP cao thường tạo điều kiện thuận lợi cho doanh nghiệp phát triển, trong khi tăng trưởng GDP thấp hoặc âm có thể làm tăng nguy cơ kiệt quệ tài chính do giảm doanh thu hoặc khó khăn trong việc tiếp cận vốn. Nghiên cứu của Charalambakis và Garrett (2019) đã chỉ ra mối quan hệ ngược chiều giữa biến này với KQTC, điều này cũng tương đồng với kết quả nghiên cứu của Nguyễn Thị Kim Oanh (2023).

Lạm phát (CPI)

Biến CPI là biến đại diện cho tỷ lệ lạm phát, được đo lường bằng thay đổi phần trăm của chỉ số giá tiêu dùng (CPI - Consumer Price Index). CPI phản ánh mức giá trung bình của hàng hóa và dịch vụ tiêu dùng và thay đổi của CPI cho thấy mức độ tăng hoặc giảm giá cả chung trong nền kinh tế. Đây là một chỉ số kinh tế vĩ mô quan trọng ảnh hưởng gián tiếp đến khả năng KQTC thông qua chi phí đầu vào, sức mua của người tiêu dùng và chi phí vốn. Lạm phát cao hoặc thấp đều có thể tác động đến khả năng duy trì HDKD và chi trả các nghĩa vụ tài chính, từ đó ảnh hưởng đến nguy cơ KQTC của các DN. Mare (2015), Tinoco và Wilson (2013) cho thấy tồn tại mối quan hệ tích cực giữa lạm phát và xác suất gặp khó khăn tài chính. Tại Việt Nam, Bình và cộng sự (2018), Nguyễn Thị Kim Oanh (2023) cũng chỉ ra điều tương tự.

Bảng 3. 2 Tổng hợp các biến độc lập

Nhóm biến	Tên biến	Ký hiệu	Công thức
Nhóm biến tài chính	Khả năng thanh khoản	WCTA	$(TS \text{ ngắn hạn} - Nợ \text{ ngắn hạn}) / \text{Tổng TS}$
	Khả năng sinh lời	EBITTA	$\text{Lợi nhuận trước lãi vay và thuế} / \text{Tổng TS}$
	Hiệu quả hoạt động	SALESTA	$\text{Doanh thu} / \text{Tổng TS}$

	Đòn bẩy tài chính	TLTA	Tổng nợ/ Tổng TS
	Tỷ lệ dòng tiền hoạt động trên tổng nợ	OCFTL	Dòng tiền HDKD/ Tổng nợ
	Quy mô doanh nghiệp	SIZE	Logarit(Tổng tài sản)
	Tăng trưởng doanh thu	GROWTH	(DT năm nay – năm trước)/ DT năm trước
Nhóm biến thị trường	Tỷ lệ giá thị trường trên giá sổ sách	PTB	Giá trị thị trường của cổ phiếu/ Giá trị sổ sách của cổ phiếu
Nhóm biến vĩ mô	Tăng trưởng kinh tế	GDP	$(GDP_t - GDP_{t-1})/GDP_{t-1}$
	Lạm phát	CPI	$(CPI_t - CPI_{t-1})/CPI_{t-1}$

Nguồn: Tổng hợp từ tác giả

3.2.3 Mô hình nghiên cứu

3.2.3.1 Mô hình hồi quy Logistic

Hồi quy Logistic là một kỹ thuật thống kê phổ biến được ứng dụng rộng rãi trong các bài toán phân loại mà biến phụ thuộc có hai giá trị rời rạc. Trong lĩnh vực tài chính, mô hình này đặc biệt hữu ích để dự báo khả năng một doanh nghiệp rơi vào tình trạng khó khăn tài chính hoặc phá sản. Biến phụ thuộc trong mô hình có giá trị bằng 1 nếu doanh nghiệp gặp rủi ro tài chính và bằng 0 nếu doanh nghiệp hoạt động bình thường. Mô hình LR có dạng hàm là logit mô tả mối quan hệ giữa $\log(\text{odds})$ – tỷ lệ xác suất xảy ra sự kiện so với không xảy ra và các biến độc lập (các chỉ số tài chính của doanh nghiệp). Phương trình cơ bản của mô hình là:

$$\log(P_i) = \ln\left(\frac{P_i}{1-P_i}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n \quad (3.1)$$

Trong đó:

- P_i : Xác suất doanh nghiệp bị KQTC
- x_1 : Các biến độc lập
- β_0 : Hệ số chặn
- $\beta_1, \dots, \beta_n$: Các hệ số hồi quy ước lượng


Từ phương trình logit, có thể xác định xác suất P_i bằng công thức dưới đây:

$$P_i = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}} \quad (3.2)$$

Sau khi xác suất được ước lượng, một điểm cắt thường được sử dụng để đưa ra quyết định phân loại, thường mặc định là 0,5. Nếu xác suất lớn hơn hoặc bằng 0,5 thì doanh nghiệp được phân loại là bị kiệt quệ tài chính, nếu nhỏ hơn thì doanh nghiệp được xếp vào nhóm bình thường.

Mô hình hồi quy logit được xem là dễ hiểu và dễ diễn giải vì các hệ số trong mô hình thể hiện một cách trực quan mức độ ảnh hưởng của các biến độc lập đến khả năng xảy ra sự kiện. Nhờ cấu trúc rõ ràng và cách trình bày kết quả đơn giản, mô hình giúp người sử dụng dễ dàng phân tích, đánh giá và đưa ra quyết định dựa trên tác động của từng yếu tố đầu vào, mặc dù mối quan hệ giữa các biến và xác suất là phi tuyến tính. Bên cạnh đó, mô hình không yêu cầu dữ liệu phải tuân theo phân phối chuẩn hay giả định đồng nhất phương sai nên có khả năng ứng dụng cho nhiều tập dữ liệu khác nhau.

3.2.3.2 Mô hình Cây quyết định



Nguồn: Sarker (2021)


Mô hình Cây quyết định là một mô hình học máy phổ biến, được sử dụng rộng rãi trong các bài toán phân loại và hồi quy. Mô hình biểu diễn quá trình ra quyết định dưới dạng một cấu trúc cây, trong đó mỗi nút biểu diễn một thuộc tính (biến đầu vào), các nhánh là các giá trị phân chia tương ứng của thuộc tính đó và các nút lá biểu thị kết quả đầu ra hoặc lớp dự đoán. Cây quyết định hoạt động bằng cách lặp lại quá trình phân chia dữ liệu thành các nhóm nhỏ hơn, nhằm tối đa hóa mức độ đồng nhất của biến mục tiêu trong từng nhóm con. Một số thuật toán xây dựng cây quyết định phổ biến bao gồm ID3, C4.5, J48 (phiên bản mở rộng của

Hình 3. 3 Mô hình Decision Tree

C4.5) và CART.

Một ưu điểm đáng chú ý của mô hình DT là khả năng phân tích tầm quan trọng của các biến đầu vào. Thông qua các chỉ số giúp phân chia dữ liệu thành các nhóm đồng nhất hơn (như Gini hoặc Entrophy), mô hình có thể xác định được những yếu tố có ảnh hưởng lớn đến kết quả phân loại DN có rơi vào KQTC hay không. Ngoài ra, do bản chất phân chia dữ liệu theo ngưỡng, cây quyết định cũng có khả năng xử lý các phần tử ngoại lai (outliers) ở mức độ nhất định vì các điểm dữ liệu bất thường có thể bị đẩy vào các nhánh riêng biệt mà không ảnh hưởng quá lớn đến cấu trúc tổng thể của cây. Tuy nhiên, cũng chính vì khả năng linh hoạt trong việc phân chia, cây quyết định có nhược điểm là dễ bị quá khớp (overfitting) nếu không được kiểm soát cẩn thận, đặc biệt khi mô hình quá phức tạp hoặc số lượng nhánh quá nhiều.

3.2.3.3 Mô hình Rừng ngẫu nhiên




Hình 3. 4 Mô hình Random Forest

Nguồn: Sarker (2021)

Mô hình Rừng ngẫu nhiên là một kỹ thuật học máy dựa trên nền tảng của mô hình cây quyết định. Mô hình hoạt động theo nguyên lý xây dựng một tập hợp (ensemble) gồm nhiều cây quyết định, trong đó mỗi cây được huấn luyện trên một tập con dữ liệu được chọn ngẫu nhiên từ tập huấn luyện gốc (kỹ thuật bootstrap) và tại mỗi nút phân chia của cây, một tập con các biến đầu vào cũng được chọn ngẫu nhiên. Việc lựa chọn ngẫu nhiên cả dữ liệu lẫn biến đầu vào giúp tăng tính đa dạng giữa các cây và giảm sự tương quan giữa chúng.

Ưu điểm nổi bật của mô hình RF là khả năng kết hợp dự đoán từ nhiều cây để đưa ra quyết định cuối cùng thông qua nguyên tắc bỏ phiếu đa số giúp làm giảm hiện tượng quá khớp và cải thiện độ chính xác tổng thể. Đồng thời, mô hình RF cũng có thể chống chịu tốt với các giá trị outliers cũng như xác định tầm quan trọng của từng biến đầu vào đối với kết quả phân loại tương tự như mô hình DT nhưng nhờ được tính toán trung bình trên toàn bộ rừng nên kết quả đánh giá trong RF ổn định và ít thiên lệch hơn so với cây đơn.

3.2.3.4 Mô hình XGBoost




Hình 3. 5 Mô hình XGBoost

Nguồn: Amjad và cộng sự (2022)

Mô hình XGBoost là một thuật toán học máy mạnh mẽ thuộc nhóm kỹ thuật học tổ hợp (ensemble learning) được xây dựng dựa trên phương pháp Gradient Boosting. Khác với Random Forest có các cây quyết định được xây dựng độc lập và kết quả được xác định thông qua nguyên tắc bỏ phiếu đa số, XGBoost xây dựng các cây quyết định một cách tuần tự, trong đó mỗi cây mới được tạo ra nhằm khắc phục sai sót còn lại từ các cây trước đó. Việc huấn luyện mô hình theo chuỗi như vậy giúp cải thiện dần độ chính xác qua từng vòng lặp, tạo nên một mô hình tổng hợp có khả năng dự đoán mạnh mẽ.

XGBoost có ưu điểm đáng chú ý là khả năng tối ưu hiệu suất tính toán nhờ khả năng hỗ trợ xử lý song song giúp tốc độ huấn luyện nhanh và tiết kiệm bộ nhớ. Ngoài ra, XGBoost được tích hợp cơ chế regularization giúp kiểm soát độ phức tạp của mô hình tránh hiện tượng overfitting. Đồng thời, mô hình cũng cho phép đánh giá tầm quan trọng của từng biến đầu vào như các mô hình cây khác giúp xác định các yếu tố chính ảnh hưởng đến kết quả dự báo. Mô hình này đặc biệt phù hợp với các bài toán có tập dữ liệu lớn, nhiều biến đầu vào hoặc chứa nhiều dữ liệu nhiễu.

3.2.3.5 Mô hình mạng nơ-ron nhân tạo



Hình 3. 6 Mô hình ANN

Nguồn: Sarker (2021)

Mạng nơ-ron nhân tạo là một trong những mô hình học máy mạnh mẽ được phát triển dựa trên cảm hứng từ cách thức hoạt động của hệ thần kinh sinh học, đặc biệt là bộ não con người. ANN bao gồm một tập hợp lớn các “nơ-ron nhân tạo” (nút) được kết nối với nhau và tổ chức thành ba lớp chính: lớp đầu vào (input layer), các lớp ẩn (hidden layers), và lớp đầu ra (output layer). Mỗi nơ-ron nhân tạo nhận tín hiệu đầu vào, tính tổng có trọng số của các tín hiệu này kết hợp với hệ số điều chỉnh (bias), sau đó chuyển tiếp tín hiệu đến các nơ-ron ở lớp tiếp theo nếu vượt qua một ngưỡng xác định.

Điểm nổi bật của ANN là khả năng học biểu diễn (representation learning) cho phép mô hình tự động trích xuất và học các đặc trưng phức tạp từ dữ liệu mà không cần chỉ định thủ công. ANN đặc biệt hiệu quả khi xử lý các quan hệ phi tuyến tính giữa các biến và phát huy sức mạnh vượt trội trong những tình huống có dữ liệu lớn. Mô hình này đã được ứng dụng thành công trong nhiều lĩnh vực, trong đó có dự báo rủi ro kiệt quệ tài chính cho các doanh nghiệp.

3.3 PHƯƠNG PHÁP ĐÁNH GIÁ HIỆU QUẢ MÔ HÌNH

Ma trận nhầm lẫn

Ma trận nhầm lẫn (confusion matrix) là một công cụ được sử dụng trong phân tích và đánh giá hiệu suất của các mô hình học máy, đặc biệt là trong các bài

toán phân loại (classification). Nó giúp biểu diễn chi tiết kết quả dự đoán của mô hình so với giá trị thực tế, từ đó cung cấp thông tin về độ chính xác, sai sót và các loại lỗi cụ thể. Từ ma trận nhầm lẫn, có thể tiến hành tính toán các chỉ số bao gồm Accuracy, Precision, Recall, Specificity và F1-score. Việc sử dụng kết hợp các chỉ số này giúp đảm bảo đánh giá toàn diện hiệu quả của mô hình trong cả hai khía cạnh nhận diện đúng và đầy đủ các trường hợp doanh nghiệp có nguy cơ kiệt quệ tài chính.

Bảng 3.3 Cấu trúc ma trận nhầm lẫn

		Giá trị thực tế	
		Positive (1)	Negative (0)
Giá trị dự đoán	Positive (1)	TP	FP
	Negative (0)	FN	TN

Nguồn: Tổng hợp từ tác giả

Trong đó:

- TP (True Positive): Mô hình dự đoán đúng kết quả tích cực, thực tế cũng là tích cực (dự đoán đúng trường hợp dương tính)
- TN (True Negative): Mô hình dự đoán đúng một kết quả tiêu cực, thực tế cũng là tiêu cực (dự đoán đúng trường hợp âm tính)
- FP (False Positive): Dự đoán sai – mô hình dự báo là kết quả tích cực nhưng thực tế là tiêu cực (dương tính giả).
- FN (False Negative): Dự đoán sai – mô hình dự báo kết quả là tiêu cực nhưng thực tế là tích cực (âm tính giả).

Accuracy

Accuracy là chỉ số đánh giá độ chính xác tổng thể mô hình phân loại, được đo lường bằng tỷ lệ các dự đoán đúng (bao gồm cả dương và âm) so với tổng số quan sát. Độ chính xác càng cao cho thấy mô hình càng dự đoán tốt.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (3.3)$$

Precision

Precision là mức độ chính xác của dự báo dương, được đo lường tỷ lệ mẫu được dự đoán là dự đoán là lớp dương (positive) đúng so với tổng số mẫu được dự đoán là lớp dương (trong số những công ty mà mô hình dự đoán là kiệt quệ có bao nhiêu công ty thực sự kiệt quệ). Chỉ số giúp đánh giá mức độ đáng tin cậy của mô hình khi cảnh báo về tình trạng tài chính xấu.

(3.4)

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall

Recall là tỷ lệ bao phủ dương, được đo lường bằng tỷ lệ các mẫu thực tế thuộc lớp dương (positive) được mô hình dự đoán đúng so với tổng số mẫu thực tế thuộc lớp dương (trong số các công ty thực sự bị kiệt quệ, có bao nhiêu công ty được mô hình phát hiện đúng). Chỉ số này phản ánh khả năng phát hiện đầy đủ các trường hợp doanh nghiệp thực sự kiệt quệ, giúp hạn chế các trường hợp bị bỏ sót (false negative).

(3.5)

$$\text{Recall} = \frac{TP}{TP + FN}$$

Specificity

Specificity là chỉ số cho biết mức độ chính xác của mô hình trong việc nhận diện những trường hợp không thuộc lớp dương tính (tức là âm tính thật sự). Chỉ số này được đo lường bằng tỷ lệ các mẫu thực tế thuộc lớp âm (negative) được mô hình dự đoán đúng so với tổng số mẫu thực tế thuộc lớp âm (trong số các DN không bị KQTC, có bao nhiêu DN mô hình đã dự đoán đúng là không kiệt quệ). Chỉ số này giúp đảm bảo rằng âm bảo rằng các doanh nghiệp hoạt động bình thường không bị đánh giá nhầm là có nguy cơ tài chính.

(3.6)

$$\text{Specificity} = \frac{TN}{TN + FP}$$

F1-score

F1-score là thước đo tổng hợp để đánh giá sự cân bằng giữa Precision và Recall, nó được đo lường bằng trung bình điều hòa của Precision (tỷ lệ chính xác dương) và Recall (tỷ lệ bao phủ dương). chỉ số F1-score được (3.7) sử dụng đóng vai trò như một thước đo tổng hợp giữa độ chính xác và khả năng phát hiện, đặc biệt hữu ích trong các bài toán có dữ liệu mất cân bằng.

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Đường cong ROC (Receiver Operating Characteristic) và chỉ số AUC (Area Under the Curve)

Đường cong ROC thể hiện mối quan hệ giữa tỷ lệ dự báo đúng các doanh nghiệp thực sự có nguy cơ kiệt quệ tài chính (True Positive Rate) và tỷ lệ dự báo sai các doanh nghiệp không gặp rủi ro thành có rủi ro (False Positive Rate). Trong khi đó, AUC là diện tích dưới đường cong ROC, phản ánh khả năng tổng quát của mô hình trong việc phân biệt giữa hai nhóm doanh nghiệp, chỉ số AUC càng (3.8) tiến gần đến 1 thì mô hình càng có khả năng phân loại tốt.

Trong đó:


$$\text{True Positive Rate} = \frac{TP}{TP + FN} \quad (3.9)$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN}$$

3.4 PHƯƠNG PHÁP ĐÁNH GIÁ CÁC BIẾN ĐẶC TRƯNG QUAN TRỌNG

Trong nghiên cứu này, SHAP được áp dụng để xác định các biến có ảnh hưởng lớn đến xác suất kiệt quệ tài chính của doanh nghiệp. Đây là phương pháp giải thích mô hình học máy được phát triển dựa trên giá trị Shapley trong lý thuyết trò chơi (Roth, 1988). Mục tiêu của SHAP là lượng hóa mức độ đóng góp của từng đặc trưng đầu vào đối với kết quả dự đoán của mô hình. Phương pháp này đảm bảo ba thuộc tính quan trọng gồm: tính không gán cho đặc trưng thiếu (missingness), tính nhất quán (consistency) và độ chính xác cục bộ (local accuracy). Giá trị SHAP được tính bằng cách xem xét tất cả các tổ hợp có thể của các đặc trưng, từ đó đánh

giá mức thay đổi của đầu ra khi thêm từng đặc trưng vào mô hình. Nhờ khả năng giải thích rõ ràng và có nền tảng toán học vững chắc, SHAP được ứng dụng rộng rãi trong việc kiểm tra độ tin cậy của các mô hình học máy. Để đánh giá mức độ ảnh hưởng của các biến đầu vào đến xác suất doanh nghiệp rơi vào tình trạng kiệt quệ tài chính, nghiên cứu đã sử dụng hai loại biểu đồ SHAP: bar plot và beeswarm plot.



Hình 3. 7 Minh họa bar plot và beeswarm plot

Trong đó, bar plot phản ánh giá trị SHAP trung bình tuyệt đối, giúp xác định các biến có ảnh hưởng mạnh và ổn định trên toàn bộ dữ liệu còn beeswarm plot thể hiện phân bố chiều hướng tác động, từ đó cho thấy cách mỗi biến làm tăng hoặc giảm xác suất xảy ra KQTC.

Nguồn: Tổng hợp từ tác giả

KẾT LUẬN CHƯƠNG 3

Chương 3 đã trình bày chi tiết quy trình xây dựng mô hình dự báo tình trạng kiệt quệ tài chính cho các doanh nghiệp phi tài chính với 10 biến đầu vào thuộc ba nhóm: tài chính, thị trường và vĩ mô. Dữ liệu sau khi được xử lý và chuẩn hóa được sử dụng cho năm mô hình gồm: Hồi quy Logistic, Cây quyết định, Rừng ngẫu nhiên, XGBoost và Mạng nơ-ron nhân tạo. Hiệu quả của các mô hình được đánh giá thông qua các chỉ số như Accuracy, Precision, Recall, Specificity, F1-score và đường cong ROC. Ngoài ra, nghiên cứu còn sử dụng phương pháp SHAP để xác định mức độ ảnh hưởng của từng biến đầu vào trong quá trình dự báo.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

Chương này trình bày về kết quả thống kê mô tả và tương quan giữa các biến sau đó tiến hành đánh giá và so sánh hiệu suất dự báo của các mô hình. Bên cạnh đó, chương này cũng xem xét các biến nào có ảnh hưởng lớn tới kết quả dự báo của mô hình.

4.1 THỐNG KÊ MÔ TẢ CÁC BIẾN

Bảng 4. 1 Kết quả thống kê mô tả các biến

Biến	Số quan sát	Giá trị trung bình	Độ lệch chuẩn	Giá trị nhỏ nhất	Giá trị lớn nhất
WCTA	4760	0.4676	0.2461	-0.7213	1.0000
EBITTA	4760	0.0838	0.0824	-0.7720	0.9970
SALESTA	4760	1.0826	0.8895	0.0000	5.9000
OCFTL	4760	0.2068	0.5484	-4.0000	6.0000
TLTA	4760	0.2161	0.1842	0.0000	0.9000
SIZE	4760	6.9245	1.6291	2.6391	13.6371
GROWTH	4760	0.1423	0.8725	-0.9930	24.6750
GDP	4760	0.0611	0.0186	0.0255	0.0812
CPI	4760	0.0282	0.0089	0.0063	0.0362
PTB	4760	1.2615	1.0298	-0.9000	9.4000
FD	4760	0.0849	0.2787	0.0000	1.0000

Nguồn: Tổng hợp từ tác giả

Nhóm biến tài chính

Biến WCTA phản ánh mức độ thanh khoản của doanh nghiệp, tức khả năng doanh nghiệp sử dụng tài sản ngắn hạn để đáp ứng các nghĩa vụ ngắn hạn. Giá trị trung bình của WCTA đạt 0.4676 cho thấy vốn lưu động trung bình chiếm khoảng

46.8% tổng tài sản của các DN, đây là một tỷ lệ tương đối tích cực phản ánh phần lớn doanh nghiệp trong mẫu có khả năng thanh toán ngắn hạn ổn định. Tuy nhiên, độ lệch chuẩn là 0.2461 cùng với giá trị nhỏ nhất là -0.7213 cho thấy vẫn tồn tại một số doanh nghiệp gặp vấn đề nghiêm trọng về thanh khoản, là tín hiệu cảnh báo sớm về rủi ro mất khả năng thanh toán nếu không có biện pháp quản trị dòng tiền hiệu quả. Ngược lại, giá trị lớn nhất là 1.0 cho thấy một số doanh nghiệp đang duy trì toàn bộ TS là vốn lưu động, thường gặp ở các công ty thương mại hoặc ngành có chu kỳ kinh doanh ngắn.

Biến EBITTA phản ánh hiệu quả sinh lời từ hoạt động kinh doanh cốt lõi so với tổng tài sản. Giá trị trung bình 0.0838 cho thấy các doanh nghiệp đạt tỷ suất sinh lời trước lãi vay và thuế là 8.38%, phản ánh khả năng tạo lợi nhuận từ TS của các DN phi tài chính tại Việt Nam ở mức vừa phải. Tuy nhiên, độ lệch chuẩn 0.0824 phản ánh sự chênh lệch lớn về hiệu quả kinh doanh giữa các công ty niêm yết. Cụ thể, giá trị cực tiểu -0.7720 cảnh báo về một nhóm doanh nghiệp đang thua lỗ nghiêm trọng, thậm chí mất hơn 77% giá trị tài sản mỗi năm do HDKD kém hiệu quả. Trong khi đó, mức cao nhất đạt 0.9970 cho thấy một số doanh nghiệp sử dụng TS cực kỳ hiệu quả để tạo ra lợi nhuận đồng thời phản ánh sự chênh lệch lớn về hiệu quả kinh doanh giữa các công ty niêm yết.

Biến SALESTA đo lường hiệu quả sử dụng tài sản trong việc tạo ra doanh thu. Biến này có giá trị trung bình là 1.0826 cho thấy trung bình mỗi đồng tài sản tạo ra hơn một đồng doanh thu, điều này thể hiện hiệu quả khai thác TS tốt của các DN. Tuy nhiên, độ lệch chuẩn lớn 0.8895 cho thấy sự chênh lệch đáng kể về hiệu suất quay vòng tài sản giữa các doanh nghiệp, điều này có thể đến từ sự khác biệt trong ngành nghề. Cụ thể các doanh nghiệp bán lẻ, dịch vụ có thể có vòng quay tài sản cao trong khi các doanh nghiệp bất động sản hay xây dựng thường đầu tư lớn nhưng doanh thu ghi nhận chậm. Với giá trị tối thiểu 0.0000 phản ánh thực trạng có những DN không tạo ra doanh thu trong khi Giá trị tối đa 5.9000 cho thấy một số doanh nghiệp đạt hiệu suất khai thác TS rất cao.

Biến OCFTL đo lường khả năng doanh nghiệp tạo ra dòng tiền từ hoạt động để chi trả nợ phải trả. Giá trị trung bình là 0.2068 cho thấy trung bình các DN có 20.68% nợ được trang trải bằng dòng tiền hoạt động, một mức khá an toàn. Độ lệch chuẩn là 0.5484 cho thấy sự biến động lớn trong khả năng thanh toán nợ giữa các DN do sự khác biệt trong cấu trúc vốn hoặc hiệu quả vận hành. Giá trị tối đa là 6.0000 thể hiện năng lực quản trị dòng tiền vượt trội của một số doanh nghiệp, trong khi giá trị tối thiểu -4.0000 cho thấy có doanh nghiệp không chỉ không đủ dòng tiền để trả nợ mà còn âm nghiêm trọng, làm gia tăng rủi ro vỡ nợ.

Biến TLTA thể hiện mức độ sử dụng đòn bẩy tài chính của các DN. Giá trị trung bình 0.2161 thể hiện phần lớn các DN có mức đòn bẩy tài chính khá thấp, ít phụ thuộc vào vốn vay. Độ lệch chuẩn là 0.1842 thể hiện sự khác biệt vừa phải giữa các DN phản ánh chiến lược tài trợ khác nhau. Giá trị nhỏ nhất bằng 0.0000 biểu thị một số doanh nghiệp hoàn toàn không sử dụng nợ vay, trong khi giá trị tối đa 0.9000 cho thấy có doanh nghiệp có tỷ lệ nợ rất cao, chiếm đến 90% tổng tài sản tiềm ẩn rủi ro thanh khoản và rủi ro lãi suất đáng kể.

Biến SIZE có giá trị trung bình là 6.9245 cho thấy phần lớn doanh nghiệp trong mẫu nghiên cứu có quy mô vừa nhỏ. Với độ lệch chuẩn cao, lên đến 1.6291 phản ánh sự hiện diện đồng thời của cả các doanh nghiệp vừa và nhỏ lẫn các tập đoàn quy mô lớn. Cụ thể, giá trị nhỏ nhất 2.6391 đại diện cho một doanh nghiệp rất nhỏ, trong khi giá trị lớn nhất 13.6371 phản ánh quy mô của một tập đoàn hàng đầu trên thị trường.

Biến GROWTH đại diện cho tăng trưởng doanh thu có giá trị trung bình là 0.1423 cho thấy xu hướng phát triển tích cực của các DN trong mẫu. Tuy nhiên, độ lệch chuẩn cao 0.8725 thể hiện sự phân hóa mạnh về tốc độ tăng trưởng. Với giá trị nhỏ nhất là -0.9930 cho thấy có doanh nghiệp đang bị suy giảm mạnh về doanh thu, là dấu hiệu điển hình của rủi ro tài chính hoặc do khủng hoảng trong chu kỳ ngành. Ngược lại, giá trị lớn nhất là 24.6750 thể hiện cho sự tăng trưởng vượt bậc, thường thấy ở các doanh nghiệp mới nổi hoặc có chiến lược kinh doanh hiệu quả trong ngành tăng trưởng nhanh.

Nhóm biến vĩ mô

Đối với các biến vĩ mô, biến GDP có giá trị trung bình là 6.11% với độ lệch chuẩn nhỏ 0.0186 và CPI trung bình ở mức 2.82% với độ lệch chuẩn rất nhỏ 0.0088. Hai chỉ tiêu này cho thấy nền kinh tế Việt Nam trong giai đoạn nghiên cứu duy trì mức tăng trưởng ổn định với lạm phát được kiểm soát, tạo môi trường thuận lợi cho hoạt động sản xuất kinh doanh. Điều này cũng phù hợp với bối cảnh kinh tế Việt Nam trong những năm gần đây, vốn được đánh giá có tốc độ tăng trưởng đều và ít chịu tác động từ các cú sốc vĩ mô lớn.

Nhóm biến thị trường

Biến PTB trung bình 1.2615, cho thấy thị trường nhìn chung vẫn đánh giá cao giá trị kỳ vọng của các doanh nghiệp phi tài chính trên TTCK Việt Nam. Độ lệch chuẩn biến động cao với giá trị 1.0298 phản ánh sự khác biệt trong kỳ vọng của thị trường. Giá trị lớn nhất là 9.4000 cho thấy có cổ phiếu được định giá cao, phản ánh kỳ vọng tăng trưởng lớn trong khi giá trị nhỏ nhất là -0.9000 thể hiện DN đang bị định giá rất thấp, thường xuất hiện ở các doanh nghiệp có lỗ lũy kế, tài sản suy giảm hoặc thị trường mất niềm tin vào triển vọng tăng trưởng.


Biến phụ thuộc

Cuối cùng, biến FD là biến nhị phân phản ánh tình trạng kiệt quệ tài chính với giá trị lớn nhất 1 biểu thị doanh nghiệp rơi vào KQTC và giá trị nhỏ nhất 0 biểu thị DN có tài chính bình thường. Giá trị trung bình 0.0849 cho thấy trung bình tỷ lệ doanh nghiệp rơi vào KQTC là 8.49%, điều này cho thấy phần lớn DN trong mẫu duy trì được tình hình tài chính ổn định.

4.2 PHÂN TÍCH TƯƠNG QUAN GIỮA CÁC BIẾN

Ma trận tương quan là một công cụ thống kê quan trọng nhằm xác định và lượng hóa mối quan hệ tuyến tính giữa các cặp biến định lượng trong tập dữ liệu nghiên cứu. Cụ thể, mỗi phần tử trong ma trận tương quan thể hiện hệ số tương quan giữa hai biến, với giá trị dao động trong khoảng từ -1 đến +1. Hệ số này cho biết mức độ và chiều hướng của mối liên hệ tuyến tính giữa các biến. Khi hệ số tương quan tiến gần đến +1, điều đó cho thấy hai biến có xu hướng tăng hoặc giảm

cùng nhau. Ngược lại, nếu hệ số tiến gần -1 , thì khi một biến tăng, biến kia có xu hướng giảm. Cuối cùng, hệ số gần 0 phản ánh mối quan hệ tuyến tính yếu hoặc không tồn tại mối liên hệ giữa hai biến.



Hình 4. 1 Kết quả phân tích tương quan các biến

Nguồn: Tổng hợp từ tác giả

Thông qua kết quả ở hình 4.1 có thể thấy hai biến WCTA và TLTA có mối tương quan nghịch mạnh nhất với hệ số tương quan ghi nhận giá trị là -0.609 . Điều này có thể lý giải rằng khi doanh nghiệp có tỷ trọng tài sản lưu động cao thường ít phải phụ thuộc vào nợ vay dài hạn để duy trì hoạt động trong khi các doanh nghiệp yếu về thanh khoản thường gia tăng sử dụng đòn bẩy làm tăng rủi ro tài chính. Kế đến, biến EBITTA tồn tại mối tương quan đáng kể với cả biến TLTA và OCFTL với

hệ số tương quan lần lượt là -0.213 và 0.419. Điều này hàm ý rằng doanh nghiệp có khả năng tạo ra lợi nhuận ổn định thường ít phụ thuộc vào nợ vay và đồng thời có năng lực tạo dòng tiền đủ mạnh để đáp ứng nghĩa vụ tài chính. Bên cạnh đó, ghi nhận mối tương quan dương giữa TLTA và SIZE với hệ số có giá trị là 0.340. Kết quả này phản ánh rằng các doanh nghiệp có quy mô lớn hơn thường sử dụng đòn bẩy tài chính cao hơn, điều này có thể lý giải vì doanh nghiệp lớn thường có khả năng tiếp cận tín dụng tốt hơn và chấp nhận mức đòn bẩy cao hơn. Mặt khác, có thể thấy được mối tương quan giữa các biến còn lại là tương đối yếu vì hệ số giữa các cặp biến đều có giá trị tuyệt đối nhỏ hơn 0.3.

Tổng thể, kết quả từ ma trận tương quan cho thấy phần lớn các biến độc lập trong mô hình có mối quan hệ tuyến tính từ yếu đến trung bình với hệ số tương quan tuyệt đối không có cặp nào vượt quá ngưỡng 0.8 – mức mà thường được coi là dấu hiệu cảnh báo hiện tượng đa cộng tuyến nghiêm trọng (Gujarati, 2009). Tuy nhiên, Gujarati (2009) nhận định hệ số tương quan cao chỉ là điều kiện đủ chứ không cần để xảy ra đa cộng tuyến, nghĩa là hiện tượng này vẫn có thể tồn tại ngay cả khi các tương quan cặp ở mức thấp. Do đó, để đảm bảo độ tin cậy cho mô hình định lượng, nghiên cứu sẽ tiếp tục kiểm định hiện tượng đa cộng tuyến bằng chỉ số phóng đại phương sai (Variance Inflation Factor – VIF). VIF cho biết mức độ mà phương sai của ước lượng hồi quy tuyến tính bị phóng đại do sự tương quan tuyến tính giữa một biến với các biến giải thích còn lại trong mô hình. Chỉ số VIF dưới 5 thường được xem là mức an toàn cho thấy hiện tượng đa cộng tuyến không đáng kể.

Bảng 4. 2 Kết quả kiểm định VIF

Biến	VIF
WCTA	1.6696
EBITTA	1.4160
SALESTA	1.2056
OCFTL	1.3073
TLTA	1.8961
SIZE	1.3577


GROWTH	1.0146
GDP	1.0637
CPI	1.0427
PTB	1.1719

Nguồn: Tổng hợp từ tác giả

Kết quả từ bảng 4.2 cho thấy toàn bộ các biến đều có chỉ số VIF dao động trong khoảng 1.0146 đến 1.8961, thấp hơn nhiều so với các ngưỡng cảnh báo phổ biến. Việc không ghi nhận biến nào có VIF vượt ngưỡng cho thấy phần lớn các biến độc lập trong mô hình không có mối liên hệ tuyến tính rõ rệt với nhau. Đồng thời, sự phân tán thấp trong mối tương quan cũng cho thấy mỗi biến có thể cung cấp thông tin riêng biệt, bổ sung lẫn nhau. Đây là cơ sở thuận lợi để đưa các biến này vào mô hình dự báo mà không gây sai lệch lớn trong ước lượng hệ số.

4.3 KẾT QUẢ MÔ HÌNH

4.3.1 Kết quả mô hình hồi quy Logistic



Hình 4. 2 Ma trận nhầm lẫn của mô hình Logistic Regression

Nguồn: Tổng hợp từ tác giả

Ma trận nhầm lẫn trong hình 4.1 cho thấy mô hình Logistic Regression đã nhận diện đúng 750 doanh nghiệp kiệt quệ và 678 doanh nghiệp không kiệt quệ. Tuy nhiên, vẫn còn 151 doanh nghiệp thực tế kiệt quệ bị bỏ sót và 164 doanh nghiệp không kiệt quệ lại bị mô hình cảnh báo nhầm là có rủi ro. Điều này cho thấy mô hình vẫn còn đưa ra một số cảnh báo sai đối với các doanh nghiệp thực tế không

gặp rủi ro và chưa có khả năng nhận diện đầy đủ các doanh nghiệp có nguy cơ kiệt quệ.


Bảng 4. 3 Kết quả dự đoán của mô hình Logistic Regression

Chỉ số	Accuracy	Precision	Recall	Specificity	F1-score	AUC
Mô hình LR	0.8193	0.8206	0.8324	0.8052	0.8264	0.9029

Nguồn: Tổng hợp từ tác giả

Kết quả dự báo của mô hình LR là tương đối tốt khi đạt độ chính xác (Accuracy) là 81.93%. Chỉ số Precision đạt 82.06% cho thấy trong số các doanh nghiệp được mô hình dự đoán là kiệt quệ thì có hơn 82% là chính xác. Đồng thời, Recall đạt 83.24% cho thấy mô hình phát hiện hơn 83% các doanh nghiệp thực sự có dấu hiệu rơi vào tình trạng kiệt quệ tài chính. Với Specificity đạt 80.52%, khả năng loại bỏ các doanh nghiệp không rơi vào tình trạng kiệt quệ của mô hình là khá chính xác. Chỉ số F1-score đạt 82.64% cho thấy sự cân bằng tương đối tốt giữa Precision và Recall, đặc biệt quan trọng trong các bài toán có rủi ro khi phân loại sai. Đáng chú ý nhất là AUC đạt 0.9029 chứng tỏ mô hình có năng lực phân biệt tốt hai nhóm doanh nghiệp kiệt quệ và không kiệt quệ.

4.3.2 Kết quả mô hình Cây quyết định



Hình 4. 3 Ma trận nhầm lẫn của mô hình Decision Tree

Nguồn: Tổng hợp từ tác giả

Ma trận nhầm lẫn của mô hình Decision Tree cho thấy mô hình đã phân loại đúng 814 doanh nghiệp bị KQTC và 753 doanh nghiệp không bị KQTC. Tuy nhiên, vẫn còn 87 doanh nghiệp rơi vào KQTC bị bỏ sót và 89 doanh nghiệp khỏe mạnh bị cảnh báo nhầm. So với mô hình LR, mô hình DT thể hiện khả năng nhận diện tốt hơn và cân đối hơn giữa hai loại sai lệch, cải thiện về cả số lượng DN có rủi ro bị bỏ sót và số lượng DN bị cảnh báo sai.


Bảng 4. 4 Kết quả dự đoán của mô hình Decision Tree

Chỉ số	Accuracy	Precision	Recall	Specificity	F1-score	AUC
Mô hình DT	0.8990	0.9014	0.9034	0.8943	0.9024	0.8989

Nguồn: Tổng hợp từ tác giả

Kết quả từ bảng 4.4 cho thấy mô hình DT đạt hiệu suất phân loại rất tốt khi có Accuracy đạt 89.90%. Độ chính xác dự đoán kiệt quệ (Precision) đạt 90.14% và khả năng phát hiện doanh nghiệp kiệt quệ (Recall) là 90.34% cho thấy mô hình phát hiện được phần lớn các doanh nghiệp thật sự gặp khủng hoảng tài chính. Đồng thời, cả Specificity và F1-score đều cho kết quả tốt với giá trị lần lượt là 89.43% và 90.24% cho thấy mô hình hoạt động cân bằng và hiệu quả trong việc giảm thiểu cả báo động giả và bỏ sót DN. Với AUC đạt 0.8989, mô hình DT cũng thể hiện tốt năng lực phân biệt giữa DN khỏe mạnh và DN gặp khó khăn tài chính.

4.3.3 Kết quả mô hình Rừng ngẫu nhiên



Hình 4. 4 Ma trận nhầm lẫn của mô hình Randon Forest

Nguồn: Tổng hợp từ tác giả

Mô hình Random Forest cho thấy kết quả khá nổi bật với 869 doanh nghiệp kiệt quệ và 803 doanh nghiệp không kiệt quệ được nhận diện đúng. Đồng thời, số lượng doanh nghiệp bị bỏ sót và cảnh báo nhầm cũng đều giảm đáng kể (32 trường hợp và 39 trường hợp). Có thể nói RF thể hiện khả năng phân loại DN một cách cân bằng và ổn định hơn khá nhiều so với mô hình LR và DC.

Bảng 4. 5 Kết quả dự đoán của mô hình Random Forest


Chỉ số	Accuracy	Precision	Recall	Specificty	F1-score	AUC
Mô hình RF	0.9593	0.9570	0.9645	0.9537	0.9608	0.9936

Nguồn: Tổng hợp từ tác giả

Từ bảng 4.5, có thể thấy mô hình RF có kết quả rất ấn tượng và khá toàn diện trong việc dự báo. Tất cả các chỉ số đánh giá chính đều vượt ngưỡng 95%, phản ánh một mô hình không chỉ mạnh về khả năng nhận diện mà còn ổn định trên cả hai chiều phân loại. Cụ thể, Recall đạt 96.45% cho thấy mô hình có khả năng bao phủ gần như toàn bộ các doanh nghiệp bị kiệt quệ. Đồng thời, Specificity đạt 95.37% thể hiện mức độ chính xác rất cao trong việc loại trừ doanh nghiệp không gặp phải khó khăn tài chính. Với Precision và F1-score lần lượt đạt 95.70% và 96.08%, thể hiện mô hình duy trì tốt sự cân bằng giữa độ chính xác và độ bao phủ

trong việc nhận diện DN. Bên cạnh đó, AUC ghi nhận giá trị 0.9936, gần như tiệm cận mức hoàn hảo, phản ánh năng lực phân biệt hai nhóm doanh nghiệp (rủi ro và không rủi ro) ở mức xuất sắc.

4.3.4 Kết quả mô hình XGBoost



Hình 4. 5 Ma trận nhầm lẫn của mô hình XGBoost

Nguồn: Tổng hợp từ tác giả

Mô hình XGBoost đã phản ánh hiệu quả phân loại ẩn tượng với số lượng 867 DN kiệt quệ và 825 DN không bị kiệt quệ được dự đoán chính xác. Thêm vào đó, chỉ ghi nhận 34 trường hợp bị bỏ sót và 17 trường hợp cảnh báo sai, mô hình XGBoost không chỉ thể hiện độ chính xác cao mà còn có khả năng kiểm soát rất tốt cả hai loại sai lệch một cách vượt trội so với các mô hình trước đó.

Bảng 4. 6 Kết quả dự đoán của mô hình XGBoost


Chỉ số	Accuracy	Precision	Recall	Specificty	F1-score	AUC
Mô hình XGB	0.9707	0.9808	0.9623	0.9798	0.9714	0.9963

Nguồn: Tổng hợp từ tác giả

Kết quả cho thấy XGBoost là mô hình có năng lực vượt trội và tiệm cận mức tối ưu trong việc dự báo KQTC. Với Accuracy đạt 97.07%, mô hình cho thấy khả năng dự báo chính xác gần như tuyệt đối. Precision đạt 98.08% và Recall đạt 96.23% thể hiện độ bao phủ trong đa số các trường hợp DN bị KQTC và mô hình hầu như không đưa ra cảnh báo sai, gần như tất cả các DN bị dự báo là KQTC đều thực sự có rủi ro. Specificity đạt 97.98% tiếp tục khẳng định khả năng nhận diện

chính xác các DN khỏe mạnh. Với F1-score lên tới 97.14%, mô hình duy trì sự cân bằng gần như hoàn hảo giữa độ chính xác và khả năng phân loại. Cuối cùng, AUC đạt 0.9963 khẳng định năng lực phân biệt gần như hoàn hảo của XGB. Có thể nói, mô hình XGB thể hiện hiệu suất vượt trội và ổn định trên nhiều khía cạnh so với các mô hình trước đó.

4.3.5 Kết quả mô hình mạng nơ-ron nhân tạo



Hình 4. 6 Ma trận nhầm lẫn của mô hình ANN

Nguồn: Tổng hợp từ tác giả

Có thể thấy mô hình ANN đã dự đoán đúng 827 doanh nghiệp gặp khó khăn tài chính và 742 doanh nghiệp có tình hình tài chính ổn định. Tuy nhiên, vẫn còn 74 doanh nghiệp rủi ro bị bỏ sót và 100 doanh nghiệp không rủi ro bị cảnh báo sai. Tuy không nổi trội nhưng kết quả này cho thấy ANN cũng đạt mức độ phân loại khá ổn.

Bảng 4. 7 Kết quả dự đoán của mô hình ANN

Chỉ số	Accuracy	Precision	Recall	Specificty	F1-score	AUC
Mô hình ANN	0.9002	0.8921	0.9179	0.8812	0.9048	0.9626

Nguồn: Tổng hợp từ tác giả

Kết quả của mô hình ANN thể hiện hiệu suất dự báo khá tốt và ổn định. Cụ thể, Accuracy đạt 90.02% cho thấy mô hình phân loại đúng phần lớn các trường hợp trong tập dữ liệu. Precision đạt 89.21%, phản ánh độ chính xác tương đối cao trong việc cảnh báo các doanh nghiệp thực sự có rủi ro. Đáng chú ý, Recall ở mức

91.79% cho thấy ANN có khả năng bao phủ tốt các doanh nghiệp đang gặp khó khăn tài chính. Specificity đạt 88.12% cũng cho thấy mô hình cũng có khả năng nhận diện hiệu quả các doanh nghiệp không rơi vào tình trạng KQTC. Mô hình với giá trị F1-score đạt 90.48% cũng phản ánh sự cân bằng tốt giữa độ bao phủ và độ chính xác trong cảnh báo. Cuối cùng, AUC đạt 0.9626 chứng tỏ mô hình có năng lực phân biệt mạnh mẽ giữa doanh nghiệp có và không có rủi ro. Mặc dù không nổi bật như XGB hay RF, mô hình ANN vẫn thể hiện độ hiệu quả tốt và cân bằng giữa các chỉ số.

4.3.6 So sánh các mô hình

Bảng 4. 8 Tổng hợp kết quả của các mô hình

Mô hình	Accuracy	Precision	Recall	Specificity	F1-score
Logistic Regression	0.8193	0.8206	0.8324	0.8052	0.8264
Decision Tree	0.8990	0.9014	0.9034	0.8943	0.9024
Random Forest	0.9593	0.9570	0.9645	0.9537	0.9608
XGBoost	0.9707	0.9808	0.9623	0.9798	0.9714
ANN	0.9002	0.8921	0.9179	0.8812	0.9048

(Nguồn: Kết quả tính toán từ tác giả)

Từ bảng 4.8, có thể nhận thấy rằng cả năm mô hình được triển khai trong nghiên cứu đều đạt hiệu suất dự báo ở mức từ tốt đến rất tốt với tất cả các chỉ số đánh giá đều đạt giá trị hơn 80%. Điều này cho thấy các mô hình đều có tiềm năng ứng dụng trong việc dự báo rủi ro kiệt quệ tài chính của các doanh nghiệp phi tài chính trên TTCK Việt Nam.


Trước hết, Logistic Regression là một mô hình tuyến tính cơ bản, tuy không đạt hiệu suất cao như các mô hình phi tuyến nhưng vẫn cho thấy mức độ ổn định với Accuracy đạt 81.93% và các chỉ số còn lại quanh mức 80–83%. Mô hình LR đóng vai trò là mô hình nền tảng trong việc đánh giá rủi ro KQTC với ưu điểm là đơn giản, dễ triển khai và khả năng diễn giải rõ ràng.

Tiếp theo, mô hình Decision Tree mang lại hiệu suất vượt trội hơn rõ rệt so với Logistic Regression, với các chỉ số đều xấp xỉ mức 90%. Ngoài hiệu năng, DT còn có ưu điểm là khả năng trực quan hóa, là lựa chọn phù hợp cho các tổ chức cần mô hình minh bạch, dễ hiểu để hỗ trợ ra quyết định.

Kế đến là mô hình Random Forest thể hiện sự vượt trội khi không chỉ đạt Accuracy gần 96% mà còn duy trì tốt sự cân bằng giữa Precision, Recall và Specificity. RF đã thể hiện năng lực nhận diện hiệu quả các doanh nghiệp có nguy cơ KQTC đồng thời kiểm soát tốt tỷ lệ cảnh báo sai cho thấy tính ổn định và độ tin cậy cao trong dự báo. Có thể nói, Random Forest là mô hình có khả năng tổng quát tốt và phù hợp để triển khai trong các tổ chức cần một giải pháp dự báo chính xác và ổn định.

Trong số các mô hình, có thể nhận thấy rằng XGBoost là mô hình có hiệu suất vượt trội nhất. Mô hình này dẫn đầu tất cả các chỉ số với Accuracy 97.07%, Precision 98.08%, Recall 96.23%, Specificity 97.98% và F1-score 97.14%. So với RF, mô hình XGB chỉ nhỉnh hơn một vài phần trăm nhưng sự ổn định và đồng đều đã đưa mô hình này trở thành ứng viên hàng đầu để ứng dụng trong các việc dự báo tình trạng KQTC của các DN.

Cuối cùng, Artificial Neural Network cũng cho thấy hiệu suất dự báo khá cân bằng và hiệu quả với các chỉ số đánh giá đều nằm trong khoảng từ 88% đến trên 92%. Dù chưa đạt mức tối ưu như RF hay XGB, ANN vẫn là mô hình có tiềm năng phát triển lớn, nhất là trong các bối cảnh yêu cầu xử lý dữ liệu đầu vào đa chiều




Hình 4. 7 Đường cong ROC của các mô hình

hoặc phi tuyến.

Nguồn: Tổng hợp từ tác giả

Từ hình 4.7 có thể thấy đường ROC thể hiện rõ sự khác biệt về hiệu suất phân loại giữa các mô hình được triển khai trong nghiên cứu. Nhìn chung, tất cả các mô hình đều đạt diện tích dưới đường cong (AUC) trên 89% cho thấy tất cả các mô hình đều có khả năng phân biệt rõ ràng giữa doanh nghiệp có bị kiệt quệ và không bị kiệt quệ. Trong số các mô hình, XGBoost và Random Forest có AUC cao nhất (lần lượt là 0.9963 và 0.9936) phản ánh khả năng phân biệt gần như hoàn hảo giữa các DN. Đồng thời, hai mô hình này cũng có đường cong ROC nằm gần sát góc trên bên trái phản ánh khả năng dự báo mạnh mẽ và ổn định. Kế đến là Artificial Neural Networks cũng đạt kết quả rất tốt với AUC là 0.9626, thể hiện khả năng nhận diện rủi ro hiệu quả trong môi trường phi tuyến. Sau cùng, Logistic Regression và Decision Tree có AUC lần lượt là 0.9029 và 0.8989. Mặc dù hai mô hình này vẫn đạt mức AUC xấp xỉ 90% nhưng đường ROC thể hiện chúng có mức độ phân biệt hai nhóm kém hơn rõ rệt, nhất là Decision Tree với đường cong gãy khúc và độ dốc kém ổn định phản ánh khả năng phân biệt vẫn còn những hạn chế so với các mô hình khác.

Tổng thể, cả năm mô hình được áp dụng trong nghiên cứu đều thể hiện năng lực nhất định trong việc dự báo tình trạng kiệt quệ tài chính của doanh nghiệp. Đặc biệt, mô hình XGBoost đã chứng minh hiệu năng vượt trội cả về độ chính xác lẫn khả năng phân biệt so với các mô hình còn lại.



Hình 4. 8 Biểu đồ SHAP của mô hình XGBoost

4.4 ĐÁNH GIÁ BIẾN ĐẶC TRƯNG QUAN TRỌNG

Nguồn: Tác giả tổng hợp

Từ biểu đồ SHAP, có thể thấy EBITTA là biến có giá trị SHAP trung bình cao nhất, đạt +2.21 cho thấy EBITTA là yếu tố được coi là quan trọng nhất trong việc dự báo khả năng doanh nghiệp rơi vào tình trạng kiệt quệ tài chính. Biểu đồ beeswarm thể hiện rõ mối quan hệ ngược chiều giữa EBITTA và xác suất kiệt quệ: khi EBITTA thấp (điểm màu xanh), SHAP có xu hướng dương, tức mô hình dự báo rủi ro cao hơn; ngược lại, EBITTA cao (điểm màu đỏ) kéo SHAP về âm làm giảm xác suất dự báo. Điều này là hoàn toàn hợp lý vì EBITTA cao cho thấy doanh nghiệp có khả năng tạo ra lợi nhuận tốt từ hoạt động kinh doanh, dòng tiền ổn định và có thể tự trang trải chi phí giúp giảm rủi ro tài chính. Ngược lại, EBITTA thấp đồng nghĩa với việc hoạt động kinh doanh không hiệu quả, dòng tiền yếu, dễ dẫn đến mất cân đối tài chính và không đủ khả năng trả nợ làm tăng nguy cơ kiệt quệ. Việc EBITTA có giá trị đứng đầu và có chiều hướng tác động rõ ràng khẳng định đây là biến quan trọng nhất trong việc phân loại tình trạng tài chính doanh nghiệp. Kết quả này cũng đồng nhất với các nghiên cứu của Bình và cộng sự (2018), Lê Hồng Ngọc và cộng sự (2023) và Thao và cộng sự (2023).

SALESTA là biến có giá trị SHAP cao thứ hai với giá trị +1.3 cho thấy SALESTA có vai trò ổn định trong dự báo kiệt quệ tài chính. Chỉ số này đo lường

khả năng tạo doanh thu từ tài sản mà doanh nghiệp đang có. Nếu một doanh nghiệp có nhiều tài sản nhưng không tạo ra được doanh thu tương xứng, điều đó cho thấy tài sản đang bị sử dụng không hiệu quả và làm tăng rủi ro về tài chính. Biểu đồ beeswarm cũng cho thấy mối quan hệ ngược chiều giữa SALESTA và rủi ro: SALESTA thấp làm tăng SHAP (tức tăng xác suất kiệt quệ), còn SALESTA cao giúp giảm xác suất. Khi SALESTA cao, doanh nghiệp tận dụng tài sản tốt, tạo ra doanh thu đều đặn, từ đó có dòng tiền ổn định để chi trả chi phí và nghĩa vụ tài chính. Ngược lại, SALESTA thấp là dấu hiệu cảnh báo về hiệu suất hoạt động, và nếu kéo dài sẽ khiến dòng tiền thiếu hụt, dễ dẫn đến tình trạng tài chính xấu. Kết quả này cũng tương đồng với các nghiên cứu của Widhiari và Merkusiwati (2015) và Phạm Thị Hồng Vân (2018).

TLTA có giá trị SHAP trung bình +1.09, đứng thứ ba sau EBITTA và SALESTA. TLTA phản ánh mức độ sử dụng nợ của doanh nghiệp so với tổng tài sản. Khi doanh nghiệp vay nợ nhiều, áp lực trả nợ cao, nếu dòng tiền yếu thì nguy cơ rơi vào khủng hoảng sẽ lớn. Biểu đồ beeswarm cho thấy TLTA có mối quan hệ cùng chiều với xác suất kiệt quệ: TLTA cao kéo SHAP lên làm tăng xác suất; TLTA thấp thì SHAP giảm, tức rủi ro thấp hơn. Điều này có nghĩa là doanh nghiệp dùng nhiều nợ (tức TLTA cao) thì rủi ro tài chính cao hơn, đặc biệt khi không đủ dòng tiền để trả nợ đúng hạn. Ngược lại, nếu doanh nghiệp chủ yếu sử dụng vốn chủ sở hữu (TLTA thấp) thì khả năng chống chịu trước biến động tài chính sẽ tốt hơn. Kết quả này cũng phù hợp với các nghiên cứu của Tinoco và Wilson (2013), Huỳnh Thị Cẩm Hà và cộng sự (2017), Phạm Thị Hồng Vân (2018) và Thao và cộng sự (2023).

Nhìn chung, cả ba biến EBITTA, SALESTA và TLTA đều là những yếu tố có ảnh hưởng lớn, ổn định và dễ diễn giải trong việc dự báo nguy cơ kiệt quệ tài chính của doanh nghiệp. Không chỉ có giá trị SHAP trung bình cao, ba biến này còn thể hiện chiều hướng tác động rõ ràng và ổn định. Kết quả này khẳng định rằng ba yếu tố cốt lõi trong việc đánh giá sức khỏe tài chính và xác định mức độ rủi ro kiệt quệ của doanh nghiệp là khả năng sinh lời, hiệu quả khai thác tài sản và mức độ đòn bẩy tài chính.

KẾT LUẬN CHƯƠNG 4

Chương 4 đã trình bày và phân tích kết quả của năm mô hình học máy trong việc dự báo kiệt quệ tài chính từ dữ liệu của 476 doanh nghiệp niêm yết. Kết quả cho thấy tất cả mô hình đều cho được hiệu suất rất tốt, đặc biệt là mô hình XGBoost và Random Forest với kết quả nổi bật nhất. Giá trị SHAP cho thấy ba biến EBITTA, SALESTA và TLTA đóng vai trò quan trọng trong việc dự báo kiệt quệ tài chính. Trong đó, EBITTA và SALESTA có mối quan hệ ngược chiều với xác suất kiệt quệ, còn TLTA lại có mối quan hệ cùng chiều.

CHƯƠNG 5: KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ

Chương này rút ra kết luận của bài nghiên cứu và dựa vào đó để đề xuất một số hàm ý quản trị cho các doanh nghiệp đồng thời nêu những hạn chế của đề tài và đề xuất hướng đi tiếp theo.

5.1 KẾT LUẬN

Dựa trên bộ dữ liệu gồm ba nhóm biến tài chính, thị trường và vĩ mô từ 476 doanh nghiệp phi tài chính niêm yết trên thị trường chứng khoán Việt Nam trong giai đoạn 2015 – 2024, nghiên cứu đã tiến hành phân tích và so sánh hiệu suất của năm mô hình học máy trong dự báo tình trạng KQTC, bao gồm: Logistic Regression, Decision Tree, Random Forest, XGBoost và ANN. Kết quả cho thấy tất cả các mô hình đều đạt hiệu suất cao với độ chính xác dự báo trên 80%, trong đó nổi bật nhất là XGBoost với độ chính xác là 97.07%. Ngoài ra, các biến có ảnh hưởng lớn đến khả năng dự báo KQTC được tìm thấy gồm: EBITTA (tỷ lệ lợi nhuận trước lãi vay và thuế trên tổng tài sản), SALESTA (tỷ lệ doanh thu trên tổng tài sản), TLTA (tỷ lệ tổng nợ trên tổng tài sản). Kết quả phân tích SHAP cho thấy EBITTA và SALESTA có mối quan hệ nghịch chiều với xác suất kiệt quệ, tức khi giá trị các biến này tăng, xác suất rơi vào tình trạng kiệt quệ có xu hướng giảm. Ngược lại, TLTA thể hiện mối quan hệ cùng chiều với khả năng KQTC, phản ánh rằng tỷ lệ nợ cao thường đi kèm với rủi ro tài chính gia tăng.

5.2 HÀM Ý QUẢN TRỊ

Ứng dụng mô hình học máy

Kết quả nghiên cứu cho thấy các mô hình học máy được triển khai đều đạt hiệu suất dự báo rất cao trong việc phân loại và cảnh báo sớm doanh nghiệp có nguy cơ kiệt quệ tài chính. Các doanh nghiệp nên chủ động tích hợp công nghệ học máy vào hệ thống quản trị rủi ro tài chính, đặc biệt là trong hoạt động phân tích dữ liệu và ra quyết định. Mô hình học máy cho phép khai thác dữ liệu tài chính và phi tài chính theo hướng toàn diện hơn, giúp phát hiện sớm các tín hiệu bất thường, từ đó đưa ra cảnh báo kịp thời trước khi rủi ro chuyển hóa thành khủng hoảng. Việc áp dụng các mô hình này có thể giúp doanh nghiệp xây dựng hệ thống đánh giá sức

khỏe tài chính định kỳ và tự động, hỗ trợ ban lãnh đạo ra quyết định kịp thời trong việc tái cấu trúc tài chính, kiểm soát chi phí hoặc điều chỉnh chiến lược tăng trưởng khi cần thiết. Đồng thời, thông qua việc giải thích mô hình như SHAP, doanh nghiệp còn có thể xác định được các yếu tố trọng yếu ảnh hưởng đến nguy cơ kiệt quệ của mình, từ đó tập trung cải thiện những điểm yếu tài chính cũng như tạo tiền đề để hoạch định các chính sách tài chính và đầu tư phù hợp với từng giai đoạn phát triển.

Nâng cao hiệu quả sinh lời trên tài sản

Doanh nghiệp cần tập trung cải thiện lợi nhuận hoạt động so với tổng tài sản bằng cách tối ưu hóa chi phí vận hành và nâng cao hiệu quả sử dụng tài sản. Trước hết, doanh nghiệp cần tăng cường quản trị chi phí thông qua việc rà soát và loại bỏ các khoản chi không cần thiết. Điều này có thể thực hiện bằng cách ứng dụng công nghệ số hoặc các công cụ kiểm soát nội bộ để theo dõi, phân tích chi phí theo từng bộ phận từ đó tối ưu hóa chi phí và tránh lãng phí nguồn lực. Đồng thời, việc tối ưu hóa sử dụng TS cũng đóng vai trò quan trọng. Doanh nghiệp nên thường xuyên đánh giá hiệu suất của tài sản, thanh lý những TS kém hiệu quả đồng thời đầu tư vào máy móc, công nghệ hiện đại nhằm nâng cao năng suất, kéo dài vòng đời sử dụng. Bên cạnh đó, các quyết định đầu tư cần được thực hiện một cách thận trọng và có cơ sở thông qua việc sử dụng các công cụ phân tích tài chính như NPV, IRR hoặc ROA,.. để đảm bảo lựa chọn được những dự án có tỷ suất sinh lời cao và khả năng tạo dòng tiền ổn định. Việc nâng cao EBITTA không chỉ góp phần cải thiện hiệu quả hoạt động của DN mà còn củng cố năng lực tài chính, giúp doanh nghiệp duy trì ổn định và giảm thiểu nguy cơ kiệt quệ trong bối cảnh biến động kinh tế.

Tối ưu hóa doanh thu trên tài sản

Bên cạnh việc cải thiện khả năng sinh lời, doanh nghiệp cũng cần chú trọng đến chỉ số doanh thu trên tài sản bằng cách đầu tư vào các chiến lược như mở rộng thị trường hoặc nâng cao năng suất. Việc đẩy mạnh hoạt động bán hàng và mở rộng thị trường tiêu thụ là yếu tố cốt lõi giúp gia tăng doanh thu và tối ưu hóa vòng quay tài sản. DN cần chú trọng đầu tư vào hệ thống phân phối, tiếp cận thị trường mới

đồng thời ứng dụng các kênh bán hàng hiện đại và nâng cao năng lực đội ngũ bán hàng và hiệu quả marketing để mở rộng quy mô tiêu thụ. Tiếp theo, DN phải thường xuyên cập nhật nhu cầu thị trường và liên tục cải tiến các sản phẩm, dịch vụ của mình để duy trì lượng khách hàng hiện tại cũng như thu hút thêm khách hàng mới giúp gia tăng doanh thu. Thêm vào đó, việc tận dụng tối đa TS hiện có để tạo ra doanh thu cũng là một giải pháp phù hợp tránh tình trạng TS bị nhàn rỗi hoặc sử dụng kém hiệu quả. Doanh nghiệp nên đánh giá lại hiệu suất sử dụng TS cũng như điều phối chúng linh hoạt giữa các bộ phận. Bên cạnh đó, việc triển khai các mô hình kinh doanh linh hoạt như cho thuê, liên doanh hoặc hợp tác khai thác TS để tối đa hóa giá trị sử dụng cũng sẽ góp phần làm tăng doanh thu cũng như giảm lãng phí chi phí cơ hội. Bằng cách tăng tốc độ quay vòng tài sản thông qua gia tăng doanh thu và cải thiện hiệu suất khai thác TS, doanh nghiệp sẽ tăng được khả năng tạo dòng tiền từ đó củng cố năng lực tài chính trong dài hạn.

Kiểm soát tỷ lệ nợ trên tổng tài sản

Doanh nghiệp cần kiểm soát tỷ lệ nợ trên tổng tài sản, tránh vay nợ quá mức để giảm áp lực thanh toán. Để kiểm soát rủi ro này, doanh nghiệp cần chủ động duy trì một tỷ lệ nợ ở mức hợp lý, phù hợp với năng lực tài chính và khả năng tạo dòng tiền từ hoạt động kinh doanh của DN. Việc cân đối giữa nợ và vốn chủ sở hữu là điều kiện tiên quyết để hạn chế áp lực trả nợ định kỳ, tránh phụ thuộc quá mức vào nguồn tài trợ bên ngoài, nhất là trong các giai đoạn kinh tế khó khăn hoặc lãi suất biến động. Bên cạnh đó, doanh nghiệp nên ưu tiên sử dụng VCSH cho các hoạt động đầu tư dài hạn như mở rộng sản xuất, mua sắm TS cố định hoặc đầu tư chiến lược. Việc dùng VCSH cho các khoản đầu tư mang tính dài hạn sẽ giúp giảm thiểu rủi ro tài chính và đảm bảo tính linh hoạt trong quản trị dòng tiền. Ngoài ra, cần thiết lập kế hoạch tài chính rõ ràng và minh bạch nhằm kiểm soát nợ vay một cách hiệu quả. Doanh nghiệp nên xây dựng các kịch bản tài chính để đánh giá khả năng trả nợ trong các điều kiện khác nhau, đồng thời giám sát chặt chẽ các chỉ số như hệ số nợ, khả năng thanh toán lãi vay hoặc EBITDA trên lãi vay. Việc chủ động đánh giá và kiểm soát rủi ro tài chính sẽ giúp doanh nghiệp ứng phó kịp thời với các cú

sốc từ bên ngoài. Một cơ cấu vốn hợp lý, kế hoạch vay nợ được kiểm soát chặt chẽ và định hướng sử dụng vốn bền vững sẽ giúp doanh nghiệp duy trì ổn định tài chính và nâng cao năng lực cạnh tranh trong dài hạn.

5.3 HẠN CHẾ CỦA ĐỀ TÀI VÀ HƯỚNG NGHIÊN CỨU TIẾP THEO

5.3.1 Hạn chế của đề tài

Mặc dù nghiên cứu đã cung cấp những kết quả khá tích cực trong việc dự báo tình trạng kiệt quệ tài chính cho các doanh nghiệp phi tài chính niêm yết tại Việt Nam nhưng vẫn còn tồn tại một số hạn chế nhất định. Trước hết, trên thị trường chứng khoán hiện tại có đến hơn 1500 doanh nghiệp đang hoạt động nhưng mẫu nghiên cứu chỉ bao gồm 476 doanh nghiệp khiến cho số lượng mẫu nghiên cứu đang còn khá khiêm tốn và chưa đại diện được cho tổng thể thị trường. Bên cạnh đó, mặc dù nghiên cứu đã có sự kết hợp giữa ba nhóm biến thị trường, tài chính và vĩ mô nhưng số lượng biến trong mỗi nhóm còn khá ít, chưa phản ánh được đầy đủ các yếu tố tác động đến tình trạng KQTC.

5.3.2 Hướng nghiên cứu tiếp theo

Nhằm khắc phục những hạn chế kể trên, các nghiên cứu trong tương lai có thể tiến hành mở rộng số lượng doanh nghiệp trong mẫu nghiên cứu bao gồm tất cả các DN trên cả ba sàn HOSE, HNX và UPCoM. Thêm vào đó, có thể bổ sung thêm các biến quan trọng khác cho các nhóm biến tài chính, thị trường và vĩ mô đồng thời đưa thêm các yếu tố phi tài chính như trình độ học vấn, kinh nghiệm quản lý, văn hóa doanh nghiệp,... vào mô hình để giúp phản ánh đầy đủ hơn các đặc điểm nội tại của DN.

KẾT LUẬN CHƯƠNG 5

Chương này đã trình bày kết quả cuối cùng của bài nghiên cứu và từ đó đề xuất một vài hàm ý quản trị giúp các doanh nghiệp phi tài chính có thể hạn chế xác suất rơi vào tình trạng kiệt quệ tài chính. Bên cạnh đó, chương này cũng chỉ ra những hạn chế của đề tài và đề xuất một số hướng phát triển cho các nghiên cứu trong tương lai.

TÀI LIỆU THAM KHẢO

Danh mục tài liệu tham khảo tiếng Việt

Huỳnh Thị Cẩm Hà, Nguyễn Thị Uyên & Lê Đào Tuyết Mai. (2017). Sử dụng các mô hình cây phân lớp dự báo kiệt quệ tài chính cho doanh nghiệp Việt Nam. *Tạp chí Khoa học Đại học Mở Thành phố Hồ Chí Minh*, 12(3), 62-76.

Lê Hồng Ngọc, Nguyễn Thế Long, Hồ Thị Lam & Hồ Thu Hoài. (2023). Dự báo kiệt quệ tài chính của các doanh nghiệp Việt Nam: Ứng dụng machine learning. *Tạp chí nghiên cứu Kinh tế và Kinh doanh Châu Á*, 12(34), 35 - 52.

Nguyễn Thị Kim Oanh. (2023). Sử dụng hồi quy Logistic trong dự báo khả năng kiệt quệ tài chính cho các doanh nghiệp niêm yết ngành khai khoáng. *Tạp chí Kinh tế và Dự báo*, 3, 7-11.

Phạm Thị Hồng Vân. (2018). Đo lường khả năng kiệt quệ tài chính tại các công ty cổ phần ngành công nghiệp ở Việt Nam. *Tạp chí Kinh tế và Phát triển*(255), 32 - 41.

Trần Ngọc Thơ, Nguyễn Thị Ngọc Trang, Phan Thị Bích Nguyệt, Nguyễn Thị Liên Hoa & Nguyễn Thị Uyên Uyên. (2007). Tài chính doanh nghiệp hiện đại. In: NXB Thống kê.

Danh mục tài liệu tham khảo tiếng Anh

Agarwal, V., & Taffler, R. J. (2007). Twenty-five years of the Taffler z-score model: Does it really have predictive ability? *Accounting and business research*, 37(4), 285-300.

Aktan, S. (2011). Application of machine learning algorithms for business failure prediction. *Investment Management and Financial Innovations*(8, Iss. 2), 52-65.

Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of finance*, 23(4), 589-609.

Altman, E. I., & Hotchkiss, E. (1993). *Corporate financial distress and bankruptcy* (Vol. 1998): New York: John Wiley & Sons.

Altman, E. I., & Hotchkiss, E. (2010). *Corporate financial distress and bankruptcy: Predict and avoid bankruptcy, analyze and invest in distressed debt* (Vol. 289): John Wiley & Sons.

Amjad, M., Ahmad, I., Ahmad, M., Wróblewski, P., Kamiński, P., & Amjad, U. (2022). Prediction of pile bearing capacity using XGBoost algorithm: modeling and performance evaluation. *Applied Sciences*, 12(4), 2126.

Andrade, G., & Kaplan, S. N. (1998). How costly is financial (not economic) distress? Evidence from highly leveraged transactions that became distressed. *The Journal of finance*, 53(5), 1443-1493.

Asquith, P., Gertner, R., & Scharfstein, D. (1994). Anatomy of financial distress: An examination of junk-bond issuers. *The quarterly journal of economics*, 109(3), 625-658.

Ball, R., & Foster, G. (1982). Corporate financial reporting: A methodological review of empirical research. *Journal of accounting research*, 161-234.

Barboza, F., Kimura, H., & Altman, E. (2017). Machine learning models and bankruptcy prediction. *Expert Systems with Applications*, 83, 405-417.

Beaver, W. H. (1966). Financial ratios as predictors of failure. *Journal of accounting research*, 71-111.

Binh, P. V. N., Trung, D. T., & Duc, V. H. (2018). Financial distress and bankruptcy prediction: An appropriate model for listed firms in Vietnam. *Economic Systems*, 42(4), 616-624.

Campbell, J. Y., Hilscher, J., & Szilagyi, J. (2008). In search of distress risk. *The Journal of finance*, 63(6), 2899-2939.

Charalambakis, E. C., & Garrett, I. (2019). On corporate financial distress prediction: What can we learn from private firms in a developing economy? Evidence from Greece. *Review of Quantitative finance and Accounting*, 52(2), 467-491.

Chava, S., & Jarrow, R. A. (2004). Bankruptcy prediction with industry effects. *Review of finance*, 8(4), 537-569.

Chen, S., & Shen, Z.-D. (2020). Financial distress prediction using hybrid machine learning techniques. *Asian Journal of Economics, Business and Accounting*, 16(2), 1-12.

Christidis, A. C.-Y., & Gregory, A. (2010). Some new models for financial distress prediction in the UK.

Fitzpatrick, P. J. (1932). *A comparison of the ratios of successful industrial enterprises with those of failed companies*.

Gaughan, P. A. (2010). *Mergers, acquisitions, and corporate restructurings*: John Wiley & Sons.

Gilbert, L. R., Menon, K., & Schwartz, K. B. (1990). Predicting bankruptcy for firms in financial distress. *Journal of Business Finance & Accounting*, 17(1).

Gilson, S. C. (1990). Bankruptcy, boards, banks, and blockholders: Evidence on changes in corporate ownership and control when firms default. *Journal of financial economics*, 27(2), 355-387.

Gu, Z. (2002). Analyzing bankruptcy in the restaurant industry: A multiple discriminant model. *International Journal of Hospitality Management*, 21(1), 25-42.

Gujarati, D. N. (2009). Basic econometrics. In: McGraw-Hill.

He, Q., Chong, T. T. L., Li, L., & Zhang, J. (2010). A competing risks analysis of corporate survival. *Financial Management*, 39(4), 1697-1718.

Husein, F. (2015). Precision of the models of Altman, Springate, Zmijewski, and Grover for predicting the financial distress. *Journal of Economics, Business & Accountancy Ventura*.

Kartika, T. P. D. (2018). Impact of Financial Ratio on Financial Distress in Indonesia Manufacturing Companies. *International Journal of Research Science and Management*, 5(9), 93-100.

Kim, S. Y., & Upneja, A. (2014). Predicting restaurant financial distress using decision tree and AdaBoosted decision tree models. *Economic Modelling*, 36, 354-362.

Long, T. K., Anh, L. H., Hien, N. T., & Trung, N. D. (2023). Examining financial distress of the Vietnamese listed firms using accounting-based models. *Plos one*, 18(5), e0284451.

Makridakis, S. (1991). What can we learn from corporate failure? *Long Range Planning*, 24(4), 115-126.

Mare, D. S. (2015). Contribution of macroeconomic factors to the prediction of small bank failures. *Journal of International Financial Markets, Institutions and Money*, 39, 25-39.

Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of accounting research*, 109-131.

Opler, T. C., & Titman, S. (1994). Financial distress and corporate performance. *The Journal of finance*, 49(3), 1015-1040.

Pindado, J., Rodrigues, L., & De la Torre, C. (2008). Estimating financial distress likelihood. *Journal of Business Research*, 61(9), 995-1003.

Platt, H. D., & Platt, M. (2006). Comparing financial distress and bankruptcy. *Review of Applied Economics*, 2(2).

Platt, H. D., & Platt, M. B. (2002). Predicting corporate financial distress: Reflections on choice-based sample bias. *Journal of economics and finance*, 26(2), 184-199.

Platt, H. D., & Platt, M. B. (2008). Financial distress comparison across three global regions. *Journal of Risk and Financial Management*, 1(1), 129-162.

Qu, Y. (2008). Macroeconomic factors and probability of default. *European Journal of Economics, Finance and Administrative Sciences*, 13, 192-215.

Ross, S. R., Rausch, M. K., & Canada, K. E. (2003). Competition and cooperation in the five-factor model: Individual differences in achievement orientation. *The Journal of psychology*, 137(4), 323-337.

Roth, A. E. (1988). *The Shapley value: essays in honor of Lloyd S. Shapley*: Cambridge University Press.

Sabela, S. W., Brummer, L. M., Hall, J. H., & Wolmarans, H. P. (2018). Using fundamental, market and macroeconomic variables to predict financial distress: A study of companies listed on the Johannesburg Stock Exchange. *Journal of economic and financial sciences*, 11(1), 1-11.

Sarker, I. H. (2021). Machine learning: Algorithms, real-world applications and research directions. *SN computer science*, 2(3), 160.

Sharma, S., & Mahajan, V. (1980). Early warning indicators of business failure. *Journal of marketing*, 44(4), 80-89.

Shumway, T. (2001). Forecasting bankruptcy more accurately: A simple hazard model. *The journal of business*, 74(1), 101-124.

Springate, G. L. V. (1978). *Predicting the Possibility of Failure in a Canadian Firm: A Discriminant Analysis*: Simon Fraser University.

Taj, A., Azam, S., & Khalid, G. K. (2017). Prediction of financial distress: A comparative study. *NUML International Journal of Business & Management*, 12(1), 127-144.

Thao, T., Ngoc, N. H., Binh, L. T., Nam, V. T., & Duc, V. H. (2023). Examining financial distress of the Vietnamese listed firms using accounting-based models. *Plos one*, 18(5), e0284451.

Tinoco, M. H., & Wilson, N. (2013). Financial distress and bankruptcy prediction among listed companies using accounting, market and macroeconomic variables. *International review of financial analysis*, 30, 394-419.

Turetsky, H. F., & McEwen, R. A. (2001). An empirical investigation of firm longevity: A model of the ex ante predictors of financial distress. *Review of Quantitative finance and Accounting*, 16, 323-343.

Van Gestel, T., Baesens, B., Van Dijke, P., Garcia, J., Suykens, J. A., & Vanthienen, J. (2006). A process model to develop an internal rating system: Sovereign credit ratings. *Decision Support Systems*, 42(2), 1131-1151.

Wanke, P., Barros, C. P., & Faria, J. R. (2015). Financial distress drivers in Brazilian banks: A dynamic slacks approach. *European Journal of Operational Research*, 240(1), 258-268.

Ward, T. J., & Foster, B. P. (1997). A note on selecting a response measure for financial distress. *Journal of Business Finance & Accounting*, 24(6), 869-879.

Whitaker, R. B. (1999). The early stages of financial distress. *Journal of economics and finance*, 23(2), 123-132.

Widhiari, N., & Merkusiwati, N. (2015). Pengaruh rasio likuiditas, leverage, operating capacity, dan sales growth terhadap financial distress. *E-Jurnal Akuntansi Universitas Udayana*, 11(2), 456-469.

Wruck, K. H. (1990). Financial distress, reorganization, and organizational efficiency. *Journal of financial economics*, 27(2), 419-444.

Yeh, C.-C., Chi, D.-J., & Lin, Y.-R. (2014). Going-concern prediction using hybrid random forests and rough set approach. *Information Sciences*, 254, 98-110.

Zhang, Z., Wu, C., Qu, S., & Chen, X. (2022). An explainable artificial intelligence approach for financial distress prediction. *Information Processing & Management*, 59(4), 102988.

Zhao, H., Sinha, A. P., & Ge, W. (2009). Effects of feature construction on classification performance: An empirical study in bank failure prediction. *Expert Systems with Applications*, 36(2), 2633-2644.

Zmijewski, M. E. (1984). Methodological issues related to the estimation of financial distress prediction models. *Journal of accounting research*, 59-82.

PHỤ LỤC

Phụ lục 01. Đọc dữ liệu

	ticker	year	WCTA	EBITTA	SALESTA	OCFTL	TLTA	SIZE	GROWTH	GDP	CPI	PTB	FD
0	AAA	2015	0.323785	0.038363	0.8	-0.064317	0.5	7.578145	0.035	0.069872	0.006312	2.5	0
1	AAA	2016	0.182261	0.063028	0.7	0.037683	0.6	8.032035	0.328	0.066900	0.026682	4.4	0
2	AAA	2017	0.158435	0.089379	0.9	-0.027448	0.5	8.428581	0.898	0.069402	0.035203	4.5	0
3	AAA	2018	0.198831	0.050472	1.1	0.008573	0.5	8.926518	0.969	0.074650	0.035396	1.5	0
4	AAA	2019	0.321898	0.102917	1.2	0.103339	0.5	8.985570	0.156	0.073593	0.027958	1.1	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...
4755	YEG	2020	0.613718	-0.118412	0.9	-0.847525	0.1	7.233455	-0.161	0.028654	0.032209	1.7	1
4756	YEG	2021	0.731778	0.087464	0.8	-0.177778	0.1	7.224025	-0.114	0.025537	0.018347	2.2	1
4757	YEG	2022	0.426269	0.029009	0.3	-0.494012	0.1	7.123673	-0.709	0.081235	0.031565	0.8	1
4758	YEG	2023	0.417742	0.027419	0.2	-0.402516	0.1	7.528332	0.311	0.050464	0.032529	1.5	0
4759	YEG	2024	0.309590	0.055312	0.4	0.352419	0.2	7.829233	1.493	0.070900	0.036211	2.3	0

4760 rows × 13 columns

Nguồn: Tổng hợp từ tác giả

Phụ lục 02. Xem thông tin dữ liệu

```
<class 'pandas.core.frame.DataFrame'>
Index: 4760 entries, 0 to 5399
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  -
0   ticker      4760 non-null   object
1   WCTA        4760 non-null   float64
2   EBITTA      4760 non-null   float64
3   SALESTA     4760 non-null   float64
4   OCFTL       4760 non-null   float64
5   TLTA        4760 non-null   float64
6   SIZE        4760 non-null   float64
7   GROWTH      4760 non-null   float64
8   GDP         4760 non-null   float64
9   CPI         4760 non-null   float64
10  PTB         4760 non-null   float64
11  FD          4760 non-null   int64
dtypes: float64(10), int64(1), object(1)
```


Nguồn: Tổng hợp từ tác giả

Phụ lục 03. Thống kê mô tả dữ liệu

	WCTA	EBITTA	SALESTA	OCFTL	TLTA	SIZE	GROWTH	GDP	CPI	PTB	FD
count	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000	4760.000000
mean	0.467598	0.083754	1.082637	0.206789	0.216134	6.924465	0.142349	0.061121	0.028241	1.261501	0.084874
std	0.246105	0.082356	0.889478	0.548416	0.184228	1.629148	0.872488	0.018579	0.008887	1.029750	0.278723
min	-0.721311	-0.771963	0.000000	-4.000000	0.000000	2.639057	-0.993000	0.025537	0.006312	-0.900000	0.000000
25%	0.282463	0.039322	0.400000	-0.020300	0.100000	5.804381	-0.101000	0.050464	0.026682	0.600000	0.000000
50%	0.472681	0.071612	0.900000	0.104590	0.200000	6.887042	0.051000	0.069637	0.031887	1.000000	0.000000
75%	0.649890	0.115685	1.500000	0.326959	0.300000	7.897017	0.212000	0.073593	0.035203	1.600000	0.000000
max	1.000000	0.997026	5.900000	6.000000	0.900000	13.637106	24.675000	0.081235	0.036211	9.400000	1.000000

Nguồn: Tổng hợp từ tác giả

Phụ lục 04. Kết quả ma trận tương quan



Nguồn: Tổng hợp từ tác giả

Phụ lục 05. Kiểm tra đa cộng tuyến

	Variable	VIF
0	WCTA	1.669607
1	EBITTA	1.416067
2	SALESTA	1.205617
3	OCFTL	1.307257
4	TLTA	1.896120
5	SIZE	1.357663
6	GROWTH	1.014604
7	GDP	1.063724
8	CPI	1.042743
9	PTB	1.171884

Nguồn: Tổng hợp từ tác giả

Phụ lục 06. Cân bằng dữ liệu

```
from imblearn.over_sampling

# Loại các cột không cần thi
df_for_model = df_balanced.c

# Tách X và y
X = df_for_model.drop('FD',
y = df_for_model['FD']

# Áp dụng SMOTE
smote = SMOTE(sampling_strat
X_smote, y_smote = smote.fit

# Đưa dữ liệu SMOTE vào Data
X_smote_df = pd.DataFrame(X_
y_smote_df = pd.Series(y_smc

print("Dữ liệu trước khi SM
print(y.value_counts())
print("Dữ liệu sau khi SMOTE
print(y_smote.value_counts())
```

```
Dữ liệu trước khi SMOTE:
FD
0    4356
1     404
Name: count, dtype: int64
Dữ liệu sau khi SMOTE:
FD
1    4356
0    4356
Name: count, dtype: int64
```


Nguồn: Tổng hợp từ tác giả

Phụ lục 07. Kết quả các mô hình

Accuracy: 0.8193
AUC Score: 0.9029
Classification Report:

	precision	recall	f1-score	support
0	0.82	0.81	0.81	842
1	0.82	0.83	0.83	901
accuracy			0.82	1743
macro avg	0.82	0.82	0.82	1743
weighted avg	0.82	0.82	0.82	1743

Specificity: 0.8052
Confusion Matrix:
[[678 164]
[151 750]]



Phụ lục 07.1 Kết quả Hồi quy Logistic


Nguồn: Tổng hợp từ tác giả

Phụ lục 07.2 Kết quả Decision Tree

Accuracy: 0.8990
AUC Score: 0.8989
Classification Report:

	precision	recall	f1-score	support
0	0.90	0.89	0.90	842
1	0.90	0.90	0.90	901
accuracy			0.90	1743
macro avg	0.90	0.90	0.90	1743
weighted avg	0.90	0.90	0.90	1743

Specificity: 0.8943
Confusion Matrix:
[[753 89]
[87 814]]




Nguồn: Tổng hợp từ tác giả

Phụ lục 07.3 Kết quả Random Forest

Accuracy: 0.9593
AUC Score: 0.9936
Classification Report:

	precision	recall	f1-score	support
0	0.96	0.95	0.96	842
1	0.96	0.96	0.96	901
accuracy			0.96	1743
macro avg	0.96	0.96	0.96	1743
weighted avg	0.96	0.96	0.96	1743

Specificity: 0.9537
Confusion Matrix:
[[803 39]
[32 869]]




Nguồn: Tổng hợp từ tác giả

Phụ lục 07.4 Kết quả XGBoost

Accuracy: 0.9707
AUC Score: 0.9963
Classification Report:

	precision	recall	f1-score	support
0	0.96	0.98	0.97	842
1	0.98	0.96	0.97	901
accuracy			0.97	1743
macro avg	0.97	0.97	0.97	1743
weighted avg	0.97	0.97	0.97	1743

Specificity: 0.9798
Confusion Matrix:
[[825 17]
[34 867]]




Nguồn: Tổng hợp từ tác giả

Phụ lục 07.5 Kết quả ANN

Accuracy: 0.9002
AUC Score: 0.9626
Classification Report:


	precision	recall	f1-score	support
0	0.91	0.88	0.90	842
1	0.89	0.92	0.90	901
accuracy			0.90	1743
macro avg	0.90	0.90	0.90	1743
weighted avg	0.90	0.90	0.90	1743

Specificity: 0.8812
Confusion Matrix:
[[742 100]
[74 827]]




Nguồn: Tổng hợp từ tác giả

Phụ lục 08. Đường cong ROC tổng hợp




Nguồn: Tổng hợp từ tác giả



Phụ lục 09. Bar plot SHAP của mô hình XGBoost

Nguồn: Tổng hợp từ tác giả

Phụ lục 10. Beeswarm plot SHAP của mô hình XGBoost



Nguồn: Tổng hợp từ tác giả